机器学习中的数学

Mathematics for Machine Learning（中文版）

Marc Peter Deisenroth　A. Aldo Faisal　Cheng Soon Ong

王业奎等译

原书由 Cambridge University Press 出版（2020）。
本书为个人学习用途的中文译本，遵循 CC BY-NC-SA 许可。
原书可在 https://mml-book.com 自由下载。

目录

第一部分　第一部分　数学基础 **8**

第 1 章　引言与动机 **9**

1.1　为直觉寻找语言 9

1.2　阅读本书的两种方式 10

1.3　习题与反馈 12

第 2 章　线性代数 **14**

2.1　线性方程组 15

2.2　矩阵 18

2.2.1　矩阵的加法与乘法 19

2.2.2　逆矩阵与转置 20

2.2.3　数乘 22

2.2.4　线性方程组的紧凑表示 22

2.3　求解线性方程组 22

2.3.1　特解与通解 23

2.3.2　初等变换 24

2.3.3　减一技巧 27

2.3.4　求解线性方程组的算法 29

2.4　向量空间 29

2.4.1　群 29

2.4.2　向量空间 31

2.4.3　向量子空间 32

2.5　线性无关 33

2.6　基与秩 36

2.6.1　生成集与基 36

2.6.2　秩 38

2.7　线性映射 39

2.7.1　线性映射的矩阵表示 41

2.7.2　基变换 43

2.7.3　像与核 47

2.8　仿射空间 50

2.8.1 仿射子空间 50
2.8.2 仿射映射 51
2.9 延伸阅读 51

第 3 章 解析几何 **58**
3.1 范数 58
3.2 内积 60
3.2.1 点积 60
3.2.2 一般内积 60
3.2.3 对称正定矩阵 61
3.3 长度与距离 62
3.4 夹角与正交性 63
3.5 规范正交基 66
3.6 正交补 66
3.7 函数的内积 67
3.8 正交投影 68
3.8.1 到一维子空间（直线）上的投影 69
3.8.2 到一般子空间上的投影 72
3.8.3 Gram–Schmidt 正交化 74
3.8.4 到仿射子空间上的投影 75
3.9 旋转 76
3.9.1 $\mathbb{R}^2$ 中的旋转 77
3.9.2 $\mathbb{R}^3$ 中的旋转 78
3.9.3 n 维中的旋转 79
3.9.4 旋转的性质 79
3.10 延伸阅读 80

第 4 章 矩阵分解 **83**
4.1 行列式与迹 83
4.2 特征值与特征向量 89
4.3 Cholesky 分解 96
4.4 特征分解与对角化 97
4.5 奇异值分解 100
4.5.1 SVD 的几何直觉 100
4.5.2 SVD 的构造 102
4.5.3 特征分解与奇异值分解对比 105
4.6 矩阵逼近 108
4.7 矩阵谱系 111
4.8 延伸阅读 112
习题 113

第 5 章 向量微积分 **116**
5.1 一元函数的微分 117
5.1.1 Taylor 级数 118
5.1.2 微分法则 121
5.2 偏导数与梯度 122
5.2.1 偏微分的基本法则 123
5.2.2 链式法则 123
5.3 向量值函数的梯度 124
5.4 矩阵的梯度 129
5.5 计算梯度的有用恒等式 131
5.6 反向传播与自动微分 131
5.6.1 深度网络中的梯度 132
5.6.2 自动微分 133
5.7 高阶导数 135
5.8 线性化与多元 Taylor 级数 136
5.9 延伸阅读 139
习题 140

第 6 章 概率与分布 **145**
6.1 构造概率空间 146
6.1.1 哲学问题 146
6.1.2 概率与随机变量 147
6.1.3 统计学 148
6.2 离散与连续概率 149
6.2.1 离散概率 149
6.2.2 连续概率 150
6.2.3 离散与连续分布对比 151
6.3 求和规则、乘积规则与贝叶斯定理 152
6.4 汇总统计量与独立性 154
6.4.1 均值与协方差 154
6.4.2 经验均值与协方差 158
6.4.3 方差的三种表达式 158
6.4.4 随机变量的和与变换 159
6.4.5 统计独立性 159
6.4.6 随机变量的内积 160
6.5 高斯分布 161
6.5.1 高斯的边缘分布与条件分布仍是高斯 162
6.5.2 高斯密度的乘积 164
6.5.3 求和与线性变换 164
6.5.4 从多元高斯分布采样 166

6.6 共轭性与指数族 167
6.6.1 共轭性 169
6.6.2 充分统计量 170
6.6.3 指数族 171
6.7 变量替换/逆变换 173
6.7.1 分布函数技巧 174
6.7.2 变量替换 175
6.8 拓展阅读 177
习题 178

第 7 章 连续优化 181
7.1 用梯度下降做优化 182
7.1.1 步长 183
7.1.2 带动量的梯度下降 185
7.1.3 随机梯度下降 185
7.2 约束优化与拉格朗日乘子 186
7.3 凸优化 189
7.3.1 线性规划 192
7.3.2 二次规划 192
7.3.3 勒让德–芬切尔变换与凸共轭 194
7.4 拓展阅读 196
习题 197

第二部分 第二部分 机器学习核心问题 199

第 8 章 当模型遇见数据 200
8.1 数据、模型与学习 200
8.1.1 作为向量的数据 200
8.1.2 作为函数的模型 202
8.1.3 作为概率分布的模型 202
8.1.4 学习即寻找参数 203
8.2 经验风险最小化 204
8.2.1 函数的假设类 205
8.2.2 用于训练的损失函数 205
8.2.3 用正则化缓解过拟合 206
8.2.4 用交叉验证评估泛化性能 207
8.2.5 拓展阅读 208
8.3 参数估计 209
8.3.1 最大似然估计 209
8.3.2 最大后验估计 210

8.3.3 模型拟合 . . . 211
8.3.4 拓展阅读 . . . 213
8.4 概率建模与推断 . . . 213
8.4.1 概率模型 . . . 214
8.4.2 贝叶斯推断 . . . 214
8.4.3 隐变量模型 . . . 215
8.4.4 拓展阅读 . . . 216
8.5 有向图模型 . . . 217
8.5.1 图语义 . . . 217
8.5.2 条件独立性与 d-分离 . . . 219
8.5.3 拓展阅读 . . . 220
8.6 模型选择 . . . 221
8.6.1 嵌套交叉验证 . . . 221
8.6.2 贝叶斯模型选择 . . . 222
8.6.3 用于模型比较的贝叶斯因子 . . . 223
8.6.4 拓展阅读 . . . 224

第 9 章 线性回归 225
9.1 问题形式化 . . . 226
9.2 参数估计 . . . 227
9.2.1 最大似然估计 . . . 228
9.2.2 线性回归中的过拟合 . . . 231
9.2.3 最大后验估计 . . . 232
9.2.4 MAP 估计作为正则化 . . . 234
9.3 贝叶斯线性回归 . . . 235
9.3.1 模型 . . . 235
9.3.2 先验预测 . . . 235
9.3.3 后验分布 . . . 237
9.3.4 后验预测 . . . 239
9.3.5 计算边际似然 . . . 240
9.4 最大似然作为正交投影 . . . 242
9.5 进一步阅读 . . . 243

第 10 章 降维：主成分分析 245
10.1 问题设定 . . . 246
10.2 最大方差视角 . . . 247
10.2.1 方差最大的方向 . . . 248
10.2.2 方差最大的 M 维子空间 . . . 249
10.3 投影视角 . . . 251
10.3.1 设定与目标 . . . 251

10.3.2 寻找最优坐标 . . . 252
10.3.3 寻找主子空间的基 . . . 254
10.4 特征向量计算与低秩近似 . . . 256
10.4.1 基于低秩矩阵近似的 PCA . . . 257
10.4.2 实践要点 . . . 257
10.5 高维情形下的 PCA . . . 258
10.6 实践中 PCA 的关键步骤 . . . 258
10.7 隐变量视角 . . . 260
10.7.1 生成过程与概率模型 . . . 261
10.7.2 似然与联合分布 . . . 263
10.7.3 后验分布 . . . 264
10.8 拓展阅读 . . . 264

第 11 章 密度估计：高斯混合模型 268
11.1 高斯混合模型 . . . 269
11.2 通过最大似然学习参数 . . . 269
11.2.1 职责 . . . 271
11.2.2 更新均值 . . . 272
11.2.3 更新协方差 . . . 274
11.2.4 更新混合权重 . . . 276
11.3 EM 算法 . . . 277
11.4 隐变量视角 . . . 279
11.4.1 生成过程与概率模型 . . . 280
11.4.2 似然 . . . 281
11.4.3 后验分布 . . . 282
11.4.4 推广到完整数据集 . . . 283
11.4.5 再谈 EM 算法 . . . 283
11.5 延伸阅读 . . . 283

第 12 章 分类：支持向量机 286
12.1 可分超平面 . . . 287
12.2 原始支持向量机 . . . 288
12.2.1 间隔的概念 . . . 289
12.2.2 间隔的传统推导 . . . 290
12.2.3 为什么可以把间隔设为 1 . . . 291
12.2.4 软间隔 SVM：几何视角 . . . 292
12.2.5 软间隔 SVM：损失函数视角 . . . 293
12.3 对偶支持向量机 . . . 295
12.3.1 通过拉格朗日乘子实现凸对偶 . . . 295
12.3.2 对偶 SVM：凸包视角 . . . 297

12.4 核函数 298
12.5 数值解 300
12.6 延伸阅读 301

第一部分

第一部分　数学基础

第 1 章　引言与动机

原书p.11

机器学习旨在设计能够自动从数据中提取有价值信息的算法。这里的重点是“自动”：机器学习关心的是可应用于众多数据集、且能产出有意义结果的通用方法论。机器学习的核心有三个概念：数据（data）、模型（model）和学习（learning）。

数据

由于机器学习本质上是数据驱动的，数据处于机器学习的核心。机器学习的目标是设计通用方法论，从数据中提取有价值的模式，理想情况下无需太多领域专门知识。例如，给定一个大型文档语料库（如图书馆中的藏书），机器学习方法可用于自动发现跨文档共有的相关主题（Hoffman et al., 2010）。为实现这一目标，我们设计的模型通常与生成数据的过程相关，类似于所给定的数据集。例如，在回归（regression）设定中，模型会描述一个把输入映射为实值输出的函数。借用 Mitchell (1997) 的说法：如果一个模型在把数据纳入考量之后，其在给定任务上的性能得到提升，就称该模型从数据中进行了学习。我们的目标是找到能够很好地泛化到未来可能关注的、尚未见过的数据上的好模型。学习可以理解为：通过优化模型参数，自动在数据中寻找模式与结构的一种方式。

模型

学习

尽管机器学习已取得诸多成功案例，且设计和训练丰富、灵活的机器学习系统所需的软件唾手可得，但我们认为，机器学习的数学基础对于理解那些构建更复杂机器学习系统所依赖的基本原理十分重要。理解这些原理有助于创造新的机器学习解决方案、理解并调试已有方法，以及认识我们所使用的方法论本身固有的假设与局限。

1.1　为直觉寻找语言

原书p.12

我们在机器学习中经常面对的一个挑战是：概念和词语往往含糊不清，机器学习系统的某个特定组成部分可以被抽象为不同的数学概念。例如，“算法”（algorithm）一词在机器学习语境中至少有两种不同含义。第一种含义上，我们用“机器学习算法”这一短语指一个基于输入数据做出预测的系统。我们称这类算法为**预测器**（predictor）。第二种含义上，我们用完全相同的短语“机器学习算法”来指一个能够调整预测器某些内部参数、使其在未来未见的输入数据上表现良好的系统。这里我们把这种调整称为**训练**（training）一个系统。

预测器

训练

本书不会消除这种歧义，但我们想提前强调：根据语境的不同，同一表述可能含义不同。不过我们会尽量让语境足够清晰，以降低歧义程度。

本书第一部分介绍讨论机器学习系统三大组成部分（数据、模型、学习）所

需的数学概念与基础。我们在此简要勾勒这些组成部分，并在讨论完必要的数学概念后于第 8 章再次回到它们。

并非所有数据都是数值型的，但用数值形式来考虑数据通常是有用的。本书假设数据已经被适当地转换为可读入计算机程序的数值表示。因此，我们把数据看作向量（vector）。再举一个说明词语之微妙的例子：对向量至少有三种不同的理解方式——向量是一个数字数组（计算机科学视角）、向量是一个既有方向又有大小的箭头（物理学视角）、向量是一个满足加法和数乘运算的对象（数学视角）。

数据即向量

模型通常用于描述一个生成数据的过程，类似于手头的数据集。因此，好模型也可以被看作真实（未知）数据生成过程的简化版本，捕捉其中与建模数据、从中提取隐藏模式相关的方面。一个好模型随后便可用来预测现实世界中将会发生什么，而无需进行现实世界的实验。

模型

现在我们来到问题的关键，即机器学习的学习组成部分。假设给定一个数据集和一个合适的模型。训练模型意味着：利用可用数据，针对一个用于评判模型对训练数据预测优劣的效用函数（utility function），去优化模型的某些参数。大多数训练方法都可以被理解为类似爬山以登顶的过程。在这个类比中，山顶对应于某个期望性能度量的极大值。然而在实践中，我们关心的是模型在未见数据上表现良好。在已经见过的数据（训练数据）上表现好，可能只意味着我们找到了一种很好地记忆数据的方式。但这未必能很好地泛化到未见数据；而在实际应用中，我们常常需要让机器学习系统面对它从未遇到过的情形。

学习
原书p.13

我们在此总结本书涉及的机器学习主要概念：

- 我们把数据表示为向量。
- 我们选择一个合适的模型，要么采用概率视角，要么采用优化视角。
- 我们通过数值优化方法从可用数据中学习，目标是让模型在未参与训练的数据上表现良好。

1.2　阅读本书的两种方式

理解机器学习的数学，可以考虑两种策略：

自底向上（bottom-up）　从基础概念逐步构建到更高级的概念。在数学等更偏技术的领域，这通常是首选方式。其优点是读者在任何时候都能依赖先前学过的概念。遗憾的是，对实践者而言，许多基础概念本身并不特别有趣，而缺乏动机意味着大多数基础定义很快就会被遗忘。

自顶向下（top-down）　从实际需要向下钻取到更基本的要求。这种目标驱动方式的优点是读者始终清楚自己为何需要研究某个概念，所需知识路径清晰明确。其缺点是知识建立在可能并不牢靠的基础之上，读者不得不记住一堆自己无法理解的术语。

我们决定以模块化方式撰写本书，把（数学）基础概念与应用分离开来，从而使本书两种读法都成立。全书分为两部分：第一部分奠定数学基础；第二部分把第一部分的概念应用于一组基本机器学习问题，即图 1.1 所示的机器学习四大支柱：回归（regression）、降维（dimensionality reduction）、密度估计（density estimation）和分类（classification）。第一部分各章大多以前一章为基础，但如有必要，也可以跳过某一章反向研读。第二部分各章之间耦合松散，可任意顺序阅读。两部分之间有大量前后呼应的指引，把数学概念与机器学习算法联系起来

原书p.14

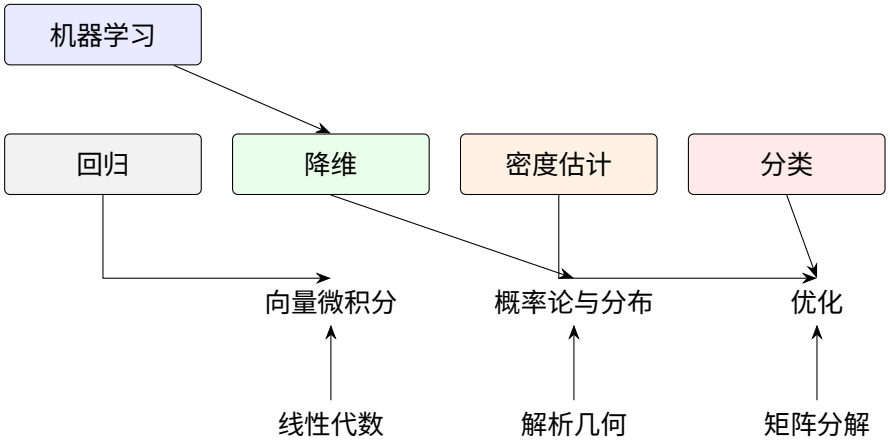


图 1.1: 机器学习的基础与四大支柱（对应原图 Figure 1.1，标签译为中文）。

当然，阅读本书的方式不止两种。大多数读者会结合自顶向下与自底向上两种方式：有时先打牢数学基本功再去攻克更复杂的概念，有时则依据机器学习的应用来选择主题。

第一部分是关于数学的

本书讨论的机器学习四大支柱（见图 1.1）需要坚实的数学基础，这由第一部分给出。我们把数值数据表示为向量，并把一张这样的数据表表示为矩阵。对向量与矩阵的研究称为线性代数（linear algebra），将在第 2 章介绍。把向量按列收集成矩阵也在该章讲述。

线性代数

给定表示现实世界中两个对象的两个向量，我们希望就它们的相似性做出论断。其想法是：相似的向量应被我们的机器学习算法（即预测器）预测为具有相似输出。为了把向量间相似性的想法形式化，我们需要引入一些运算：它们以两个向量为输入，返回一个表示二者相似性的数值。相似性与距离的构建是解析几何（analytic geometry）的核心，将在第 3 章讨论。

解析几何

第 4 章介绍矩阵与矩阵分解（matrix decomposition）的一些基本概念。矩阵上的某些运算在机器学习中极为有用，它们使我们能够直观地解释数据，并更高效地学习。

矩阵分解

我们常把数据视为对某个真实底层信号含噪声的观测。我们希望通过机器学习从噪声中辨识出信号。这要求我们拥有一套语言来量化“噪声”意味着什么。我们还常常希望拥有这样的预测器：它能让我们表达某种不确定性，例如

原书p.15

量化我们在某个特定测试数据点上对预测值的信心。不确定性的量化属于概率论（probability theory）的范畴，将在第 6 章讨论。

概率论

要训练机器学习模型，我们通常会找到使某个性能度量最大化的参数。许多优化技术需要梯度（gradient）这一概念，它告诉我们朝哪个方向搜索解。第 5 章讲向量微积分（vector calculus），详细介绍梯度概念；随后我们将在第 7 章使用梯度，在那里讨论用以求函数极大/极小值的优化（optimization）。

向量微积分

优化

第二部分是关于机器学习的

本书第二部分介绍如图 1.1 所示的机器学习四大支柱。我们说明第一部分引入的数学概念如何构成每一支柱的基础。大致而言，各章按难度递增排序。

第 8 章中，我们以数学方式重述机器学习的三个组成部分（数据、模型、参数估计）。此外，我们就如何构建实验设置给出若干指引，以防对机器学习系统做出过于乐观的评估。请记住，目标是构建一个在未见数据上表现良好的预测器。

第 9 章将仔细考察线性回归（linear regression）：我们的目标是找到把输入 $x \in \mathbb{R}^D$ 映射为相应观测函数值 $y \in \mathbb{R}$ 的函数，后者可解释为各自输入的标签。我们将通过最大似然估计与最大后验估计讨论经典模型拟合（参数估计），以及贝叶斯线性回归——在后一种方法中我们对参数做积分积出，而非对其进行优化。

线性回归

第 10 章聚焦于图 1.1 中的第二根支柱——降维（dimensionality reduction），使用主成分分析（principal component analysis, PCA）。降维的核心目标是为高维数据 $x \in \mathbb{R}^D$ 找到紧凑的低维表示，它通常比原始数据更易于分析。与回归不同，降维只关心对数据建模——数据点 x 没有对应的标签。

第 11 章进入第三根支柱：密度估计（density estimation）。密度估计的目标是找到一个描述给定数据集的概率分布。我们将聚焦高斯混合模型（Gaussian mixture model），并讨论一种用于确定该模型参数的迭代格式。与降维一样，数据点 $x \in \mathbb{R}^D$ 没有标签关联；但我们并不寻求数据的低维表示，而是关心一个描述数据的密度模型。

密度估计

第 12 章以对第四根支柱的深入讨论作结：分类（classification）。我们将在支持向量机（support vector machine, SVM）的语境下讨论分类。与回归（第 9 章）类似，我们有输入 x 和相应标签 y；但与标签取实数值的回归不同，分类中的标签是整数，需要特别小心。

原书p.16
分类

1.3　习题与反馈

我们在第一部分提供了一些习题，大多可纸笔完成。第二部分则提供编程教程（Jupyter notebook），用以探究本书所讨论机器学习算法的若干性质。

我们感谢剑桥大学出版社大力支持我们推动教育普及的目标——本书可在 `https://mml-book.com` 自由下载，教程、勘误和补充材料亦可在该站获取。如

发现错误，可通过上述网址报告并提供反馈。

第 2 章　线性代数

原书p.17

在把直观概念形式化时，一种常见做法是：构造一组对象（符号）以及一组用来操作这些对象的规则。这就是所谓的代数（algebra）。线性代数研究的是向量以及用来操作向量的某些规则。我们许多人在学校里熟悉的那种向量称为“几何向量”，通常用字母上方的一个小箭头来表示，例如 $\vec{x}$ 和 $\vec{y}$。本书讨论更一般的向量概念，并用粗体字母表示它们，例如 **x** 和 **y**。

代数

一般而言，向量是一类特殊的对象：它们可以相加，也可以乘以标量，运算结果仍是同类对象。从抽象数学的观点看，任何满足这两条性质的对象都可以视为向量。下面是几类这样的向量对象：

1. 几何向量。这个向量例子或许在中学数学和物理中就很熟悉。几何向量——见图 2.1(a)——是有向线段，（至少在二维中）可以画出来。两个几何向量 $\vec{x}, \vec{y}$ 可以相加，使得 $\vec{x} + \vec{y} = \vec{z}$ 仍是一个几何向量。此外，乘以标量 $\lambda\vec{x}$，$\lambda \in \mathbb{R}$，也仍是一个几何向量；事实上它就是原向量按 λ 缩放后的结果。因此，几何向量是前面引入的向量概念的实例。把向量解释为几何向量，使我们能够借助关于方向和大小的直觉来对数学运算进行推理。

2. 多项式也是向量；见图 2.1(b)：两个多项式可以相加，结果仍是一个多项式；它们也可以乘以标量 $\lambda \in \mathbb{R}$，结果同样是一个多项式。因此，多项式是（相当不寻常的）向量实例。注意，多项式与几何向量很不相同：几何向量是具体的“图形”，而多项式是抽象概念。但就前述定义而言，它们都是向量。

原书p.18

3. 音频信号是向量。音频信号表示为一串数。我们可以把音频信号相加，其和是一个新的音频信号；把一个音频信号缩放，得到的仍是音频信号。因此，音频信号也是一种向量。

4. $\mathbb{R}^n$ 中的元素（n 个实数构成的元组）是向量。$\mathbb{R}^n$ 比多项式更抽象，而它正是本书关注的对象。例如，

$$\mathbf{a} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \in \mathbb{R}^3 \tag{2.1}$$

就是一个三元数组的例子。把两个向量 $\mathbf{a}, \mathbf{b} \in \mathbb{R}^n$ 按分量相加，得到另一个向量：$\mathbf{a} + \mathbf{b} = \mathbf{c} \in \mathbb{R}^n$。此外，把 $\mathbf{a} \in \mathbb{R}^n$ 乘以 $\lambda \in \mathbb{R}$，得到缩放后的向

量 $\lambda \mathbf{a} \in \mathbb{R}^n$。把向量看作 $\mathbb{R}^n$ 中的元素还有一个额外好处：它与计算机上的实数数组大致对应。许多编程语言支持数组运算，从而可以方便地实现涉及向量运算的算法。

注意检查数组运算是否真的是向量运算

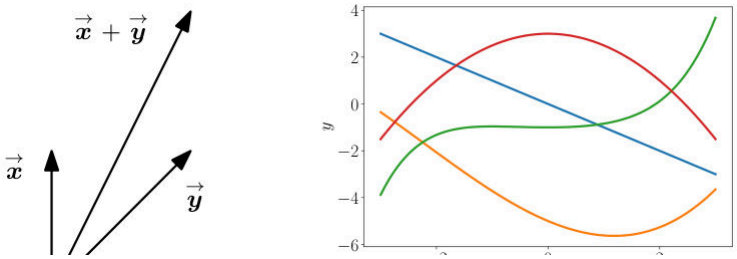


图 2.1: 不同类型的向量。向量可以是出人意料的对象，包括 (a) 几何向量与 (b) 多项式。

线性代数关注这些向量概念之间的共性：我们可以把它们相加、用标量去乘。由于线性代数中的大多数算法都是在 $\mathbb{R}^n$ 中表述的，我们将主要讨论 $\mathbb{R}^n$ 中的向量。在第 8 章我们会看到，常把数据表示为 $\mathbb{R}^n$ 中的向量。本书只讨论有限维向量空间，此时任意一种向量都与 $\mathbb{R}^n$ 一一对应。在方便时，我们会借用关于几何向量的直觉，并考虑基于数组的算法。

数学中的一个重要思想是“封闭性”（closure）。它问的是：由我所设定的运算，所有可能产生的结果构成的集合是什么？对向量而言：从一小撮向量出发，把它们彼此相加、再做缩放，最终能得到的向量集合是什么？这就引出了向量空间（第 2.4 节）。向量空间及其性质是机器学习许多内容的基础。本章引入的概念汇总于图 2.2。

本章主要基于 Drumm and Weil (2001)、Strang (2003)、Hogben (2013)、Liesen and Mehrmann (2015) 的讲义与教材，以及 Pavel Grinfeld 的线性代数系列视频。其他优秀资源还有 Gilbert Strang 在 MIT 的线性代数课程和 3Blue1Brown 的线性代数系列。

线性代数视频资源 原书 p.19

线性代数在机器学习和一般数学中都扮演重要角色。本章引入的概念将在第 3 章进一步扩展到几何。在第 5 章我们将讨论向量微积分，在那里熟练掌握矩阵运算非常关键。在第 10 章，我们将使用投影（见第 3.8 节）结合主成分分析（PCA）进行降维。在第 9 章我们将讨论线性回归，其中线性代数在求解最小二乘问题中处于核心地位。

2.1　线性方程组

线性方程组在线性代数中处于中心地位。许多问题都可以表述为线性方程组，而线性代数给了我们求解它们的工具。

例 2.1 某公司生产产品 $N_1, \ldots, N_n$，生产它们需要资源 $R_1, \ldots, R_m$。生产一单位产品 N_j 需要消耗 a_{ij} 单位资源 R_i，其中 $i = 1, \ldots, m$，$j = 1, \ldots, n$。目

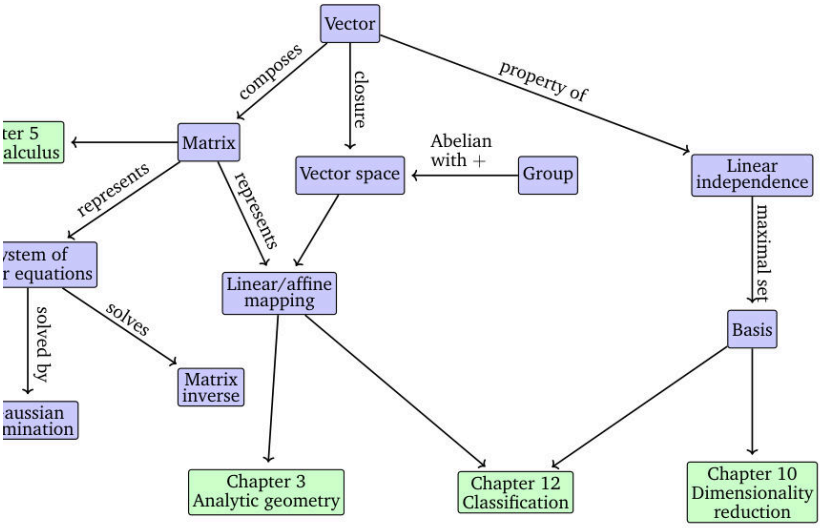


图 2.2: 本章引入概念的思维导图，以及这些概念在本书其他部分的应用位置。

标是找到一个最优生产计划，即在资源 R_i 总量为 b_i 单位、且（理想情况下）不留任何剩余资源的条件下，产品 N_j 应生产多少单位 x_j。如果我们生产 $x_1, \ldots, x_n$ 单位相应产品，则总共需要

原书p.20

$$a_{i1}x_1 + \cdots + a_{in}x_n \tag{2.2}$$

单位资源 R_i。因此，一个最优生产计划 $(x_1, \ldots, x_n) \in \mathbb{R}^n$ 必须满足如下方程组：

$$\begin{cases} a_{11}x_1 + \cdots + a_{1n}x_n = b_1 \\ \quad \vdots \\ a_{m1}x_1 + \cdots + a_{mn}x_n = b_m \end{cases} \tag{2.3}$$

其中 $a_{ij} \in \mathbb{R}$，$b_i \in \mathbb{R}$。式 (2.3) 是线性方程组的一般形式，$x_1, \ldots, x_n$ 是该方程组的未知量。每个满足 (2.3) 的 n 元组 $(x_1, \ldots, x_n) \in \mathbb{R}^n$ 都是该线性方程组的一个解。

线性方程组

例 2.2 线性方程组

$$\begin{cases} x_1 + x_2 + x_3 = 3 \\ x_1 - x_2 + 2x_3 = 2 \\ 2x_1 + 3x_3 = 1 \end{cases} \tag{2.4}$$

无解：把前两个方程相加得到 $2x_1 + 3x_3 = 5$，与第三个方程矛盾。

再看方程组

$$\begin{cases} x_1 + x_2 + x_3 = 3 \\ x_1 - x_2 + 2x_3 = 2 \\ x_2 + x_3 = 2 \end{cases} \tag{2.5}$$

由第一、第三个方程得 $x_1 = 1$。由 $(1)+(2)$ 得 $2x_1 + 3x_3 = 5$，即 $x_3 = 1$。再由 (3) 得 $x_2 = 1$。因此 $(1,1,1)$ 是唯一可能的解（请代入验证 $(1,1,1)$ 确实是解）。

第三个例子是

$$\begin{cases} x_1 + x_2 + x_3 = 3 \\ x_1 - x_2 + 2x_3 = 2 \\ 2x_1 + 3x_3 = 5 \end{cases} \tag{2.6}$$

由于 $(1)+(2) = (3)$，第三个方程是多余的，可以省略。由 (1)、(2) 得 $2x_1 = 5 - 3x_3$ 和 $2x_2 = 1 + x_3$。我们把 $x_3 = a \in \mathbb{R}$ 取作自由变量，于是任意三元组

$$\left(\frac{5}{2} - \frac{3}{2}a,\ \frac{1}{2} + \frac{1}{2}a,\ a\right), \qquad a \in \mathbb{R} \tag{2.7}$$

都是该线性方程组的解，即我们得到一个含无穷多解的解集。

一般而言，实系数线性方程组要么无解，要么恰有一解，要么有无穷多解。当我们无法精确求解线性方程组时，线性回归（第 9 章）求解的就是例 2.1 的一个变体。

[线性方程组的几何解释] 对于含两个变量 x_1, x_2 的线性方程组，每个线性方程都在 x_1x_2 平面上定义一条直线。由于方程组的解必须同时满足所有方程，解集就是这些直线的交集。这个交集可以是一条直线（当各方程描述同一条直线时）、一个点，或空集（当直线平行时）。图 2.3 以方程组

$$\begin{cases} 4x_1 + 4x_2 = 5 \\ 2x_1 - 4x_2 = 1 \end{cases} \tag{2.8}$$

为例给出了图示，其解空间是点 $(x_1, x_2) = (1, \frac{1}{4})$。类似地，对三个变量，每个线性方程在三维空间中确定一个平面。当我们求这些平面的交（即同时满足所有方程）时，得到的解集可以是平面、直线、点或空集（当平面没有公共交时）。 原书p.21

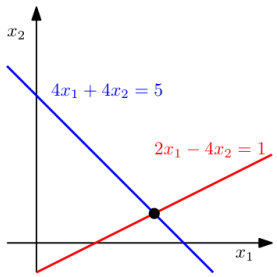


图 2.3: 两个变量、两个方程的线性方程组，其解空间可几何地理解为两条直线的交点。每个线性方程代表一条直线。

为了系统地求解线性方程组，我们引入一种有用的紧凑记号：把系数 a_{ij} 收集成向量，再把这些向量收集成矩阵。也就是说，把 (2.3) 写成如下形式：

$$\begin{bmatrix} a_{11} \\ \vdots \\ a_{m1} \end{bmatrix} x_1 + \begin{bmatrix} a_{12} \\ \vdots \\ a_{m2} \end{bmatrix} x_2 + \cdots + \begin{bmatrix} a_{1n} \\ \vdots \\ a_{mn} \end{bmatrix} x_n = \begin{bmatrix} b_1 \\ \vdots \\ b_m \end{bmatrix} \tag{2.9}$$

原书p.22

$$\iff \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} b_1 \\ \vdots \\ b_m \end{bmatrix}. \tag{2.10}$$

下面我们仔细考察这些矩阵并定义运算规则。我们将在第 2.3 节回到求解线性方程组的问题。

2.2　矩阵

矩阵在线性代数中处于中心地位。它们既可用来紧凑地表示线性方程组，也可用来表示线性函数（线性映射），这一点将在第 2.7 节看到。在讨论这些有趣话题之前，先定义什么是矩阵、以及可以对矩阵做哪些运算。矩阵的更多性质将在第 4 章介绍。

定义 2.1 (矩阵). 设 $m, n \in \mathbb{N}$，一个实值 (m, n) 矩阵 $\mathbf{A}$ 是元素 a_{ij}（$i = 1, \ldots, m$，$j = 1, \ldots, n$）构成的 $m \cdot n$ 元组，按 m 行 n 列的矩形阵列排列：

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}, \qquad a_{ij} \in \mathbb{R}. \tag{2.11}$$

矩阵
列向量

按惯例，$(1, n)$ 矩阵称为行（row），$(m, 1)$ 矩阵称为列（column）。这些特殊矩阵也称为行/列向量。$\mathbb{R}^{m \times n}$ 是所有实值 (m, n) 矩阵的集合。把矩阵 $\mathbf{A} \in \mathbb{R}^{m \times n}$ 的全部 n 列堆叠成一个长向量，可等价地表示为 $\mathbf{a} \in \mathbb{R}^{mn}$；见图 2.4。

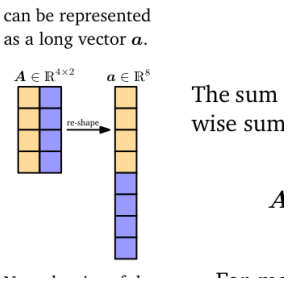


图 2.4: 把矩阵 $\mathbf{A}$ 的各列堆叠起来，可将其表示为一个长向量 $\mathbf{a}$。

2.2.1　矩阵的加法与乘法

两个矩阵 $\mathbf{A}\in\mathbb{R}^{m\times n}$、$\mathbf{B}\in\mathbb{R}^{m\times n}$ 之和定义为逐元素相加，即

$$\mathbf{A}+\mathbf{B}:=\begin{bmatrix} a_{11}+b_{11} & \cdots & a_{1n}+b_{1n}\\ \vdots & & \vdots\\ a_{m1}+b_{m1} & \cdots & a_{mn}+b_{mn}\end{bmatrix}\in\mathbb{R}^{m\times n}. \tag{2.12}$$

对矩阵 $\mathbf{A}\in\mathbb{R}^{m\times n}$、$\mathbf{B}\in\mathbb{R}^{n\times k}$，乘积 $\mathbf{C}=\mathbf{AB}\in\mathbb{R}^{m\times k}$ 的元素 c_{ij} 计算为

$$c_{ij}=\sum_{l=1}^{n}a_{il}b_{lj},\qquad i=1,\dots,m,\ j=1,\dots,k. \tag{2.13}$$

注意矩阵的尺寸

原书p.23

m('il,lj',A,B)

也就是说，要计算元素 c_{ij}，就把 $\mathbf{A}$ 的第 i 行与 $\mathbf{B}$ 的第 j 列对应元素相乘再求和。在第 3.2 节我们将把这称为相应行与列的点积。当需要明确表示做乘法时，我们用记号 $\mathbf{A}\cdot\mathbf{B}$（显式写出“$\cdot$”）。

两个向量、A、B 的点积常记作 aTb 或⟨a, b⟩

矩阵只有在“相邻”维度匹配时才能相乘。例如，$n\times k$ 矩阵 $\mathbf{A}$ 只能从左侧与 $k\times m$ 矩阵 $\mathbf{B}$ 相乘：

$$\underbrace{\mathbf{A}}_{n\times k}\underbrace{\mathbf{B}}_{k\times m}=\underbrace{\mathbf{C}}_{n\times m} \tag{2.14}$$

当 $m\neq n$ 时乘积 $\mathbf{BA}$ 没有定义，因为相邻维度不匹配。

矩阵乘法并不是对矩阵元素逐元素进行的运算，即 $c_{ij}\neq a_{ij}b_{ij}$（即使 $\mathbf{A},\mathbf{B}$ 尺寸选得合适）。这种逐元素相乘在编程语言中（对多维数组做乘法时）很常见，称为 Hadamard 积。

Hadamard 积

例 2.3　对 $\mathbf{A}=\begin{bmatrix}1&2&3\\3&2&1\end{bmatrix}\in\mathbb{R}^{2\times3}$，$\mathbf{B}=\begin{bmatrix}0&2\\1&-1\\0&1\end{bmatrix}\in\mathbb{R}^{3\times2}$，有

$$\mathbf{AB}=\begin{bmatrix}1&2&3\\3&2&1\end{bmatrix}\begin{bmatrix}0&2\\1&-1\\0&1\end{bmatrix}=\begin{bmatrix}2&3\\2&5\end{bmatrix}\in\mathbb{R}^{2\times2}, \tag{2.15}$$

$$\mathbf{BA}=\begin{bmatrix}0&2\\1&-1\\0&1\end{bmatrix}\begin{bmatrix}1&2&3\\3&2&1\end{bmatrix}=\begin{bmatrix}6&4&2\\-2&0&2\\3&2&1\end{bmatrix}\in\mathbb{R}^{3\times3}. \tag{2.16}$$

由本例已经可以看出矩阵乘法不满足交换律，即 $\mathbf{AB}\neq\mathbf{BA}$；另见图 2.5。

原书p.24

定义 2.2 (单位矩阵). 在 $\mathbb{R}^{n\times n}$ 中，把单位矩阵 $\mathbf{I}_n$ 定义为对角线上全为 1、其余

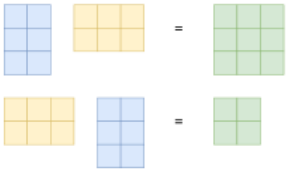


图 2.5: 即使 **AB** 与 **BA** 都有定义，结果的维度也可能不同。

位置全为 0 的 $n \times n$ 矩阵：

单位矩阵

$$\mathbf{I}_n := \begin{bmatrix} 1 & 0 & \cdots & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots & & \vdots \\ 0 & 0 & \cdots & 1 & \cdots & 0 \\ \vdots & \vdots & & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 & \cdots & 1 \end{bmatrix} \in \mathbb{R}^{n \times n} \tag{2.17}$$

现在我们定义了矩阵乘法、矩阵加法和单位矩阵，下面看矩阵的一些性质：

结合律：

$$\forall \mathbf{A} \in \mathbb{R}^{m \times n},\ \mathbf{B} \in \mathbb{R}^{n \times p},\ \mathbf{C} \in \mathbb{R}^{p \times q}: \qquad (\mathbf{AB})\mathbf{C} = \mathbf{A}(\mathbf{BC}) \tag{2.18}$$

结合律

分配律：

$$\forall \mathbf{A}, \mathbf{B} \in \mathbb{R}^{m \times n},\ \mathbf{C}, \mathbf{D} \in \mathbb{R}^{n \times p}: \qquad (\mathbf{A} + \mathbf{B})\mathbf{C} = \mathbf{AC} + \mathbf{BC} \tag{2.19a}$$

$$\mathbf{A}(\mathbf{C} + \mathbf{D}) = \mathbf{AC} + \mathbf{AD} \tag{2.19b}$$

分配律

与单位矩阵相乘：

$$\forall \mathbf{A} \in \mathbb{R}^{m \times n}: \qquad \mathbf{I}_m \mathbf{A} = \mathbf{A}\mathbf{I}_n = \mathbf{A}. \tag{2.20}$$

注意当 $m \neq n$ 时 $\mathbf{I}_m \neq \mathbf{I}_n$。

2.2.2　逆矩阵与转置

定义 2.3 (逆矩阵). 考虑方阵 $\mathbf{A} \in \mathbb{R}^{n \times n}$。若矩阵 $\mathbf{B} \in \mathbb{R}^{n \times n}$ 满足 $\mathbf{AB} = \mathbf{I}_n = \mathbf{BA}$，则称 **B** 为 **A** 的逆矩阵，记作 $\mathbf{A}^{-1}$。

逆矩阵的行列数相同

遗憾的是，并非每个矩阵 **A** 都有逆矩阵 $\mathbf{A}^{-1}$。若逆存在，称 **A** 是正则的（regular）/可逆的（invertible）/非奇异的（nonsingular）；否则称奇异的（singular）/不可逆的（noninvertible）。逆矩阵若存在则唯一。第 2.3 节将讨论通过求解线性方程组来计算逆矩阵的一般方法。

奇异矩阵

[2×2 矩阵逆的存在性] 考虑矩阵

$$\mathbf{A} := \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} \in \mathbb{R}^{2 \times 2}. \tag{2.21}$$

把 **A** 乘以

$$\mathbf{A}' := \begin{bmatrix} a_{22} & -a_{12} \\ -a_{21} & a_{11} \end{bmatrix} \tag{2.22}$$

得到

$$\mathbf{A}\mathbf{A}' = \begin{bmatrix} a_{11}a_{22} - a_{12}a_{21} & 0 \\ 0 & a_{11}a_{22} - a_{12}a_{21} \end{bmatrix} = (a_{11}a_{22} - a_{12}a_{21})\mathbf{I}. \tag{2.23}$$

因此

$$\mathbf{A}^{-1} = \frac{1}{a_{11}a_{22} - a_{12}a_{21}} \begin{bmatrix} a_{22} & -a_{12} \\ -a_{21} & a_{11} \end{bmatrix} \tag{2.24}$$

当且仅当 $a_{11}a_{22} - a_{12}a_{21} \neq 0$ 时成立。在第 4.1 节我们将看到 $a_{11}a_{22} - a_{12}a_{21}$ 就是 2×2 矩阵的行列式。此外，一般可用行列式来判断矩阵是否可逆。 原书p.25

例 2.4（逆矩阵） 矩阵

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 1 \\ 4 & 4 & 5 \\ 6 & 7 & 7 \end{bmatrix}, \qquad \mathbf{B} = \begin{bmatrix} -7 & -7 & 6 \\ 2 & 1 & -1 \\ 4 & 5 & -4 \end{bmatrix} \tag{2.25}$$

互为逆矩阵，因为 $\mathbf{A}\mathbf{B} = \mathbf{I} = \mathbf{B}\mathbf{A}$。

定义 2.4 (转置). 对 $\mathbf{A} \in \mathbb{R}^{m \times n}$，满足 $b_{ij} = a_{ji}$ 的矩阵 $\mathbf{B} \in \mathbb{R}^{n \times m}$ 称为 **A** 的转置，记作 $\mathbf{B} = \mathbf{A}^\top$。 转置

矩阵 **A** 的主对角线（有时亦称“principle diagonal”“primary diagonal”“leading diagonal”或“major diagonal”）是所有满足 $i = j$ 的元素 A_{ij} 的集合。

一般地，$\mathbf{A}^\top$ 可由把 **A** 的各列写成 $\mathbf{A}^\top$ 的各行得到。下面是逆与转置的重要性质：

$$\mathbf{A}\mathbf{A}^{-1} = \mathbf{I} = \mathbf{A}^{-1}\mathbf{A} \tag{2.26}$$

$$(\mathbf{A}\mathbf{B})^{-1} = \mathbf{B}^{-1}\mathbf{A}^{-1} \tag{2.27}$$

$$(\mathbf{A} + \mathbf{B})^{-1} \neq \mathbf{A}^{-1} + \mathbf{B}^{-1} \tag{2.28}$$

$$(\mathbf{A}^\top)^\top = \mathbf{A} \tag{2.29}$$

$$(\mathbf{A}\mathbf{B})^\top = \mathbf{B}^\top\mathbf{A}^\top \tag{2.30}$$

$$(\mathbf{A} + \mathbf{B})^\top = \mathbf{A}^\top + \mathbf{B}^\top \tag{2.31}$$

(2.28) 的标量情形是 $\frac{1}{2+4} = \frac{1}{6} = \frac{1}{2} + \frac{1}{4}$

定义 2.5 (对称矩阵). 若矩阵 $\mathbf{A} \in \mathbb{R}^{n \times n}$ 满足 $\mathbf{A} = \mathbf{A}^\top$，则称它是对称的。 对称矩阵

注意只有 (n, n) 矩阵才能对称。一般地，(n, n) 矩阵也称为方阵，因为它的行数与列数相同。此外，若 **A** 可逆，则 $\mathbf{A}^\top$ 也可逆，且 $(\mathbf{A}^{-1})^\top = (\mathbf{A}^\top)^{-1} =: \mathbf{A}^{-\top}$

[对称矩阵的和与积] 对称矩阵 $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times n}$ 之和总是对称的。然而，虽然它们的积总有定义，却一般不对称：

$$\begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 0 & 0 \end{bmatrix}. \tag{2.32}$$

2.2.3　数乘

来看矩阵乘以标量 $\lambda \in \mathbb{R}$ 时会发生什么。设 $\mathbf{A} \in \mathbb{R}^{m\times n}$，$\lambda \in \mathbb{R}$。则 $\lambda\mathbf{A} = \mathbf{K}$，其中 $K_{ij} = \lambda a_{ij}$。实际上，λ 缩放 $\mathbf{A}$ 的每个元素。对 $\lambda, \psi \in \mathbb{R}$，有：

原书p.26

结合律 $(\lambda\psi)\mathbf{C} = \lambda(\psi\mathbf{C})$，$\mathbf{C} \in \mathbb{R}^{m\times n}$；$\lambda(\mathbf{B}\mathbf{C}) = (\lambda\mathbf{B})\mathbf{C} = \mathbf{B}(\lambda\mathbf{C}) = (\mathbf{B}\mathbf{C})\lambda$，$\mathbf{B} \in \mathbb{R}^{m\times n}, \mathbf{C} \in \mathbb{R}^{n\times k}$。注意这让我们可以随意移动标量。$(\lambda\mathbf{C})^\top = \mathbf{C}^\top\lambda^\top = \mathbf{C}^\top\lambda = \lambda\mathbf{C}^\top$，因为对所有 $\lambda \in \mathbb{R}$ 有 $\lambda = \lambda^\top$。

结合律

分配律 $(\lambda+\psi)\mathbf{C} = \lambda\mathbf{C} + \psi\mathbf{C}$，$\mathbf{C} \in \mathbb{R}^{m\times n}$；$\lambda(\mathbf{B}+\mathbf{C}) = \lambda\mathbf{B} + \lambda\mathbf{C}$，$\mathbf{B}, \mathbf{C} \in \mathbb{R}^{m\times n}$。

分配律

例 2.5（分配律） 若定义

$$\mathbf{C} := \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}, \tag{2.33}$$

则对任意 $\lambda, \psi \in \mathbb{R}$ 有

$$(\lambda+\psi)\mathbf{C} = \begin{bmatrix} (\lambda+\psi)1 & (\lambda+\psi)2 \\ (\lambda+\psi)3 & (\lambda+\psi)4 \end{bmatrix} = \begin{bmatrix} \lambda+\psi & 2\lambda+2\psi \\ 3\lambda+3\psi & 4\lambda+4\psi \end{bmatrix} \tag{2.34a}$$

$$= \begin{bmatrix} \lambda & 2\lambda \\ 3\lambda & 4\lambda \end{bmatrix} + \begin{bmatrix} \psi & 2\psi \\ 3\psi & 4\psi \end{bmatrix} = \lambda\mathbf{C} + \psi\mathbf{C}. \tag{2.34b}$$

2.2.4　线性方程组的紧凑表示

考虑线性方程组

$$\begin{cases} 2x_1 + 3x_2 + 5x_3 = 1 \\ 4x_1 - 2x_2 - 7x_3 = 8 \\ 9x_1 + 5x_2 - 3x_3 = 2 \end{cases} \tag{2.35}$$

利用矩阵乘法规则，可把它写成更紧凑的形式：

$$\begin{bmatrix} 2 & 3 & 5 \\ 4 & -2 & -7 \\ 9 & 5 & -3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 1 \\ 8 \\ 2 \end{bmatrix}. \tag{2.36}$$

注意 x_1 缩放第一列，x_2 缩放第二列，x_3 缩放第三列。

一般地，线性方程组可紧凑地写成矩阵形式 $\mathbf{A}\mathbf{x} = \mathbf{b}$；见 (2.3)。乘积 $\mathbf{A}\mathbf{x}$ 是 $\mathbf{A}$ 各列的一个（线性）组合。我们将在第 2.5 节详细讨论线性组合。

2.3　求解线性方程组

原书p.27

在 (2.3) 中我们给出了方程组的一般形式，即

$$\begin{cases} a_{11}x_1 + \cdots + a_{1n}x_n = b_1 \\ \quad\vdots \\ a_{m1}x_1 + \cdots + a_{mn}x_n = b_m \end{cases} \tag{2.37}$$

其中 $a_{ij} \in \mathbb{R}$、$b_i \in \mathbb{R}$ 是已知常数，x_j 是未知量，$i = 1, \dots, m$，$j = 1, \dots, n$。至此我们看到：矩阵可用来紧凑地表示线性方程组，从而写成 $\mathbf{Ax} = \mathbf{b}$，见 (2.10)；我们还定义了矩阵的基本运算，如加法和乘法。下面聚焦于求解线性方程组，并给出一个求逆矩阵的算法。

2.3.1　特解与通解

在讨论如何一般地求解线性方程组之前，先看一个例子。考虑方程组

$$\begin{bmatrix} 1 & 0 & 8 & -4 \\ 0 & 1 & 2 & 12 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} 42 \\ 8 \end{bmatrix}. \tag{2.38}$$

该方程组有两个方程、四个未知量，因此一般预期有无穷多解。这个方程组特别简单：前两列由 1 和 0 组成。记住我们要找标量 $x_1, \dots, x_4$，使得 $\sum_{i=1}^{4} x_i \mathbf{c}_i = \mathbf{b}$，其中 $\mathbf{c}_i$ 是矩阵的第 i 列，$\mathbf{b}$ 是 (2.38) 的右端。本题的解可以立刻得到：取第一列的 42 倍和第二列的 8 倍，于是

$$\mathbf{b} = \begin{bmatrix} 42 \\ 8 \end{bmatrix} = 42 \begin{bmatrix} 1 \\ 0 \end{bmatrix} + 8 \begin{bmatrix} 0 \\ 1 \end{bmatrix}. \tag{2.39}$$

因此一个解是 $[42, 8, 0, 0]^\top$。这个解称为特解（particular solution），亦称特殊解（special solution）。但它不是该方程组的唯一解。要囊括其他所有解，我们需要巧妙地用矩阵的列以非平凡的方式凑出 0：往特解上加 0 不会改变特解。为此，用前两列（形式非常简单）表示第三列：

特解

$$\begin{bmatrix} 8 \\ 2 \end{bmatrix} = 8 \begin{bmatrix} 1 \\ 0 \end{bmatrix} + 2 \begin{bmatrix} 0 \\ 1 \end{bmatrix} \tag{2.40}$$

于是 $0 = 8\mathbf{c}_1 + 2\mathbf{c}_2 - 1\mathbf{c}_3 + 0\mathbf{c}_4$，即 $(x_1, x_2, x_3, x_4) = (8, 2, -1, 0)$。事实上，把这个解任意缩放 $\lambda_1 \in \mathbb{R}$ 都得到零向量，即

原书p.28

$$\begin{bmatrix} 1 & 0 & 8 & -4 \\ 0 & 1 & 2 & 12 \end{bmatrix} \left(\lambda_1 \begin{bmatrix} 8 \\ 2 \\ -1 \\ 0 \end{bmatrix} \right) = \lambda_1 (8\mathbf{c}_1 + 2\mathbf{c}_2 - \mathbf{c}_3) = \mathbf{0}. \tag{2.41}$$

同理，把 (2.38) 中第四列用前两列表示，又得到一组非平凡的 0：

$$\begin{bmatrix} 1 & 0 & 8 & -4 \\ 0 & 1 & 2 & 12 \end{bmatrix} \left(\lambda_2 \begin{bmatrix} -4 \\ 12 \\ 0 \\ -1 \end{bmatrix} \right) = \lambda_2 (-4\mathbf{c}_1 + 12\mathbf{c}_2 - \mathbf{c}_4) = \mathbf{0} \tag{2.42}$$

对任意 $\lambda_2 \in \mathbb{R}$ 成立。合起来，(2.38) 的全部解（即通解）为集合

$$\left\{ \mathbf{x} \in \mathbb{R}^4 : \mathbf{x} = \begin{bmatrix} 42 \\ 8 \\ 0 \\ 0 \end{bmatrix} + \lambda_1 \begin{bmatrix} 8 \\ 2 \\ -1 \\ 0 \end{bmatrix} + \lambda_2 \begin{bmatrix} -4 \\ 12 \\ 0 \\ -1 \end{bmatrix}, \ \lambda_1, \lambda_2 \in \mathbb{R} \right\}. \tag{2.43}$$

通解

我们采用的一般方法分三步：

1. 求 $\mathbf{Ax} = \mathbf{b}$ 的一个特解。
2. 求 $\mathbf{Ax} = \mathbf{0}$ 的全部解。
3. 把第 1、2 步的解合并为通解。

通解和特解都不唯一。

上例中的方程组容易求解，是因为 (2.38) 中的矩阵形式特别方便，可以直接观察出特解与通解。但一般方程组并非如此简单。幸运的是，存在一种构造性算法可把任意线性方程组化成这种简单形式：高斯消元法（Gaussian elimination）。高斯消元的关键是方程组的初等变换，它把方程组化成简单形式；之后就能把上面三步应用于这个简单形式。

2.3.2　初等变换

求解线性方程组的关键是保持解集不变、但把方程组化成更简单形式的初等变换：

初等变换
原书p.29

- 交换两个方程（即交换表示方程组的矩阵中的两行）；
- 把某个方程（某行）乘以常数 $\lambda \in \mathbb{R} \setminus \{0\}$；
- 把两个方程（两行）相加。

例 2.6 对 $a \in \mathbb{R}$，求方程组的全部解：

$$\begin{cases} -2x_1 + 4x_2 - 2x_3 - x_4 + 4x_5 = -3 \\ 4x_1 - 8x_2 + 3x_3 - 3x_4 + x_5 = 2 \\ x_1 - 2x_2 + x_3 - x_4 + x_5 = 0 \\ x_1 - 2x_2 - 3x_4 + 4x_5 = a \end{cases} \tag{2.44}$$

先把方程组写成紧凑的矩阵记号 $\mathbf{Ax} = \mathbf{b}$。我们不再显式写出变量 $\mathbf{x}$，而是构造增广矩阵（形如 $[\mathbf{A} \mid \mathbf{b}]$）

增广矩阵

$$\left[\begin{array}{cccccc} -2 & 4 & -2 & -1 & 4 & -3 \\ 4 & -8 & 3 & -3 & 1 & 2 \\ 1 & -2 & 1 & -1 & 1 & 0 \\ 1 & -2 & 0 & -3 & 4 & a \end{array}\right]$$

其中用竖线分隔 (2.44) 的左端与右端。我们用 $\rightsquigarrow$ 表示对增广矩阵做初等变换。

增广矩阵

[A | b] 紧凑地表示方程组Ax = b

交换第 1、3 行得

$$\left[\begin{array}{cccccc} 1 & -2 & 1 & -1 & 1 & 0 \\ 4 & -8 & 3 & -3 & 1 & 2 \\ -2 & 4 & -2 & -1 & 4 & -3 \\ 1 & -2 & 0 & -3 & 4 & a \end{array}\right]$$

再做所示变换（如第 2 行减去第 1 行的 4 倍），得

$$\left[\begin{array}{cccccc} 1 & -2 & 1 & -1 & 1 & 0 \\ 0 & 0 & -1 & 1 & -3 & 2 \\ 0 & 0 & 0 & -3 & 6 & -3 \\ 0 & 0 & -1 & -2 & 3 & a+1 \end{array}\right] \rightsquigarrow \left[\begin{array}{cccccc} 1 & -2 & 1 & -1 & 1 & 0 \\ 0 & 0 & -1 & 1 & -3 & 2 \\ 0 & 0 & 0 & -3 & 6 & -3 \\ 0 & 0 & 0 & 0 & 0 & a+1 \end{array}\right] \rightsquigarrow \left[\begin{array}{cccccc} 1 & -2 & 1 & -1 & 1 & 0 \\ 0 & 0 & 1 & -1 & 3 & -2 \\ 0 & 0 & 0 & 1 & -2 & 1 \\ 0 & 0 & 0 & 0 & 0 & a+1 \end{array}\right].$$

这个（增广）矩阵已是一种方便的形式——行阶梯形（row-echelon form, REF）把紧凑记号还原为含变量的显式记号，得到

原书p.30

行阶梯形

$$\begin{cases} x_1 - 2x_2 + x_3 - x_4 + x_5 = 0 \\ x_3 - x_4 + 3x_5 = -2 \\ x_4 - 2x_5 = 1 \\ 0 = a + 1 \end{cases} \tag{2.45}$$

只有当 $a = -1$ 时该方程组才可解。一个特解为

特解

$$\begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \end{bmatrix} = \begin{bmatrix} 2 \\ 0 \\ -1 \\ 1 \\ 0 \end{bmatrix}. \tag{2.46}$$

涵盖所有可能解的通解为

通解

$$\left\{ \mathbf{x} \in \mathbb{R}^5 : \mathbf{x} = \begin{bmatrix} 2 \\ 0 \\ -1 \\ 1 \\ 0 \end{bmatrix} + \lambda_1 \begin{bmatrix} 2 \\ 1 \\ 0 \\ 0 \\ 0 \end{bmatrix} + \lambda_2 \begin{bmatrix} 2 \\ 0 \\ -1 \\ 2 \\ 1 \end{bmatrix},\ \lambda_1, \lambda_2 \in \mathbb{R} \right\}. \tag{2.47}$$

下面详细介绍求特解与通解的构造性方法。

[主元与阶梯结构] 一行的首项系数（从左数第一个非零数）称为主元（pivot），它总是严格位于上一行主元的右侧。因此任何行阶梯形方程组都具有“阶梯”结构。

主元

定义 2.6 (行阶梯形). 一个矩阵是行阶梯形的，若：

行阶梯形

- 所有只含零的行位于矩阵底部；相应地，所有至少含一个非零元素的行都在全零行之上。
- 只看非零行，从左数第一个非零数（亦称主元或首项系数）总是严格位于上一行主元的右侧。

首项系数

[基本变量与自由变量] 行阶梯形中与主元对应的变量称为基本变量，其余变量称为自由变量。例如在 (2.45) 中，x_1, x_3, x_4 是基本变量，而 x_2, x_5 是自由变量。

有些教材还要求主元为 1

基本变量

[求特解] 行阶梯形让我们更容易求特解。做法是用主元列表示方程组的右端，即 $\mathbf{b} = \sum_{i=1}^{P} \lambda_i \mathbf{p}_i$，其中 $\mathbf{p}_i$（$i = 1, \ldots, P$）是主元列。从最右边的主元列向左递推最容易确定各 λ_i。在上例中，我们要找 $\lambda_1, \lambda_2, \lambda_3$ 使得

原书p.31

$$\lambda_1 \begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \end{bmatrix} + \lambda_2 \begin{bmatrix} 1 \\ 1 \\ 0 \\ 0 \end{bmatrix} + \lambda_3 \begin{bmatrix} -1 \\ -1 \\ 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ -2 \\ 1 \\ 0 \end{bmatrix}. \tag{2.48}$$

由此直接得 $\lambda_3 = 1$，$\lambda_2 = -1$，$\lambda_1 = 2$。合起来时不要忘记非主元列，其系数隐含取 0。于是得特解 $\mathbf{x} = [2, 0, -1, 1, 0]^\top$。

[简化行阶梯形] 一个方程组是简化行阶梯形（reduced row-echelon form，亦称 row-reduced echelon form 或 row canonical form）的，若：

简化行阶梯形

- 它是行阶梯形；
- 每个主元都为 1；
- 主元是其所在列中唯一的非零元素。

简化行阶梯形在第 2.3.3 节很重要，因为它让我们能直接确定线性方程组的通解。

[高斯消元法] 高斯消元法是一个通过做初等变换把线性方程组化成简化行阶梯形的算法。

高斯消元

例 2.7（简化行阶梯形） 验证下列矩阵是简化行阶梯形（主元用粗体标出）：

$$\mathbf{A} = \begin{bmatrix} \mathbf{1} & 3 & 0 & 0 & 3 \\ 0 & 0 & \mathbf{1} & 0 & 9 \\ 0 & 0 & 0 & \mathbf{1} & -4 \end{bmatrix}. \tag{2.49}$$

求 $\mathbf{Ax} = \mathbf{0}$ 解的关键是考察非主元列——我们需要把它们表示成主元列的（线性）组合。简化行阶梯形使这一步相当直接：把非主元列表示成其左侧各主元列的和与倍数。第二列是第一列的 3 倍（第二列右侧的主元列可忽略）。因此，为凑出 0，需要用第一列的 3 倍减去第二列。

原书p.32

再看第五列，它是第二个非主元列。第五列可表示为：第一主元列的 3 倍第二主元列的 9 倍、第三主元列的 -4 倍。我们要记下主元列的下标，把它翻译成：第一列的 3 倍、第二列（非主元列）的 0 倍、第三列（第二主元列）的 9 倍、第四列（第三主元列）的 -4 倍，然后减去第五列得到 0。归根结底，我们解的仍是一个齐次方程组。

综上，$\mathbf{Ax}=\mathbf{0}$（$\mathbf{x}\in\mathbb{R}^5$）的全部解为

$$\left\{\mathbf{x}\in\mathbb{R}^5:\ \mathbf{x}=\lambda_1\begin{bmatrix}3\\-1\\0\\0\\0\end{bmatrix}+\lambda_2\begin{bmatrix}3\\0\\9\\-4\\-1\end{bmatrix},\ \lambda_1,\lambda_2\in\mathbb{R}\right\}. \tag{2.50}$$

2.3.3　减一技巧

下面介绍一个实用技巧，用来直接读出齐次线性方程组 $\mathbf{Ax}=\mathbf{0}$（$\mathbf{A}\in\mathbb{R}^{k\times n}$，$\mathbf{x}\in\mathbb{R}^n$）的解 $\mathbf{x}$。

开始时，假设 $\mathbf{A}$ 已是简化行阶梯形，且没有全零行，其结构为（每个主元列恰有一个 1、其余为 0，主元之间的非主元列可含任意实数 $*$）：

$$\mathbf{A}=\begin{bmatrix}1&*&0&*&0&*\\0&0&1&*&0&*\\0&0&0&0&1&*\end{bmatrix}\in\mathbb{R}^{k\times n}, \tag{2.51}$$

其中 $*$ 可为任意实数，但要求每行第一个非零元素必为 1，且对应列的其他元素必为 0。带主元（粗体标出）的列 $j_1,\dots,j_k$ 是标准单位向量 $\mathbf{e}_1,\dots,\mathbf{e}_k\in\mathbb{R}^k$。我们给矩阵补上 $n-k$ 行形如

$$\begin{bmatrix}0&\cdots&0&-1&0&\cdots&0\end{bmatrix} \tag{2.52}$$

的行，把它扩展为 $n\times n$ 矩阵 $\tilde{\mathbf{A}}$，使得增广矩阵 $\tilde{\mathbf{A}}$ 的对角线上不是 1 就是 -1。于是，$\tilde{\mathbf{A}}$ 中以 -1 为主元的那些列就是齐次方程组 $\mathbf{Ax}=\mathbf{0}$ 的解。更确切地说这些列构成 $\mathbf{Ax}=\mathbf{0}$ 解空间的一组基（第 2.6.1 节），我们之后称之为核（kernel 或零空间（null space）；见第 2.7.3 节。

原书p.33

核 零空间

例 2.8（减一技巧） 回到 (2.49) 中那个已是简化行阶梯形的矩阵：

$$\mathbf{A}=\begin{bmatrix}1&3&0&0&3\\0&0&1&0&9\\0&0&0&1&-4\end{bmatrix}. \tag{2.53}$$

现在在对角线缺主元的位置补上形如 (2.52) 的行，把它扩展为 5×5 矩阵，

得

$$\tilde{\mathbf{A}} = \begin{bmatrix} 1 & 3 & 0 & 0 & 3 \\ 0 & -1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 9 \\ 0 & 0 & 0 & 1 & -4 \\ 0 & 0 & 0 & 0 & -1 \end{bmatrix}. \tag{2.54}$$

由这个形式，取 $\tilde{\mathbf{A}}$ 中对角线上为 -1 的列，即可直接读出 $\mathbf{Ax} = \mathbf{0}$ 的解：

$$\left\{ \mathbf{x} \in \mathbb{R}^5 : \mathbf{x} = \lambda_1 \begin{bmatrix} 3 \\ -1 \\ 0 \\ 0 \\ 0 \end{bmatrix} + \lambda_2 \begin{bmatrix} 3 \\ 0 \\ 9 \\ -4 \\ -1 \end{bmatrix}, \ \lambda_1, \lambda_2 \in \mathbb{R} \right\}, \tag{2.55}$$

它与我们靠“洞察力”得到的 (2.50) 完全一致。

计算逆矩阵

要计算 $\mathbf{A} \in \mathbb{R}^{n\times n}$ 的逆 $\mathbf{A}^{-1}$，需要找一个满足 $\mathbf{AX} = \mathbf{I}_n$ 的矩阵 $\mathbf{X}$，则 $\mathbf{X} = \mathbf{A}^{-1}$。我们可以把它写成一组联立方程 $\mathbf{AX} = \mathbf{I}_n$，对 $\mathbf{X} = [\mathbf{x}_1 \mid \cdots \mid \mathbf{x}_n]$ 求解。用增广矩阵记号紧凑表示这一组方程组，得到

$$[\mathbf{A} \mid \mathbf{I}_n] \rightsquigarrow \cdots \rightsquigarrow [\mathbf{I}_n \mid \mathbf{A}^{-1}]. \tag{2.56}$$

这意味着：若把增广方程组化成简化行阶梯形，就能在右端直接读出逆矩阵。因此，求矩阵的逆等价于求解线性方程组。

原书p.34

例 2.9（用高斯消元求逆矩阵） 要确定

$$\mathbf{A} = \begin{bmatrix} 1 & 0 & 2 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 2 & 0 & 1 \\ 1 & 1 & 1 & 1 \end{bmatrix} \tag{2.57}$$

的逆，写出增广矩阵，用高斯消元把它化成简化行阶梯形

$$\begin{bmatrix} 1 & 0 & 0 & 0 & -1 & 2 & -2 & 2 \\ 0 & 1 & 0 & 0 & 1 & -1 & 2 & -2 \\ 0 & 0 & 1 & 0 & 1 & -1 & 1 & -1 \\ 0 & 0 & 0 & 1 & -1 & 0 & -1 & 2 \end{bmatrix},$$

于是所求逆矩阵就是右端：

$$\mathbf{A}^{-1} = \begin{bmatrix} -1 & 2 & -2 & 2 \\ 1 & -1 & 2 & -2 \\ 1 & -1 & 1 & -1 \\ -1 & 0 & -1 & 2 \end{bmatrix}. \tag{2.58}$$

做乘法 $\mathbf{AA}^{-1}$ 可验证它确实恢复出 $\mathbf{I}_4$。

2.3.4　求解线性方程组的算法

下面简要讨论求解形如 $\mathbf{A}\mathbf{x}=\mathbf{b}$ 的方程组的方法。假设解存在；若无解，则需求助于近似解，本章不涉及。求解近似问题的一种途径是线性回归，将在第 9 章详细讨论。

在特殊情形下，我们可以求出逆 $\mathbf{A}^{-1}$，从而解为 $\mathbf{x}=\mathbf{A}^{-1}\mathbf{b}$。但这仅当 $\mathbf{A}$ 是方阵且可逆时才行，而实际往往并非如此。否则，在温和假设下（即 $\mathbf{A}$ 列线性无关），可用变换

$$\mathbf{A}\mathbf{x}=\mathbf{b} \iff \mathbf{A}^{\top}\mathbf{A}\mathbf{x}=\mathbf{A}^{\top}\mathbf{b} \iff \mathbf{x}=(\mathbf{A}^{\top}\mathbf{A})^{-1}\mathbf{A}^{\top}\mathbf{b} \tag{2.59}$$

并用 Moore–Penrose 伪逆 $(\mathbf{A}^{\top}\mathbf{A})^{-1}\mathbf{A}^{\top}$ 求出解 (2.59)，它同时也是最小范数最小二乘解。该方法的缺点是矩阵–矩阵乘法和求 $(\mathbf{A}^{\top}\mathbf{A})^{-1}$ 计算量大；此外，出于数值精度考虑，一般不建议直接计算逆或伪逆。因此下面简要讨论求解线性方程组的其他方法。

原书p.35 Moore–Penrose伪逆

高斯消元在计算行列式（第 4.1 节）、判断一组向量是否线性无关（第 2.5 节）、求逆矩阵（第 2.2.2 节）、求矩阵的秩（第 2.6.2 节）以及确定向量空间的基（第 2.6.1 节）中都很重要。高斯消元是求解含数千变量方程组的直观且构造性的方法；但对含数百万变量的方程组则不切实际，因为所需算术运算次数随方程数三次方增长。

实际中，大规模线性方程组多采用间接法求解：要么是平稳迭代法，如 Richardson 法、Jacobi 法、Gauß–Seidel 法和逐次超松弛法；要么是 Krylov 子空间法，如共轭梯度法、广义最小残差法或双共轭梯度法。进一步细节参见 Stoer and Burlirsch (2002)、Strang (2003)、Liesen and Mehrmann (2015)。

设 $\mathbf{x}^{*}$ 是 $\mathbf{A}\mathbf{x}=\mathbf{b}$ 的解。这些迭代法的核心思想是构造形如

$$\mathbf{x}^{(k+1)}=\mathbf{C}\mathbf{x}^{(k)}+\mathbf{d} \tag{2.60}$$

的迭代，选取合适的 $\mathbf{C}$ 和 $\mathbf{d}$，使每次迭代都缩小残差 $\|\mathbf{x}^{(k+1)}-\mathbf{x}^{*}\|$ 并收敛到 $\mathbf{x}^{*}$。我们将在第 3.1 节引入范数 $\|\cdot\|$，它让我们能计算向量间的相似度。

2.4　向量空间

至此我们考察了线性方程组及其解法（第 2.3 节），看到线性方程组可用矩阵–向量记号紧凑表示 (2.10)。下面仔细考察向量空间，即向量所在的、具有结构的空间。

本章开头我们曾非正式地把向量描述为可相加、可乘标量且仍为同类对象的东西。现在我们把它形式化，先引入群的概念：群是一个元素集合，连同定义在这些元素上、并保持集合某种结构的一种运算。

2.4.1　群

原书p.36

群在计算机科学中扮演重要角色。除了为集合上的运算提供基本框架外，群还大量用于密码学、编码理论和图形学。

定义 2.7 (群). 考虑集合 G 及其上定义的运算 $\otimes : G \times G \to G$。若下列条件成立，则 $\mathcal{G} := (G, \otimes)$ 称为群：

群

1. G 对 $\otimes$ 封闭：$\forall x, y \in G:\ x \otimes y \in G$；　封闭性
2. 结合律：$\forall x, y, z \in G:\ (x \otimes y) \otimes z = x \otimes (y \otimes z)$；　结合律
3. 单位元：存在 $e \in G$，使得 $\forall x \in G:\ x \otimes e = x$ 且 $e \otimes x = x$；　单位元
4. 逆元：$\forall x \in G$ 存在 $y \in G$，使得 $x \otimes y = e$ 且 $y \otimes x = e$，其中 e 是单位元。我们常把 x 的逆元记作 x^{-1}。　逆元

逆元是相对于运算 $\otimes$ 定义的，并不一定就是 $\frac{1}{x}$。
若还满足 $\forall x, y \in G:\ x \otimes y = y \otimes x$，则 $\mathcal{G} = (G, \otimes)$ 是 Abel 群（可交换群）。

Abel 群

例 2.10（群） 看几个带运算的集合，判断它们是否为群：

- $(\mathbb{Z}, +)$ 是 Abel 群。
- $(\mathbb{N}_0, +)$ 不是群：虽然它有单位元 0，但缺少逆元。　N0 := N ∪{0}
- $(\mathbb{Z}, \cdot)$ 不是群：虽然它含单位元 1，但对任何 $z \in \mathbb{Z}$、$z \neq \pm 1$，都缺少逆元。
- $(\mathbb{R}, \cdot)$ 不是群，因为 0 没有逆元。
- $(\mathbb{R} \setminus \{0\}, \cdot)$ 是 Abel 群。
- $(\mathbb{R}^n, +)$、$(\mathbb{Z}^n, +)$（$n \in \mathbb{N}$）在加法按分量定义时是 Abel 群，即

$$(x_1, \ldots, x_n) + (y_1, \ldots, y_n) = (x_1 + y_1, \ldots, x_n + y_n). \tag{2.61}$$

  此时 $(x_1, \ldots, x_n)^{-1} := (-x_1, \ldots, -x_n)$ 是逆元，$e = (0, \ldots, 0)$ 是单位元。
- $(\mathbb{R}^{m \times n}, +)$（$m \times n$ 矩阵的集合）是 Abel 群（加法按 (2.61) 逐分量定义）。

再仔细看 $(\mathbb{R}^{n \times n}, \cdot)$，即以 (2.13) 定义的矩阵乘法为运算的 $n \times n$ 矩阵集合。

- 封闭性与结合律直接由矩阵乘法定义得到。
- 单位元：单位矩阵 $\mathbf{I}_n$ 是 $(\mathbb{R}^{n \times n}, \cdot)$ 中关于矩阵乘法“$\cdot$”的单位元。　原书p.37
- 逆元：若逆存在（即 $\mathbf{A}$ 正则），则 $\mathbf{A}^{-1}$ 是 $\mathbf{A} \in \mathbb{R}^{n \times n}$ 的逆元；恰在此情形下 $(\mathbb{R}^{n \times n}, \cdot)$ 是一个群，称为一般线性群。

定义 2.8 (一般线性群). 正则（可逆）矩阵 $\mathbf{A} \in \mathbb{R}^{n \times n}$ 的集合，在 (2.13) 定义的矩阵乘法下构成群，称为一般线性群 $\mathrm{GL}(n, \mathbb{R})$。由于矩阵乘法不可交换，它不是 Abel 群。

一般线性群

2.4.2　向量空间

讨论群时，我们考察集合 G 及其上的内运算，即只作用于 G 中元素的映射 $G \times G \to G$。下面考虑除内运算 $+$ 外还含外运算 $\cdot$ 的集合，即用标量 $\lambda \in \mathbb{R}$ 乘向量 $\mathbf{x} \in G$。可把内运算看作一种加法、外运算看作一种缩放。注意内/外运算与内积/外积无关。

定义 2.9 (向量空间). 一个实值向量空间 $\mathcal{V} = (V, +, \cdot)$ 是带两种运算的集合 V：

$$+ : V \times V \to V \tag{2.62}$$

$$\cdot : \mathbb{R} \times V \to V \tag{2.63}$$

向量空间

其中：

1. $(V, +)$ 是 Abel 群；
2. 分配律：
   (a) $\forall \lambda \in \mathbb{R},\ \mathbf{x}, \mathbf{y} \in V:\ \lambda \cdot (\mathbf{x} + \mathbf{y}) = \lambda \cdot \mathbf{x} + \lambda \cdot \mathbf{y}$；
   (b) $\forall \lambda, \psi \in \mathbb{R},\ \mathbf{x} \in V:\ (\lambda + \psi) \cdot \mathbf{x} = \lambda \cdot \mathbf{x} + \psi \cdot \mathbf{x}$；
3.（外运算的）结合律：$\forall \lambda, \psi \in \mathbb{R},\ \mathbf{x} \in V:\ \lambda \cdot (\psi \cdot \mathbf{x}) = (\lambda\psi) \cdot \mathbf{x}$；
4. 外运算的单位元：$\forall \mathbf{x} \in V:\ 1 \cdot \mathbf{x} = \mathbf{x}$。

元素 $\mathbf{x} \in V$ 称为向量。$(V, +)$ 的单位元是零向量 $\mathbf{0} = [0, \dots, 0]^\top$，内运算 $+$ 称为向量加法。元素 $\lambda \in \mathbb{R}$ 称为标量，外运算 $\cdot$ 就是数乘。注意标量积是另一回事将在第 3.2 节讨论。

向量　标量　向量加法

“向量相乘”**ab**（$\mathbf{a}, \mathbf{b} \in \mathbb{R}^n$）并未定义。理论上可以定义逐元素乘法，即 $\mathbf{c} = \mathbf{ab}$、$c_j = a_j b_j$。这种“数组乘法”在许多编程语言中常见，但按矩阵乘法的标准规则在数学上意义有限：若把向量当作 $n \times 1$ 矩阵（我们通常就这么做）则可用 (2.13) 的矩阵乘法，但此时向量维度不匹配。向量只有以下两种乘法有定义：$\mathbf{ab}^\top \in \mathbb{R}^{n \times n}$（外积）和 $\mathbf{a}^\top \mathbf{b} \in \mathbb{R}$（内积/标量积/点积）。

原书p.38

外积

例 2.11（向量空间） 几个重要例子：

- $V = \mathbb{R}^n$（$n \in \mathbb{N}$）是向量空间，运算定义如下：
  - 加法：$\mathbf{x} + \mathbf{y} = (x_1, \dots, x_n) + (y_1, \dots, y_n) = (x_1 + y_1, \dots, x_n + y_n)$，对所有 $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$；
  - 数乘：$\lambda \mathbf{x} = \lambda(x_1, \dots, x_n) = (\lambda x_1, \dots, \lambda x_n)$，对所有 $\lambda \in \mathbb{R}$、$\mathbf{x} \in \mathbb{R}^n$。
- $V = \mathbb{R}^{m \times n}$（$m, n \in \mathbb{N}$）是向量空间：
  - 加法：$\mathbf{A} + \mathbf{B} = \begin{bmatrix} a_{11} + b_{11} & \cdots & a_{1n} + b_{1n} \\ \vdots & & \vdots \\ a_{m1} + b_{m1} & \cdots & a_{mn} + b_{mn} \end{bmatrix}$ 对所有 $\mathbf{A}, \mathbf{B} \in V$ 逐元素定义；

  - 数乘：$\lambda\mathbf{A} = \begin{bmatrix} \lambda a_{11} & \cdots & \lambda a_{1n} \\ \vdots & & \vdots \\ \lambda a_{m1} & \cdots & \lambda a_{mn} \end{bmatrix}$，如第 2.2 节所述。记住 $\mathbb{R}^{m\times n}$ 等价于 $\mathbb{R}^{mn}$。

- $V = \mathbb{C}$，按复数加法的标准定义。

今后当 $+$ 与 $\cdot$ 是标准向量加法与数乘时，我们把向量空间 $(V, +, \cdot)$ 简记为 V。并用记号 $\mathbf{x} \in V$ 表示 V 中的向量以简化写法。

向量空间 $\mathbb{R}^n$、$\mathbb{R}^{n\times 1}$、$\mathbb{R}^{1\times n}$ 只是写法不同。今后不区分 $\mathbb{R}^n$ 与 $\mathbb{R}^{n\times 1}$，从而可把 n 元组写成列向量

列向量

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}. \tag{2.64}$$

这简化了向量空间运算的记号。但我们确实区分 $\mathbb{R}^{n\times 1}$ 与 $\mathbb{R}^{1\times n}$（行向量），以免与矩阵乘法混淆。默认用 $\mathbf{x}$ 表示列向量，行向量记作 $\mathbf{x}^\top$，即 $\mathbf{x}$ 的转置。

转置量

2.4.3　向量子空间

原书p.39

下面引入向量子空间。直观上，它们是原向量空间中包含的集合，且当我们对子空间内的元素做向量空间运算时，永远不会离开它。在这个意义上它们是“封闭的”。向量子空间是机器学习中的关键概念，例如第 10 章展示了如何用向量子空间做降维。

定义 2.10 (向量子空间). 设 $\mathcal{V} = (V, +, \cdot)$ 是向量空间，$U \subseteq V$，$U \neq \emptyset$。若 U 在限制于 $U \times U$ 与 $\mathbb{R} \times U$ 的运算 $+$、$\cdot$ 下仍是向量空间，则 $\mathcal{U} = (U, +, \cdot)$ 称为 V 的向量子空间（或线性子空间）。我们记 $U \subseteq V$ 表示 V 的子空间 U。

线性子空间

若 $U \subseteq V$ 且 V 是向量空间，则 U 自然继承 V 的许多性质，因为这些性质对所有 $\mathbf{x} \in V$ 成立，特别对所有 $\mathbf{x} \in U \subseteq V$ 成立。这包括 Abel 群性质、分配律、结合律和单位元。要判断 $(U, +, \cdot)$ 是否为 V 的子空间，仍需验证：

1. $U \neq \emptyset$，特别地 $\mathbf{0} \in U$；
2. U 的封闭性：
   (a) 对外运算：$\forall \lambda \in \mathbb{R}\ \forall \mathbf{x} \in U:\ \lambda\mathbf{x} \in U$；
   (b) 对内运算：$\forall \mathbf{x}, \mathbf{y} \in U:\ \mathbf{x} + \mathbf{y} \in U$。

例 2.12（向量子空间） 几个例子：

- 对每个向量空间 V，平凡子空间是 V 自身和 $\{\mathbf{0}\}$。
- 图 2.6 中只有例子 D 是 $\mathbb{R}^2$ 的子空间（在通常的内/外运算下）。A、C 违反封闭性；B 不含 $\mathbf{0}$。

- 含 n 个未知量 $\mathbf{x} = [x_1, \dots, x_n]^\top$ 的齐次线性方程组 $\mathbf{Ax} = \mathbf{0}$ 的解集是 $\mathbb{R}^n$ 的子空间。
- 非齐次线性方程组 $\mathbf{Ax} = \mathbf{b}$（$\mathbf{b} \neq \mathbf{0}$）的解不是 $\mathbb{R}^n$ 的子空间。
- 任意多个子空间的交仍是子空间。

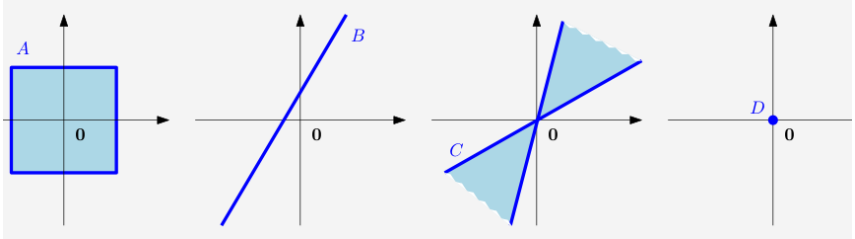


图 2.6: 并非 $\mathbb{R}^2$ 的所有子集都是子空间。A、C 违反封闭性；B 不含 0。只有 D 是子空间。

原书p.40

每个子空间 $U \subseteq (\mathbb{R}^n, +, \cdot)$ 都是某个齐次线性方程组 $\mathbf{Ax} = \mathbf{0}$（$\mathbf{x} \in \mathbb{R}^n$）的解空间。

2.5　线性无关

下面考察我们对向量（向量空间的元素）能做什么。特别地，可以把向量相加、用标量去乘；封闭性保证结果仍是同一向量空间中的向量。有可能找到一组向量，使得向量空间中的每个向量都能通过把它们相加、缩放而表示出来。这组向量就是一组基，将在第 2.6.1 节讨论。在此之前，需先引入线性组合与线性无关的概念。

定义 2.11 (线性组合). 考虑向量空间 V 和有限个向量 $\mathbf{x}_1, \dots, \mathbf{x}_k \in V$。则任意形如

$$\mathbf{v} = \lambda_1 \mathbf{x}_1 + \cdots + \lambda_k \mathbf{x}_k = \sum_{i=1}^{k} \lambda_i \mathbf{x}_i \in V \tag{2.65}$$

（其中 $\lambda_1, \dots, \lambda_k \in \mathbb{R}$）的 $\mathbf{v} \in V$，称为向量 $\mathbf{x}_1, \dots, \mathbf{x}_k$ 的线性组合。

线性组合

零向量总能写成 k 个向量 $\mathbf{x}_1, \dots, \mathbf{x}_k$ 的线性组合，因为 $\mathbf{0} = \sum_{i=1}^{k} 0\,\mathbf{x}_i$ 恒成立。下面我们关心的是一组向量用来表示 $\mathbf{0}$ 的非平凡线性组合，即 (2.65) 中系数 λ_i 不全为 0 的线性组合。

定义 2.12 (线性（无）关). 考虑向量空间 V，$k \in \mathbb{N}$，$\mathbf{x}_1, \dots, \mathbf{x}_k \in V$。若存在非平凡线性组合使 $\mathbf{0} = \sum_{i=1}^{k} \lambda_i \mathbf{x}_i$ 且至少一个 $\lambda_i \neq 0$，则称向量 $\mathbf{x}_1, \dots, \mathbf{x}_k$ 线性相关。若只有平凡解，即 $\lambda_1 = \cdots = \lambda_k = 0$，则称它们线性无关。

线性相关

线性无关是线性代数中最重要的概念之一。直观上，一组线性无关的向量没有冗余：若从中去掉任一向量，就会丢失某些东西。后续各节将把这一直观进一步形式化。

例 2.13（线性相关的向量） 一个地理例子有助于理解线性无关。在内罗毕（肯尼亚）的人描述基加利（卢旺达）在哪时会说：“先向西北走 506 公里到坎帕拉（乌干达），再向西南走 374 公里就到了。”这足以描述基加利的位置因为地理坐标系可看作二维向量空间（忽略海拔和地球曲面）。这人可能补充说：“它离这儿正西约 751 公里。”最后这句话虽属实，但有了前面的信息就没必要再用来找基加利（见图 2.7）。本例中，“西北 506 公里”向量（蓝）与“西南 374 公里”向量（紫）线性无关，意思是西南向量无法用西北向量表示，反之亦然。但第三个“正西 751 公里”向量（黑）是前两个向量的线性组合，它使这组向量线性相关。等价地，给定“正西 751 公里”和“西南 374 公里”，可线性组合得到“西北 506 公里”。

原书p.41

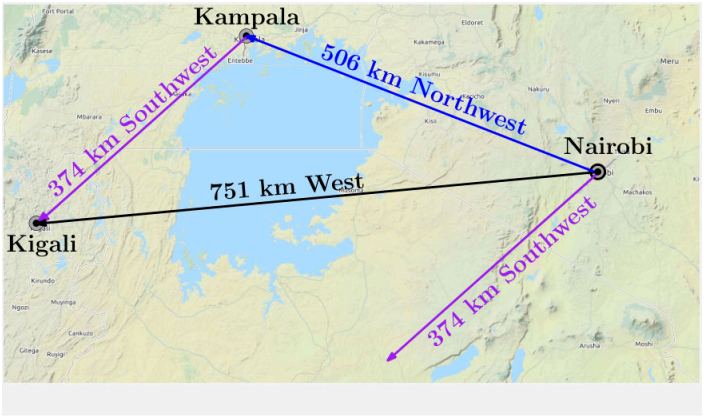


图 2.7: 线性相关向量的地理例子（方向为粗略近似），位于二维空间（平面）中。

以下性质有助于判断向量是否线性无关：

- k 个向量要么线性相关要么线性无关，没有第三种情况。
- 若 $\mathbf{x}_1, \ldots, \mathbf{x}_k$ 中有至少一个是 $\mathbf{0}$，则它们线性相关；若有两个向量相同，也线性相关。
- 向量集 $\{\mathbf{x}_1, \ldots, \mathbf{x}_k : \mathbf{x}_i \neq \mathbf{0},\ i = 1, \ldots, k\}$（$k \geqslant 2$）线性相关，当且仅当其中（至少）一个是其余向量的线性组合。特别地，若一个向量是另一个的倍数，即 $\mathbf{x}_i = \lambda \mathbf{x}_j$（$\lambda \in \mathbb{R}$），则该集合线性相关。
- 判断向量 $\mathbf{x}_1, \ldots, \mathbf{x}_k \in V$ 是否线性无关的实用方法是高斯消元：把所有向量写成矩阵 $\mathbf{A}$ 的列，做高斯消元直到矩阵成行阶梯形（此处不必是简化行阶梯形）：

  原书p.42

  - 主元列对应那些与左侧向量线性无关的向量。注意构造矩阵时向量是有顺序的。
  - 非主元列可表示为其左侧主元列的线性组合。例如行阶梯形

$$\begin{bmatrix} 1 & 3 & 0 \\ 0 & 0 & 2 \end{bmatrix} \tag{2.66}$$

告诉我们第一列和第三列是主元列；第二列是非主元列，因为它是第一列的 3 倍。

所有列向量线性无关，当且仅当所有列都是主元列。若至少有一个非主元列，则各列（因而对应向量）线性相关。

例 2.14 在 $\mathbb{R}^4$ 中考虑

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 2 \\ -3 \\ 4 \end{bmatrix}, \quad \mathbf{x}_2 = \begin{bmatrix} 1 \\ 1 \\ 0 \\ 2 \end{bmatrix}, \quad \mathbf{x}_3 = \begin{bmatrix} -1 \\ -2 \\ 1 \\ 1 \end{bmatrix}. \tag{2.67}$$

要判断它们是否线性相关，按一般方法求解

$$\lambda_1\mathbf{x}_1 + \lambda_2\mathbf{x}_2 + \lambda_3\mathbf{x}_3 = \lambda_1 \begin{bmatrix} 1 \\ 2 \\ -3 \\ 4 \end{bmatrix} + \lambda_2 \begin{bmatrix} 1 \\ 1 \\ 0 \\ 2 \end{bmatrix} + \lambda_3 \begin{bmatrix} -1 \\ -2 \\ 1 \\ 1 \end{bmatrix} = \mathbf{0} \tag{2.68}$$

中的 $\lambda_1, \ldots, \lambda_3$。把向量 $\mathbf{x}_i$（$i = 1, 2, 3$）写成矩阵的列，做初等行变换直到识别出主元列：

$$\begin{bmatrix} 1 & 1 & -1 \\ 2 & 1 & -2 \\ -3 & 0 & 1 \\ 4 & 2 & 1 \end{bmatrix} \rightsquigarrow \cdots \rightsquigarrow \begin{bmatrix} 1 & 1 & -1 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \end{bmatrix}. \tag{2.69}$$

这里矩阵每一列都是主元列,因此没有非平凡解,必须取 $\lambda_1 = \lambda_2 = \lambda_3 = 0$。故 $\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3$ 线性无关。

原书p.43

考虑向量空间 V，含 k 个线性无关向量 $\mathbf{b}_1, \ldots, \mathbf{b}_k$ 和 m 个线性组合

$$\mathbf{x}_1 = \sum_{i=1}^{k} \lambda_{i1}\mathbf{b}_i, \qquad \ldots, \qquad \mathbf{x}_m = \sum_{i=1}^{k} \lambda_{im}\mathbf{b}_i. \tag{2.70}$$

定义 $\mathbf{B} = [\mathbf{b}_1, \ldots, \mathbf{b}_k]$ 为以线性无关向量 $\mathbf{b}_1, \ldots, \mathbf{b}_k$ 为列的矩阵，则可紧凑地写成

$$\mathbf{x}_j = \mathbf{B}\boldsymbol{\lambda}_j, \qquad \boldsymbol{\lambda}_j = \begin{bmatrix} \lambda_{1j} \\ \vdots \\ \lambda_{kj} \end{bmatrix}, \quad j = 1, \ldots, m, \tag{2.71}$$

我们想检验 $\mathbf{x}_1, \ldots, \mathbf{x}_m$ 是否线性无关。为此按一般方法考察何时 $\sum_{j=1}^{m} \psi_j\mathbf{x}_j = \mathbf{0}$。由 (2.71) 得

$$\sum_{j=1}^{m} \psi_j\mathbf{x}_j = \sum_{j=1}^{m} \psi_j\mathbf{B}\boldsymbol{\lambda}_j = \mathbf{B}\sum_{j=1}^{m} \psi_j\boldsymbol{\lambda}_j. \tag{2.72}$$

这意味着 $\{\mathbf{x}_1, \ldots, \mathbf{x}_m\}$ 线性无关，当且仅当列向量 $\{\boldsymbol{\lambda}_1, \ldots, \boldsymbol{\lambda}_m\}$ 线性无关。

在向量空间 V 中，k 个向量的 m 个线性组合当 $m > k$ 时必线性相关。

例 2.15 考虑一组线性无关向量 $\mathbf{b}_1, \mathbf{b}_2, \mathbf{b}_3, \mathbf{b}_4 \in \mathbb{R}^n$，且

$$\begin{aligned}\mathbf{x}_1 &= \mathbf{b}_1 - 2\mathbf{b}_2 + \mathbf{b}_3 - \mathbf{b}_4\\ \mathbf{x}_2 &= -4\mathbf{b}_1 - 2\mathbf{b}_2 + 4\mathbf{b}_4\\ \mathbf{x}_3 &= 2\mathbf{b}_1 + 3\mathbf{b}_2 - \mathbf{b}_3 - 3\mathbf{b}_4\\ \mathbf{x}_4 &= 17\mathbf{b}_1 - 10\mathbf{b}_2 + 11\mathbf{b}_3 + \mathbf{b}_4.\end{aligned} \tag{2.73}$$

向量 $\mathbf{x}_1, \ldots, \mathbf{x}_4 \in \mathbb{R}^n$ 是否线性无关？为回答此问，考察列向量

$$\left\{ \begin{bmatrix} 1 \\ -2 \\ 1 \\ -1 \end{bmatrix}, \begin{bmatrix} -4 \\ -2 \\ 0 \\ 4 \end{bmatrix}, \begin{bmatrix} 2 \\ 3 \\ -1 \\ -3 \end{bmatrix}, \begin{bmatrix} 17 \\ -10 \\ 11 \\ 1 \end{bmatrix} \right\} \tag{2.74}$$

是否线性无关。对应系数矩阵

原书p.44

$$\mathbf{A} = \begin{bmatrix} 1 & -4 & 2 & 17 \\ -2 & -2 & 3 & -10 \\ 1 & 0 & -1 & 11 \\ -1 & 4 & -3 & 1 \end{bmatrix} \tag{2.75}$$

的简化行阶梯形为

$$\begin{bmatrix} 1 & 0 & 0 & -7 \\ 0 & 1 & 0 & -15 \\ 0 & 0 & 1 & -18 \\ 0 & 0 & 0 & 0 \end{bmatrix}. \tag{2.76}$$

可见对应方程组有非平凡解: 最后一列不是主元列, 且 $\mathbf{x}_4 = -7\mathbf{x}_1 - 15\mathbf{x}_2 - 18\mathbf{x}_3$。因此 $\mathbf{x}_1, \ldots, \mathbf{x}_4$ 线性相关，因为 $\mathbf{x}_4$ 可表示为 $\mathbf{x}_1, \ldots, \mathbf{x}_3$ 的线性组合。

2.6　基与秩

在向量空间 V 中，我们特别关注这样的向量集 A：任一向量 $\mathbf{v} \in V$ 都可由 A 中向量的线性组合得到。这些向量很特殊，下面刻画它们。

2.6.1　生成集与基

定义 2.13 (生成集与张成). 考虑向量空间 $\mathcal{V} = (V, +, \cdot)$ 和向量集 $A = \{\mathbf{x}_1, \ldots, \mathbf{x}_k\} \subseteq V$。若每个 $\mathbf{v} \in V$ 都能表示为 $\mathbf{x}_1, \ldots, \mathbf{x}_k$ 的线性组合，则称 A 是 V 的生成集。A 中向量的所有线性组合构成的集合称为 A 的张成（span）。若 A 张成向量空间 V，记作 $V = \text{span}[A]$ 或 $V = \text{span}[\mathbf{x}_1, \ldots, \mathbf{x}_k]$。

张成集

生成集就是张成向量（子）空间的向量集，即每个向量都能表示为生成集中向量的线性组合。现在我们更精确地刻画张成一个向量（子）空间的最小生成集。

定义 2.14 (基). 考虑向量空间 $\mathcal{V} = (V, +, \cdot)$，$A \subseteq V$。若不存在更小的集合 $\tilde{A} \subsetneq A \subseteq V$ 也能张成 V，则称 V 的生成集 A 是极小的。V 的每个线性无关生成集都是极小的，称为 V 的一组基。

极小基

原书p.45

基是极小生成集，也是极大线性无关向量集

设 $\mathcal{V} = (V, +, \cdot)$ 是向量空间，$B \subseteq V$，$B \neq \emptyset$。则下列命题等价:

- B 是 V 的一组基;
- B 是极小生成集;
- B 是 V 中的极大线性无关向量集，即再加入任何其他向量都会使其线性相关;
- 每个 $\mathbf{x} \in V$ 都是 B 中向量的线性组合，且每个线性组合唯一，即若

$$\sum_{i=1}^{k} \lambda_i \mathbf{b}_i = \sum_{i=1}^{k} \psi_i \mathbf{b}_i \tag{2.77}$$

且 $\lambda_i, \psi_i \in \mathbb{R}$、$\mathbf{b}_i \in B$，则 $\lambda_i = \psi_i$ $(i = 1, \ldots, k)$。

正则基

例 2.16 在 $\mathbb{R}^3$ 中，正则基/标准基为

$$B = \left\{ \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \right\}. \tag{2.78}$$

$\mathbb{R}^3$ 中的其他基有

$$B_1 = \left\{ \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} \right\}, \quad B_2 = \left\{ \begin{bmatrix} 0.5 \\ 0.8 \\ 0.4 \end{bmatrix}, \begin{bmatrix} 1.8 \\ 0.3 \\ 0.3 \end{bmatrix}, \begin{bmatrix} -2.2 \\ -1.3 \\ 3.5 \end{bmatrix} \right\}. \tag{2.79}$$

集合

$$A = \left\{ \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \end{bmatrix}, \begin{bmatrix} 2 \\ -1 \\ 0 \\ 2 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \\ 0 \\ -4 \end{bmatrix} \right\} \tag{2.80}$$

线性无关，但不是 $\mathbb{R}^4$ 的生成集（因而不是基）: 例如向量 $[1, 0, 0, 0]^\top$ 无法由 A 中元素的线性组合得到。

每个向量空间 V 都有一组基 B。上面的例子表明向量空间 V 可以有多组基，即基不唯一。但所有基所含元素（基向量）个数相同。

基向量

我们只考虑有限维向量空间 V。此时 V 的维数就是 V 的基向量个数，记作 $\dim(V)$。若 $U \subseteq V$ 是 V 的子空间，则 $\dim(U) \leqslant \dim(V)$，且 $\dim(U) = \dim(V)$ 当且仅当 $U = V$。直观上，向量空间的维数可理解为该向量空间中独立方向的个数。

维数

原书p.46

向量空间的维数等于其基向量个数

向量空间的维数不一定是向量中元素的个数。例如向量空间 $V = \text{span}\left[\begin{bmatrix}0\\1\end{bmatrix}\right]$ 是一维的，尽管基向量含两个元素。

子空间 $U = \text{span}[\mathbf{x}_1, \ldots, \mathbf{x}_m] \subseteq \mathbb{R}^n$ 的一组基可按以下步骤求出：

1. 把张成向量写成矩阵 $\mathbf{A}$ 的列；
2. 求 $\mathbf{A}$ 的行阶梯形；
3. 与主元列对应的张成向量即 U 的一组基。

例 2.17（求基） 对子空间 $U \subseteq \mathbb{R}^5$，它由下列向量张成：

$$\mathbf{x}_1 = \begin{bmatrix}1\\2\\-1\\-1\\-1\end{bmatrix},\ \mathbf{x}_2 = \begin{bmatrix}2\\-1\\1\\2\\-2\end{bmatrix},\ \mathbf{x}_3 = \begin{bmatrix}3\\-4\\3\\5\\-3\end{bmatrix},\ \mathbf{x}_4 = \begin{bmatrix}-1\\8\\-5\\-6\\1\end{bmatrix} \in \mathbb{R}^5, \tag{2.81}$$

我们想知道 $\mathbf{x}_1, \ldots, \mathbf{x}_4$ 中哪些构成 U 的一组基。为此需判断它们是否线性无关，即求解

$$\sum_{i=1}^{4} \lambda_i \mathbf{x}_i = \mathbf{0}, \tag{2.82}$$

它对应以

$$[\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3, \mathbf{x}_4] = \begin{bmatrix}1 & 2 & 3 & -1\\2 & -1 & -4 & 8\\-1 & 1 & 3 & -5\\-1 & 2 & 5 & -6\\-1 & -2 & -3 & 1\end{bmatrix} \tag{2.83}$$

为矩阵的齐次方程组。利用方程组的基本变换规则，得到行阶梯形

$$\begin{bmatrix}1 & 2 & 3 & -1\\2 & -1 & -4 & 8\\-1 & 1 & 3 & -5\\-1 & 2 & 5 & -6\\-1 & -2 & -3 & 1\end{bmatrix} \rightsquigarrow \cdots \rightsquigarrow \begin{bmatrix}1 & 2 & 3 & -1\\0 & 1 & 2 & -2\\0 & 0 & 0 & 1\\0 & 0 & 0 & 0\\0 & 0 & 0 & 0\end{bmatrix}.$$

由于主元列指出哪些向量线性无关，由行阶梯形可见 $\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_4$ 线性无关（因为方程组 $\lambda_1\mathbf{x}_1 + \lambda_2\mathbf{x}_2 + \lambda_4\mathbf{x}_4 = \mathbf{0}$ 只能由 $\lambda_1 = \lambda_2 = \lambda_4 = 0$ 求解）。因此 $\{\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_4\}$ 是 U 的一组基。 原书p.47

2.6.2 秩

矩阵 $\mathbf{A} \in \mathbb{R}^{m\times n}$ 的线性无关列数等于线性无关行数，称为 $\mathbf{A}$ 的秩，记作 $\text{rk}(\mathbf{A})$。 秩

矩阵的秩有以下重要性质：

- $\mathrm{rk}(\mathbf{A}) = \mathrm{rk}(\mathbf{A}^\top)$，即列秩等于行秩。
- $\mathbf{A} \in \mathbb{R}^{m\times n}$ 的各列张成子空间 $U \subseteq \mathbb{R}^m$，且 $\dim(U) = \mathrm{rk}(\mathbf{A})$。之后称此子空间为像或值域。对 $\mathbf{A}$ 做高斯消元找出主元列，即可得到 U 的一组基。
- $\mathbf{A} \in \mathbb{R}^{m\times n}$ 的各行张成子空间 $W \subseteq \mathbb{R}^n$，且 $\dim(W) = \mathrm{rk}(\mathbf{A})$。对 $\mathbf{A}^\top$ 做高斯消元可得 W 的一组基。
- 对所有 $\mathbf{A} \in \mathbb{R}^{n\times n}$，$\mathbf{A}$ 正则（可逆）当且仅当 $\mathrm{rk}(\mathbf{A}) = n$。
- 对所有 $\mathbf{A} \in \mathbb{R}^{m\times n}$ 和所有 $\mathbf{b} \in \mathbb{R}^m$，方程组 $\mathbf{Ax} = \mathbf{b}$ 有解当且仅当 $\mathrm{rk}(\mathbf{A}) = \mathrm{rk}(\mathbf{A} \mid \mathbf{b})$，其中 $\mathbf{A} \mid \mathbf{b}$ 表示增广方程组。
- 对 $\mathbf{A} \in \mathbb{R}^{m\times n}$，$\mathbf{Ax} = \mathbf{0}$ 的解子空间维数为 $n - \mathrm{rk}(\mathbf{A})$。之后称此子空间为核或零空间。

零空间

- 若矩阵 $\mathbf{A} \in \mathbb{R}^{m\times n}$ 的秩等于同维矩阵可能的最大秩，则称它满秩。即满秩矩阵的秩等于行数与列数的较小者：$\mathrm{rk}(\mathbf{A}) = \min(m, n)$。不满秩的矩阵称为秩亏。

满秩

例 2.18（秩） $\mathbf{A} = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & 0 \end{bmatrix}$。$\mathbf{A}$ 有两个线性无关的行/列，故 $\mathrm{rk}(\mathbf{A}) = 2$。 原书p.48

$\mathbf{A} = \begin{bmatrix} 1 & 2 & 1 \\ -2 & -3 & 1 \\ 3 & 5 & 0 \end{bmatrix}$。用高斯消元求秩：

$$\begin{bmatrix} 1 & 2 & 1 \\ -2 & -3 & 1 \\ 3 & 5 & 0 \end{bmatrix} \rightsquigarrow \cdots \rightsquigarrow \begin{bmatrix} 1 & 2 & 1 \\ 0 & 1 & 3 \\ 0 & 0 & 0 \end{bmatrix}. \tag{2.84}$$

可见线性无关的行与列数为 2，故 $\mathrm{rk}(\mathbf{A}) = 2$。

2.7　线性映射

下面研究向量空间上保持其结构的映射，这将让我们能定义坐标概念。本章开头说过，向量是可相加、可乘标量、结果仍为向量的对象。我们希望施加映射时也保持这一性质：考虑两个实向量空间 V, W。映射 $\Phi : V \to W$ 保持向量空间结构，若

$$\Phi(\mathbf{x} + \mathbf{y}) = \Phi(\mathbf{x}) + \Phi(\mathbf{y}) \tag{2.85}$$

$$\Phi(\lambda\mathbf{x}) = \lambda\Phi(\mathbf{x}) \tag{2.86}$$

对所有 $\mathbf{x}, \mathbf{y} \in V$ 和 $\lambda \in \mathbb{R}$ 成立。可概括为下面的定义。

定义 2.15 (线性映射). 对向量空间 V, W，若映射 $\Phi : V \to W$ 满足　线性映射

$$\forall \mathbf{x}, \mathbf{y} \in V \; \forall \lambda, \psi \in \mathbb{R} : \quad \Phi(\lambda \mathbf{x} + \psi \mathbf{y}) = \lambda \Phi(\mathbf{x}) + \psi \Phi(\mathbf{y}), \tag{2.87}$$

则称 Φ 为线性映射（亦称向量空间同态/线性变换）。　线性变换　向量空间同态

可以证明线性映射可用矩阵表示（第 2.7.1 节）。回顾一下，我们也可把一组向量收集为矩阵的列。使用矩阵时要牢记矩阵代表什么：是线性映射，还是一组向量的集合。第 4 章将进一步讨论线性映射。继续之前先简要介绍特殊映射。

定义 2.16 (单射、满射、双射). 考虑映射 $\Phi : V \to W$，其中 V, W 可以是任意集合。则：　单射

- Φ 是单射（injective），若 $\forall \mathbf{x}, \mathbf{y} \in V : \; \Phi(\mathbf{x}) = \Phi(\mathbf{y}) \Rightarrow \mathbf{x} = \mathbf{y}$；
- Φ 是满射（surjective），若 $\Phi(V) = W$；　满射
- Φ 是双射（bijective），若它既单射又满射。　双射

若 Φ 是满射，则 W 中每个元素都能由 Φ 从 V “到达”。双射 Φ 可被“撤销”，即存在映射 $\Psi : W \to V$ 使 $\Psi \circ \Phi(\mathbf{x}) = \mathbf{x}$，这个 Ψ 称为 Φ 的逆，通常记作 Φ^{-1}。　原书p.49

由这些定义，我们引入向量空间 V, W 之间线性映射的以下特殊情形：

- 同构（isomorphism）：$\Phi : V \to W$ 线性且双射；　同构
- 自同态（endomorphism）：$\Phi : V \to V$ 线性；　自同态
- 自同构（automorphism）：$\Phi : V \to V$ 线性且双射。　自同构

我们把 $\mathrm{id}_V : V \to V$，$\mathbf{x} \mapsto \mathbf{x}$，定义为 V 中的恒等映射或恒等自同构。　恒等映射　恒等自同构

例 2.19（同态） 映射 $\Phi : \mathbb{R}^2 \to \mathbb{C}$，$\Phi(\mathbf{x}) = x_1 + \mathrm{i} x_2$，是一个同态：

$$\Phi\left(\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + \begin{bmatrix} y_1 \\ y_2 \end{bmatrix}\right) = (x_1 + y_1) + \mathrm{i}(x_2 + y_2) = x_1 + \mathrm{i} x_2 + y_1 + \mathrm{i} y_2 \tag{2.88a}$$

$$= \Phi\left(\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}\right) + \Phi\left(\begin{bmatrix} y_1 \\ y_2 \end{bmatrix}\right) \tag{2.88b}$$

$$\Phi\left(\lambda \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}\right) = \lambda x_1 + \lambda \mathrm{i} x_2 = \lambda(x_1 + \mathrm{i} x_2) = \lambda \Phi\left(\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}\right). \tag{2.88c}$$

这也说明了为什么复数可表示为 $\mathbb{R}^2$ 中的元组：存在一个双射线性映射，把 $\mathbb{R}^2$ 中元组的逐元素加法转化为复数集上相应的加法。注意这里只证明了线性，未证明双射。

定理 2.17 (Axler (2015) 中 Theorem 3.59). 有限维向量空间 V 与 W 同构，当且仅当 $\dim(V) = \dim(W)$。

定理 2.17 表明，维数相同的两个向量空间之间存在线性双射映射。直观上这意味着维数相同的向量空间在某种意义上是同一种东西，因为它们可以彼此转化而不损失信息。定理 2.17 也让我们有理由把 $\mathbb{R}^{m\times n}$（$m\times n$ 矩阵的向量空间）与 $\mathbb{R}^{mn}$（长度为 mn 的向量空间）同等看待，因为它们维数都是 mn，且存在把其一变为另一的线性双射映射。

考虑向量空间 V, W, X。则：

- 对线性映射 $\Phi: V\to W$ 和 $\Psi: W\to X$，复合映射 $\Psi\circ\Phi: V\to X$ 也线性。
- 若 $\Phi: V\to W$ 是同构，则 $\Phi^{-1}: W\to V$ 也是同构。
- 若 $\Phi: V\to W$、$\Psi: V\to W$ 线性，则 $\Phi+\Psi$ 和 $\lambda\Phi$（$\lambda\in\mathbb{R}$）也线性。

原书p.50

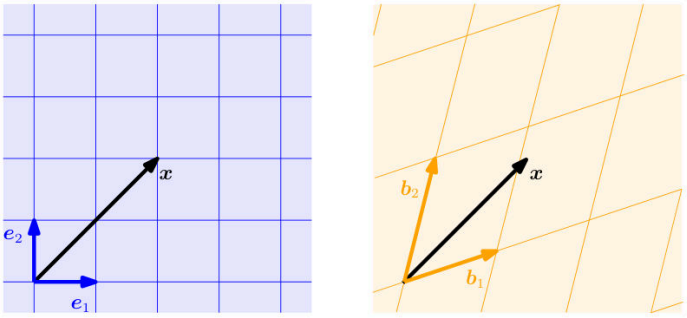


图 2.8: 由两组基向量定义的两个不同坐标系。同一向量 $\mathbf{x}$ 在不同坐标系下有不同的坐标表示。

2.7.1　线性映射的矩阵表示

任意 n 维向量空间都与 $\mathbb{R}^n$ 同构（定理 2.17）。考虑 n 维向量空间 V 的一组基 $\{\mathbf{b}_1,\dots,\mathbf{b}_n\}$。下面基向量的顺序很重要，因此写

$$B=(\mathbf{b}_1,\dots,\mathbf{b}_n) \tag{2.89}$$

并称这个 n 元组为 V 的一组有序基。

有序基

[记号] 这里记号变得有点微妙，集中说明：$B=(\mathbf{b}_1,\dots,\mathbf{b}_n)$ 是有序基；$\mathcal{B}=\{\mathbf{b}_1,\dots,\mathbf{b}_n\}$ 是（无序）基；$\mathbf{B}=[\mathbf{b}_1,\dots,\mathbf{b}_n]$ 是以 $\mathbf{b}_1,\dots,\mathbf{b}_n$ 为列的矩阵。

定义 2.18 (坐标). 考虑向量空间 V 及其有序基 $B=(\mathbf{b}_1,\dots,\mathbf{b}_n)$。对任意 $\mathbf{x}\in V$，存在唯一表示（线性组合）

坐标

$$\mathbf{x}=\alpha_1\mathbf{b}_1+\cdots+\alpha_n\mathbf{b}_n \tag{2.90}$$

则 $\alpha_1,\dots,\alpha_n$ 是 $\mathbf{x}$ 在基 B 下的坐标，而向量

$$\boldsymbol{\alpha}=\begin{bmatrix}\alpha_1\\ \vdots\\ \alpha_n\end{bmatrix}\in\mathbb{R}^n \tag{2.91}$$

是 $\mathbf{x}$ 在有序基 B 下的坐标向量/坐标表示。

坐标向量

一组基实际上定义了一个坐标系。我们熟悉二维笛卡尔坐标系，它由正则基向量 $\mathbf{e}_1, \mathbf{e}_2$ 张成。在该坐标系中，向量 $\mathbf{x} \in \mathbb{R}^2$ 的表示告诉我们如何线性组合 $\mathbf{e}_1, \mathbf{e}_2$ 得到 $\mathbf{x}$。但 $\mathbb{R}^2$ 的任一组基都定义了一个合法坐标系，前面那个 $\mathbf{x}$ 在基 $(\mathbf{b}_1, \mathbf{b}_2)$ 下可能有不同坐标。在图 2.8 中，$\mathbf{x}$ 在标准基 $(\mathbf{e}_1, \mathbf{e}_2)$ 下的坐标是 $[2, 2]^\top$，而在基 $(\mathbf{b}_1, \mathbf{b}_2)$ 下同一向量 $\mathbf{x}$ 表示为 $[1.09, 0.72]^\top$，即 $\mathbf{x} = 1.09\mathbf{b}_1 + 0.72\mathbf{b}_2$。后面几节将说明如何得到这一表示。 原书p.51

例 2.20 看一个几何向量 $\mathbf{x} \in \mathbb{R}^2$，它在 $\mathbb{R}^2$ 标准基 $(\mathbf{e}_1, \mathbf{e}_2)$ 下的坐标为 $[2, 3]^\top$，即 $\mathbf{x} = 2\mathbf{e}_1 + 3\mathbf{e}_2$。但表示这个向量不必选标准基。若选基向量 $\mathbf{b}_1 = [1, -1]^\top$、$\mathbf{b}_2 = [1, 1]^\top$，则同一向量在 $(\mathbf{b}_1, \mathbf{b}_2)$ 下的坐标为 $\frac{1}{2}[-1, 5]^\top$（见图 2.9）。

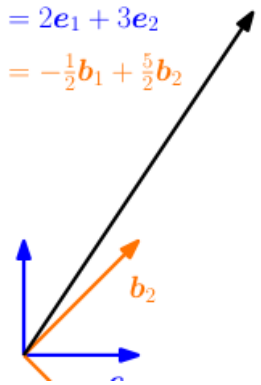


图 2.9: 向量 $\mathbf{x}$ 在不同基下的不同坐标表示。

对 n 维向量空间 V 及其有序基 B,映射 $\Phi : \mathbb{R}^n \to V$、$\Phi(\mathbf{e}_i) = \mathbf{b}_i (i = 1, \ldots, n)$ 是线性的（且由定理 2.17 是同构），其中 $(\mathbf{e}_1, \ldots, \mathbf{e}_n)$ 是 $\mathbb{R}^n$ 的标准基。

现在我们可以显式建立矩阵与有限维向量空间之间线性映射的联系。

定义 2.19 (变换矩阵). 考虑向量空间 V, W 及相应（有序）基 $B = (\mathbf{b}_1, \ldots, \mathbf{b}_n)$、$C = (\mathbf{c}_1, \ldots, \mathbf{c}_m)$，以及线性映射 $\Phi : V \to W$。对 $j \in \{1, \ldots, n\}$，

$$\Phi(\mathbf{b}_j) = \alpha_{1j}\mathbf{c}_1 + \cdots + \alpha_{mj}\mathbf{c}_{mj} = \sum_{i=1}^{m} \alpha_{ij}\mathbf{c}_i \tag{2.92}$$

是 $\Phi(\mathbf{b}_j)$ 在基 C 下的唯一表示。则元素为

$$A_\Phi(i, j) = \alpha_{ij} \tag{2.93}$$

的 $m \times n$ 矩阵 $\mathbf{A}_\Phi$ 称为 Φ（关于 V 的有序基 B 与 W 的有序基 C）的变换矩阵。 变换矩阵

$\Phi(\mathbf{b}_j)$ 在 W 的有序基 C 下的坐标就是 $\mathbf{A}_\Phi$ 的第 j 列。考虑（有限维）向量空间 V, W 及有序基 B, C，线性映射 $\Phi : V \to W$ 的变换矩阵为 $\mathbf{A}_\Phi$。若 $\hat{\mathbf{x}}$ 是 $\mathbf{x} \in V$ 在 B 下的坐标向量，$\hat{\mathbf{y}}$ 是 $\mathbf{y} = \Phi(\mathbf{x}) \in W$ 在 C 下的坐标向量，则 原书p.52

$$\hat{\mathbf{y}} = \mathbf{A}_\Phi \hat{\mathbf{x}}. \tag{2.94}$$

即变换矩阵可把 V 中某有序基下的坐标映射为 W 中另一有序基下的坐标。

例 2.21（变换矩阵） 考虑同态 $\Phi : V \to W$，V 的有序基 $B = (\mathbf{b}_1, \ldots, \mathbf{b}_3)$，$W$ 的有序基 $C = (\mathbf{c}_1, \ldots, \mathbf{c}_4)$。已知

$$\begin{aligned}\Phi(\mathbf{b}_1) &= \mathbf{c}_1 - \mathbf{c}_2 + 3\mathbf{c}_3 - \mathbf{c}_4 \\ \Phi(\mathbf{b}_2) &= 2\mathbf{c}_1 + \mathbf{c}_2 + 7\mathbf{c}_3 + 2\mathbf{c}_4 \\ \Phi(\mathbf{b}_3) &= 3\mathbf{c}_2 + \mathbf{c}_3 + 4\mathbf{c}_4\end{aligned} \tag{2.95}$$

则关于 B, C 的变换矩阵 $\mathbf{A}_\Phi$ 满足 $\Phi(\mathbf{b}_k) = \sum_{i=1}^{4} \alpha_{ik}\mathbf{c}_i$（$k = 1, 2, 3$），为

$$\mathbf{A}_\Phi = [\boldsymbol{\alpha}_1, \boldsymbol{\alpha}_2, \boldsymbol{\alpha}_3] = \begin{bmatrix} 1 & 2 & 0 \\ -1 & 1 & 3 \\ 3 & 7 & 1 \\ -1 & 2 & 4 \end{bmatrix}, \tag{2.96}$$

其中 $\boldsymbol{\alpha}_j$（$j = 1, 2, 3$）是 $\Phi(\mathbf{b}_j)$ 在 C 下的坐标向量。

例 2.22（向量的线性变换） 我们对 $\mathbb{R}^2$ 中的一组向量做三种线性变换，变换矩阵为

$$\mathbf{A}_1 = \begin{bmatrix} \cos(\frac{\pi}{4}) & -\sin(\frac{\pi}{4}) \\ \sin(\frac{\pi}{4}) & \cos(\frac{\pi}{4}) \end{bmatrix}, \quad \mathbf{A}_2 = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}, \quad \mathbf{A}_3 = \frac{1}{2}\begin{bmatrix} 3 & -1 \\ 1 & -1 \end{bmatrix}. \tag{2.97}$$

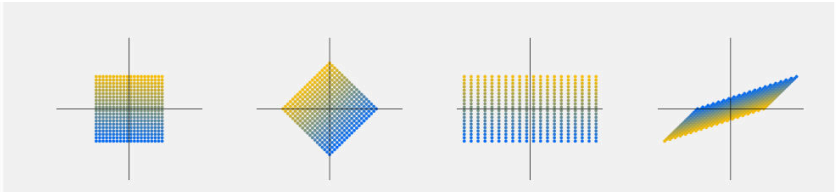


图 2.10: 向量线性变换的三个例子：(a) 原始数据（点）；(b) 旋转 45°；(c) 横坐标拉伸为 2 倍；(d) 反射、旋转与拉伸的组合。

图 2.10 给出了一组向量线性变换的三个例子。图 2.10(a) 是 $\mathbb{R}^2$ 中的 400 个向量，每个用对应 (x_1, x_2) 坐标处的点表示，排列成正方形。用 (2.97) 中矩阵 $\mathbf{A}_1$ 线性变换每个向量，得到图 2.10(b) 中旋转后的正方形。施加 $\mathbf{A}_2$ 表示的线性映射，得到图 2.10(c) 中的矩形，每个 x_1 坐标被拉伸为 2 倍。图 2.10(d) 是图 2.10(a) 的原正方形经 $\mathbf{A}_3$ 线性变换的结果，它是反射、旋转与拉伸的组合。

原书p.53

2.7.2　基变换

下面仔细考察：当我们改变 V 和 W 中的基时，线性映射 $\Phi : V \to W$ 的变换矩阵如何变化。考虑 V 的两组有序基

$$B = (\mathbf{b}_1, \ldots, \mathbf{b}_n), \quad \tilde{B} = (\tilde{\mathbf{b}}_1, \ldots, \tilde{\mathbf{b}}_n) \tag{2.98}$$

和 W 的两组有序基

$$C = (\mathbf{c}_1, \ldots, \mathbf{c}_m), \quad \tilde{C} = (\tilde{\mathbf{c}}_1, \ldots, \tilde{\mathbf{c}}_m). \tag{2.99}$$

$\mathbf{A}_\Phi \in \mathbb{R}^{m\times n}$ 是线性映射 $\Phi : V \to W$ 关于基 B, C 的变换矩阵，$\tilde{\mathbf{A}}_\Phi \in \mathbb{R}^{m\times n}$ 是关于 $\tilde{B}, \tilde{C}$ 的相应变换矩阵。下面研究 $\mathbf{A}$ 与 $\tilde{\mathbf{A}}$ 的关系，即从 B, C 换到 $\tilde{B}, \tilde{C}$ 时能否把 $\mathbf{A}_\Phi$ 变成 $\tilde{\mathbf{A}}_\Phi$。

我们实际上得到的是恒等映射 id_V 的不同坐标表示。在图 2.9 的语境下，这意味着在不改变向量 $\mathbf{x}$ 的前提下，把 $(\mathbf{e}_1, \mathbf{e}_2)$ 下的坐标映射为 $(\mathbf{b}_1, \mathbf{b}_2)$ 下的坐标。通过更换基并相应地改变向量表示，关于新基的变换矩阵可以具有特别简单的形式，便于直接计算。

例 2.23（基变换） 考虑关于 $\mathbb{R}^2$ 正则基的变换矩阵

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}. \tag{2.100}$$

若定义新基

$$B = \left(\begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right) \tag{2.101}$$

则得到关于 B 的对角变换矩阵

原书p.54

$$\tilde{\mathbf{A}} = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix}, \tag{2.102}$$

它比 $\mathbf{A}$ 更容易处理。

下面研究把一组基下的坐标向量变换为另一组基下坐标向量的映射。先给出主要结果再解释。

定理 2.20 (基变换). 对线性映射 $\Phi : V \to W$，V 的有序基

$$B = (\mathbf{b}_1, \ldots, \mathbf{b}_n), \quad \tilde{B} = (\tilde{\mathbf{b}}_1, \ldots, \tilde{\mathbf{b}}_n) \tag{2.103}$$

与 W 的有序基

$$C = (\mathbf{c}_1, \ldots, \mathbf{c}_m), \quad \tilde{C} = (\tilde{\mathbf{c}}_1, \ldots, \tilde{\mathbf{c}}_m) \tag{2.104}$$

以及 Φ 关于 B, C 的变换矩阵 $\mathbf{A}_\Phi$，则 Φ 关于 $\tilde{B}, \tilde{C}$ 的相应变换矩阵 $\tilde{\mathbf{A}}_\Phi$ 为

$$\tilde{\mathbf{A}}_\Phi = \mathbf{T}^{-1}\mathbf{A}_\Phi\mathbf{S}. \tag{2.105}$$

这里 $\mathbf{S} \in \mathbb{R}^{n\times n}$ 是 id_V 的变换矩阵，把 $\tilde{B}$ 下的坐标映射为 B 下的坐标；$\mathbf{T} \in \mathbb{R}^{m\times m}$ 是 id_W 的变换矩阵，把 $\tilde{C}$ 下的坐标映射为 C 下的坐标。

证明. 按 Drumm and Weil (2001)，可把 V 的新基 $\tilde{B}$ 的向量写成 B 的基向量的线性组合：

$$\tilde{\mathbf{b}}_j = s_{1j}\mathbf{b}_1 + \cdots + s_{nj}\mathbf{b}_n = \sum_{i=1}^{n} s_{ij}\mathbf{b}_i, \qquad j = 1, \ldots, n. \tag{2.106}$$

类似地，把 W 的新基向量 $\tilde{C}$ 写成 C 的基向量的线性组合：

$$\tilde{\mathbf{c}}_k = t_{1k}\mathbf{c}_1 + \cdots + t_{mk}\mathbf{c}_m = \sum_{l=1}^{m} t_{lk}\mathbf{c}_l, \qquad k = 1, \ldots, m. \tag{2.107}$$

定义 $\mathbf{S} = ((s_{ij})) \in \mathbb{R}^{n\times n}$ 为把 $\tilde{B}$ 下坐标映射为 B 下坐标的变换矩阵，$\mathbf{T} = ((t_{lk})) \in \mathbb{R}^{m\times m}$ 为把 $\tilde{C}$ 下坐标映射为 C 下坐标的变换矩阵。特别地，$\mathbf{S}$ 的第 j 列是 $\tilde{\mathbf{b}}_j$ 在 B 下的坐标表示，$\mathbf{T}$ 的第 k 列是 $\tilde{\mathbf{c}}_k$ 在 C 下的坐标表示。注意 $\mathbf{S}, \mathbf{T}$ 都正则。 原书p.55

从两个角度看 $\Phi(\tilde{\mathbf{b}}_j)$。首先施加映射 Φ，对所有 $j = 1, \ldots, n$ 有

$$\Phi(\tilde{\mathbf{b}}_j) \overset{(2.107)}{=} \sum_{k=1}^{m} \underbrace{\tilde{a}_{kj}\tilde{\mathbf{c}}_k}_{\in W} = \sum_{k=1}^{m} \tilde{a}_{kj} \sum_{l=1}^{m} t_{lk}\mathbf{c}_l = \sum_{l=1}^{m} \left(\sum_{k=1}^{m} t_{lk}\tilde{a}_{kj} \right) \mathbf{c}_l, \tag{2.108}$$

这里先把新基向量 $\tilde{\mathbf{c}}_k \in W$ 表示成基向量 $\mathbf{c}_l \in W$ 的线性组合，再交换求和次序。

另一方面，把 $\tilde{\mathbf{b}}_j \in V$ 表示成 $\mathbf{b}_j \in V$ 的线性组合，得

$$\Phi(\tilde{\mathbf{b}}_j) \overset{(2.106)}{=} \Phi\left(\sum_{i=1}^{n} s_{ij}\mathbf{b}_i \right) = \sum_{i=1}^{n} s_{ij}\Phi(\mathbf{b}_i) = \sum_{i=1}^{n} s_{ij} \sum_{l=1}^{m} a_{li}\mathbf{c}_l \tag{2.109a}$$

$$= \sum_{l=1}^{m} \left(\sum_{i=1}^{n} a_{li}s_{ij} \right) \mathbf{c}_l, \qquad j = 1, \ldots, n, \tag{2.109b}$$

这里用到了 Φ 的线性。比较 (2.108) 与 (2.109b), 对所有 $j = 1, \ldots, n$、$l = 1, \ldots, m$ 有

$$\sum_{k=1}^{m} t_{lk}\tilde{a}_{kj} = \sum_{i=1}^{n} a_{li}s_{ij} \tag{2.110}$$

因而

$$\mathbf{T}\tilde{\mathbf{A}}_\Phi = \mathbf{A}_\Phi\mathbf{S} \in \mathbb{R}^{m\times n}, \tag{2.111}$$

即

$$\tilde{\mathbf{A}}_\Phi = \mathbf{T}^{-1}\mathbf{A}_\Phi\mathbf{S}, \tag{2.112}$$

定理 2.20 得证。 □

定理 2.20 告诉我们：在 V 中把 B 换成 $\tilde{B}$、在 W 中把 C 换成 $\tilde{C}$ 时，线性映射 $\Phi : V \to W$ 的变换矩阵 $\mathbf{A}_\Phi$ 被等价矩阵 $\tilde{\mathbf{A}}_\Phi$ 替换，且

$$\tilde{\mathbf{A}}_\Phi = \mathbf{T}^{-1}\mathbf{A}_\Phi\mathbf{S}. \tag{2.113}$$

图 2.11 说明了这一关系：考虑同态 $\Phi : V \to W$，V 的有序基 $B, \tilde{B}$，W 的有序基 $C, \tilde{C}$。映射 $\Phi_{C,B}$ 是 Φ 的一个实例，把 B 的基向量映到 C 的基向量的线性组合。设已知 $\Phi_{C,B}$ 关于有序基 B, C 的变换矩阵 $\mathbf{A}_\Phi$。当在 V 中从 B 换到 $\tilde{B}$、在 W 中从 C 换到 $\tilde{C}$ 时，可如下确定对应变换矩阵 $\tilde{\mathbf{A}}_\Phi$：先求线性映射 $\Psi_{B,\tilde{B}} : V \to V$ 的矩阵表示，它把新基 $\tilde{B}$ 下的坐标映射为 V 中“旧”基 B 下的（唯一）坐标；再用 $\Phi_{C,B} : V \to W$ 的变换矩阵 $\mathbf{A}_\Phi$ 把这些坐标映射为 W 中 C 下的坐标；最后用线性映射 $\Xi_{\tilde{C},C} : W \to W$ 把 C 下的坐标映射为 $\tilde{C}$ 下的坐标。因此可把线性映射 $\Phi_{\tilde{C},\tilde{B}}$ 表示为涉及“旧”基的线性映射的复合：

$$\Phi_{\tilde{C},\tilde{B}} = \Xi_{\tilde{C},C} \circ \Phi_{C,B} \circ \Psi_{B,\tilde{B}} = \Xi^{-1}_{C,\tilde{C}} \circ \Phi_{C,B} \circ \Psi_{B,\tilde{B}}. \tag{2.114}$$

具体地，取 $\Psi_{B,\tilde{B}} = \mathrm{id}_V$、$\Xi_{C,\tilde{C}} = \mathrm{id}_W$，即把向量映到自身、只是基不同的恒等映射。

原书p.56

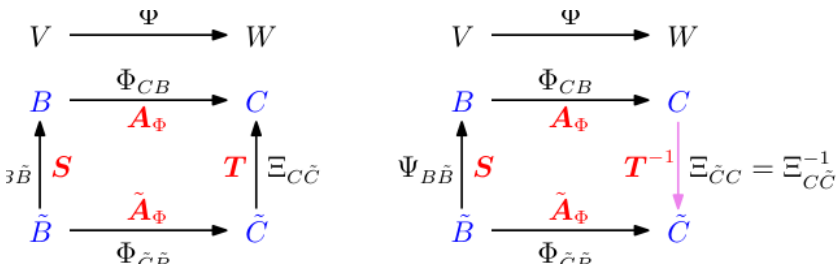


图 2.11: 对同态 $\Phi : V \to W$ 及 V 的有序基 $B, \tilde{B}$、W 的有序基 $C, \tilde{C}$（蓝色标出），关于基 $\tilde{B}, \tilde{C}$ 的映射 $\Phi_{\tilde{C},\tilde{B}}$ 可等价地表示为下标基所对应的同态之复合。相应变换矩阵以红色标出。

定义 2.21 (等价). 若存在正则矩阵 $\mathbf{S} \in \mathbb{R}^{n\times n}$ 和 $\mathbf{T} \in \mathbb{R}^{m\times m}$ 使 $\tilde{\mathbf{A}} = \mathbf{T}^{-1}\mathbf{A}\mathbf{S}$，则称矩阵 $\mathbf{A}, \tilde{\mathbf{A}} \in \mathbb{R}^{m\times n}$ 等价。

等价

定义 2.22 (相似). 若存在正则矩阵 $\mathbf{S} \in \mathbb{R}^{n\times n}$ 使 $\tilde{\mathbf{A}} = \mathbf{S}^{-1}\mathbf{A}\mathbf{S}$，则称矩阵 $\mathbf{A}, \tilde{\mathbf{A}} \in \mathbb{R}^{n\times n}$ 相似。

相似

相似矩阵总是等价的；但等价矩阵未必相似。

考虑向量空间 V, W, X。由定理 2.17 后的注，已知对线性映射 $\Phi : V \to W$ 和 $\Psi : W \to X$，复合 $\Psi \circ \Phi : V \to X$ 也线性。设相应映射的变换矩阵为 $\mathbf{A}_\Phi$、$\mathbf{A}_\Psi$，则总的变换矩阵为 $\mathbf{A}_{\Psi\circ\Phi} = \mathbf{A}_\Psi\mathbf{A}_\Phi$。

由这条注，可从复合线性映射的角度看基变换：

- $\mathbf{A}_\Phi$ 是线性映射 $\Phi_{C,B} : V \to W$ 关于基 B, C 的变换矩阵；
- $\tilde{\mathbf{A}}_\Phi$ 是线性映射 $\Phi_{\tilde{C},\tilde{B}} : V \to W$ 关于基 $\tilde{B}, \tilde{C}$ 的变换矩阵；
- $\mathbf{S}$ 是线性映射 $\Psi_{B,\tilde{B}} : V \to V$（自同构）关于用 B 表示 $\tilde{B}$ 的变换矩阵；通常 $\Psi = \mathrm{id}_V$ 是 V 中的恒等映射；
- $\mathbf{T}$ 是线性映射 $\Xi_{C,\tilde{C}} : W \to W$（自同构）关于用 C 表示 $\tilde{C}$ 的变换矩阵；通常 $\Xi = \mathrm{id}_W$ 是 W 中的恒等映射。

原书p.57

若（非正式地）只用基写出变换，则 $\mathbf{A}_\Phi : B \to C$，$\tilde{\mathbf{A}}_\Phi : \tilde{B} \to \tilde{C}$，$\mathbf{S} : \tilde{B} \to B$，$\mathbf{T} : \tilde{C} \to C$，$\mathbf{T}^{-1} : C \to \tilde{C}$，且

$$\tilde{B} \to \tilde{C} = \tilde{B} \to B \to C \to \tilde{C} \tag{2.115}$$

$$\tilde{\mathbf{A}}_\Phi = \mathbf{T}^{-1}\mathbf{A}_\Phi\mathbf{S}. \tag{2.116}$$

注意 (2.116) 的执行顺序是从右到左，因为向量乘在右侧：$\mathbf{x} \mapsto \mathbf{S}\mathbf{x} \mapsto \mathbf{A}_\Phi(\mathbf{S}\mathbf{x}) \mapsto \mathbf{T}^{-1}(\mathbf{A}_\Phi(\mathbf{S}\mathbf{x})) = \tilde{\mathbf{A}}_\Phi\mathbf{x}$。

例 2.24（基变换） 考虑线性映射 $\Phi : \mathbb{R}^3 \to \mathbb{R}^4$，其变换矩阵关于标准基为

$$\mathbf{A}_\Phi = \begin{bmatrix} 1 & 2 & 0 \\ -1 & 1 & 3 \\ 3 & 7 & 1 \\ -1 & 2 & 4 \end{bmatrix} \tag{2.117}$$

其中

$$B = \left(\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \right), \quad C = \left(\begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 0 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 0 \\ 0 \\ 1 \end{bmatrix} \right). \tag{2.118}$$

我们求 Φ 关于新基

$$\tilde{B} = \left(\begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} \right) \in \mathbb{R}^3, \quad \tilde{C} = \left(\begin{bmatrix} 1 \\ 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \\ 0 \\ 1 \end{bmatrix} \right) \tag{2.119}$$

的变换矩阵 $\tilde{\mathbf{A}}_\Phi$。则

$$\mathbf{S} = \begin{bmatrix} 1 & 0 & 1 \\ 1 & 1 & 0 \\ 0 & 1 & 1 \end{bmatrix}, \qquad \mathbf{T} = \begin{bmatrix} 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 \\ 0 & 1 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}, \tag{2.120}$$

其中 $\mathbf{S}$ 的第 i 列是 $\tilde{\mathbf{b}}_i$ 在 B 的基向量下的坐标表示。由于 B 是标准基, 坐标表示很容易求得; 对一般的 B, 则需解线性方程组求 λ_i 使 $\sum_{i=1}^{3} \lambda_i \mathbf{b}_i = \tilde{\mathbf{b}}_j$ $(j = 1, 2, 3)$。类似地, $\mathbf{T}$ 的第 j 列是 $\tilde{\mathbf{c}}_j$ 在 C 的基向量下的坐标表示。因此 原书p.58

$$\tilde{\mathbf{A}}_\Phi = \mathbf{T}^{-1} \mathbf{A}_\Phi \mathbf{S} = \frac{1}{2} \begin{bmatrix} 1 & 1 & -1 & -1 \\ 1 & -1 & 1 & -1 \\ -1 & 1 & 1 & 1 \\ 0 & 0 & 0 & 2 \end{bmatrix} \begin{bmatrix} 3 & 2 & 1 \\ 0 & 4 & 2 \\ 10 & 8 & 4 \\ 1 & 6 & 3 \end{bmatrix} \tag{2.121a}$$

$$= \begin{bmatrix} -4 & -4 & -2 \\ 6 & 0 & 0 \\ 4 & 8 & 4 \\ 1 & 6 & 3 \end{bmatrix}. \tag{2.121b}$$

第 4 章我们将能利用基变换概念找一组基，使自同构在该基下的变换矩阵具有特别简单的（对角）形式。第 10 章将研究数据压缩问题，找一组方便的基, 使数据投影上去时压缩损失最小。

2.7.3　像与核

线性映射的像与核是具有重要性质的向量子空间。下面仔细刻画它们。

定义 2.23 (像与核). 对 $\Phi : V \to W$，定义核/零空间 穆空间

$$\ker(\Phi) := \Phi^{-1}(\mathbf{0}_W) = \{\mathbf{v} \in V : \Phi(\mathbf{v}) = \mathbf{0}_W\} \tag{2.122}$$

以及像/值域　像域

$$\mathrm{Im}(\Phi) := \Phi(V) = \{\mathbf{w} \in W \mid \exists \mathbf{v} \in V : \Phi(\mathbf{v}) = \mathbf{w}\}. \tag{2.123}$$

我们也称 V、W 分别为 Φ 的定义域和陪域。　陪域域

直观上，核是被 Φ 映到单位元 $\mathbf{0}_W \in W$ 的那些向量 $\mathbf{v} \in V$ 的集合；像是 W 中能由 Φ 从 V 中某向量“到达”的向量 $\mathbf{w} \in W$ 的集合。见图 2.12。

考虑线性映射 $\Phi : V \to W$，V, W 为向量空间。

- 恒有 $\Phi(\mathbf{0}_V) = \mathbf{0}_W$，因此 $\mathbf{0}_V \in \ker(\Phi)$；特别地，零空间永非空。
- $\mathrm{Im}(\Phi) \subseteq W$ 是 W 的子空间，$\ker(\Phi) \subseteq V$ 是 V 的子空间。
- Φ 单射当且仅当 $\ker(\Phi) = \{\mathbf{0}\}$。

原书p.59

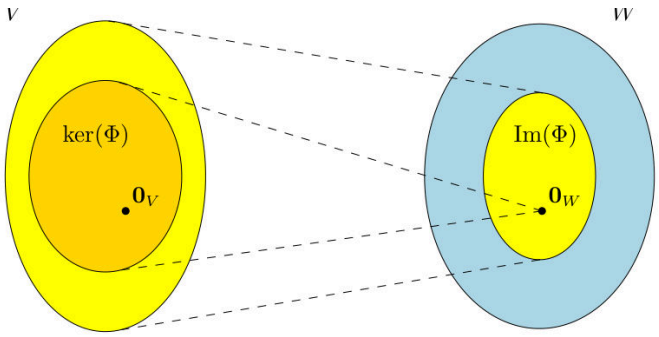


图 2.12: 线性映射 $\Phi : V \to W$ 的核与像。

[零空间与列空间] 考虑 $\mathbf{A} \in \mathbb{R}^{m \times n}$ 和线性映射 $\Phi : \mathbb{R}^n \to \mathbb{R}^m$，$\mathbf{x} \mapsto \mathbf{A}\mathbf{x}$。

- 对 $\mathbf{A} = [\mathbf{a}_1, \ldots, \mathbf{a}_n]$（$\mathbf{a}_i$ 为 $\mathbf{A}$ 的列），有

$$\mathrm{Im}(\Phi) = \{\mathbf{A}\mathbf{x} : \mathbf{x} \in \mathbb{R}^n\} = \left\{ \sum_{i=1}^{n} x_i \mathbf{a}_i : x_1, \ldots, x_n \in \mathbb{R} \right\} \tag{2.124a}$$

$$= \mathrm{span}[\mathbf{a}_1, \ldots, \mathbf{a}_n] \subseteq \mathbb{R}^m, \tag{2.124b}$$

  即像是 $\mathbf{A}$ 各列的张成，亦称列空间。因此列空间（像）是 $\mathbb{R}^m$ 的子空间　列空间
  其中 m 是矩阵的“高度”。

- $\mathrm{rk}(\mathbf{A}) = \dim(\mathrm{Im}(\Phi))$。
- 核/零空间 $\ker(\Phi)$ 是齐次方程组 $\mathbf{A}\mathbf{x} = \mathbf{0}$ 的通解，囊括了 $\mathbb{R}^n$ 中产生 $\mathbf{0} \in \mathbb{R}^m$ 的所有可能线性组合。核是 $\mathbb{R}^n$ 的子空间，其中 n 是矩阵的“宽度”。
- 核关注列之间的关系，可用来判断/如何把某一列表示为其他列的线性组合。

例 2.25（线性映射的像与核） 映射

$$\Phi:\mathbb{R}^4\to\mathbb{R}^2,\quad \begin{bmatrix}x_1\\x_2\\x_3\\x_4\end{bmatrix}\mapsto\begin{bmatrix}1&2&-1&0\\1&0&0&1\end{bmatrix}\begin{bmatrix}x_1\\x_2\\x_3\\x_4\end{bmatrix}=\begin{bmatrix}x_1+2x_2-x_3\\x_1+x_4\end{bmatrix} \tag{2.125a}$$

$$=x_1\begin{bmatrix}1\\1\end{bmatrix}+x_2\begin{bmatrix}2\\0\end{bmatrix}+x_3\begin{bmatrix}-1\\0\end{bmatrix}+x_4\begin{bmatrix}0\\1\end{bmatrix} \tag{2.125b}$$

是线性的。要确定 $\mathrm{Im}(\Phi)$，可取变换矩阵各列的张成，得

原书p.60

$$\mathrm{Im}(\Phi)=\mathrm{span}\left[\begin{bmatrix}1\\1\end{bmatrix},\begin{bmatrix}2\\0\end{bmatrix},\begin{bmatrix}-1\\0\end{bmatrix},\begin{bmatrix}0\\1\end{bmatrix}\right]. \tag{2.126}$$

要计算 Φ 的核（零空间），需解 $\mathbf{Ax}=\mathbf{0}$，即解一个齐次方程组。用高斯消元把 $\mathbf{A}$ 化成简化行阶梯形：

$$\begin{bmatrix}1&2&-1&0\\1&0&0&1\end{bmatrix}\rightsquigarrow\cdots\rightsquigarrow\begin{bmatrix}1&0&0&1\\0&1&-\frac{1}{2}&-\frac{1}{2}\end{bmatrix}. \tag{2.127}$$

该矩阵已是简化行阶梯形，可用减一技巧求核的一组基（见第 2.3.3 节）。也可把非主元列（第 3、4 列）表示为主元列（第 1、2 列）的线性组合：第三列 $\mathbf{a}_3$ 等于第二列 $\mathbf{a}_2$ 的 $-\frac{1}{2}$ 倍，因此 $\mathbf{0}=\mathbf{a}_3+\frac{1}{2}\mathbf{a}_2$。同理 $\mathbf{a}_4=\mathbf{a}_1-\frac{1}{2}\mathbf{a}_2$，故 $\mathbf{0}=\mathbf{a}_1-\frac{1}{2}\mathbf{a}_2-\mathbf{a}_4$。合起来，核（零空间）为

$$\ker(\Phi)=\mathrm{span}\left[\begin{bmatrix}0\\\frac{1}{2}\\1\\0\end{bmatrix},\begin{bmatrix}-1\\\frac{1}{2}\\0\\1\end{bmatrix}\right]. \tag{2.128}$$

秩—零化度定理

定理 2.24 (秩–零化度定理). 对向量空间 V,W 和线性映射 $\Phi:V\to W$，有

$$\dim(\ker(\Phi))+\dim(\mathrm{Im}(\Phi))=\dim(V). \tag{2.129}$$

线性映射基本定理

秩–零化度定理亦称线性映射基本定理（Axler, 2015, theorem 3.22）。由定理 2.24 直接得到：

- 若 $\dim(\mathrm{Im}(\Phi))<\dim(V)$，则 $\ker(\Phi)$ 非平凡，即核中含有多于 $\mathbf{0}_V$ 的元素，且 $\dim(\ker(\Phi))\geqslant 1$。
- 若 $\mathbf{A}_\Phi$ 是 Φ 关于某有序基的变换矩阵且 $\dim(\mathrm{Im}(\Phi))<\dim(V)$，则方程组 $\mathbf{A}_\Phi\mathbf{x}=\mathbf{0}$ 有无穷多解。
- 若 $\dim(V)=\dim(W)$，则由于 $\mathrm{Im}(\Phi)\subseteq W$，有三向等价：$\Phi$ 单射 $\iff$ Φ 满射 $\iff$ Φ 双射。

2.8　仿射空间

原书p.61

下面仔细考察偏离原点的空间，即不再是向量子空间的空间；并简要讨论这些仿射空间之间类似于线性映射的映射的性质。

在机器学习文献中，线性与仿射的区别有时不明确，因此会看到把仿射空间/映射称作线性空间/映射的说法。

2.8.1　仿射子空间

仿射子空间

定义 2.25 (仿射子空间). 设 V 是向量空间，$\mathbf{x}_0 \in V$，$U \subseteq V$ 是子空间。则子集

$$L = \mathbf{x}_0 + U := \{\mathbf{x}_0 + \mathbf{u} : \mathbf{u} \in U\} \tag{2.130a}$$

$$= \{\mathbf{v} \in V \mid \exists \mathbf{u} \in U : \mathbf{v} = \mathbf{x}_0 + \mathbf{u}\} \subseteq V \tag{2.130b}$$

称为 V 的仿射子空间或线性流形。U 称为方向或方向空间，$\mathbf{x}_0$ 称为支撑点。第 12 章我们称这种子空间为超平面。

超平面

注意当 $\mathbf{x}_0 \notin U$ 时，仿射子空间的定义排除了 $\mathbf{0}$。因此当 $\mathbf{x}_0 \notin U$ 时仿射子空间不是 V 的（线性）子空间（向量子空间）。仿射子空间的例子有 $\mathbb{R}^3$ 中（不一定）过原点的点、直线和平面。

考虑向量空间 V 的两个仿射子空间 $L = \mathbf{x}_0 + U$ 和 $\tilde{L} = \tilde{\mathbf{x}}_0 + \tilde{U}$。则 $L \subseteq \tilde{L}$ 当且仅当 $U \subseteq \tilde{U}$ 且 $\mathbf{x}_0 - \tilde{\mathbf{x}}_0 \in \tilde{U}$。仿射子空间常用参数描述：考虑 V 的 k 维仿射空间 $L = \mathbf{x}_0 + U$。若 $(\mathbf{b}_1, \ldots, \mathbf{b}_k)$ 是 U 的一组有序基，则 L 中每个元素 $\mathbf{x}$ 可唯一描述为

$$\mathbf{x} = \mathbf{x}_0 + \lambda_1 \mathbf{b}_1 + \cdots + \lambda_k \mathbf{b}_k, \tag{2.131}$$

其中 $\lambda_1, \ldots, \lambda_k \in \mathbb{R}$。这个表示称为 L 关于方向向量 $\mathbf{b}_1, \ldots, \mathbf{b}_k$、参数 $\lambda_1, \ldots, \lambda_k$ 的参数方程。

参数方程

例 2.26（仿射子空间） 一维仿射子空间称为直线，可写成 $\mathbf{y} = \mathbf{x}_0 + \lambda \mathbf{b}_1$，其中 $\lambda \in \mathbb{R}$，$U = \operatorname{span}[\mathbf{b}_1] \subseteq \mathbb{R}^n$ 是 $\mathbb{R}^n$ 的一维子空间。即直线由一个支撑点 $\mathbf{x}_0$ 和一个定义方向的向量 $\mathbf{b}_1$ 确定。见图 2.13。

直线

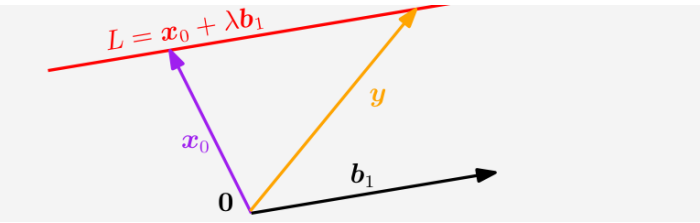


图 2.13: 直线是仿射子空间。直线 $\mathbf{x}_0 + \lambda \mathbf{b}_1$ 上的向量 $\mathbf{y}$ 位于以 $\mathbf{x}_0$ 为支撑点、以 $\mathbf{b}_1$ 为方向的仿射子空间 L 中。

原书p.62

$\mathbb{R}^n$ 的二维仿射子空间称为平面。平面的参数方程为 $\mathbf{y} = \mathbf{x}_0 + \lambda_1 \mathbf{b}_1 + \lambda_2 \mathbf{b}_2$ 其中 $\lambda_1, \lambda_2 \in \mathbb{R}$，$U = \operatorname{span}[\mathbf{b}_1, \mathbf{b}_2] \subseteq \mathbb{R}^n$。即平面由一个支撑点 $\mathbf{x}_0$ 和两个张成方向空间的线性无关向量 $\mathbf{b}_1, \mathbf{b}_2$ 确定。

超平面

在 $\mathbb{R}^n$ 中，$(n-1)$ 维仿射子空间称为超平面，相应参数方程为 $\mathbf{y} = \mathbf{x}_0 + \sum_{i=1}^{n-1} \lambda_i \mathbf{b}_i$，其中 $\mathbf{b}_1, \ldots, \mathbf{b}_{n-1}$ 构成 $\mathbb{R}^n$ 的一个 $(n-1)$ 维子空间 U 的基。即超平面由一个支撑点 $\mathbf{x}_0$ 和 $(n-1)$ 个张成方向空间的线性无关向量 $\mathbf{b}_1, \ldots, \mathbf{b}_{n-1}$ 确定。在 $\mathbb{R}^2$ 中，直线也是超平面；在 $\mathbb{R}^3$ 中，平面也是超平面。

[非齐次线性方程组与仿射子空间] 对 $\mathbf{A} \in \mathbb{R}^{m \times n}$ 和 $\mathbf{x} \in \mathbb{R}^m$，方程组 $\mathbf{A}\boldsymbol{\lambda} = \mathbf{x}$ 的解要么是空集，要么是 $\mathbb{R}^n$ 中维数为 $n - \mathrm{rk}(\mathbf{A})$ 的仿射子空间。特别地，线性方程 $\lambda_1 \mathbf{b}_1 + \cdots + \lambda_n \mathbf{b}_n = \mathbf{x}$（其中 $(\lambda_1, \ldots, \lambda_n) \neq (0, \ldots, 0)$）的解是 $\mathbb{R}^n$ 中的一个超平面。在 $\mathbb{R}^n$ 中，每个 k 维仿射子空间都是某个非齐次线性方程组 $\mathbf{A}\mathbf{x} = \mathbf{b}$ 的解，其中 $\mathbf{A} \in \mathbb{R}^{m \times n}$、$\mathbf{b} \in \mathbb{R}^m$ 且 $\mathrm{rk}(\mathbf{A}) = n - k$。回顾齐次方程组 $\mathbf{A}\mathbf{x} = \mathbf{0}$ 的解是向量子空间，也可把它看作支撑点 $\mathbf{x}_0 = \mathbf{0}$ 的特殊仿射空间。

2.8.2　仿射映射

与第 2.7 节讨论的向量空间之间线性映射类似，可在两个仿射空间之间定义仿射映射。线性映射与仿射映射关系密切，因此许多我们已从线性映射得知的性质（例如线性映射的复合仍是线性映射）对仿射映射也成立。

原书p.63

定义 2.26 (仿射映射). 对两个向量空间 V, W，线性映射 $\Phi : V \to W$，以及 $\mathbf{a} \in W$ 映射

仿射映射

$$\phi : V \to W \tag{2.132}$$

$$\mathbf{x} \mapsto \mathbf{a} + \Phi(\mathbf{x}) \tag{2.133}$$

是从 V 到 W 的仿射映射。向量 $\mathbf{a}$ 称为 ϕ 的平移向量。

平移向量

每个仿射映射 $\phi : V \to W$ 也是线性映射 $\Phi : V \to W$ 与 W 中平移 $\tau : W \to W$ 的复合，即 $\phi = \tau \circ \Phi$。映射 Φ 与 τ 唯一确定。仿射映射 $\phi : V \to W$ 与 $\phi' : W \to X$ 的复合 $\phi' \circ \phi$ 仍是仿射的。若 ϕ 双射，则仿射映射保持几何结构不变，因而也保持维数和平行性。

2.9　延伸阅读

学习线性代数的资源很多，包括 Strang (2003)、Golan (2007)、Axler (2015)、Liesen and Mehrmann (2015) 的教材。本章引言中还提到了若干在线资源。这里只讲了高斯消元，但求解线性方程组还有许多其他方法；深入讨论见数值线性代数教材 Stoer and Burlirsch (2002)、Golub and Van Loan (2012)、Horn and Johnson (2013)。

本书区分线性代数的主题（如向量、矩阵、线性无关、基）与向量空间几何相关的主题。第 3 章将引入内积，它诱导出范数。这些概念让我们能定义角度、长度和距离，用于正交投影。投影在许多机器学习算法中是关键，如线性回归和主成分分析，分别见第 9、10 章。

习题

原书p.64

2.1　考虑 $(\mathbb{R}\setminus\{-1\},\star)$，其中

$$a\star b := ab+a+b,\qquad a,b\in\mathbb{R}\setminus\{-1\} \tag{2.134}$$

a. 证明 $(\mathbb{R}\setminus\{-1\},\star)$ 是 Abel 群。

b. 在 Abel 群 $(\mathbb{R}\setminus\{-1\},\star)$ 中解方程 $3\star x\star x=15$，其中 $\star$ 由 (2.134) 定义。

2.2　设 $n\in\mathbb{N}\setminus\{0\}$，$k,x\in\mathbb{Z}$。把整数 k 的同余类 $\bar{k}$ 定义为集合

$$\bar{k}=\{x\in\mathbb{Z}\mid x-k=0\pmod n\}=\{x\in\mathbb{Z}\mid\exists a\in\mathbb{Z}:(x-k=n\cdot a)\}.$$

把 $\mathbb{Z}/n\mathbb{Z}$（有时记作 $\mathbb{Z}_n$）定义为所有模 n 同余类的集合。由带余除法知该集合是含 n 个元素的有限集：$\mathbb{Z}_n=\{0,1,\dots,n-1\}$。对所有 $a,b\in\mathbb{Z}_n$，定义 $a\oplus b:=a+b$。

a. 证明 $(\mathbb{Z}_n,\oplus)$ 是群。它是 Abel 群吗？

b. 再对所有 $a,b\in\mathbb{Z}_n$ 定义运算 $\otimes$：

$$a\otimes b=a\times b, \tag{2.135}$$

其中 $a\times b$ 表示 $\mathbb{Z}$ 中通常的乘法。取 $n=5$，画出 $\mathbb{Z}_5\setminus\{0\}$ 中元素在 $\otimes$ 下的乘法表，即计算所有 $a,b\in\mathbb{Z}_5\setminus\{0\}$ 的乘积 $a\otimes b$。由此证明 $\mathbb{Z}_5\setminus\{0\}$ 在 $\otimes$ 下封闭、且有关于 $\otimes$ 的单位元；列出 $\mathbb{Z}_5\setminus\{0\}$ 中所有元素在 $\otimes$ 下的逆。从而得出 $(\mathbb{Z}_5\setminus\{0\},\otimes)$ 是 Abel 群。

c. 证明 $(\mathbb{Z}_8\setminus\{0\},\otimes)$ 不是群。

d. 回顾 Bézout 定理：两个整数 a,b 互素（即 $\gcd(a,b)=1$）当且仅当存在整数 u,v 使 $au+bv=1$。证明 $(\mathbb{Z}_n\setminus\{0\},\otimes)$ 是群当且仅当 $n\in\mathbb{N}\setminus\{0\}$ 是素数。

2.3　考虑如下定义的 3×3 矩阵集合 G：

$$G=\left\{\begin{bmatrix}1&x&z\\0&1&y\\0&0&1\end{bmatrix}\in\mathbb{R}^{3\times3}:x,y,z\in\mathbb{R}\right\}.$$

定义 $\cdot$ 为标准矩阵乘法。$(G,\cdot)$ 是群吗？若是，它是 Abel 群吗？说明理由。

原书p.65

2.4　若可能，计算下列矩阵乘积：

a. $\begin{bmatrix}1&2&4\\5&7&8\end{bmatrix}\begin{bmatrix}1&1&0\\0&1&1\\1&0&1\end{bmatrix}$

b. $\begin{bmatrix}1&2&3\\4&5&6\\7&8&9\end{bmatrix}\begin{bmatrix}1&1&0\\0&1&1\\1&0&1\end{bmatrix}$

c. $\begin{bmatrix}1&1&0\\0&1&1\\1&0&1\end{bmatrix}\begin{bmatrix}1&2&3\\4&5&6\\7&8&9\end{bmatrix}$

d. $\begin{bmatrix}1&2&1\\2&4&1\\-1&-4&1\end{bmatrix}\begin{bmatrix}0&3&1\\-1&2&1\\5&2&0\end{bmatrix}$

e. $\begin{bmatrix}0&3&1\\-1&2&1\\5&2&0\end{bmatrix}\begin{bmatrix}1&2&1\\2&4&1\\-1&-4&1\end{bmatrix}$

2.5　求下列非齐次线性方程组 $\mathbf{Ax}=\mathbf{b}$ 在 $\mathbf{x}$ 中的全部解集合 S，其中 $\mathbf{A},\mathbf{b}$ 定义如下：

a. $\mathbf{A}=\begin{bmatrix}1&1&-1&-1\\2&5&-7&-5\\2&-1&1&3\\5&2&-4&2\end{bmatrix}$，　$\mathbf{b}=\begin{bmatrix}1\\-2\\4\\6\end{bmatrix}$

b. $\mathbf{A}=\begin{bmatrix}1&-1&0&0\\1&1&1&0\\-3&0&2&-1\\0&1&-1&-1\\2&0&-2&-1\end{bmatrix}$，　$\mathbf{b}=\begin{bmatrix}3\\6\\5\\-1\\2\end{bmatrix}$

2.6　用高斯消元求非齐次方程组 $\mathbf{Ax}=\mathbf{b}$ 的全部解，其中

$$\mathbf{A}=\begin{bmatrix}0&1&0&0\\1&0&0&1\\1&0&0&0\\1&0&0&0\\1&0&0&0\end{bmatrix},\qquad \mathbf{b}=\begin{bmatrix}2\\-1\\1\\0\end{bmatrix}.$$

原书p.66

2.7　求方程组 $\mathbf{Ax}=12\mathbf{x}$ 在 $\mathbf{x}=\begin{bmatrix}x_1\\x_2\\x_3\end{bmatrix}\in\mathbb{R}^3$ 中的全部解，其中

$$\mathbf{A}=\begin{bmatrix}6&4&3\\6&0&9\\0&8&0\end{bmatrix},\qquad \text{且 } \sum_{i=1}^{3}x_i=1.$$

2.8　若可能，求下列矩阵的逆：

a. $\mathbf{A}=\begin{bmatrix}2&3&4\\3&4&5\\4&5&6\end{bmatrix}$

b. $\mathbf{A} = \begin{bmatrix} 1 & 0 & 1 & 0 \\ 0 & 1 & 1 & 0 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$

2.9　下列集合哪些是 $\mathbb{R}^3$ 的子空间?

a. $A = \{(\lambda, \lambda + \mu^3, \lambda - \mu^3) \mid \lambda, \mu \in \mathbb{R}\}$

b. $B = \{(\lambda^2, -\lambda^2, 0) \mid \lambda \in \mathbb{R}\}$

c. 设 $\gamma \in \mathbb{R}$，$C = \{(\xi_1, \xi_2, \xi_3) \in \mathbb{R}^3 \mid \xi_1 - 2\xi_2 + 3\xi_3 = \gamma\}$

d. $D = \{(\xi_1, \xi_2, \xi_3) \in \mathbb{R}^3 \mid \xi_2 \in \mathbb{Z}\}$

2.10　下列向量组是否线性无关?

a. $\mathbf{x}_1 = \begin{bmatrix} 2 \\ -1 \\ 3 \end{bmatrix}, \mathbf{x}_2 = \begin{bmatrix} 1 \\ 1 \\ -2 \end{bmatrix}, \mathbf{x}_3 = \begin{bmatrix} 3 \\ -3 \\ 8 \end{bmatrix}$

b. $\mathbf{x}_1 = \begin{bmatrix} 1 \\ 2 \\ 1 \\ 0 \\ 0 \end{bmatrix}, \mathbf{x}_2 = \begin{bmatrix} 1 \\ 1 \\ 0 \\ 1 \\ 1 \end{bmatrix}, \mathbf{x}_3 = \begin{bmatrix} 1 \\ 0 \\ 0 \\ 1 \\ 1 \end{bmatrix}$

2.11　把

$$\mathbf{y} = \begin{bmatrix} 1 \\ -2 \\ 5 \end{bmatrix}$$

写成下列向量的线性组合:

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}, \quad \mathbf{x}_2 = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}, \quad \mathbf{x}_3 = \begin{bmatrix} 2 \\ -1 \\ 1 \end{bmatrix}.$$

2.12　考虑 $\mathbb{R}^4$ 的两个子空间:　　原书p.67

$$U_1 = \text{span}\left[\begin{bmatrix} 1 \\ 1 \\ -3 \\ 1 \end{bmatrix}, \begin{bmatrix} 2 \\ -1 \\ 0 \\ -1 \end{bmatrix}, \begin{bmatrix} -1 \\ 1 \\ -1 \\ 1 \end{bmatrix}\right],$$

$$U_2 = \text{span}\left[\begin{bmatrix} -1 \\ -2 \\ 2 \\ 1 \end{bmatrix}, \begin{bmatrix} 2 \\ -2 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} -3 \\ 6 \\ -2 \\ -1 \end{bmatrix}\right].$$

求 $U_1 \cap U_2$ 的一组基。

2.13　考虑两个子空间 U_1, U_2，其中 U_1 是齐次方程组 $\mathbf{A}_1\mathbf{x} = \mathbf{0}$ 的解空间，U_2 是齐次方程组 $\mathbf{A}_2\mathbf{x} = \mathbf{0}$ 的解空间，且

$$\mathbf{A}_1 = \begin{bmatrix} 1 & 0 & 1 \\ 1 & -2 & -1 \\ 2 & 1 & 3 \\ 1 & 0 & 1 \end{bmatrix}, \qquad \mathbf{A}_2 = \begin{bmatrix} 3 & -3 & 0 \\ 1 & 2 & 3 \\ 7 & -5 & 2 \\ 3 & -1 & 2 \end{bmatrix}.$$

a. 求 U_1, U_2 的维数。

b. 求 U_1, U_2 的基。

c. 求 $U_1 \cap U_2$ 的一组基。

2.14　考虑两个子空间 U_1, U_2，其中 U_1 由 $\mathbf{A}_1$ 的各列张成，U_2 由 $\mathbf{A}_2$ 的各列张成，$\mathbf{A}_1, \mathbf{A}_2$ 同 2.13。

a. 求 U_1, U_2 的维数。

b. 求 U_1, U_2 的基。

c. 求 $U_1 \cap U_2$ 的一组基。

2.15　设 $F = \{(x, y, z) \in \mathbb{R}^3 \mid x + y - z = 0\}$，$G = \{(a - b, a + b, a - 3b) \mid a, b \in \mathbb{R}\}$。

a. 证明 F, G 是 $\mathbb{R}^3$ 的子空间。

b. 不借助任何基向量，计算 $F \cap G$。

c. 为 F 和 G 各找一组基，用所找基向量计算 $F \cap G$，并与上一问结果核对。

2.16　下列映射是否线性?

a. 设 $a, b \in \mathbb{R}$，$\Phi : L^1([a, b]) \to \mathbb{R}$，$f \mapsto \Phi(f) = \int_a^b f(x)\,\mathrm{d}x$，其中 $L^1([a, b])$ 表示 $[a, b]$ 上可积函数的集合。

b. $\Phi : C^1 \to C^0$，$f \mapsto \Phi(f) = f'$，其中 $k \geqslant 1$ 时 C^k 表示 k 次连续可微函数的集合，C^0 表示连续函数的集合。

原书p.68

c. $\Phi : \mathbb{R} \to \mathbb{R}$，$x \mapsto \Phi(x) = \cos(x)$。

d. $\Phi : \mathbb{R}^3 \to \mathbb{R}^2$，$\mathbf{x} \mapsto \begin{bmatrix} 1 & 2 & 3 \\ 1 & 4 & 3 \end{bmatrix} \mathbf{x}$。

e. 设 $\theta \in [0, 2\pi[$，$\Phi : \mathbb{R}^2 \to \mathbb{R}^2$，$\mathbf{x} \mapsto \begin{bmatrix} \cos(\theta) & \sin(\theta) \\ -\sin(\theta) & \cos(\theta) \end{bmatrix} \mathbf{x}$。

2.17　考虑线性映射

$$\Phi : \mathbb{R}^3 \to \mathbb{R}^4, \quad \Phi\left(\begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}\right) = \begin{bmatrix} 3x_1 + 2x_2 + x_3 \\ x_1 + x_2 + x_3 \\ x_1 - 3x_2 \\ 2x_1 + 3x_2 + x_3 \end{bmatrix}.$$

1. 求变换矩阵 $\mathbf{A}_\Phi$。

2. 求 $\text{rk}(\mathbf{A}_\Phi)$。

3. 计算 Φ 的核与像。$\dim(\ker(\Phi))$ 和 $\dim(\text{Im}(\Phi))$ 各是多少?

2.18　设 E 是向量空间，f, g 是 E 上两个自同构且满足 $f \circ g = \text{id}_E$（即 $f \circ g$ 是恒等映射 id_E）。证明 $\ker(f) = \ker(g \circ f)$，$\text{Im}(g) = \text{Im}(g \circ f)$，且 $\ker(f) \cap \text{Im}(g) = \{\mathbf{0}_E\}$。

2.19　考虑自同态 $\Phi : \mathbb{R}^3 \to \mathbb{R}^3$，其（关于 $\mathbb{R}^3$ 标准基的）变换矩阵为

$$\mathbf{A}_\Phi = \begin{bmatrix} 1 & 1 & 0 \\ 1 & -1 & 0 \\ 1 & 1 & 1 \end{bmatrix}.$$

a. 求 $\ker(\Phi)$ 和 $\text{Im}(\Phi)$。

b. 求关于基

$$B = \left(\begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}\right)$$

的变换矩阵 $\tilde{\mathbf{A}}_\Phi$，即向新基 B 做基变换。

2.20　考虑 $\mathbb{R}^2$ 的四个向量 $\mathbf{b}_1, \mathbf{b}_2, \mathbf{b}_1', \mathbf{b}_2'$，在 $\mathbb{R}^2$ 标准基下表示为

$$\mathbf{b}_1 = \begin{bmatrix} 2 \\ 1 \end{bmatrix}, \quad \mathbf{b}_2 = \begin{bmatrix} -1 \\ -1 \end{bmatrix}, \quad \mathbf{b}_1' = \begin{bmatrix} 2 \\ -2 \end{bmatrix}, \quad \mathbf{b}_2' = \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

并定义 $\mathbb{R}^2$ 的两组有序基 $B = (\mathbf{b}_1, \mathbf{b}_2)$ 和 $B' = (\mathbf{b}_1', \mathbf{b}_2')$。

原书p.69

a. 证明 B, B' 都是 $\mathbb{R}^2$ 的基，并画出这些基向量。

b. 计算从 B' 到 B 做基变换的矩阵 P_1。

c. 考虑 $\mathbb{R}^3$ 的三个向量 $\mathbf{c}_1, \mathbf{c}_2, \mathbf{c}_3$，在 $\mathbb{R}^3$ 标准基下定义为

$$\mathbf{c}_1 = \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix}, \quad \mathbf{c}_2 = \begin{bmatrix} 0 \\ -1 \\ 2 \end{bmatrix}, \quad \mathbf{c}_3 = \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix},$$

并定义 $C = (\mathbf{c}_1, \mathbf{c}_2, \mathbf{c}_3)$。

(i) 证明 C 是 $\mathbb{R}^3$ 的基（例如用行列式，见第 4.1 节）。

(ii) 记 $C' = (\mathbf{c}'_1, \mathbf{c}'_2, \mathbf{c}'_3)$ 为 $\mathbb{R}^3$ 的标准基。求从 C 到 C' 做基变换的矩阵 P_2。

d. 考虑同态 $\Phi : \mathbb{R}^2 \to \mathbb{R}^3$，满足

$$\Phi(\mathbf{b}_1 + \mathbf{b}_2) = \mathbf{c}_2 + \mathbf{c}_3, \qquad \Phi(\mathbf{b}_1 - \mathbf{b}_2) = 2\mathbf{c}_1 - \mathbf{c}_2 + 3\mathbf{c}_3,$$

其中 $B = (\mathbf{b}_1, \mathbf{b}_2)$、$C = (\mathbf{c}_1, \mathbf{c}_2, \mathbf{c}_3)$ 分别是 $\mathbb{R}^2$、$\mathbb{R}^3$ 的有序基。求 Φ 关于有序基 B, C 的变换矩阵 $\mathbf{A}_\Phi$。

e. 求 Φ 关于基 B', C' 的变换矩阵 $\mathbf{A}'$。

f. 考虑向量 $\mathbf{x} \in \mathbb{R}^2$，它在 B' 下的坐标为 $[2, 3]^\top$，即 $\mathbf{x} = 2\mathbf{b}'_1 + 3\mathbf{b}'_2$。

(i) 计算 $\mathbf{x}$ 在 B 下的坐标。

(ii) 在此基础上，计算 $\Phi(\mathbf{x})$ 在 C 下的坐标。

(iii) 把 $\Phi(\mathbf{x})$ 用 $\mathbf{c}'_1, \mathbf{c}'_2, \mathbf{c}'_3$ 表示。

(iv) 直接用 $\mathbf{x}$ 在 B' 下的表示和矩阵 $\mathbf{A}'$ 求出该结果。

第 3 章　解析几何

原书p.70

在第 2 章中，我们以一般而抽象的方式研究了向量、向量空间和线性映射在本章中，我们将为所有这些概念增添一些几何解释与直觉。具体而言，我们将考察几何向量，计算其长度，以及两个向量之间的距离或夹角。为了能够做到这一点，我们为向量空间装备一个内积，由它诱导出该向量空间的几何。内积及其相应的范数与度量刻画了相似性与距离的直观概念，我们将在第 12 章用它们来构建支持向量机。随后，我们将利用向量间长度与夹角的概念来讨论正交投影，当我们在第 10 章讨论主成分分析、在第 9 章讨论基于最大似然估计的回归时，正交投影将扮演核心角色。图 3.1 概述了本章各概念之间的关系，以及它们如何与本书其他章节相联系。

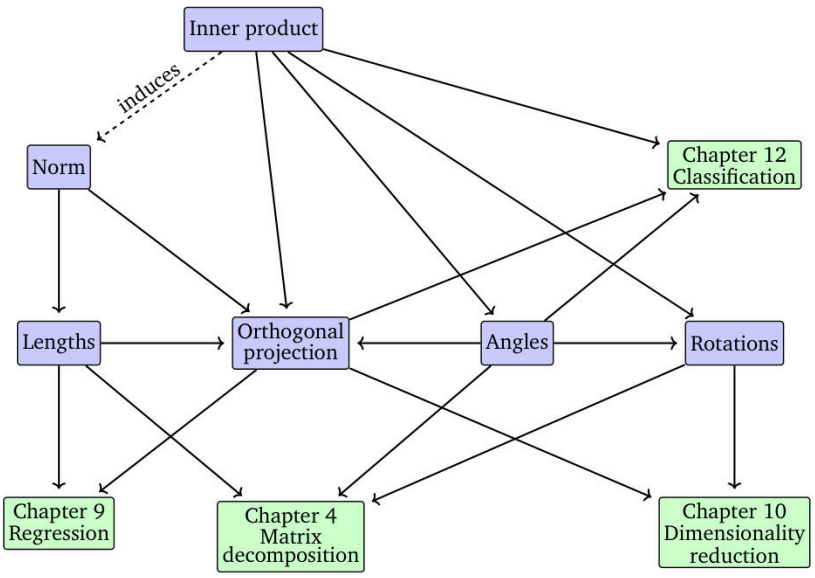


图 3.1: 本章所引入概念的思维导图，以及它们在本书其他部分被使用的时机（对应原图 Figure 3.1）。

3.1　范数

当我们想到几何向量，即从原点出发的有向线段时，直觉上向量的长度就是这条有向线段的“端点”到原点的距离。下面，我们将使用范数这一概念来讨论向量长度的含义。

定义 3.1 (范数). 向量空间 V 上的一个**范数**（norm）是一个函数　　范数

$$\|\cdot\| : V \to \mathbb{R}, \tag{3.1}$$

$$x \mapsto \|x\|, \tag{3.2}$$

它为每个向量 x 指定其长度 $\|x\| \in \mathbb{R}$，使得对所有 $\lambda \in \mathbb{R}$ 以及 $x, y \in V$，下列条件成立：　　长度

- 绝对齐次性（absolutely homogeneous）：$\|\lambda x\| = |\lambda| \, \|x\|$　　绝对齐次
- 三角不等式（triangle inequality）：$\|x + y\| \leq \|x\| + \|y\|$　　三角不等式
- 正定性（positive definite）：$\|x\| \geq 0$，且 $\|x\| = 0 \iff x = 0$　　正定

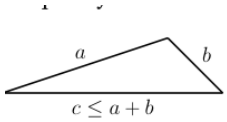


图 3.2: 三角不等式。

从几何角度看，三角不等式表述为：对任意三角形，任意两边长度之和必须大于或等于第三边的长度；其图示见图 3.2。定义 3.1 是针对一般向量空间 V（第 2.4 节）给出的，但在本书中我们只考虑有限维向量空间 $\mathbb{R}^n$。回忆一下，对向量 $x \in \mathbb{R}^n$，我们用下标表示向量的分量，即 x_i 是向量 x 的第 i 个元素。

例 3.1 (曼哈顿范数). $\mathbb{R}^n$ 上的**曼哈顿范数**（Manhattan norm）对 $x \in \mathbb{R}^n$ 定义为　　曼哈顿范数

$$\|x\|_1 := \sum_{i=1}^{n} |x_i|, \tag{3.3}$$

其中 $|\cdot|$ 是绝对值。图 3.3 左图展示了所有满足 $\|x\|_1 = 1$ 的向量 $x \in \mathbb{R}^2$。曼哈顿范数也称为 ℓ_1 范数。　　ell1 范数

原书p.71

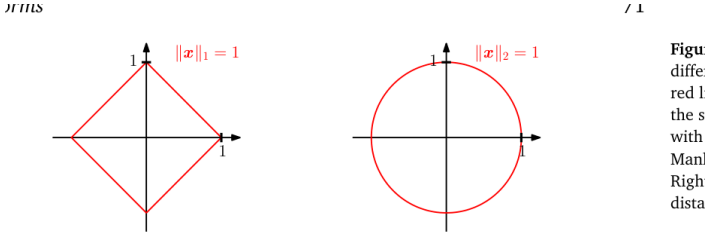


图 3.3: 对不同的范数，红线标出范数为 1 的向量集合。左：曼哈顿范数；右：欧几里得距离。

例 3.2 (欧几里得范数)**.** $x \in \mathbb{R}^n$ 的**欧几里得范数**（Euclidean norm）定义为　原书p.72　欧氏范数

$$\|x\|_2 := \sqrt{\sum_{i=1}^{n} x_i^2} = \sqrt{x^\top x} \tag{3.4}$$

它计算 x 到原点的欧几里得距离。图 3.3 右图展示了所有满足 $\|x\|_2 = 1$ 的向量 $x \in \mathbb{R}^2$。欧几里得范数也称为 ℓ_2 范数。　ell2 范数

注. 在本书中，除非另有说明，我们默认使用欧几里得范数 (3.4)。

3.2　内积

内积使我们能够引入直观的几何概念，例如向量的长度，以及两个向量之间的夹角或距离。内积的一个主要目的是判断向量之间是否正交。

3.2.1　点积

我们可能已经熟悉某一类内积，即 $\mathbb{R}^n$ 中的标量积/点积（scalar product/dot product），其表达式为　点积

$$x^\top y = \sum_{i=1}^{n} x_i y_i. \tag{3.5}$$

在本书中，我们把这一特定内积称为点积。然而，内积是更一般的概念，具有特定的性质，下面我们就来介绍。

3.2.2　一般内积

回忆第 2.7 节中的线性映射，我们可以对其关于加法和与标量的乘法进行重新整理。**双线性映射**（bilinear mapping）Ω 是具有两个自变量的映射，并且对每个自变量都是线性的，即当我们考察向量空间 V 时，对所有 $x, y, z \in V$、$\lambda, \psi \in \mathbb{R}$ 成立　双线性映射

$$\Omega(\lambda x + \psi y, z) = \lambda\,\Omega(x, z) + \psi\,\Omega(y, z) \tag{3.6}$$

$$\Omega(x, \lambda y + \psi z) = \lambda\,\Omega(x, y) + \psi\,\Omega(x, z). \tag{3.7}$$

这里，(3.6) 断言 Ω 对第一个自变量是线性的，(3.7) 断言 Ω 对第二个自变量是线性的（另见 (2.87)）。

定义 3.2. 设 V 是一个向量空间，$\Omega : V \times V \to \mathbb{R}$ 是一个双线性映射，它把两个向量映射为一个实数。若对所有 $x, y \in V$ 都有 $\Omega(x, y) = \Omega(y, x)$，即自变量的顺序无关紧要，则称 Ω 是**对称**（symmetric）的。　原书p.73　对称

若

$$\forall x \in V \setminus \{0\} : \Omega(x, x) > 0, \qquad \Omega(0, 0) = 0, \tag{3.8}$$

则称 Ω 是**正定**（positive definite）的。　正定

定义 3.3. 设 V 是一个向量空间，$\Omega : V \times V \to \mathbb{R}$ 是一个把两个向量映射为实数的双线性映射。则正定、对称的双线性映射 $\Omega : V \times V \to \mathbb{R}$ 称为 V 上的一个**内积**（inner product）。我们通常把 $\Omega(x, y)$ 写作 $\langle x, y\rangle$。 内积

配对 $(V, \langle\cdot,\cdot\rangle)$ 称为内积空间，或带内积的（实）向量空间。若我们使用 (3.5) 中定义的点积，则称 $(V, \langle\cdot,\cdot\rangle)$ 为欧几里得向量空间。 内积空间

在本书中，我们将把这些空间统称为内积空间。

例 3.3 (不是点积的内积)**.** 考虑 $V = \mathbb{R}^2$。若我们定义

$$\langle x, y\rangle := x_1y_1 - (x_1y_2 + x_2y_1) + 2x_2y_2 \tag{3.9}$$

则 $\langle\cdot,\cdot\rangle$ 是一个内积，但不同于点积。其证明留作习题。

3.2.3　对称正定矩阵

对称正定矩阵在机器学习中扮演重要角色，它们通过内积来定义。在第 4.3 节中，我们将在矩阵分解的语境下回到对称正定矩阵。对称半正定矩阵的概念是核（kernel）定义的关键（第 12.4 节）。

考虑一个 n 维向量空间 V，其上有内积 $\langle\cdot,\cdot\rangle : V \times V \to \mathbb{R}$（见定义 3.3），以及 V 的一组有序基 $B = (b_1, \ldots, b_n)$。回忆第 2.6.1 节，任意向量 $x, y \in V$ 都可写成基向量的线性组合，即对适当的 $\psi_i, \lambda_j \in \mathbb{R}$ 有 $x = \sum_{i=1}^n \psi_i b_i \in V$、$y = \sum_{j=1}^n \lambda_j b_j \in V$。由于内积的双线性，对所有 $x, y \in V$ 成立

$$\langle x, y\rangle = \left\langle \sum_{i=1}^n \psi_i b_i, \sum_{j=1}^n \lambda_j b_j \right\rangle = \sum_{i=1}^n \sum_{j=1}^n \psi_i \langle b_i, b_j\rangle \lambda_j = \hat{x}^\top A\, \hat{y}, \tag{3.10}$$

其中 $A_{ij} := \langle b_i, b_j\rangle$，而 $\hat{x}, \hat{y}$ 是 x, y 关于基 B 的坐标。这意味着内积 $\langle\cdot,\cdot\rangle$ 由 A 唯一确定。内积的对称性也意味着 A 是对称的。此外，内积的正定性蕴含 原书p.74

$$\forall x \in V \setminus \{0\} : x^\top A x > 0. \tag{3.11}$$

定义 3.4 (对称正定矩阵)**.** 满足 (3.11) 的对称矩阵 $A \in \mathbb{R}^{n\times n}$ 称为**对称正定**（symmetric positive definite）矩阵，或简称正定矩阵。若在 (3.11) 中只成立 $\geq$，则 A 称为对称半正定（symmetric positive semidefinite）矩阵。 对称正定

例 3.4 (对称正定矩阵)**.** 考虑矩阵

$$A_1 = \begin{bmatrix} 9 & 6 \\ 6 & 5 \end{bmatrix}, \qquad A_2 = \begin{bmatrix} 9 & 6 \\ 6 & 3 \end{bmatrix}. \tag{3.12}$$

A_1 是正定的，因为它对称，且

$$x^\top A_1 x = [x_1\ x_2] \begin{bmatrix} 9 & 6 \\ 6 & 5 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \tag{3.13a}$$

$$= 9x_1^2 + 12x_1x_2 + 5x_2^2 = (3x_1 + 2x_2)^2 + x_2^2 > 0 \tag{3.13b}$$

对所有 $x \in V \setminus \{0\}$ 成立。与之相反，A_2 对称但不是正定的，因为 $x^\top A_2 x = 9x_1^2 + 12x_1x_2 + 3x_2^2 = (3x_1 + 2x_2)^2 - x_2^2$ 可以小于 0，例如取 $x = [2, -3]^\top$。

若 $A \in \mathbb{R}^{n\times n}$ 是对称正定的，则

$$\langle x, y\rangle = \hat{x}^\top A\, \hat{y} \tag{3.14}$$

关于有序基 B 定义了一个内积，其中 $\hat{x}, \hat{y}$ 是 $x, y \in V$ 关于 B 的坐标表示。

定理 3.1. 对实值、有限维向量空间 V 及其一组有序基 B, 映射 $\langle\cdot,\cdot\rangle : V \times V \to \mathbb{R}$ 是内积，当且仅当存在对称正定矩阵 $A \in \mathbb{R}^{n\times n}$ 使得

$$\langle x, y\rangle = \hat{x}^\top A\, \hat{y}. \tag{3.15}$$

若 $A \in \mathbb{R}^{n\times n}$ 对称正定，则成立以下性质：

- A 的零空间（核）只由 0 组成，因为对所有 $x \neq 0$ 都有 $x^\top Ax > 0$。这蕴含当 $x \neq 0$ 时 $Ax \neq 0$。
- A 的对角元素 a_{ii} 为正，因为 $a_{ii} = e_i^\top Ae_i > 0$，其中 e_i 是 $\mathbb{R}^n$ 中标准基的第 i 个向量。

3.3　长度与距离

在第 3.1 节中，我们已经讨论了可用来计算向量长度的范数。内积与范数密切相关：任何内积都以一种自然的方式诱导出一个范数

原书p.75

内积诱导范数

$$\|x\| := \sqrt{\langle x, x\rangle}, \tag{3.16}$$

从而我们可以用内积来计算向量的长度。然而，并非每个范数都是由内积诱导的。曼哈顿范数 (3.3) 就是一个没有对应内积的范数的例子。下面，我们将聚焦于由内积诱导的范数，并引入长度、距离和夹角等几何概念。

注 (柯西–施瓦茨不等式). 对内积向量空间 $(V, \langle\cdot,\cdot\rangle)$，其诱导范数 $\|\cdot\|$ 满足柯西–施瓦茨不等式（Cauchy–Schwarz inequality）

柯西施瓦茨

$$|\langle x, y\rangle| \leq \|x\|\,\|y\|. \tag{3.17}$$

例 3.5 (用内积计算向量长度)**.** 在几何学中，我们常常关心向量的长度。现在我们可以用内积，通过 (3.16) 来计算它们。取 $x = [1, 1]^\top \in \mathbb{R}^2$。若我们把点积用作内积，由 (3.16) 得到

$$\|x\| = \sqrt{x^\top x} = \sqrt{1^2 + 1^2} = \sqrt{2} \tag{3.18}$$

作为 x 的长度。现在我们另选一个内积：

$$\langle x, y\rangle := x^\top \begin{bmatrix} 1 & -\frac{1}{2} \\ -\frac{1}{2} & 1 \end{bmatrix} y = x_1y_1 - \tfrac{1}{2}(x_1y_2 + x_2y_1) + x_2y_2. \tag{3.19}$$

若我们计算一个向量的范数，则当 x_1 与 x_2 同号（即 $x_1x_2 > 0$）时，这个内积返回的值比点积小；否则返回的值比点积大。用这个内积，我们得到

$$\langle x, x\rangle = x_1^2 - x_1x_2 + x_2^2 = 1 - 1 + 1 = 1 \quad \Longrightarrow \quad \|x\| = \sqrt{1} = 1, \tag{3.20}$$

因而在这个内积下 x 比在点积下“更短”。

定义 3.5 (距离与度量)**.** 考虑内积空间 $(V, \langle\cdot,\cdot\rangle)$。则

$$d(x, y) := \|x - y\| = \sqrt{\langle x - y, x - y\rangle} \tag{3.21}$$

称为 $x, y \in V$ 之间的距离（distance）。若我们把点积用作内积，则该距离称为欧几里得距离（Euclidean distance）。

距离
原书p.76

映射

$$d : V \times V \to \mathbb{R} \tag{3.22}$$

$$(x, y) \mapsto d(x, y) \tag{3.23}$$

称为一个度量（metric）。

度量

注. 与向量的长度类似，向量之间的距离并不要求内积：有一个范数就足够了。若我们有一个由内积诱导的范数，则距离会随内积的选择而变化。

度量 d 满足以下性质：

1. d 是正定的，即对所有 $x, y \in V$ 有 $d(x, y) \geq 0$，且 $d(x, y) = 0 \iff x = y$。

正定

2. d 是对称的，即对所有 $x, y \in V$ 有 $d(x, y) = d(y, x)$。

对称

3. 三角不等式：对所有 $x, y, z \in V$ 有 $d(x, z) \leq d(x, y) + d(y, z)$。

三角不等式

注. 乍看之下，内积与度量的性质清单非常相似。然而，把定义 3.3 与定义 3.6 相比较，我们会发现 $\langle x, y\rangle$ 与 $d(x, y)$ 的行为方向相反。非常相似的 x 与 y 会使内积取大值、使度量取小值。

3.4　夹角与正交性

除了能够定义向量的长度以及两个向量之间的距离之外，内积还通过定义两个向量之间的夹角 ω 来刻画向量空间的几何。我们利用柯西–施瓦茨不等式 (3.17) 在内积空间中定义两个向量 x, y 之间的夹角 ω，这一概念与我们在 $\mathbb{R}^2$ 和 $\mathbb{R}^3$ 中的直觉一致。假设 $x \neq 0$、$y \neq 0$。则

$$-1 \leq \frac{\langle x, y\rangle}{\|x\|\,\|y\|} \leq 1. \tag{3.24}$$

因此存在唯一的 $\omega \in [0, \pi]$（见图 3.4）使得

$$\cos\omega = \frac{\langle x, y\rangle}{\|x\|\,\|y\|}. \tag{3.25}$$

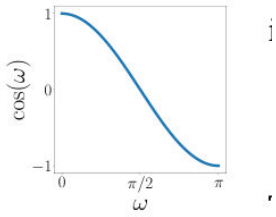


图 3.4: 当限制在 $[0, \pi]$ 上时，$f(\omega) = \cos(\omega)$ 在区间 $[-1, 1]$ 中返回唯一值。

数值 ω 是向量 x 与 y 之间的夹角（angle）。直觉上，两个向量之间的夹角告诉我们它们的方向有多么相似。例如，用点积时，x 与 $y = 4x$（即 y 是 x 的一个缩放版本）之间的夹角为 0：它们方向相同。

夹角

原书p.77

例 3.6 (向量间的夹角)**.** 我们来计算 $x = [1, 1]^\top \in \mathbb{R}^2$ 与 $y = [1, 2]^\top \in \mathbb{R}^2$ 之间的夹角；见图 3.5，其中我们把点积用作内积。于是得到

$$\cos\omega = \frac{\langle x, y\rangle}{\sqrt{\langle x, x\rangle \langle y, y\rangle}} = \frac{x^\top y}{\sqrt{x^\top x\, y^\top y}} = \frac{3}{\sqrt{10}}, \tag{3.26}$$

两向量之间的夹角为 $\arccos\left(\frac{3}{\sqrt{10}}\right) \approx 0.32$ rad，约合 18°。

原书p.78

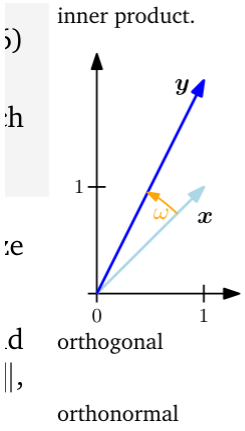


图 3.5: 两个向量 x, y 之间的夹角 ω 用内积计算。

内积的一个关键特征是：它还使我们能够刻画正交的向量。

原书p.79

定义 3.6 (正交性)**.** 两个向量 x 与 y 正交，当且仅当 $\langle x, y\rangle = 0$，我们记作 $x \perp y$ 若此外还有 $\|x\| = 1 = \|y\|$，即两向量都是单位向量，则 x 与 y 是规范正交的（orthonormal）。

正交

该定义的一个推论是：零向量与向量空间中每个向量都正交。

注. 正交性是把垂直这一概念推广到不必为点积的双线性形式。在我们的语境中，从几何上可以把正交向量想象为相对于某个特定内积具有直角。

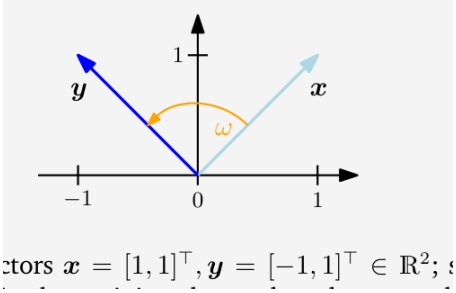
例 3.7 (正交向量)**.** 考虑两个向量 $x = [1, 1]^\top$、$y = [-1, 1]^\top \in \mathbb{R}^2$；见图 3.6。我们感兴趣的是用两种不同的内积来确定它们之间的夹角 ω。把点积用作内积时，x 与 y 之间的夹角 ω 为 90°，从而 $x \perp y$。然而，若我们选择内积

$$\langle x, y \rangle = x^\top \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} y, \tag{3.27}$$

则得到 x 与 y 之间的夹角 ω 为

$$\cos\omega = \frac{\langle x, y \rangle}{\|x\| \, \|y\|} = -\frac{1}{3} \quad \Longrightarrow \quad \omega \approx 1.91 \text{ rad} \approx 109.5^\circ, \tag{3.28}$$

此时 x 与 y 不正交。因此，关于某一个内积正交的向量，关于另一个内积不必正交。



ctors $\boldsymbol{x} = [1, 1]^\top, \boldsymbol{y} = [-1, 1]^\top \in \mathbb{R}^2$;

图 3.6: 两个向量 x, y 之间的夹角 ω 会随内积的不同而改变。

定义 3.7 (正交矩阵)**.** 方阵 $A \in \mathbb{R}^{n \times n}$ 是正交矩阵（orthogonal matrix），当且仅当它的各列规范正交，从而

$$AA^\top = I = A^\top A, \tag{3.29}$$

这蕴含　　正交矩阵

$$A^{-1} = A^\top, \tag{3.30}$$

即只需对矩阵转置就得到逆矩阵。（约定上称这些矩阵为“正交的”，但更精确的描述应是“规范正交的”。）

由正交矩阵进行的变换是特殊的，因为用正交矩阵 A 变换向量 x 时，x 的长度不发生改变。对点积，我们有

$$\|Ax\|^2 = (Ax)^\top (Ax) = x^\top A^\top Ax = x^\top Ix = x^\top x = \|x\|^2. \tag{3.31}$$

此外，用正交矩阵 A 同时变换任意两个向量 x, y 时，由它们的内积测得的夹角也保持不变。假设以点积为内积，像 Ax 与 Ay 之间的夹角为

$$\cos\omega = \frac{(Ax)^\top (Ay)}{\|Ax\| \, \|Ay\|} = \frac{x^\top A^\top Ay}{\sqrt{x^\top A^\top Ax \, y^\top A^\top Ay}} = \frac{x^\top y}{\|x\| \, \|y\|}, \tag{3.32}$$

这恰好给出 x 与 y 之间的夹角。这意味着满足 $A^\top = A^{-1}$ 的正交矩阵 A 同时保持夹角和距离。事实证明，正交矩阵定义的变换是旋转（可能带有翻转）。在第 3.9 节中，我们将进一步讨论旋转的细节。

3.5　规范正交基

在第 2.6.1 节中，我们刻画了基向量的性质，并发现在 n 维向量空间中需要 n 个基向量，即 n 个线性无关的向量。在第 3.3 节和第 3.4 节中，我们用内积计算了向量的长度和向量间的夹角。下面，我们将讨论基向量彼此正交、且每个基向量长度为 1 的特殊情形。我们把这样的基称为规范正交基。

定义 3.8 (规范正交基)**.** 考虑 n 维向量空间 V 及其一组基 $\{b_1, \dots, b_n\}$。若

$$\langle b_i, b_j \rangle = 0 \qquad (i \neq j) \tag{3.33}$$

$$\langle b_i, b_i \rangle = 1 \tag{3.34}$$

对所有 $i, j = 1, \dots, n$ 成立，则称该基为规范正交基（orthonormal basis, ONB）。若只满足 (3.33)，则该基称为正交基（orthogonal basis）。注意 (3.34) 蕴含每个基向量的长度/范数为 1。

规范正交基
正交基

回忆第 2.6.1 节，我们可以用高斯消去法为一组向量张成的向量空间求一组基。假设给定一组非正交、未归一化的基向量 $\{\tilde{b}_1, \dots, \tilde{b}_n\}$。我们把它们拼成矩阵 $\tilde{B} = [\tilde{b}_1, \dots, \tilde{b}_n]$，并对增广矩阵（第 2.3.2 节）$[\tilde{B}\tilde{B}^\top \mid \tilde{B}]$ 应用高斯消去法，以得到一组规范正交基。这种迭代地构造规范正交基 $\{b_1, \dots, b_n\}$ 的构造性方法称为 Gram–Schmidt 过程（Strang, 2003）。

例 3.8 (规范正交基)**.** 欧几里得向量空间 $\mathbb{R}^n$ 的典范/标准基就是一组规范正交基，其中内积为向量的点积。在 $\mathbb{R}^2$ 中，向量

$$b_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \qquad b_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix} \tag{3.35}$$

构成一组规范正交基，因为 $b_1^\top b_2 = 0$ 且 $\|b_1\| = 1 = \|b_2\|$。

我们将在第 12 章和第 10 章讨论支持向量机和主成分分析时利用规范正交基这一概念。

3.6　正交补

定义了正交性之后，我们现在来考察彼此正交的向量空间。这在第 10 章中将扮演重要角色，那时我们从几何视角讨论线性降维。

考虑一个 D 维向量空间 V 及其 M 维子空间 $U \subseteq V$。则其**正交补**（orthogonal complement）$U^\perp$ 是 V 的一个 $(D - M)$ 维子空间，它包含 V 中所有与 U 中每个向量都正交的向量。此外，$U \cap U^\perp = \{0\}$，从而任意向量 $x \in V$ 都可以唯一分解为

正交补

$$x = \sum_{m=1}^{M} \lambda_m b_m + \sum_{j=1}^{D-M} \psi_j b_j^\perp, \qquad \lambda_m, \psi_j \in \mathbb{R}, \tag{3.36}$$

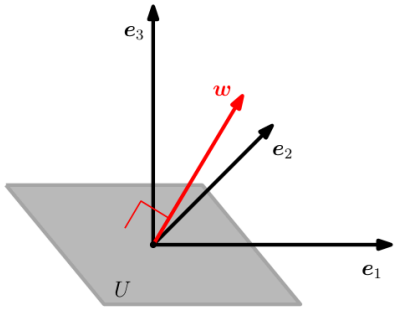
其中 $(b_1, \dots, b_M)$ 是 U 的一组基，$(b_1^\perp, \dots, b_{D-M}^\perp)$ 是 $U^\perp$ 的一组基。

因此, 正交补也可用来描述三维向量空间中的一个平面 U（二维子空间)。更具体地说，与平面 U 正交、且满足 $\|w\| = 1$ 的向量 w 就是 $U^\perp$ 的基向量。图 3.7 展示了这一设定。所有与 w 正交的向量必然（按构造）位于平面 U 内。向量 w 称为 U 的法向量（normal vector)。

法向量

一般而言，正交补可用来描述 n 维向量空间与仿射空间中的超平面。

原书p.80



nposed into

图 3.7: 三维向量空间中的平面 U 可由其法向量描述，该法向量张成其正交补 $U^\perp$。

3.7　函数的内积

至此，我们考察了用内积计算长度、夹角和距离的性质。我们聚焦于有限维向量的内积。下面，我们来看另一类向量的内积的例子：函数的内积。

迄今为止我们讨论的内积都是对具有有限个分量的向量定义的。我们可以把向量 $x \in \mathbb{R}^n$ 想成具有 n 个函数值的函数。内积的概念可以推广到具有无穷多个分量的向量（可数无穷)，以及取连续值的函数（不可数无穷)。此时，对向量各个分量求和（例如见式 (3.5)）就变成了积分。

两个函数 $u : \mathbb{R} \to \mathbb{R}$ 与 $v : \mathbb{R} \to \mathbb{R}$ 的内积可定义为定积分

$$\langle u, v \rangle := \int_a^b u(x)\, v(x)\, dx \tag{3.37}$$

其中下限、上限分别为 $a, b < \infty$。与通常的内积一样，我们可以通过考察内积来定义范数和正交性。若 (3.37) 的值为 0，则函数 u 与 v 正交。为使上述内积在数学上严格，我们需要处理测度与积分的定义问题，从而导出 Hilbert 空间的定义。此外，与有限维向量上的内积不同，函数上的内积可能发散（取无穷值)。所有这一切都需要深入到实分析与泛函分析中更为精巧的细节，本书不予涉及。

原书p.81

例 3.9 (函数的内积)**.** 若我们取 $u = \sin(x)$、$v = \cos(x)$，则 (3.37) 的被积函数 $f(x) = u(x)v(x)$ 如图 3.8 所示。我们看到这个函数是奇函数, 即 $f(-x) = -f(x)$。因此，在限 $a = -\pi$、$b = \pi$ 下该乘积的积分值为 0。所以 sin 与 cos 是正交函数。

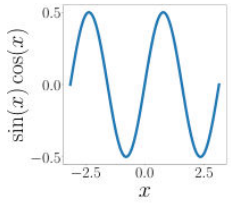


图 3.8: $f(x) = \sin(x)\cos(x)$。

注. 还成立的是：函数集合

$$\{1,\ \cos(x),\ \cos(2x),\ \cos(3x),\ \dots\} \tag{3.38}$$

若我们从 $-\pi$ 积分到 π，则它是正交的，即任意一对函数彼此正交。(3.38) 中的函数集合张成了在 $[-\pi, \pi)$ 上为偶且周期函数的一个很大的子空间，把函数投影到这个子空间上正是傅里叶级数背后的基本思想。

在第 6.4.6 节中，我们将考察第二类非常规内积：随机变量的内积。

3.8　正交投影

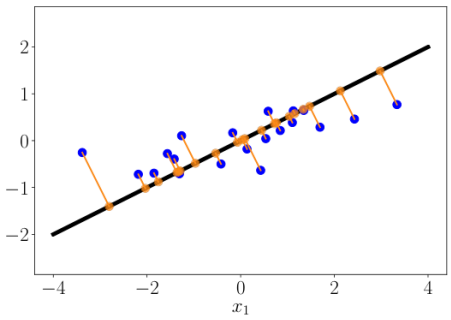
投影是一类重要的线性变换（除旋转和反射之外），在图形学、编码理论、统计学和机器学习中扮演重要角色。在机器学习中，我们常常处理高维数据。高维数据往往难以分析或可视化。然而，高维数据常常具有这样的性质：只有少数几个维度包含大部分信息，而其他大多数维度对描述数据的关键性质并非必不可少。当我们压缩或可视化高维数据时，会丢失信息。为了最小化这种压缩损失，我们理想地找到数据中最具信息量的维度。如第 1 章所讨论的，数据可表示为向量，本章我们将讨论数据压缩的一些基本工具。更具体地说，我们可以把原始高维数据投影到一个更低维的特征空间，并在这个低维空间中工作，以进一步了解数据集并提取相关模式。例如，机器学习算法，如 Pearson (1901) 和 Hotelling (1933) 的主成分分析（PCA），以及深度神经网络（例如深度自编码器（Deng et al., 2010）），都大量利用了降维这一思想。下面，我们将聚焦正交投影，我们将在第 10 章用它进行线性降维，在第 12 章用它进行分类。即便是我们将在第 9 章讨论的线性回归，也可以用正交投影来解释。对于给定的低维子空间，高维数据的正交投影尽可能多地保留信息，并最小化原始数据与相应投影之间的差/误差。图 3.9 给出了这种正交投影的图示。在详述如何得到这些投影之前，我们先定义投影究竟是什么。

原书p.82

定义 3.9 (投影)**.** 设 V 是一个向量空间，$U \subseteq V$ 是 V 的一个子空间。一个线性映射 $\pi : V \to U$ 称为**投影**（projection），如果

投影

$$\pi^2 = \pi \circ \pi = \pi.$$



ms, such as principal component analysis (PC/

图 3.9: 一个二维数据集（蓝色点）到一维子空间（直线）上的正交投影（橙色点）。

由于线性映射可以用变换矩阵表示（见第 2.7 节），上述定义同样适用于一类特殊的变换矩阵，即投影矩阵 P_π，它具有性质 $P_\pi^2 = P_\pi$。

投影矩阵

下面，我们将在由内积空间 $(\mathbb{R}^n, \langle\cdot,\cdot\rangle)$ 向子空间上投影向量。我们从一维子空间开始，它也称为直线（line）。除非另有说明，我们假设以点积 $\langle x, y\rangle = x^\top y$ 作为内积。

直线

3.8.1　到一维子空间（直线）上的投影

假设给定一条过原点、以 $b \in \mathbb{R}^n$ 为基向量的直线（一维子空间）。该直线是由 b 张成的一维子空间 $U \subseteq \mathbb{R}^n$。当我们把 $x \in \mathbb{R}^n$ 投影到 U 上时，我们寻求 U 中离 x 最近的向量 $\pi_U(x) \in U$。用几何论证，我们来刻画投影 $\pi_U(x)$ 的一些性质（图 3.10(a) 作为图示）：

- 投影 $\pi_U(x)$ 离 x 最近，其中“最近”意味着距离 $\|x - \pi_U(x)\|$ 最小。由此可知，从 $\pi_U(x)$ 到 x 的线段 $\pi_U(x) - x$ 与 U 正交，因而也与 U 的基向量 b 正交。正交性条件给出 $\langle \pi_U(x) - x,\, b\rangle = 0$，因为向量间的夹角是通过内积定义的。
- x 到 U 上的投影 $\pi_U(x)$ 必须是 U 的元素，因而必须是张成 U 的基向量 b 的某个倍数。于是 $\pi_U(x) = \lambda b$，其中 $\lambda \in \mathbb{R}$。

原书p.83

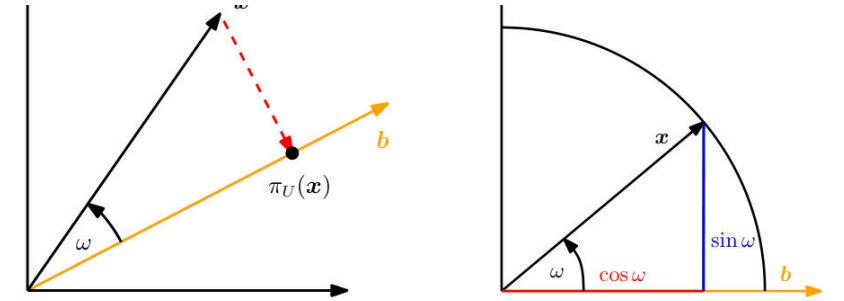
下面分三步来确定坐标 λ、投影 $\pi_U(x) \in U$，以及把任意 $x \in \mathbb{R}^n$ 映射到 U 上的投影矩阵 P_π：

1. 求坐标 λ。　正交性条件给出

$$\langle x - \pi_U(x),\, b\rangle = 0 \overset{\pi_U(x)=\lambda b}{\iff} \langle x - \lambda b,\, b\rangle = 0. \tag{3.39}$$

现在我们可以利用内积的双线性，得到

$$\langle x, b\rangle - \lambda\langle b, b\rangle = 0 \iff \lambda = \frac{\langle x, b\rangle}{\langle b, b\rangle} = \frac{\langle b, x\rangle}{\|b\|^2}. \tag{3.40}$$



(a) Projection of $\boldsymbol{x} \in \mathbb{R}^2$ onto a subspace U with basis vector $\boldsymbol{b}$.

(b) Projection of a two-dimensional vector $\boldsymbol{x}$ with $\|\boldsymbol{x}\| = 1$ onto a one-dimensional subspace spanned by $\boldsymbol{b}$.

图 3.10: 到一维子空间上投影的例子。(a) $x \in \mathbb{R}^2$ 到以 b 为基向量的子空间 U 上的投影；(b) 范数为 $\|x\| = 1$ 的二维向量 x 到由 b 张成的一维子空间上的投影。

在最后一步，我们利用了内积对称这一事实。若我们取 $\langle \cdot, \cdot \rangle$ 为点积，则得到

$$\lambda = \frac{b^\top x}{b^\top b} = \frac{b^\top x}{\|b\|^2}. \tag{3.41}$$

若 $\|b\| = 1$，则投影的坐标 λ 由 $b^\top x$ 给出。

原书p.84

2. 求投影点 $\pi_U(x) \in U$。　由于 $\pi_U(x) = \lambda b$，由 (3.40) 立即得到

$$\pi_U(x) = \lambda b = \frac{\langle x, b \rangle}{\|b\|^2} b = \frac{b^\top x}{\|b\|^2} b, \tag{3.42}$$

其中最后一个等号仅对点积成立。我们还可以用定义 3.1 计算 $\pi_U(x)$ 的长度：

$$\|\pi_U(x)\| = \|\lambda b\| = |\lambda| \, \|b\|. \tag{3.43}$$

因此，我们的投影长度为 $|\lambda|$ 乘以 b 的长度。这也增添了如下直觉：λ 是 $\pi_U(x)$ 关于张成一维子空间 U 的基向量 b 的坐标。

若我们以点积为内积，则有

$$\|\pi_U(x)\| \overset{(3.42)}{=} \frac{|b^\top x|}{\|b\|^2} \|b\| \overset{(3.25)}{=} \frac{|\cos\omega| \, \|x\| \, \|b\| \, \|b\|}{\|b\|^2} = |\cos\omega| \, \|x\|. \tag{3.44}$$

这里，ω 是 x 与 b 之间的夹角。这个式子在三角学中是熟悉的：若 $\|x\| = 1$，则 x 位于单位圆上。由此可知，到由 b 张成的水平轴上的投影恰好是 $\cos\omega$，相应向量 $\pi_U(x)$ 的长度为 $|\cos\omega|$。图 3.10(b) 给出了图示。

3. 求投影矩阵 P_π。　我们知道投影是线性映射（见定义 3.10）。因此存在投影矩阵 P_π，使得 $\pi_U(x) = P_\pi x$。以点积为内积，且

$$\pi_U(x) = \lambda b = b\lambda = b \frac{b^\top x}{\|b\|^2} = \frac{bb^\top}{\|b\|^2} x, \tag{3.45}$$

我们立即看到

$$P_\pi = \frac{bb^\top}{\|b\|^2}. \tag{3.46}$$

注意 $bb^\top$（以及随之而来的 P_π）是一个对称矩阵（秩为 1），而 $\|b\|^2 = \langle b, b\rangle$ 是一个标量。

投影矩阵 P_π 把任意向量 $x \in \mathbb{R}^n$ 投影到过原点、方向为 b 的直线上（等价地，投影到由 b 张成的子空间 U 上）。

注. 投影 $\pi_U(x) \in \mathbb{R}^n$ 仍然是一个 n 维向量，而不是标量。然而，若我们想相对于张成子空间 U 的基向量 b 来表示它，就不再需要 n 个坐标，而只需一个坐标：λ。

原书p.85

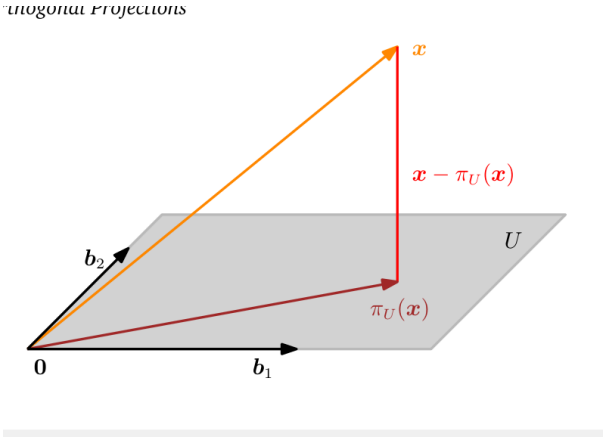


图 3.11: 到以 b_1, b_2 为基的二维子空间 U 上的投影。$x \in \mathbb{R}^3$ 在 U 上的投影 $\pi_U(x)$ 可表示为 b_1, b_2 的线性组合，而位移向量 $x - \pi_U(x)$ 与 b_1 和 b_2 都正交。

例 3.10 (到直线上的投影). 求过原点、由 $b = [1\ 2\ 2]^\top$ 张成的直线上的投影矩阵 P_π。b 既是方向，也是该一维子空间（过原点的直线）的一组基。

由 (3.46)，我们得到

$$P_\pi = \frac{bb^\top}{b^\top b} = \frac{1}{9}\begin{bmatrix}1\\2\\2\end{bmatrix}[1\ 2\ 2] = \frac{1}{9}\begin{bmatrix}1 & 2 & 2\\2 & 4 & 4\\2 & 4 & 4\end{bmatrix}. \tag{3.47}$$

现在我们选取一个特定的 x，看它是否位于由 b 张成的子空间中。取 $x = [1\ 1\ 1]^\top$，投影为

$$\pi_U(x) = P_\pi x = \frac{1}{9}\begin{bmatrix}1 & 2 & 2\\2 & 4 & 4\\2 & 4 & 4\end{bmatrix}\begin{bmatrix}1\\1\\1\end{bmatrix} = \frac{1}{9}\begin{bmatrix}5\\10\\10\end{bmatrix} \in \operatorname{span}\left[\begin{bmatrix}1\\2\\2\end{bmatrix}\right]. \tag{3.48}$$

注意对 $\pi_U(x)$ 再作用一次 P_π 不会改变任何东西，即 $P_\pi \pi_U(x) = \pi_U(x)$。这是符合预期的，因为根据定义 3.10，我们知道投影矩阵 P_π 对所有 x 满足 $P_\pi^2 x = P_\pi x$。

注. 利用第 4 章的结果，我们可以证明 $\pi_U(x)$ 是 P_π 的特征向量，相应特征值为 1。

3.8.2　到一般子空间上的投影

下面，我们来看向量 $x \in \mathbb{R}^n$ 到低维子空间 $U \subseteq \mathbb{R}^n$（其中 $\dim(U) = m \geq 1$）上的正交投影。图 3.11 给出了图示。

假设 $(b_1, \ldots, b_m)$ 是 U 的一组有序基。任意在 U 上的投影 $\pi_U(x)$ 必然是 U 的元素。因此，它们可以表示为 U 的基向量 $b_1, \ldots, b_m$ 的线性组合，即 $\pi_U(x) = \sum_{i=1}^{m} \lambda_i b_i$。与一维情形一样，我们按三步来求投影 $\pi_U(x)$ 和投影矩阵 P_π：

原书p.86

1. 求投影的坐标 $\lambda_1, \ldots, \lambda_m$（关于 U 的基）。　使线性组合

$$\pi_U(x) = \sum_{i=1}^{m} \lambda_i b_i = B\,\lambda, \tag{3.49}$$

$$B = [b_1, \ldots, b_m] \in \mathbb{R}^{n \times m}, \qquad \lambda = [\lambda_1, \ldots, \lambda_m]^\top \in \mathbb{R}^m, \tag{3.50}$$

离 $x \in \mathbb{R}^n$ 最近。与一维情形一样，“最近”意味着“距离最小”，这蕴含连接 $\pi_U(x) \in U$ 与 $x \in \mathbb{R}^n$ 的向量必须与 U 的所有基向量正交。因此我们得到 m 个联立条件（假设以点积为内积）

$$\langle b_1,\, x - \pi_U(x) \rangle = b_1^\top (x - \pi_U(x)) = 0 \tag{3.51}$$

$$\vdots$$

$$\langle b_m,\, x - \pi_U(x) \rangle = b_m^\top (x - \pi_U(x)) = 0 \tag{3.52}$$

代入 $\pi_U(x) = B\lambda$，可写成

$$b_1^\top (x - B\lambda) = 0 \tag{3.53}$$

$$\vdots$$

$$b_m^\top (x - B\lambda) = 0 \tag{3.54}$$

从而得到一个齐次线性方程组

$$\begin{bmatrix} b_1^\top \\ \vdots \\ b_m^\top \end{bmatrix} [x - B\lambda] = 0 \quad \Longleftrightarrow \quad B^\top (x - B\lambda) = 0 \tag{3.55}$$

$$\Longleftrightarrow \quad B^\top B\,\lambda = B^\top x. \tag{3.56}$$

最后这个式子称为法方程（normal equation）。由于 $b_1, \ldots, b_m$ 是 U 的一组基，因而线性无关，$B^\top B \in \mathbb{R}^{m \times m}$ 是正则的、可逆的。这使我们能够解出系数/坐标

法方程

$$\lambda = (B^\top B)^{-1} B^\top x. \tag{3.57}$$

矩阵 $(B^\top B)^{-1} B^\top$ 也称为 B 的伪逆（pseudo-inverse），它可以对非方阵 B 计算。它只要求 $B^\top B$ 正定，当 B 满秩时即是如此。在实际应用中（例如线性回归）我们常常给 $B^\top B$ 加上一个“抖动项” ϵI 以保证数值稳定性并使正定性增强。这种“岭”可以用贝叶斯推断严格推导。详见第 9 章。

原书p.87

伪逆

2. 求投影 $\pi_U(x) \in U$。　我们已经确立 $\pi_U(x) = B\lambda$。因此，由 (3.57)

$$\pi_U(x) = B(B^\top B)^{-1}B^\top x. \tag{3.58}$$

3. 求投影矩阵 P_π。　由 (3.58)，我们立即看到满足 $P_\pi x = \pi_U(x)$ 的投影矩阵必为

$$P_\pi = B(B^\top B)^{-1}B^\top. \tag{3.59}$$

注. 到一般子空间上投影的解把一维情形作为特例包含在内: 若 $\dim(U) = 1$, 则 $B^\top B \in \mathbb{R}$ 是一个标量, 我们可以把 (3.59) 中的投影矩阵 $P_\pi = B(B^\top B)^{-1}B^\top$ 改写为 $P_\pi = \dfrac{BB^\top}{B^\top B}$，这正是 (3.46) 中的投影矩阵。

例 3.11 (到二维子空间上的投影)**.** 对给定子空间 $U = \operatorname{span}\left[\begin{bmatrix}1\\1\\1\end{bmatrix}, \begin{bmatrix}0\\1\\2\end{bmatrix}\right] \subseteq \mathbb{R}^3$ 以及 $x = \begin{bmatrix}6\\0\\0\end{bmatrix} \in \mathbb{R}^3$，求 x 关于子空间 U 的坐标 λ、投影点 $\pi_U(x)$ 和投影矩阵 P_π。

首先，我们看到 U 的生成集是一组基（线性无关），并把 U 的基向量写成矩阵

$$B = \begin{bmatrix}1 & 0\\1 & 1\\1 & 2\end{bmatrix}.$$

其次，计算矩阵 $B^\top B$ 和向量 $B^\top x$:

$$B^\top B = \begin{bmatrix}1 & 1 & 1\\0 & 1 & 2\end{bmatrix}\begin{bmatrix}1 & 0\\1 & 1\\1 & 2\end{bmatrix} = \begin{bmatrix}3 & 3\\3 & 5\end{bmatrix}, \qquad B^\top x = \begin{bmatrix}1 & 1 & 1\\0 & 1 & 2\end{bmatrix}\begin{bmatrix}6\\0\\0\end{bmatrix} = \begin{bmatrix}6\\0\end{bmatrix}. \tag{3.60}$$

第三，解法方程 $B^\top B\lambda = B^\top x$ 求 λ:

$$\begin{bmatrix}3 & 3\\3 & 5\end{bmatrix}\begin{bmatrix}\lambda_1\\\lambda_2\end{bmatrix} = \begin{bmatrix}6\\0\end{bmatrix} \quad\Longleftrightarrow\quad \lambda = \begin{bmatrix}5\\-3\end{bmatrix}. \tag{3.61}$$

第四，x 在 U 上（即在 B 的列空间中）的投影 $\pi_U(x)$ 可直接算得

$$\pi_U(x) = B\lambda = \begin{bmatrix}5\\2\\-1\end{bmatrix}. \tag{3.62}$$

相应的投影误差是原始向量与其在 U 上投影之间差向量的范数，即

投影误差
原书p.88

$$\|x - \pi_U(x)\| = \|[1\ -2\ 1]^\top\| = \sqrt{6}. \tag{3.63}$$

第五，（对任意 $x \in \mathbb{R}^3$ 的）投影矩阵为

$$P_\pi = B(B^\top B)^{-1}B^\top = \frac{1}{6}\begin{bmatrix} 5 & 2 & -1 \\ 2 & 2 & 2 \\ -1 & 2 & 5 \end{bmatrix}. \tag{3.64}$$

为验证结果，我们可以 (a) 检查位移向量 $\pi_U(x) - x$ 是否与 U 的所有基向量正交；(b) 验证 $P_\pi = P_\pi^2$（见定义 3.10）。

注. 投影 $\pi_U(x)$ 虽然位于 m 维子空间 $U \subseteq \mathbb{R}^n$ 中，但它们仍是 $\mathbb{R}^n$ 中的向量。然而，要表示一个被投影的向量，我们只需相对于 U 的基向量 $b_1, \ldots, b_m$ 的 m 个坐标 $\lambda_1, \ldots, \lambda_m$。

注. 在具有一般内积的向量空间中，计算由内积定义的夹角和距离时必须小心。

投影使我们能够考察没有解的线性方程组 $Ax = b$ 的情形。回忆这意味着 b 不在 A 的张成空间中，即向量 b 不在 A 的各列所张成的子空间中。鉴于该线性方程无法精确求解，我们可以求一个近似解。其想法是：在由 A 的各列张成的子空间中找到离 b 最近的向量，即计算 b 到 A 的各列所张成子空间上的正交投影。这个问题在实践中经常出现，其解称为超定方程组的最小二乘解（least-squares solution）（假设以点积为内积）。这将在第 9.4 节进一步讨论。使用重构误差 (3.63) 是导出主成分分析的一种可能途径（第 10.3 节）。

最小二乘

注. 我们刚刚考察了向量 x 到以 $\{b_1, \ldots, b_k\}$ 为基的子空间 U 上的投影。若这组基是规范正交基（即满足 (3.33) 和 (3.34)），则投影方程 (3.58) 大大简化为

$$\pi_U(x) = BB^\top x \tag{3.65}$$

因为此时 $B^\top B = I$，其坐标为

$$\lambda = B^\top x. \tag{3.66}$$

这意味着我们不再需要从 (3.58) 计算逆矩阵，从而节省计算时间。

3.8.3 Gram–Schmidt 正交化

原书p.89

投影是 Gram–Schmidt 方法的核心，它使我们能够把 n 维向量空间 V 的任意基 $(b_1, \ldots, b_n)$ 构造性地变换为 V 的一组正交/规范正交基 $(u_1, \ldots, u_n)$。这组基总是存在（Liesen and Mehrmann, 2015），且 $\text{span}[b_1, \ldots, b_n] = \text{span}[u_1, \ldots, u_n]$。Gram–Schmidt 正交化方法从 V 的任意基 $(b_1, \ldots, b_n)$ 迭代地构造一组正交基 $(u_1, \ldots, u_n)$，步骤如下：

GS 正交化

$$u_1 := b_1 \tag{3.67}$$

$$u_k := b_k - \pi_{\text{span}[u_1,\ldots,u_{k-1}]}(b_k), \qquad k = 2, \ldots, n. \tag{3.68}$$

在 (3.68) 中，第 k 个基向量 b_k 被投影到由前 $k-1$ 个已构造的正交向量 $u_1, \ldots, u_{k-1}$ 张成的子空间上；见第 3.8.2 节。然后从 b_k 中减去这个投影，得到一个与由

$u_1, \ldots, u_{k-1}$ 张成的 $(k-1)$ 维子空间正交的向量 u_k。对所有 n 个基向量 $b_1, \ldots, b_n$ 重复此过程，就得到 V 的一组正交基 $(u_1, \ldots, u_n)$。若我们把 u_k 归一化，就得到一组满足 $\|u_k\| = 1$（$k = 1, \ldots, n$）的规范正交基。

例 3.12 (Gram–Schmidt 正交化)**.** 考虑 $\mathbb{R}^2$ 的一组基 (b_1, b_2)，其中

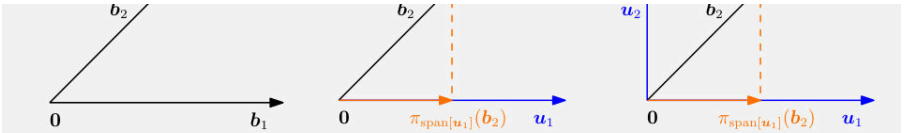
$$b_1 = \begin{bmatrix} 2 \\ 0 \end{bmatrix}, \qquad b_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}; \tag{3.69}$$

另见图 3.12(a)。用 Gram–Schmidt 方法，我们按如下方式构造 $\mathbb{R}^2$ 的一组正交基 (u_1, u_2)（假设以点积为内积）：

$$u_1 := b_1 = \begin{bmatrix} 2 \\ 0 \end{bmatrix}, \tag{3.70}$$

$$u_2 := b_2 - \pi_{\text{span}[u_1]}(b_2) \overset{(3.45)}{=} b_2 - \frac{u_1 u_1^\top}{\|u_1\|^2} b_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} - \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \end{bmatrix}. \tag{3.71}$$

这些步骤在图 3.12(b) 和 (c) 中给出了图示。我们立即看到 u_1 与 u_2 正交，即 $u_1^\top u_2 = 0$。



(a) Original non-orthogonal basis vectors $\boldsymbol{b}_1, \boldsymbol{b}_2$.

(b) First new basis vector $\boldsymbol{u}_1 = \boldsymbol{b}_1$ and projection of $\boldsymbol{b}_2$ onto the subspace spanned by $\boldsymbol{u}_1$.

(c) Orthogonal basis vectors $\boldsymbol{u}_1$ and $\boldsymbol{u}_2 = \boldsymbol{b}_2 - \pi_{\text{span}[\boldsymbol{u}_1]}(\boldsymbol{b}_2)$.

Consider a basis $(\boldsymbol{b}_1, \boldsymbol{b}_2)$ of $\mathbb{R}^2$, where

$$\boldsymbol{b}_1 = \begin{bmatrix} 2 \\ 0 \end{bmatrix}, \quad \boldsymbol{b}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}; \tag{3.69}$$

图 3.12: Gram–Schmidt 正交化。(a) $\mathbb{R}^2$ 的非正交基 (b_1, b_2)；(b) 先构造的基向量 u_1 以及 b_2 到 span$[u_1]$ 上的正交投影；(c) $\mathbb{R}^2$ 的正交基 (u_1, u_2)。

3.8.4　到仿射子空间上的投影

至此，我们讨论了如何把一个向量投影到低维子空间 U 上。下面，我们给出把向量投影到仿射子空间上的解法。

考虑图 3.13(a) 中的设定。给定一个仿射空间 $L = x_0 + U$，其中 b_1, b_2 是 U 的基向量。为确定 x 在 L 上的正交投影 $\pi_L(x)$，我们把问题转化为一个我们知道如何求解的问题：到向量子空间上的投影。为做到这一点，我们从 x 和 L 中都减去支撑点 x_0，于是 $L - x_0 = U$ 恰好是向量子空间 U。现在我们可以使用第 3.8.2 节讨论的到子空间上的正交投影，得到投影 $\pi_U(x - x_0)$，如图 3.13(b) 所示。这个投影现在可以通过加上 x_0 平移回 L，于是我们得到到仿射空间 L 上的正交投影为

$$\pi_L(x) = x_0 + \pi_U(x - x_0), \tag{3.72}$$

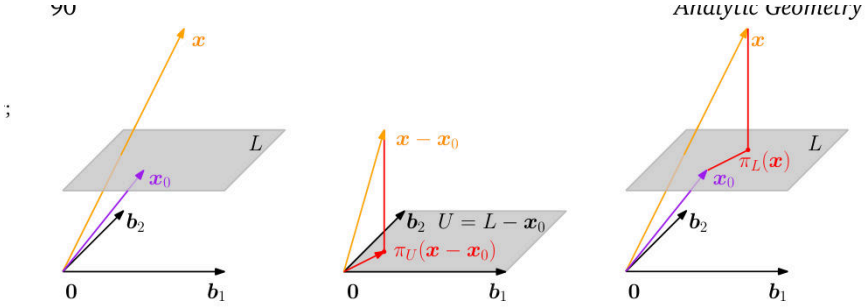
其中 $\pi_U(\cdot)$ 是到子空间 U（即 L 的方向空间）上的正交投影；见图 3.13(c)。

从图 3.13 也可明显看出，x 到仿射空间 L 的距离与 $x - x_0$ 到 U 的距离相同，即

$$d(x, L) = \|x - \pi_L(x)\| = \|x - (x_0 + \pi_U(x - x_0))\| \tag{3.73a}$$

$$= d(x - x_0,\ \pi_U(x - x_0)) = d(x - x_0,\ U). \tag{3.73b}$$

我们将在第 12.1 节用仿射子空间上的投影来推导可分离超平面的概念。



(a) Setting.

(b) Reduce problem to projection π_U onto vector subspace.

(c) Add support point back in to get affine projection π_L.

图 3.13: 到仿射空间上的投影。(a) 原始设定；(b) 把设定平移 $-x_0$，使 $x - x_0$ 可投影到方向空间 U 上；(c) 把投影平移回 $x_0 + \pi_U(x - x_0)$，得到最终正交投影 $\pi_L(x)$。

3.9　旋转

如第 3.4 节所讨论的，长度保持与角度保持是具有正交变换矩阵的线性映射的两个特征。下面，我们将更仔细地考察描述旋转的特定正交变换矩阵。

旋转是一个线性映射（更具体地说，是欧几里得向量空间的一个自同构），它把一个平面绕原点旋转一个角度 θ，即原点是一个不动点。对于正角 $\theta > 0$，按照通常约定，我们沿逆时针方向旋转。图 3.14 给出了一个例子，其变换矩阵为

旋转

$$R = \begin{bmatrix} -0.38 & -0.92 \\ 0.92 & -0.38 \end{bmatrix}. \tag{3.74}$$

旋转的重要应用领域包括计算机图形学和机器人学。例如，在机器人学中，弄清如何旋转机械臂的关节以拾取或放置物体常常很重要，见图 3.15。

原书p.91

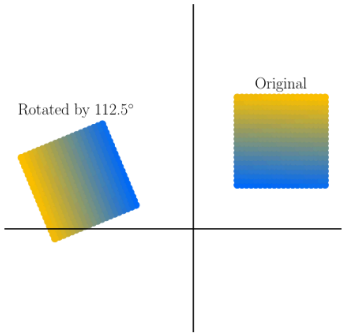


图 3.14: 旋转把平面中的对象绕原点转动。若旋转角为正，我们沿逆时针方向旋转。

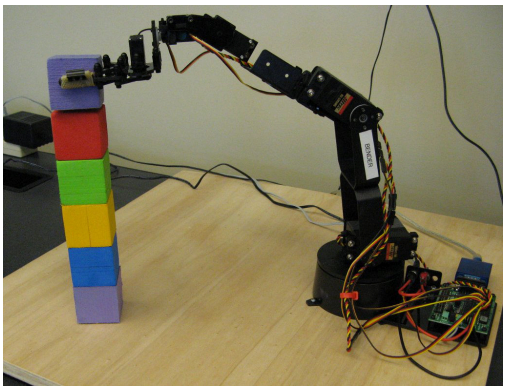


图 3.15: 机械臂需要旋转其关节，以便拾取物体或正确放置物体。图取自 (Deisenroth et al., 2015)。

3.9.1　$\mathbb{R}^2$ 中的旋转

考虑 $\mathbb{R}^2$ 的标准基 $\left\{e_1 = \begin{bmatrix}1\\0\end{bmatrix}, e_2 = \begin{bmatrix}0\\1\end{bmatrix}\right\}$，它定义了 $\mathbb{R}^2$ 中的标准坐标系。我们想把这个坐标系旋转一个角度 θ，如图 3.16 所示。注意旋转后的向量仍然线性无关，因而是 $\mathbb{R}^2$ 的一组基。这意味着旋转执行了一次基变换。

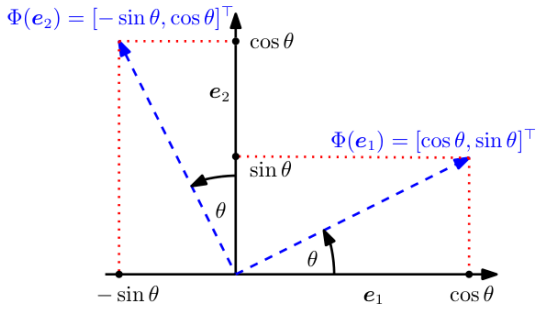
旋转 Φ 是线性映射，因此我们可以用旋转矩阵 $R(\theta)$ 来表示它们。三角学（见图 3.16）使我们能够确定旋转后的坐标轴（Φ 的像）关于 $\mathbb{R}^2$ 中标准基的坐标。我们得到

旋转矩阵
原书p.92

$$\Phi(e_1) = \begin{bmatrix}\cos\theta\\ \sin\theta\end{bmatrix}, \qquad \Phi(e_2) = \begin{bmatrix}-\sin\theta\\ \cos\theta\end{bmatrix}. \tag{3.75}$$

因此，执行到旋转坐标的基变换的旋转矩阵 $R(\theta)$ 为

$$R(\theta) = [\Phi(e_1)\ \Phi(e_2)] = \begin{bmatrix}\cos\theta & -\sin\theta\\ \sin\theta & \cos\theta\end{bmatrix}. \tag{3.76}$$



3.9.1 Rotations in $\mathbb{R}^2$

图 3.16: $\mathbb{R}^2$ 中标准基旋转一个角度 θ。

3.9.2　$\mathbb{R}^3$ 中的旋转

与 $\mathbb{R}^2$ 情形不同，在 $\mathbb{R}^3$ 中我们可以绕一个一维轴旋转任意二维平面。指定一般旋转矩阵最简单的方式，是规定标准基 e_1, e_2, e_3 的像应如何旋转，并确保这些像 Re_1, Re_2, Re_3 彼此规范正交。然后我们可以通过组合标准基的像得到一般旋转矩阵 R。

为了使旋转角有意义，我们必须定义在多于二维的情形下“逆时针”意味着什么。我们采用这样的约定：绕轴的（平面）“逆时针”旋转，是指当我们“从轴的末端朝向原点、正对轴看”时所做的旋转。因此在 $\mathbb{R}^3$ 中，绕三个标准基向量分别有三个（平面）旋转（见图 3.17）：

绕 e_1 轴的旋转

$$R_1(\theta) = [\Phi(e_1)\ \Phi(e_2)\ \Phi(e_3)] = \begin{bmatrix} 1 & 0 & 0 \\ 0 & \cos\theta & -\sin\theta \\ 0 & \sin\theta & \cos\theta \end{bmatrix}. \tag{3.77}$$

这里 e_1 坐标保持固定，逆时针旋转在 e_2e_3 平面内进行。

绕 e_2 轴的旋转

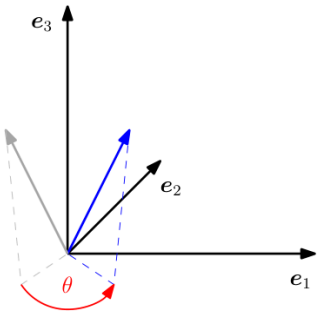
$$R_2(\theta) = \begin{bmatrix} \cos\theta & 0 & \sin\theta \\ 0 & 1 & 0 \\ -\sin\theta & 0 & \cos\theta \end{bmatrix}. \tag{3.78}$$

若我们绕 e_2 轴旋转 e_1e_3 平面，则需要从 e_2 轴的“尖端”朝向原点看 e_2 轴。

绕 e_3 轴的旋转

$$R_3(\theta) = \begin{bmatrix} \cos\theta & -\sin\theta & 0 \\ \sin\theta & \cos\theta & 0 \\ 0 & 0 & 1 \end{bmatrix}. \tag{3.79}$$

图 3.17 对此给出了图示。



ut the e_3-axis.

图 3.17: $\mathbb{R}^3$ 中一个向量（灰色）绕 e_3 轴旋转角度 θ。旋转后的向量以蓝色显示。

3.9.3　n 维中的旋转

把旋转从二维和三维推广到 n 维欧几里得向量空间, 可以直观地描述为: 固定 $n-2$ 个维度，把旋转限制在 n 维空间中的一个二维平面内。与三维情形一样，我们可以旋转任意平面（$\mathbb{R}^n$ 的二维子空间）。

定义 3.10 (Givens 旋转)**.** 设 V 是一个 n 维欧几里得向量空间，$\Phi : V \to V$ 是一个以变换矩阵

原书p.94

$$R_{ij}(\theta) := \begin{bmatrix} I_{i-1} & & & & 0 \\ & \cos\theta & 0 & -\sin\theta & \\ & 0 & I_{j-i-1} & 0 & \\ & \sin\theta & 0 & \cos\theta & \\ 0 & & & & I_{n-j} \end{bmatrix} \in \mathbb{R}^{n\times n}, \tag{3.80}$$

$(1 \leq i < j \leq n,\ \theta \in \mathbb{R})$ 为变换的自同构。则 $R_{ij}(\theta)$ 称为一个 Givens 旋转。

Givens 旋转

本质上，$R_{ij}(\theta)$ 是单位矩阵 I_n，但其中

$$r_{ii} = \cos\theta, \quad r_{ij} = -\sin\theta, \quad r_{ji} = \sin\theta, \quad r_{jj} = \cos\theta. \tag{3.81}$$

在二维（即 $n = 2$）时，我们得到 (3.76) 作为特例。

3.9.4　旋转的性质

旋转具有许多有用的性质，可把它们看作正交矩阵（定义 3.8）来推导:

- 旋转保持距离，即 $\|x - y\| = \|R_\theta(x) - R_\theta(y)\|$。换言之，旋转使任意两点在变换后保持距离不变。
- 旋转保持角度，即 $R_\theta x$ 与 $R_\theta y$ 之间的夹角等于 x 与 y 之间的夹角。
- 三维（或更高维）中的旋转一般不可交换。因此旋转施加的顺序很重要，即使它们绕同一点旋转。只有在二维中向量旋转才可交换，即对所有 $\varphi, \theta \in [0, 2\pi)$ 有 $R(\varphi)R(\theta) = R(\theta)R(\varphi)$。仅当它们绕同一点（例如原点）旋转时，它们（在乘法下）构成一个阿贝尔群。

3.10　延伸阅读

在本章中，我们简要概述了解析几何中的一些重要概念，这些概念将在本书后续章节中使用。若想对我们所介绍的某些概念获得更广泛、更深入的概述，我们推荐以下优秀著作：Axler (2015) 和 Boyd and Vandenberghe (2018)。

内积使我们能够确定向量（子）空间的特定基，其中每个向量与其他所有向量都正交（正交基），这可以用 Gram–Schmidt 方法实现。这些基在优化和求解线性方程组的数值算法中很重要。例如，Krylov 子空间方法，如共轭梯度法或广义最小残差法（GMRES），使彼此正交的残差误差最小化（Stoer and Burlirsch, 2002）。

原书p.95

在机器学习中，内积在核方法的语境下很重要（Schölkopf and Smola, 2002）核方法利用这样一个事实：许多线性算法可以完全由内积计算来表达。于是，“核技巧”使我们能够在一个（可能无穷维的）特征空间中隐式地计算这些内积，甚至无需显式地知道这个特征空间。这使得机器学习中许多算法得以“非线性化”，例如用于降维的核 PCA（Schölkopf et al., 1997）。高斯过程（Rasmussen and Williams, 2006）也属于核方法范畴，是当前概率回归（把曲线拟合到数据点）的最先进方法。核的思想将在第 12 章进一步探讨。

投影常用于计算机图形学，例如生成阴影。在优化中，正交投影常被用来（迭代地）最小化残差误差。这在机器学习中也有应用，例如在线性回归中，我们希望找到一个使残差误差（即数据到线性函数的正交投影的长度）最小的（线性）函数（Bishop, 2006）。我们将在第 9 章进一步研究这一点。PCA（Pearson, 1901; Hotelling, 1933）也使用投影来降低高维数据的维数。我们将在第 10 章更详细地讨论这一点。

习题

原书p.96

3.1　证明对所有 $x = [x_1, x_2]^\top \in \mathbb{R}^2$、$y = [y_1, y_2]^\top \in \mathbb{R}^2$ 定义的

$$\langle x, y \rangle := x_1 y_1 - (x_1 y_2 + x_2 y_1) + 2(x_2 y_2)$$

是一个内积。

3.2　考虑 $\mathbb{R}^2$，其上对所有 $x, y \in \mathbb{R}^2$ 定义

$$\langle x, y \rangle := x^\top \underbrace{\begin{bmatrix} 2 & 0 \\ 1 & 2 \end{bmatrix}}_{=:A} y.$$

$\langle \cdot, \cdot \rangle$ 是内积吗?

3.3　计算

$$x = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}, \qquad y = \begin{bmatrix} -1 \\ -1 \\ 0 \end{bmatrix}$$

之间的距离，使用

a. $\langle x, y\rangle := x^\top y$

b. $\langle x, y\rangle := x^\top A y$，其中 $A := \begin{bmatrix} 2 & 1 & 0 \\ 1 & 3 & -1 \\ 0 & -1 & 2 \end{bmatrix}$

3.4 计算

$$x = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \qquad y = \begin{bmatrix} -1 \\ -1 \end{bmatrix}$$

之间的夹角，使用

a. $\langle x, y\rangle := x^\top y$

b. $\langle x, y\rangle := x^\top B y$，其中 $B := \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}$

3.5 考虑带有点积的欧几里得向量空间 $\mathbb{R}^5$。给定子空间 $U \subseteq \mathbb{R}^5$ 以及 $x \in \mathbb{R}^5$：

$$U = \text{span}\left[\begin{bmatrix} 0 \\ -1 \\ 2 \\ 0 \\ 2 \end{bmatrix}, \begin{bmatrix} 1 \\ -3 \\ 1 \\ -1 \\ 2 \end{bmatrix}, \begin{bmatrix} -3 \\ 4 \\ 1 \\ 2 \\ 1 \end{bmatrix}, \begin{bmatrix} -1 \\ -3 \\ 5 \\ 0 \\ 7 \end{bmatrix}\right], \qquad x = \begin{bmatrix} -1 \\ -9 \\ -1 \\ 4 \\ 1 \end{bmatrix}.$$

a. 确定 x 在 U 上的正交投影 $\pi_U(x)$。

b. 确定距离 $d(x, U)$。

3.6 考虑带内积

$$\langle x, y\rangle := x^\top \begin{bmatrix} 2 & 1 & 0 \\ 1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix} y$$

的 $\mathbb{R}^3$。此外，把 e_1, e_2, e_3 定义为 $\mathbb{R}^3$ 中的标准/典范基。

原书p.97

a. 确定 e_2 在 $U = \text{span}[e_1, e_3]$ 上的正交投影 $\pi_U(e_2)$。
提示：正交性是通过内积定义的。

b. 计算距离 $d(e_2, U)$。

c. 画出该场景：标准基向量以及 $\pi_U(e_2)$。

3.7　设 V 是一个向量空间，π 是 V 的一个自同态。

a. 证明：π 是投影，当且仅当 $\mathrm{id}_V - \pi$ 是投影，其中 id_V 是 V 上的恒等自同态。

b. 现在假设 π 是一个投影。把 $\mathrm{Im}(\mathrm{id}_V - \pi)$ 和 $\ker(\mathrm{id}_V - \pi)$ 表示为 $\mathrm{Im}(\pi)$ 和 $\ker(\pi)$ 的函数。

3.8　用 Gram–Schmidt 方法，把二维子空间 $U \subseteq \mathbb{R}^3$ 的基 $B = (b_1, b_2)$ 化为 U 的一组规范正交基 $C = (c_1, c_2)$，其中

$$b_1 := \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}, \qquad b_2 := \begin{bmatrix} -1 \\ 2 \\ 0 \end{bmatrix}.$$

3.9　设 $n \in \mathbb{N}$，$x_1, \ldots, x_n > 0$ 为 n 个正实数，且 $x_1 + \cdots + x_n = 1$。用柯西–施瓦茨不等式证明

a. $\displaystyle\sum_{i=1}^{n} x_i^2 \geq \frac{1}{n}$

b. $\displaystyle\sum_{i=1}^{n} \frac{1}{x_i} \geq n^2$

提示：想想 $\mathbb{R}^n$ 上的点积。然后选取特定的向量 $x, y \in \mathbb{R}^n$ 并应用柯西–施瓦茨不等式。

3.10　把向量

$$x_1 := \begin{bmatrix} 2 \\ 3 \end{bmatrix}, \qquad x_2 := \begin{bmatrix} 0 \\ -1 \end{bmatrix}$$

旋转 30°。

第 4 章　矩阵分解

原书p.98

在第 2、3 章中，我们研究了处理和度量向量、向量投影以及线性映射的各种方法。向量的映射与变换可以方便地用矩阵所执行的运算来描述。此外，数据也常以矩阵形式表示，例如矩阵的行表示不同的人，列描述这些人的不同特征，如体重、身高和社会经济地位。本章将介绍矩阵的三个方面：如何概括矩阵、如何分解矩阵，以及如何利用这些分解做矩阵逼近。

我们首先讨论那些只需用少数几个数来刻画矩阵整体性质的方法。针对方阵这一重要特例，我们将在行列式（第 4.1 节）和特征值（第 4.2 节）两节中完成这一概括。这些特征数具有重要的数学推论，使我们能迅速把握一个矩阵具备哪些有用性质。由此我们进入矩阵分解方法：矩阵分解的一个类比是数的因数分解，例如把 21 分解为素数 $7 \cdot 3$。正因如此，矩阵分解也常被称为矩阵因式分解（matrix factorization）。矩阵分解用一组可解释的因子矩阵，以另一种表示来描述原矩阵。

矩阵因式分解

我们首先介绍一种作用于对称正定矩阵、类似开平方的运算——Cholesky 分解（第 4.3 节）。随后讨论两种把矩阵因式分解为标准型的相关方法：第一种是矩阵对角化（第 4.4 节），它使我们在选择恰当基后，能用一个对角变换矩阵来表示该线性映射；第二种是奇异值分解（第 4.5 节），它把这种分解推广到非方阵，被视为线性代数的基本概念之一。这些分解非常有用，因为表示数值数据的矩阵往往非常庞大、难以直接分析。最后，我们以矩阵谱系（matrix taxonomy，第 4.7 节）的形式，系统地概述矩阵的类型及其区分性特征。

本章所讲的方法，不仅在后续数学章节（如第 6 章）中变得重要，也出现在应用章节中，例如第 10 章的降维或第 11 章的密度估计。本章的整体结构如图 4.1 的思维导图所示。

原书p.99

4.1　行列式与迹

行列式（determinant）是线性代数中的重要概念。行列式是分析和求解线性方程组时的一个数学对象。行列式仅对方阵 $A \in \mathbb{R}^{n \times n}$ 有定义，即行数与列数

行列式

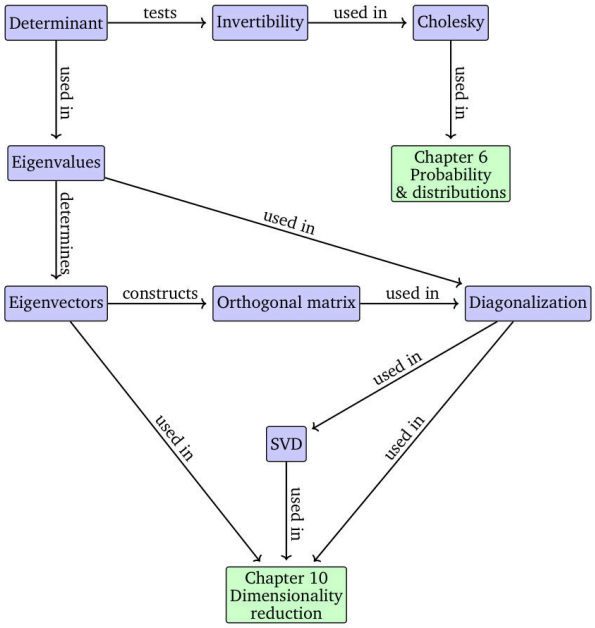


图 4.1: 本章引入概念的思维导图，以及它们在本书其他部分中的用途（对应原书 Figure 4.1）。

相等的矩阵。本书把行列式记作 $\det(A)$，有时也记作 $|A|$，于是

$$\det(A) = \begin{vmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{vmatrix}. \tag{4.1}$$

方阵 $A \in \mathbb{R}^{n\times n}$ 的行列式是一个把 A 映射到实数的函数。在给出一般 $n \times n$ 矩阵行列式的定义之前，先看几个具有启发性的例子，并对一些特殊矩阵定义行列式。 原书 p.100

例 4.1（检验矩阵是否可逆）　先来考察方阵 A 是否可逆（见第 2.2.2 节）。对最小的几种情形，我们已经知道矩阵何时可逆。若 A 是 1×1 矩阵，即一个标量，则 $A = a \Rightarrow A^{-1} = \frac{1}{a}$。于是 $a \cdot \frac{1}{a} = 1$ 当且仅当 $a \neq 0$。

对 2×2 矩阵，由逆矩阵的定义（定义 2.3）知 $AA^{-1} = I$。结合 (2.24)，A 的逆为

$$A^{-1} = \frac{1}{a_{11}a_{22} - a_{12}a_{21}} \begin{bmatrix} a_{22} & -a_{12} \\ -a_{21} & a_{11} \end{bmatrix}. \tag{4.2}$$

因此，A 可逆当且仅当

$$a_{11}a_{22} - a_{12}a_{21} \neq 0. \tag{4.3}$$

这个量就是 $A \in \mathbb{R}^{2\times 2}$ 的行列式，即

$$\det(A) = \begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix} = a_{11}a_{22} - a_{12}a_{21}. \tag{4.4}$$

例 4.1 已经指出了行列式与逆矩阵存在性之间的关系。下一定理对 $n \times n$ 矩阵给出同样结论。

定理 4.1 (4.1)**.** 对任意方阵 $A \in \mathbb{R}^{n\times n}$，$A$ 可逆当且仅当 $\det(A) \neq 0$。

对小矩阵, 我们可以用矩阵元素给出行列式的显式 (闭式) 表达式。当 $n = 1$ 时,

$$\det(A) = \det(a_{11}) = a_{11}. \tag{4.5}$$

当 $n = 2$ 时,

$$\det(A) = \begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix} = a_{11}a_{22} - a_{12}a_{21}, \tag{4.6}$$

即前例中所见。当 $n = 3$ 时（称为 Sarrus 法则),

$$\begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix} = a_{11}a_{22}a_{33}+a_{21}a_{32}a_{13}+a_{31}a_{12}a_{23}-a_{31}a_{22}a_{13}-a_{11}a_{32}a_{23}-a_{21}a_{12}a_{33}. \tag{4.7}$$

原书 p.101

为帮助记忆 Sarrus 法则中的乘积项，可以顺着矩阵中这些三重乘积的元素描一遍。

若方阵 T 满足 $T_{ij} = 0$（当 $i > j$)，即对角线以下全为零，则称 T 为上三角矩阵（upper-triangular matrix)。类似地，把对角线以上全为零的矩阵定义为下三角矩阵（lower-triangular matrix)。对三角矩阵 $T \in \mathbb{R}^{n\times n}$，其行列式等于对角线元素之积，即

上三角矩阵
下三角矩阵

$$\det(T) = \prod_{i=1}^{n} T_{ii}. \tag{4.8}$$

columns of the matrix.
Figure 4.2 The a of the parallelogr (shaded region) spanned by the vectors $\boldsymbol{b}$ and $\boldsymbol{g}$ is

图 4.2: 由向量 b、g 张成的平行四边形（阴影区域）的面积为 $|\det([b, g])|$。

$|\det([\boldsymbol{b}, \boldsymbol{g}])|$.

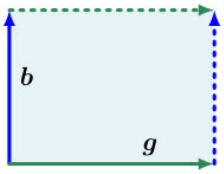


Figure 4.3 The volume of the

图 4.3: 由向量 r, b, g 张成的平行六面体 (阴影体积) 的体积为 $|\det([r, b, g])|$。

例 4.2（作为体积度量的行列式）　当把行列式看作从一组张成 $\mathbb{R}^n$ 中某个几何体的 n 个向量出发的映射时，它的概念就很自然。事实上，行列式 $\det(A)$ 是由矩阵 A 的各列所张成的 n 维平行六面体的带符号体积。

行列式是带符号体积

当 $n = 2$ 时，矩阵各列构成一个平行四边形，见图 4.2。向量间夹角越小平行四边形的面积也越小。考虑两个向量 b, g 作为矩阵 $A = [b, g]$ 的列。则 A 行列式的绝对值，就是以 $0, b, g, b + g$ 为顶点的平行四边形的面积。特别地，若

b, g 线性相关，即存在 $\lambda \in \mathbb{R}$ 使 $b = \lambda g$，它们便不再张成二维平行四边形，相应面积为 0。反之，若 b, g 线性无关且是基向量 e_1, e_2 的倍数，则可写成 $b = \begin{bmatrix} b \\ 0 \end{bmatrix}$、$g = \begin{bmatrix} 0 \\ g \end{bmatrix}$，行列式为

$$\begin{vmatrix} b & 0 \\ 0 & g \end{vmatrix} = bg - 0 = bg.$$

行列式的符号指示张成向量 b, g 相对于标准基 (e_1, e_2) 的定向。在图中，把顺序换成 g, b 会交换 A 的两列，并反转阴影区域的定向。这就回到了熟知的公式：面积 = 高 × 长。这种直觉可推广到更高维。在 $\mathbb{R}^3$ 中，考虑三个向量 $r, b, g \in \mathbb{R}^3$ 张成平行六面体的棱，即一个各面为平行平行四边形的立体（见图 4.3）。3×3 矩阵 $[r, b, g]$ 行列式的绝对值就是该立体的体积。因此，行列式是一个度量由列向量组合成矩阵后所张成带符号体积的函数。

行列式符号指示定向

考虑三个线性无关向量 $r, g, b \in \mathbb{R}^3$：

$$r = \begin{bmatrix} 2 \\ 0 \\ -8 \end{bmatrix}, \quad g = \begin{bmatrix} 6 \\ 1 \\ 0 \end{bmatrix}, \quad b = \begin{bmatrix} 1 \\ 4 \\ -1 \end{bmatrix}. \tag{4.9}$$

把它们写成矩阵的列

原书 p.102

$$A = [r, g, b] = \begin{bmatrix} 2 & 6 & 1 \\ 0 & 1 & 4 \\ -8 & 0 & -1 \end{bmatrix} \tag{4.10}$$

即可把所求体积计算为

$$V = |\det(A)| = 186. \tag{4.11}$$

计算 $n \times n$ 矩阵的行列式需要一个适用于 $n > 3$ 的一般算法，下面就来讨论。定理 4.2 把计算 $n \times n$ 矩阵行列式的问题，归结为计算 $(n-1) \times (n-1)$ 矩阵的行列式。通过递归地应用 Laplace 展开（定理 4.2），我们最终只需计算 2×2 矩阵的行列式，便可求得 $n \times n$ 矩阵的行列式。

定理 4.2 (4.2（Laplace 展开）)**.** 设 $A \in \mathbb{R}^{n \times n}$。则对所有 $j = 1, \ldots, n$：

1. 沿第 j 列展开

$$\det(A) = \sum_{k=1}^{n} (-1)^{k+j} a_{kj} \det(A_{k,j}). \tag{4.12}$$

2. 沿第 j 行展开

$$\det(A) = \sum_{k=1}^{n} (-1)^{k+j} a_{jk} \det(A_{j,k}). \tag{4.13}$$

其中 $A_{k,j} \in \mathbb{R}^{(n-1) \times (n-1)}$ 是删去 A 的第 k 行、第 j 列后得到的子矩阵。$\det(A_{k,j})$ 称为余子式（*minor*），$(-1)^{k+j} \det(A_{k,j})$ 称为代数余子式（*cofactor*）。

余子式 代数余子式

例 4.3（Laplace 展开）　用沿第一行的 Laplace 展开计算

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 3 & 1 & 2 \\ 0 & 0 & 1 \end{bmatrix}. \tag{4.14}$$

由 (4.13) 得

$$\begin{vmatrix} 1 & 2 & 3 \\ 3 & 1 & 2 \\ 0 & 0 & 1 \end{vmatrix} = (-1)^{1+1} \cdot 1 \begin{vmatrix} 1 & 2 \\ 0 & 1 \end{vmatrix} + (-1)^{1+2} \cdot 2 \begin{vmatrix} 3 & 2 \\ 0 & 1 \end{vmatrix} + (-1)^{1+3} \cdot 3 \begin{vmatrix} 3 & 1 \\ 0 & 0 \end{vmatrix}. \tag{4.15}$$

用 (4.6) 计算各 2×2 矩阵的行列式，得

原书 p.103

$$\det(A) = 1(1-0) - 2(3-0) + 3(0-0) = -5. \tag{4.16}$$

作为对照，用 Sarrus 法则 (4.7) 计算：

$$\det(A) = 1\cdot 1\cdot 1 + 3\cdot 0\cdot 3 + 0\cdot 2\cdot 2 - 0\cdot 1\cdot 3 - 1\cdot 0\cdot 2 - 3\cdot 2\cdot 1 = 1 - 6 = -5. \tag{4.17}$$

对 $A \in \mathbb{R}^{n\times n}$，行列式具有以下性质：

- 矩阵乘积的行列式等于相应行列式之积，$\det(AB) = \det(A)\det(B)$。
- 行列式对转置不变，即 $\det(A) = \det(A^\top)$。
- 若 A 可逆（正则），则 $\det(A^{-1}) = \dfrac{1}{\det(A)}$。
- 相似矩阵（定义 2.22）有相同的行列式。因此对线性映射 $\Phi : V \to V$，其所有变换矩阵 A_Φ 都有相同的行列式。故行列式与线性映射基的选取无关。
- 把某一列（行）的倍数加到另一列（行）上，不改变 $\det(A)$。
- 用 $\lambda \in \mathbb{R}$ 乘某一列（行），$\det(A)$ 缩放 λ 倍。特别地，$\det(\lambda A) = \lambda^n \det(A)$。
- 交换两行（列），$\det(A)$ 变号。

由于后三条性质，我们可以用高斯消元（见第 2.1 节）把 A 化为行阶梯形来计算 $\det(A)$。当 A 化为下三角元素全为零的三角形时即可停止。由 (4.8) 知三角矩阵的行列式等于对角线元素之积。

定理 4.3 (4.3)**.** 方阵 $A \in \mathbb{R}^{n\times n}$ 满足 $\det(A) \neq 0$ 当且仅当 $\operatorname{rk}(A) = n$。换言之，A 可逆当且仅当它满秩。

在数学主要靠手算的时代，行列式计算被视为分析矩阵可逆性的基本手段。然而，机器学习中的当代方法采用直接数值方法，已取代了行列式的显式计算。例如在第 2 章中我们学过，逆矩阵可由高斯消元求得，因此高斯消元也可用于计算矩阵行列式。

行列式在后续章节中仍将起重要的理论作用，尤其是在通过特征多项式学习特征值与特征向量（第 4.2 节）时。

定义 4.1 (4.4)**.** 方阵 $A \in \mathbb{R}^{n\times n}$ 的迹（trace）定义为　　迹

$$\operatorname{tr}(A) := \sum_{i=1}^{n} a_{ii}, \tag{4.18}$$

即迹是 A 的对角线元素之和。

原书 p.104

迹满足以下性质：

- $\operatorname{tr}(A+B) = \operatorname{tr}(A) + \operatorname{tr}(B)$，对 $A, B \in \mathbb{R}^{n\times n}$；
- $\operatorname{tr}(\alpha A) = \alpha \operatorname{tr}(A)$，$\alpha \in \mathbb{R}$，对 $A \in \mathbb{R}^{n\times n}$；
- $\operatorname{tr}(I_n) = n$；
- $\operatorname{tr}(AB) = \operatorname{tr}(BA)$，对 $A \in \mathbb{R}^{n\times k}$、$B \in \mathbb{R}^{k\times n}$。

可以证明，只有一个函数同时满足这四条性质——迹（Gohberg et al., 2012）。

矩阵乘积迹的性质更一般。具体地，迹在循环置换下不变，即　　迹在循环置换下不变

$$\operatorname{tr}(AKL) = \operatorname{tr}(KLA) \tag{4.19}$$

对 $A \in \mathbb{R}^{a\times k}$、$K \in \mathbb{R}^{k\times l}$、$L \in \mathbb{R}^{l\times a}$ 成立。此性质可推广到任意多个矩阵的乘积。作为 (4.19) 的特例，对两个向量 $x, y \in \mathbb{R}^n$ 有

$$\operatorname{tr}(xy^\top) = \operatorname{tr}(y^\top x) = y^\top x \in \mathbb{R}. \tag{4.20}$$

给定线性映射 $\Phi : V \to V$（V 为向量空间），我们用 Φ 的矩阵表示的迹来定义该映射的迹。给定 V 的一组基，可用变换矩阵 A 描述 Φ，则 Φ 的迹就是 A 的迹。对 V 的另一组基，相应变换矩阵 B 可由形如 $S^{-1}AS$ 的基变换得到（S 适当选取，见第 2.7.2 节）。于是

$$\operatorname{tr}(B) = \operatorname{tr}(S^{-1}AS) \overset{(4.19)}{=} \operatorname{tr}(ASS^{-1}) = \operatorname{tr}(A). \tag{4.21}$$

因此，虽然线性映射的矩阵表示依赖于基，但线性映射 Φ 的迹与基的选取无关。

本节把行列式和迹作为刻画方阵的函数。综合对行列式和迹的理解，我们现在可以定义一个用多项式描述矩阵 A 的重要方程，它将在后续章节中被广泛使用。

定义 4.2 (4.5（特征多项式）)**.** 对 $\lambda \in \mathbb{R}$ 和方阵 $A \in \mathbb{R}^{n\times n}$，

$$p_A(\lambda) := \det(A - \lambda I) \tag{4.22a}$$

$$= c_0 + c_1\lambda + c_2\lambda^2 + \cdots + c_{n-1}\lambda^{n-1} + (-1)^n\lambda^n, \tag{4.22b}$$

其中 $c_0, \ldots, c_{n-1} \in \mathbb{R}$，称为 A 的特征多项式（characteristic polynomial）。特别地，　　特征多项式

原书 p.105

$$c_0 = \det(A), \tag{4.23}$$

$$c_{n-1} = (-1)^{n-1}\operatorname{tr}(A). \tag{4.24}$$

特征多项式 (4.22a) 将使我们能够计算下一节要讲的特征值与特征向量。

4.2　特征值与特征向量

现在介绍刻画矩阵及其关联线性映射的一种新方式。回顾第 2.7.1 节：给定一组有序基，每个线性映射都有唯一的变换矩阵。我们可以通过“特征”分析来理解线性映射及其变换矩阵。正如将看到的，线性映射的特征值会告诉我们一组特殊向量（特征向量）是如何被该线性映射变换的。

Eigen 为德语

定义 4.3 (4.6)**.** 设 $A \in \mathbb{R}^{n\times n}$ 为方阵。若 $\lambda \in \mathbb{R}$ 是 A 的特征值（eigenvalue），$x \in \mathbb{R}^n \setminus \{0\}$ 是相应的特征向量（eigenvector），则

特征值□ 特征向量

$$Ax = \lambda x. \tag{4.25}$$

我们称 (4.25) 为特征值方程（eigenvalue equation）。

特征值方程

注. 在线性代数文献和软件中，常约定把特征值按降序排列，于是最大特征值及其特征向量称为第一特征值与对应特征向量，次大的称为第二特征值，依此类推。然而教材和文献可能有不同的排序约定，也可能不作排序。本书除非明确说明，否则不预设任何排序。

下列命题等价：

- λ 是 $A \in \mathbb{R}^{n\times n}$ 的特征值；
- 存在 $x \in \mathbb{R}^n \setminus \{0\}$ 使 $Ax = \lambda x$，等价地，$(A - \lambda I_n)x = 0$ 有非平凡解，即 $x \neq 0$；
- $\operatorname{rk}(A - \lambda I_n) < n$；
- $\det(A - \lambda I_n) = 0$。

定义 4.4 (4.7（共向与共线）)**.** 指向同一方向的两个向量称为共向（codirected）。若两个向量指向相同或相反方向，则称它们共线（collinear）。

共向□ 共线

注. （特征向量的不唯一性）若 x 是 A 属于特征值 λ 的特征向量，则对任意 $c \in \mathbb{R} \setminus \{0\}$，$cx$ 也是 A 属于同一特征值的特征向量，因为

$$A(cx) = cAx = c\lambda x = \lambda(cx). \tag{4.26}$$

因此，所有与 x 共线的向量也都是 A 的特征向量。

原书 p.106

定理 4.4 (4.8)**.** $\lambda \in \mathbb{R}$ 是 $A \in \mathbb{R}^{n\times n}$ 的特征值，当且仅当 λ 是 A 的特征多项式 $p_A(\lambda)$ 的根。

定义 4.5 (4.9)**.** 设方阵 A 有特征值 λ_i。λ_i 的代数重数（algebraic multiplicity）是该根在特征多项式中出现的次数。

代数重数

定义 4.6 (4.10（特征子空间与谱）)**.** 对 $A \in \mathbb{R}^{n\times n}$，$A$ 属于某特征值 λ 的所有特征向量张成 $\mathbb{R}^n$ 的一个子空间，称为 A 关于 λ 的特征子空间（eigenspace），记作 E_λ。A 的所有特征值构成的集合称为 A 的特征谱（eigenspectrum），简称谱（spectrum）。

特征子空间

谱

若 λ 是 $A \in \mathbb{R}^{n\times n}$ 的特征值，则相应特征子空间 E_λ 是齐次线性方程组 $(A-\lambda I)x=0$ 的解空间。几何上，非零特征值对应的特征向量指向一个被线性映射拉伸的方向，特征值就是拉伸的倍数；若特征值为负，则拉伸方向反转。

例 4.4（单位矩阵的情形）　单位矩阵 $I \in \mathbb{R}^{n\times n}$ 的特征多项式为 $p_I(\lambda)=\det(I-\lambda I)=(1-\lambda)^n=0$，它只有一个特征值 $\lambda=1$，且出现 n 次。此外，对所有 $x\in\mathbb{R}^n\setminus\{0\}$ 都有 $Ix=\lambda x=1x$。因此单位矩阵唯一的特征子空间 E_1 张成 n 维，$\mathbb{R}^n$ 的全部 n 个标准基向量都是 I 的特征向量。

特征值与特征向量的常用性质如下：

- 矩阵 A 与其转置 $A^\top$ 有相同的特征值，但特征向量不一定相同。
- 特征子空间 E_λ 是 $A-\lambda I$ 的零空间，因为

$$Ax=\lambda x \iff Ax-\lambda x=0 \tag{4.27a}$$

$$\iff (A-\lambda I)x=0 \iff x\in\ker(A-\lambda I). \tag{4.27b}$$

- 相似矩阵（见定义 2.22）有相同的特征值。因此线性映射 Φ 的特征值与其变换矩阵基的选取无关。这使特征值与行列式、迹一起，成为线性映射的关键特征参数，因为它们在基变换下都不变。
- 对称正定矩阵总有正的实特征值。

原书 p.107

例 4.5（计算特征值、特征向量与特征子空间）　求 2×2 矩阵

$$A=\begin{bmatrix}4 & 2\\ 1 & 3\end{bmatrix} \tag{4.28}$$

的特征值与特征向量。

第 1 步：特征多项式。由特征向量 $x\neq 0$ 与特征值 λ 的定义，存在向量使 $Ax=\lambda x$，即 $(A-\lambda I)x=0$。由于 $x\neq 0$，这要求 $A-\lambda I$ 的核（零空间）中不止有 0 一个元素，即 $A-\lambda I$ 不可逆，从而 $\det(A-\lambda I)=0$。因此需要求特征多项式 (4.22a) 的根来得到特征值。

第 2 步：特征值。特征多项式为

$$p_A(\lambda)=\det(A-\lambda I) \tag{4.29a}$$

$$=\det\left(\begin{bmatrix}4 & 2\\ 1 & 3\end{bmatrix}-\begin{bmatrix}\lambda & 0\\ 0 & \lambda\end{bmatrix}\right)=\begin{vmatrix}4-\lambda & 2\\ 1 & 3-\lambda\end{vmatrix} \tag{4.29b}$$

$$=(4-\lambda)(3-\lambda)-2\cdot 1. \tag{4.29c}$$

分解特征多项式：

$$p(\lambda)=(4-\lambda)(3-\lambda)-2\cdot 1=10-7\lambda+\lambda^2=(2-\lambda)(5-\lambda) \tag{4.30}$$

得根 $\lambda_1 = 2$、$\lambda_2 = 5$。

第 3 步：特征向量与特征子空间。求对应这些特征值的特征向量，即找满足

$$\begin{bmatrix} 4-\lambda & 2 \\ 1 & 3-\lambda \end{bmatrix} x = 0 \tag{4.31}$$

的向量 x。对 $\lambda = 5$，有

$$\begin{bmatrix} 4-5 & 2 \\ 1 & 3-5 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} -1 & 2 \\ 1 & -2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 0. \tag{4.32}$$

解此齐次方程组得解空间

$$E_5 = \operatorname{span}\left[\begin{bmatrix} 2 \\ 1 \end{bmatrix} \right]. \tag{4.33}$$

该特征子空间是一维的, 因为它只含一个基向量。类似地, 解齐次方程组求 $\lambda = 2$ 的特征向量:

$$\begin{bmatrix} 4-2 & 2 \\ 1 & 3-2 \end{bmatrix} x = \begin{bmatrix} 2 & 2 \\ 1 & 1 \end{bmatrix} x = 0. \tag{4.34}$$

这意味着任何满足 $x_2 = -x_1$ 的向量 $x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$，例如 $\begin{bmatrix} 1 \\ -1 \end{bmatrix}$，都是特征值 2 的特征向量。相应特征子空间为 原书 p.108

$$E_2 = \operatorname{span}\left[\begin{bmatrix} 1 \\ -1 \end{bmatrix} \right]. \tag{4.35}$$

例 4.5 中的两个特征子空间 E_5、E_2 都是一维的, 因为各自由单个向量张成。但在其他情形可能有多个相同特征值（见定义 4.9），特征子空间也可能不止一维。

定义 4.7 (4.11)**.** 设 λ_i 是方阵 A 的一个特征值。λ_i 的几何重数（geometric multiplicity）是与 λ_i 相伴的线性无关特征向量的个数。换言之，它是由属于 λ_i 的特征向量所张成特征子空间的维数。 几何重数

注. 某个特征值的几何重数至少为 1, 因为每个特征值至少有一个相伴特征向量。几何重数不会超过其代数重数，但可能小于代数重数。

例 4.6　矩阵 $A = \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix}$ 有两个重特征值 $\lambda_1 = \lambda_2 = 2$，代数重数为 2；但该特征值只有一个不同的单位特征向量 $x_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$，故几何重数为 1。

二维中的几何直觉

我们用不同的线性映射来建立对行列式、特征向量和特征值的直觉。图 4.4 画出了五个变换矩阵 $A_1, \ldots, A_5$ 及其对以原点为中心的方形网格点的作用。 原书 p.109

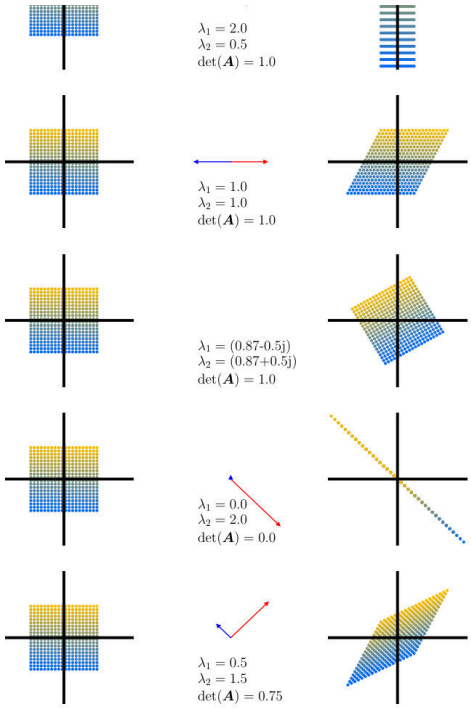


图 4.4: 行列式与特征子空间。五个线性映射及其变换矩阵 $A_i \in \mathbb{R}^{2\times 2}$ 的概览：把 400 个颜色编码的点 $x \in \mathbb{R}^2$（左列）投影到目标点 $A_i x$（右列）。中列画出第一特征向量（被其特征值 λ_1 拉伸）与第二特征向量（被 λ_2 拉伸）。每行对应五个变换矩阵之一在标准基下的作用（对应原书 Figure 4.4）。

- $A_1 = \begin{bmatrix} \frac{1}{2} & 0 \\ 0 & 2 \end{bmatrix}$。两个特征向量的方向对应 $\mathbb{R}^2$ 的基向量，即两个主轴。纵轴被拉伸 2 倍（特征值 $\lambda_1 = 2$），横轴被压缩 $\frac{1}{2}$ 倍（特征值 $\lambda_2 = \frac{1}{2}$）。该映射保面积（$\det(A_1) = 1 = 2 \cdot \frac{1}{2}$）。

- $A_2 = \begin{bmatrix} 1 & \frac{1}{2} \\ 0 & 1 \end{bmatrix}$ 对应一个剪切映射，即把横轴上方正半平面的点向右剪切，负半平面的点向左剪切。该映射保面积（$\det(A_2) = 1$）。特征值 $\lambda_1 = 1 = \lambda_2$ 为重根，特征向量共线（图中为强调画成两个相反方向）。这表明映射只沿一个方向（横轴）作用。这种平行于轴的剪切保面积性质，在几何学上也称为 Cavalieri 平行四边形等面积原理（Katz, 2004）。

- $A_3 = \begin{bmatrix} \cos(\frac{\pi}{6}) & -\sin(\frac{\pi}{6}) \\ \sin(\frac{\pi}{6}) & \cos(\frac{\pi}{6}) \end{bmatrix} = \frac{1}{2}\begin{bmatrix} \sqrt{3} & -1 \\ 1 & \sqrt{3} \end{bmatrix}$。矩阵 A_3 把点逆时针旋转 $\frac{\pi}{6}$ 弧度 $= 30°$，且只有复特征值，反映出该映射是旋转（故不画特征向量）。旋转必保体积，因此行列式为 1。旋转的细节见第 3.9 节。

原书 p.110

- $A_4 = \begin{bmatrix} 1 & -1 \\ -1 & 1 \end{bmatrix}$ 表示在标准基下把二维区域压到一维的映射。由于一个特征值为 0，对应于 $\lambda_1 = 0$ 的（蓝色）特征向量方向上的空间被压平，而正交的（红色）特征向量方向把空间拉伸 $\lambda_2 = 2$ 倍，因此像的面积为 0。

- $A_5 = \begin{bmatrix} 1 & \frac{1}{2} \\ \frac{1}{2} & 1 \end{bmatrix}$ 是剪切兼拉伸映射，把空间缩放 75%，因为 $|\det(A_5)| = \frac{3}{4}$。它沿 λ_2 的（红色）特征向量方向拉伸 1.5 倍，沿正交的（蓝色）特征向量方向压缩 0.5 倍。

例 4.7（生物神经网络的特征谱）　分析和学习网络数据的方法是机器学习方法的重要组成。理解网络的关键在于网络节点间的连接，尤其是两个节点是否相连。在数据科学应用中，研究刻画这种连接关系的矩阵往往很有用。

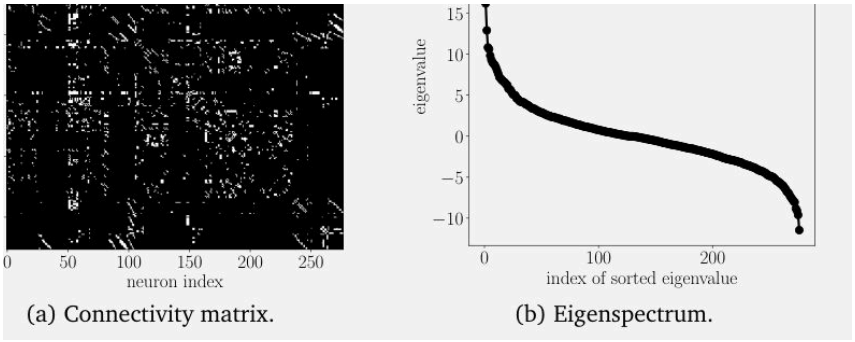


图 4.5: 秀丽隐杆线虫（*Caenorhabditis elegans*）神经网络（Kaiser and Hilgetag, 2006）。(a) 对称化后的连接矩阵；(b) 特征谱。

我们为线虫 C.Elegans 完整神经网络建立连接矩阵/邻接矩阵 $A \in \mathbb{R}^{277\times 277}$，每行（列）对应该线虫脑的 277 个神经元之一。若神经元 i 通过突触与神经元 j 通信，则 $a_{ij} = 1$，否则 $a_{ij} = 0$。该连接矩阵不对称，这意味着特征值可能不是实数。因此我们计算连接矩阵的对称化版本 $A_{\text{sym}} := A + A^\top$。新矩阵 A_{sym} 见图 4.5(a)，当且仅当两神经元相连时 a_{ij} 非零（白色像素），而不论连接方向。图 4.5(b) 给出 A_{sym} 的相应特征谱：横轴是按降序排列的特征值下标，纵轴是相应特征值。这一 S 形特征谱在许多生物神经网络中很典型，其背后机制是当前神经科学的活跃研究方向。

原书 p.111

定理 4.5 (4.12)**.** 若矩阵 $A \in \mathbb{R}^{n\times n}$ 有 n 个互异特征值 $\lambda_1, \ldots, \lambda_n$，则其特征向量 $x_1, \ldots, x_n$ 线性无关。

该定理说明：有 n 个互异特征值的矩阵，其特征向量构成 $\mathbb{R}^n$ 的一组基。

定义 4.8 (4.13)**.** 若方阵 $A \in \mathbb{R}^{n\times n}$ 的线性无关特征向量少于 n 个，则称 A 是亏损的（defective）。

亏损矩阵

非亏损矩阵 $A \in \mathbb{R}^{n\times n}$ 并不一定需要 n 个互异特征值，但它要求特征向量构成 $\mathbb{R}^n$ 的一组基。考察亏损矩阵的特征子空间可知，其各特征子空间维数之和小于 n。具体地，亏损矩阵至少有一个特征值 λ_i 的代数重数 $m > 1$，而几何重数小于 m。

注. 亏损矩阵不可能有 n 个互异特征值，因为互异特征值对应的特征向量线性无关（定理 4.12）。

定理 4.6 (4.14)**.** 给定矩阵 $A \in \mathbb{R}^{m\times n}$，总能构造一个对称半正定矩阵 $S \in \mathbb{R}^{n\times n}$：

$$S := A^\top A. \tag{4.36}$$

注. 若 $\mathrm{rk}(A) = n$，则 $S := A^\top A$ 对称正定。

理解定理 4.14 为何成立，有助于我们理解如何使用对称化矩阵：对称性要求 $S = S^\top$，代入 (4.36) 得 $S = A^\top A = A^\top (A^\top)^\top = (A^\top A)^\top = S^\top$。此外，半正定性（第 3.2.3 节）要求 $x^\top Sx \geqslant 0$，代入 (4.36) 得 $x^\top Sx = x^\top A^\top Ax = (x^\top A^\top)(Ax) = (Ax)^\top (Ax) \geqslant 0$，因为点积计算的是平方和（本身非负）。

定理 4.7 (4.15（谱定理）)**.** 若 $A \in \mathbb{R}^{n\times n}$ 对称，则相应向量空间 V 存在一组由 A 的特征向量构成的标准正交基，且每个特征值都是实数。 谱定理

谱定理的直接推论是：对称矩阵 A 的特征分解存在（特征值为实数），且可找到一组由特征向量构成的 ONB，使 $A = PDP^\top$，其中 D 为对角矩阵，P 的各列为特征向量。

例 4.8　考虑矩阵

$$A = \begin{bmatrix} 3 & 2 & 2 \\ 2 & 3 & 2 \\ 2 & 2 & 3 \end{bmatrix}. \tag{4.37}$$

其特征多项式为 原书 p.112

$$p_A(\lambda) = -(\lambda - 1)^2(\lambda - 7), \tag{4.38}$$

故特征值为 $\lambda_1 = 1$（重根）和 $\lambda_2 = 7$。按求特征向量的标准步骤，得特征子空间

$$E_1 = \mathrm{span}\left[\underbrace{\begin{bmatrix} -1 \\ 1 \\ 0 \end{bmatrix}}_{=:x_1}, \underbrace{\begin{bmatrix} -1 \\ 0 \\ 1 \end{bmatrix}}_{=:x_2}\right], \qquad E_7 = \mathrm{span}\left[\underbrace{\begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}}_{=:x_3}\right]. \tag{4.39}$$

可见 x_3 与 x_1、x_2 都正交，但 $x_1^\top x_2 = 1 \neq 0$，故二者不正交。谱定理（定理 4.15）说存在正交基，但我们现有的这组并不正交。不过我们可以构造一组。

为此利用 x_1, x_2 是同一特征值 λ 的特征向量这一事实。因此对任意 $\alpha, \beta \in \mathbb{R}$ 有

$$A(\alpha x_1 + \beta x_2) = Ax_1\alpha + Ax_2\beta = \lambda(\alpha x_1 + \beta x_2), \tag{4.40}$$

即 x_1, x_2 的任意线性组合也是 A 属于 λ 的特征向量。Gram-Schmidt 算法（第 3.8.3 节）正是利用这种线性组合，从一组基向量迭代构造正交（标准正交）基的方法。因此，即使 x_1, x_2 不正交，也可应用 Gram-Schmidt 算法，找到属于 $\lambda_1 = 1$ 且彼此正交（并与 x_3 正交）的特征向量。本例中可得

$$x_1' = \begin{bmatrix} -1 \\ 1 \\ 0 \end{bmatrix}, \qquad x_2' = \frac{1}{2}\begin{bmatrix} -1 \\ -1 \\ 2 \end{bmatrix}, \tag{4.41}$$

它们彼此正交、与 x_3 正交，且都是 A 属于 $\lambda_1 = 1$ 的特征向量。

在结束对特征值与特征向量的讨论之前，把这些矩阵特征与行列式、迹的概念联系起来是有益的。

定理 4.8 (4.16)**.** 矩阵 $A \in \mathbb{R}^{n\times n}$ 的行列式等于其特征值之积，即

$$\det(A) = \prod_{i=1}^{n} \lambda_i, \tag{4.42}$$

其中 $\lambda_i \in \mathbb{C}$ 是 A 的（可能重复的）特征值。

原书 p.113

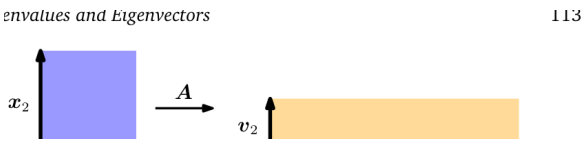


图 4.6: 特征值的几何解释。A 的特征向量被相应特征值拉伸。单位正方形的面积改变 $|\lambda_1\lambda_2|$ 倍，周长改变 $\frac{1}{2}(|\lambda_1| + |\lambda_2|)$ 倍（对应原书 Figure 4.6）。

定理 4.9 (4.17)**.** 矩阵 $A \in \mathbb{R}^{n\times n}$ 的迹等于其特征值之和，即

$$\operatorname{tr}(A) = \sum_{i=1}^{n} \lambda_i, \tag{4.43}$$

其中 $\lambda_i \in \mathbb{C}$ 是 A 的（可能重复的）特征值。

我们给这两个定理一个几何直觉。考虑 $A \in \mathbb{R}^{2\times 2}$，它有两个线性无关特征向量 x_1, x_2。本例假设 (x_1, x_2) 是 $\mathbb{R}^2$ 的一组 ONB，即彼此正交且所张正方形面积为 1，见图 4.6。由第 4.1 节知，行列式计算单位正方形在变换 A 下的面积变化。本例可显式计算：用 A 映射特征向量得 $v_1 = Ax_1 = \lambda_1 x_1$、$v_2 = Ax_2 = \lambda_2 x_2$，即新向量 v_i 是特征向量 x_i 的缩放版，缩放因子为相应特征值 λ_i。v_1, v_2 仍正交，它们张成的矩形面积为 $|\lambda_1\lambda_2|$。

由于本例中 x_1, x_2 标准正交，单位正方形周长直接为 $2(1+1)$。用 A 映射特征向量后得到的矩形周长为 $2(|\lambda_1| + |\lambda_2|)$。因此，特征值绝对值之和告诉我们单位正方形周长在变换矩阵 A 下如何变化。

例 4.9（Google PageRank——网页即特征向量） Google 用矩阵 A 最大特征值对应的特征向量来决定网页在搜索中的排名。PageRank 算法由 Larry Page 和 Sergey Brin 于 1996 年在斯坦福大学提出，其思想是：任意网页的重要性可以由链接到它的网页的重要性来近似。为此，他们把所有网站写成一张巨大的有向图，表明哪个网页链接到哪个网页。PageRank 通过统计指向网站 a_i 的网页数，计算网站 a_i 的权重（重要性）$x_i \geqslant 0$；并且还考虑链接到 a_i 的网站自身的重要性。用户的导航行为则用该图的转移矩阵 A 建模，它告诉我们某人以多大（点击）概率最终到达另一网站。矩阵 A 具有这样的性质：对任意初始排名/重要性向量 x，序列 $x, Ax, A^2x, \ldots$ 收敛到某向量 x^*。该向量称为 PageRank，满足 $Ax^* = x^*$，

原书 p.114
PageRank

即它是 A 的一个特征向量（对应特征值 1）。归一化 x^* 使 $\|x^*\| = 1$ 后，即可把各分量解释为概率。PageRank 的更多细节与不同视角见原始技术报告（Page et al., 1999）。

4.3　Cholesky 分解

机器学习中经常遇到多种特殊类型的矩阵，可以用多种方式因式分解。在正实数中，有开平方运算，把一个数分解为相同因子之积，例如 $9 = 3 \cdot 3$。对矩阵，我们需要小心地在正定对象上做类似开平方的运算。对对称正定矩阵（见第 3.2.3 节），可在若干等价于开平方的运算中选择。Cholesky 分解（Cholesky decomposition）/Cholesky 因式分解（Cholesky factorization）在对称正定矩阵上提供了一种实用的、等价于开平方的运算。

Cholesky分解

定理 4.10 (4.18 (Cholesky 分解))**.** 对称正定矩阵 A 可因式分解为乘积 $A = LL^\top$，其中 L 是对角线元素为正的下三角矩阵:

$$\begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{bmatrix} = \begin{bmatrix} l_{11} & \cdots & 0 \\ \vdots & \ddots & \vdots \\ l_{n1} & \cdots & l_{nn} \end{bmatrix} \begin{bmatrix} l_{11} & \cdots & l_{n1} \\ \vdots & \ddots & \vdots \\ 0 & \cdots & l_{nn} \end{bmatrix}. \tag{4.44}$$

L 称为 A 的 *Cholesky* 因子（*Cholesky factor*），且 L 唯一。

*Cholesky*因子

例 4.10（Cholesky 因式分解）　考虑对称正定矩阵 $A \in \mathbb{R}^{3\times 3}$，求其 Cholesky 分解 $A = LL^\top$，即

$$A = \begin{bmatrix} a_{11} & a_{21} & a_{31} \\ a_{21} & a_{22} & a_{32} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} = LL^\top = \begin{bmatrix} l_{11} & 0 & 0 \\ l_{21} & l_{22} & 0 \\ l_{31} & l_{32} & l_{33} \end{bmatrix} \begin{bmatrix} l_{11} & l_{21} & l_{31} \\ 0 & l_{22} & l_{32} \\ 0 & 0 & l_{33} \end{bmatrix}. \tag{4.45}$$

展开右端乘积得

$$A = \begin{bmatrix} l_{11}^2 & l_{21}l_{11} & l_{31}l_{11} \\ l_{21}l_{11} & l_{21}^2 + l_{22}^2 & l_{31}l_{21} + l_{32}l_{22} \\ l_{31}l_{11} & l_{31}l_{21} + l_{32}l_{22} & l_{31}^2 + l_{32}^2 + l_{33}^2 \end{bmatrix}. \tag{4.46}$$

比较 (4.45) 左端与 (4.46) 右端，可见对角线元素 l_{ii} 有简单规律:

原书 p.115

$$l_{11} = \sqrt{a_{11}}, \qquad l_{22} = \sqrt{a_{22} - l_{21}^2}, \qquad l_{33} = \sqrt{a_{33} - (l_{31}^2 + l_{32}^2)}. \tag{4.47}$$

类似地，对角线以下元素（l_{ij}，$i > j$）也有重复规律:

$$l_{21} = \frac{1}{l_{11}} a_{21}, \qquad l_{31} = \frac{1}{l_{11}} a_{31}, \qquad l_{32} = \frac{1}{l_{22}}(a_{32} - l_{31}l_{21}). \tag{4.48}$$

这样我们就为任意对称正定 3×3 矩阵构造了 Cholesky 分解。关键认识是：给定 A 的元素 a_{ij} 和已算出的 l_{ij}，便可反推出 L 的各分量 l_{ij}。

Cholesky 分解是机器学习底层数值计算的重要工具。这里频繁操作对称正定矩阵，例如多元高斯变量的协方差矩阵（见第 6.5 节）就是对称正定的。对协方差矩阵做 Cholesky 分解，使我们能从高斯分布中生成样本；它还允许对随机变量做线性变换，这在深度随机模型（如变分自编码器）中计算梯度时被大量利用（Jimenez Rezende et al., 2014; Kingma and Welling, 2014）。Cholesky 分解还能高效计算行列式：由 $A = LL^\top$ 知 $\det(A) = \det(L)\det(L^\top) = \det(L)^2$。由于 L 是三角矩阵，其行列式就是对角线元素之积，故 $\det(A) = \prod_i l_{ii}^2$。因此许多数值软件包都用 Cholesky 分解来提高计算效率。

4.4　特征分解与对角化

对角矩阵（diagonal matrix）是所有非对角线元素都为零的矩阵，即形如　对角矩阵

$$D = \begin{bmatrix} c_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & c_n \end{bmatrix}. \tag{4.49}$$

它们使行列式、幂和逆的计算都很快：行列式是对角线元素之积；矩阵幂 D^k 就是各对角线元素取 k 次幂；若对角线元素都非零，则逆 D^{-1} 是各对角线元素的倒数。本节讨论如何把矩阵化为对角形，这是第 2.7.2 节基变换与第 4.2 节特征值的重要应用。　原书 p.116

回顾：若存在可逆矩阵 P 使 $D = P^{-1}AP$，则两矩阵 A, D 相似（定义 2.22）。更具体地，我们考察那些与对角矩阵 D（其对角线上放着 A 的特征值）相似的矩阵 A。

定义 4.9 (4.19（可对角化）)**.** 若矩阵 $A \in \mathbb{R}^{n\times n}$ 与某对角矩阵相似，即存在可逆矩阵 $P \in \mathbb{R}^{n\times n}$ 使 $D = P^{-1}AP$，则称 A 可对角化（diagonalizable）。　可对角化

下面将看到，对角化矩阵 $A \in \mathbb{R}^{n\times n}$ 是用另一组基（见第 2.6.1 节）来表示同一线性映射，而这组基恰好由 A 的特征向量构成。

设 $A \in \mathbb{R}^{n\times n}$，$\lambda_1, \ldots, \lambda_n$ 为一组标量，$p_1, \ldots, p_n$ 为 $\mathbb{R}^n$ 中一组向量。定义 $P := [p_1, \ldots, p_n]$，并设 $D \in \mathbb{R}^{n\times n}$ 是对角线元素为 $\lambda_1, \ldots, \lambda_n$ 的对角矩阵。则可证明

$$AP = PD \tag{4.50}$$

当且仅当 $\lambda_1, \ldots, \lambda_n$ 是 A 的特征值、$p_1, \ldots, p_n$ 是相应特征向量。

此命题成立是因为

$$AP = A[p_1, \ldots, p_n] = [Ap_1, \ldots, Ap_n], \tag{4.51}$$

$$PD = [p_1, \ldots, p_n] \begin{bmatrix} \lambda_1 & & 0 \\ & \ddots & \\ 0 & & \lambda_n \end{bmatrix} = [\lambda_1 p_1, \ldots, \lambda_n p_n]. \tag{4.52}$$

因此 (4.50) 意味着

$$Ap_1 = \lambda_1 p_1, \tag{4.53}$$

$$Ap_n = \lambda_n p_n. \tag{4.54}$$

故 P 的各列必为 A 的特征向量。

对角化的定义要求 $P \in \mathbb{R}^{n\times n}$ 可逆，即 P 满秩（定理 4.3）。这要求我们有 n 个线性无关特征向量 $p_1, \dots, p_n$，即 p_i 构成 $\mathbb{R}^n$ 的一组基。

定理 4.11 (4.20（特征分解）)**.** 方阵 $A \in \mathbb{R}^{n\times n}$ 可因式分解为

$$A = PDP^{-1}, \tag{4.55}$$

其中 $P \in \mathbb{R}^{n\times n}$，$D$ 为对角矩阵、对角线元素是 A 的特征值；当且仅当 A 的特征向量构成 $\mathbb{R}^n$ 的一组基时成立。

原书 p.117

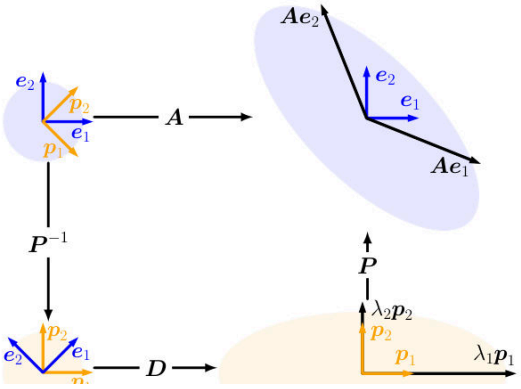


图 4.7: 把特征分解理解为依次进行的变换。左上到左下：P^{-1} 把基从标准基变换到特征基（此处画在 $\mathbb{R}^2$ 中，类似旋转操作）。左下到右下：D 沿重新映射后的正交特征向量缩放（图中圆被拉伸为椭圆）。右下到右上：P 撤销基变换（画成反向旋转），恢复原坐标系（对应原书 Figure 4.7）。

定理 4.20 表明，只有非亏损矩阵才能对角化，且 P 的各列是 A 的 n 个特征向量。对对称矩阵，可得到更强的特征分解结果。

定理 4.12 (4.21)**.** 对称矩阵 $S \in \mathbb{R}^{n\times n}$ 总可对角化。

定理 4.21 直接由谱定理 4.15 推出。此外，谱定理指出可找到 $\mathbb{R}^n$ 的一组特征向量 ONB，这使 P 成为正交矩阵，从而 $D = P^\top AP$。

注. 矩阵的 Jordan 标准形提供了一种对亏损矩阵也适用的分解（Lang, 1987），但超出本书范围。

特征分解的几何直觉　可把矩阵的特征分解理解如下（另见图 4.7）：设 A 是线性映射在标准基 e_i（蓝色箭头）下的变换矩阵。P^{-1} 把基从标准基变换到特征基；然后对角矩阵 D 沿这些轴按特征值 λ_i 缩放向量；最后 P 把缩放后的向量变换回标准/典范坐标，得到 $\lambda_i p_i$。

例 4.11（特征分解）　求 $A = \frac{1}{2}\begin{bmatrix} 5 & -2 \\ -2 & 5 \end{bmatrix}$ 的特征分解。

原书 p.118

第 1 步：求特征值与特征向量。A 的特征多项式为

$$\det(A - \lambda I) = \det\left(\begin{bmatrix} \frac{5}{2} - \lambda & -1 \\ -1 & \frac{5}{2} - \lambda \end{bmatrix}\right) \tag{4.56a}$$

$$= \left(\frac{5}{2} - \lambda\right)^2 - 1 = \lambda^2 - 5\lambda + \frac{21}{4} = \left(\lambda - \frac{7}{2}\right)\left(\lambda - \frac{3}{2}\right). \tag{4.56b}$$

因此 A 的特征值为 $\lambda_1 = \frac{7}{2}$、$\lambda_2 = \frac{3}{2}$（特征多项式的根），相应（归一化）特征向量由

$$Ap_1 = \frac{7}{2}p_1, \qquad Ap_2 = \frac{3}{2}p_2 \tag{4.57}$$

解得

$$p_1 = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 \\ -1 \end{bmatrix}, \qquad p_2 = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 \\ 1 \end{bmatrix}. \tag{4.58}$$

第 2 步：检查存在性。特征向量 p_1, p_2 构成 $\mathbb{R}^2$ 的一组基，故 A 可对角化。

第 3 步：构造对角化矩阵 P。把 A 的特征向量收集到 P 中：

$$P = [p_1, p_2] = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \\ -1 & 1 \end{bmatrix}. \tag{4.59}$$

于是

$$P^{-1}AP = \begin{bmatrix} \frac{7}{2} & 0 \\ 0 & \frac{3}{2} \end{bmatrix} = D. \tag{4.60}$$

等价地（利用本例中 p_1, p_2 构成 ONB 故 $P^{-1} = P^\top$），

$$\underbrace{\frac{1}{2}\begin{bmatrix} 5 & -2 \\ -2 & 5 \end{bmatrix}}_{A} = \underbrace{\frac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \\ -1 & 1 \end{bmatrix}}_{P}\begin{bmatrix} \frac{7}{2} & 0 \\ 0 & \frac{3}{2} \end{bmatrix}\underbrace{\frac{1}{\sqrt{2}}\begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix}}_{P^{-1}}. \tag{4.61}$$

对角矩阵 D 可高效求幂。因此可通过特征分解（若存在）求矩阵 $A \in \mathbb{R}^{n\times n}$ 的幂：

$$A^k = (PDP^{-1})^k = PD^kP^{-1}. \tag{4.62}$$

计算 D^k 很高效，因为只需对每个对角线元素单独取幂。

设特征分解 $A = PDP^{-1}$ 存在，则

$$\det(A) = \det(PDP^{-1}) = \det(P)\det(D)\det(P^{-1}) \tag{4.63a}$$

$$= \det(D) = \prod_i d_{ii} \tag{4.63b}$$

从而高效计算 A 的行列式。

原书 p.119

特征分解要求方阵。若能对一般矩阵做分解就更好了。下一节介绍更一般的矩阵分解技术——奇异值分解。

4.5　奇异值分解

矩阵的奇异值分解（singular value decomposition, SVD）是线性代数中一种核心的矩阵分解方法。它被称为“线性代数基本定理”（Strang, 1993），因为它适用于所有矩阵（不限于方阵），并且总是存在。此外，正如后文将探讨的，表示线性映射 $\Phi : V \to W$ 的矩阵 A 的 SVD，量化了这两个向量空间底层几何之间的变化。更深入的 SVD 数学概览推荐 Kalman (1996) 与 Roy and Banerjee (2014)。

奇异值分解

定理 4.13 (4.22（SVD 定理）)**.** 设 $A \in \mathbb{R}^{m\times n}$ 为秩 $r \in [0, \min(m,n)]$ 的矩阵。A 的 *SVD* 是如下形式的分解：

$$A = U\Sigma V^\top, \tag{4.64}$$

其中 $U \in \mathbb{R}^{m\times m}$ 为正交矩阵，列向量为 u_i（$i = 1,\dots,m$）；$V \in \mathbb{R}^{n\times n}$ 为正交矩阵，列向量为 v_j（$j = 1,\dots,n$）。Σ 是 $m \times n$ 矩阵，满足 $\Sigma_{ii} = \sigma_i \geqslant 0$，$\Sigma_{ij} = 0$（$i \neq j$）。$\Sigma$ 的对角线元素 σ_i（$i = 1,\dots,r$）称为奇异值（*singular values*），u_i 称为左奇异向量（*left-singular vectors*），v_j 称为右奇异向量（*right-singular vectors*）按约定，奇异值排序为 $\sigma_1 \geqslant \sigma_2 \geqslant \cdots \geqslant \sigma_r \geqslant 0$。

奇异值
左奇异向量
右奇异向量

奇异值矩阵 Σ 是唯一的，但需要稍加注意。注意 $\Sigma \in \mathbb{R}^{m\times n}$ 是矩形的，与 A 同尺寸。这意味着 Σ 有一个含奇异值的对角子矩阵，还需要额外补零。具体地，若 $m > n$，则 Σ 在前 n 行具有对角结构，其后从 $n+1$ 到 m 行全为零：

$$\Sigma = \begin{bmatrix} \sigma_1 & 0 & 0 & 0 \\ 0 & \ddots & 0 & 0 \\ 0 & 0 & \sigma_n & 0 \\ \vdots & & \vdots & \\ 0 & 0 & \cdots & 0 \end{bmatrix}. \tag{4.65}$$

若 $m < n$，则 Σ 在前 m 列具有对角结构，从 $m+1$ 到 n 列全为零：

$$\Sigma = \begin{bmatrix} \sigma_1 & 0 & 0 & 0 & \cdots & 0 \\ 0 & \ddots & 0 & 0 & \cdots & 0 \\ 0 & 0 & \sigma_m & 0 & \cdots & 0 \end{bmatrix}. \tag{4.66}$$

注. 对任意矩阵 $A \in \mathbb{R}^{m\times n}$，SVD 都存在。

4.5.1　SVD 的几何直觉

SVD 为描述变换矩阵 A 提供了几何直觉。下面把 SVD 看作依次对基进行的线性变换。在例 4.12 中，我们再把 SVD 的变换矩阵作用于 $\mathbb{R}^2$ 中的一组向量，从而更清楚地可视化每个变换的效果。

矩阵的 SVD 可解释为把相应线性映射（回顾第 2.7.1 节）$\Phi : \mathbb{R}^n \to \mathbb{R}^m$ 分解为三个运算，见图 4.8。SVD 直觉表面上与特征分解直觉（图 4.7）结构相似：粗略地说，SVD 先通过 $V^\top$ 做基变换，再通过奇异值矩阵 Σ 缩放并增（减）维，

原书 p.121

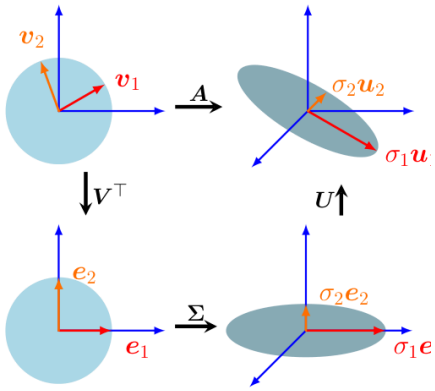


图 4.8: $A \in \mathbb{R}^{3\times 2}$ 的 SVD 作为依次变换的直觉。左上到左下：$V^\top$ 在 $\mathbb{R}^2$ 中做基变换。左下到右下：Σ 缩放并从 $\mathbb{R}^2$ 映射到 $\mathbb{R}^3$，右下的椭圆位于 $\mathbb{R}^3$ 中，第三维垂直于椭圆盘面。右下到右上：U 在 $\mathbb{R}^3$ 内做基变换（对应原书 Figure 4.8）。

最后通过 U 做第二次基变换。SVD 还包含若干重要细节与注意事项，因此下面更细致地回顾直觉。

原书 p.120

设给定线性映射 $\Phi : \mathbb{R}^n \to \mathbb{R}^m$ 分别在 $\mathbb{R}^n$、$\mathbb{R}^m$ 标准基 B、C 下的变换矩阵，并设 $\mathbb{R}^n$ 的另一组基 $\tilde{B}$、$\mathbb{R}^m$ 的另一组基 $\tilde{C}$。则：

1. 矩阵 V 在定义域 $\mathbb{R}^n$ 中把基从 $\tilde{B}$（图 4.8 左上角红色、橙色向量 v_1, v_2）变到标准基 B。$V^\top = V^{-1}$ 把基从 B 变到 $\tilde{B}$。此时红、橙向量与典范基对齐（图 4.8 左下）。

2. 基变换到 $\tilde{B}$ 后，Σ 用奇异值 σ_i 缩放新坐标（并增删维数），即 Σ 是 Φ 在 $\tilde{B}$、$\tilde{C}$ 下的变换矩阵，表现为红、橙向量被拉伸并落在 e_1-e_2 平面上，而该平面此时被嵌入第三维（图 4.8 右下）。

3. U 在陪域 $\mathbb{R}^m$ 中把基从 $\tilde{C}$ 变到 $\mathbb{R}^m$ 的典范基，表现为红、橙向量被旋出 e_1-e_2 平面（图 4.8 右上）。

SVD 在定义域和陪域中都表达了基变换。这与特征分解不同：特征分解在同一向量空间内操作，先做基变换再撤销。SVD 的特别之处在于，这两组不同的基同时被奇异值矩阵 Σ 联系起来。

例 4.12（向量与 SVD）　考虑对位于以原点为中心、边长 2×2 的方框内的向量网格 $X \in \mathbb{R}^2$ 做映射。用标准基，通过

原书 p.123

$$A = \begin{bmatrix} 1 & -0.8 & 0 \\ 1 & 1 & 0 \end{bmatrix} = U\Sigma V^\top \tag{4.67a}$$

$$= \begin{bmatrix} -0.79 & -0.62 & 0.38 \\ -0.78 & -0.49 & -0.62 \\ -0.48 & -0.62 & 0.62 \end{bmatrix} \begin{bmatrix} 1.62 & 0 \\ 0 & 1.0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} -0.78 & 0.62 \\ -0.62 & -0.78 \end{bmatrix} \tag{4.67b}$$

映射这些向量。我们从排成网格的一组向量 X（彩色点，图 4.9 左上）开始。先作用 $V^\top \in \mathbb{R}^{2\times 2}$，它旋转 X，旋转后的向量见图 4.9 左下。再用奇异值矩阵 Σ 把这些向量映射到陪域 $\mathbb{R}^3$（图 4.9 右下）。注意所有向量都在 x_1-x_2 平面内，第三坐标恒为 0，且 x_1-x_2 平面内的向量已被奇异值拉伸。 原书 p.122

把向量 X 用 A 直接映射到陪域 $\mathbb{R}^3$，等价于用 $U\Sigma V^\top$ 变换 X，其中 U 在陪域 $\mathbb{R}^3$ 内旋转，使映射后的向量不再局限于 x_1-x_2 平面，但仍在某平面上，如图 4.9 右上所示。

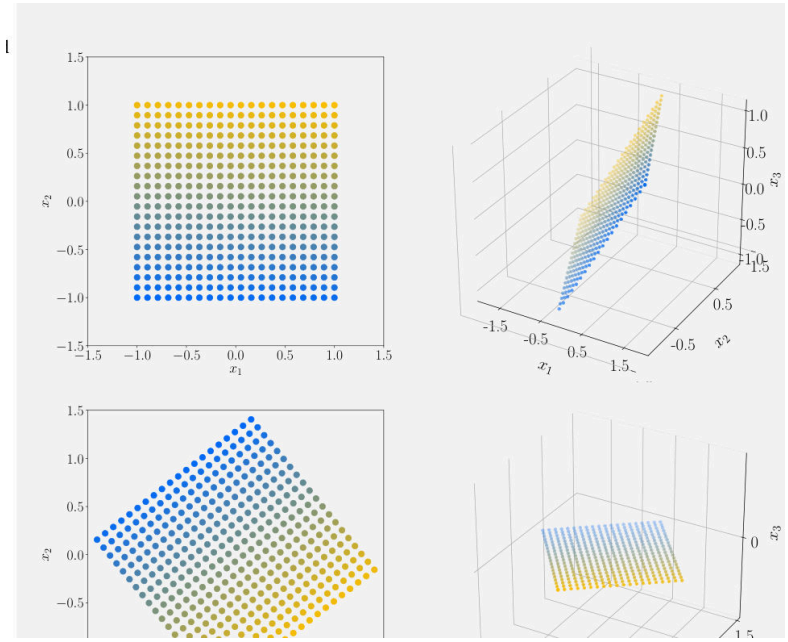


图 4.9: SVD 与向量映射（向量用圆盘表示）。各子图与图 4.8 采用相同的逆时针布局（对应原书 Figure 4.9）。

4.5.2　SVD 的构造

下面讨论 SVD 为何存在，并详细说明如何计算。一般矩阵的 SVD 与方阵的特征分解有相似之处。

注. 对比 SPD 矩阵的特征分解

$$S = S^\top = PDP^\top \tag{4.68}$$

与相应的 SVD

$$S = U\Sigma V^\top. \tag{4.69}$$

若令

$$U = P = V, \qquad D = \Sigma, \tag{4.70}$$

可见 SPD 矩阵的 SVD 就是其特征分解。

下面探讨定理 4.22 为何成立以及 SVD 如何构造。计算 $A \in \mathbb{R}^{m\times n}$ 的 SVD，等价于分别为陪域 $\mathbb{R}^m$ 和定义域 $\mathbb{R}^n$ 找两组标准正交基 $U = (u_1, \ldots, u_m)$ 和 $V = (v_1, \ldots, v_n)$，再由这些有序基构造矩阵 U、V。

我们的计划是：先构造右奇异向量的标准正交组 $v_1, \dots, v_n \in \mathbb{R}^n$；再构造左奇异向量的标准正交组 $u_1, \dots, u_m \in \mathbb{R}^m$；然后把二者联系起来，要求 v_i 的正交性在 A 变换下保持。这很重要，因为我们知道像 Av_i 构成一组正交向量，再用标量因子归一化这些像，该标量因子正是奇异值。

先构造右奇异向量。谱定理（定理 4.15）告诉我们，对称矩阵的特征向量构成 ONB，也意味着它可对角化。此外，由定理 4.14，对任意矩形矩阵 $A \in \mathbb{R}^{m\times n}$，总能构造对称半正定矩阵 $A^\top A \in \mathbb{R}^{n\times n}$。因此总可对角化 $A^\top A$，得

$$A^\top A = PDP^\top = P \begin{bmatrix} \lambda_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \lambda_n \end{bmatrix} P^\top, \tag{4.71}$$

其中 P 是由标准正交特征基构成的正交矩阵，$\lambda_i \geqslant 0$ 是 $A^\top A$ 的特征值。设 A 的 SVD 存在，把 (4.64) 代入 (4.71)：

$$A^\top A = (U\Sigma V^\top)^\top (U\Sigma V^\top) = V\Sigma^\top U^\top U\Sigma V^\top, \tag{4.72}$$

其中 U, V 为正交矩阵。由 $U^\top U = I$ 得

$$A^\top A = V\Sigma^\top \Sigma V^\top = V \begin{bmatrix} \sigma_1^2 & 0 & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & \sigma_n^2 \end{bmatrix} V^\top. \tag{4.73}$$

比较 (4.71) 与 (4.73)，得

$$V^\top = P^\top, \tag{4.74}$$

$$\sigma_i^2 = \lambda_i. \tag{4.75}$$

因此，构成 P 的 $A^\top A$ 的特征向量就是 A 的右奇异向量 V（见 (4.74)），$A^\top A$ 的特征值是 Σ 奇异值的平方（见 (4.75)）。 原书 p.124

为得到左奇异向量 U，采用类似步骤。先计算对称矩阵 $AA^\top \in \mathbb{R}^{m\times m}$（而非前面的 $A^\top A \in \mathbb{R}^{n\times n}$）的 SVD。$A$ 的 SVD 给出

$$AA^\top = (U\Sigma V^\top)(U\Sigma V^\top)^\top = U\Sigma V^\top V\Sigma^\top U^\top \tag{4.76a}$$

$$= U \begin{bmatrix} \sigma_1^2 & 0 & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & \sigma_m^2 \end{bmatrix} U^\top. \tag{4.76b}$$

谱定理告诉我们 $AA^\top = SDS^\top$ 可对角化，并可找到 $AA^\top$ 的一组特征向量 ONB，收集于 S 中。$AA^\top$ 的标准正交特征向量就是左奇异向量 U，在 SVD 的陪域中构成标准正交基。

剩下的问题是矩阵 Σ 的结构。由于 $AA^\top$ 与 $A^\top A$ 有相同的非零特征值（见原书 106 页），两种情形 SVD 中 Σ 的非零元素必相同。

最后一步把目前涉及的各部分联系起来。我们已有一组标准正交右奇异向量 V。为完成 SVD 构造，把它们与标准正交向量 U 连接。为此利用 v_i 在 A 下

的像也必正交这一事实，可用第 3.4 节结果证明。要求对 $i \neq j$，Av_i 与 Av_j 的内积为 0。对任意两个正交特征向量 v_i, v_j（$i \neq j$），有

$$(Av_i)^\top (Av_j) = v_i^\top (A^\top A) v_j = v_i^\top (\lambda_j v_j) = \lambda_j v_i^\top v_j = 0. \tag{4.77}$$

当 $m \geqslant r$ 时，$\{Av_1, \ldots, Av_r\}$ 是 $\mathbb{R}^m$ 的一个 r 维子空间的基。

为完成 SVD 构造，需要标准正交的左奇异向量：把右奇异向量的像 Av_i 归一化，得

$$u_i := \frac{Av_i}{\|Av_i\|} = \frac{1}{\sqrt{\lambda_i}} Av_i = \frac{1}{\sigma_i} Av_i, \tag{4.78}$$

最后一个等号由 (4.75) 和 (4.76b) 得到，它告诉我们 $AA^\top$ 的特征值满足 $\sigma_i^2 = \lambda_i$。

因此，$A^\top A$ 的特征向量（即右奇异向量 v_i）及其在 A 下的归一化像（左奇异向量 u_i）构成两组自洽的 ONB，并通过奇异值矩阵 Σ 相联系。把 (4.78) 整理得奇异值方程（singular value equation）

奇异值方程

$$Av_i = \sigma_i u_i, \qquad i = 1, \ldots, r. \tag{4.79}$$

该方程与特征值方程 (4.25) 非常相似，但左右两端的向量并不相同。

原书 p.125

当 $n < m$ 时，(4.79) 仅对 $i \leqslant n$ 成立，而 (4.79) 对 $i > n$ 的 u_i 未作规定；但由构造知它们标准正交。反之，当 $m < n$ 时，(4.79) 仅对 $i \leqslant m$ 成立；对 $i > m$ 有 $Av_i = 0$，而我们仍知道 v_i 构成标准正交组。这意味着 SVD 还提供了 A 的核（零空间）的一组标准正交基，即满足 $Ax = 0$ 的向量 x 之集合（见第 2.7.3 节）。

把 v_i 作为 V 的列、u_i 作为 U 的列拼接，得

$$AV = U\Sigma, \tag{4.80}$$

其中 Σ 与 A 同尺寸，且对前 r 行具有对角结构。右乘 $V^\top$ 得 $A = U\Sigma V^\top$，即 A 的 SVD。

例 4.13（计算 SVD）　求

$$A = \begin{bmatrix} 1 & 0 & 1 \\ -2 & 1 & 0 \end{bmatrix} \tag{4.81}$$

的奇异值分解。SVD 需要计算右奇异向量 v_j、奇异值 σ_k 和左奇异向量 u_i。

第 1 步：右奇异向量即 $A^\top A$ 的特征基。先算

$$A^\top A = \begin{bmatrix} 1 & -2 & 0 \\ 1 & 1 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & 1 \\ -2 & 1 & 0 \end{bmatrix} = \begin{bmatrix} 5 & -2 & 1 \\ -2 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix}. \tag{4.82}$$

通过 $A^\top A$ 的特征分解求奇异值和右奇异向量 v_j：

$$A^\top A = \begin{bmatrix} \frac{5}{\sqrt{30}} & 0 & -\frac{1}{\sqrt{6}} \\ -\frac{2}{\sqrt{30}} & \frac{1}{\sqrt{5}} & -\frac{2}{\sqrt{6}} \\ \frac{1}{\sqrt{30}} & \frac{2}{\sqrt{5}} & \frac{1}{\sqrt{6}} \end{bmatrix} \begin{bmatrix} 6 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} \frac{5}{\sqrt{30}} & -\frac{2}{\sqrt{30}} & \frac{1}{\sqrt{30}} \\ 0 & \frac{1}{\sqrt{5}} & \frac{2}{\sqrt{5}} \\ -\frac{1}{\sqrt{6}} & -\frac{2}{\sqrt{6}} & \frac{1}{\sqrt{6}} \end{bmatrix} = PDP^\top, \tag{4.83}$$

于是右奇异向量即 P 的各列：

$$V = P = \begin{bmatrix} \frac{5}{\sqrt{30}} & 0 & -\frac{1}{\sqrt{6}} \\ -\frac{2}{\sqrt{30}} & \frac{1}{\sqrt{5}} & -\frac{2}{\sqrt{6}} \\ \frac{1}{\sqrt{30}} & \frac{2}{\sqrt{5}} & \frac{1}{\sqrt{6}} \end{bmatrix}. \tag{4.84}$$

第 2 步：奇异值矩阵。由于奇异值 σ_i 是 $A^\top A$ 特征值的平方根，可直接由 D 得到。因 $\mathrm{rk}(A) = 2$，只有两个非零奇异值：$\sigma_1 = \sqrt{6}$、$\sigma_2 = 1$。奇异值矩阵须与 A 同尺寸，得 原书 p.126

$$\Sigma = \begin{bmatrix} \sqrt{6} & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}. \tag{4.85}$$

第 3 步：左奇异向量即右奇异向量像的归一化。把右奇异向量用 A 映射后除以相应奇异值进行归一化，得到左奇异向量：

$$u_1 = \frac{1}{\sigma_1} A v_1 = \frac{1}{\sqrt{6}} \begin{bmatrix} 1 & 0 & 1 \\ -2 & 1 & 0 \end{bmatrix} \begin{bmatrix} \frac{5}{\sqrt{30}} \\ -\frac{2}{\sqrt{30}} \\ \frac{1}{\sqrt{30}} \end{bmatrix} = \begin{bmatrix} \frac{1}{\sqrt{5}} \\ -\frac{2}{\sqrt{5}} \end{bmatrix}, \tag{4.86}$$

$$u_2 = \frac{1}{\sigma_2} A v_2 = \begin{bmatrix} 1 & 0 & 1 \\ -2 & 1 & 0 \end{bmatrix} \begin{bmatrix} 0 \\ \frac{1}{\sqrt{5}} \\ \frac{2}{\sqrt{5}} \end{bmatrix} = \begin{bmatrix} \frac{2}{\sqrt{5}} \\ \frac{1}{\sqrt{5}} \end{bmatrix}, \tag{4.87}$$

$$U = [u_1, u_2] = \frac{1}{\sqrt{5}} \begin{bmatrix} 1 & 2 \\ -2 & 1 \end{bmatrix}. \tag{4.88}$$

注意，在计算机上本例所示方法数值性质较差；实际计算 A 的 SVD 通常不通过 $A^\top A$ 的特征分解来做。

4.5.3　特征分解与奇异值分解对比

考察特征分解 $A = PDP^{-1}$ 与 SVD $A = U\Sigma V^\top$，回顾前几节的核心要点。

- SVD 对任意矩阵 $\mathbb{R}^{m\times n}$ 都存在；特征分解只对 $\mathbb{R}^{n\times n}$ 方阵定义，且仅当能找到 $\mathbb{R}^n$ 的一组特征向量基时才存在。
- 特征分解矩阵 P 中的向量不一定正交，即基变换不是简单的旋转加缩放；而 SVD 中 U, V 的向量标准正交，确实表示旋转。
- 特征分解与 SVD 都是三个线性映射的复合：
  1. 定义域中的基变换；
  2. 各新基向量独立缩放，并从定义域映射到陪域；
  3. 陪域中的基变换。
- 二者的一个关键区别是：SVD 中定义域与陪域可以是不同维数的向量空间。

- SVD 中左、右奇异向量矩阵 U, V 一般互不相逆（它们在不同向量空间中做基变换）；而特征分解中基变换矩阵 P 与 P^{-1} 互逆。
- SVD 中对角矩阵 Σ 的元素全为非负实数，特征分解中的对角矩阵一般并不如此。
- SVD 与特征分解通过它们的投影密切相关：
  - A 的左奇异向量是 $AA^\top$ 的特征向量；
  - A 的右奇异向量是 $A^\top A$ 的特征向量；
  - A 的非零奇异值是 $AA^\top$ 与 $A^\top A$ 二者非零特征值的平方根。
- 对对称矩阵 $A \in \mathbb{R}^{n\times n}$，特征分解与 SVD 完全相同，这由谱定理 4.15 推出。

例 4.14（在电影评分与观众中寻找结构）　通过分析人和他们偏好电影的数据，给 SVD 一个实际解释。考虑三位观众（Ali、Beatrix、Chandra）对四部电影（Star Wars、Blade Runner、Amelie、Delicatessen）的评分。评分在 0（最差）到 5（最佳）之间，编码为数据矩阵 $A \in \mathbb{R}^{4\times 3}$，如图 4.10 所示。每行表示一部电影，每列表示一位用户，于是各观众的评分列向量为 $x_{\text{Ali}}, x_{\text{Beatrix}}, x_{\text{Chandra}}$。 原书 p.127

$$\begin{bmatrix} 5 & 4 & 1 \\ 5 & 5 & 0 \\ 0 & 0 & 5 \\ 1 & 0 & 4 \end{bmatrix} \begin{matrix} \text{Star Wars} \\ \text{Blade Runner} \\ \text{Amelie} \\ \text{Delicatessen} \end{matrix} = U\,\Sigma\,V^\top$$

$$U = \begin{bmatrix} -0.6710 & 0.0236 & 0.4647 & -0.5774 \\ -0.7197 & 0.2054 & -0.4759 & 0.4619 \\ -0.0939 & -0.7705 & -0.5268 & -0.3464 \\ -0.1515 & -0.6030 & 0.5293 & -0.5774 \end{bmatrix}$$

$$\Sigma = \begin{bmatrix} 9.6438 & 0 & 0 \\ 0 & 6.3639 & 0 \\ 0 & 0 & 0.7056 \\ 0 & 0 & 0 \end{bmatrix} \qquad V^\top = \begin{bmatrix} -0.7367 & -0.6515 & -0.1811 \\ 0.1762 & -0.9807 & 0.6708 \\ -0.7379 & -0.0743 & 0.0852 \end{bmatrix}$$

图 4.10: 三人对四部电影的评分及其 SVD 分解（对应原书 Figure 4.10）。行：电影；列：Ali、Beatrix、Chandra。

用 SVD 分解 A，提供了一种捕捉人们如何给电影评分之间关系的方式，尤其是是否存在把“哪些人喜欢哪些电影”联系起来的结构。对数据矩阵 A 应用 SVD 隐含了若干假设： 原书 p.128

1. 所有观众都用同一线性映射一致地评分；

2. 评分中没有误差或噪声；

3. 把左奇异向量 u_i 解释为“典型电影”，右奇异向量 v_j 解释为“典型观众”。

于是假设：任意观众的具体电影偏好可表示为 v_j 的线性组合；类似地，任意电影的受欢迎程度可表示为 u_i 的线性组合。因此，SVD 定义域中的一个向量可解释为“典型观众空间”中的一个观众，SVD 陪域中的向量相应地对应“典型电影空间”中的一部电影。

考察电影-用户矩阵的 SVD：第一个左奇异向量 u_1 对两部科幻电影有很大绝对值，且第一个奇异值很大（图 4.10 红色）。于是它把一类用户与一组特定电影（科幻主题）归为一类。类似地，第一个右奇异向量 v_1 对 Ali、Beatrix 有很大绝对值，他们都给科幻电影高分（绿色）。这表明 v_1 反映了“科幻爱好者”这一概念。类似地，u_2 似乎捕捉了法国艺术电影主题，v_2 表明 Chandra 接近这类电影的理想化爱好者。一个理想化的科幻爱好者是纯粹主义者，只爱科幻电影，因此 v_1 对非科幻主题电影给零分——这一逻辑由奇异值矩阵 Σ 的对角子结构所隐含。因此一部具体电影由它如何（线性）分解为各典型电影来表示；同样，一个人由他如何（通过线性组合）分解为各电影主题来表示。

值得简要讨论 SVD 的术语与约定，因为文献中存在不同版本。这些差异虽可能令人困惑，但数学本身对它们不变。为记号和抽象上的方便，我们采用这样的 SVD 记号：SVD 有两个方阵（左、右奇异向量矩阵），但奇异值矩阵非方阵。我们的 SVD 定义 (4.64) 有时称为完全 SVD（full SVD）。

完全SVD

有些作者对 SVD 的定义略有不同，聚焦于方形奇异矩阵。则对 $A \in \mathbb{R}^{m\times n}$、$m \geqslant n$：

$$\underset{m\times n}{A} = \underset{m\times n}{U}\ \underset{n\times n}{\Sigma}\ \underset{n\times n}{V^{\top}}. \tag{4.89}$$

这种形式有时称为精简 SVD（reduced SVD，如 Datta (2010)）或就称 SVD（如 Press et al. (2007)）。这种替代形式只改变矩阵的构造方式，不改变 SVD 的数学结构。其方便之处在于 Σ 是对角的，如同特征分解那样。

精简SVD

在第 4.6 节，我们将学习用 SVD 做矩阵逼近的技术，也称为截断 SVD（truncated SVD）。对秩 r 矩阵 A，可定义其 SVD 使 U 为 $m \times r$ 矩阵、Σ 为 $r \times r$ 对角矩阵、V 为 $r \times n$ 矩阵。这与我们的定义非常相似，并保证对角矩阵 Σ 的对角线上只有非零元素。这种替代记号的主要方便之处仍在于 Σ 是对角的，如同特征分解。

截断SVD

认为 A 的 SVD 只适用于 $m > n$ 的 $m \times n$ 矩阵，实际上并无必要。当 $m < n$ 时，SVD 分解给出的 Σ 零列多于零行，因而奇异值 $\sigma_{m+1}, \ldots, \sigma_n$ 为 0。

SVD 在机器学习中应用广泛，从曲线拟合中的最小二乘问题到求解线性方程组。这些应用利用 SVD 的各种重要性质：它与矩阵秩的关系，以及用低秩矩阵逼近给定秩矩阵的能力。用 SVD 替换矩阵往往使计算对数值舍入误差更稳健。正如下一节将探讨的，SVD 以有原则的方式用“更简单”矩阵逼近矩阵的能力，开启了从降维、主题建模到数据压缩、聚类等一系列机器学习应用。

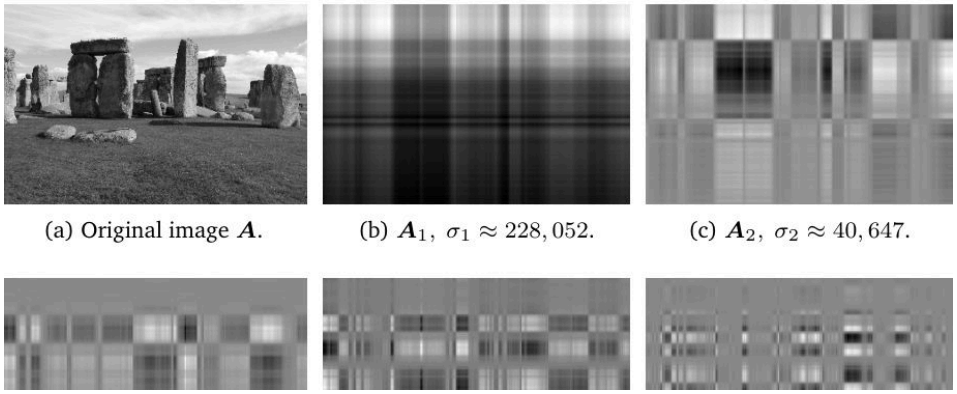
4.6　矩阵逼近

我们把 SVD 看作把 $A = U\Sigma V^\top \in \mathbb{R}^{m\times n}$ 分解为三个矩阵之积，其中 $U \in \mathbb{R}^{m\times m}$、$V \in \mathbb{R}^{n\times n}$ 正交，Σ 在主对角线上含奇异值。现在不做完整 SVD，而研究 SVD 如何把矩阵 A 表示为更简单（低秩）矩阵 A_i 之和，这给出一种比完整 SVD 计算代价更低的矩阵逼近方案。

我们构造秩 1 矩阵 $A_i \in \mathbb{R}^{m\times n}$：

$$A_i := u_i v_i^\top, \tag{4.90}$$

它由 U、V 的第 i 个正交列向量做外积得到。图 4.11 展示了巨石阵（Stonehenge）的一幅图像（可表示为矩阵 $A \in \mathbb{R}^{1432\times 1910}$）以及若干由 (4.90) 定义的外积 A_i。 原书 p.130



(a) Original image $\boldsymbol{A}$.　(b) $\boldsymbol{A}_1$, $\sigma_1 \approx 228,052$.　(c) $\boldsymbol{A}_2$, $\sigma_2 \approx 40,647$.

图 4.11: 用 SVD 做图像处理。(a) 原始灰度图像是 1432×1910 的矩阵，取值在 0（黑）到 1（白）之间。(b)–(f) 秩 1 矩阵 $A_1, \ldots, A_5$ 及相应奇异值 $\sigma_1, \ldots, \sigma_5$。每个秩 1 矩阵的网格状结构由左、右奇异向量的外积所决定（对应原书 Figure 4.11）。

秩 r 矩阵 $A \in \mathbb{R}^{m\times n}$ 可写成秩 1 矩阵 A_i 之和：

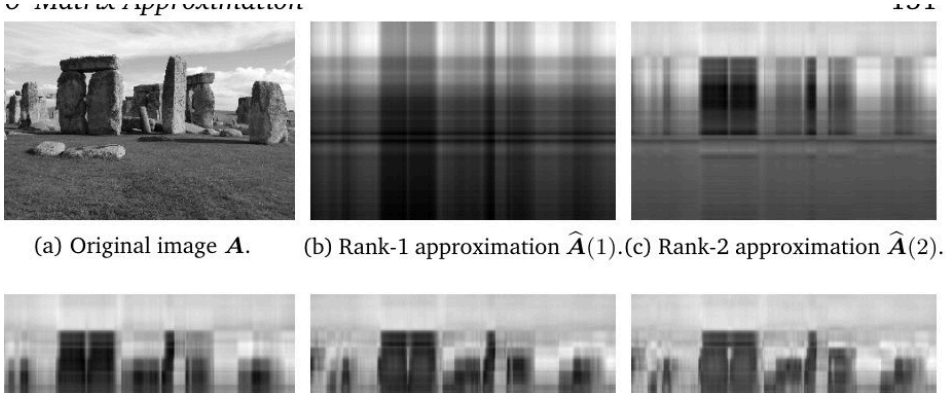
$$A = \sum_{i=1}^{r} \sigma_i u_i v_i^\top = \sum_{i=1}^{r} \sigma_i A_i, \tag{4.91}$$

其中外积矩阵 A_i 由第 i 个奇异值 σ_i 加权。(4.91) 成立的原因是：奇异值矩阵 Σ 的对角结构只把配对的左、右奇异向量 $u_i v_i^\top$ 相乘，并按相应奇异值 σ_i 缩放；由于 Σ 是对角矩阵，所有 $i \neq j$ 的项 $\Sigma_{ij} u_i v_j^\top$ 都为零；任何 $i > r$ 的项也为零，因为相应奇异值为 0。

在 (4.90) 中我们引入了秩 1 矩阵 A_i。把 r 个秩 1 矩阵相加得到秩 r 矩阵 A，见 (4.91)。若求和不遍历全部 A_i（$i = 1, \ldots, r$），而只到中间某个 $k < r$，便得到秩 k 逼近 秩- k逼近

$$\widehat{A}(k) := \sum_{i=1}^{k} \sigma_i u_i v_i^\top = \sum_{i=1}^{k} \sigma_i A_i \tag{4.92}$$

它是 A 的逼近，且 $\mathrm{rk}(\widehat{A}(k)) = k$。图 4.12 给出巨石阵原始图像 A 的低秩逼近 $\widehat{A}(k)$。岩石的形状在秩 5 逼近中越来越清晰可辨。原始图像需要 $1432 \cdot 1910 = 2\,735\,120$



(a) Original image $\boldsymbol{A}$.　(b) Rank-1 approximation $\widehat{\boldsymbol{A}}(1)$.　(c) Rank-2 approximation $\widehat{\boldsymbol{A}}(2)$.

图 4.12: 用 SVD 做图像重建。(a) 原始图像。(b)–(f) 用 SVD 的低秩逼近重建图像，其中秩 k 逼近为 $\widehat{A}(k)=\sum_{i=1}^{k}\sigma_i A_i$（对应原书 Figure 4.12）。

个数，而秩 5 逼近只需存储五个奇异值和五对左、右奇异向量（各为 1432 维和 1910 维），共 $5\cdot(1432+1910+1)=16\,715$ 个数——仅略多于原始数据的 0.6%。

原书 p.131

为度量 A 与其秩 k 逼近 $\widehat{A}(k)$ 之间的差异（误差），需要范数的概念。第 3.1 节中我们已用向量范数度量向量长度，类比地也可定义矩阵范数。

定义 4.10 (4.23（矩阵的谱范数）)**.** 对 $x\in\mathbb{R}^n\setminus\{0\}$，矩阵 $A\in\mathbb{R}^{m\times n}$ 的谱范数（spectral norm）定义为

谱范数

$$\|A\|_2:=\max_{x}\frac{\|Ax\|_2}{\|x\|_2}. \tag{4.93}$$

我们在矩阵范数中引入下标记号（左端），类似向量的欧氏范数（右端，下标为 2）。谱范数 (4.93) 决定任意向量 x 被 A 乘后最长能变成多长。

定理 4.14 (4.24)**.** A 的谱范数就是其最大奇异值 σ_1。

此定理的证明留作习题。

定理 4.15 (4.25（Eckart-Young 定理）（Eckart and Young, 1936）)**.** 设 $A\in\mathbb{R}^{m\times n}$ 秩为 r，$B\in\mathbb{R}^{m\times n}$ 秩为 k。对任意 $k\leqslant r$，记 $\widehat{A}(k)=\sum_{i=1}^{k}\sigma_i u_i v_i^{\top}$，则

$$\widehat{A}(k)=\operatorname*{arg\,min}_{\mathrm{rk}(B)=k}\|A-B\|_2, \tag{4.94}$$

$$\|A-\widehat{A}(k)\|_2=\sigma_{k+1}. \tag{4.95}$$

Eckart-Young 定理明确给出用秩 k 逼近 A 引入了多大误差。可把 SVD 得到的秩 k 逼近解释为把满秩矩阵 A 投影到秩至多 k 的矩阵所构成的低维空间。在所有可能的投影中，SVD 使 A 与任意秩 k 逼近之间的误差（在谱范数意义下）最小。

原书 p.132

我们可回溯若干步骤来理解 (4.95) 为何成立。注意 $A-\widehat{A}(k)$ 是一个由剩余秩 1 矩阵之和构成的矩阵：

$$A-\widehat{A}(k)=\sum_{i=k+1}^{r}\sigma_i u_i v_i^{\top}. \tag{4.96}$$

由定理 4.24，立即得到该差矩阵的谱范数为 σ_{k+1}。再细看 (4.94)：假设存在另一矩阵 B，$\mathrm{rk}(B) \leqslant k$，使

$$\|A - B\|_2 < \|A - \widehat{A}(k)\|_2, \tag{4.97}$$

则存在至少 $(n-k)$ 维的零空间 $Z \subseteq \mathbb{R}^n$，使 $x \in Z$ 蕴含 $Bx = 0$。于是

$$\|Ax\|_2 = \|(A - B)x\|_2, \tag{4.98}$$

并用推广到矩阵范数的 Cauchy-Schwartz 不等式 (3.17)，得

$$\|Ax\|_2 \leqslant \|A - B\|_2 \|x\|_2 < \sigma_{k+1}\|x\|_2. \tag{4.99}$$

然而，存在一个 $(k+1)$ 维子空间，其中 $\|Ax\|_2 \geqslant \sigma_{k+1}\|x\|_2$，它由 A 的右奇异向量 v_j（$j \leqslant k+1$）张成。这两个空间维数之和大于 n，因为两个空间中必有一个非零向量，这与第 2.7.3 节的秩-零化度定理（定理 2.24）矛盾。

Eckart-Young 定理意味着：可以用 SVD 以有原则、最优（在谱范数意义下）的方式，把秩 r 矩阵 A 约化为秩 k 矩阵 $\widehat{A}$。可把用秩 k 矩阵逼近 A 理解为一种有损压缩。因此，矩阵的低秩逼近出现在许多机器学习应用中，例如图像处理、噪声过滤和不适定问题的正则化。此外，它在降维和主成分分析中起关键作用，如第 10 章所见。

例 4.15（在电影评分与观众中寻找结构（续））　回到电影评分例子，现在应用低秩逼近概念来逼近原始数据矩阵。回顾第一个奇异值捕捉了电影中的科幻主题和科幻爱好者概念。于是，在电影评分矩阵的秩 1 分解中只使用第一个奇异值项，得到预测评分

$$A_1 = u_1 v_1^\top = \begin{bmatrix} -0.6710 \\ -0.7197 \\ -0.0939 \\ -0.1515 \end{bmatrix} \begin{bmatrix} -0.7367 & -0.6515 & -0.1811 \end{bmatrix} \tag{4.100a}$$

原书 p.133

$$= \begin{bmatrix} 0.4943 & 0.4372 & 0.1215 \\ 0.5302 & 0.4689 & 0.1303 \\ 0.0692 & 0.0612 & 0.0170 \\ 0.1116 & 0.0987 & 0.0274 \end{bmatrix}. \tag{4.100b}$$

第一个秩 1 逼近 A_1 很有启发性：它告诉我们 Ali 和 Beatrix 喜欢科幻电影（如 Star Wars、Blade Runner），对应条目值 > 0.4，但未能捕捉 Chandra 对其他电影的评分。这并不奇怪，因为 Chandra 喜欢的电影类型未被第一个奇异值捕捉。第二个奇异值给这类电影爱好者一个更好的秩 1 逼近：

$$A_2 = u_2 v_2^\top = \begin{bmatrix} 0.0236 \\ 0.2054 \\ -0.7705 \\ -0.6030 \end{bmatrix} \begin{bmatrix} 0.0852 & 0.1762 & -0.9807 \end{bmatrix} \tag{4.101a}$$

$$= \begin{bmatrix} 0.0020 & 0.0042 & -0.0231 \\ 0.0175 & 0.0362 & -0.2014 \\ -0.0656 & -0.1358 & 0.7556 \\ -0.0514 & -0.1063 & 0.5914 \end{bmatrix}. \tag{4.101b}$$

在第二个秩 1 逼近 A_2 中，我们较好地捕捉了 Chandra 的评分和电影类型，但没捕捉科幻电影。这促使我们考虑秩 2 逼近 $\widehat{A}(2)$，即把前两个秩 1 逼近相加：

$$\widehat{A}(2) = \sigma_1 A_1 + \sigma_2 A_2 = \begin{bmatrix} 4.7801 & 4.2419 & 1.0244 \\ 5.2252 & 4.7522 & -0.0250 \\ 0.2493 & -0.2743 & 4.9724 \\ 0.7495 & 0.2756 & 4.0278 \end{bmatrix}. \tag{4.102}$$

$\widehat{A}(2)$ 与原始电影评分表

$$A = \begin{bmatrix} 5 & 4 & 1 \\ 5 & 5 & 0 \\ 0 & 0 & 5 \\ 1 & 0 & 4 \end{bmatrix} \tag{4.103}$$

相近，这表明可以忽略 A_3 的贡献。可解释为：数据表中没有第三类电影主题/爱好者类别的证据。这也意味着本例中电影主题/爱好者的整个空间是一个二维空间，由科幻电影和法国艺术电影及其爱好者张成。

4.7　矩阵谱系

“phylogenetic”一词描述我们如何捕捉个体或群体之间的关系，源自希腊语中表示“部落”和“来源”的词。第 2、3 章涵盖了线性代数与解析几何的基础。本章考察了矩阵和线性映射的基本特征。图 4.13 描绘了不同类型矩阵之间关系的谱系树（黑箭头表示“是……的子集”），以及我们可对它们执行的操作（蓝色）。我们考虑所有实矩阵 $A \in \mathbb{R}^{n\times m}$。对非方阵（$n \neq m$），如本章所见，SVD 总存在。聚焦方阵 $A \in \mathbb{R}^{n\times n}$，行列式告诉我们方阵是否有逆矩阵，即它是否属于正则、可逆矩阵类。若 $n \times n$ 方阵有 n 个线性无关特征向量，则矩阵非亏损且存在特征分解（定理 4.12）。我们知道重特征值可能导致亏损矩阵，而亏损矩阵不能对角化。

原书 p.134

非奇异与非亏损并不相同。例如，旋转矩阵可逆（行列式非零），但在实数范围内不可对角化（特征值不保证是实数）。

原书 p.135

我们进一步深入非亏损 $n \times n$ 方阵这一分支。若条件 $A^\top A = AA^\top$ 成立，则 A 正规（normal）。若更严格的条件 $A^\top A = AA^\top = I$ 成立，则 A 称为正交（orthogonal，见定义 3.8）。正交矩阵集合是正则（可逆）矩阵的子集，并满足 $A^\top = A^{-1}$。

正规矩阵有一个常见子集，即对称矩阵 $S \in \mathbb{R}^{n\times n}$，满足 $S = S^\top$。对称矩阵只有实特征值。对称矩阵的一个子集是正定矩阵 P，它对所有 $x \in \mathbb{R}^n \setminus \{0\}$

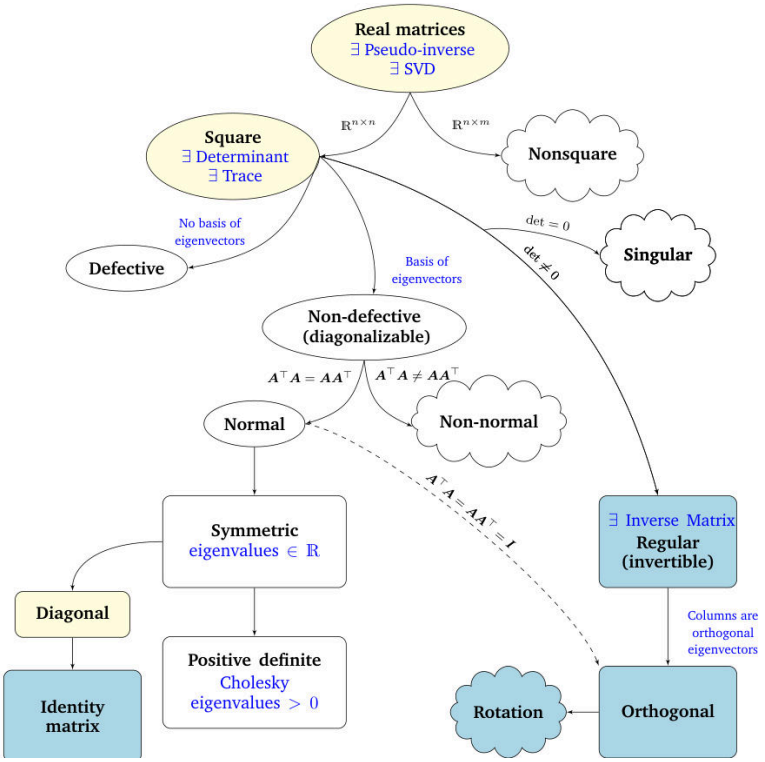


图 4.13: 机器学习中常见矩阵的功能谱系（对应原书 Figure 4.13）。

满足 $x^\top Px > 0$。此时存在唯一的 Cholesky 分解（定理 4.18）。正定矩阵只有正特征值，且总是可逆（即行列式非零）。

对称矩阵的另一个子集是对角矩阵 D。对角矩阵对乘法和加法封闭，但不一定构成群（只有当所有对角线元素非零、矩阵可逆时才构成群）。一个特殊的对角矩阵是单位矩阵 I。

4.8　延伸阅读

本章大部分内容奠定了底层数学，并把它们与研究映射的方法联系起来，其中许多方法位于机器学习的核心，是几乎所有机器学习理论的底层软件方案与构件。用行列式、特征谱和特征子空间来刻画矩阵，为矩阵的分类与分析提供了基本特征和条件。这扩展到数据的所有表示形式和涉及数据的映射，以及判断对此类矩阵做计算时的数值稳定性（Press et al., 2007）。

行列式是求逆矩阵和“手算”特征值的基本工具。然而，除最小规模情形外，用高斯消元做数值计算都优于行列式（Press et al., 2007）。尽管如此，行列式仍是强有力的理论概念，例如可根据行列式符号获得基定向的直觉。特征向量可用于做基变换，把数据变换到有意义的正交特征向量坐标中。类似地，Cholesky 分解等矩阵分解方法在计算或模拟随机事件时频繁出现（Rubinstein and Kroese, 2016）。因此 Cholesky 分解使我们能计算重参数化技巧，以便对随机变量做连续微分，例如在变分自编码器中（Jimenez Rezende et al., 2014; Kingma and Welling, 2014）。

特征分解是提取刻画线性映射之有意义、可解释信息的基础。因此，特征分解支撑了一类称为谱方法（spectral methods）的通用机器学习算法，这类方法对正定核做特征分解。这些谱分解方法涵盖经典的统计数据分析方法，例如：

- 主成分分析（principal component analysis, PCA，Pearson, 1901，另见第 10 章）：寻找一个能解释数据中大部分方差的低维子空间。
- Fisher 判别分析（Fisher discriminant analysis）：为数据分类确定一个分离超平面（Mika et al., 1999）。
- 多维缩放（multidimensional scaling, MDS）（Carroll and Chang, 1970）。

这些方法的计算效率通常来自求对称半正定矩阵的最佳秩 k 逼近。更多当代谱方法起源不同，但都要求计算正定核的特征向量与特征值，例如 Isomap（Tenenbaum et al., 2000）、Laplacian 特征映射（Belkin and Niyogi, 2003）、Hessian 特征映射（Donoho and Grimes, 2003）和谱聚类（Shi and Malik, 2000）。这些方法的核心计算一般以低秩矩阵逼近技术为基础（Belabbas and Wolfe, 2009），即我们这里通过 SVD 遇到的技术。

SVD 使我们能发现与特征分解同类的信息。但 SVD 更普遍地适用于非方阵和数据表。每当我们想识别数据中的异质性、想通过逼近做数据压缩（例如不存储 $n \times m$ 个值，而只存储 $(n+m)k$ 个值），或想做数据预处理（例如把设计矩阵的预测变量去相关，Ormoneit et al., 2001）时，这些矩阵分解方法就派上用场。SVD 作用于矩阵，我们可把矩阵解释为带两个下标（行、列）的矩形数组。把类似矩阵的结构推广到更高维数组，就得到张量。事实上，SVD 是作用于此类张量的更一般分解族的特例（Kolda and Bader, 2009）。对张量做的类 SVD 运算和低秩逼近，例如 Tucker 分解（Tucker, 1966）或 CP 分解（Carroll and Chang, 1970）。

SVD 低秩逼近因计算效率而在机器学习中频繁使用，因为它减少了我们需要对可能非常大的数据矩阵执行的存储量和非零乘法运算量（Trefethen and Bau III, 1997）。此外，低秩逼近还用于处理可能含缺失值的矩阵，以及用于有损压缩和降维（Moonen and De Moor, 1995; Markovsky, 2011）。

习题

原书 p.137

1. 用 Laplace 展开（第一行）和 Sarrus 法则计算

$$A = \begin{bmatrix} 1 & 3 & 5 \\ 2 & 4 & 6 \\ 0 & 2 & 4 \end{bmatrix}$$

的行列式。

2. 高效计算下列行列式：

$$\begin{bmatrix} 2 & 0 & 1 & 2 & 0 \\ 2 & -1 & 0 & 1 & 1 \\ 0 & 1 & 2 & 1 & 2 \\ -2 & 0 & 2 & -1 & 2 \\ 2 & 0 & 0 & 1 & 1 \end{bmatrix}.$$

3. 计算下列矩阵的特征子空间：

   a) $A := \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}$

   b) $B := \begin{bmatrix} -2 & 2 \\ 2 & 1 \end{bmatrix}$

4. 计算下列矩阵的全部特征子空间：

$$A = \begin{bmatrix} 0 & -1 & 1 & 1 \\ -1 & 1 & -2 & 3 \\ 2 & -1 & 0 & 0 \\ 1 & -1 & 1 & 0 \end{bmatrix}.$$

5. 矩阵是否可对角化与其是否可逆无关。判断下列四个矩阵是否可对角化和/或可逆：

$$\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \quad \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}, \quad \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}, \quad \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}.$$

6. 计算下列变换矩阵的特征子空间。它们可对角化吗?

   a) 对

$$A = \begin{bmatrix} 2 & 3 & 0 \\ 1 & 4 & 3 \\ 0 & 0 & 1 \end{bmatrix}$$

   b) 对

$$A = \begin{bmatrix} 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

7. 下列矩阵可对角化吗? 若可，给出其对角形，以及使变换矩阵对角化的基。若不可，说明原因。

   a) $A = \begin{bmatrix} 0 & 1 \\ -8 & 4 \end{bmatrix}$

原书 p.138

b) $A = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$

c) $A = \begin{bmatrix} 5 & 4 & 2 & 1 \\ 0 & 1 & -1 & -1 \\ -1 & -1 & 3 & 0 \\ 1 & 1 & -1 & 2 \end{bmatrix}$

d) $A = \begin{bmatrix} 5 & -6 & -6 \\ -1 & 4 & 2 \\ 3 & -6 & -4 \end{bmatrix}$

8. 求矩阵

$$A = \begin{bmatrix} 3 & 2 & 2 \\ 2 & 3 & -2 \end{bmatrix}$$

的 SVD。

9. 求

$$A = \begin{bmatrix} 2 & 2 \\ -1 & 1 \end{bmatrix}$$

的奇异值分解。

10. 求

$$A = \begin{bmatrix} 3 & 2 & 2 \\ 2 & 3 & -2 \end{bmatrix}$$

的秩 1 逼近。

11. 证明对任意 $A \in \mathbb{R}^{m \times n}$，矩阵 $A^\top A$ 与 $AA^\top$ 有相同的非零特征值。

12. 证明对 $x \neq 0$ 定理 4.24 成立，即证明

$$\max_x \frac{\|Ax\|_2}{\|x\|_2} = \sigma_1,$$

其中 σ_1 是 $A \in \mathbb{R}^{m \times n}$ 的最大奇异值。

第 5 章　向量微积分

原书 p.139

机器学习中许多算法都要关于一组待求的模型参数来优化一个目标函数，这些参数控制着模型对数据的解释程度：求得好的参数可以表述为一个优化问题（见第 8.2 和 8.3 节）。例子包括：(i) 线性回归（见第 9 章），我们研究曲线拟合问题，并优化线性权重参数以最大化似然；(ii) 用于降维和数据压缩的神经网络自编码器，其中参数是每一层的权重和偏置，我们通过反复应用链式法则来最小化重构误差；以及 (iii) 用于建模数据分布的高斯混合模型（见第 11 章），我们优化每个混合成分的位置与形状参数以最大化模型的似然。图 5.1 展示了其中一些问题，我们通常利用梯度信息、借助优化算法来求解它们（第 7.1 节）。图 5.2 概述了本章各概念之间的关系，以及它们如何与本书其他章节相联系。

本章的核心是函数这一概念。函数 f 是把两个量相互联系起来的一个量。在本书中，这些量通常是输入 $x \in \mathbb{R}^D$ 和目标（函数值）$f(x)$，除非另有说明，我们假定它们取实数值。这里 $\mathbb{R}^D$ 是 f 的定义域，函数值 $f(x)$ 则是 f 的像域/陪域。

定义域

像域/ 陪域

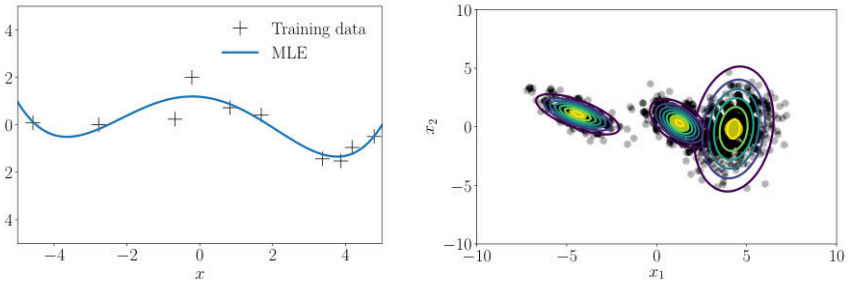


图 5.1: 向量微积分在 (a) 回归（曲线拟合）和 (b) 密度估计（即建模数据分布）中都起着核心作用（对应原图 Figure 5.1）。

原书 p.140

第 2.7.3 节在线性函数的语境下对此做了详细得多的讨论。我们常写成

$$f : \mathbb{R}^D \to \mathbb{R} \tag{5.1a}$$

$$x \mapsto f(x) \tag{5.1b}$$

来指定一个函数，其中 (5.1a) 指明 f 是从 $\mathbb{R}^D$ 到 $\mathbb{R}$ 的映射，(5.1b) 则指明把一个输入 x 显式指派为函数值 $f(x)$。函数 f 为每个输入 x 恰好指派一个函数值 $f(x)$。

例 5.1 (点积)**.** 回忆点积是内积的一个特例（第 3.2 节）。用上述记号，函数 $f(x) =$

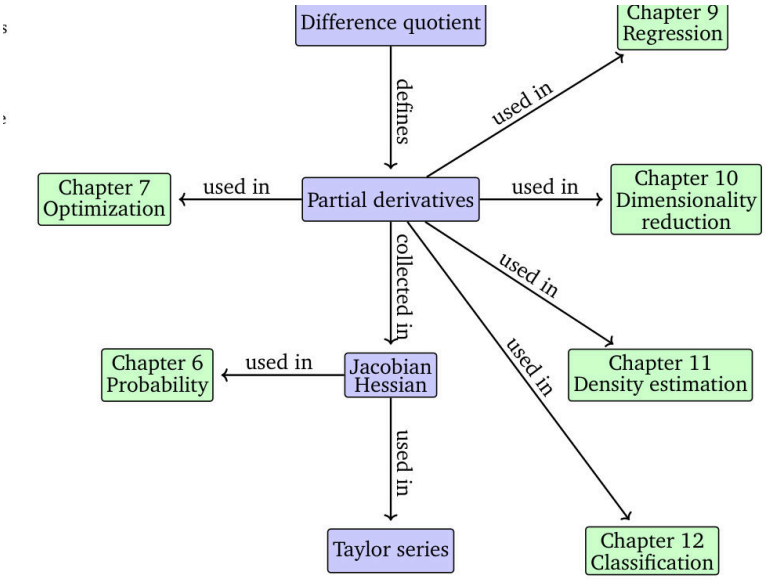


图 5.2: 本章所引入概念的思维导图, 以及它们在本书其他部分被使用的时机（对应原图 Figure 5.2）。

$x^\top x$、$x \in \mathbb{R}^2$ 应写为

$$f : \mathbb{R}^2 \to \mathbb{R} \tag{5.2a}$$

$$x \mapsto x_1^2 + x_2^2 \,. \tag{5.2b}$$

本章将讨论如何计算函数的梯度，这往往是在机器学习模型中促成学习的关键，因为梯度指向最陡上升的方向。因此，向量微积分是我们在机器学习中所需的基本数学工具之一。贯穿全书，我们都假定函数是可微的。借助一些本书不涉及的额外技术性定义，这里介绍的许多方法可以推广到次微分（即在某些点连续但不可微的函数）。我们将在第 7 章考察带约束情形的推广。

5.1　一元函数的微分

下面，我们简要回顾一元函数的微分，这在中学数学中或许已为读者所熟悉。我们从一元函数 $y = f(x)$（$x, y \in \mathbb{R}$）的差商开始，随后用它来定义导数。

定义 5.1 (差商)**. 差商**（difference quotient）　差商

$$\frac{\delta y}{\delta x} := \frac{f(x + \delta x) - f(x)}{\delta x} \tag{5.3}$$

计算 f 图像上两点之间割线的斜率。在图 5.3 中，这两个点的横坐标分别为 x_0 和 $x_0 + \delta x$。若假定 f 是线性函数，差商也可看作 f 在 x 与 $x + \delta x$ 之间的平均斜率。当 $\delta x \to 0$ 取极限时，若 f 可微，我们就得到 f 在 x 处的切线。该切线即为 f 在 x 处的导数。

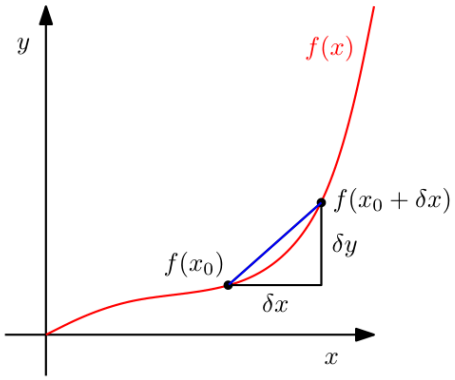


图 5.3: 函数 f 在 x_0 与 $x_0+\delta x$ 之间的平均倾角，就是过 $f(x_0)$ 与 $f(x_0+\delta x)$ 的割线（蓝色）的倾角，由 $\delta y/\delta x$ 给出（对应原图 Figure 5.3）。

定义 5.2 (导数)**.** 更严格地，对 $h>0$，f 在 x 处的**导数**（derivative）定义为极限 导数

$$\frac{\mathrm{d}f}{\mathrm{d}x} := \lim_{h\to 0}\frac{f(x+h)-f(x)}{h}\,, \tag{5.4}$$

此时图 5.3 中的割线变成了切线。f 的导数指向 f 的最陡上升方向。

原书 p.142

例 5.2 (多项式的导数)**.** 我们想计算 $f(x)=x^n$（$n\in\mathbb{N}$）的导数。我们或许已经知道答案是 nx^{n-1}，但我们想用导数定义——即差商的极限——来推出这一结果。利用 (5.4) 中的导数定义，得到

$$\frac{\mathrm{d}f}{\mathrm{d}x} = \lim_{h\to 0}\frac{f(x+h)-f(x)}{h} \tag{5.5a}$$

$$= \lim_{h\to 0}\frac{(x+h)^n - x^n}{h} \tag{5.5b}$$

$$= \lim_{h\to 0}\frac{\sum_{i=0}^{n}\binom{n}{i}x^{n-i}h^i - x^n}{h}\,. \tag{5.5c}$$

我们看到 $x^n=\binom{n}{0}x^{n-0}h^0$。从 1 开始求和，$x^n$ 项抵消，于是得到

$$\frac{\mathrm{d}f}{\mathrm{d}x} = \lim_{h\to 0}\frac{\sum_{i=1}^{n}\binom{n}{i}x^{n-i}h^i}{h} \tag{5.6a}$$

$$= \lim_{h\to 0}\sum_{i=1}^{n}\binom{n}{i}x^{n-i}h^{i-1} \tag{5.6b}$$

$$= \lim_{h\to 0}\underbrace{\binom{n}{1}x^{n-1} + \sum_{i=2}^{n}\binom{n}{i}x^{n-i}h^{i-1}}_{\to 0 \text{ 当 } h\to 0} \tag{5.6c}$$

$$= \frac{n!}{1!(n-1)!}x^{n-1} = nx^{n-1}\,. \tag{5.6d}$$

5.1.1　Taylor 级数

Taylor 级数是把函数 f 表示为无穷多项之和的一种形式。这些项由 f 在 x_0 处取值的导数决定。

定义 5.3 (Taylor 多项式)**.** $f : \mathbb{R} \to \mathbb{R}$ 在 x_0 处的 n 次 **Taylor 多项式**（Taylor polynomial）定义为

Taylor 多项式

$$T_n(x) := \sum_{k=0}^{n} \frac{f^{(k)}(x_0)}{k!}(x - x_0)^k \,, \tag{5.7}$$

其中 $f^{(k)}(x_0)$ 是 f 在 x_0 处的 k 阶导数（我们假定它存在），而 $\frac{f^{(k)}(x_0)}{k!}$ 是该多项式的系数。

原书 p.143

定义 5.4 (Taylor 级数)**.** 对光滑函数 $f \in C^\infty$、$f : \mathbb{R} \to \mathbb{R}$，$f$ 在 x_0 处的 **Taylor 级数**（Taylor series）定义为

Taylor 级数

$$T_\infty(x) = \sum_{k=0}^{\infty} \frac{f^{(k)}(x_0)}{k!}(x - x_0)^k \,. \tag{5.8}$$

当 $x_0 = 0$ 时，我们得到 Maclaurin 级数，它是 Taylor 级数的一个特例。若 $f(x) = T_\infty(x)$，则称 f 是解析的。

Maclaurin 级数
解析

注. 一般而言，n 次 Taylor 多项式是对一个函数的近似，该函数本身不必是多项式。Taylor 多项式在 x_0 附近的邻域内与 f 相近。然而，对次数 $k \leq n$ 的多项式 f 而言，n 次 Taylor 多项式是它的精确表示，因为当 $i > k$ 时所有导数 $f^{(i)}$ 都为零。这里 $f \in C^\infty$ 意味着 f 无穷次连续可微。

例 5.3 (Taylor 多项式)**.** 我们考虑多项式

$$f(x) = x^4 \tag{5.9}$$

并求它在 $x_0 = 1$ 处取值的 Taylor 多项式 T_6。我们先计算 $k = 0, \ldots, 6$ 的系数 $f^{(k)}(1)$：

$$f(1) = 1 \tag{5.10}$$
$$f'(1) = 4 \tag{5.11}$$
$$f''(1) = 12 \tag{5.12}$$
$$f^{(3)}(1) = 24 \tag{5.13}$$
$$f^{(4)}(1) = 24 \tag{5.14}$$
$$f^{(5)}(1) = 0 \tag{5.15}$$
$$f^{(6)}(1) = 0 \tag{5.16}$$

因此，所求的 Taylor 多项式为

$$T_6(x) = \sum_{k=0}^{6} \frac{f^{(k)}(x_0)}{k!}(x - x_0)^k \tag{5.17a}$$
$$= 1 + 4(x-1) + 6(x-1)^2 + 4(x-1)^3 + (x-1)^4 + 0 \,. \tag{5.17b}$$

展开并重新整理得

$$T_6(x) = (1 - 4 + 6 - 4 + 1) + x(4 - 12 + 12 - 4) + x^2(6 - 12 + 6) + x^3(4 - 4) + x^4 \tag{5.18a}$$

$$= x^4 = f(x)\,, \tag{5.18b}$$

即我们得到了原函数的精确表示。

原书 p.144

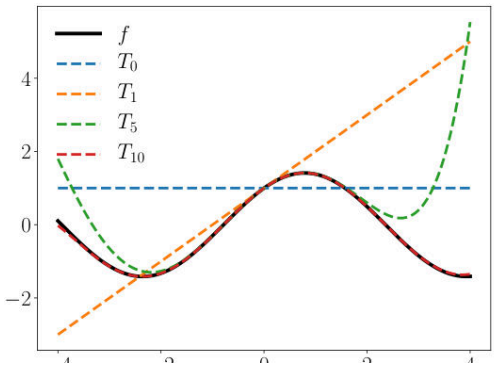


图 5.4: Taylor 多项式。原函数 $f(x) = \sin(x) + \cos(x)$（黑色实线）被 $x_0 = 0$ 附近的 Taylor 多项式（虚线）近似。阶数越高的 Taylor 多项式对 f 的近似越好、越全局；T_{10} 在 $[-4, 4]$ 内已与 f 相近（对应原图 Figure 5.4）。

例 5.4 (Taylor 级数)**.** 考虑图 5.4 中由下式给出的函数

$$f(x) = \sin(x) + \cos(x) \in C^\infty\,. \tag{5.19}$$

我们求 f 在 $x_0 = 0$ 处的 Taylor 级数展开，即 f 的 Maclaurin 级数展开。我们得到如下各阶导数:

$$f(0) = \sin(0) + \cos(0) = 1 \tag{5.20}$$

$$f'(0) = \cos(0) - \sin(0) = 1 \tag{5.21}$$

$$f''(0) = -\sin(0) - \cos(0) = -1 \tag{5.22}$$

$$f^{(3)}(0) = -\cos(0) + \sin(0) = -1 \tag{5.23}$$

$$f^{(4)}(0) = \sin(0) + \cos(0) = f(0) = 1 \tag{5.24}$$

$$\vdots$$

我们能看出这里的规律：Taylor 级数中的系数只取 ± 1（因为 $\sin(0) = 0$），每个系数在切换到另一个之前各出现两次。此外 $f^{(k+4)}(0) = f^{(k)}(0)$。因此，$f$ 在

$x_0 = 0$ 处的完整 Taylor 级数展开为

$$T_\infty(x) = \sum_{k=0}^{\infty} \frac{f^{(k)}(x_0)}{k!}(x - x_0)^k \tag{5.25a}$$
$$= 1 + x - \frac{1}{2!}x^2 - \frac{1}{3!}x^3 + \frac{1}{4!}x^4 + \frac{1}{5!}x^5 - \cdots \tag{5.25b}$$
$$= 1 - \frac{1}{2!}x^2 + \frac{1}{4!}x^4 \mp \cdots + x - \frac{1}{3!}x^3 + \frac{1}{5!}x^5 \mp \cdots \tag{5.25c}$$
$$= \sum_{k=0}^{\infty}(-1)^k \frac{1}{(2k)!}x^{2k} + \sum_{k=0}^{\infty}(-1)^k \frac{1}{(2k+1)!}x^{2k+1} \tag{5.25d}$$
$$= \cos(x) + \sin(x)\,, \tag{5.25e}$$

其中我们用到了幂级数表示

原书 p.145

$$\cos(x) = \sum_{k=0}^{\infty}(-1)^k \frac{1}{(2k)!}x^{2k}\,, \tag{5.26}$$

$$\sin(x) = \sum_{k=0}^{\infty}(-1)^k \frac{1}{(2k+1)!}x^{2k+1}\,. \tag{5.27}$$

图 5.4 给出了相应的前几个 Taylor 多项式 T_n（$n = 0, 1, 5, 10$）。

注. Taylor 级数是幂级数

$$f(x) = \sum_{k=0}^{\infty} a_k(x - c)^k \tag{5.28}$$

的一个特例，其中 a_k 是系数、c 是常数，它具有定义 5.4 中的特殊形式。

幂级数表示

5.1.2　微分法则

下面我们简要列出基本微分法则，其中用 f' 表示 f 的导数。

$$\text{乘积法则：}\quad (f(x)g(x))' = f'(x)g(x) + f(x)g'(x) \tag{5.29}$$
$$\text{商法则：}\quad \Big(\frac{f(x)}{g(x)}\Big)' = \frac{f'(x)g(x) - f(x)g'(x)}{(g(x))^2} \tag{5.30}$$
$$\text{和法则：}\quad (f(x) + g(x))' = f'(x) + g'(x) \tag{5.31}$$
$$\text{链式法则：}\quad \big(g(f(x))\big)' = (g \circ f)'(x) = g'(f(x))f'(x) \tag{5.32}$$

这里 $g \circ f$ 表示函数复合 $x \mapsto f(x) \mapsto g(f(x))$。

例 5.5 (链式法则)**.** 我们用链式法则计算函数 $h(x) = (2x + 1)^4$ 的导数。由

$$h(x) = (2x + 1)^4 = g(f(x))\,, \tag{5.33}$$
$$f(x) = 2x + 1\,, \tag{5.34}$$
$$g(f) = f^4\,, \tag{5.35}$$

我们得到 f 和 g 的导数为

$$f'(x) = 2\,, \tag{5.36}$$

$$g'(f) = 4f^3\,, \tag{5.37}$$

于是 h 的导数为

原书 p.146

$$h'(x) = g'(f)f'(x) = (4f^3)\cdot 2 = 4(2x+1)^3\cdot 2 = 8(2x+1)^3\,, \tag{5.38}$$

这里我们用了链式法则 (5.32)，并在 $g'(f)$ 中代入了 (5.34) 中 f 的定义。

5.2　偏导数与梯度

第 5.1 节讨论的微分适用于标量变量 $x \in \mathbb{R}$ 的函数 f。下面，我们考虑更一般的情形，即函数 f 依赖于一个或多个变量 $x \in \mathbb{R}^n$，例如 $f(x) = f(x_1, x_2)$。导数向多元函数的推广就是梯度。

我们通过每次只变动一个变量、而保持其余变量不变，来求函数 f 关于 x 的梯度。于是梯度就是这些偏导数的汇集。

定义 5.5 (偏导数)**.** 对 n 个变量 $x_1, \ldots, x_n$ 的函数 $f : \mathbb{R}^n \to \mathbb{R}$、$x \mapsto f(x)$、$x \in \mathbb{R}^n$，我们把偏导数定义为

偏导数

$$\frac{\partial f}{\partial x_1} = \lim_{h\to 0}\frac{f(x_1+h, x_2, \ldots, x_n) - f(x)}{h} \quad \cdots \quad \frac{\partial f}{\partial x_n} = \lim_{h\to 0}\frac{f(x_1, \ldots, x_{n-1}, x_n + h) - f(x)}{h} \tag{5.39}$$

并把它们汇集为行向量

$$\nabla_x f = \operatorname{grad} f = \frac{\mathrm{d}f}{\mathrm{d}x} = \left[\frac{\partial f(x)}{\partial x_1}\ \frac{\partial f(x)}{\partial x_2}\ \cdots\ \frac{\partial f(x)}{\partial x_n}\right] \in \mathbb{R}^{1\times n}\,, \tag{5.40}$$

其中 n 是变量个数，1 是 f 的像域/值域/陪域的维数。这里我们把列向量 $x = [x_1, \ldots, x_n]^\top \in \mathbb{R}^n$ 定义为自变量。(5.40) 中的行向量称为 f 的**梯度**（gradient）或 **Jacobian**（雅可比），它是第 5.1 节中导数的推广。

梯度　ian

注. 对向量值函数的一般定义而言，此处对 Jacobian 的定义只是一个特例，即把偏导数汇集起来。我们将在第 5.3 节回到这一点。

例 5.6 (用链式法则求偏导数)**.** 对 $f(x, y) = (x + 2y^3)^2$，我们得到偏导数

标量微分结果可直接用

$$\frac{\partial f(x,y)}{\partial x} = 2(x+2y^3)\frac{\partial}{\partial x}(x+2y^3) = 2(x+2y^3)\,, \tag{5.41}$$

原书 p.147

$$\frac{\partial f(x,y)}{\partial y} = 2(x+2y^3)\frac{\partial}{\partial y}(x+2y^3) = 12(x+2y^3)y^2\,. \tag{5.42}$$

这里我们用了链式法则 (5.32) 来计算偏导数。

注 (作为行向量的梯度). 在文献中，把梯度向量定义为列向量的做法并不少见，这遵循" 向量一般为列向量" 的约定。我们之所以把梯度向量定义为行向量，理由有二：第一，我们可以一致地把梯度推广到向量值函数 $f : \mathbb{R}^n \to \mathbb{R}^m$（此时梯度成为矩阵）；第二，我们可以立即应用多元链式法则而无需顾及梯度的维数。我们将在第 5.3 节讨论这两点。

例 5.7 (梯度). 对 $f(x_1, x_2) = x_1^2 x_2 + x_1 x_2^3 \in \mathbb{R}$，偏导数（即 f 关于 x_1 和 x_2 的导数）为

$$\frac{\partial f(x_1, x_2)}{\partial x_1} = 2x_1 x_2 + x_2^3 \tag{5.43}$$

$$\frac{\partial f(x_1, x_2)}{\partial x_2} = x_1^2 + 3x_1 x_2^2 \tag{5.44}$$

于是梯度为

$$\frac{\mathrm{d}f}{\mathrm{d}x} = \begin{bmatrix} \frac{\partial f(x_1, x_2)}{\partial x_1} & \frac{\partial f(x_1, x_2)}{\partial x_2} \end{bmatrix} = \begin{bmatrix} 2x_1 x_2 + x_2^3 & x_1^2 + 3x_1 x_2^2 \end{bmatrix} \in \mathbb{R}^{1\times 2}. \tag{5.45}$$

5.2.1 偏微分的基本法则

乘积法则：$(fg)' = f'g + fg'$
和法则：$(f + g)' = f' + g'$
链式法则：$(g(f))' = g'(f)f'$

在 $x \in \mathbb{R}^n$ 的多元情形下，我们在学校里学过的基本微分法则（如和法则、乘积法则、链式法则；另见第 5.1.2 节）依然适用。然而，当我们关于向量 $x \in \mathbb{R}^n$ 计算导数时需要小心：我们的梯度现在涉及向量和矩阵，而矩阵乘法不可交换（第 2.2.1 节），即顺序很重要。

下面是一般的乘积法则、和法则和链式法则：

原书 p.148

$$\text{乘积法则：}\quad \frac{\partial}{\partial x}\big(f(x)g(x)\big) = \frac{\partial f}{\partial x}g(x) + f(x)\frac{\partial g}{\partial x} \tag{5.46}$$

$$\text{和法则：}\quad \frac{\partial}{\partial x}\big(f(x) + g(x)\big) = \frac{\partial f}{\partial x} + \frac{\partial g}{\partial x} \tag{5.47}$$

$$\text{链式法则：}\quad \frac{\partial}{\partial x}(g \circ f)(x) = \frac{\partial}{\partial x}\big(g(f(x))\big) = \frac{\partial g}{\partial f}\frac{\partial f}{\partial x} \tag{5.48}$$

我们仔细看一下链式法则。链式法则 (5.48) 在某种程度上让人联想到矩阵乘法的法则，即矩阵乘法要有定义就必须相邻维数匹配；见第 2.2.1 节。如果我们从左向右看，链式法则呈现出类似的性质：∂f 出现在第一个因子的" 分母" 中又出现在第二个因子的" 分子" 中。若把各因子相乘，乘法就有定义，即 ∂f 的维数匹配，∂f 像约掉一样消去，最后剩下 $\partial g/\partial x$。

只是直觉，非严格数学

5.2.2 链式法则

考虑二元函数 $f : \mathbb{R}^2 \to \mathbb{R}$，自变量为 x_1, x_2。此外，$x_1(t)$ 和 $x_2(t)$ 本身又是 t 的函数。为计算 f 关于 t 的梯度，我们需要对多元函数应用链式法则 (5.48)：

$$\frac{\mathrm{d}f}{\mathrm{d}t} = \begin{bmatrix} \frac{\partial f}{\partial x_1} & \frac{\partial f}{\partial x_2} \end{bmatrix} \begin{bmatrix} \frac{\partial x_1(t)}{\partial t} \\ \frac{\partial x_2(t)}{\partial t} \end{bmatrix} = \frac{\partial f}{\partial x_1}\frac{\partial x_1}{\partial t} + \frac{\partial f}{\partial x_2}\frac{\partial x_2}{\partial t}, \tag{5.49}$$

链式法则可写成矩阵乘法

其中 d 表示梯度，∂ 表示偏导数。

例 5.8. 考虑 $f(x_1, x_2) = x_1^2 + 2x_2$，其中 $x_1 = \sin t$、$x_2 = \cos t$，则

$$\frac{\mathrm{d}f}{\mathrm{d}t} = \frac{\partial f}{\partial x_1}\frac{\partial x_1}{\partial t} + \frac{\partial f}{\partial x_2}\frac{\partial x_2}{\partial t} \tag{5.50a}$$

$$= 2\sin t \frac{\partial \sin t}{\partial t} + 2\frac{\partial \cos t}{\partial t} \tag{5.50b}$$

$$= 2\sin t\cos t - 2\sin t = 2\sin t(\cos t - 1) \tag{5.50c}$$

就是 f 关于 t 的相应导数。

若 $f(x_1, x_2)$ 是 x_1, x_2 的函数，而 $x_1(s,t)$、$x_2(s,t)$ 本身又是两个变量 s, t 的函数，则链式法则给出偏导数

$$\frac{\partial f}{\partial s} = \frac{\partial f}{\partial x_1}\frac{\partial x_1}{\partial s} + \frac{\partial f}{\partial x_2}\frac{\partial x_2}{\partial s}\,, \tag{5.51}$$

$$\frac{\partial f}{\partial t} = \frac{\partial f}{\partial x_1}\frac{\partial x_1}{\partial t} + \frac{\partial f}{\partial x_2}\frac{\partial x_2}{\partial t}\,, \tag{5.52}$$

梯度由矩阵乘法得到

原书 p.149

$$\frac{\mathrm{d}f}{\mathrm{d}(s,t)} = \frac{\partial f}{\partial x}\frac{\partial x}{\partial (s,t)} = \underbrace{\begin{bmatrix}\frac{\partial f}{\partial x_1} & \frac{\partial f}{\partial x_2}\end{bmatrix}}_{=\frac{\partial f}{\partial x}} \underbrace{\begin{bmatrix}\frac{\partial x_1}{\partial s} & \frac{\partial x_1}{\partial t} \\ \frac{\partial x_2}{\partial s} & \frac{\partial x_2}{\partial t}\end{bmatrix}}_{=\frac{\partial x}{\partial (s,t)}}. \tag{5.53}$$

把链式法则写成矩阵乘法的这种紧凑方式，只有当梯度被定义为行向量时才有意义。否则我们就不得不开始转置梯度，以使矩阵维数匹配。只要梯度是向量或矩阵，这样做或许还直接；然而，当梯度成为张量时（下面会讨论），转置就不再是一件微不足道的事了。

梯度检验

注 (验证梯度实现的正确性). 偏导数被定义为相应差商的极限（见 (5.39)），这一定义可在计算机程序中数值检验梯度正确性时加以利用：当我们计算并实现梯度时，可以用有限差分数值测试我们的计算与实现：我们取一个很小的 h（例如 $h = 10^{-4}$），把 (5.39) 的有限差分近似与我们（解析）实现的梯度相比较。若误差很小，我们的梯度实现很可能是正确的。”很小”可以指 $\sqrt{\frac{\sum_i (\mathrm{d}h_i - \mathrm{d}f_i)^2}{\sum_i (\mathrm{d}h_i + \mathrm{d}f_i)^2}} < 10^{-6}$，其中 $\mathrm{d}h_i$ 是有限差分近似，$\mathrm{d}f_i$ 是 f 关于第 i 个变量 x_i 的解析梯度。

5.3　向量值函数的梯度

到此为止，我们讨论了映射到实数的函数 $f : \mathbb{R}^n \to \mathbb{R}$ 的偏导数与梯度。下面，我们把梯度概念推广到向量值函数（向量场）$f : \mathbb{R}^n \to \mathbb{R}^m$，其中 $n \geq 1$、$m > 1$。

对函数 $f : \mathbb{R}^n \to \mathbb{R}^m$ 和向量 $x = [x_1, \ldots, x_n]^\top \in \mathbb{R}^n$，相应的函数值向量为

$$f(x) = \begin{bmatrix} f_1(x) \\ \vdots \\ f_m(x)\end{bmatrix} \in \mathbb{R}^m\,. \tag{5.54}$$

这样写向量值函数，使我们可以把 $f:\mathbb{R}^n\to\mathbb{R}^m$ 看作函数向量 $[f_1,\dots,f_m]^\top$，其中每个 $f_i:\mathbb{R}^n\to\mathbb{R}$ 映射到 $\mathbb{R}$。每个 f_i 的微分法则正是我们在第 5.2 节讨论过的那些。

原书 p.150

因此，向量值函数 $f:\mathbb{R}^n\to\mathbb{R}^m$ 关于 $x_i\in\mathbb{R}$（$i=1,\dots,n$）的偏导数是向量

$$\frac{\partial f}{\partial x_i}=\begin{bmatrix}\frac{\partial f_1}{\partial x_i}\\ \vdots\\ \frac{\partial f_m}{\partial x_i}\end{bmatrix}=\begin{bmatrix}\lim_{h\to0}\frac{f_1(x_1,\dots,x_{i-1},x_i+h,x_{i+1},\dots,x_n)-f_1(x)}{h}\\ \vdots\\ \lim_{h\to0}\frac{f_m(x_1,\dots,x_{i-1},x_i+h,x_{i+1},\dots,x_n)-f_m(x)}{h}\end{bmatrix}\in\mathbb{R}^m\,. \tag{5.55}$$

由 (5.40) 知，f 关于向量的梯度是偏导数组成的行向量。在 (5.55) 中，每个偏导数 $\partial f/\partial x_i$ 本身是一个列向量。因此，把这些偏导数汇集起来，我们就得到 $f:\mathbb{R}^n\to\mathbb{R}^m$ 关于 $x\in\mathbb{R}^n$ 的梯度：

$$\frac{\mathrm{d}f(x)}{\mathrm{d}x}=\begin{bmatrix}\frac{\partial f(x)}{\partial x_1}&\cdots&\frac{\partial f(x)}{\partial x_n}\end{bmatrix} \tag{5.56a}$$

$$=\begin{bmatrix}\frac{\partial f_1(x)}{\partial x_1}&\cdots&\frac{\partial f_1(x)}{\partial x_n}\\ \vdots&\ddots&\vdots\\ \frac{\partial f_m(x)}{\partial x_1}&\cdots&\frac{\partial f_m(x)}{\partial x_n}\end{bmatrix}\in\mathbb{R}^{m\times n}\,. \tag{5.56b}$$

定义 5.6 (Jacobian)**.** 向量值函数 $f:\mathbb{R}^n\to\mathbb{R}^m$ 的所有一阶偏导数的汇集称为 **Jacobian**（雅可比矩阵）。Jacobian J 是一个 $m\times n$ 矩阵，我们定义并排列如下：

Jacobi 函数 $f:\mathbb{R}^n\to\mathbb{R}^m$ 的梯度是 $m\times n$ 矩阵

$$J=\nabla_x f=\frac{\mathrm{d}f(x)}{\mathrm{d}x}=\begin{bmatrix}\frac{\partial f(x)}{\partial x_1}&\cdots&\frac{\partial f(x)}{\partial x_n}\end{bmatrix} \tag{5.57}$$

$$=\begin{bmatrix}\frac{\partial f_1(x)}{\partial x_1}&\cdots&\frac{\partial f_1(x)}{\partial x_n}\\ \vdots&\ddots&\vdots\\ \frac{\partial f_m(x)}{\partial x_1}&\cdots&\frac{\partial f_m(x)}{\partial x_n}\end{bmatrix}, \tag{5.58}$$

$$x=\begin{bmatrix}x_1\\ \vdots\\ x_n\end{bmatrix},\qquad J(i,j)=\frac{\partial f_i}{\partial x_j}\,. \tag{5.59}$$

作为 (5.58) 的特例，把向量 $x\in\mathbb{R}^n$ 映射到标量的函数 $f:\mathbb{R}^n\to\mathbb{R}^1$（例如 $f(x)=\sum_{i=1}^n x_i$），其 Jacobian 是一个行向量（$1\times n$ 矩阵）；见 (5.40)。

注. 本书使用导数的**分子布局**（numerator layout），即 $f\in\mathbb{R}^m$ 关于 $x\in\mathbb{R}^n$ 的导数 $\mathrm{d}f/\mathrm{d}x$ 是一个 $m\times n$ 矩阵，其中 f 的各元素定义行、x 的各元素定义相应 Jacobian 的列；见 (5.58)。此外还有**分母布局**（denominator layout），它是分子布局的转置。本书使用分子布局。

分子布局

分母布局

我们将在第 6.7 节看到，Jacobian 如何用于概率分布的变量替换法。变量变换所引起的缩放程度由行列式给出。

原书 p.151

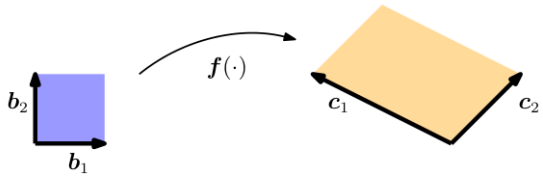


图 5.5: f 的 Jacobian 行列式可用来计算蓝色与橙色区域之间的放大率（对应原图 Figure 5.5）。

在第 4.1 节中我们看到，行列式可用来计算平行四边形的面积。若取两个向量 $b_1 = [1, 0]^\top$、$b_2 = [0, 1]^\top$ 作为单位正方形（蓝色；见图 5.5）的边，则该正方形的面积为

$$\left|\det\left(\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}\right)\right| = 1\,. \tag{5.60}$$

若取边为 $c_1 = [-2, 1]^\top$、$c_2 = [1, 1]^\top$ 的平行四边形（图 5.5 中橙色），其面积为行列式的绝对值（见第 4.1 节）

$$\left|\det\left(\begin{bmatrix} -2 & 1 \\ 1 & 1 \end{bmatrix}\right)\right| = |-3| = 3\,, \tag{5.61}$$

即它的面积恰好是单位正方形面积的三倍。我们可以通过找到一个把单位正方形变换为另一个正方形的映射来求得这个缩放因子。用线性代数的术语，我们实际上是在做从 (b_1, b_2) 到 (c_1, c_2) 的变量变换。在本例中，映射是线性的，该映射行列式的绝对值恰好给出我们所要的缩放因子。

下面我们描述确定该映射的两种途径。第一，利用映射是线性的这一事实，借助第 2 章的工具来确定它。第二，用本章一直在讨论的偏导数工具来找到映射。

途径 1　从线性代数途径入手，我们把 $\{b_1, b_2\}$ 和 $\{c_1, c_2\}$ 都识别为 $\mathbb{R}^2$ 的基（回顾见第 2.6.1 节）。我们实际所做的是从 (b_1, b_2) 到 (c_1, c_2) 的基变换，我们要找实现该基变换的变换矩阵。利用第 2.7.2 节的结果，我们把所需的基变换矩阵识别为

$$J = \begin{bmatrix} -2 & 1 \\ 1 & 1 \end{bmatrix}\,, \tag{5.62}$$

使得 $Jb_1 = c_1$、$Jb_2 = c_2$。J 行列式的绝对值给出我们所要的缩放因子，为 $|\det(J)| = 3$，即由 (c_1, c_2) 张成的正方形面积是由 (b_1, b_2) 张成面积的三倍。 原书 p.152

途径 2　线性代数途径适用于线性变换；对于非线性变换（在第 6.7 节会变得重要），我们采用基于偏导数的更一般途径。

为此，我们考虑一个执行变量变换的函数 $f : \mathbb{R}^2 \to \mathbb{R}^2$。在本例中，$f$ 把任意向量 $x \in \mathbb{R}^2$ 关于 (b_1, b_2) 的坐标表示，映射为它关于 (c_1, c_2) 的坐标表示 $y \in \mathbb{R}^2$。我们想识别这个映射，以便计算一个面积（或体积）在被 f 变换时如何变化。为此，我们需要知道：若对 x 稍作改动，$f(x)$ 会如何变化。这个问题恰好由 Jacobian 矩阵 $\mathrm{d}f/\mathrm{d}x \in \mathbb{R}^{2\times 2}$ 回答。由于可写出

$$y_1 = -2x_1 + x_2 \tag{5.63}$$

$$y_2 = x_1 + x_2 \tag{5.64}$$

我们得到 x 与 y 之间的函数关系，由此求得偏导数

$$\frac{\partial y_1}{\partial x_1} = -2, \quad \frac{\partial y_1}{\partial x_2} = 1, \quad \frac{\partial y_2}{\partial x_1} = 1, \quad \frac{\partial y_2}{\partial x_2} = 1 \tag{5.65}$$

并组装成 Jacobian：

$$J = \begin{bmatrix} \frac{\partial y_1}{\partial x_1} & \frac{\partial y_1}{\partial x_2} \\ \frac{\partial y_2}{\partial x_1} & \frac{\partial y_2}{\partial x_2} \end{bmatrix} = \begin{bmatrix} -2 & 1 \\ 1 & 1 \end{bmatrix}. \tag{5.66}$$

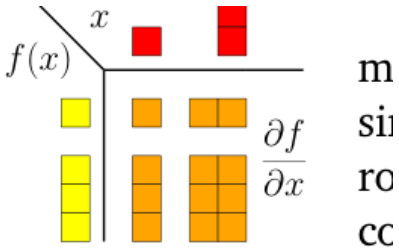


图 5.6: （偏）导数的维数（对应原图 Figure 5.6）。

Jacobian行列式的几何意义

该 Jacobian 表示我们所要的坐标变换。若坐标变换是线性的（如本例），它是精确的，(5.66) 恰好恢复 (5.62) 中的基变换矩阵。若坐标变换是非线性的 Jacobian 就在局部用一个线性变换来近似这个非线性变换。**Jacobian 行列式**（Jacobian determinant）$|\det(J)|$ 就是坐标变换时面积或体积被缩放的因子。本例给出 $|\det(J)| = 3$。当我们在第 6.7 节变换随机变量和概率分布时，Jacobian 行列式与变量变换将变得重要。这些变换在深度学习中极为相关，即用重参数化技巧（也称为无穷扰动分析）训练深度神经网络。

Jacobian行列式

本章我们遇到了函数的导数。图 5.6 总结了这些导数的维数。若 $f : \mathbb{R} \to \mathbb{R}$，梯度只是一个标量（左上角）。若 $f : \mathbb{R}^D \to \mathbb{R}$，梯度是 $1 \times D$ 行向量（右上角）。若 $f : \mathbb{R} \to \mathbb{R}^E$，梯度是 $E \times 1$ 列向量；若 $f : \mathbb{R}^D \to \mathbb{R}^E$，梯度是 $E \times D$ 矩阵。

原书 p.153

例 5.9 (向量值函数的梯度)**.** 给定

$$f(x) = Ax, \qquad f(x) \in \mathbb{R}^M, \qquad A \in \mathbb{R}^{M \times N}, \qquad x \in \mathbb{R}^N.$$

为计算梯度 $\mathrm{d}f/\mathrm{d}x$，我们先确定 $\mathrm{d}f/\mathrm{d}x$ 的维数：由于 $f : \mathbb{R}^N \to \mathbb{R}^M$，故 $\mathrm{d}f/\mathrm{d}x \in \mathbb{R}^{M \times N}$。其次，为计算梯度，我们求 f 关于每个 x_j 的偏导数：

$$f_i(x) = \sum_{j=1}^{N} A_{ij} x_j \quad \Longrightarrow \quad \frac{\partial f_i}{\partial x_j} = A_{ij} \tag{5.67}$$

我们把偏导数汇集到 Jacobian 中，得到梯度

$$\frac{\mathrm{d}f}{\mathrm{d}x} = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \cdots & \frac{\partial f_1}{\partial x_N} \\ \vdots & \ddots & \vdots \\ \frac{\partial f_M}{\partial x_1} & \cdots & \frac{\partial f_M}{\partial x_N} \end{bmatrix} = \begin{bmatrix} A_{11} & \cdots & A_{1N} \\ \vdots & \ddots & \vdots \\ A_{M1} & \cdots & A_{MN} \end{bmatrix} = A \in \mathbb{R}^{M \times N}. \tag{5.68}$$

例 5.10 (链式法则). 考虑函数 $h : \mathbb{R} \to \mathbb{R}$、$h(t) = (f \circ g)(t)$，其中

$$f : \mathbb{R}^2 \to \mathbb{R} \tag{5.69}$$

$$g : \mathbb{R} \to \mathbb{R}^2 \tag{5.70}$$

$$f(x) = \exp(x_1 x_2^2)\,, \tag{5.71}$$

$$x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = g(t) = \begin{bmatrix} t\cos t \\ t\sin t \end{bmatrix} \tag{5.72}$$

并计算 h 关于 t 的梯度。由于 $f : \mathbb{R}^2 \to \mathbb{R}$、$g : \mathbb{R} \to \mathbb{R}^2$，我们注意到

$$\frac{\partial f}{\partial x} \in \mathbb{R}^{1\times 2}, \qquad \frac{\partial g}{\partial t} \in \mathbb{R}^{2\times 1}\,. \tag{5.73}$$

所求梯度通过应用链式法则计算：

$$\frac{\mathrm{d}h}{\mathrm{d}t} = \frac{\partial f}{\partial x}\frac{\partial x}{\partial t} = \begin{bmatrix}\frac{\partial f}{\partial x_1} & \frac{\partial f}{\partial x_2}\end{bmatrix} \begin{bmatrix}\frac{\partial x_1}{\partial t} \\ \frac{\partial x_2}{\partial t}\end{bmatrix} \tag{5.74a}$$

$$= \begin{bmatrix}\exp(x_1x_2^2)x_2^2 & 2\exp(x_1x_2^2)x_1x_2\end{bmatrix} \begin{bmatrix}\cos t - t\sin t \\ \sin t + t\cos t\end{bmatrix} \tag{5.74b}$$

$$= \exp(x_1x_2^2)\big(x_2^2(\cos t - t\sin t) + 2x_1x_2(\sin t + t\cos t)\big)\,, \tag{5.74c}$$

其中 $x_1 = t\cos t$、$x_2 = t\sin t$；见 (5.72)。

原书 p.154

例 5.11 (线性模型中最小二乘损失的梯度). 考虑线性模型

第9 章详述线性回归

$$y = \Phi\theta\,, \tag{5.75}$$

其中 $\theta \in \mathbb{R}^D$ 是参数向量，$\Phi \in \mathbb{R}^{N\times D}$ 是输入特征，$y \in \mathbb{R}^N$ 是相应观测。我们定义函数

$$L(e) := \|e\|^2\,, \tag{5.76}$$

$$e(\theta) := y - \Phi\theta\,. \tag{5.77}$$

我们求 $\partial L/\partial\theta$, 并将为此使用链式法则。$L$ 称为**最小二乘损失** (least-squares loss)。在开始计算前，我们先确定梯度的维数：

最小二乘损失

$$\frac{\partial L}{\partial\theta} \in \mathbb{R}^{1\times D}\,. \tag{5.78}$$

链式法则使我们能把梯度算为

$$\frac{\partial L}{\partial\theta} = \frac{\partial L}{\partial e}\frac{\partial e}{\partial\theta}\,, \tag{5.79}$$

其中第 d 个元素为

$$\frac{\partial L}{\partial\theta}[1,d] = \sum_{n=1}^{N}\frac{\partial L}{\partial e}[n]\,\frac{\partial e}{\partial\theta}[n,d]\,. \tag{5.80}$$

np.einsum('n,nd',dLde,dedtheta)

我们知道 $\|e\|^2 = e^\top e$（见第 3.2 节），并确定

原书 p.155

$$\frac{\partial L}{\partial e} = 2e^\top \in \mathbb{R}^{1\times N}\,. \tag{5.81}$$

此外，我们得到

$$\frac{\partial e}{\partial \theta} = -\Phi \in \mathbb{R}^{N\times D}\,, \tag{5.82}$$

于是所求导数为

$$\frac{\partial L}{\partial \theta} = -2e^\top\Phi = \underbrace{-2(y^\top - \theta^\top\Phi^\top)}_{\in\mathbb{R}^{1\times N}}\underbrace{\Phi}_{\in\mathbb{R}^{N\times D}} \in \mathbb{R}^{1\times D}\,. \tag{5.83}$$

注. 我们不使用链式法则、而是直接考察函数

$$L_2(\theta) := \|y - \Phi\theta\|^2 = (y-\Phi\theta)^\top(y-\Phi\theta) \tag{5.84}$$

也会得到相同结果。对 L_2 这样的简单函数，这种方法仍然可行；但对于深层函数复合，它就不切实际了。

5.4　矩阵的梯度

我们会遇到需要关于向量（或其他矩阵）对矩阵求梯度的情形，其结果是一个多维张量。我们可把这个张量看作汇集偏导数的多维数组。例如，若计算 $m\times n$ 矩阵 A 关于 $p\times q$ 矩阵 B 的梯度，所得 Jacobian 将是 $(m\times n)\times(p\times q)$ 即一个四维张量 J，其元素为 $J_{ijkl} = \partial A_{ij}/\partial B_{kl}$。

张量可看作多维数组

由于矩阵表示线性映射，我们可以利用这样一个事实：$m\times n$ 矩阵空间 $\mathbb{R}^{m\times n}$ 与 mn 维向量空间 $\mathbb{R}^{mn}$ 之间存在向量空间同构（线性、可逆的映射）。因此，我们可以把矩阵分别重塑为长度 mn 和 pq 的向量。用这些 mn 维向量求得的梯度其 Jacobian 大小为 $mn\times pq$。图 5.7 可视化了这两种途径。在实际应用中，常常希望把矩阵重塑为向量并继续使用这个 Jacobian 矩阵：链式法则 (5.48) 归结为简单的矩阵乘法；而在 Jacobian 张量的情形下，我们需要更小心地留意对哪些维数求和。

矩阵可按列堆叠展平为向量

例 5.12 (向量关于矩阵的梯度)**.** 考虑下例，其中

$$f = Ax, \qquad f\in\mathbb{R}^M, \qquad A\in\mathbb{R}^{M\times N}, \qquad x\in\mathbb{R}^N \tag{5.85}$$

我们求梯度 $\mathrm{d}f/\mathrm{d}A$。先确定梯度的维数：

$$\frac{\mathrm{d}f}{\mathrm{d}A} \in \mathbb{R}^{M\times(M\times N)}\,. \tag{5.86}$$

由定义，梯度是偏导数的汇集：

$$\frac{\mathrm{d}f}{\mathrm{d}A} = \begin{bmatrix} \frac{\partial f_1}{\partial A} \\ \vdots \\ \frac{\partial f_M}{\partial A} \end{bmatrix}, \qquad \frac{\partial f_i}{\partial A} \in \mathbb{R}^{1\times(M\times N)}\,. \tag{5.87}$$

为计算偏导数，显式写出矩阵向量乘法会有帮助：

$$f_i = \sum_{j=1}^{N} A_{ij} x_j, \qquad i = 1, \ldots, M\,, \tag{5.88}$$

于是偏导数为

$$\frac{\partial f_i}{\partial A_{iq}} = x_q\,. \tag{5.89}$$

这使我们能计算 f_i 关于 A 某一行的偏导数：

$$\frac{\partial f_i}{\partial A_{i,:}} = x^\top \in \mathbb{R}^{1\times 1\times N}\,, \tag{5.90}$$

原书 p.157

$$\frac{\partial f_i}{\partial A_{k\neq i,:}} = 0^\top \in \mathbb{R}^{1\times 1\times N}\,, \tag{5.91}$$

这里必须注意正确的维数。由于 f_i 映射到 $\mathbb{R}$，而 A 的每一行大小为 $1\times N$，故 f_i 关于 A 某一行的偏导数是一个 $1\times 1\times N$ 大小的张量。

我们堆叠偏导数 (5.91)，并由下式得到 (5.87) 中所求的梯度：

$$\frac{\partial f_i}{\partial A} = \begin{bmatrix} 0^\top \\ \vdots \\ 0^\top \\ x^\top \\ 0^\top \\ \vdots \\ 0^\top \end{bmatrix} \in \mathbb{R}^{1\times(M\times N)}\,. \tag{5.92}$$

例 5.13 (矩阵关于矩阵的梯度)**.** 考虑矩阵 $R \in \mathbb{R}^{M\times N}$ 和 $f : \mathbb{R}^{M\times N} \to \mathbb{R}^{N\times N}$，其中

$$f(R) = R^\top R =: K \in \mathbb{R}^{N\times N}\,, \tag{5.93}$$

我们求梯度 $\mathrm{d}K/\mathrm{d}R$。

要解决这个难题，先写下我们已知的：该梯度的维数为

$$\frac{\mathrm{d}K}{\mathrm{d}R} \in \mathbb{R}^{(N\times N)\times(M\times N)}\,, \tag{5.94}$$

它是一个张量。此外

$$\frac{\mathrm{d}K_{pq}}{\mathrm{d}R} \in \mathbb{R}^{1\times M\times N} \tag{5.95}$$

对 $p, q = 1, \ldots, N$ 成立，其中 K_{pq} 是 $K = f(R)$ 的第 (p, q) 个元素。记 R 的第 i 列为 r_i，则 K 的每个元素由 R 两列的点积给出，即

$$K_{pq} = r_p^\top r_q = \sum_{m=1}^{M} R_{mp} R_{mq}\,. \tag{5.96}$$

现在计算偏导数 $\partial K_{pq}/\partial R_{ij}$，得到

$$\frac{\partial K_{pq}}{\partial R_{ij}} = \sum_{m=1}^{M} \frac{\partial}{\partial R_{ij}} R_{mp} R_{mq} = \partial_{pqij}\,, \tag{5.97}$$

原书 p.158

$$\partial_{pqij} = \begin{cases} R_{iq} & \text{若} j = p,\ p \neq q \\ R_{ip} & \text{若} j = q,\ p \neq q \\ 2R_{iq} & \text{若} j = p,\ p = q \\ 0 & \text{其他} \end{cases}. \tag{5.98}$$

由 (5.94) 知，所求梯度的维数为 $(N \times N) \times (M \times N)$，该张量的每一个元素由 (5.98) 中的 ∂_{pqij} 给出，其中 $p, q, j = 1, \ldots, N$、$i = 1, \ldots, M$。

5.5　计算梯度的有用恒等式

下面列出在机器学习语境中经常用到的一些有用梯度（Petersen and Pedersen, 2012）。这里 tr$(\cdot)$ 表示迹（见定义 4.4），det$(\cdot)$ 表示行列式（见第 4.1 节），$f(X)^{-1}$ 表示 $f(X)$ 的逆（假定它存在）。

$$\frac{\partial}{\partial X} f(X)^\top = \Big(\frac{\partial f(X)}{\partial X}\Big)^\top \tag{5.99}$$

$$\frac{\partial}{\partial X} \operatorname{tr}(f(X)) = \operatorname{tr}\Big(\frac{\partial f(X)}{\partial X}\Big) \tag{5.100}$$

$$\frac{\partial}{\partial X} \det(f(X)) = \det(f(X)) \operatorname{tr}\Big(f(X)^{-1} \frac{\partial f(X)}{\partial X}\Big) \tag{5.101}$$

$$\frac{\partial}{\partial X} f(X)^{-1} = -f(X)^{-1} \frac{\partial f(X)}{\partial X} f(X)^{-1} \tag{5.102}$$

$$\frac{\partial\, a^\top X^{-1} b}{\partial X} = -(X^{-1})^\top a b^\top (X^{-1})^\top \tag{5.103}$$

$$\frac{\partial\, x^\top a}{\partial x} = a^\top \tag{5.104}$$

$$\frac{\partial\, a^\top x}{\partial x} = a^\top \tag{5.105}$$

$$\frac{\partial\, a^\top X b}{\partial X} = a b^\top \tag{5.106}$$

$$\frac{\partial\, x^\top B x}{\partial x} = x^\top (B + B^\top) \tag{5.107}$$

$$\frac{\partial}{\partial s}(x - As)^\top W (x - As) = -2(x - As)^\top W A, \quad \text{对对称的} W \tag{5.108}$$

注. 本书只涉及矩阵的迹和转置。然而我们已经看到，导数可以是更高维的张量，此时通常的迹和转置并未定义。在这些情形下，$D \times D \times E \times F$ 张量的迹将是一个 $E \times F$ 维矩阵。这是张量缩并的一个特例。类似地，当我们对张量做" 转置" 时，指的是交换前两维。具体地，在 (5.99)–(5.102) 中，当我们处理多元函数 $f(\cdot)$ 并关于矩阵计算导数时（且选择不按第 5.4 节那样向量化），就需要用到与张量相关的运算。

原书 p.159

5.6　反向传播与自动微分

反向传播与链式法则的讨论见Tim Vieira 博客

在许多机器学习应用中，我们通过梯度下降（第 7.1 节）来求得好的模型参数，梯度下降依赖于这样一个事实：我们能够计算学习目标关于模型参数的梯度。对给定的目标函数，我们可以用微积分并应用链式法则来得到关于模型参数的梯度；见第 5.2.2 节。在第 5.3 节考察平方损失关于线性回归模型参数的梯度时，我们已经初尝过这一点。

考虑函数

$$f(x) = \sqrt{x^2 + \exp(x^2)} + \cos\big(x^2 + \exp(x^2)\big)\,. \tag{5.109}$$

应用链式法则，并注意到微分是线性的，我们计算梯度

$$\begin{aligned}\frac{\mathrm{d}f}{\mathrm{d}x} &= \frac{2x + 2x\exp(x^2)}{2\sqrt{x^2 + \exp(x^2)}} - \sin\big(x^2 + \exp(x^2)\big)\big(2x + 2x\exp(x^2)\big) \\ &= 2x\Big(\frac{1}{2\sqrt{x^2 + \exp(x^2)}} - \sin\big(x^2 + \exp(x^2)\big)\Big)\big(1 + \exp(x^2)\big)\,.\end{aligned} \tag{5.110}$$

以这种显式方式写出梯度往往不切实际，因为它常常导致导数的表达式非常冗长。在实践中，这意味着如果不够小心，梯度的实现可能比计算函数本身开销大得多，从而带来不必要的额外开销。为训练深度神经网络模型，**反向传播**（back-propagation）算法（Kelley, 1960; Bryson, 1961; Dreyfus, 1962; Rumelhart et al., 1986）是一种高效计算误差函数关于模型参数梯度的方法。

反向传播

5.6.1　深度网络中的梯度

链式法则被用到极致的一个领域是深度学习，其中函数值 y 是多层函数复合计算出来的：

$$y = (f_K \circ f_{K-1} \circ \cdots \circ f_1)(x) = f_K(f_{K-1}(\cdots(f_1(x))\cdots))\,, \tag{5.111}$$

其中 x 是输入（例如图像），y 是观测（例如类别标签），每个函数 f_i ($i = 1, \ldots, K$) 都有自己的参数。

在多层神经网络中，第 i 层有函数 $f_i(x_{i-1}) = \sigma(A_{i-1}x_{i-1} + b_{i-1})$。这里 x_{i-1} 是第 $i-1$ 层的输出，σ 是一个激活函数，例如 logistic sigmoid $\frac{1}{1+e^{-x}}$、tanh 或整流线性单元（ReLU）。为训练这些模型，我们需要损失函数 L 关于所有模型参数 A_j, b_j（$j = 1, \ldots, K$）的梯度。这还要求我们计算 L 关于每一层输入的梯度例如，若有输入 x、观测 y 和由下式定义的网络结构

为记号简洁，假定各层激活函数相同

$$f_0 := x \tag{5.112}$$

$$f_i := \sigma_i(A_{i-1}f_{i-1} + b_{i-1}), \qquad i = 1, \ldots, K\,, \tag{5.113}$$

另见图 5.8，我们可能想找 A_j, b_j（$j = 0, \ldots, K-1$）使平方损失

$$L(\theta) = \|y - f_K(\theta, x)\|^2 \tag{5.114}$$

最小，其中 $\theta = \{A_0, b_0, \ldots, A_{K-1}, b_{K-1}\}$。

为得到关于参数集 θ 的梯度，我们需要 L 关于每一层 $j=0,\dots,K-1$ 的参数 $\theta_j=\{A_j,b_j\}$ 的偏导数。链式法则使我们能把偏导数确定为

神经网络梯度的深入讨论见 Justin Domke 讲义

$$\frac{\partial L}{\partial \theta_{K-1}}=\frac{\partial L}{\partial f_K}\frac{\partial f_K}{\partial \theta_{K-1}} \tag{5.115}$$

$$\frac{\partial L}{\partial \theta_{K-2}}=\frac{\partial L}{\partial f_K}\frac{\partial f_K}{\partial f_{K-1}}\frac{\partial f_{K-1}}{\partial \theta_{K-2}} \tag{5.116}$$

$$\frac{\partial L}{\partial \theta_{K-3}}=\frac{\partial L}{\partial f_K}\frac{\partial f_K}{\partial f_{K-1}}\frac{\partial f_{K-1}}{\partial f_{K-2}}\frac{\partial f_{K-2}}{\partial \theta_{K-3}} \tag{5.117}$$

$$\frac{\partial L}{\partial \theta_i}=\frac{\partial L}{\partial f_K}\frac{\partial f_K}{\partial f_{K-1}}\cdots\frac{\partial f_{i+2}}{\partial f_{i+1}}\frac{\partial f_{i+1}}{\partial \theta_i} \tag{5.118}$$

其中橙色项是某层输出关于其输入的偏导数，而蓝色项是某层输出关于其参数的偏导数。假设我们已经算出了偏导数 $\partial L/\partial\theta_{i+1}$，那么大部分计算都可以复用来计算 $\partial L/\partial\theta_i$。我们需要额外计算的项由方框标出。图 5.9 可视化了梯度如何在网络中反向传递。

原书 p.161

5.6.2　自动微分

事实证明，反向传播是数值分析中一种通用技术——**自动微分**（automatic differentiation）——的一个特例。我们可以把自动微分看作这样一组技术：通过处理中间变量并应用链式法则，来数值地（而非符号地）计算一个函数的精确（达到机器精度）梯度。自动微分应用一系列初等算术运算（如加法和乘法）和初等函数（如 $\sin,\cos,\exp,\log$）。通过对这些运算应用链式法则，就可以自动地计算相当复杂函数的梯度。自动微分适用于一般的计算机程序，并有前向模式和反向模式。Baydin et al. (2018) 对机器学习中的自动微分做了很好的综述。

自动微分

自动微分不同于符号微分和有限差分

图 5.10 展示了一个简单的图，表示数据经中间变量 a,b 从输入 x 到输出 y 的流。若要计算导数 $\mathrm{d}y/\mathrm{d}x$，我们应用链式法则得到

$$\frac{\mathrm{d}y}{\mathrm{d}x}=\frac{\mathrm{d}y}{\mathrm{d}b}\frac{\mathrm{d}b}{\mathrm{d}a}\frac{\mathrm{d}a}{\mathrm{d}x}\,. \tag{5.119}$$

直观上，前向模式与反向模式的区别在于乘法的顺序。由于矩阵乘法的结合律我们可以在下面两种写法之间选择：

一般情形下处理 Jacobian

$$\frac{\mathrm{d}y}{\mathrm{d}x}=\Big(\frac{\mathrm{d}y}{\mathrm{d}b}\frac{\mathrm{d}b}{\mathrm{d}a}\Big)\frac{\mathrm{d}a}{\mathrm{d}x}\,, \tag{5.120}$$

$$\frac{\mathrm{d}y}{\mathrm{d}x}=\frac{\mathrm{d}y}{\mathrm{d}b}\Big(\frac{\mathrm{d}b}{\mathrm{d}a}\frac{\mathrm{d}a}{\mathrm{d}x}\Big)\,. \tag{5.121}$$

(5.120) 是**反向模式**（reverse mode），因为梯度在图中反向传播，即与数据流相反。(5.121) 是**前向模式**（forward mode），其中梯度随数据从左向右流经图。

前向模式

下面我们聚焦于反向模式自动微分，也就是反向传播。在神经网络的语境中，输入维数往往远高于标签维数，此时反向模式在计算上比前向模式便宜得多。让我们从一个有启发性的例子开始。

例 5.14. 考虑函数

$$f(x)=\sqrt{x^2+\exp(x^2)}+\cos\big(x^2+\exp(x^2)\big) \tag{5.122}$$

（来自 (5.109)）。若要在计算机上实现函数 f，我们可以借助中间变量来节省一些计算：

中间变量

$$a = x^2\,, \tag{5.123}$$
$$b = \exp(a)\,, \tag{5.124}$$
$$c = a + b\,, \tag{5.125}$$
$$d = \sqrt{c}\,, \tag{5.126}$$
$$e = \cos(c)\,, \tag{5.127}$$
$$f = d + e\,. \tag{5.128}$$

这与应用链式法则时的思考过程是同一类。注意上面这组方程比直接实现 (5.109) 所定义的函数 $f(x)$ 所需的运算更少。图 5.11 中相应的计算图展示了为得到函数值 f 所需的数据和计算的流。

包含中间变量的这组方程可看作一个计算图，这是神经网络软件库实现中广泛使用的一种表示。通过回忆初等函数的导数定义，我们可以直接计算中间变量关于其相应输入的导数。我们得到：

原书 p.163

$$\frac{\partial a}{\partial x} = 2x \tag{5.129}$$
$$\frac{\partial b}{\partial a} = \exp(a) \tag{5.130}$$
$$\frac{\partial c}{\partial a} = 1 = \frac{\partial c}{\partial b} \tag{5.131}$$
$$\frac{\partial d}{\partial c} = \frac{1}{2\sqrt{c}} \tag{5.132}$$
$$\frac{\partial e}{\partial c} = -\sin(c) \tag{5.133}$$
$$\frac{\partial f}{\partial d} = 1 = \frac{\partial f}{\partial e}\,. \tag{5.134}$$

观察图 5.11 中的计算图，我们可以从输出向后工作来计算 $\partial f/\partial x$，得到

$$\frac{\partial f}{\partial c} = \frac{\partial f}{\partial d}\frac{\partial d}{\partial c} + \frac{\partial f}{\partial e}\frac{\partial e}{\partial c} \tag{5.135}$$
$$\frac{\partial f}{\partial b} = \frac{\partial f}{\partial c}\frac{\partial c}{\partial b} \tag{5.136}$$
$$\frac{\partial f}{\partial a} = \frac{\partial f}{\partial b}\frac{\partial b}{\partial a} + \frac{\partial f}{\partial c}\frac{\partial c}{\partial a} \tag{5.137}$$
$$\frac{\partial f}{\partial x} = \frac{\partial f}{\partial a}\frac{\partial a}{\partial x}\,. \tag{5.138}$$

注意我们隐含地应用了链式法则来得到 $\partial f/\partial x$。代入初等函数导数的结果，得到

$$\frac{\partial f}{\partial c} = 1 \cdot \frac{1}{2\sqrt{c}} + 1 \cdot (-\sin(c)) \tag{5.139}$$
$$\frac{\partial f}{\partial b} = \frac{\partial f}{\partial c} \cdot 1 \tag{5.140}$$
$$\frac{\partial f}{\partial a} = \frac{\partial f}{\partial b}\exp(a) + \frac{\partial f}{\partial c} \cdot 1 \tag{5.141}$$
$$\frac{\partial f}{\partial x} = \frac{\partial f}{\partial a} \cdot 2x\,. \tag{5.142}$$

把上面每个导数都看作一个变量，我们观察到：计算导数所需的计算量与计算函数本身的计算量相近。这相当反直觉，因为导数 $\partial f/\partial x$ (5.110) 的数学表达式远比 (5.109) 中函数 $f(x)$ 的数学表达式复杂。

自动微分是对例 5.14 的形式化。设 $x_1, \dots, x_d$ 是函数的输入变量，$x_{d+1}, \dots, x_{D-1}$ 是中间变量，x_D 是输出变量。则计算图可表示如下：对 $i = d+1, \dots, D$，

$$x_i = g_i(x_{\mathrm{Pa}(x_i)})\,, \tag{5.143}$$

其中 $g_i(\cdot)$ 是初等函数，$x_{\mathrm{Pa}(x_i)}$ 是图中变量 x_i 的父节点。对这样定义的函数，我们可以用链式法则逐步计算其导数。回忆由定义 $f = x_D$，因而 原书 p.164

$$\frac{\partial f}{\partial x_D} = 1\,. \tag{5.144}$$

对其他变量 x_i，我们应用链式法则

$$\frac{\partial f}{\partial x_i} = \sum_{x_j:\, x_i \in \mathrm{Pa}(x_j)} \frac{\partial f}{\partial x_j}\frac{\partial x_j}{\partial x_i} = \sum_{x_j:\, x_i \in \mathrm{Pa}(x_j)} \frac{\partial f}{\partial x_j}\frac{\partial g_j}{\partial x_i}\,, \tag{5.145}$$

其中 $\mathrm{Pa}(x_j)$ 是计算图中 x_j 的父节点集合。(5.143) 是函数的前向传播，而 (5.145) 是梯度在计算图中的反向传播。对神经网络训练，我们把预测误差关于标签反向传播。

反向模式自动微分需要一棵解析树

只要函数能表示为一个计算图、且其中的初等函数都可微，上述自动微分方法就成立。事实上，该函数甚至不必是一个数学函数，而可以是一个计算机程序。然而，并非所有计算机程序都能自动微分，例如当我们找不到可微的初等函数时。像 for 循环和 if 语句这样的编程结构也需要更加小心处理。

5.7　高阶导数

到此为止，我们讨论了梯度，即一阶导数。有时我们对高阶导数感兴趣，例如当我们想用 Newton 法做优化时，它需要二阶导数（Nocedal and Wright, 2006）。在第 5.1.1 节，我们讨论了用多项式来近似函数的 Taylor 级数。在多元情形下，我们完全可以照做。下面我们就这么做。但先从一些记号开始。

考虑二元函数 $f : \mathbb{R}^2 \to \mathbb{R}$，自变量为 x, y。我们对高阶偏导数（以及梯度）使用如下记号：

- $\dfrac{\partial^2 f}{\partial x^2}$ 是 f 关于 x 的二阶偏导数。
- $\dfrac{\partial^n f}{\partial x^n}$ 是 f 关于 x 的 n 阶偏导数。
- $\dfrac{\partial^2 f}{\partial y\,\partial x} = \dfrac{\partial}{\partial y}\left(\dfrac{\partial f}{\partial x}\right)$ 是先关于 x 求偏导、再关于 y 求偏导所得的偏导数。
- $\dfrac{\partial^2 f}{\partial x\,\partial y}$ 是先关于 y 求偏导、再关于 x 求偏导所得的偏导数。

Hessian（海森矩阵）是所有二阶偏导数的汇集。

Hessian
原书 p.165

若 $f(x,y)$ 是二阶（连续）可微函数，则

$$\frac{\partial^2 f}{\partial x\,\partial y} = \frac{\partial^2 f}{\partial y\,\partial x}\,, \tag{5.146}$$

即求导顺序无关，相应的 **Hessian 矩阵**

Hessian矩阵

$$H = \begin{bmatrix} \frac{\partial^2 f}{\partial x^2} & \frac{\partial^2 f}{\partial x\,\partial y} \\ \frac{\partial^2 f}{\partial x\,\partial y} & \frac{\partial^2 f}{\partial y^2} \end{bmatrix} \tag{5.147}$$

是对称的。Hessian 记为 $\nabla^2_{x,y} f(x,y)$。一般地，对 $x \in \mathbb{R}^n$、$f : \mathbb{R}^n \to \mathbb{R}$，Hessian 是一个 $n \times n$ 矩阵。Hessian 度量函数在 (x,y) 附近局部的曲率。

注 (向量场的 Hessian). 若 $f : \mathbb{R}^n \to \mathbb{R}^m$ 是向量场, 则 Hessian 是一个 $(m \times n \times n)$-张量。

5.8　线性化与多元 Taylor 级数

函数 f 的梯度 ∇f 常用于在 x_0 附近对 f 做局部线性近似:

$$f(x) \approx f(x_0) + (\nabla_x f)(x_0)(x - x_0)\,. \tag{5.148}$$

这里 $(\nabla_x f)(x_0)$ 是 f 关于 x 的梯度在 x_0 处的取值。图 5.12 展示了函数 f 在输入 x_0 处的线性近似。原函数被一条直线近似。这种近似在局部是准确的，但离 x_0 越远，近似就越差。(5.148) 是 f 在 x_0 处多元 Taylor 级数展开的一个特例，其中我们只取前两项。下面讨论更一般的情形，它能给出更好的近似。

原书 p.166

定义 5.7 (多元 Taylor 级数)**.** 我们考虑函数

$$f : \mathbb{R}^D \to \mathbb{R} \tag{5.149}$$

$$x \mapsto f(x), \qquad x \in \mathbb{R}^D\,, \tag{5.150}$$

它在 x_0 处光滑。定义差向量 $\delta := x - x_0$，则 f 在 x_0 处的**多元 Taylor 级数**（multivariate Taylor series）定义为

多元 Taylor 级数

$$f(x) = \sum_{k=0}^{\infty} \frac{D^k_x f(x_0)}{k!}\delta^k\,, \tag{5.151}$$

其中 $D^k_x f(x_0)$ 是 f 关于 x 的第 k 阶（全）导数在 x_0 处的取值。

定义 5.8 (Taylor 多项式)**.** f 在 x_0 处的 n 次 **Taylor 多项式**（Taylor polynomial）包含 (5.151) 中级数的前 $n+1$ 项，定义为

Taylor 多项式

$$T_n(x) = \sum_{k=0}^{n} \frac{D^k_x f(x_0)}{k!}\delta^k\,. \tag{5.152}$$

在 (5.151) 和 (5.152) 中，我们使用了 δ^k 这一略显随意的记号，它对向量 $x \in \mathbb{R}^D$（$D > 1$、$k > 1$）并未定义。注意 $D_x^k f$ 和 δ^k 都是 k 阶张量，即 k 维数组。k 阶张量 $\delta^k \in \mathbb{R}^{\underbrace{D \times D \times \cdots \times D}_{k\text{次}}}$ 由向量 $\delta \in \mathbb{R}^D$ 的 k 重外积（记为 $\otimes$）得到。例如，

向量是一维数组，矩阵是二维数组

$$\delta^2 := \delta \otimes \delta = \delta\delta^\top, \qquad \delta^2[i,j] = \delta[i]\delta[j] \tag{5.153}$$

原书 p.167

$$\delta^3 := \delta \otimes \delta \otimes \delta, \qquad \delta^3[i,j,k] = \delta[i]\delta[j]\delta[k]\,. \tag{5.154}$$

图 5.13 可视化了两个这样的外积。一般地，我们得到 Taylor 级数中的各项

$$D_x^k f(x_0)\delta^k = \sum_{i_1=1}^{D} \cdots \sum_{i_k=1}^{D} D_x^k f(x_0)[i_1, \ldots, i_k]\, \delta[i_1] \cdots \delta[i_k] \tag{5.155}$$

其中 $D_x^k f(x_0)\delta^k$ 包含 k 次多项式。

既然已经为向量场定义了 Taylor 级数，让我们显式写出 $k = 0, \ldots, 3$ 时 Taylor 级数展开的前几项 $D_x^k f(x_0)\delta^k$，其中 $\delta := x - x_0$：

$$k = 0: \quad D_x^0 f(x_0)\delta^0 = f(x_0) \in \mathbb{R} \tag{5.156}$$

np.einsum('i,i',Df1,d)

$$k = 1: \quad D_x^1 f(x_0)\delta^1 = \underbrace{\nabla_x f(x_0)}_{\in \mathbb{R}^{1\times D}} \underbrace{\delta}_{\in \mathbb{R}^{D\times 1}} = \sum_{i=1}^{D} \nabla_x f(x_0)[i]\delta[i] \in \mathbb{R} \tag{5.157}$$

$$k = 2: \quad D_x^2 f(x_0)\delta^2 = \operatorname{tr}\big(\underbrace{H(x_0)}_{\in \mathbb{R}^{D\times D}} \underbrace{\delta}_{\in \mathbb{R}^{D\times 1}} \underbrace{\delta^\top}_{\in \mathbb{R}^{1\times D}}\big) = \delta^\top H(x_0)\delta \tag{5.158}$$

np.einsum('ij,i,j',Df2,d,d)

$$= \sum_{i=1}^{D}\sum_{j=1}^{D} H[i,j]\delta[i]\delta[j] \in \mathbb{R} \tag{5.159}$$

np.einsum('ijk,i,j,k',Df3,d,d,d)

$$k = 3: \quad D_x^3 f(x_0)\delta^3 = \sum_{i=1}^{D}\sum_{j=1}^{D}\sum_{k=1}^{D} D_x^3 f(x_0)[i,j,k]\delta[i]\delta[j]\delta[k] \in \mathbb{R} \tag{5.160}$$

这里 $H(x_0)$ 是 f 在 x_0 处的 Hessian。

例 5.15 (二元函数的 Taylor 级数展开)**.** 考虑函数

$$f(x,y) = x^2 + 2xy + y^3\,. \tag{5.161}$$

我们想求 f 在 $(x_0, y_0) = (1, 2)$ 处的 Taylor 级数展开。开始前，先讨论一下预期结果：(5.161) 中的函数是一个三次多项式。我们要找的 Taylor 级数展开本身是多项式的线性组合。因此，我们不期望 Taylor 级数展开含有四次或更高次的项

来表示一个三次多项式。这意味着确定 (5.151) 的前四项，就足以得到 (5.161) 的一个精确的替代表示。

为确定 Taylor 级数展开，我们从常数项和一阶导数开始，它们为

$$f(1,2) = 13 \tag{5.162}$$

原书 p.168

$$\frac{\partial f}{\partial x} = 2x + 2y \quad \Longrightarrow \quad \frac{\partial f}{\partial x}(1,2) = 6 \tag{5.163}$$

$$\frac{\partial f}{\partial y} = 2x + 3y^2 \quad \Longrightarrow \quad \frac{\partial f}{\partial y}(1,2) = 14\,. \tag{5.164}$$

因此，我们得到

$$D^1_{x,y} f(1,2) = \nabla_{x,y} f(1,2) = \left[\frac{\partial f}{\partial x}(1,2)\ \frac{\partial f}{\partial y}(1,2)\right] = \begin{bmatrix}6 & 14\end{bmatrix} \in \mathbb{R}^{1\times 2} \tag{5.165}$$

于是

$$\frac{D^1_{x,y} f(1,2)}{1!}\delta = \begin{bmatrix}6 & 14\end{bmatrix}\begin{bmatrix}x-1\\ y-2\end{bmatrix} = 6(x-1) + 14(y-2)\,. \tag{5.166}$$

注意 $D^1_{x,y} f(1,2)\delta$ 只含线性项，即一次多项式。

二阶偏导数为

$$\frac{\partial^2 f}{\partial x^2} = 2 \quad \Longrightarrow \quad \frac{\partial^2 f}{\partial x^2}(1,2) = 2 \tag{5.167}$$

$$\frac{\partial^2 f}{\partial y^2} = 6y \quad \Longrightarrow \quad \frac{\partial^2 f}{\partial y^2}(1,2) = 12 \tag{5.168}$$

$$\frac{\partial^2 f}{\partial y\,\partial x} = 2 \quad \Longrightarrow \quad \frac{\partial^2 f}{\partial y\,\partial x}(1,2) = 2 \tag{5.169}$$

$$\frac{\partial^2 f}{\partial x\,\partial y} = 2 \quad \Longrightarrow \quad \frac{\partial^2 f}{\partial x\,\partial y}(1,2) = 2\,. \tag{5.170}$$

汇集二阶偏导数，得到 Hessian

$$H = \begin{bmatrix}\frac{\partial^2 f}{\partial x^2} & \frac{\partial^2 f}{\partial x\,\partial y}\\ \frac{\partial^2 f}{\partial y\,\partial x} & \frac{\partial^2 f}{\partial y^2}\end{bmatrix} = \begin{bmatrix}2 & 2\\ 2 & 6y\end{bmatrix}, \tag{5.171}$$

于是

$$H(1,2) = \begin{bmatrix}2 & 2\\ 2 & 12\end{bmatrix} \in \mathbb{R}^{2\times 2}\,. \tag{5.172}$$

因此，Taylor 级数展开的下一项为

$$\frac{D^2_{x,y} f(1,2)}{2!}\delta^2 = \frac{1}{2}\delta^\top H(1,2)\delta \tag{5.173a}$$

$$= \frac{1}{2}\begin{bmatrix}x-1 & y-2\end{bmatrix}\begin{bmatrix}2 & 2\\ 2 & 12\end{bmatrix}\begin{bmatrix}x-1\\ y-2\end{bmatrix} \tag{5.173b}$$

$$= (x-1)^2 + 2(x-1)(y-2) + 6(y-2)^2\,. \tag{5.173c}$$

这里 $D^2_{x,y}f(1,2)\delta^2$ 只含二次项，即二次多项式。

原书 p.169

三阶导数为

$$D^3_{x,y}f = \left[\frac{\partial H}{\partial x}\ \frac{\partial H}{\partial y}\right] \in \mathbb{R}^{2\times 2\times 2}\,, \tag{5.174}$$

$$D^3_{x,y}f[:,:,1] = \frac{\partial H}{\partial x} = \begin{bmatrix} \frac{\partial^3 f}{\partial x^3} & \frac{\partial^3 f}{\partial x^2 \partial y} \\ \frac{\partial^3 f}{\partial x\,\partial y\,\partial x} & \frac{\partial^3 f}{\partial x\,\partial y^2} \end{bmatrix}, \tag{5.175}$$

$$D^3_{x,y}f[:,:,2] = \frac{\partial H}{\partial y} = \begin{bmatrix} \frac{\partial^3 f}{\partial y\,\partial x^2} & \frac{\partial^3 f}{\partial y\,\partial x\,\partial y} \\ \frac{\partial^3 f}{\partial y^2 \partial x} & \frac{\partial^3 f}{\partial y^3} \end{bmatrix}. \tag{5.176}$$

由于 (5.171) 中 Hessian 的大多数二阶偏导数都是常数，唯一非零的三阶偏导数是

$$\frac{\partial^3 f}{\partial y^3} = 6 \quad\Longrightarrow\quad \frac{\partial^3 f}{\partial y^3}(1,2) = 6\,. \tag{5.177}$$

更高阶导数和三阶混合导数（例如 $\partial^3 f/\partial x^2\partial y$）都为零，于是

$$D^3_{x,y}f[:,:,1] = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}, \qquad D^3_{x,y}f[:,:,2] = \begin{bmatrix} 0 & 0 \\ 0 & 6 \end{bmatrix} \tag{5.178}$$

且

$$\frac{D^3_{x,y}f(1,2)}{3!}\delta^3 = (y-2)^3\,, \tag{5.179}$$

它汇集了 Taylor 级数的所有三次项。总体上，f 在 $(x_0,y_0)=(1,2)$ 处的（精确）Taylor 级数展开为

$$\begin{aligned} f(x) &= f(1,2) + D^1_{x,y}f(1,2)\delta + \frac{D^2_{x,y}f(1,2)}{2!}\delta^2 + \frac{D^3_{x,y}f(1,2)}{3!}\delta^3 && \text{(5.180a)}\\ &= f(1,2) + \frac{\partial f(1,2)}{\partial x}(x-1) + \frac{\partial f(1,2)}{\partial y}(y-2) \\ &\quad + \frac{1}{2!}\Big(\frac{\partial^2 f(1,2)}{\partial x^2}(x-1)^2 + \frac{\partial^2 f(1,2)}{\partial y^2}(y-2)^2 + 2\frac{\partial^2 f(1,2)}{\partial x\,\partial y}(x-1)(y-2)\Big) \\ &\quad + \frac{1}{6}\frac{\partial^3 f(1,2)}{\partial y^3}(y-2)^3 && \text{(5.180b)}\\ &= 13 + 6(x-1) + 14(y-2) + (x-1)^2 + 6(y-2)^2 + 2(x-1)(y-2) + (y-2)^3\,. && \text{(5.180c)} \end{aligned}$$

在本例中，我们得到了 (5.161) 中多项式的精确 Taylor 级数展开，即 (5.180c) 中的多项式与 (5.161) 中的原多项式完全相同。在这个特定例子中，这一结果并不令人意外，因为原函数是一个三次多项式，我们通过 (5.180c) 中常数项、一次、二次和三次多项式的线性组合把它表示了出来。

5.9　延伸阅读

原书 p.170

矩阵微分的更多细节，连同所需线性代数的简短回顾，可参见 Magnus and Neudecker (2007)。自动微分历史悠久，我们推荐 Griewank and Walther (2003)、Griewank and Walther (2008)、Elliott (2009) 及其中的参考文献。

在机器学习（以及其他学科）中，我们常常需要计算期望，即需要求解如下形式的积分：

$$\mathbb{E}_x[f(x)] = \int f(x)p(x)\,\mathrm{d}x\,. \tag{5.181}$$

即使 $p(x)$ 形式简便（例如高斯），该积分一般也无法解析求解。f 的 Taylor 级数展开是求近似解的一种方法：假定 $p(x) = \mathcal{N}(\mu, \Sigma)$ 是高斯分布，则在 μ 附近的一阶 Taylor 级数展开局部地线性化了非线性函数 f。对线性函数，若 $p(x)$ 服从高斯分布，我们可以精确计算其均值（和协方差）（见第 6.5 节）。这一性质被扩展 Kalman 滤波器（extended Kalman filter）大量用于非线性动力系统（亦称"状态空间模型"）的在线状态估计（Maybeck, 1979）。其他逼近 (5.181) 中积分的确定性方法有 unscented 变换（unscented transform）（Julier and Uhlmann, 1997）它不需要任何梯度；以及 Laplace 近似（Laplace approximation）（MacKay, 2003; Bishop, 2006; Murphy, 2012），它使用二阶 Taylor 级数展开（需要 Hessian），在 $p(x)$ 的众数附近做局部高斯近似。

扩展 Kalman 滤波 cented变换 lace近似

习题

1. 求 $f'(x)$，其中 $f(x) = \log(x^4)\sin(x^3)$。
2. 求 logistic sigmoid $f(x) = \dfrac{1}{1+\exp(-x)}$ 的导数 $f'(x)$。
3. 求函数 $f(x) = \exp\Big(-\dfrac{1}{2\sigma^2}(x-\mu)^2\Big)$ 的导数 $f'(x)$，其中 $\mu, \sigma \in \mathbb{R}$ 为常数。
4. 求 $f(x) = \sin(x) + \cos(x)$ 在 $x_0 = 0$ 处的 Taylor 多项式 T_n（$n = 0, \ldots, 5$）。
5. 考虑下列函数：

$$\begin{aligned} f_1(x) &= \sin(x_1)\cos(x_2), & x &\in \mathbb{R}^2 \\ f_2(x, y) &= x^\top y, & x, y &\in \mathbb{R}^n \\ f_3(x) &= xx^\top, & x &\in \mathbb{R}^n \end{aligned}$$

原书 p.171

   (a) $\partial f_i/\partial x$ 的维数各是多少?

   (b) 计算各 Jacobian。

6. 对 t 求 f 的导，对 X 求 g 的导，其中

$$\begin{aligned} f(t) &= \sin(\log(t^\top t)), & t &\in \mathbb{R}^D \\ g(X) &= \mathrm{tr}(AXB), & A &\in \mathbb{R}^{D\times E},\ X \in \mathbb{R}^{E\times F},\ B \in \mathbb{R}^{F\times D}, \end{aligned}$$

   其中 $\mathrm{tr}(\cdot)$ 表示迹。

7. 用链式法则计算下列函数的导数 $\mathrm{d}f/\mathrm{d}x$。给出每个偏导数的维数。详细描述你的步骤。

(a) $f(z) = \log(1+z), \quad z = x^\top x, \quad x \in \mathbb{R}^D$

(b) $f(z) = \sin(z), \quad z = Ax + b, \quad A \in \mathbb{R}^{E\times D},\ x \in \mathbb{R}^D,\ b \in \mathbb{R}^E$，其中 $\sin(\cdot)$ 作用于 z 的每个元素。

8. 计算下列函数的导数 $\mathrm{d}f/\mathrm{d}x$。详细描述你的步骤。

(a) 用链式法则。给出每个偏导数的维数。

$$f(z) = \exp\Big(-\frac{1}{2}z\Big), \qquad z = g(y) = y^\top S^{-1} y, \qquad y = h(x) = x - \mu$$

其中 $x, \mu \in \mathbb{R}^D$、$S \in \mathbb{R}^{D\times D}$。

(b) $f(x) = \mathrm{tr}(xx^\top + \sigma^2 I), \quad x \in \mathbb{R}^D$。这里 $\mathrm{tr}(A)$ 是 A 的迹，即对角线元素 A_{ii} 之和。提示：显式写出外积。

(c) 用链式法则。给出每个偏导数的维数。你不需要显式计算偏导数的乘积。

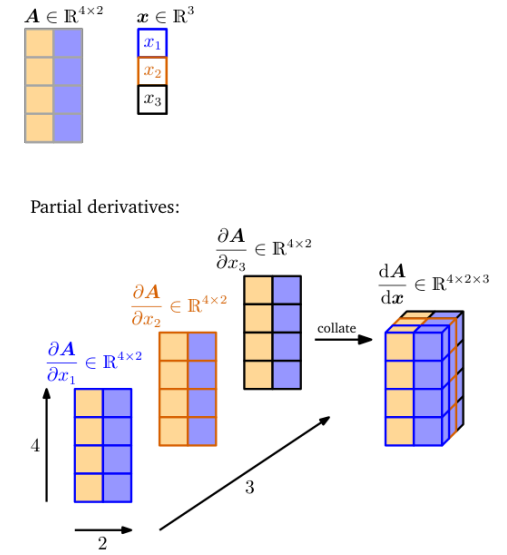
$$f = \tanh(z) \in \mathbb{R}^M, \qquad z = Ax+b, \qquad x \in \mathbb{R}^N,\ A \in \mathbb{R}^{M\times N},\ b \in \mathbb{R}^M.$$

这里 tanh 作用于 z 的每个分量。

9. 我们定义

$$g(x, z, \nu) := \log p(x, z) - \log q(z, \nu), \qquad z := t(\epsilon, \nu)$$

其中 p, q, t 为可微函数，$x \in \mathbb{R}^D$、$z \in \mathbb{R}^E$、$\nu \in \mathbb{R}^F$、$\epsilon \in \mathbb{R}^G$。用链式法则计算梯度 $\dfrac{\mathrm{d}}{\mathrm{d}\nu} g(x, z, \nu)$。



(a) Approach 1: We compute the partial derivative $\frac{\partial \boldsymbol{A}}{\partial x_1}, \frac{\partial \boldsymbol{A}}{\partial x_2}, \frac{\partial \boldsymbol{A}}{\partial x_3}$, each of which is a 4×2 matrix, and collate them in a $4 \times 2 \times 3$ tensor.

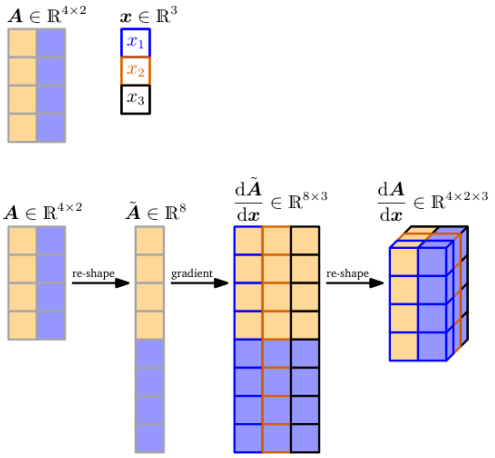


图 5.7: 矩阵关于向量求梯度的示意。我们想计算 $A \in \mathbb{R}^{4\times2}$ 关于向量 $x \in \mathbb{R}^3$ 的梯度。已知 $\mathrm{d}A/\mathrm{d}x \in \mathbb{R}^{4\times2\times3}$。我们用两种等价途径得到它：(a) 把偏导数汇集为 Jacobian 张量；(b) 把矩阵展平为向量，算出 Jacobian 矩阵，再重塑为 Jacobian 张量（对应原图 Figure 5.7）。

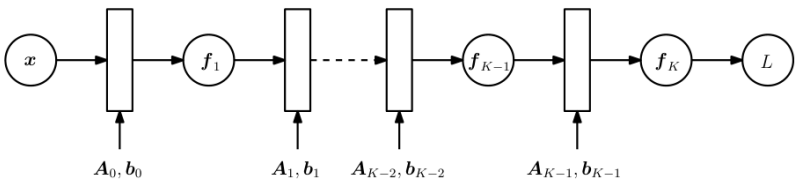


图 5.8: 多层神经网络中的前向传播，用以计算损失 L（它是输入 x 和参数 A_i, b_i 的函数）（对应原图 Figure 5.8）。

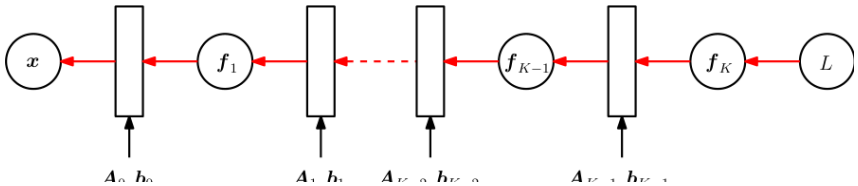


图 5.9: 多层神经网络中的反向传播, 用以计算损失函数的梯度（对应原图 Figure 5.9）。

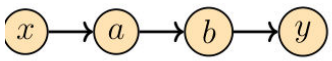


图 5.10: 说明数据如何经中间变量 a, b 从 x 流向 y 的简单图（对应原图 Figure 5.10）。

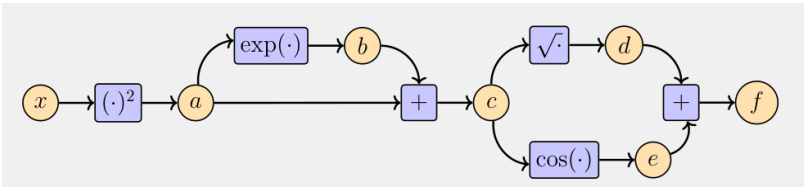


图 5.11: 计算图，含输入 x、函数值 f 和中间变量 a, b, c, d, e（对应原图 Figure 5.11）。

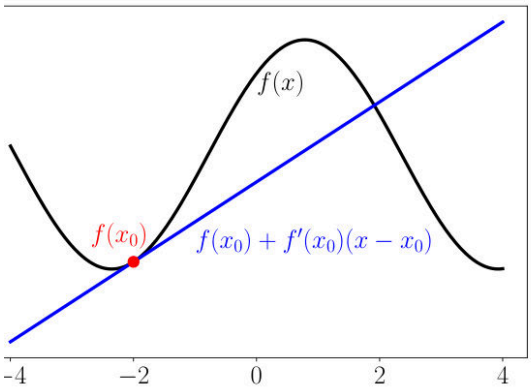
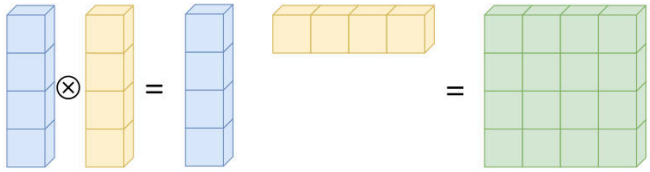
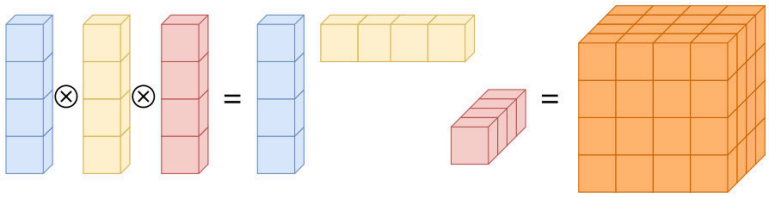


图 5.12: 函数的线性近似。原函数 f 在 $x_0 = -2$ 处用一阶 Taylor 级数展开做了线性化（对应原图 Figure 5.12）。



(a) Given a vector $\boldsymbol{\delta} \in \mathbb{R}^4$, we obtain the outer product $\boldsymbol{\delta}^2 := \boldsymbol{\delta} \otimes \boldsymbol{\delta} = \boldsymbol{\delta}\boldsymbol{\delta}^\top \in \mathbb{R}^{4\times 4}$ as a matrix.



(b) An outer product $\boldsymbol{\delta}^3 := \boldsymbol{\delta} \otimes \boldsymbol{\delta} \otimes \boldsymbol{\delta} \in \mathbb{R}^{4\times 4\times 4}$ results in a third-order tensor ("three-dimensional matrix"), i.e., an array with three indexes.

图 5.13: 可视化外积。向量的外积每做一项就使数组的维数增加 1。(a) 两个向量的外积得到一个矩阵；(b) 三个向量的外积得到一个三阶张量（对应原图 Figure 5.13）。

第 6 章　概率与分布

原书 p.172

粗略地说，概率论研究的是不确定性。概率可以理解为某事件发生的频率，也可以理解为我们对某事件所持的置信程度。于是我们希望用这一概率来度量在一次试验中某件事发生的可能性。如第 1 章所述，我们常常要量化数据中的不确定性、机器学习模型中的不确定性，以及模型所产生预测的不确定性。量化不确定性需要借助随机变量这一概念，它是一个把随机试验的结果映射到我们所关心的一组性质上的函数。与随机变量相伴的还有一个函数，用于度量某一特定结果（或结果集合）发生的可能性，这就是概率分布。

随机变量

概率分布

概率分布被用作许多其他概念的基石，例如概率建模（第 8.4 节）、图模型（第 8.5 节）以及模型选择（第 8.6 节）。下一节中，我们给出定义一个概率空间所需的三个概念（样本空间、事件以及事件的概率），并说明它们如何与第四个概念——随机变量——相联系。这里的叙述有意写得略显模糊，因为过于严谨的表述反而会掩盖这些概念背后的直观。图 6.1 给出了本章所述概念的提纲。

原书 p.173

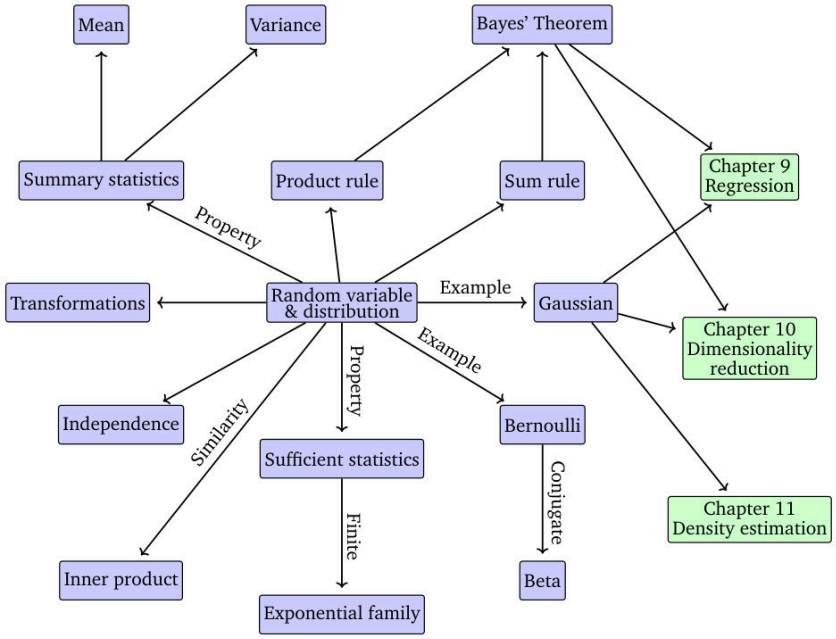


图 6.1: 与随机变量和概率分布相关概念的思维导图，如本章所述（对应原图 Figure 6.1）。

6.1　构造概率空间

概率论旨在定义一个数学结构，用以描述试验的随机结果。例如，抛掷一枚硬币时我们无法预知结果，但在大量重复抛掷之后，可以观察到平均结果上的某种规律性。借助这一概率的数学结构，目标是进行自动推理；在这个意义上，概率把逻辑推理推广了（Jaynes, 2003）。

6.1.1　哲学问题

在构造自动推理系统时，经典布尔逻辑无法表达某些形式的似真推理。考虑下面的情形：我们观察到 A 为假，于是觉得 B 变得不那么可信，尽管从经典逻辑中并不能得出任何结论。我们观察到 B 为真，于是觉得 A 变得更可信。我们每天都在使用这种推理。假设我们在等一位朋友，并考虑三种可能：H_1，她准时；H_2，她因堵车而耽搁；H_3，她被外星人绑架了。当我们观察到朋友迟到时，必须在逻辑上排除 H_1；我们也倾向于认为 H_2 更可能，尽管逻辑上并不要求如此；最后，我们也许认为 H_3 并非不可能，但仍觉得它相当不可能。我们是如何断定 H_2 是最可信答案的呢？这样看来，概率论可以看作布尔逻辑的推广。在机器学习的语境中，它常常被用来把自动推理系统的设计形式化。关于概率论为何是推理系统之基础的进一步论证，可参见 Pearl (1988)。

（Jaynes, 2003　“似真推理需把真假连续化”

概率的哲学基础，以及它应如何与我们（在逻辑意义上）认为应当为真的东西相联系，曾由 Cox 研究（Jaynes, 2003）。另一种看法是：只要我们把自己的常识刻画得足够精确，最终就会构造出概率。E. T. Jaynes（1922–1998）给出了三条必须适用于所有似信度（plausibility）的数学准则：

1. 似信度由实数表示。
2. 这些数必须基于常识规则。

原书 p.174

3. 由此得到的推理必须是一致的，这里“一致”有如下三层含义：
   (a) 一致性/无矛盾：当经由不同途径得到同一结果时，在所有情形下都必须得到相同的似信度值。
   (b) 诚实性：必须考虑所有可用数据。
   (c) 可复现性：若我们对两个问题的认知状态相同，就必须赋予二者相同的似信度。

Cox–Jaynes 定理证明了：这些似信度足以定义一套普适的数学规则，它适用于似信度 p，只差任意一个单调函数的变换。关键在于，这些规则正是概率的规则。

注. 在机器学习与统计学中，概率有两种主要解释：贝叶斯解释与频率派解释（Bishop, 2006; Efron and Hastie, 2016）。贝叶斯解释用概率来刻画用户对某事件所持的不确定性程度，有时被称为“主观概率”或“置信度”。频率派解释考察所关心事件的发生次数占全部已发生事件总数的相对频率；一个事件的概率被定义为数据趋于无穷时该事件相对频率的极限。

一些讨论概率模型的机器学习教材使用了含混的记号和行话，令人困惑；本书也不例外。多个不同概念都被笼统地称为“概率分布”，读者往往需要从上下文去辨别其含

义。一个帮助理解概率分布的小技巧是：先判断我们要建模的是离散的东西（离散随机变量）还是连续的东西（连续随机变量）。机器学习中处理的问题类型，与我们采用离散模型还是连续模型密切相关。

6.1.2 概率与随机变量

讨论概率时，有三个常被混淆的不同概念。其一是概率空间，它使我们能够量化概率这一概念。但我们大多并不直接在这个基础概率空间上工作，而是使用随机变量（第二个概念），它把概率转移到一个更方便（通常是数值）的空间上。第三个概念是与随机变量相联系的分布或规律（law）。本节介绍前两个概念，第三个概念在第 6.2 节展开。

原书 p.175

现代概率论建立在 Kolmogorov 提出的一组公理之上（Grinstead and Snell, 1997; Jaynes, 2003），它引入样本空间、事件空间和概率测度三个概念。概率空间对一个带有随机结果的现实过程（称为一次试验）进行建模。

样本空间

样本空间 Ω　样本空间是试验所有可能结果的集合，通常记作 Ω。例如，连续抛掷两次硬币的样本空间为 $\{hh, tt, ht, th\}$，其中“h”表示“正面”，“t”表示“反面”。

事件空间

事件空间 $\mathcal{A}$　事件空间是试验潜在结果的空间。样本空间 Ω 的一个子集 A 属于事件空间 $\mathcal{A}$，当且仅当试验结束后我们能够观察某一特定结果 $\omega \in \Omega$ 是否属于 A。事件空间 $\mathcal{A}$ 由收集 Ω 的所有子集而得；对于离散概率分布（第 6.2.1 节），$\mathcal{A}$ 通常就是 Ω 的幂集。

概率

概率 P　对每个事件 $A \in \mathcal{A}$，我们赋予一个数 $P(A)$，用以度量该事件发生的概率或置信度。$P(A)$ 称为 A 的概率。单个事件的概率必须落在区间 $[0, 1]$ 内，而样本空间 Ω 上所有结果的总概率必须为 1，即 $P(\Omega) = 1$。给定一个概率空间 $(\Omega, \mathcal{A}, P)$，我们想用它来建模某个现实现象。在机器学习中，我们常常避免显式提及概率空间，而是直接谈论我们所关心的量上的概率，并把这些量记作 $\mathcal{T}$。本书把 $\mathcal{T}$ 称为目标空间，把 $\mathcal{T}$ 中的元素称为状态。我们引入一个函数 $X : \Omega \to \mathcal{T}$，它取 Ω 中的一个元素（一个结果）返回某个特定的待求量 x，即 $\mathcal{T}$ 中的一个值。这个从 Ω 到 $\mathcal{T}$ 的对应/映射称为随机变量。例如，在抛掷两枚硬币并数正面次数的情形中，随机变量 X 映射到三个可能结果 $X(hh) = 2$，$X(ht) = 1$，$X(th) = 1$，$X(tt) = 0$。在这个特例中 $\mathcal{T} = \{0, 1, 2\}$，而我们真正关心的是 $\mathcal{T}$ 中各元素上的概率。对于有限样本空间 Ω 和有限 $\mathcal{T}$，随机变量所对应的函数本质上就是一张查表。对任意子集 $S \subseteq \mathcal{T}$，我们把 $P_X(S) \in [0, 1]$（概率）与随机变量 X 对应的某一特定事件联系起来。例 6.1 给出了这些术语的具体说明。

目标空间

随机变量

注. 遗憾的是，前面提到的样本空间 Ω 在不同书中有不同叫法。Ω 另一个常见名称是“状态空间”（Jacod and Protter, 2004），但“状态空间”有时又被保留用来指动力系统中的状态（Hasselblatt and Katok, 2003）。用来称呼 Ω 的其他名字还有：“样本描述空间”“可能空间”和“事件空间”。

“随机变量”名不副实：它既不随机也不是变量，而是函数。

例 6.1 (抛硬币式的玩具试验)**.** 我们假定读者已经熟悉事件集合的交与并的概率计算 Walpole et al. (2011) 第 2 章给出了一个更温和、含大量例子的概率入门。

考虑一个统计试验：我们建模一个游园游戏，即从一个袋子中有放回地摸出两枚硬币。袋中有来自美国（记作 \$）和来自英国（记作 $）的硬币；由于摸两次，共有四种结果。该试验的状态空间或样本空间 Ω 为 $(\$, \$), (\$, \$), (\$, \$), (\$, \$)$。设袋中硬币的构成使得每次摸出 \$ 的概率为 0.3。

我们关心的事件是重复摸币返回 \$ 的总次数。定义随机变量 X，把样本空间 Ω 映射到 $\mathcal{T}$，$\mathcal{T}$ 表示从袋中摸出 \$ 的次数。由上面的样本空间可知，我们可能摸到零个 \$、

一个 $ 或两个 $，因此 $\mathcal{T} = \{0, 1, 2\}$。随机变量 X（一个函数或查表）可表示为如下表格：

$$X((\$, \$)) = 2 \tag{6.1}$$
$$X((\$, \$)) = 1 \tag{6.2}$$
$$X((\$, \$)) = 1 \tag{6.3}$$
$$X((\$, \$)) = 0\,. \tag{6.4}$$

由于摸出第一枚后放回再摸第二枚，这意味着两次摸币相互独立，我们将在第 6.4.5 节讨论。注意有两个试验结果映射到同一事件——两次中恰有一次摸出 $。因此 X 的概率质量函数（第 6.2.1 节）为

$$P(X = 2) = P((\$, \$)) = P(\$) \cdot P(\$) = 0.3 \cdot 0.3 = 0.09 \tag{6.5}$$
$$\begin{aligned} P(X = 1) &= P((\$, \$) \cup (\$, \$)) = P((\$, \$)) + P((\$, \$)) \\ &= 0.3(1 - 0.3) + (1 - 0.3) \cdot 0.3 = 0.42 \end{aligned} \tag{6.6}$$
$$P(X = 0) = P((\$, \$)) = P(\$) \cdot P(\$) = (1 - 0.3)^2 = 0.49\,. \tag{6.7}$$

在上述计算中，我们把两个不同的概念等同了起来：X 的输出的概率与 Ω 中样本的概率。例如在 (6.7) 中我们写 $P(X = 0) = P((\$, \$))$。考虑随机变量 $X : \Omega \to \mathcal{T}$ 和一个子集 $S \subseteq \mathcal{T}$（例如 $\mathcal{T}$ 的单个元素，如抛两枚硬币得到一个正面这一结果）。令 $X^{-1}(S)$ 为 S 在 X 下的原像，即 Ω 中在 X 下映射到 S 的元素集合；$\{\omega \in \Omega : X(\omega) \in S\}$。理解概率如何经由随机变量 X 从 Ω 中的事件迁移的一种方式，是把它与 S 的原像的概率联系起来（Jacod and Protter, 2004）。对 $S \subseteq \mathcal{T}$，我们有记号

原书 p.177

$$P_X(S) = P(X \in S) = P(X^{-1}(S)) = P(\{\omega \in \Omega : X(\omega) \in S\})\,. \tag{6.8}$$

(6.8) 的左端是我们所关心的、可能结果集合的概率（例如 $ 的个数 $= 1$）。经由把状态映射到结果的随机变量 X，我们在 (6.8) 的右端看到，这是 Ω 中具有该性质的状态集合（例如 $\$, \$$）的概率。我们说随机变量 X 服从某一特定概率分布 P_X，它定义了事件与随机变量输出的概率之间的映射。换言之，函数 P_X（等价地 $P \circ X^{-1}$）就是随机变量 X 的规律或分布。

规律/ 分布

注. 目标空间，即随机变量 X 的值域 $\mathcal{T}$，被用来指示概率空间的种类，即“$\mathcal{T}$ 型随机变量”。当 $\mathcal{T}$ 有限或可数无穷时，称为离散随机变量（第 6.2.1 节）。对于连续随机变量（第 6.2.2 节），我们只考虑 $\mathcal{T} = \mathbb{R}$ 或 $\mathcal{T} = \mathbb{R}^D$。

6.1.3　统计学

概率论与统计学常被放在一起介绍，但它们关注不确定性的不同侧面。区分二者的一种方式是看所处理的问题类型。用概率论，我们可以考虑某个过程的模型，其中潜在的不确定性由随机变量刻画，再用概率规则推导会发生什么。在统计学中，我们观察到某件事已经发生，试图找出能解释这些观察的潜在过程。在这个意义上，机器学习与统计学目标相近：构造一个能充分表示生成数据之过程的模型。我们可以用概率规则为某些数据求得一个“最佳拟合”模型。

机器学习系统的另一个方面是我们关注泛化误差（见第 8 章）。这意味着我们真正关心的是系统在将来才会观察到的实例上的表现，这些实例与我们目前所见并不相同。这种对未来表现的分析依赖于概率论与统计学，其中大部分超出本章范围。感兴趣的读者可参阅 Boucheron et al. (2013) 与 Shalev-Shwartz and Ben-David (2014) 的著作。我们将在第 8 章更多地讨论统计学。

原书 p.178

6.2　离散与连续概率

让我们把注意力集中于第 6.1 节所述描述事件概率的方式。根据目标空间是离散还是连续，称呼分布的自然方式也不同。当目标空间 $\mathcal{T}$ 离散时，我们可以指定随机变量 X 取某一特定值 $x \in \mathcal{T}$ 的概率，记作 $P(X = x)$。对离散随机变量 X，$P(X = x)$ 称为概率质量函数。当目标空间 $\mathcal{T}$ 连续时（例如实直线 $\mathbb{R}$），更自然的做法是指定随机变量 X 落在某区间内的概率，对 $a < b$ 记作 $P(a \leq X \leq b)$。按惯例，我们指定随机变量 X 小于某一特定值 x 的概率，记作 $P(X \leq x)$。对连续随机变量 X，$P(X \leq x)$ 称为累积分布函数。我们将在第 6.2.2 节讨论连续随机变量，并在第 6.2.3 节回到术语、对比离散与连续随机变量。

概率质量函数

累积分布函数

注. 我们用“单变量分布”一词指单个随机变量（其状态用非粗体 x 表示）的分布；用“多变量分布”指多个随机变量的分布，并通常考虑随机变量组成的向量（其状态用粗体 $\boldsymbol{x}$ 表示）。

单变量

多变量

6.2.1　离散概率

当目标空间离散时，我们可以把多个随机变量的概率分布想象为填满一个（多维）数值数组。图 6.2 给出了一个例子。联合概率的目标空间是各随机变量目标空间的笛卡儿积。我们把联合概率定义为两个取值联合出现的条目

$$P(X = x_i, Y = y_j) = \frac{n_{ij}}{N}\,, \tag{6.9}$$

其中 n_{ij} 是状态为 x_i 且 y_j 的事件数，N 是事件总数。联合概率是两个事件交的概率，即 $P(X = x_i, Y = y_j) = P(X = x_i \cap Y = y_j)$。图 6.2 展示了一个离散概率分布的概率质量函数（pmf）。

原书 p.179

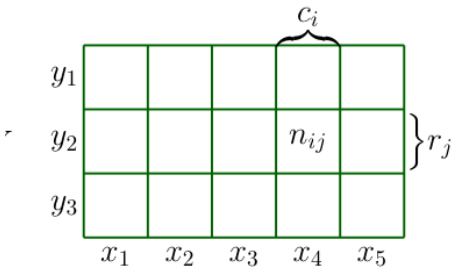


图 6.2: 离散二元概率质量函数的可视化, 含随机变量 X 与 Y。此图改编自 Bishop (2006)（对应原图 Figure 6.2）。

对两个随机变量 X 和 Y，$X = x$ 且 $Y = y$ 的概率（含混地）写作 $p(x, y)$，称为联合概率。可以把概率看作一个以状态 x, y 为输入、返回实数的函数，这也是我们写成 $p(x, y)$ 的原因。X 取 x 值而不论随机变量 Y 取何值的边缘概率（含混地）写作 $p(x)$。我们写 $X \sim p(x)$ 表示随机变量 X 服从 $p(x)$。若只考察 $X = x$ 的样本，则其中 $Y = y$ 所占比例（条件概率）（含混地）写作 $p(y \mid x)$。

联合概率

边缘概率

条件概率

例 6.2 (二维列联表)**.** 考虑两个随机变量 X 与 Y，其中 X 有五个可能状态，Y 有三个可能状态，如图 6.2 所示。用 n_{ij} 表示状态为 $X = x_i$ 且 $Y = y_j$ 的事件数，N 表示事件总数。c_i 是第 i 列各频数之和，即 $c_i = \sum_{j=1}^{3} n_{ij}$；类似地，$r_j$ 是行和，即 $r_j = \sum_{i=1}^{5} n_{ij}$。利用这些定义，我们可以紧凑地表达 X 与 Y 的分布。

每个随机变量的概率分布，即边缘概率，可看作沿某一行或某一列求和：

$$P(X = x_i) = \frac{c_i}{N} = \frac{\sum_{j=1}^{3} n_{ij}}{N} \tag{6.10}$$

以及

$$P(Y = y_j) = \frac{r_j}{N} = \frac{\sum_{i=1}^{5} n_{ij}}{N}\,, \tag{6.11}$$

其中 c_i 与 r_j 分别是概率表的第 i 列与第 j 行。按惯例，对于事件数有限的离散随机变量，我们假定概率之和为 1，即

$$\sum_{i=1}^{5} P(X = x_i) = 1 \qquad \text{且} \qquad \sum_{j=1}^{3} P(Y = y_j) = 1\,. \tag{6.12}$$

条件概率是某一单元格在一行或一列中所占的比例。例如，给定 X 时 Y 的条件概率为 原书 p.180

$$P(Y = y_j \mid X = x_i) = \frac{n_{ij}}{c_i}\,, \tag{6.13}$$

而给定 Y 时 X 的条件概率为

$$P(X = x_i \mid Y = y_j) = \frac{n_{ij}}{r_j}\,. \tag{6.14}$$

在机器学习中，我们用离散概率分布建模类别变量，即取有限个无序取值的变量。它们可以是类别特征（如预测某人薪水时所取的大学学位），也可以是类别标签（如手写识别时的字母表字母）。离散分布还常用于构造把有限个连续分布组合起来的概率模型（第 11 章）。

类别变量

6.2.2　连续概率

本节考虑实值随机变量，即目标空间为实直线 $\mathbb{R}$ 上的区间。在本书中，我们假装可以像对待有限状态的离散概率空间那样对实随机变量进行运算。然而这种简化在两种情形下并不精确：一是当我们把某件事重复无穷多次时，二是当我们想从一个区间中抽取一个点时。第一种情形出现在讨论机器学习的泛化误差时（第 8 章）；第二种情形出现在讨论连续分布（如第 6.5 节的高斯分布）时。就本书的目的而言，这种不精确性换来的是概率入门的简洁。

注. 在连续空间中，还有两点额外的、违反直觉的技术性细节。第一，所有子集构成的集合（用于在第 6.1 节定义事件空间 $\mathcal{A}$）性质不够好；$\mathcal{A}$ 需要加以限制，使其在取补集、交和并下都表现良好。第二，一个集合的大小（在离散空间中可通过数元素得到）结果并不简单。集合的大小称为它的测度。例如离散集合的基数、$\mathbb{R}$ 中区间的长度、$\mathbb{R}^d$ 中区域的体积，都是测度。在集合运算下表现良好、并且还带有拓扑结构的集合族称为 Borel σ 代数。Betancourt 细致地从集合论出发构造概率空间而不陷入技术细节，见 https://tinyurl.com/yb3t6mfd。更严格的构造可参见 Billingsley (1995) 与 Jacod and Protter (2004)。本书考虑实值随机变量及其相应的 Borel σ 代数；把取值于 $\mathbb{R}^D$ 的随机变量看作实值随机变量组成的向量。

测度

Borelσ 代数

定义 6.1 (概率密度函数)**.** 函数 $f : \mathbb{R}^D \to \mathbb{R}$ 称为**概率密度函数**（pdf），若

概率密度函数

1. 对任意 $x \in \mathbb{R}^D$，$f(x) \geq 0$；
2. 其积分存在，且

$$\int_{\mathbb{R}^D} f(x)\,\mathrm{d}x = 1\,. \tag{6.15}$$

对离散随机变量的概率质量函数（pmf），(6.15) 中的积分换成求和 (6.12)。

注意概率密度函数就是任意一个非负、且积分为 1 的函数。我们把随机变量 X 与这个函数 f 通过下式相联系：

$$P(a \leq X \leq b) = \int_a^b f(x)\,\mathrm{d}x\,, \tag{6.16}$$

其中 $a, b \in \mathbb{R}$、$x \in \mathbb{R}$ 是连续随机变量 X 的取值。状态 $x \in \mathbb{R}^D$ 可类似地由一个 $x \in \mathbb{R}$ 的向量来定义。这一对应关系 (6.16) 称为随机变量 X 的规律或分布。

注. 与离散随机变量不同，连续随机变量 X 取某一特定值的概率 $P(X = x)$ 为零。这就像在 (6.16) 中取 $a = b$ 来指定一个区间一样。

单点测度为零

定义 6.2 (累积分布函数)**.** 状态为 $\boldsymbol{x} \in \mathbb{R}^D$ 的多元实值随机变量 X 的**累积分布函数**（cdf 为

累积分布函数

$$F_X(\boldsymbol{x}) = P(X_1 \leq x_1, \ldots, X_D \leq x_D)\,, \tag{6.17}$$

其中 $X = [X_1, \ldots, X_D]^\top$，$\boldsymbol{x} = [x_1, \ldots, x_D]^\top$，右端表示随机变量 X_i 取小于等于 x_i 之值的概率。

$$F_X(\boldsymbol{x}) = \int_{-\infty}^{x_1} \cdots \int_{-\infty}^{x_D} f(z_1, \ldots, z_D)\,\mathrm{d}z_1 \cdots \mathrm{d}z_D\,. \tag{6.18}$$

注. 我们重申，谈论分布时实际上有两个不同概念：其一是 pdf 的概念（记作 $f(x)$），它是一个非负、求和为 1 的函数；其二是随机变量 X 的规律，即随机变量 X 与 pdf $f(x)$ 的对应关系。

pdf 与规律不同 .182

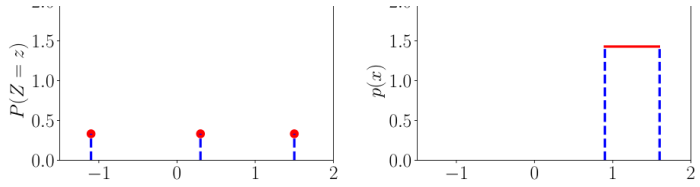


图 6.3: (a) 离散与 (b) 连续均匀分布的例子。分布细节见例 6.3（对应原图 Figure 6.3）。

在本书大部分内容中，我们并不使用 $f(x)$ 与 $F_X(x)$ 这两种记号，因为我们大多无需区分 pdf 与 cdf；但在第 6.7 节我们需要小心区分 pdf 与 cdf。

6.2.3　离散与连续分布对比

回忆第 6.1.2 节，概率为正且总概率之和为 1。对离散随机变量（见 (6.12)），这意味着每个状态的概率必落在区间 $[0, 1]$。但对连续随机变量，归一化（见 (6.15)）并不意味着密度在所有取值处都小于等于 1。我们用图 6.3 中的均匀分布（同时给出离散与连续随机变量两种情形）来说明这一点。

均匀分布

例 6.3 (均匀分布)**.** 我们考虑均匀分布的两个例子，其中每个状态等可能出现。本例说明离散与连续概率分布之间的一些差异。

设 Z 是离散均匀随机变量，有三个状态 $\{z = -1.1,\ z = 0.3,\ z = 1.5\}$。其概率质量函数可表示为一张概率值表：

z	-1.1	0.3	1.5
$P(Z = z)$	$\frac{1}{3}$	$\frac{1}{3}$	$\frac{1}{3}$

或者我们可以把它看作一张图（图 6.3(a)）：把状态放在横轴上，纵轴表示某一状态的概率。图 6.3(a) 的纵轴被有意拉长，使其与图 6.3(b) 相同。

此处状态取值本身无意义，刻意选数以强调：我们不应使用（也应忽略）状态的顺序。

设 X 是取值于区间 $0.9 \le X \le 1.6$ 的连续随机变量，如图 6.3(b) 所示。注意密度的高度可以大于 1，但必须满足

$$\int_{0.9}^{1.6} p(x)\,\mathrm{d}x = 1\,. \tag{6.19}$$

注. 关于离散概率分布还有一处微妙之处。状态 $z_1, \ldots, z_d$ 原则上没有任何结构，即通常无法比较它们，例如 $z_1 =$ 红、$z_2 =$ 绿、$z_3 =$ 蓝。然而在许多机器学习应用中，离散状态取数值，例如 $z_1 = -1.1$、$z_2 = 0.3$、$z_3 = 1.5$，这时我们可以说 $z_1 < z_2 < z_3$。取数值的离散状态特别有用，因为我们常常考虑随机变量的期望值（第 6.4.1 节）。

遗憾的是，机器学习文献使用的记号和术语掩盖了样本空间 Ω、目标空间 $\mathcal{T}$ 与随机变量 X 之间的区别。对随机变量 X 可能结果集合中的一个值 x（即 $x \in \mathcal{T}$），$p(x)$ 表示随机变量 X 取结果 x 的概率。对离散随机变量，这写作 $P(X = x)$，即概率质量函数；pmf 常被称为“分布”。对连续变量，$p(x)$ 称为概率密度函数（常简称密度）。更让人糊涂的是，累积分布函数 $P(X \le x)$ 也常被称为“分布”。本章中，我们用记号 X 同时指代单变量与多变量随机变量，状态分别记作 x 与 $\boldsymbol{x}$。术语汇总于表 6.1。

把 x 看作产生 p(x) 的自变量

原书 p.183

表 6.1: 概率分布的术语对照表（对应原书 Table 6.1）。

类型	“点概率”	“区间概率”	名称
离散	$P(X = x)$	不适用	概率质量函数
连续	$p(x)$	$P(X \le x)$	概率密度函数 / 累积分布函数

注. 我们不仅把“概率分布”一词用于离散概率质量函数，也用于连续概率密度函数，尽管严格来说这并不正确。与多数机器学习文献一致，我们也依靠上下文来区分“概率分布”一词的不同用法。

6.3　求和规则、乘积规则与贝叶斯定理

原书 p.184

我们把概率论看作逻辑推理的推广。如第 6.1.1 节所论，这里给出的概率规则自然地来自对那些期望性质的满足（Jaynes, 2003, 第 2 章）。概率建模（第 8.4 节）为设计机器学习方法提供了有原则的基础。一旦我们定义了与数据和问题之不确定性相对应的概率分布（第 6.2 节），就会发现只有两条基本规则：求和规则与乘积规则。

回忆 (6.9)，$p(x, y)$ 是两个随机变量 x, y 的联合分布。$p(x)$ 与 $p(y)$ 是相应的边缘分布，$p(y \mid x)$ 是给定 x 时 y 的条件分布。给定第 6.2 节中离散与连续随机变量的边缘概率和条件概率定义，我们现在可以给出概率论中的两条基本规则。

这两条规则由 6.1 的要求自然导出

第一条规则是求和规则，它指出

$$p(x) = \begin{cases} \displaystyle\sum_{y \in \mathcal{Y}} p(x, y) & \text{若} y \text{ 离散} \\ \displaystyle\int_{\mathcal{Y}} p(x, y)\,\mathrm{d}y & \text{若} y \text{ 连续} \end{cases} \tag{6.20}$$

其中 $\mathcal{Y}$ 是随机变量 Y 目标空间的状态集合。这意味着我们把随机变量 Y 的状态集合 y 求和掉（或积分掉）。求和规则也称为边缘化性质。求和规则把联合分布与边缘分布联系起来。一般地，当联合分布含有多于两个随机变量时，求和规则可作用于随机变量的

边缘化

任意子集，得到可能含多于一个随机变量的边缘分布。更具体地，若 $\boldsymbol{x} = [x_1, \ldots, x_D]^\top$，反复应用求和规则，把除 x_i 外的所有随机变量积分/求和掉，就得到边缘

$$p(x_i) = \int p(x_1, \ldots, x_D)\, \mathrm{d}\boldsymbol{x}_{\setminus i}\,, \tag{6.21}$$

其中 $\setminus i$ 读作“除 i 外的全部”。

注. 概率建模的许多计算困难都来自求和规则的应用。当变量很多、或离散变量有很多状态时，求和规则归结为做一个高维求和或积分。计算高维求和或积分通常是计算困难的，即不存在已知的多项式时间算法能精确算出它们。

第二条规则称为乘积规则，它通过下式把联合分布与条件分布联系起来：

$$p(x, y) = p(y \mid x)\, p(x)\,. \tag{6.22}$$

乘积规则可理解为：两个随机变量的任一联合分布都可以分解（写成乘积）为另外两个分布。这两个因子是第一个随机变量的边缘分布 $p(x)$，以及第二个随机变量在给定第一个时的条件分布 $p(y \mid x)$。由于在 $p(x, y)$ 中随机变量的次序是任意的，乘积规则也蕴涵 $p(x, y) = p(x \mid y)p(y)$。确切地说，(6.22) 是对离散随机变量用概率质量函数写出的；对连续随机变量，乘积规则用概率密度函数写出（第 6.2.3 节）。 原书 p.185

在机器学习与贝叶斯统计中，我们常常希望在已观察到某些随机变量的条件下，对未观察到（隐）随机变量作推断。设我们对未观察到的随机变量 x 有某种先验知识 $p(x)$，并且 x 与另一个我们能观察的随机变量 y 之间有某种关系 $p(y \mid x)$。若观察到 y，就可以用贝叶斯定理在给定 y 之观察值的条件下对 x 下结论。贝叶斯定理（亦称贝叶斯规则或贝叶斯定律）

$$\underbrace{p(x \mid y)}_{\text{后验}} = \frac{\overbrace{p(y \mid x)}^{\text{似然}}\ \overbrace{p(x)}^{\text{先验}}}{\underbrace{p(y)}_{\text{证据}}} \tag{6.23}$$

是 (6.22) 中乘积规则的直接推论，因为

$$p(x, y) = p(x \mid y)\, p(y) \tag{6.24}$$

与

$$p(x, y) = p(y \mid x)\, p(x) \tag{6.25}$$

所以

$$p(x \mid y)\, p(y) = p(y \mid x)\, p(x) \quad \Longleftrightarrow \quad p(x \mid y) = \frac{p(y \mid x)\, p(x)}{p(y)}\,. \tag{6.26}$$

在 (6.23) 中，$p(x)$ 是先验，它概括了我们在观察任何数据之前对未观察（隐）变量 x 的主观先验知识。我们可以任选一个对自己合理的先验，但关键是要确保先验在所有看似合理的 x 上都有非零的 pdf（或 pmf），即使这些 x 非常罕见。 先验

似然 $p(y \mid x)$ 描述 x 与 y 如何关联；在离散概率分布情形，它就是若已知隐变量 x 时数据 y 的概率。注意似然并不是关于 x 的分布，而只是关于 y 的分布。我们把 $p(y \mid x)$ 称为“(给定 y 时 x 的) 似然”或“给定 x 时 y 的概率”，但绝不称其为 y 的似然 (MacKay, 2003)。 似然

似然亦称“概率模型” 后验 $p(x \mid y)$ 是贝叶斯统计中真正关心的量，因为它确切表达了我们所关心的东西，即在观察到 y 之后我们对 x 的了解。

量

$$p(y) := \int p(y \mid x)\, p(x)\, \mathrm{d}x = \mathbb{E}_X[p(y \mid x)] \tag{6.27}$$

原书 p.186

是边缘似然/证据。(6.27) 的右端使用了期望算子，我们将在第 6.4.1 节定义它。由定义边缘似然把 (6.23) 的分子对隐变量 x 积分，因此边缘似然与 x 无关，并保证后验 $p(x \mid y)$ 被归一化。边缘似然也可解释为关于先验 $p(x)$ 取期望所得的期望似然。除了归一化后验之外，边缘似然在贝叶斯模型选择中也起重要作用，我们将在第 8.6 节讨论。由于 (8.44) 中的积分，证据往往很难计算。

边缘似然/ 证据

贝叶斯定理 (6.23) 使我们能够反转似然所给出的 x 与 y 之间的关系，因此有时被称为概率逆。我们将在第 8.4 节进一步讨论贝叶斯定理。

贝叶斯定理亦称“概率逆”

注. 在贝叶斯统计中，后验分布是真正关心的量，因为它概括了来自先验与数据的全部可用信息。我们不必时刻携带整个后验，而可以聚焦于后验的某个统计量，例如后验的最大值，我们将在第 8.3 节讨论。然而，聚焦于后验的某个统计量会丢失信息。若放在更大的背景中看，后验可用于一个决策系统，拥有完整后验可能极为有用，并能导出对扰动稳健的决策。例如在基于模型的强化学习中，Deisenroth et al. (2015) 表明：使用合理转移函数的完整后验分布能带来非常快速（数据/样本高效）的学习，而只取后验最大值则会导致持续失败。因此，拥有完整后验对下游任务可能非常有用。在第 9 章线性回归的语境中，我们将继续这一讨论。

6.4　汇总统计量与独立性

我们常常希望概括一组随机变量，并成对地比较随机变量。一个随机变量的统计量是该随机变量的一个确定性函数。一个分布的汇总统计量为我们提供了关于随机变量如何行为的一个有用视角，顾名思义，它给出概括并刻画该分布的数值。我们介绍两个熟知的汇总统计量：均值与方差。随后讨论比较一对随机变量的两种方式：一是如何判断两个随机变量相互独立；二是如何计算它们之间的内积。

原书 p.187

6.4.1　均值与协方差

均值与（协）方差常用于描述概率分布的性质（期望值与散布程度）。我们将在第 6.6 节看到，有一族很有用的分布（称为指数族），其中随机变量的统计量捕获了全部可能的信息。

期望值的概念在机器学习中处于核心地位，而概率论本身的基础概念也可以从期望值导出（Whittle, 2000）。

期望

定义 6.3 (期望值)**.** 单变量连续随机变量 $X \sim p(x)$ 的函数 $g : \mathbb{R} \to \mathbb{R}$ 的**期望值**为

$$\mathbb{E}_X[g(x)] = \int_X g(x)\, p(x)\, \mathrm{d}x\,. \tag{6.28}$$

相应地，离散随机变量 $X \sim p(x)$ 的函数 g 的期望值为

$$\mathbb{E}_X[g(x)] = \sum_{x \in \mathcal{X}} g(x)\, p(x)\,, \tag{6.29}$$

其中 $\mathcal{X}$ 是随机变量 X 的可能结果集合（目标空间）。

本节中我们认为离散随机变量取数值结果；从函数 g 以实数为输入即可看出这一点。

随机变量函数的期望亦称“无意识统计学家定律”

注. 我们把多变量随机变量 X 看作单变量随机变量组成的有限向量 $[X_1, \dots, X_D]^\top$。对多变量随机变量，我们逐元素定义期望值

$$\mathbb{E}_X[g(\boldsymbol{x})] = \begin{bmatrix} \mathbb{E}_{X_1}[g(x_1)] \\ \vdots \\ \mathbb{E}_{X_D}[g(x_D)] \end{bmatrix} \in \mathbb{R}^D\,, \tag{6.30}$$

其中下标 $\mathbb{E}_{X_d}$ 表示我们关于向量 $\boldsymbol{x}$ 的第 d 个元素取期望。

定义 6.3 把记号 $\mathbb{E}_X$ 的含义规定为一个算子：对连续分布关于概率密度取积分，对离散分布关于所有状态求和。均值（定义 6.4）是期望值的一个特例，即取 g 为恒等函数。

原书 p.188

均值

定义 6.4 (均值)**.** 状态为 $\boldsymbol{x} \in \mathbb{R}^D$ 的随机变量 X 的**均值**是一个平均值，定义为

$$\mathbb{E}_X[\boldsymbol{x}] = \begin{bmatrix} \mathbb{E}_{X_1}[x_1] \\ \vdots \\ \mathbb{E}_{X_D}[x_D] \end{bmatrix} \in \mathbb{R}^D\,, \tag{6.31}$$

其中

$$\mathbb{E}_{X_d}[x_d] := \begin{cases} \displaystyle\int_X x_d\, p(x_d)\,\mathrm{d}x_d & \text{若} X \text{ 是连续随机变量} \\ \displaystyle\sum_{x_i \in \mathcal{X}} x_i\, p(x_d = x_i) & \text{若} X \text{ 是离散随机变量} \end{cases} \tag{6.32}$$

对 $d = 1, \dots, D$ 成立，下标 d 指示 $\boldsymbol{x}$ 的相应维数。积分与求和都遍历随机变量 X 目标空间的状态 $\mathcal{X}$。

在一维中，还有另外两种直观的“平均”概念：中位数与众数。中位数是把数值排序后位于“中间”的值，即 50% 的值大于中位数、50% 的值小于中位数。这一想法可推广到连续值，取 cdf（定义 6.2）等于 0.5 处的值即可。对于偏斜或长尾的分布，中位数给出的典型值比均值更接近人的直觉；此外，中位数比均值对离群点更稳健。中位数向高维的推广并不平凡，因为在多于一维时没有显然的方式来“排序”（Hallin et al., 2010; Kong and Mizera, 2012）。众数是出现最频繁的值。对离散随机变量，众数定义为出现频率最高的 x 值；对连续随机变量，众数定义为密度 $p(x)$ 的一个峰。一个特定密度 $p(x)$ 可能有不止一个众数，而且在高维分布中众数数量可能非常多。因此找出一个分布的所有众数在计算上可能颇具挑战。

中位数

众数

例 6.4 (二维分布的均值、众数与中位数)**.** 考虑图 6.4 所示的二维分布：

$$p(\boldsymbol{x}) = 0.4\,\mathcal{N}\left(\boldsymbol{x}\middle|\begin{bmatrix}10\\2\end{bmatrix}, \begin{bmatrix}1 & 0\\0 & 1\end{bmatrix}\right) + 0.6\,\mathcal{N}\left(\boldsymbol{x}\middle|\begin{bmatrix}0\\0\end{bmatrix}, \begin{bmatrix}8.4 & 2.0\\2.0 & 1.7\end{bmatrix}\right). \tag{6.33}$$

我们将在第 6.5 节定义高斯分布 $\mathcal{N}(\mu, \sigma^2)$。图中还画出了各维相应的边缘分布。注意该分布是双峰的（有两个众数），但其中一个边缘分布是单峰的（只有一个众数）。水平方向的双峰单变量分布说明均值与中位数可以彼此不同。虽然把二维中位数定义为各维中位数的拼接很诱人，但无法在二维点之间定义序关系这一事实使之变得困难。所谓“无法定义序”，是指定义关系 $<$ 使 $\begin{bmatrix}3\\0\end{bmatrix} < \begin{bmatrix}2\\3\end{bmatrix}$ 的方式不止一种。

原书 p.189

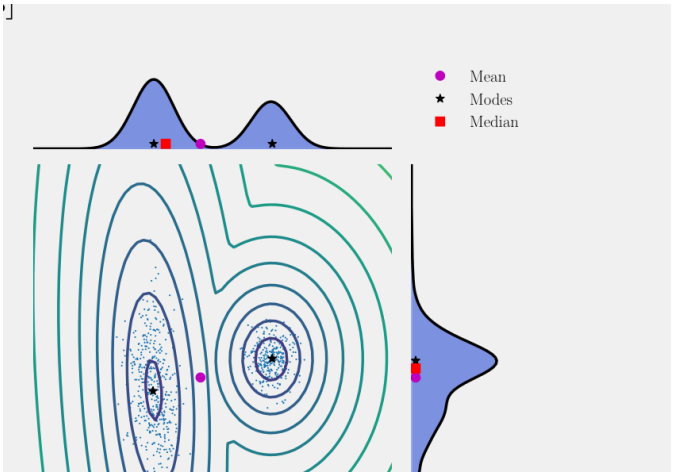


图 6.4: 二维数据集的均值、众数与中位数，以及其边缘密度的示意（对应原图 Figure 6.4）。

注. 期望值（定义 6.3）是线性算子。例如，给定实值函数 $f(x) = ag(x) + bh(x)$，其中 $a, b \in \mathbb{R}$、$\boldsymbol{x} \in \mathbb{R}^D$，我们有

$$\begin{aligned}\mathbb{E}_X[f(\boldsymbol{x})] &= \int f(\boldsymbol{x})\, p(\boldsymbol{x})\, \mathrm{d}\boldsymbol{x} && (6.34a)\\ &= \int [ag(\boldsymbol{x}) + bh(\boldsymbol{x})]\, p(\boldsymbol{x})\, \mathrm{d}\boldsymbol{x} && (6.34b)\\ &= a \int g(\boldsymbol{x})\, p(\boldsymbol{x})\, \mathrm{d}\boldsymbol{x} + b \int h(\boldsymbol{x})\, p(\boldsymbol{x})\, \mathrm{d}\boldsymbol{x} && (6.34c)\\ &= a\, \mathbb{E}_X[g(\boldsymbol{x})] + b\, \mathbb{E}_X[h(\boldsymbol{x})]\,. && (6.34d)\end{aligned}$$

对两个随机变量，我们也许希望刻画它们彼此之间的对应关系。协观上表示随机变量之间相互依赖程度的概念。

原书 p.190

定义 6.5 (协方差（单变量）). 两个单变量随机变量 $X, Y \in \mathbb{R}$ 之间的**协方差**由它们各自偏离均值之偏差的期望乘积给出，即

协方差

$$\mathrm{Cov}_{X,Y}[x, y] := \mathbb{E}_{X,Y}\left[(x - \mathbb{E}_X[x])(y - \mathbb{E}_Y[y])\right]. \tag{6.35}$$

多变量间协方差

注. 当与期望或协方差相关的随机变量可由其参数看出时，下标常被省略（例如 $\mathbb{E}_X[x]$ 常写作 $\mathbb{E}[x]$）。

Cov[x,y]亦称互协方差，Cov[x,x]才称方差。

利用期望的线性性，定义 6.5 中的表达式可改写为乘积的期望减去期望的乘积，即

$$\mathrm{Cov}[x, y] = \mathbb{E}[xy] - \mathbb{E}[x]\,\mathbb{E}[y]\,. \tag{6.36}$$

一个变量与其自身的协方差 $\mathrm{Cov}[x, x]$ 称为方差，记作 $\mathbb{V}_X[x]$。方差的平方根称为标准差，常记作 $\sigma(x)$。协方差的概念可推广到多变量随机变量。

方差

标准差

定义 6.6 (协方差（多变量）). 若考虑两个多变量随机变量 X 与 Y，状态分别为 $\boldsymbol{x} \in \mathbb{R}^D$ 与 $\boldsymbol{y} \in \mathbb{R}^E$，则 X 与 Y 之间的协方差定义为

$$\mathrm{Cov}[\boldsymbol{x}, \boldsymbol{y}] = \mathbb{E}[\boldsymbol{x}\boldsymbol{y}^\top] - \mathbb{E}[\boldsymbol{x}]\,\mathbb{E}[\boldsymbol{y}]^\top = \mathrm{Cov}[\boldsymbol{y}, \boldsymbol{x}]^\top \in \mathbb{R}^{D \times E}\,. \tag{6.37}$$

把定义 6.6 中的两个自变量取为同一个多变量随机变量，就得到一个有用的概念，它直观地刻画了随机变量的“散布”。对多变量随机变量，方差描述该随机变量各维之间的关系。

定义 6.7 (方差)**.** 状态为 $\boldsymbol{x} \in \mathbb{R}^D$、均值向量为 $\boldsymbol{\mu} \in \mathbb{R}^D$ 的随机变量 X 的**方差**定义为

$$\mathbb{V}_X[\boldsymbol{x}] = \mathrm{Cov}_X[\boldsymbol{x}, \boldsymbol{x}] \tag{6.38a}$$

$$= \mathbb{E}_X[(\boldsymbol{x} - \boldsymbol{\mu})(\boldsymbol{x} - \boldsymbol{\mu})^\top] = \mathbb{E}_X[\boldsymbol{x}\boldsymbol{x}^\top] - \mathbb{E}_X[\boldsymbol{x}]\,\mathbb{E}_X[\boldsymbol{x}]^\top \tag{6.38b}$$

$$= \begin{bmatrix} \mathrm{Cov}[x_1, x_1] & \mathrm{Cov}[x_1, x_2] & \cdots & \mathrm{Cov}[x_1, x_D] \\ \mathrm{Cov}[x_2, x_1] & \mathrm{Cov}[x_2, x_2] & \cdots & \mathrm{Cov}[x_2, x_D] \\ \vdots & \vdots & \ddots & \vdots \\ \mathrm{Cov}[x_D, x_1] & \cdots & \cdots & \mathrm{Cov}[x_D, x_D] \end{bmatrix}. \tag{6.38c}$$

(6.38c) 中的 $D \times D$ 矩阵称为多变量随机变量 X 的协方差矩阵。协方差矩阵是对称半正定的，它告诉我们数据散布的一些情况。其对角线上是各边缘分布的方差 协方差矩阵

$$p(x_i) = \int p(x_1, \ldots, x_D)\, \mathrm{d}\boldsymbol{x}_{\setminus i}\,, \tag{6.39}$$

其中“$\setminus i$”表示“除 i 外的所有变量”。非对角元素是互协方差项 $\mathrm{Cov}[x_i, x_j], i, j = 1, \ldots, D$, $i \neq j$。 互协方差

注. 本书通常假定协方差矩阵正定，以便获得更好的直观。因此我们不讨论导致半正定（低秩）协方差矩阵的边界情形。

当我们想比较不同随机变量对之间的协方差时，会发现每个随机变量的方差都会影响协方差的值。协方差的归一化版本称为相关系数。

定义 6.8 (相关系数)**.** 两个随机变量 X, Y 之间的**相关系数**为 相关系数

$$\mathrm{corr}[x, y] = \frac{\mathrm{Cov}[x, y]}{\sqrt{\mathbb{V}[x]\,\mathbb{V}[y]}} \in [-1, 1]\,. \tag{6.40}$$

相关矩阵是标准化随机变量 $\boldsymbol{x}/\sigma(\boldsymbol{x})$ 的协方差矩阵。换言之，在相关矩阵中每个随机变量都除以其标准差（方差的平方根）。

协方差（及相关系数）指示两个随机变量如何关联；见图 6.5。正相关 $\mathrm{corr}[x, y]$ 意味着当 x 增大时 y 也期望增大；负相关意味着当 x 增大时 y 减小。

原书 p.191

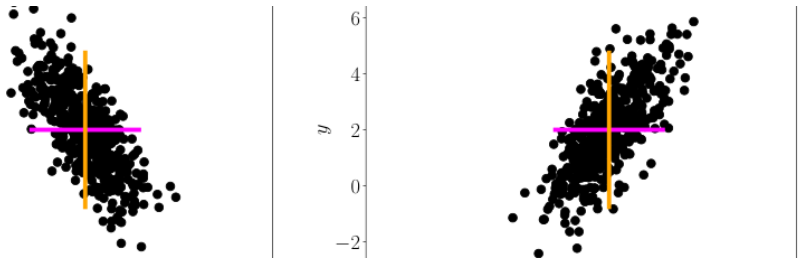


图 6.5: 两个二维数据集，各轴上的均值与方差相同（彩色线），但协方差不同。(a) x 与 y 负相关；(b) x 与 y 正相关（对应原图 Figure 6.5）。

6.4.2　经验均值与协方差

总体均值/ 协方差

第 6.4.1 节中的定义常被称为总体均值与总体协方差，因为它们指总体的真实统计量。在机器学习中，我们需要从数据的经验观察中学习。考虑一个随机变量 X。从总体统计量到经验统计量的实现有两个概念步骤。第一，我们利用手头有一个（大小为 N 的）有限数据集这一事实，构造一个经验统计量，它是有限个相同随机变量 $X_1, \ldots, X_N$ 的函数。第二，我们观察数据，即查看每个随机变量的实现 $x_1, \ldots, x_N$，并应用该经验统计量。

.192

具体地，对均值（定义 6.4），给定一个特定数据集可以得到均值的一个估计，称为经验均值或样本均值。经验协方差同理。

经验均值/ 样本均值

定义 6.9 (经验均值与协方差)**.** 经验均值向量是各变量观察值的算术平均，定义为

$$\bar{\boldsymbol{x}} := \frac{1}{N}\sum_{n=1}^{N} \boldsymbol{x}_n \,, \tag{6.41}$$

其中 $\boldsymbol{x}_n \in \mathbb{R}^D$。与经验均值类似，经验协方差矩阵是一个 $D \times D$ 矩阵

$$\Sigma := \frac{1}{N}\sum_{n=1}^{N} (\boldsymbol{x}_n - \bar{\boldsymbol{x}})(\boldsymbol{x}_n - \bar{\boldsymbol{x}})^\top \,. \tag{6.42}$$

全书使用经验协方差（有偏估计）。无偏（亦称修正）协方差分母用N −1 而非N。此推导留作本章末习题

要为某个特定数据集计算统计量，我们就用实现（观察值）$\boldsymbol{x}_1, \ldots, \boldsymbol{x}_N$ 并代入 (6.41) 与 (6.42)。经验协方差矩阵是对称半正定的（见第 3.2.3 节）。

6.4.3　方差的三种表达式

现在我们聚焦于单个随机变量 X，并用前面的经验公式导出方差的三种可能表达式。下面的推导对总体方差同样成立，只是需要小心积分。与协方差定义（定义 6.5）对应的方差标准定义，是随机变量 X 偏离其期望 μ 之偏差平方的期望，即

$$\mathbb{V}_X[x] := \mathbb{E}_X[(x-\mu)^2] \,. \tag{6.43}$$

(6.43) 中的期望与均值 $\mu = \mathbb{E}_X(x)$ 根据 X 是离散还是连续随机变量，用 (6.32) 计算。(6.43) 所表达的方差是新随机变量 $Z := (X-\mu)^2$ 的均值。

原书 p.193

在经验地估计 (6.43) 中的方差时，我们需要两遍算法：第一遍用 (6.41) 计算均值 μ，第二遍用这个估计 $\hat{\mu}$ 计算方差。结果表明，通过重新整理各项可以避免两遍。(6.43) 中的公式可化为所谓方差的原始分数公式：

原始分数公式

$$\mathbb{V}_X[x] = \mathbb{E}_X[x^2] - \big(\mathbb{E}_X[x]\big)^2 \,. \tag{6.44}$$

(6.44) 中的表达式可记为“平方的均值减去均值的平方”。它可以在数据上一遍算完，因为我们可以同时累积 x_i（用以算均值）与 x_i^2，其中 x_i 是第 i 个观察值。不幸的是，若这样实现，数值上可能不稳定。方差的原始分数形式在机器学习中很有用，例如在推导偏差–方差分解时（Bishop, 2006）。

若 (6.44)中两项都很大且近似相等，浮点运算中可能无谓损失数值精度。

理解方差的第三种方式是：它是所有观察值两两之间差的某种和。考虑随机变量 X 的一组实现样本 $x_1, \ldots, x_N$，计算 x_i 与 x_j 配对的平方差。展开平方后可以证明，N^2 个两两差之和就是观察值的经验方差：

$$\frac{1}{N^2}\sum_{i,j=1}^{N}(x_i - x_j)^2 = 2\left[\frac{1}{N}\sum_{i=1}^{N} x_i^2 - \left(\frac{1}{N}\sum_{i=1}^{N} x_i\right)^2\right] . \tag{6.45}$$

我们看到 (6.45) 是原始分数表达式 (6.44) 的两倍。这意味着我们可以把两两距离之和（共有 N^2 个）表示为到均值的偏差之和（共有 N 个）。几何上，这意味着两两距离与点集到中心的距离之间等价。从计算角度看，这意味着：先算均值（求和 N 项），再算方差（再求和 N 项），就能得到一个含 N^2 项的表达式（(6.45) 左端）。

6.4.4　随机变量的和与变换

我们也许想建模一个无法由教科书分布很好解释的现象（我们将在第 6.5、6.6 节介绍一些），因而可能对随机变量做一些简单操作（如把两个随机变量相加）。

考虑两个状态为 $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^D$ 的随机变量 X, Y。则：

$$\mathbb{E}[\boldsymbol{x}+\boldsymbol{y}] = \mathbb{E}[\boldsymbol{x}] + \mathbb{E}[\boldsymbol{y}] \tag{6.46}$$

$$\mathbb{E}[\boldsymbol{x}-\boldsymbol{y}] = \mathbb{E}[\boldsymbol{x}] - \mathbb{E}[\boldsymbol{y}] \tag{6.47}$$

$$\mathbb{V}[\boldsymbol{x}+\boldsymbol{y}] = \mathbb{V}[\boldsymbol{x}] + \mathbb{V}[\boldsymbol{y}] + \mathrm{Cov}[\boldsymbol{x},\boldsymbol{y}] + \mathrm{Cov}[\boldsymbol{y},\boldsymbol{x}] \tag{6.48}$$

$$\mathbb{V}[\boldsymbol{x}-\boldsymbol{y}] = \mathbb{V}[\boldsymbol{x}] + \mathbb{V}[\boldsymbol{y}] - \mathrm{Cov}[\boldsymbol{x},\boldsymbol{y}] - \mathrm{Cov}[\boldsymbol{y},\boldsymbol{x}]\,. \tag{6.49}$$

当对随机变量做仿射变换时，均值与（协）方差呈现出一些有用的性质。考虑一个均值为 $\boldsymbol{\mu}$、协方差矩阵为 Σ 的随机变量 X，以及对 x 的一个（确定性）仿射变换 $\boldsymbol{y} = A\boldsymbol{x} + \boldsymbol{b}$。则 $\boldsymbol{y}$ 本身也是一个随机变量，其均值向量与协方差矩阵分别为 原书 p.194

$$\mathbb{E}_Y[\boldsymbol{y}] = \mathbb{E}_X[A\boldsymbol{x}+\boldsymbol{b}] = A\,\mathbb{E}_X[\boldsymbol{x}] + \boldsymbol{b} = A\boldsymbol{\mu} + \boldsymbol{b}\,, \tag{6.50}$$

$$\mathbb{V}_Y[\boldsymbol{y}] = \mathbb{V}_X[A\boldsymbol{x}+\boldsymbol{b}] = \mathbb{V}_X[A\boldsymbol{x}] = A\,\mathbb{V}_X[\boldsymbol{x}]\,A^\top = A\Sigma A^\top\,, \tag{6.51}$$

其中最后一步利用了 $\Sigma = \mathbb{E}[\boldsymbol{x}\boldsymbol{x}^\top] - \boldsymbol{\mu}\boldsymbol{\mu}^\top$ 是 X 的协方差。此外，

可直接用均值与协方差定义证明。

$$\begin{aligned}
\mathrm{Cov}[\boldsymbol{x},\boldsymbol{y}] &= \mathbb{E}[\boldsymbol{x}(A\boldsymbol{x}+\boldsymbol{b})^\top] - \mathbb{E}[\boldsymbol{x}]\,\mathbb{E}[A\boldsymbol{x}+\boldsymbol{b}]^\top && \text{(6.52a)}\\
&= \mathbb{E}[\boldsymbol{x}]\boldsymbol{b}^\top + \mathbb{E}[\boldsymbol{x}\boldsymbol{x}^\top]A^\top - \boldsymbol{\mu}\boldsymbol{b}^\top - \boldsymbol{\mu}\boldsymbol{\mu}^\top A^\top && \text{(6.52b)}\\
&= \boldsymbol{\mu}\boldsymbol{b}^\top - \boldsymbol{\mu}\boldsymbol{b}^\top + \big(\mathbb{E}[\boldsymbol{x}\boldsymbol{x}^\top] - \boldsymbol{\mu}\boldsymbol{\mu}^\top\big)A^\top && \text{(6.52c)}\\
&\overset{(6.38b)}{=} \Sigma A^\top\,. && \text{(6.52d)}
\end{aligned}$$

6.4.5　统计独立性

定义 6.10 (独立性)**.** 两个随机变量 X, Y 统计独立，当且仅当

统计独立

$$p(x,y) = p(x)\,p(y)\,. \tag{6.53}$$

直观上，两个随机变量 X 与 Y 独立，是指 y 的值（一旦知道）不会带来关于 x 的任何额外信息（反之亦然）。若 X, Y（统计）独立，则

$$\begin{aligned}
p(y \mid x) &= p(y)\\
p(x \mid y) &= p(x)\\
\mathbb{V}_{X,Y}[x+y] &= \mathbb{V}_X[x] + \mathbb{V}_Y[y]\\
\mathrm{Cov}_{X,Y}[x,y] &= 0
\end{aligned}$$

最后一条反过来未必成立，即两个随机变量协方差为零却未必统计独立。要理解原因，回忆协方差只度量线性相关性。因此，非线性相关的随机变量也可能协方差为零。

例 6.5 (协方差为零却不独立)**.** 考虑一个零均值的随机变量 X($\mathbb{E}_X[x]=0$)且 $\mathbb{E}_X[x^3]=0$。令 $y=x^2$（因而 Y 依赖于 X），考察 X 与 Y 之间的协方差 (6.36)。这给出

$$\mathrm{Cov}[x,y]=\mathbb{E}[xy]-\mathbb{E}[x]\,\mathbb{E}[y]=\mathbb{E}[x^3]=0\,. \tag{6.54}$$

原书 p.195

在机器学习中，我们常常考虑可建模为独立同分布（i.i.d.）随机变量 $X_1,\ldots,X_N$ 的问题。对多于两个随机变量，“独立”一词（定义 6.10）通常指相互独立，即所有子集都独立（见 Pollard (2002, 第 4 章) 与 Jacod and Protter (2004, 第 3 章)）。“同分布”一词指所有随机变量都来自同一分布。

独立同分布

机器学习中另一个重要概念是条件独立。

定义 6.11 (条件独立)**.** 两个随机变量 X 与 Y 在给定 Z 时条件独立，当且仅当

条件独立

$$p(x,y\mid z)=p(x\mid z)\,p(y\mid z)\qquad \text{对所有}z\in\mathcal{Z}\,, \tag{6.55}$$

其中 $\mathcal{Z}$ 是随机变量 Z 的状态集合。我们写 $X\perp\!\!\!\perp Y\mid Z$ 表示在给定 Z 时 X 条件独立于 Y。

定义 6.11 要求 (6.55) 中的关系对 z 的每个取值都成立。(6.55) 的含义可理解为“在已知 z 的条件下，x 与 y 的分布可分解”。独立性可看作条件独立的特例，只要写成 $X\perp\!\!\!\perp Y\mid\emptyset$。利用概率的乘积规则 (6.22)，把 (6.55) 的左端展开，得到

$$p(x,y\mid z)=p(x\mid y,z)\,p(y\mid z)\,. \tag{6.56}$$

把 (6.55) 的右端与 (6.56) 比较，可见 $p(y\mid z)$ 同时出现在二者中，于是

$$p(x\mid y,z)=p(x\mid z)\,. \tag{6.57}$$

(6.57) 给出了条件独立即 $X\perp\!\!\!\perp Y\mid Z$ 的另一种定义。这一替代表述给出的解释是“在已知 z 的条件下，关于 y 的知识不会改变我们关于 x 的知识”。

6.4.6　随机变量的内积

回忆第 3.2 节的内积定义。我们可以定义随机变量之间的内积，本节简要介绍。若有两个不相关的随机变量 X,Y，则

$$\mathbb{V}[x+y]=\mathbb{V}[x]+\mathbb{V}[y]\,. \tag{6.58}$$

由于方差以平方单位度量，这看起来非常像直角三角形的勾股定理 $c^2=a^2+b^2$。下面我们看看能否对 (6.58) 中不相关随机变量的方差关系找到几何解释。

原书 p.196

随机变量可看作向量空间中的向量，我们可以定义内积以获得随机变量的几何性质（Eaton, 2007）。若对零均值随机变量 X,Y 定义

$$\langle X,Y\rangle:=\mathrm{Cov}[x,y]\,, \tag{6.59}$$

就得到一个内积。我们看到协方差是对称、正定的，且对任一自变量都是线性的。随机变量的长度为

Cov[x, x] = 0 ⟺x = 0；Cov[αx + z, y] = α Cov[x, y]+ Cov[z, y]，α ∈R。

$$\|X\|=\sqrt{\mathrm{Cov}[x,x]}=\sqrt{\mathbb{V}[x]}=\sigma[x]\,, \tag{6.60}$$

即其标准差。随机变量“越长”，它就越不确定；长度为 0 的随机变量是确定的。

若看两个随机变量 X,Y 之间的夹角 θ，则有

$$\cos\theta=\frac{\langle X,Y\rangle}{\|X\|\,\|Y\|}=\frac{\mathrm{Cov}[x,y]}{\sqrt{\mathbb{V}[x]\,\mathbb{V}[y]}}\,, \tag{6.61}$$

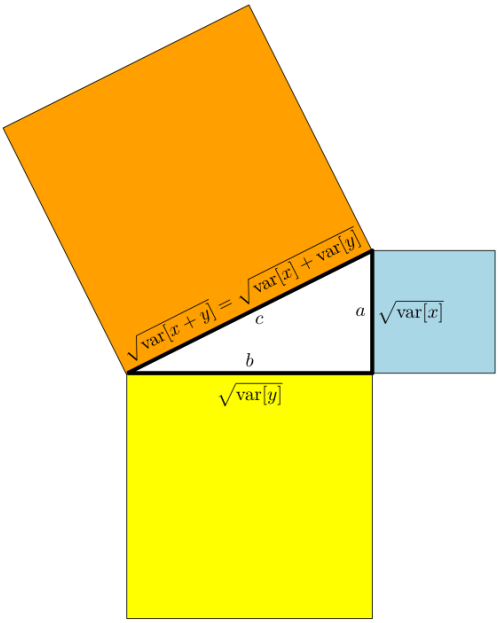


图 6.6: 随机变量的几何。若随机变量 X 与 Y 不相关，则它们在相应向量空间中是正交向量，勾股定理成立（对应原图 Figure 6.6）。

这就是两个随机变量之间的相关系数（定义 6.8）。这意味着，当我们从几何上看待随机变量时，可以把相关系数理解为两个随机变量之间夹角的余弦。由定义 3.7 知 $X \perp Y \iff \langle X, Y\rangle = 0$。在我们这里，这意味着 X 与 Y 正交当且仅当 $\mathrm{Cov}[x, y] = 0$，即二者不相关。图 6.6 展示了这一关系。

注. 虽然很想使用欧氏距离（由前面的内积定义构造）来比较概率分布，但不幸的是它并非获得分布间距离的最佳方式。回忆概率质量（或密度）为正且需相加为 1。这些约束意味着分布生活在一个称为统计流形的东西上。研究这个概率分布空间称为信息几何。计算分布间距离常借助 Kullback–Leibler 散度，它是对距离的一种推广，考虑了统计流形的性质。正如欧氏距离是度量（第 3.3 节）的特例一样，Kullback–Leibler 散度是两类更一般的散度——Bregman 散度与 f 散度——的特例。散度的研究超出本书范围，更多细节可参阅信息几何奠基人之一 Amari (2016) 的新著。

6.5　高斯分布

正态分布

独立同分布随机变量之和自然引出**高斯**，即中心极限定理。

高斯分布是连续值随机变量研究得最透彻的概率分布，也称正态分布。它之所以重要，源于它有许多计算上方便的性质，下面将逐一讨论。特别地，我们将用它来定义线性回归（第 9 章）中的似然与先验，并考虑高斯混合用于密度估计（第 11 章）。

机器学习中还有许多领域也得益于使用高斯分布，例如高斯过程、变分推断和强化学习。它还广泛用于其他应用领域，如信号处理（例如 Kalman 滤波）、控制（例如线性二次调节器）以及统计学（例如假设检验）。

对单变量随机变量，高斯分布的密度为

$$p(x \mid \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right). \tag{6.62}$$

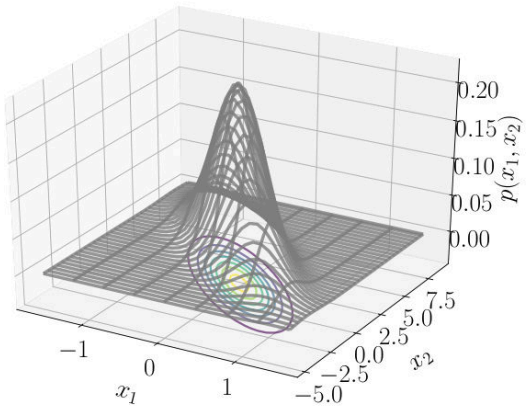


图 6.7: 两个随机变量 x_1 与 x_2 的高斯分布（对应原图 Figure 6.7）。

多变量高斯分布完全由一个均值向量 $\boldsymbol{\mu}$ 和一个协方差矩阵 Σ 刻画，定义为

$$p(\boldsymbol{x} \mid \boldsymbol{\mu}, \Sigma) = (2\pi)^{-\frac{D}{2}} |\Sigma|^{-\frac{1}{2}} \exp\left(-\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu})^\top \Sigma^{-1}(\boldsymbol{x}-\boldsymbol{\mu})\right), \tag{6.63}$$

均值向量/ 协方差矩阵

其中 $\boldsymbol{x} \in \mathbb{R}^D$。我们写 $p(\boldsymbol{x}) = \mathcal{N}(\boldsymbol{x} \mid \boldsymbol{\mu}, \Sigma)$ 或 $X \sim \mathcal{N}(\boldsymbol{\mu}, \Sigma)$。图 6.7 展示了一个二元高斯（网格面）及相应的等高线图。图 6.8 展示了一个单变量高斯与一个二元高斯及相应样本。均值为零、协方差为单位阵（即 $\boldsymbol{\mu} = \mathbf{0}$、$\Sigma = I$）的高斯特例称为标准正态分布。

标准正态分布 p.198

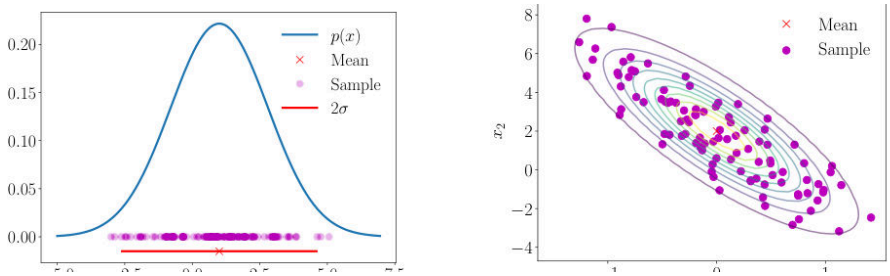


图 6.8: 叠加了 100 个样本的高斯分布。(a) 一维情形；(b) 二维情形。左：单变量（一维）高斯，红叉表示均值，红线标示方差范围；右：多变量（二维）高斯俯视图，红叉为均值，彩色线为密度等高线（对应原图 Figure 6.8）。

高斯被广泛用于统计估计与机器学习，因为它的边缘分布与条件分布都有闭式表达式。在第 9 章线性回归中我们将大量使用这些闭式表达式。用高斯随机变量建模的一大优点是：往往无需做变量变换（第 6.7 节）。由于高斯分布完全由其均值与协方差确定，我们常常只需对随机变量的均值与协方差施加该变换，即可得到变换后的分布。

6.5.1　高斯的边缘分布与条件分布仍是高斯

下面在多变量随机变量的一般情形下介绍边缘化与条件化。若初读觉得困惑，建议读者先考虑两个单变量随机变量。设 X 与 Y 是两个维数可以不同的多变量随机变量。为考察施加概率求和规则的效果以及条件化的效果，我们按拼接状态 $[\boldsymbol{x}^\top \boldsymbol{y}^\top]^\top$ 显式写出高斯分布：

原书 p.199

$$p(\boldsymbol{x}, \boldsymbol{y}) = \mathcal{N}\left(\begin{bmatrix}\boldsymbol{\mu}_x \\ \boldsymbol{\mu}_y\end{bmatrix}, \begin{bmatrix}\Sigma_{xx} & \Sigma_{xy} \\ \Sigma_{yx} & \Sigma_{yy}\end{bmatrix}\right), \tag{6.64}$$

其中 $\Sigma_{xx} = \mathrm{Cov}[\boldsymbol{x}, \boldsymbol{x}]$、$\Sigma_{yy} = \mathrm{Cov}[\boldsymbol{y}, \boldsymbol{y}]$ 分别是 $\boldsymbol{x}$ 与 $\boldsymbol{y}$ 的边缘协方差矩阵，$\Sigma_{xy} = \mathrm{Cov}[\boldsymbol{x}, \boldsymbol{y}]$ 是 $\boldsymbol{x}$ 与 $\boldsymbol{y}$ 之间的互协方差矩阵。

条件分布 $p(\boldsymbol{x} \mid \boldsymbol{y})$ 也是高斯（图 6.9(c)），由下式给出（推导见 Bishop, 2006 第 2.3 节）：

$$p(\boldsymbol{x} \mid \boldsymbol{y}) = \mathcal{N}\big(\boldsymbol{\mu}_{x|y}, \Sigma_{x|y}\big) \tag{6.65}$$

$$\boldsymbol{\mu}_{x|y} = \boldsymbol{\mu}_x + \Sigma_{xy}\Sigma_{yy}^{-1}(\boldsymbol{y} - \boldsymbol{\mu}_y) \tag{6.66}$$

$$\Sigma_{x|y} = \Sigma_{xx} - \Sigma_{xy}\Sigma_{yy}^{-1}\Sigma_{yx}\,. \tag{6.67}$$

注意在 (6.66) 计算均值时，$\boldsymbol{y}$ 的取值是一次观察，不再是随机的。

注. 条件高斯分布出现在许多我们关心后验分布的地方：

- Kalman 滤波（Kalman, 1960）是信号处理中状态估计最核心的算法之一，它所做的无非就是计算联合分布的高斯条件（Deisenroth and Ohlsson, 2011; Särkkä, 2013）。
- 高斯过程（Rasmussen and Williams, 2006）是函数上分布的一种实用实现。在高斯过程中，我们假定随机变量联合高斯；通过对观察数据做（高斯）条件化，就能确定函数上的后验分布。
- 潜线性高斯模型（Roweis and Ghahramani, 1999; Murphy, 2012），包括概率主成分分析（PPCA）（Tipping and Bishop, 1999）。我们将在第 10.7 节更详细地讨论 PPCA。

联合高斯分布 $p(\boldsymbol{x}, \boldsymbol{y})$（见 (6.64)）的边缘分布 $p(\boldsymbol{x})$ 本身也是高斯，通过施加求和规则 (6.20) 计算，由下式给出：

$$p(\boldsymbol{x}) = \int p(\boldsymbol{x}, \boldsymbol{y})\,\mathrm{d}\boldsymbol{y} = \mathcal{N}(\boldsymbol{x} \mid \boldsymbol{\mu}_x, \Sigma_{xx})\,. \tag{6.68}$$

对 $p(\boldsymbol{y})$ 相应的结论成立，它通过对 $\boldsymbol{x}$ 边缘化得到。直观上，看 (6.64) 的联合分布时，我们把不感兴趣的一切都忽略（即积分掉）。图 6.9(b) 展示了这一点。

例 6.6 (高斯的边缘与条件)**.** 考虑图 6.9 所示的二元高斯分布：

$$p(x_1, x_2) = \mathcal{N}\left(\begin{bmatrix}0\\2\end{bmatrix}, \begin{bmatrix}0.3 & -1\\ -1 & 5\end{bmatrix}\right)\,. \tag{6.69}$$

我们可以用 (6.66)、(6.67) 计算在 $x_2 = -1$ 条件下单变量高斯的参数，分别得到均值与方差。数值上为

$$\mu_{x_1|x_2=-1} = 0 + (-1)\cdot 0.2\cdot(-1-2) = 0.6 \tag{6.70}$$

以及

$$\sigma^2_{x_1|x_2=-1} = 0.3 - (-1)\cdot 0.2\cdot(-1) = 0.1\,. \tag{6.71}$$

因此条件高斯为

$$p(x_1 \mid x_2 = -1) = \mathcal{N}(0.6, 0.1)\,. \tag{6.72}$$

相比之下，边缘分布 $p(x_1)$ 可由 (6.68) 得到，它本质上使用随机变量 x_1 的均值与方差，于是

$$p(x_1) = \mathcal{N}(0, 0.3)\,. \tag{6.73}$$

原书 p.200
原书 p.201

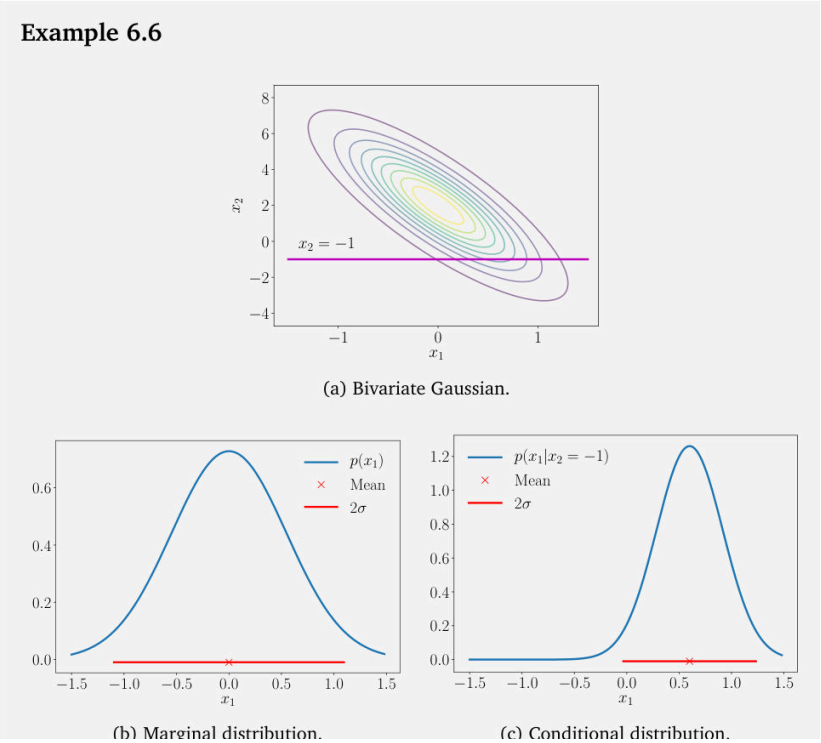


图 6.9: (a) 二元高斯；(b) 联合高斯分布的边缘分布仍是高斯；(c) 高斯的条件分布也是高斯（对应原图 Figure 6.9）。

6.5.2　高斯密度的乘积

对线性回归（第 9 章），我们需要计算高斯似然。此外，我们也许希望假定一个高斯先验（第 9.3 节）。我们应用贝叶斯定理计算后验，这导致似然与先验相乘，即两个高斯密度相乘。两个高斯 $\mathcal{N}(x \mid a, A)\mathcal{N}(x \mid b, B)$ 的乘积是一个被常数 $c \in \mathbb{R}$ 缩放的高斯分布，即 $c\mathcal{N}(x \mid c, C)$，其中

$$C = (A^{-1} + B^{-1})^{-1} \tag{6.74}$$

$$\boldsymbol{c} = C(A^{-1}\boldsymbol{a} + B^{-1}\boldsymbol{b}) \tag{6.75}$$

$$c = (2\pi)^{-\frac{D}{2}}|A + B|^{-\frac{1}{2}} \exp\left(-\frac{1}{2}(\boldsymbol{a} - \boldsymbol{b})^\top (A + B)^{-1}(\boldsymbol{a} - \boldsymbol{b})\right) . \tag{6.76}$$

缩放常数 c 本身也可写成以 $\boldsymbol{a}$ 或 $\boldsymbol{b}$ 为自变量、协方差矩阵“膨胀”为 $A + B$ 的高斯密度形式，即 $c = \mathcal{N}(\boldsymbol{a} \mid \boldsymbol{b}, A + B) = \mathcal{N}(\boldsymbol{b} \mid \boldsymbol{a}, A + B)$。

该推导留作本章末习题。

注. 为记号方便，即使 x 不是随机变量，我们有时也用 $\mathcal{N}(x \mid m, S)$ 来描述一个高斯密度的函数形式。前面的演示中我们刚这样做过，写了

$$c = \mathcal{N}(\boldsymbol{a} \mid \boldsymbol{b}, A + B) = \mathcal{N}(\boldsymbol{b} \mid \boldsymbol{a}, A + B) . \tag{6.77}$$

这里 $\boldsymbol{a}$ 与 $\boldsymbol{b}$ 都不是随机变量。但这样写 c 比 (6.76) 更紧凑。

6.5.3　求和与线性变换

若 X, Y 是独立高斯随机变量（即联合分布为 $p(x, y) = p(x)p(y)$），其中 $p(x) = \mathcal{N}(x \mid \mu_x, \Sigma_x)$、$p(y) = \mathcal{N}(y \mid \mu_y, \Sigma_y)$，则 $x + y$ 也服从高斯分布，由下式给出：

$$p(x + y) = \mathcal{N}(\mu_x + \mu_y, \Sigma_x + \Sigma_y) . \tag{6.78}$$

知道 $p(x+y)$ 是高斯后，均值与协方差矩阵即可用 (6.46)–(6.49) 的结果立即确定。当我们考虑作用于随机变量的 i.i.d. 高斯噪声时（如线性回归第 9 章的情形），这一性质将很重要。

例 6.7 (加权和)**.** 由于期望是线性运算，我们可以得到独立高斯随机变量的加权和

$$p(ax+by)=\mathcal{N}(a\mu_x+b\mu_y,\ a^2\Sigma_x+b^2\Sigma_y)\,. \tag{6.79}$$

注. 第 11 章会用到的一种情形是高斯密度的加权和。这与高斯随机变量的加权和不同。 原书 p.202

在下面的定理中，随机变量 x 来自由两个密度 $p_1(x)$、$p_2(x)$ 以权重 α 混合而成的密度。该定理可推广到多变量随机变量情形，因为期望的线性性对多变量随机变量也成立；但“随机变量平方”这一想法需替换为 $\boldsymbol{x}\boldsymbol{x}^\top$。

定理 6.12 (高斯混合的均值与方差)**.** 考虑两个单变量高斯密度的混合

$$p(x)=\alpha\,p_1(x)+(1-\alpha)\,p_2(x)\,, \tag{6.80}$$

其中标量 $0<\alpha<1$ 是混合权重，$p_1(x)$ 与 $p_2(x)$ 是参数不同的单变量高斯密度 (*(6.62)*)，即 $(\mu_1,\sigma_1^2)\neq(\mu_2,\sigma_2^2)$。则混合密度 $p(x)$ 的均值由各随机变量均值的加权和给出：

$$\mathbb{E}[x]=\alpha\mu_1+(1-\alpha)\mu_2\,. \tag{6.81}$$

混合密度 $p(x)$ 的方差为

$$\mathbb{V}[x]=\big[\alpha\sigma_1^2+(1-\alpha)\sigma_2^2\big]+\Big(\big[\alpha\mu_1^2+(1-\alpha)\mu_2^2\big]-\big[\alpha\mu_1+(1-\alpha)\mu_2\big]^2\Big)\,. \tag{6.82}$$

证明　混合密度 $p(x)$ 的均值由各随机变量均值的加权和给出。我们代入均值定义（定义 *6.4*）与混合 *(6.80)*，得到 原书 p.203

$$\begin{aligned}
\mathbb{E}[x]&=\int_{-\infty}^{\infty}x\,p(x)\,\mathrm{d}x && \text{(6.83a)}\\
&=\int_{-\infty}^{\infty}\big(\alpha x p_1(x)+(1-\alpha)xp_2(x)\big)\,\mathrm{d}x && \text{(6.83b)}\\
&=\alpha\int_{-\infty}^{\infty}xp_1(x)\,\mathrm{d}x+(1-\alpha)\int_{-\infty}^{\infty}xp_2(x)\,\mathrm{d}x && \text{(6.83c)}\\
&=\alpha\mu_1+(1-\alpha)\mu_2\,. && \text{(6.83d)}
\end{aligned}$$

要计算方差，可使用 *(6.44)* 中方差的原始分数形式，它需要随机变量平方之期望的表达式。这里使用随机变量函数（平方）的期望定义（定义 *6.3*）：

$$\begin{aligned}
\mathbb{E}[x^2]&=\int_{-\infty}^{\infty}x^2p(x)\,\mathrm{d}x && \text{(6.84a)}\\
&=\int_{-\infty}^{\infty}\big(\alpha x^2p_1(x)+(1-\alpha)x^2p_2(x)\big)\,\mathrm{d}x && \text{(6.84b)}\\
&=\alpha\int_{-\infty}^{\infty}x^2p_1(x)\,\mathrm{d}x+(1-\alpha)\int_{-\infty}^{\infty}x^2p_2(x)\,\mathrm{d}x && \text{(6.84c)}\\
&=\alpha(\mu_1^2+\sigma_1^2)+(1-\alpha)(\mu_2^2+\sigma_2^2)\,, && \text{(6.84d)}
\end{aligned}$$

最后一个等号再次使用了方差的原始分数形式 *(6.44)*，即 $\sigma^2=\mathbb{E}[x^2]-\mu^2$。把它整理为：随机变量平方的期望等于均值平方与方差之和。

于是方差由 *(6.84d)* 减去 *(6.83d)* 得到：

$$\begin{aligned}
\mathbb{V}[x]&=\mathbb{E}[x^2]-(\mathbb{E}[x])^2 && \text{(6.85a)}\\
&=\alpha(\mu_1^2+\sigma_1^2)+(1-\alpha)(\mu_2^2+\sigma_2^2)-\big(\alpha\mu_1+(1-\alpha)\mu_2\big)^2 && \text{(6.85b)}\\
&=\big[\alpha\sigma_1^2+(1-\alpha)\sigma_2^2\big]+\Big(\big[\alpha\mu_1^2+(1-\alpha)\mu_2^2\big]-\big[\alpha\mu_1+(1-\alpha)\mu_2\big]^2\Big)\,. && \text{(6.85c)}
\end{aligned}$$

注. 上述推导对任意密度都成立；但由于高斯完全由均值与方差确定，混合密度可闭式确定。

对混合密度，各个成分可看作条件分布（以成分身份为条件）。(6.85c) 是条件方差公式的一个例子，也称全方差定律，它一般地说：对两个随机变量 X 与 Y，有 $\mathbb{V}_X[x] = \mathbb{E}_Y[\mathbb{V}_X[x \mid y]] + \mathbb{V}_Y[\mathbb{E}_X[x \mid y]]$，即 X 的（总）方差等于条件方差的期望加上条件均值的方差。

全方差定律

我们在例 6.17 中考虑过二元标准高斯随机变量 X，并对它做了线性变换 $A\boldsymbol{x}$。结果是一个均值为零、协方差为 $AA^\top$ 的高斯随机变量。注意加上一个常向量会改变分布的均值而不影响其方差，即随机变量 $\boldsymbol{x} + \boldsymbol{\mu}$ 是均值为 $\boldsymbol{\mu}$、协方差为单位阵的高斯。因此，高斯随机变量的任何线性/仿射变换仍服从高斯分布。

高斯的线性/仿射变换仍为高斯

考虑高斯随机变量 $X \sim \mathcal{N}(\boldsymbol{\mu}, \Sigma)$。对一个形状合适的给定矩阵 A，令 Y 为使得 $\boldsymbol{y} = A\boldsymbol{x}$ 为 $\boldsymbol{x}$ 之变换版本的随机变量。利用期望是线性算子 (6.50) 计算 $\boldsymbol{y}$ 的均值：

$$\mathbb{E}[\boldsymbol{y}] = \mathbb{E}[A\boldsymbol{x}] = A\,\mathbb{E}[\boldsymbol{x}] = A\boldsymbol{\mu}\,. \tag{6.86}$$

类似地，$\boldsymbol{y}$ 的方差可用 (6.51) 求得：

$$\mathbb{V}[\boldsymbol{y}] = \mathbb{V}[A\boldsymbol{x}] = A\,\mathbb{V}[\boldsymbol{x}]\,A^\top = A\Sigma A^\top\,. \tag{6.87}$$

这意味着随机变量 $\boldsymbol{y}$ 服从

$$p(\boldsymbol{y}) = \mathcal{N}(\boldsymbol{y} \mid A\boldsymbol{\mu}, A\Sigma A^\top)\,. \tag{6.88}$$

现在考虑逆变换：当我们已知一个随机变量的均值是另一个随机变量的线性变换。对给定的满秩矩阵 $A \in \mathbb{R}^{M\times N}$（$M \geq N$），令 $\boldsymbol{y} \in \mathbb{R}^M$ 是均值为 $A\boldsymbol{x}$ 的高斯随机变量，即

原书 p.204

$$p(\boldsymbol{y}) = \mathcal{N}(\boldsymbol{y} \mid A\boldsymbol{x}, \Sigma)\,. \tag{6.89}$$

相应的概率分布 $p(\boldsymbol{x})$ 是什么？若 A 可逆，则可写 $\boldsymbol{x} = A^{-1}\boldsymbol{y}$ 并应用上一段的变换。但一般 A 不可逆，我们使用与伪逆（(3.57)）类似的做法：两边左乘 $A^\top$，再对 $A^\top A$（对称正定）求逆，得到关系

$$\boldsymbol{y} = A\boldsymbol{x} \quad\Longleftrightarrow\quad (A^\top A)^{-1}A^\top\boldsymbol{y} = \boldsymbol{x}\,. \tag{6.90}$$

因此 $\boldsymbol{x}$ 是 $\boldsymbol{y}$ 的线性变换，于是得到

$$p(\boldsymbol{x}) = \mathcal{N}\big(\boldsymbol{x} \mid (A^\top A)^{-1}A^\top\boldsymbol{y},\ (A^\top A)^{-1}A^\top\Sigma A(A^\top A)^{-1}\big)\,. \tag{6.91}$$

6.5.4　从多元高斯分布采样

我们不打算解释计算机上随机抽样的微妙之处，感兴趣的读者可参阅 Gentle (2004)。对多元高斯，这一过程分三个阶段：第一，需要一个伪随机数源，在区间 $[0, 1]$ 上提供均匀样本；第二，用一个非线性变换（如 Box–Müller 变换，Devroye, 1986）从单变量高斯得到样本；第三，把这些样本拼成一个向量，得到多元标准正态 $\mathcal{N}(0, I)$ 的样本。

对一般的多元高斯（即均值非零、协方差非单位阵），我们利用高斯随机变量线性变换的性质。设我们想从均值为 $\boldsymbol{\mu}$、协方差矩阵为 Σ 的多元高斯分布生成样本 $\boldsymbol{x}_i$，$i = 1, \ldots, n$。我们希望从一个能提供多元标准正态 $\mathcal{N}(0, I)$ 样本的采样器出发来构造样本。要从多元正态 $\mathcal{N}(\boldsymbol{\mu}, \Sigma)$ 得到样本，可利用高斯随机变量线性变换的性质：若 $\boldsymbol{x} \sim \mathcal{N}(0, I)$，则 $\boldsymbol{y} = A\boldsymbol{x} + \boldsymbol{\mu}$（其中 $AA^\top = \Sigma$）是均值为 $\boldsymbol{\mu}$、协方差矩阵为 Σ 的高斯。A 的一个方便选择是用协方差矩阵 $\Sigma = AA^\top$ 的 Cholesky 分解（第 4.3 节）。Cholesky 分解的好处是 A 为三角阵，计算高效。

对矩阵做 Cholesky 分解要求其对称正定；协方差矩阵满足该性质（第 3.2.3 节）。

6.6　共轭性与指数族

原书 p.205

统计学教科书中许多“有名有姓”的概率分布，都是为了建模特定类型的现象而被发现的。例如我们在第 6.5 节见过的高斯分布。这些分布之间还以复杂的方式相互关联（Leemis and McQueston, 2008）。对刚入门的人来说，该选用哪个分布会让人无从下手。此外，这些分布很多是在统计与计算还靠纸笔的时代发现的。在计算时代追问哪些概念仍然有意义，是很自然的（Efron and Hastie, 2016）。上一节我们看到：当分布是高斯时推断所需的许多运算都能方便地算出。此时值得回顾一下在机器学习语境中操作概率分布的期望性质：

“计算机”曾是一种职业。

1. 施加概率规则（如贝叶斯定理）时应有某种“封闭性”。所谓封闭，是指施加某一运算后返回同类型的对象。
2. 随着收集到更多数据，我们不需要更多参数来描述该分布。
3. 既然我们关心从数据中学习，就希望参数估计表现良好。

结果表明，一类称为指数族的分布在保持良好计算与推断性质的同时，提供了恰当的一般性平衡。在引入指数族之前，先看三个“有名”分布的成员：Bernoulli（例 6.8）、二项（例 6.9）和 Beta（例 6.10）分布。

指数族

例 6.8 (Bernoulli 分布)**.** Bernoulli 分布是单个二元随机变量 X（状态 $x \in \{0,1\}$）的分布。它由一个连续参数 $\mu \in [0,1]$ 控制，μ 表示 $X=1$ 的概率。Bernoulli 分布 $\mathrm{Ber}(\mu)$ 定义为

Bernoulli 分布

$$p(x \mid \mu) = \mu^x (1-\mu)^{1-x}, \qquad x \in \{0,1\}, \tag{6.92}$$

$$\mathbb{E}[x] = \mu, \tag{6.93}$$

$$\mathbb{V}[x] = \mu(1-\mu), \tag{6.94}$$

其中 $\mathbb{E}[x]$ 与 $\mathbb{V}[x]$ 是二元随机变量 X 的均值与方差。Bernoulli 分布可用的一个例子是：当我们想建模抛硬币出现“正面”的概率时。

注. 上面重写 Bernoulli 分布时，把布尔变量当作数值 0 或 1 并写到指数上，这是机器学习教材中常用的技巧。另一个例子出现在表达多项分布时。

原书 p.206

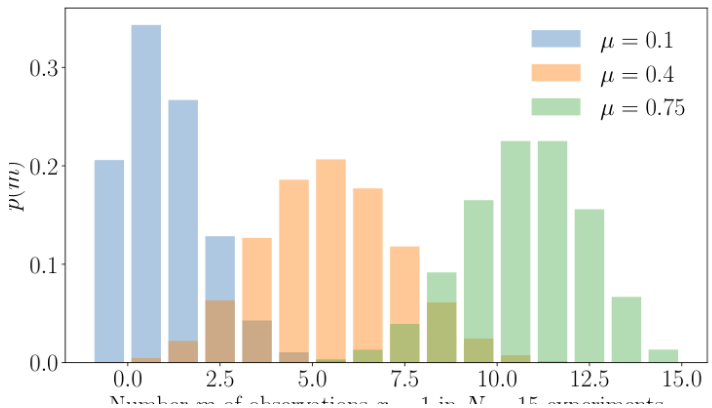


图 6.10: $\mu \in \{0.1, 0.4, 0.75\}$、$N = 15$ 时二项分布的例子（对应原图 Figure 6.10）。

二项分布

例 6.9 (二项分布)**.** 二项分布是 Bernoulli 分布向整数上分布的推广（图 6.10）。具体地二项分布可用来描述：在一组来自 Bernoulli 分布（$p(X=1)=\mu\in[0,1]$）的 N 个样本中，观察到 $X=1$ 出现 m 次的概率。二项分布 $\mathrm{Bin}(N,\mu)$ 定义为

$$p(m\mid N,\mu)=\binom{N}{m}\mu^m(1-\mu)^{N-m}\,, \tag{6.95}$$

$$\mathbb{E}[m]=N\mu\,, \tag{6.96}$$

$$\mathbb{V}[m]=N\mu(1-\mu)\,, \tag{6.97}$$

其中 $\mathbb{E}[m]$ 与 $\mathbb{V}[m]$ 分别是 m 的均值与方差。二项分布可用的一个例子是：若单次试验出现正面的概率为 μ，我们想描述在 N 次抛硬币试验中观察到 m 次“正面”的概率。

原书 p.207

Beta 分布

例 6.10 (Beta 分布)**.** 我们也许想在一个有限区间上建模连续随机变量。Beta 分布是连续随机变量 $\mu\in[0,1]$ 上的分布，常用来表示某个二元事件的概率（例如控制 Bernoulli 分布的参数）。Beta 分布 $\mathrm{Beta}(\alpha,\beta)$（图 6.11）本身由两个参数 $\alpha>0$、$\beta>0$ 控制，定义为

$$p(\mu\mid\alpha,\beta)=\frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)}\mu^{\alpha-1}(1-\mu)^{\beta-1} \tag{6.98}$$

$$\mathbb{E}[\mu]=\frac{\alpha}{\alpha+\beta}\,,\qquad \mathbb{V}[\mu]=\frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)} \tag{6.99}$$

其中 $\Gamma(\cdot)$ 是 Gamma 函数，定义为

$$\Gamma(t):=\int_0^\infty x^{t-1}\exp(-x)\,\mathrm{d}x,\qquad t>0\,. \tag{6.100}$$

$$\Gamma(t+1)=t\,\Gamma(t)\,. \tag{6.101}$$

注意 (6.98) 中 Gamma 函数之比用于归一化 Beta 分布。

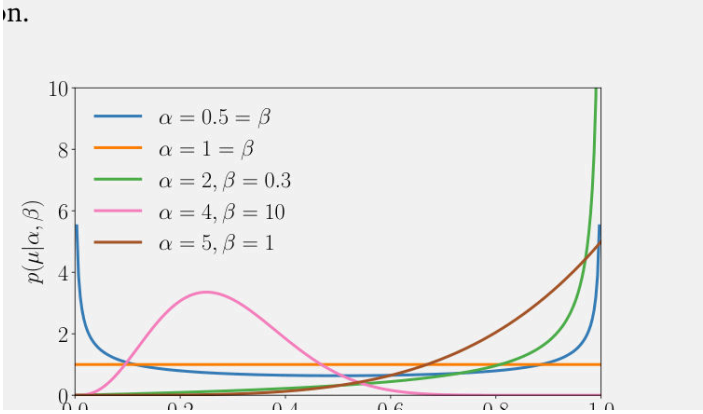


图 6.11: 不同 α、β 值下 Beta 分布的例子（对应原图 Figure 6.11）。

直观上，α 把概率质量推向 1，而 β 把概率质量推向 0。有一些特殊情形（Murphy, 2012）：

- $\alpha=1=\beta$ 时，得到均匀分布 $\mathcal{U}[0,1]$。
- $\alpha,\beta<1$ 时，得到在 0 与 1 处有尖峰的双峰分布。
- $\alpha,\beta>1$ 时，分布单峰。

- $\alpha, \beta > 1$ 且 $\alpha = \beta$ 时，分布单峰、对称，中心位于区间 $[0, 1]$，即众数/均值在 $\frac{1}{2}$。

注. 有名有姓的分布有一整个“动物园”，它们之间以不同方式相互关联（Leemis and McQueston, 2008）。值得记住的是：每个有名分布都是为特定理由而造，但也可能有其他用途。了解某个分布被创造出来的缘由，往往能帮助我们洞悉如何最好地使用它。我们引入前面三个分布，是为了说明共轭性（第 6.6.1 节）与指数族（第 6.6.3 节）的概念。 原书 p.208

6.6.1　共轭性

由贝叶斯定理 (6.23)，后验正比于先验与似然的乘积。指定先验有两点棘手：第一，先验应概括我们在看到任何数据之前对问题的了解，这往往难以描述；第二，往往无法解析地算出后验分布。然而，有一些先验在计算上很方便：共轭先验。 共轭先验

定义 6.13 (共轭先验)**.** 若后验与先验具有相同的形式/类型，则称该先验对似然函数是共轭的。共轭性特别方便，因为我们可以通过更新先验分布的参数，用代数方式算出后验分布。

注. 从概率分布的几何来看，共轭先验与似然保持相同的距离结构（Agarwal and Daumé III, 2010）。

为引入共轭先验的具体例子，我们在例 6.11 中介绍二项分布（定义在离散随机变量上）与 Beta 分布（定义在连续随机变量上）。

例 6.11 (Beta–二项共轭)**.** 考虑二项随机变量 $x \sim \text{Bin}(N, \mu)$，其中

$$p(x \mid N, \mu) = \binom{N}{x} \mu^x (1-\mu)^{N-x}, \qquad x = 0, 1, \ldots, N, \tag{6.102}$$

它是在 N 次抛硬币中得到 x 次“正面”的概率，μ 是“正面”的概率。我们在参数 μ 上放一个 Beta 先验，即 $\mu \sim \text{Beta}(\alpha, \beta)$，其中

$$p(\mu \mid \alpha, \beta) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \mu^{\alpha-1} (1-\mu)^{\beta-1}. \tag{6.103}$$

若现在观察到某个结果 $x = h$，即在 N 次抛硬币中看到 h 次正面，则我们按如下方式计算 μ 的后验分布：

$$\begin{aligned} p(\mu \mid x = h, N, \alpha, \beta) &\propto p(x \mid N, \mu)\, p(\mu \mid \alpha, \beta) && \text{(6.104a)} \\ &\propto \mu^h (1-\mu)^{N-h} \mu^{\alpha-1} (1-\mu)^{\beta-1} && \text{(6.104b)} \\ &= \mu^{h+\alpha-1} (1-\mu)^{(N-h)+\beta-1} && \text{(6.104c)} \\ &\propto \text{Beta}(h+\alpha,\ N-h+\beta), && \text{(6.104d)} \end{aligned}$$

即后验分布与先验一样是 Beta 分布，也就是说，对二项似然中的参数 μ，Beta 先验是共轭的。

下面这个例子将导出与 Beta–二项共轭类似的结果。这里我们说明 Beta 分布是 Bernoulli 分布的共轭先验。 原书 p.209

例 6.12 (Beta–Bernoulli 共轭)**.** 设 $x \in \{0, 1\}$ 服从参数为 $\theta \in [0, 1]$ 的 Bernoulli 分布，即 $p(x = 1 \mid \theta) = \theta$，也可写成 $p(x \mid \theta) = \theta^x (1-\theta)^{1-x}$。设 θ 服从参数为 α, β 的 Beta 分布，

表 6.2: 常见似然函数的共轭先验示例（对应原书 Table 6.2）。

似然	共轭先验	后验
Bernoulli	Beta	Beta
二项	Beta	Beta
高斯（单变量）	高斯/逆 Gamma	高斯/逆 Gamma
高斯（多变量）	高斯/逆 Wishart	高斯/逆 Wishart
多项	Dirichlet	Dirichlet

即 $p(\theta \mid \alpha, \beta) \propto \theta^{\alpha-1}(1-\theta)^{\beta-1}$。把 Beta 与 Bernoulli 分布相乘，得到

$$
\begin{aligned}
p(\theta \mid x, \alpha, \beta) &\propto p(x \mid \theta)\, p(\theta \mid \alpha, \beta) && \text{(6.105a)}\\
&= \theta^{x}(1-\theta)^{1-x}\theta^{\alpha-1}(1-\theta)^{\beta-1} && \text{(6.105b)}\\
&= \theta^{\alpha+x-1}(1-\theta)^{\beta+(1-x)-1} && \text{(6.105c)}\\
&\propto p(\theta \mid \alpha + x,\ \beta + (1-x))\,. && \text{(6.105d)}
\end{aligned}
$$

最后一行是参数为 $(\alpha + x, \beta + (1-x))$ 的 Beta 分布。

表 6.2 列出了概率建模中一些标准似然之参数的共轭先验示例。多项、逆 Gamma、逆 Wishart、Dirichlet 等分布可在任何统计教材中查到，例如 Bishop (2006) 就有描述。Beta 分布既是二项似然中参数 μ 的共轭先验，也是 Bernoulli 似然中参数 μ 的共轭先验对高斯似然，我们可以在均值上放一个共轭高斯先验。高斯似然在表中出现两次，是因为需要区分单变量与多变量情形。在单变量（标量）情形，逆 Gamma 是方差的共轭先验；在多变量情形，我们用共轭的逆 Wishart 分布作为协方差矩阵的先验。Dirichlet 分布是多项似然的共轭先验。更多细节参见 Bishop (2006)。

Gamma 先验是单变量高斯似然中精度（方差倒数）的共轭先验；Wishart 先验是多变量高斯似然中精度矩阵（协方差矩阵逆）的共轭先验。

6.2.2　充分统计量

回忆一个随机变量的统计量是该随机变量的确定性函数。例如，若 $\boldsymbol{x} = [x_1, \ldots, x_N]^\top$ 是单变量高斯随机变量组成的向量，即 $x_n \sim \mathcal{N}(\mu, \sigma^2)$，则样本均值 $\hat{\mu} = \frac{1}{N}(x_1 + \cdots + x_N)$ 就是一个统计量。Ronald Fisher 爵士提出了充分统计量的概念：存在这样一些统计量它们包含了从与所论分布相对应的数据中所能推断出的全部可用信息。换言之，充分统计量携带着对总体作推断所需的全部信息，即它们是足以表示该分布的统计量。

充分统计量

对一族由参数 θ 参数化的分布，设 X 是分布为 $p(x \mid \theta_0)$ 的随机变量，θ_0 未知。统计量向量 $\boldsymbol{\phi}(x)$ 称为 θ_0 的充分统计量，若它包含关于 θ_0 的全部可能信息。要把“包含全部可能信息”说得更正式，这意味着给定 θ 时 x 的概率可分解为一部分不依赖 θ，以及另一部分只经由 $\boldsymbol{\phi}(x)$ 依赖 θ。Fisher–Neyman 分解定理把这一概念形式化，我们不加证明地列为定理 6.14。

定理 6.14 (Fisher–Neyman)**.** *[Lehmann and Casella (1998) 定理 6.5]* 设 X 有概率密度函数 $p(x \mid \theta)$。则统计量 $\boldsymbol{\phi}(x)$ 对 θ 充分，当且仅当 $p(x \mid \theta)$ 可写成如下形式

$$
p(x \mid \theta) = h(x)\, g_\theta\big(\boldsymbol{\phi}(x)\big)\,, \tag{6.106}
$$

其中 $h(x)$ 是与 θ 无关的分布，g_θ 经由充分统计量 $\boldsymbol{\phi}(x)$ 捕获对 θ 的全部依赖。

若 $p(x \mid \theta)$ 不依赖 θ，则对任意函数 $\boldsymbol{\phi}$，$\boldsymbol{\phi}(x)$ 平凡地是充分统计量。更有意思的情形是 $p(x \mid \theta)$ 只依赖 $\boldsymbol{\phi}(x)$ 而不依赖 x 本身；此时 $\boldsymbol{\phi}(x)$ 是 θ 的充分统计量。

在机器学习中，我们考虑从一个分布抽取的有限个样本。可以想见，对简单分布（如例 6.8 的 Bernoulli）我们只需少量样本就能估计其参数。我们也可以考虑相反的问题：若有一组数据（来自某未知分布的样本），哪个分布拟合得最好？一个自然的问题是：随着观察到更多数据，我们是否需要更多参数 θ 来描述该分布？结果表明一般而言答案是肯定的，这属于非参数统计的研究范畴（Wasserman, 2007）。反过来问：哪一族分布具有有限维充分统计量，即描述它们所需的参数个数不会任意增长？答案就是指数族分布，下一节介绍。

原书 p.211

6.6.3　指数族

考虑（离散或连续随机变量的）分布时，我们可以有三个抽象层次。在第一层（最具体的一端），我们有一个参数固定的、特定的有名分布，例如均值为零、方差为 1 的单变量高斯 $\mathcal{N}(0, 1)$。在机器学习中，我们常使用第二层抽象：固定参数形式（单变量高斯），从数据推断参数。例如假定一个均值 μ 未知、方差 σ^2 未知的单变量高斯 $\mathcal{N}(\mu, \sigma^2)$，用最大似然拟合确定最佳参数 (μ, σ^2)。在第 9 章线性回归中我们会看到这样的例子。第三层抽象是考虑分布族，本书考虑指数族。单变量高斯是指数族的一个成员。许多广泛使用的统计模型，包括表 6.2 中所有“有名”模型，都是指数族的成员，它们都可以统一为一个概念（Brown, 1986）。

注. 一段简短的历史逸闻：与数学和科学中的许多概念一样，指数族也由不同研究者在同一时期各自独立发现。1935–1936 年间，塔斯马尼亚的 Edwin Pitman、巴黎的 Georges Darmois 和纽约的 Bernard Koopman 各自独立证明了：在重复独立抽样下，指数族是唯一具有有限维充分统计量的分布族（Lehmann and Casella, 1998）。

原书 p.212

指数族是一族以 $\theta \in \mathbb{R}^D$ 参数化的概率分布，形式为

$$p(x \mid \theta) = h(x)\, \exp\left(\langle \theta, \boldsymbol{\phi}(x) \rangle - A(\theta)\right), \tag{6.107}$$

其中 $\boldsymbol{\phi}(x)$ 是充分统计量向量。一般地，(6.107) 中可用任意内积（第 3.2 节）；为具体起见，这里用标准点积（$\langle \theta, \boldsymbol{\phi}(x) \rangle = \theta^\top \boldsymbol{\phi}(x)$）。注意指数族的形式本质上就是 Fisher–Neyman 定理（定理 6.14）中 $g_\theta(\boldsymbol{\phi}(x))$ 的一种特定表达。

因子 $h(x)$ 可以被吸收到点积项中：把充分统计量向量 $\boldsymbol{\phi}(x)$ 增加一个分量 $(\log h(x))$，并约束相应参数 $\theta_0 = 1$。项 $A(\theta)$ 是归一化常数，保证分布求和（或积分）为 1，称为对数配分函数。要直观地理解指数族，可以忽略这两项，把指数族看作如下形式的分布：

对数配分函数

$$p(x \mid \theta) \propto \exp\left(\theta^\top \boldsymbol{\phi}(x)\right). \tag{6.108}$$

对这种参数化，参数 θ 称为自然参数。乍看之下，指数族不过是对点积结果再套一个指数函数的平凡变换；然而，基于“我们能把关于数据的信息捕获到 $\boldsymbol{\phi}(x)$ 中”这一事实，它带来了许多便于建模、便于高效计算的推论。

自然参数

例 6.13 (高斯作为指数族)**.** 考虑单变量高斯分布 $\mathcal{N}(\mu, \sigma^2)$。令 $\boldsymbol{\phi}(x) = \begin{bmatrix} x \\ x^2 \end{bmatrix}$。则由指数族定义，

$$p(x \mid \theta) \propto \exp(\theta_1 x + \theta_2 x^2). \tag{6.109}$$

令

$$\theta = \left[\frac{\mu}{\sigma^2}, -\frac{1}{2\sigma^2}\right]^\top \tag{6.110}$$

代入 (6.109)，得到

$$p(x \mid \theta) \propto \exp\left(\frac{\mu x}{\sigma^2} - \frac{x^2}{2\sigma^2}\right) \propto \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right). \tag{6.111}$$

因此，单变量高斯分布是指数族的一个成员，充分统计量为 $\boldsymbol{\phi}(x) = \begin{bmatrix} x \\ x^2 \end{bmatrix}$，自然参数为 (6.110) 中的 θ。

例 6.14 (Bernoulli 作为指数族)**.** 回忆例 6.8 的 Bernoulli 分布

$$p(x \mid \mu) = \mu^x (1-\mu)^{1-x}, \qquad x \in \{0, 1\}. \tag{6.112}$$

它可写成指数族形式

$$\begin{aligned} p(x \mid \mu) &= \exp\left(\log(\mu^x (1-\mu)^{1-x})\right) && \text{(6.113a)} \\ &= \exp\left(x \log \mu + (1-x)\log(1-\mu)\right) && \text{(6.113b)} \\ &= \exp\left(x \log \mu - x \log(1-\mu) + \log(1-\mu)\right) && \text{(6.113c)} \\ &= \exp\left(x \log \frac{\mu}{1-\mu} + \log(1-\mu)\right). && \text{(6.113d)} \end{aligned}$$

最后一行 (6.113d) 可识别为指数族形式 (6.107)，只要注意到

$$h(x) = 1 \tag{6.114}$$

原书 p.213

$$\theta = \log \frac{\mu}{1-\mu} \tag{6.115}$$

$$\boldsymbol{\phi}(x) = x \tag{6.116}$$

$$A(\theta) = -\log(1-\mu) = \log(1 + \exp(\theta)). \tag{6.117}$$

θ 与 μ 的关系可逆，从而

$$\mu = \frac{1}{1 + \exp(-\theta)}. \tag{6.118}$$

关系 (6.118) 用于得到 (6.117) 的右端等式。

注. 原 Bernoulli 参数 μ 与自然参数 θ 之间的关系称为 sigmoid 或 logistic 函数。注意 $\mu \in (0, 1)$ 而 $\theta \in \mathbb{R}$，因此 sigmoid 函数把一个实数压缩到 $(0, 1)$ 区间。这一性质在机器学习中很有用，例如它用于 logistic 回归（Bishop, 2006, 4.3.2 节），也用作神经网络中的非线性激活函数（Goodfellow et al., 2016, 第 6 章）。 sigmoid

要找出某个特定分布（例如表 6.2 中的那些）的共轭分布的参数形式，往往并不显然。指数族为找出共轭分布对提供了一条方便的途径。考虑随机变量 X 是指数族 (6.107) 的一个成员：

$$p(x \mid \theta) = h(x)\, \exp\left(\langle \theta, \boldsymbol{\phi}(x) \rangle - A(\theta)\right). \tag{6.119}$$

指数族的每个成员都有一个共轭先验（Brown, 1986）

$$p(\theta \mid \boldsymbol{\gamma}) = h_c(\theta)\, \exp\left(\left\langle \begin{bmatrix} \gamma_1 \\ \gamma_2 \end{bmatrix}, \begin{bmatrix} \theta \\ -A(\theta) \end{bmatrix} \right\rangle - A_c(\boldsymbol{\gamma})\right), \tag{6.120}$$

其中 $\boldsymbol{\gamma} = \begin{bmatrix} \gamma_1 \\ \gamma_2 \end{bmatrix}$ 的维数为 $\dim(\theta) + 1$。共轭先验的充分统计量是 $\begin{bmatrix} \theta \\ -A(\theta) \end{bmatrix}$。利用指数族共轭先验的一般形式，我们可以导出与特定分布相对应的共轭先验函数形式。

例 6.15 (Bernoulli 的标准共轭先验)**.** 回忆 Bernoulli 分布的指数族形式 (6.113d)

$$p(x \mid \mu) = \exp\left(x \log \frac{\mu}{1-\mu} + \log(1-\mu)\right) . \tag{6.121}$$

标准共轭先验具有形式

原书 p.214

$$p(\mu \mid \alpha, \beta) = \frac{\mu}{1-\mu} \exp\left(\alpha \log \frac{\mu}{1-\mu} + (\beta+\alpha)\log(1-\mu) - A_c(\boldsymbol{\gamma})\right) , \tag{6.122}$$

其中定义 $\boldsymbol{\gamma} := [\alpha,\ \beta+\alpha]^\top$、$h_c(\mu) := \mu/(1-\mu)$。于是 (6.122) 化简为

$$p(\mu \mid \alpha, \beta) = \exp\left((\alpha-1)\log\mu + (\beta-1)\log(1-\mu) - A_c(\alpha,\beta)\right) . \tag{6.123}$$

把它写成非指数族形式，得到

$$p(\mu \mid \alpha, \beta) \propto \mu^{\alpha-1}(1-\mu)^{\beta-1} , \tag{6.124}$$

我们认出这就是 Beta 分布 (6.98)。在例 6.12 中，我们假定 Beta 分布是 Bernoulli 分布的共轭先验，并证明了它确实是共轭先验。在本例中，我们通过考察 Bernoulli 分布在指数族形式下的标准共轭先验，导出了 Beta 分布的形式。

如上一节所述，指数族的主要动机是它们具有有限维充分统计量。此外，共轭分布容易写出，而且共轭分布也来自指数族。从推断角度看，最大似然估计表现良好，因为充分统计量的经验估计是其总体值的最优估计（回忆高斯的均值与协方差）。从优化角度看，对数似然函数是凹的，可应用高效的优化方法（第 7 章）。

6.7　变量替换/逆变换

看起来已知的分布非常多，但实际上我们给得起名字的分布集合相当有限。因此，理解变换后的随机变量服从什么分布往往很有用。例如，设 X 是服从单变量正态分布 $\mathcal{N}(0,1)$ 的随机变量，X^2 的分布是什么？另一个在机器学习中相当常见的例子是：给定 X_1, X_2 都是单变量标准正态，$\frac{1}{2}(X_1+X_2)$ 的分布是什么？

算出 $\frac{1}{2}(X_1+X_2)$ 分布的一种做法是：计算 X_1 与 X_2 的均值和方差，再把它们组合起来。如第 6.4.4 节所见，当考虑随机变量的仿射变换时，我们能算出结果随机变量的均值与方差。然而，我们可能无法得到变换后分布的函数形式；此外，我们还可能关心随机变量的非线性变换，其闭式表达式并不容易得到。

原书 p.215

注 (记号)*.* 本节中，我们将明确区分随机变量与其取值。回忆我们用大写字母 X, Y 表示随机变量，用小写字母 x, y 表示随机变量在目标空间 $\mathcal{T}$ 中取的值。离散随机变量 X 的 pmf 我们显式写作 $P(X=x)$；对连续随机变量 X（第 6.2.2 节），pdf 写作 $f(x)$，cdf 写作 $F_X(x)$。

我们将考察两种求随机变量变换后分布的途径：一种是利用累积分布函数定义的直接途径，另一种是使用微积分链式法则（第 5.2.2 节）的变量替换途径。变量替换途径被广泛使用，因为它为“尝试计算变换所导致的分布”提供了一套“配方”。我们将讲解单变量随机变量的技巧，对一般的多变量情形只给出结果。

矩母函数也可用于研究随机变量的变换（Casella and Berger, 2002, 第2章）。

离散随机变量的变换可以直接理解。设离散随机变量 X 有 pmf $P(X=x)$（第 6.2.1 节），并有可逆函数 $U(x)$。考虑变换后的随机变量 $Y := U(X)$，其 pmf 为 $P(Y=y)$。则

$$P(Y=y) = P(U(X)=y) \qquad \text{（所关心的变换）} \tag{6.125a}$$

$$= P(X = U^{-1}(y)) \qquad \text{（取逆）} \tag{6.125b}$$

其中我们可观察到 $x = U^{-1}(y)$。因此，对离散随机变量，变换直接改变各个事件（概率作相应变换）。

6.7.1　分布函数技巧

分布函数技巧回到第一性原理，使用 cdf 的定义 $F_X(x) = P(X \leq x)$ 以及其微分就是 pdf $f(x)$ 这一事实（Wasserman, 2004, 第 2 章）。对随机变量 X 和函数 U，我们通过下面两步求随机变量 $Y := U(X)$ 的 pdf：

1. 求 cdf：
$$F_Y(y) = P(Y \leq y) \tag{6.126}$$
2. 对 cdf $F_Y(y)$ 求导得 pdf $f(y)$：
$$f(y) = \frac{\mathrm{d}}{\mathrm{d}y} F_Y(y)\,. \tag{6.127}$$

我们还需记住，随机变量的定义域可能因 U 的变换而改变。 原书 p.216

例 6.16 (平方变换)**.** 设 X 是连续随机变量，在 $0 \leq x \leq 1$ 上有概率密度函数
$$f(x) = 3x^2\,. \tag{6.128}$$

我们想求 $Y = X^2$ 的 pdf。函数 f 关于 x 是递增的，因此 y 的取值落在区间 $[0, 1]$ 内。我们得到

$$\begin{aligned}
F_Y(y) &= P(Y \leq y) && \text{（cdf 定义）} && (6.129a)\\
&= P(X^2 \leq y) && \text{（所关心的变换）} && (6.129b)\\
&= P(X \leq y^{1/2}) && \text{（取逆）} && (6.129c)\\
&= F_X(y^{1/2}) && \text{（cdf 定义）} && (6.129d)\\
&= \int_0^{y^{1/2}} 3t^2\,\mathrm{d}t && \text{（cdf 即定积分）} && (6.129e)\\
&= \left[t^3\right]_{t=0}^{t=y^{1/2}} && \text{（积分结果）} && (6.129f)\\
&= y^{3/2}\,, \qquad 0 \leq y \leq 1\,. && && (6.129g)
\end{aligned}$$

因此 Y 的 cdf 为
$$F_Y(y) = y^{3/2} \tag{6.130}$$
对 $0 \leq y \leq 1$。为得到 pdf，对 cdf 求导
$$f(y) = \frac{\mathrm{d}}{\mathrm{d}y} F_Y(y) = \frac{3}{2} y^{1/2} \tag{6.131}$$
对 $0 \leq y \leq 1$。

在例 6.16 中，我们考虑的是严格单调递增函数 $f(x) = 3x^2$。这意味着我们可以算出反函数。一般地，我们要求所关心的函数 $y = U(x)$ 有逆 $x = U^{-1}(y)$。一个有用的结果是：取随机变量 X 的累积分布函数 $F_X(x)$，并把它当作变换 $U(x)$。这导出下面的定理。

有逆的函数称为双射函数（第2.7节）。

定理 6.15 (概率积分变换)**.** *[Casella and Berger (2002) 定理 2.1.10]* 设 X 是连续随机变量，其累积分布函数 $F_X(x)$ 严格单调。则由
$$Y := F_X(X) \tag{6.132}$$
定义的随机变量 Y 服从均匀分布。

定理 6.15 称为概率积分变换，它被用来推导从分布中采样的算法：把从均匀随机变量采样的结果作变换（Bishop, 2006）。该算法先从均匀分布生成一个样本，再用逆 cdf（假设它可得）对其作变换，得到从目标分布采样的样本。概率积分变换还用于检验一个样本是否来自某一特定分布的假设检验（Lehmann and Romano, 2005）。“cdf 的输出给出均匀分布”这一想法也构成 copula 的基础（Nelsen, 2006）。

概率积分变换

6.7.2　变量替换

第 6.7.1 节的分布函数技巧是从第一性原理导出的，它基于 cdf 的定义，并利用逆函数、微分与积分的性质。这一第一性原理的论证依赖两个事实：

1. 我们能把 Y 的 cdf 改写成 X 的 cdf 的表达式。
2. 我们能对 cdf 求导得到 pdf。

让我们一步步拆解推理过程，目标是理解定理 6.16 中更一般的变量替换途径。

概率中的变量替换依赖微积分中的变量替换法（Tandra, 2014）。

注. “变量替换”这一名字来自：遇到难积的分时换积分变量。对单变量函数，我们使用积分的换元法则

$$\int f(g(x))\, g'(x)\, \mathrm{d}x = \int f(u)\, \mathrm{d}u\,, \qquad \text{其中} u = g(x)\,. \tag{6.133}$$

这条法则的推导基于微积分链式法则 (5.32)，并两次应用微积分基本定理。微积分基本定理把“积分与微分互为某种逆运算”这一事实形式化。对这条法则的直观理解，可以这样（粗略地）想：对等式 $u = g(x)$ 作微小改变（微分），即把 $\Delta u = g'(x)\Delta x$ 看作 $u = g(x)$ 的微分。代入 $u = g(x)$ 后，(6.133) 右端积分内的自变量变成 $f(g(x))$。再假装 $\mathrm{d}u \approx \Delta u = g'(x)\Delta x$、$\mathrm{d}x \approx \Delta x$，就得到 (6.133)。

考虑单变量随机变量 X，以及一个可逆函数 U，它给出另一个随机变量 $Y = U(X)$。设随机变量 X 的状态为 $x \in [a, b]$。由 cdf 定义，有

$$F_Y(y) = P(Y \leq y)\,. \tag{6.134}$$

我们关心随机变量的函数 U：

原书 p.218

$$P(Y \leq y) = P(U(X) \leq y)\,, \tag{6.135}$$

其中假定函数 U 可逆。区间上的可逆函数要么严格递增，要么严格递减。若 U 严格递增，则其逆 U^{-1} 也严格递增。把逆 U^{-1} 作用于 $P(U(X) \leq y)$ 的两端，得到

$$P(U(X) \leq y) = P(U^{-1}(U(X)) \leq U^{-1}(y)) = P(X \leq U^{-1}(y))\,. \tag{6.136}$$

(6.136) 最右端是 X 的 cdf 的表达式。回忆 cdf 用 pdf 表示的定义：

$$P(X \leq U^{-1}(y)) = \int_a^{U^{-1}(y)} f(x)\, \mathrm{d}x\,. \tag{6.137}$$

现在我们得到了 Y 的 cdf 用 x 表示的表达式：

$$F_Y(y) = \int_a^{U^{-1}(y)} f(x)\, \mathrm{d}x\,. \tag{6.138}$$

为得到 pdf，对 y 求导 (6.138)：

$$f(y) = \frac{\mathrm{d}}{\mathrm{d}y} F_y(y) = \frac{\mathrm{d}}{\mathrm{d}y} \int_a^{U^{-1}(y)} f(x)\, \mathrm{d}x\,. \tag{6.139}$$

注意右端积分是关于 x 的，但因为我们对 y 求导，需要一个关于 y 的积分。具体地，我们用 (6.133) 作换元：

$$\int f(U^{-1}(y))\,U^{-1\prime}(y)\,\mathrm{d}y = \int f(x)\,\mathrm{d}x\,, \qquad \text{其中} x = U^{-1}(y)\,. \tag{6.140}$$

对 (6.139) 右端使用 (6.140)，得到

$$f(y) = \frac{\mathrm{d}}{\mathrm{d}y}\int_a^{U^{-1}(y)} f_x(U^{-1}(y))\,U^{-1\prime}(y)\,\mathrm{d}y\,. \tag{6.141}$$

我们再回忆微分是线性算子，并用下标 x 提醒自己 $f_x(U^{-1}(y))$ 是 x 的函数而非 y 的函数。再次调用微积分基本定理，得到

$$f(y) = f_x(U^{-1}(y)) \cdot \left(\frac{\mathrm{d}}{\mathrm{d}y}U^{-1}(y)\right)\,. \tag{6.142}$$

回忆我们假定 U 严格递增。对递减函数，按同样推导会得到一个负号。为使递增与递减的 U 有同一表达式，我们引入微分的绝对值：

$$f(y) = f_x(U^{-1}(y)) \cdot \left|\frac{\mathrm{d}}{\mathrm{d}y}U^{-1}(y)\right|\,. \tag{6.143}$$

这称为变量替换技巧。(6.143) 中的 $\left|\frac{\mathrm{d}}{\mathrm{d}y}U^{-1}(y)\right|$ 度量施加 U 时单位体积变化了多少（另见第 5.3 节 Jacobian 的定义）。

变量替换技巧

注. 与 (6.125b) 中的离散情形相比，我们多了一个因子 $\left|\frac{\mathrm{d}}{\mathrm{d}y}U^{-1}(y)\right|$。连续情形需要更小心，因为对所有 y 都有 $P(Y = y) = 0$。概率密度函数 $f(y)$ 无法被描述为某个涉及 y 的事件的概率。

到目前为止，我们研究的是单变量变量替换。多变量随机变量的情形类似，但复杂之处在于：对多变量函数不能使用绝对值，而要使用 Jacobian 矩阵的行列式。回忆 (5.58)，Jacobian 是偏导数组成的矩阵；非零行列式的存在表明我们可以对 Jacobian 求逆。回忆第 4.1 节的讨论：行列式之所以出现，是因为我们的微分（体积立方体）被 Jacobian 变换成了平行六面体。我们把前面的讨论总结为下面的定理，它给出多变量变量替换的配方。

定理 6.16 (多变量变量替换)**.** *[Billingsley (1995)* 定理 *17.2]* 设 $f(x)$ 是多变量连续随机变量 X 的概率密度之值。若向量值函数 $y = U(x)$ 在 x 的定义域内处处可微且可逆，则对相应的 y 值，$Y = U(X)$ 的概率密度为

$$f(y) = f_x(U^{-1}(y)) \cdot \left|\det\left(\frac{\partial}{\partial y}U^{-1}(y)\right)\right|\,. \tag{6.144}$$

这个定理乍看令人生畏，但关键在于：多变量随机变量的变量替换遵循与单变量变量替换相同的步骤。首先求出逆变换，把它代入 x 的密度；然后计算 Jacobian 的行列式并与之相乘。下面的例子说明二元随机变量的情形。

例 6.17 (线性变换)**.** 考虑二元随机变量 X，状态为 $\boldsymbol{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$，概率密度函数为

$$f\left(\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}\right) = \frac{1}{2\pi}\exp\left(-\frac{1}{2}\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}^\top \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}\right)\,. \tag{6.145}$$

我们用定理 6.16 的变量替换技巧，推导对该随机变量做线性变换（第 2.7 节）的效果。

原书 p.220

考虑 2×2 矩阵

$$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix} . \tag{6.146}$$

我们想求变换后的二元随机变量 Y（状态 $\boldsymbol{y} = A\boldsymbol{x}$）的概率密度函数。回忆变量替换需要把 x 表为 y 的函数这一逆变换。由于考虑线性变换，逆变换由矩阵逆给出（见第 2.2.2 节）。对 2×2 矩阵，可显式写出公式

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = A^{-1} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \frac{1}{ad - bc} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} . \tag{6.147}$$

注意 $ad - bc$ 就是 A 的行列式（第 4.1 节）。相应的概率密度函数为

$$f(\boldsymbol{x}) = f(A^{-1}\boldsymbol{y}) = \frac{1}{2\pi} \exp\left(-\frac{1}{2} \boldsymbol{y}^\top A^{-\top} A^{-1} \boldsymbol{y} \right) . \tag{6.148}$$

矩阵乘向量关于该向量的偏导数就是矩阵本身（第 5.5 节），因此

$$\frac{\partial}{\partial \boldsymbol{y}} A^{-1}\boldsymbol{y} = A^{-1} . \tag{6.149}$$

回忆第 4.1 节，逆的行列式等于行列式的逆，因此 Jacobian 矩阵的行列式为

$$\det\left(\frac{\partial}{\partial \boldsymbol{y}} A^{-1}\boldsymbol{y} \right) = \frac{1}{ad - bc} . \tag{6.150}$$

现在可以应用定理 6.16 的变量替换公式，把 (6.148) 与 (6.150) 相乘，得到

$$f(\boldsymbol{y}) = f(\boldsymbol{x}) \left| \det\left(\frac{\partial}{\partial \boldsymbol{y}} A^{-1}\boldsymbol{y} \right) \right| \tag{6.151a}$$

$$= \frac{1}{2\pi} \exp\left(-\frac{1}{2} \boldsymbol{y}^\top A^{-\top} A^{-1} \boldsymbol{y} \right) |ad - bc|^{-1} . \tag{6.151b}$$

虽然例 6.17 基于二元随机变量（便于我们轻松算出矩阵逆），但上述关系对更高维也成立。

注. 我们在第 6.5 节看到，(6.148) 中的密度 $f(x)$ 实际上是标准高斯分布，而变换后的密度 $f(y)$ 是协方差为 $\Sigma = AA^\top$ 的二元高斯。

我们将在第 8.4 节使用本章的思想来描述概率建模，并在第 8.5 节引入一种图形语言；在第 9 章与第 11 章，我们将看到这些思想在机器学习中的直接应用。 原书 p.221

6.8　拓展阅读

本章有时相当简略。Grinstead and Snell (1997) 与 Walpole et al. (2011) 给出了更从容、适合自学的叙述。对概率的哲学方面感兴趣的读者可参阅 Hacking (2001)；一种更贴近软件工程的途径见 Downey (2014)。

指数族的综述可参见 Barndorff-Nielsen (2014)。我们将在第 8 章更多地看到如何用概率分布为机器学习任务建模。颇具讽刺意味的是，近来神经网络兴趣的高涨反而使人们更广泛地认识到概率模型的价值。例如，归一化流（Jimenez Rezende and Mohamed, 2015）这一思想就依赖变量替换来变换随机变量。Goodfellow et al. (2016) 一书第 16–20 章综述了应用于神经网络的变分推断方法。

我们通过回避测度论问题（Billingsley, 1995; Pollard, 2002）、并在不做构造的情况下假定我们有实数以及在实数上定义集合的方式和它们相应的出现频率，绕开了连续

随机变量的大部分难点。这些细节确实重要，例如在为连续随机变量 x, y 指定条件概率 $p(y \mid x)$ 时（Proschan and Presnell, 1998）。含混的记号掩盖了我们想指定 $X = x$（这是一个零测度集合）这一事实；此外，我们关心的是 y 的概率密度函数。更精确的记号必须写成 $\mathbb{E}_y[f(y) \mid \sigma(x)]$，即在 x 的 σ 代数条件下对测试函数 f 关于 y 取期望。对概率论细节感兴趣、更技术化的读者有许多选择（Jaynes, 2003; MacKay, 2003; Jacod and Protter, 2004; Grimmett and Welsh, 2014），包括一些非常技术化的讨论（Shiryayev, 1984; Lehmann and Casella, 1998; Dudley, 2002; Bickel and Doksum, 2006; Çinlar, 2011）。处理概率的另一种途径是从期望的概念出发，“反向”推导出概率空间所需的性质（Whittle, 2000）。随着机器学习使我们能对越来越复杂类型的数据建模越来越精巧的分布，概率机器学习模型的开发者将不得不理解这些更技术化的方面。以概率建模为重点的机器学习教材包括 MacKay (2003)、Bishop (2006)、Rasmussen and Williams (2006)、Barber (2012)、Murphy (2012)。

习题

6.1 考虑两个离散随机变量 X 与 Y 的如下二元分布 $p(x, y)$。

原书 p.222

	x_1	x_2	x_3	x_4	x_5
y_3	0.01	0.02	0.03		
y_2	0.1	0.05			
y_1	0.1	0.05	0.07	0.2	0.1
	0.05	0.03	0.05	0.04	

计算：

(a) 边缘分布 $p(x)$ 与 $p(y)$。

(b) 条件分布 $p(x \mid Y = y_1)$ 与 $p(y \mid X = x_3)$。

6.2 考虑两个高斯分布的混合（图 6.4）：

$$0.4\mathcal{N}\left(\begin{bmatrix}10\\2\end{bmatrix}, \begin{bmatrix}1 & 0\\0 & 1\end{bmatrix}\right) + 0.6\mathcal{N}\left(\begin{bmatrix}0\\0\end{bmatrix}, \begin{bmatrix}8.4 & 2.0\\2.0 & 1.7\end{bmatrix}\right).$$

(a) 计算各维的边缘分布。

(b) 计算每个边缘分布的均值、众数与中位数。

(c) 计算二维分布的均值与众数。

6.3 你写了一个计算机程序，它有时能编译、有时不能（代码没有变化）。你决定用参数为 μ 的 Bernoulli 分布建模编译器表面上的随机性（成功与否）x：

$$p(x \mid \mu) = \mu^x (1-\mu)^{1-x}, \qquad x \in \{0, 1\}.$$

为 Bernoulli 似然选一个共轭先验，并计算后验分布 $p(\mu \mid x_1, \ldots, x_N)$。

6.4 有两个袋子。第一个袋子装有四个芒果和两个苹果；第二个袋子装有四个芒果和四个苹果。我们还有一枚偏心硬币，出现“正面”的概率为 0.6，出现“反面”的概率为 0.4。若硬币出现“正面”，我们从 1 号袋中随机取一个水果；否则从 2 号袋中随机取一个水果。你的朋友抛了硬币（你看不到结果），从相应袋子中随机取了一个水果，递给你一个芒果。问这个芒果是从 2 号袋取出的概率是多少？提示：用贝叶斯定理。

6.5 考虑如下时间序列模型

$$x_{t+1} = Ax_t + w, \quad w \sim \mathcal{N}(0, Q)$$

$$y_t = Cx_t + v, \quad v \sim \mathcal{N}(0, R)\,,$$

其中 w, v 是 i.i.d. 高斯噪声变量。进一步假定 $p(x_0) = \mathcal{N}(\mu_0, \Sigma_0)$。

原书 p.223

(a) $p(x_0, x_1, \ldots, x_T)$ 是什么形式？说明理由（你不必显式计算联合分布）。

(b) 假定 $p(x_t \mid y_1, \ldots, y_t) = \mathcal{N}(\mu_t, \Sigma_t)$。

(1) 计算 $p(x_{t+1} \mid y_1, \ldots, y_t)$。

(2) 计算 $p(x_{t+1}, y_{t+1} \mid y_1, \ldots, y_t)$。

(3) 在时刻 $t{+}1$,我们观察到值 $y_{t+1} = \hat{y}$。计算条件分布 $p(x_{t+1} \mid y_1, \ldots, y_{t+1})$。

6.6 证明 (6.44) 中的关系，它把方差的标准定义与方差的原始分数表达式联系起来。

6.7 证明 (6.45) 中的关系，它把数据集中样本之间的两两差与方差的原始分数表达式联系起来。

6.8 用指数族的自然参数形式（见 (6.107)）表示 Bernoulli 分布。

6.9 把二项分布表示为指数族分布；再把 Beta 分布表示为指数族分布。证明 Beta 分布与二项分布的乘积也是指数族的成员。

6.10 用两种方式推导第 6.5.2 节中的关系：

(a) 配方法；

(b) 把高斯写成指数族形式。

两个高斯 $\mathcal{N}(x \mid a, A)\mathcal{N}(x \mid b, B)$ 的乘积是一个未归一化的高斯分布 $c\mathcal{N}(x \mid c, C)$，其中

$$C = (A^{-1} + B^{-1})^{-1}$$

$$\boldsymbol{c} = C(A^{-1}\boldsymbol{a} + B^{-1}\boldsymbol{b})$$

$$c = (2\pi)^{-\frac{D}{2}} |A + B|^{-\frac{1}{2}} \exp\left(-\frac{1}{2}(\boldsymbol{a} - \boldsymbol{b})^\top (A + B)^{-1}(\boldsymbol{a} - \boldsymbol{b})\right).$$

注意归一化常数 c 本身也可看作以 $\boldsymbol{a}$ 或 $\boldsymbol{b}$ 为自变量、协方差矩阵“膨胀”为 $A+B$ 的（归一化）高斯分布，即 $c = \mathcal{N}(\boldsymbol{a} \mid \boldsymbol{b}, A + B) = \mathcal{N}(\boldsymbol{b} \mid \boldsymbol{a}, A + B)$。

6.11 **迭代期望**。考虑两个有联合分布 $p(x, y)$ 的随机变量 x, y。证明

$$\mathbb{E}_X[x] = \mathbb{E}_Y\left[\mathbb{E}_X[x \mid y]\right].$$

这里 $\mathbb{E}_X[x \mid y]$ 表示在条件分布 $p(x \mid y)$ 下 x 的期望值。

6.12 **高斯随机变量的运算**。考虑高斯随机变量 $x \sim \mathcal{N}(x \mid \mu_x, \Sigma_x)$，其中 $x \in \mathbb{R}^D$。此外有

$$y = Ax + b + w\,,$$

其中 $y \in \mathbb{R}^E$、$A \in \mathbb{R}^{E \times D}$、$b \in \mathbb{R}^E$，$w \sim \mathcal{N}(w \mid 0, Q)$ 是独立的高斯噪声。“独立”意味着 x 与 w 是独立随机变量，且 Q 为对角阵。

(a) 写出似然 $p(y \mid x)$。

(b) 分布 $p(y) = \int p(y \mid x)\, p(x)\, \mathrm{d}x$ 是高斯。计算均值 μ_y 与协方差 Σ_y。详细推导你的结果。

原书 p.224

(c) 随机变量 y 按如下测量映射作变换：

$$z = Cy + v\,,$$

其中 $z \in \mathbb{R}^F$、$C \in \mathbb{R}^{F \times E}$，$v \sim \mathcal{N}(v \mid 0, R)$ 是独立的高斯（测量）噪声。写出 $p(z \mid y)$。计算 $p(z)$，即均值 μ_z 与协方差 Σ_z。详细推导你的结果。

(d) 现在测得一个值 $\hat{y}$。计算后验分布 $p(x \mid \hat{y})$。

提示：这个后验也是高斯，即我们只需确定它的均值与协方差矩阵。先显式计算联合高斯 $p(x, y)$。这还需要计算互协方差 $\mathrm{Cov}_{x,y}[x, y]$ 与 $\mathrm{Cov}_{y,x}[y, x]$，然后应用高斯条件化规则。

6.13 **概率积分变换**。给定连续随机变量 X，其 cdf 为 $F_X(x)$，证明随机变量 $Y := F_X(X)$ 服从均匀分布（定理 6.15）。

第 7 章　连续优化

原书 p.225

由于机器学习算法最终要在计算机上实现，其数学表述都以数值优化方法的形式给出。本章介绍训练机器学习模型所用的基本数值方法。训练一个机器学习模型，往往归结为寻找一组合适的参数。“好”的标准由目标函数（objective function）或概率模型决定，本书第二部分会给出具体例子。给定一个目标函数之后，寻找其最优值的工作由优化算法完成。

本章讨论连续优化（continuous optimization）的两大分支（图 7.1）：无约束优化与约束优化。本章假设目标函数可微（见第 5 章），因此我们在空间中每一点都能得到一个梯度，用以帮助寻找最优值。按惯例，机器学习中大多数目标函数都是要最小化的，即最优值就是最小值。直观上，寻找最优值好比寻找目标函数的谷底，而梯度指向山坡上方。思路就是朝下坡方向（与梯度相反的方向）移动，并期望找到最低点。对无约束优化而言，这是我们唯一需要的概念，但其中有若干设计选择，将在 7.1 节讨论。对约束优化，我们需要引入其他概念来处理约束（7.2 节）。我们还将介绍一类特殊的问题（7.3 节的凸优化问题），在这类问题中我们可以断言能够达到全局最优。

考虑图 7.3 中的函数。该函数在 $x = -4.5$ 附近有一个全局最小（global minimum），函数值约为 -47。由于函数是“光滑”的，可以借助梯度来帮助寻找最小值——梯度会指明我们该向右走还是向左走。这一假设的前提是我们已经位于正确的谷底，因为在 $x = 0.7$ 附近还存在另一个局部最小（local minimum）。回忆一下，我们可以通过求导并令导数为零来解出函数的所有驻点。驻点是导数的实根，即梯度为零的点。对

全局最小

局部最小

驻点

$$\ell(x) = x^4 + 7x^3 + 5x^2 - 17x + 3, \tag{7.1}$$

相应的梯度为

$$\frac{\mathrm{d}\ell(x)}{\mathrm{d}x} = 4x^3 + 21x^2 + 10x - 17. \tag{7.2}$$

因为这是一个三次方程，令其为零一般有三个解。在本例中，其中两个是极小值点，一个是极大值点（约在 $x = -1.4$ 处）。要判断一个驻点是极小还是极大，需要再求一次导数，考察该驻点处二阶导数为正还是为负。在我们的例子中，二阶导数为

$$\frac{\mathrm{d}^2\ell(x)}{\mathrm{d}x^2} = 12x^2 + 42x + 10. \tag{7.3}$$

代入我们目测估计的 $x = -4.5, -1.4, 0.7$，可以观察到，正如预期，中间那个点是极大值点（$\frac{\mathrm{d}^2\ell}{\mathrm{d}x^2} < 0$），另外两个驻点是极小值点。

注意，前面的讨论中我们并没有解析地解出 x 的值，尽管对上面这种低次多项式我们是可以解析求解的。一般情况下，我们无法得到解析解，因此需要从某个初值出发，比如 $x_0 = -6$，沿着负梯度方向前进。负梯度告诉我们应该向右走，但并没有告诉我们走多远（这称为步长 step-size）。此外，如果我们从右侧出发（例如 $x_0 = 0$），负梯度会把我们引向错误的极小值。图 7.3 说明了这一点：当 $x > -1$ 时，负梯度指向图右侧的极小值，而那个极小值对应的目标函数值更大。

步长

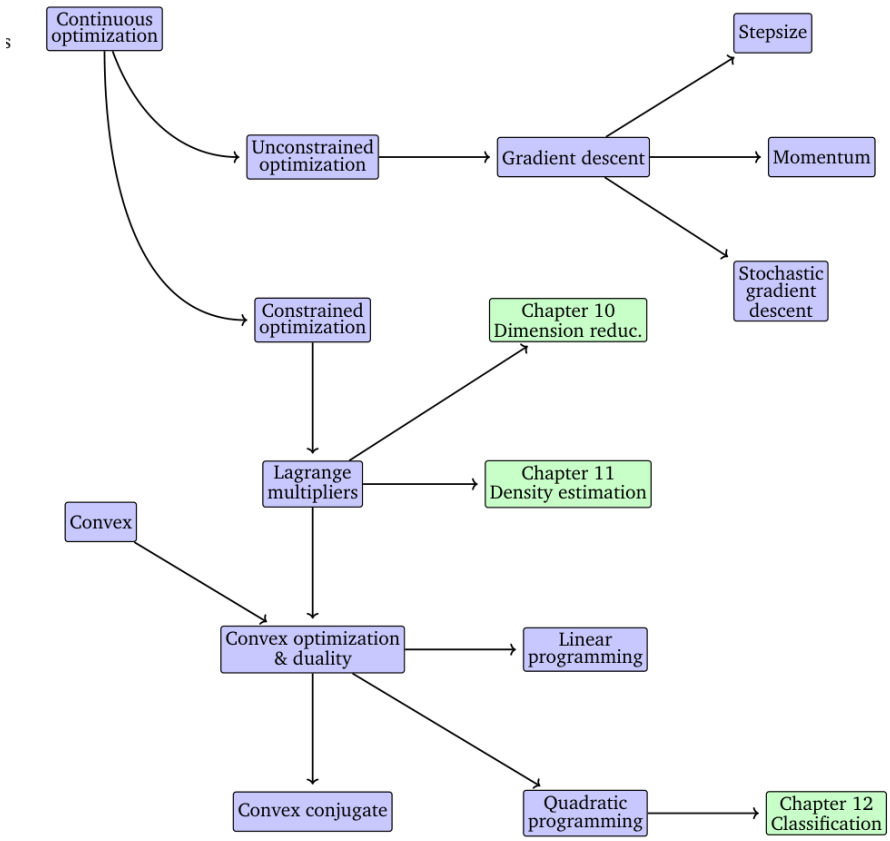


图 7.1: 与本章优化相关概念的思维导图。有两条主线：梯度下降与凸优化。（对应原书 Figure 7.1，图中节点文字保留英文。）

根据阿贝尔–鲁菲尼定理（Abel–Ruffini theorem），五次及以上的多项式一般没有代数解（Abel, 1826）。

Abel-Ruffini

在 7.3 节中，我们将学习一类称为凸函数（convex function）的函数，它们不存在这种对优化算法起点的棘手依赖。对凸函数而言，所有局部极小都是全局最小。事实上许多机器学习目标函数都被设计成凸的，我们将在第 12 章看到一个例子。

凸函数

本章到目前为止的讨论都是针对一维函数的，我们得以可视化梯度、下降方向和最优值这些概念。在本章余下部分，我们将在高维中发展同样的思想。遗憾的是，我们只能在一维中可视化这些概念，而且有些概念并不能直接推广到高维，因此阅读时需要格外小心。

原书 p.226

7.1　用梯度下降做优化

我们现在考虑求解实值函数最小值的问题

$$\min_{\boldsymbol{x}} f(\boldsymbol{x}), \tag{7.4}$$

其中 $f : \mathbb{R}^d \to \mathbb{R}$ 是刻画当前机器学习问题的目标函数。我们假设函数 f 可微，且无法解析地得到闭式解。

原书 p.228

梯度下降（gradient descent）是一种一阶优化算法。要用梯度下降求函数的局部最小值，就在当前点沿函数梯度的负方向、按与梯度大小成比例的步长移动。回忆 5.1 节，

梯度指向最速上升方向。另一个有用的直觉是：考虑函数取某一定值的点集（对某个 梯度约定
$c \in \mathbb{R}$，$f(\boldsymbol{x}) = c$），它们称为等值线（contour lines）。梯度指向与待优化函数等值线正交的方向。

我们用行向量来表示梯度。

考虑多元函数。想象一个由函数 $f(\boldsymbol{x})$ 描述的曲面，一个小球从某点 $\boldsymbol{x}_0$ 处出发。释放小球后，它会沿最速下降方向滚下坡。梯度下降利用了这样一个事实：从 $\boldsymbol{x}_0$ 出发，沿 f 在该点的负梯度 $-((\nabla f)(\boldsymbol{x}_0))^\top$ 方向移动时，$f(\boldsymbol{x}_0)$ 下降得最快。本书假设函数可微，更一般的情形请参阅 7.4 节。于是，若取一个小步长 $\gamma \geqslant 0$，令

$$\boldsymbol{x}_1 = \boldsymbol{x}_0 - \gamma\left((\nabla f)(\boldsymbol{x}_0)\right)^\top, \tag{7.5}$$

则有 $f(\boldsymbol{x}_1) \leqslant f(\boldsymbol{x}_0)$。注意我们对梯度取了转置，否则量纲对不上。

这一观察使我们可以定义一个简单的梯度下降算法：若要求函数 $f : \mathbb{R}^n \to \mathbb{R}$（$\boldsymbol{x} \mapsto f(\boldsymbol{x})$）的局部最优值 $f(\boldsymbol{x}^*)$，就从待优化参数的一个初始猜测 $\boldsymbol{x}_0$ 出发，然后按

$$\boldsymbol{x}_{i+1} = \boldsymbol{x}_i - \gamma_i\left((\nabla f)(\boldsymbol{x}_i)\right)^\top \tag{7.6}$$

进行迭代。在合适的步长 γ_i 下，序列 $f(\boldsymbol{x}_0) \geqslant f(\boldsymbol{x}_1) \geqslant \cdots$ 收敛到一个局部最小值。

例 7.1. 考虑一个二维二次函数

$$f\left(\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}\right) = \tfrac{1}{2}\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}^\top \begin{bmatrix} 2 & 1 \\ 1 & 20 \end{bmatrix}\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} - \begin{bmatrix} 5 \\ 3 \end{bmatrix}^\top \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \tag{7.7}$$

其梯度为

$$\nabla f\left(\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}\right) = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}^\top \begin{bmatrix} 2 & 1 \\ 1 & 20 \end{bmatrix} - \begin{bmatrix} 5 \\ 3 \end{bmatrix}^\top. \tag{7.8}$$

从初始位置 $\boldsymbol{x}_0 = [-3, -1]^\top$ 出发，反复应用式 (7.6)，得到一列估计值并收敛到最小值（见图 7.2）。我们可以看到（无论从图上还是把 $\boldsymbol{x}_0$ 代入 (7.8) 并取 $\gamma = 0.085$），$\boldsymbol{x}_0$ 处的负梯度指向北和东，从而得到 $\boldsymbol{x}_1 = [-1.98, 1.21]^\top$。重复这一过程得到 $\boldsymbol{x}_2 = [-1.32, -0.42]^\top$，依此类推。

原书 p.229
原书 p.227

注。梯度下降在最小值附近可能相当慢：其渐近收敛速率逊于许多其他方法。用小球滚下山的类比来说，当曲面是一条狭长的山谷时，问题是病态的（poorly conditioned）（Trefethen and Bau III, 1997）。对病态的凸问题，当梯度几乎正交于指向最小点的最短方向时，梯度下降会越来越“之字形”地前进；见图 7.2。◇

7.1.1　步长

如前所述，选择合适的步长对梯度下降很重要。步长太小，梯度下降会很慢；步长取得太大，梯度下降可能越过目标、不收敛甚至发散。步长也称为学习率（learning rate）。我们在下一节讨论动量（momentum）的使用，它是一种平滑梯度更新中的不规则行为、抑制振荡的方法。 学习率

自适应梯度方法会在每次迭代时根据函数的局部性质重新缩放步长。有两条简单的启发式规则（Toussaint, 2012）：

- 若一次梯度步之后函数值上升，说明步长太大。撤销该步并减小步长。
- 若函数值下降，说明步长本可以更大。尝试增大步长。

虽然“撤销”这一步看似浪费资源，但使用这条启发式规则可保证单调收敛。 原书 p.230

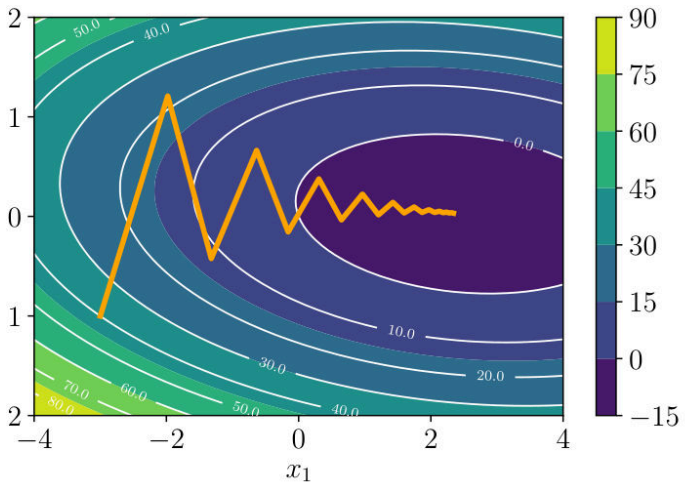


图 7.2: 在二维二次曲面（以热力图显示）上的梯度下降。描述见例 7.1。（对应原书 Figure 7.3。）

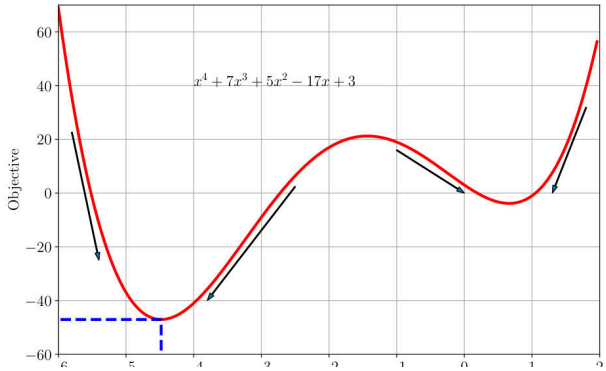


图 7.3: 目标函数示例。负梯度以箭头表示，全局最小值以蓝色虚线标出。（对应原书 Figure 7.2。）

例 7.2 (求解线性方程组)**.** 当求解形如 $A\boldsymbol{x} = \boldsymbol{b}$ 的线性方程时，实际做法是求 $\boldsymbol{x}^*$ 使平方误差最小，从而近似求解 $A\boldsymbol{x} - \boldsymbol{b} = \boldsymbol{0}$:

$$\|A\boldsymbol{x} - \boldsymbol{b}\|^2 = (A\boldsymbol{x} - \boldsymbol{b})^\top (A\boldsymbol{x} - \boldsymbol{b}) \tag{7.9}$$

这里使用欧几里得范数。(7.9) 关于 $\boldsymbol{x}$ 的梯度为

$$\nabla_{\boldsymbol{x}} = 2(A\boldsymbol{x} - \boldsymbol{b})^\top A. \tag{7.10}$$

我们可以直接把这个梯度用在梯度下降算法中。不过，在这一特殊情形下，事实证明存在解析解，可令梯度为零求得。关于求解平方误差问题的更多内容将在第 9 章介绍。

注。当用于求解线性方程组 $A\boldsymbol{x} = \boldsymbol{b}$ 时，梯度下降可能收敛很慢。梯度下降的收敛速度依赖于条件数（condition number）$\kappa = \sigma(A)_{\max}/\sigma(A)_{\min}$，即 A 的最大奇异值与最小奇异值之比（见 4.5 节）。条件数本质上度量的是“最弯曲方向”与“最平坦方向”之比，对应我们对病态问题是狭长山谷的想象：它们在一个方向上非常弯曲，而在另一个方向上非常平坦。我们不必直接求解 $A\boldsymbol{x} = \boldsymbol{b}$，而可以求解 $P^{-1}(A\boldsymbol{x} - \boldsymbol{b}) = \boldsymbol{0}$，其中 P 称为预处理子（preconditioner）。目标是设计 P^{-1}，使 $P^{-1}A$ 有更好的条件数，同时 P^{-1}

条件数

预处理子

又容易计算。关于梯度下降、预处理和收敛的进一步信息，参见 Boyd and Vandenberghe (2004, 第 9 章)。◇

7.1.2　带动量的梯度下降

如图 7.2 所示，如果优化曲面的曲率导致某些区域尺度不良，梯度下降的收敛可能非常慢。在这种曲率下，梯度下降的步在山谷两壁之间来回跳跃，以很小的步子逼近最优点。为改进收敛而提出的调整，是给梯度下降加上一些“记忆”。

Goh (2017) 写过一篇直观的博客，介绍带动量的梯度下降。

动量

带动量的梯度下降（Rumelhart et al., 1986）引入了一个额外项，用以记住上一次迭代发生了什么。这种记忆能抑制振荡、平滑梯度更新。延续小球的类比，动量项模拟了一个沉重的球不愿改变方向的现象。其思想是做一个带记忆的梯度更新，以实现滑动平均。基于动量的方法在每次迭代 i 记住更新量 $\Delta \boldsymbol{x}_i$，并把下一次更新取为当前梯度与历史梯度的线性组合：

原书 p.231

$$\boldsymbol{x}_{i+1} = \boldsymbol{x}_i - \gamma_i \left((\nabla f)(\boldsymbol{x}_i)\right)^\top + \alpha \, \Delta \boldsymbol{x}_i \tag{7.11}$$

$$\Delta \boldsymbol{x}_i = \boldsymbol{x}_i - \boldsymbol{x}_{i-1} = \alpha \, \Delta \boldsymbol{x}_{i-1} - \gamma_{i-1} \left((\nabla f)(\boldsymbol{x}_{i-1})\right)^\top, \tag{7.12}$$

其中 $\alpha \in [0, 1]$。有时我们只能近似地知道梯度。在这种情况下，动量项很有用，因为它能对各种含噪声的梯度估计做平均。一种特别有用的获得近似梯度的方式是使用随机近似，下面就来讨论。

7.1.3　随机梯度下降

计算梯度可能非常耗时。然而，往往可以找到梯度的一个“廉价”近似。只要近似梯度大致指向与真实梯度相同的方向，它仍然是有用的。

随机梯度下降（stochastic gradient descent，常缩写为 SGD）是梯度下降法的一种随机近似，用于最小化一个写成若干可微函数之和的目标函数。这里“随机”一词指的是我们承认自己并不知道精确的梯度，而只知道它的一个含噪声的近似。通过约束近似梯度的概率分布，我们在理论上仍可保证 SGD 收敛。

随机梯度下降

在机器学习中，给定 $n = 1, \ldots, N$ 个数据点，我们常常考虑的目标函数是每个样本 n 所产生损失 L_n 之和。写成数学形式即

$$L(\theta) = \sum_{n=1}^{N} L_n(\theta), \tag{7.13}$$

其中 θ 是我们关心的参数向量，即我们要找使 L 最小的 θ。回归（第 9 章）中的一个例子是负对数似然，它写成各样本对数似然之和：

$$L(\theta) = -\sum_{n=1}^{N} \log p(y_n \mid x_n, \theta), \tag{7.14}$$

其中 $x_n \in \mathbb{R}^D$ 是训练输入，y_n 是训练目标，θ 是回归模型的参数。

原书 p.232

前面介绍的标准梯度下降是一种“批量”（batch）优化方法，即使用整个训练集来优化，按下式更新参数向量：

$$\theta_{i+1} = \theta_i - \gamma_i (\nabla L(\theta_i))^\top = \theta_i - \gamma_i \sum_{n=1}^{N} (\nabla L_n(\theta_i))^\top \tag{7.15}$$

其中 γ_i 是合适的步长参数。计算这个求和梯度，可能需要对所有单个函数 L_n 的梯度做昂贵的求值。当训练集非常大、且/或不存在简单公式时，求这些梯度之和就变得非常昂贵。

考虑式 (7.15) 中的求和项 $\sum_{n=1}^{N}(\nabla L_n(\theta_i))$。我们可以只对一个较小的 L_n 子集求和来减少计算量。与使用全部 L_n（$n=1,\dots,N$）的批量梯度下降不同，小批量梯度下降（mini-batch gradient descent）随机选取 L_n 的一个子集。在极端情形下，我们随机只选单个 L_n 来估计梯度。关于“为何取数据子集是合理的”这一关键洞见是：要让梯度下降收敛，我们只要求梯度是真实梯度的无偏估计即可。事实上，(7.15) 中的 $\sum_{n=1}^{N}(\nabla L_n(\theta_i))$ 正是梯度期望值（见 6.4.1 节）的一个经验估计。因此，期望值的任何其他无偏经验估计——例如使用数据的任意子样本——都足以让梯度下降收敛。

注。当学习率以恰当速率下降、且满足相对温和的假设时，随机梯度下降几乎必然收敛到局部最小值（Bottou, 1998）。◇

为什么要考虑使用近似梯度？一个主要原因是实际实现上的限制，例如中央处理器（CPU）/图形处理器（GPU）内存大小或计算时间的限制。我们可以像在估计经验均值时考虑样本大小那样（见 6.4.1 节），考虑用于估计梯度的子集大小。大的小批量能给出梯度的精确估计，减小参数更新中的方差。此外，大的小批量还能在代价函数与梯度的向量化实现中利用高度优化的矩阵运算。方差减小会带来更稳定的收敛，但每次梯度计算也更昂贵。

相比之下，小的小批量估计起来很快。如果保持小批量规模较小，梯度估计中的噪声会使我们摆脱某些糟糕的局部最优（否则可能陷在其中）。在机器学习中，优化方法用于在训练数据上最小化目标函数来完成训练，但整体目标是提升泛化性能（第 8 章）。由于机器学习的目标并不需要对目标函数最小值做精确估计，使用小批量方法的近似梯度已被广泛采用。随机梯度下降在大规模机器学习问题中非常有效（Bottou et al., 2018），例如在数百万张图像上训练深度神经网络（Dean et al., 2012）、主题模型（Hoffman et al., 2013）、强化学习（Mnih et al., 2015），或训练大规模高斯过程模型（Hensman et al., 2013; Gal et al., 2014）。

7.2　约束优化与拉格朗日乘子

上一节我们考虑的是求解函数最小值的问题

$$\min_{\boldsymbol{x}} f(\boldsymbol{x}), \tag{7.16}$$

其中 $f:\mathbb{R}^D\to\mathbb{R}$。

本节中我们有额外的约束。即对实值函数 $g_i:\mathbb{R}^D\to\mathbb{R}$（$i=1,\dots,m$），我们考虑如下约束优化问题（图示见图 7.4）：

$$\begin{aligned}\min_{\boldsymbol{x}} \quad & f(\boldsymbol{x})\\ \text{subject to} \quad & g_i(\boldsymbol{x})\leqslant 0 \quad \text{对所有} i=1,\dots,m.\end{aligned} \tag{7.17}$$

值得指出的是，函数 f 和 g_i 一般可以是非凸的，凸的情形将在下一节讨论。

原书 p.233

把约束问题 (7.17) 转化为无约束问题，一个显而易见但不太实用的办法是使用指示函数

$$J(\boldsymbol{x})=f(\boldsymbol{x})+\sum_{i=1}^{m}\mathbf{1}(g_i(\boldsymbol{x})), \tag{7.18}$$

其中 $\mathbf{1}(z)$ 是一个无穷阶跃函数

原书 p.234

$$\mathbf{1}(z)=\begin{cases}0 & \text{若} z\leqslant 0,\\ \infty & \text{否则.}\end{cases} \tag{7.19}$$

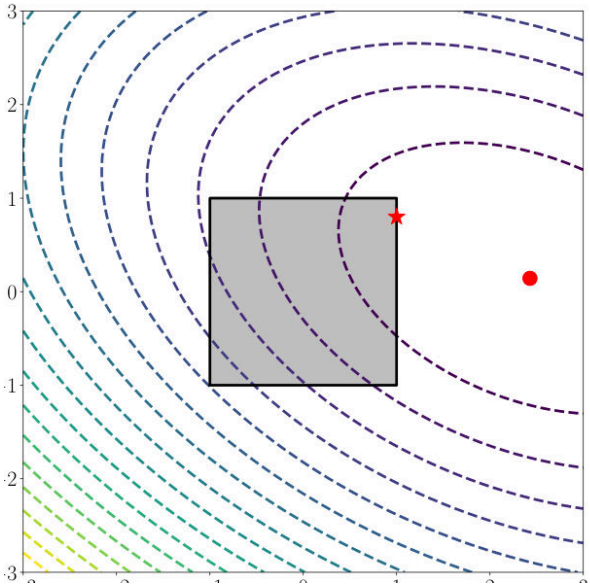


图 7.4: 约束优化示意。无约束问题（由等值线表示）在右侧有一个最小值（由圆圈标出）。方框约束（$-1 \leqslant x \leqslant 1$、$-1 \leqslant y \leqslant 1$）要求最优解落在方框内，从而得到由星号标出的最优值。（对应原书 Figure 7.4。）

当约束不满足时这会给出无穷大惩罚，因此能得到相同的解。然而，这个无穷阶跃函数同样难以优化。我们可以通过引入拉格朗日乘子（Lagrange multiplier）来克服这一困难。拉格朗日乘子的思想是用一个线性函数代替阶跃函数。

拉格朗日乘子

我们给问题 (7.17) 关联一个拉格朗日函数（Lagrangian），做法是为每个不等式约束分别引入拉格朗日乘子 $\lambda_i \geqslant 0$（Boyd and Vandenberghe, 2004, 第 4 章），于是

拉格朗日函数

$$\mathcal{L}(\boldsymbol{x}, \lambda) = f(\boldsymbol{x}) + \sum_{i=1}^{m} \lambda_i g_i(\boldsymbol{x}) \tag{7.20a}$$

$$= f(\boldsymbol{x}) + \lambda^\top \boldsymbol{g}(\boldsymbol{x}), \tag{7.20b}$$

其中最后一行把所有约束 $g_i(\boldsymbol{x})$ 拼接成向量 $\boldsymbol{g}(\boldsymbol{x})$，把所有拉格朗日乘子拼接成向量 $\lambda \in \mathbb{R}^m$。

现在引入拉格朗日对偶的思想。一般来说，优化中的对偶（duality）是指：把在一组变量 $\boldsymbol{x}$（称为原变量 primal variables）上的优化问题，转化为在另一组变量 λ（称为对偶变量 dual variables）上的另一个优化问题。我们介绍两种不同的对偶：本节讨论拉格朗日对偶；7.3.3 节讨论勒让德–芬切尔对偶（Legendre–Fenchel duality）。

定义 7.1. (7.17) 中的问题

$$\begin{aligned} \min_{\boldsymbol{x}} \quad & f(\boldsymbol{x}) \\ \text{subject to} \quad & g_i(\boldsymbol{x}) \leqslant 0 \quad \text{对所有} i = 1, \ldots, m \end{aligned} \tag{7.21}$$

称为原问题（primal problem），对应原变量 $\boldsymbol{x}$。相应的拉格朗日对偶问题（Lagrangian dual problem）为

原问题
对偶问题

$$\begin{aligned} \max_{\lambda \in \mathbb{R}^m} \quad & D(\lambda) \\ \text{subject to} \quad & \lambda \geqslant 0, \end{aligned} \tag{7.22}$$

其中 λ 是对偶变量，$D(\lambda) = \min_{\boldsymbol{x} \in \mathbb{R}^d} \mathcal{L}(\boldsymbol{x}, \lambda)$。

注。在定义 7.1 的讨论中，我们用到了两个本身也很有意义的概念（Boyd and Vandenberghe, 2004）。第一个是极小极大不等式（minimax inequality）：对任意带两个自变量的函数 $\phi(x,y)$，极大极小值小于等于极小极大值，即 极小极大

$$\max_y \min_x \phi(x,y) \leqslant \min_x \max_y \phi(x,y). \tag{7.23}$$

该不等式可通过考察下式来证明：

原书 p.235

$$\min_x \phi(x,y) \leqslant \max_y \phi(x,y) \qquad \text{对所有} x, y. \tag{7.24}$$

注意到 (7.24) 左边对 y 取最大值后不等式仍成立，因为该不等式对所有 y 都成立。类似地，对 (7.24) 右边的 x 取最小值，即得到 (7.23)。

第二个概念是弱对偶（weak duality），它利用 (7.23) 说明原问题的值总是大于等于对偶问题的值。这一点将在 (7.27) 中更详细地描述。$\diamond$ 弱对偶

回忆 (7.18) 中的 $J(\boldsymbol{x})$ 与 (7.20b) 中的拉格朗日函数之间的区别：我们把指示函数松弛成了一个线性函数。因此，当 $\lambda \geqslant 0$ 时，拉格朗日函数 $\mathcal{L}(\boldsymbol{x},\lambda)$ 是 $J(\boldsymbol{x})$ 的一个下界。于是，$\mathcal{L}(\boldsymbol{x},\lambda)$ 关于 λ 的最大值为

$$J(\boldsymbol{x}) = \max_{\lambda \geqslant 0} \mathcal{L}(\boldsymbol{x},\lambda). \tag{7.25}$$

回忆原问题是最小化 $J(\boldsymbol{x})$：

$$\min_{\boldsymbol{x}\in\mathbb{R}^d} \max_{\lambda \geqslant 0} \mathcal{L}(\boldsymbol{x},\lambda). \tag{7.26}$$

由极小极大不等式 (7.23)，交换最小与最大的顺序会得到一个更小的值，即

$$\min_{\boldsymbol{x}\in\mathbb{R}^d} \max_{\lambda \geqslant 0} \mathcal{L}(\boldsymbol{x},\lambda) \geqslant \max_{\lambda \geqslant 0} \min_{\boldsymbol{x}\in\mathbb{R}^d} \mathcal{L}(\boldsymbol{x},\lambda). \tag{7.27}$$

这也称为弱对偶。注意右边的内层部分正是对偶目标函数 $D(\lambda)$，定义由此而来。

与原优化问题带约束不同，对给定的 λ，$\min_{\boldsymbol{x}\in\mathbb{R}^d} \mathcal{L}(\boldsymbol{x},\lambda)$ 是一个无约束优化问题。如果求解 $\min_{\boldsymbol{x}\in\mathbb{R}^d} \mathcal{L}(\boldsymbol{x},\lambda)$ 很容易，那么整个问题就容易解。从 (7.20b) 可以看到 $\mathcal{L}(\boldsymbol{x},\lambda)$ 关于 λ 是仿射的。因此 $\min_{\boldsymbol{x}\in\mathbb{R}^d} \mathcal{L}(\boldsymbol{x},\lambda)$ 是 λ 的仿射函数的逐点最小，从而即使 $f(\cdot)$ 和 $g_i(\cdot)$ 可能非凸，$D(\lambda)$ 也是凹的。外层问题是关于 λ 的最大化，即求一个凹函数的最大值，可以高效计算。

假设 $f(\cdot)$ 和 $g_i(\cdot)$ 可微，我们通过对拉格朗日函数关于 $\boldsymbol{x}$ 求导、令微分为零、再解出最优值，来得到拉格朗日对偶问题。我们将在 7.3.1 和 7.3.2 节讨论两个具体例子，其中 $f(\cdot)$ 和 $g_i(\cdot)$ 都是凸的。

注（等式约束）。考虑在 (7.17) 中加入额外的等式约束：

$$\begin{aligned} \min_{\boldsymbol{x}} \quad & f(\boldsymbol{x}) \\ \text{subject to} \quad & g_i(\boldsymbol{x}) \leqslant 0 \quad \text{对所有} i = 1,\dots,m \\ & h_j(\boldsymbol{x}) = 0 \quad \text{对所有} j = 1,\dots,n. \end{aligned} \tag{7.28}$$

我们可以把等式约束替换为两个不等式约束来建模。即对每个等式约束 $h_j(\boldsymbol{x}) = 0$，等价地用两个约束 $h_j(\boldsymbol{x}) \leqslant 0$ 和 $h_j(\boldsymbol{x}) \geqslant 0$ 代替。可以证明，这样得到的拉格朗日乘子是不受约束的。

原书 p.236

因此，我们把 (7.28) 中对应不等式约束的拉格朗日乘子约束为非负，而让对应等式约束的拉格朗日乘子不受约束。$\diamond$

7.3　凸优化

我们把注意力集中到一类特别有用的优化问题上，对这类问题我们可以保证全局最优性。当 $f(\cdot)$ 是凸函数、且涉及 $g(\cdot)$ 和 $h(\cdot)$ 的约束都是凸集时，就称为凸优化问题（convex optimization problem）。在这种情形下，我们有强对偶（strong duality）：对偶问题的最优解与原问题的最优解相同。凸函数与凸集之间的区别在机器学习文献中往往不被严格区分，但通常可从上下文推断其隐含含义。

强对偶

定义 7.2. 称集合 $\mathcal{C}$ 为凸集（convex set），如果对任意 $\boldsymbol{x}, \boldsymbol{y} \in \mathcal{C}$ 和任意标量 θ（$0 \leqslant \theta \leqslant 1$）都有

凸集

$$\theta\boldsymbol{x} + (1-\theta)\boldsymbol{y} \in \mathcal{C}. \tag{7.29}$$

凸集是这样的集合：连接集合中任意两个元素的直线段都落在集合内部。图 7.5 和图 7.6 分别给出了凸集与非凸集的示例。

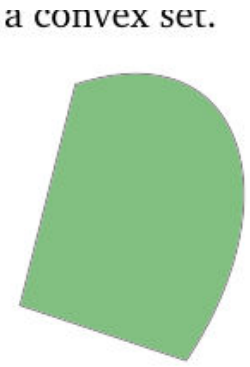


图 7.5: 凸集示例。（对应原书 Figure 7.5。）

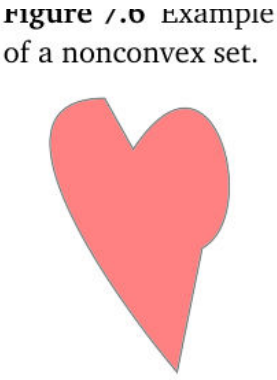


图 7.6: 非凸集示例。（对应原书 Figure 7.6。）

凸函数是这样的函数：函数上任意两点之间的直线段都位于函数上方。图 7.3 给出了一个非凸函数，图 7.2 给出了一个凸函数。另一个凸函数如图 7.7 所示。

定义 7.3. 设函数 $f : \mathbb{R}^D \to \mathbb{R}$ 的定义域是凸集。称 f 是凸函数（convex function），如果对 f 定义域内所有 $\boldsymbol{x}, \boldsymbol{y}$ 和任意标量 θ（$0 \leqslant \theta \leqslant 1$），都有

凸函数

$$f(\theta\boldsymbol{x} + (1-\theta)\boldsymbol{y}) \leqslant \theta f(\boldsymbol{x}) + (1-\theta)f(\boldsymbol{y}). \tag{7.30}$$

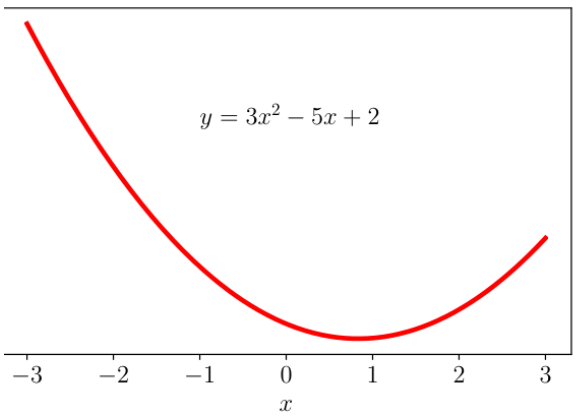


图 7.7: 凸函数示例。（对应原书 Figure 7.7。）

注。凹函数（concave function）就是凸函数取负。⋄　　凹函数

(7.28) 中涉及 $g(\cdot)$ 和 $h(\cdot)$ 的约束会把函数在某个标量值处截断，从而得到集合。凸函数与凸集之间的另一种关系，是考虑把一个凸函数“填满”后所得的集合。凸函数像一个碗状物体，我们想象往里面倒水把它填满。这样得到的被填满的集合称为凸函数的上图（epigraph），它是一个凸集。　　上图

如果函数 $f : \mathbb{R}^n \to \mathbb{R}$ 可微，我们可以用其梯度 $\nabla_{\boldsymbol{x}} f(\boldsymbol{x})$（见 5.2 节）来刻画凸性。函数 $f(\boldsymbol{x})$ 是凸的，当且仅当对任意两点 $\boldsymbol{x}, \boldsymbol{y}$ 都有

$$f(\boldsymbol{y}) \geqslant f(\boldsymbol{x}) + \nabla_{\boldsymbol{x}} f(\boldsymbol{x})^\top (\boldsymbol{y} - \boldsymbol{x}). \tag{7.31}$$

原书 p.237

如果进一步知道函数 $f(\boldsymbol{x})$ 二阶可微，即在 $\boldsymbol{x}$ 定义域内所有点 Hessian 矩阵（见 (5.147)）都存在，则函数 $f(\boldsymbol{x})$ 是凸的，当且仅当 $\nabla^2_{\boldsymbol{x}} f(\boldsymbol{x})$ 半正定（Boyd and Vandenberghe, 2004）。

例 7.3. 负熵 $f(x) = x \log_2 x$ 在 $x > 0$ 时是凸的。该函数的可视化见图 7.8，可以看出它是凸的。为说明前面的凸性定义，我们对 $x = 2$ 和 $x = 4$ 两个点做计算。注意，要证明 $f(x)$ 的凸性，我们需要对所有 $x \in \mathbb{R}$ 进行检验。

回忆定义 7.3。取两点之间的中点（即 $\theta = 0.5$）；则左边为 $f(0.5 \cdot 2 + 0.5 \cdot 4) = 3 \log_2 3 \approx 4.75$。右边为 $0.5(2 \log_2 2) + 0.5(4 \log_2 4) = 1 + 4 = 5$。因此定义得到满足。

由于 $f(x)$ 可微，我们也可以改用 (7.31)。对 $f(x)$ 求导得

$$\nabla_x (x \log_2 x) = 1 \cdot \log_2 x + x \cdot \frac{1}{x \log_e 2} = \log_2 x + \frac{1}{\log_e 2}. \tag{7.32}$$

仍用测试点 $x = 2$ 和 $x = 4$，(7.31) 的左边为 $f(4) = 8$。右边为

$$f(\boldsymbol{x}) + \nabla_{\boldsymbol{x}}^\top (\boldsymbol{y} - \boldsymbol{x}) = f(2) + \nabla f(2) \cdot (4 - 2) \tag{7.33a}$$

$$= 2 + \left(1 + \frac{1}{\log_e 2}\right) \cdot 2 \approx 6.9. \tag{7.33b}$$

原书 p.238

我们可以从第一性原理出发，通过回忆定义来检验一个函数或集合是否凸。在实践中，我们常常依赖那些保持凸性的运算来检验某个函数或集合是否凸。尽管细节大不相同，这又是我们在第 2 章对向量空间引入过的“封闭性”思想。

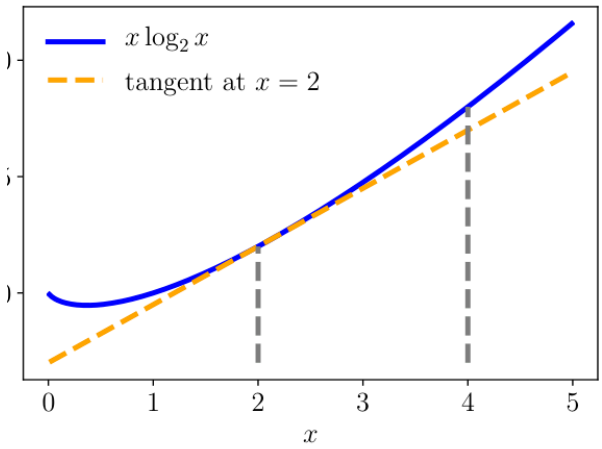


图 7.8: 负熵函数（它是凸的）及其在 $x = 2$ 处的切线。（对应原书 Figure 7.8。）

例 7.4. 凸函数的非负加权和仍是凸的。注意到，如果 f 是凸函数，$\alpha \geqslant 0$ 是非负标量，则函数 αf 是凸的。这一点可由把定义 7.3 等式两边同乘 α 看出，并回忆到乘以一个非负数不改变不等式方向。

如果 f_1 和 f_2 是凸函数，则由定义有

$$f_1(\theta \boldsymbol{x} + (1-\theta)\boldsymbol{y}) \leqslant \theta f_1(\boldsymbol{x}) + (1-\theta) f_1(\boldsymbol{y}) \tag{7.34}$$

$$f_2(\theta \boldsymbol{x} + (1-\theta)\boldsymbol{y}) \leqslant \theta f_2(\boldsymbol{x}) + (1-\theta) f_2(\boldsymbol{y}). \tag{7.35}$$

两式左右分别相加得

$$f_1(\theta \boldsymbol{x}+(1-\theta)\boldsymbol{y})+f_2(\theta \boldsymbol{x}+(1-\theta)\boldsymbol{y}) \leqslant \theta f_1(\boldsymbol{x})+(1-\theta) f_1(\boldsymbol{y})+\theta f_2(\boldsymbol{x})+(1-\theta) f_2(\boldsymbol{y}), \tag{7.36}$$

右边可整理为

$$\theta\big(f_1(\boldsymbol{x}) + f_2(\boldsymbol{x})\big) + (1-\theta)\big(f_1(\boldsymbol{y}) + f_2(\boldsymbol{y})\big), \tag{7.37}$$

从而完成了“凸函数之和仍是凸函数”的证明。

结合前面两条事实可知，对 $\alpha, \beta \geqslant 0$，$\alpha f_1(\boldsymbol{x}) + \beta f_2(\boldsymbol{x})$ 是凸的。利用类似论证，这种封闭性质可推广到更多凸函数的非负加权和。

注。 (7.30) 中的不等式有时称为 Jensen 不等式（Jensen's inequality）。事实上，一整类对凸函数取非负加权和的不等式都称为 Jensen 不等式。◇

Jensen不等式

总之，一个约束优化问题称为凸优化问题（convex optimization problem），如果

凸优化

$$\begin{aligned} \min_{\boldsymbol{x}} \quad & f(\boldsymbol{x}) \\ \text{subject to} \quad & g_i(\boldsymbol{x}) \leqslant 0 \quad \text{对所有} i = 1, \ldots, m \\ & h_j(\boldsymbol{x}) = 0 \quad \text{对所有} j = 1, \ldots, n, \end{aligned} \tag{7.38}$$

其中所有函数 $f(\boldsymbol{x})$、$g_i(\boldsymbol{x})$ 都是凸函数，所有 $h_j(\boldsymbol{x}) = 0$ 都是凸集。下面我们介绍两类被广泛使用、研究得很透彻的凸优化问题。

7.3.1　线性规划

考虑前述所有函数都为线性的特殊情形，即

$$\min_{\boldsymbol{x}\in\mathbb{R}^d} \boldsymbol{c}^\top \boldsymbol{x} \tag{7.39}$$

subject to　$A\boldsymbol{x} \leqslant \boldsymbol{b}$,

其中 $A \in \mathbb{R}^{m\times d}$，$\boldsymbol{b} \in \mathbb{R}^m$。这称为线性规划（linear program，LP）。它有 d 个变量和 m 个线性约束。线性规划是工业界应用最广的方法之一。其拉格朗日函数为

线性规划
工业应用

$$\mathcal{L}(\boldsymbol{x}, \lambda) = \boldsymbol{c}^\top \boldsymbol{x} + \lambda^\top (A\boldsymbol{x} - \boldsymbol{b}), \tag{7.40}$$

其中 $\lambda \in \mathbb{R}^m$ 是非负拉格朗日乘子向量。整理关于 $\boldsymbol{x}$ 的项得

$$\mathcal{L}(\boldsymbol{x}, \lambda) = (\boldsymbol{c} + A^\top \lambda)^\top \boldsymbol{x} - \lambda^\top \boldsymbol{b}. \tag{7.41}$$

对 $\mathcal{L}(\boldsymbol{x}, \lambda)$ 关于 $\boldsymbol{x}$ 求导并令其为零，得到

$$\boldsymbol{c} + A^\top \lambda = \boldsymbol{0}. \tag{7.42}$$

因此对偶拉格朗日函数为 $D(\lambda) = -\lambda^\top \boldsymbol{b}$。回忆我们要最大化 $D(\lambda)$。除了 $\mathcal{L}(\boldsymbol{x}, \lambda)$ 导数为零所给出的约束外，还有 $\lambda \geqslant 0$ 这一事实，于是得到如下对偶优化问题：

原极小对偶极大

$$\begin{aligned} \max_{\lambda\in\mathbb{R}^m} \quad & -\boldsymbol{b}^\top \lambda \\ \text{subject to} \quad & \boldsymbol{c} + A^\top \lambda = \boldsymbol{0} \\ & \lambda \geqslant 0. \end{aligned} \tag{7.43}$$

这也是一个线性规划，但有 m 个变量。我们可以根据 m 与 d 哪个更大，来选择求解原问题 (7.39) 还是对偶问题 (7.43)。回忆 d 是原线性规划中的变量数，m 是约束数。

原书 p.240

例 7.5 (线性规划)**.** 考虑线性规划

$$\begin{aligned} \min_{\boldsymbol{x}\in\mathbb{R}^2} \quad & -\begin{bmatrix} 5 \\ 3 \end{bmatrix}^\top \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \\ \text{subject to} \quad & \begin{bmatrix} 2 & 2 \\ 2 & -4 \\ 2 & 1 \\ 0 & -1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \leqslant \begin{bmatrix} 33 \\ 8 \\ 5 \\ -1 \\ 8 \end{bmatrix} \end{aligned} \tag{7.44}$$

它有两个变量。该规划也示于图 7.9。目标函数是线性的，因此等值线是直线。标准形式的约束集被翻译成图例。最优值必须位于阴影（可行）区域内，由星号标出。

原书 p.241

7.3.2　二次规划

考虑凸二次目标函数、且约束为仿射的情形，即

$$\min_{\boldsymbol{x}\in\mathbb{R}^d} \tfrac{1}{2}\boldsymbol{x}^\top Q\boldsymbol{x} + \boldsymbol{c}^\top \boldsymbol{x} \tag{7.45}$$

subject to　$A\boldsymbol{x} \leqslant \boldsymbol{b}$,

其中 $A \in \mathbb{R}^{m\times d}$，$\boldsymbol{b} \in \mathbb{R}^m$，$\boldsymbol{c} \in \mathbb{R}^d$。方阵 $Q \in \mathbb{R}^{d\times d}$ 对称正定，因此目标函数是凸的。这称为二次规划（quadratic program，QP）。注意它有 d 个变量和 m 个线性约束。

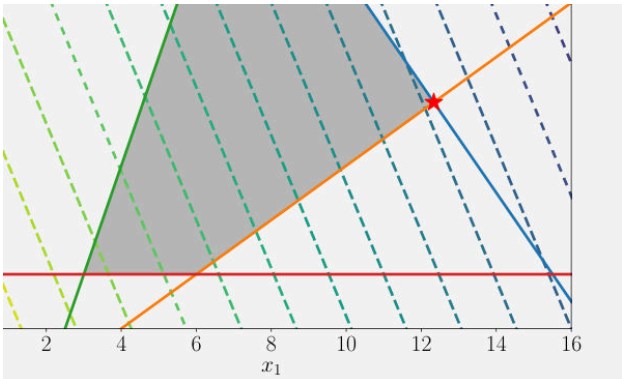


图 7.9: 线性规划示意。无约束问题（由等值线表示）在右侧有最小值。给定约束后的最优值由星号标出。（对应原书 Figure 7.9。）

例 7.6 (二次规划)**.** 考虑二次规划

$$\min_{\boldsymbol{x}\in\mathbb{R}^2} \frac{1}{2}\begin{bmatrix}x_1\\x_2\end{bmatrix}^\top \begin{bmatrix}2 & 1\\1 & 4\end{bmatrix}\begin{bmatrix}x_1\\x_2\end{bmatrix} + \begin{bmatrix}5\\3\end{bmatrix}^\top \begin{bmatrix}x_1\\x_2\end{bmatrix} \tag{7.46}$$

$$\text{subject to} \quad \begin{bmatrix}1 & 0\\-1 & 0\\0 & 1\\0 & -1\end{bmatrix}\begin{bmatrix}x_1\\x_2\end{bmatrix} \leqslant \begin{bmatrix}1\\1\\1\\1\end{bmatrix} \tag{7.47}$$

它有两个变量。该规划也示于图 7.4。目标函数是二次的，矩阵 Q 半正定，因此等值线为椭圆。最优值必须位于阴影（可行）区域内，由星号标出。

拉格朗日函数为

$$\mathcal{L}(\boldsymbol{x},\lambda) = \tfrac{1}{2}\boldsymbol{x}^\top Q\boldsymbol{x} + \boldsymbol{c}^\top\boldsymbol{x} + \lambda^\top(A\boldsymbol{x}-\boldsymbol{b}) \tag{7.48a}$$

$$= \tfrac{1}{2}\boldsymbol{x}^\top Q\boldsymbol{x} + (\boldsymbol{c}+A^\top\lambda)^\top\boldsymbol{x} - \lambda^\top\boldsymbol{b}, \tag{7.48b}$$

这里同样整理了各项。对 $\mathcal{L}(\boldsymbol{x},\lambda)$ 关于 $\boldsymbol{x}$ 求导并令其为零，得到

$$Q\boldsymbol{x} + (\boldsymbol{c}+A^\top\lambda) = \mathbf{0}. \tag{7.49}$$

由于 Q 正定因而可逆，得到

$$\boldsymbol{x} = -Q^{-1}(\boldsymbol{c}+A^\top\lambda). \tag{7.50}$$

把 (7.50) 代入原拉格朗日函数 $\mathcal{L}(\boldsymbol{x},\lambda)$，得到对偶拉格朗日函数

$$D(\lambda) = -\tfrac{1}{2}(\boldsymbol{c}+A^\top\lambda)^\top Q^{-1}(\boldsymbol{c}+A^\top\lambda) - \lambda^\top\boldsymbol{b}. \tag{7.51}$$

因此对偶优化问题为

原书 p.242

$$\begin{aligned}\max_{\lambda\in\mathbb{R}^m} \quad & -\tfrac{1}{2}(\boldsymbol{c}+A^\top\lambda)^\top Q^{-1}(\boldsymbol{c}+A^\top\lambda) - \lambda^\top\boldsymbol{b}\\ \text{subject to} \quad & \lambda \geqslant 0.\end{aligned} \tag{7.52}$$

我们将在第 12 章看到二次规划在机器学习中的一个应用。

7.3.3　勒让德–芬切尔变换与凸共轭

让我们在不考虑约束的情况下，重新审视 7.2 节的对偶思想。关于凸集的一个有用事实是：凸集可以等价地用它的支撑超平面（supporting hyperplane）来描述。一个超平面称为凸集的支撑超平面，如果它与凸集相交、且凸集完全位于它的某一侧。回忆我们可以把一个凸函数“填满”得到上图，而上图是一个凸集。因此，我们也可以用支撑超平面来描述凸函数。进一步注意到，支撑超平面恰好与凸函数相切，事实上就是函数在该点处的切线。回忆函数 $f(\boldsymbol{x})$ 在给定点 x_0 处的切线，就是该函数在该点梯度的取值 $\frac{\mathrm{d}f(x)}{\mathrm{d}x}\Big|_{x=x_0}$。总之，由于凸集可以等价地用其支撑超平面描述，凸函数也可以等价地用其梯度的一个函数来描述。勒让德变换（Legendre transform）把这一概念形式化。物理专业的学生通常是在经典力学中通过拉格朗日量与哈密顿量之间的关系来认识勒让德变换的。

支撑超平面

勒让德变换

物理联系

我们从最一般的定义出发（遗憾的是它形式上有些反直觉），然后考察特例，把定义与上段描述的直觉联系起来。勒让德–芬切尔变换（Legendre–Fenchel transform）是一种（类似傅里叶变换意义下的）变换，它把一个凸的可微函数 $f(\boldsymbol{x})$ 变换为一个依赖于切线 $s(\boldsymbol{x}) = \nabla_{\boldsymbol{x}} f(\boldsymbol{x})$ 的函数。需要强调，这是对函数 $f(\cdot)$ 本身的变换，而不是对变量 $\boldsymbol{x}$ 或函数在 $\boldsymbol{x}$ 处取值的变换。勒让德–芬切尔变换也称为凸共轭（convex conjugate）（原因很快会看到），它与对偶密切相关（Hiriart-Urruty and Lemaréchal, 2001, 第 5 章）。

LF 变换

凸共轭

定义 7.4. 函数 $f : \mathbb{R}^D \to \mathbb{R}$ 的凸共轭 f^* 定义为

$$f^*(s) = \sup_{\boldsymbol{x}\in\mathbb{R}^D} \big(\langle s, \boldsymbol{x}\rangle - f(\boldsymbol{x})\big). \tag{7.53}$$

注意，上面这个凸共轭定义并不要求函数 f 是凸的或可微的。在定义 7.4 中，我们使用了一般的内积（见 3.2 节），但在本节余下部分，为避免过多技术细节，我们考虑有限维向量之间的标准点积（$\langle s, \boldsymbol{x}\rangle = s^\top \boldsymbol{x}$）。

原书 p.243

要从几何上理解定义 7.4, 考虑一个简单漂亮的一维凸且可微函数, 例如 $f(x) = x^2$。注意由于我们看的是一维问题，超平面退化为一条直线。考虑直线 $y = sx + c$。回忆我们可以用支撑超平面来描述凸函数，那么让我们尝试用支撑直线来描述函数 $f(x)$。固定直线的斜率 $s \in \mathbb{R}$，对 f 图像上每个点 $(x_0, f(x_0))$，求出使直线仍经过 $(x_0, f(x_0))$ 的最小 c 值。注意 c 的最小值就是斜率为 s 的直线“刚好碰到”函数 $f(x) = x^2$ 的位置。经过 $(x_0, f(x_0))$、斜率为 s 的直线为

$$y - f(x_0) = s(x - x_0). \tag{7.54}$$

这条直线在 y 轴上的截距为 $-sx_0 + f(x_0)$。因此使 $y = sx + c$ 与 f 图像相交的最小 c 为

$$\inf_{x_0} -sx_0 + f(x_0). \tag{7.55}$$

按惯例，前面这个凸共轭定义取为它的相反数。这一段推理并不依赖于我们选取了一维凸且可微函数这一事实，对非凸、不可微的 $f : \mathbb{R}^D \to \mathbb{R}$ 也成立。经典的勒让德变换定义在 $\mathbb{R}^D$ 上凸且可微的函数上。

经典勒让德

注。像例子 $f(x) = x^2$ 这样凸且可微的函数是一个漂亮的特例：此时不需要上确界，函数与其勒让德变换之间存在一一对应。让我们从第一性原理导出这一点。对凸且可微的函数，我们知道在 x_0 处切线与 $f(x_0)$ 相切，因此

$$f(x_0) = sx_0 + c. \tag{7.56}$$

回忆我们想用梯度 $\nabla_{\boldsymbol{x}} f(\boldsymbol{x})$ 来描述凸函数 $f(x)$，而 $s = \nabla_{\boldsymbol{x}} f(x_0)$。整理得到 $-c$ 的表达式：

$$-c = sx_0 - f(x_0). \tag{7.57}$$

注意 $-c$ 随 x_0 变化、因而也随 s 变化，这就是为什么我们可以把它看作 s 的函数，记为

$$f^*(s) := sx_0 - f(x_0). \tag{7.58}$$

把 (7.58) 与定义 7.4 对比，可见 (7.58) 是（不带上确界的）一个特例。⋄

共轭函数有一些很好的性质；例如，对凸函数，再做一次勒让德变换就会回到原函数。正如 $f(x)$ 的斜率是 s，$f^*(s)$ 的斜率就是 x。下面两个例子展示了凸共轭在机器学习中的常见用法。 原书 p.244

例 7.7 (凸共轭)**.** 为说明凸共轭的应用，考虑基于正定矩阵 $K \in \mathbb{R}^{n\times n}$ 的二次函数

$$f(\boldsymbol{y}) = \frac{\lambda}{2}\boldsymbol{y}^\top K^{-1}\boldsymbol{y}. \tag{7.59}$$

我们记原变量为 $\boldsymbol{y} \in \mathbb{R}^n$，对偶变量为 $\alpha \in \mathbb{R}^n$。

应用定义 7.4，得到函数

$$f^*(\alpha) = \sup_{\boldsymbol{y}\in\mathbb{R}^n} \langle \boldsymbol{y}, \alpha\rangle - \frac{\lambda}{2}\boldsymbol{y}^\top K^{-1}\boldsymbol{y}. \tag{7.60}$$

由于函数可微，我们可以通过对 $\boldsymbol{y}$ 求导并令其为零来求最大值：

$$\frac{\partial}{\partial \boldsymbol{y}}\Big[\langle \boldsymbol{y}, \alpha\rangle - \tfrac{\lambda}{2}\boldsymbol{y}^\top K^{-1}\boldsymbol{y}\Big] = (\alpha - \lambda K^{-1}\boldsymbol{y})^\top \tag{7.61}$$

于是当梯度为零时，有 $\boldsymbol{y} = \frac{1}{\lambda}K\alpha$。代入 (7.60) 得

$$f^*(\alpha) = \frac{1}{\lambda}\alpha^\top K\alpha - \frac{\lambda}{2}\Big(\frac{1}{\lambda}K\alpha\Big)^\top K^{-1}\Big(\frac{1}{\lambda}K\alpha\Big) = \frac{1}{2\lambda}\alpha^\top K\alpha. \tag{7.62}$$

例 7.8. 在机器学习中，我们经常使用函数之和；例如，训练集的目标函数包含训练集中每个样本损失之和。下面我们推导损失 $\ell(t)$ 之和的凸共轭，其中 $\ell : \mathbb{R} \to \mathbb{R}$。这也说明了凸共轭在向量情形中的应用。令 $L(\boldsymbol{t}) = \sum_{i=1}^n \ell_i(t_i)$。则 原书 p.245

$$\begin{aligned}
L^*(\boldsymbol{z}) &= \sup_{\boldsymbol{t}\in\mathbb{R}^n} \langle \boldsymbol{z}, \boldsymbol{t}\rangle - \sum_{i=1}^n \ell_i(t_i) && (7.63a)\\
&= \sup_{\boldsymbol{t}\in\mathbb{R}^n} \sum_{i=1}^n z_i t_i - \ell_i(t_i) \qquad \text{（点积定义）} && (7.63b)\\
&= \sum_{i=1}^n \sup_{t\in\mathbb{R}^n} z_i t_i - \ell_i(t_i) && (7.63c)\\
&= \sum_{i=1}^n \ell_i^*(z_i) \qquad \text{（共轭定义）}. && (7.63d)
\end{aligned}$$

回忆在 7.2 节中我们用拉格朗日乘子导出了对偶优化问题。此外，对凸优化问题我们有强对偶，即原问题与对偶问题的解一致。这里介绍的勒让德–芬切尔变换也可用于导出对偶优化问题。此外，当函数凸且可微时，上确界是唯一的。为进一步研究这两种方法之间的关系，让我们考虑一个带线性等式约束的凸优化问题。

例 7.9. 设 $f(\boldsymbol{y})$ 和 $g(\boldsymbol{x})$ 是凸函数，A 是维数合适的实矩阵，满足 $A\boldsymbol{x} = \boldsymbol{y}$。则

$$\min_{\boldsymbol{x}} f(A\boldsymbol{x}) + g(\boldsymbol{x}) = \min_{A\boldsymbol{x}=\boldsymbol{y}} f(\boldsymbol{y}) + g(\boldsymbol{x}). \tag{7.64}$$

对约束 $A\boldsymbol{x}=\boldsymbol{y}$ 引入拉格朗日乘子 $\boldsymbol{u}$,

$$\min_{A\boldsymbol{x}=\boldsymbol{y}} f(\boldsymbol{y})+g(\boldsymbol{x}) = \min_{\boldsymbol{x},\boldsymbol{y}}\max_{\boldsymbol{u}} f(\boldsymbol{y})+g(\boldsymbol{x})+(A\boldsymbol{x}-\boldsymbol{y})^\top\boldsymbol{u} \tag{7.65a}$$

$$= \max_{\boldsymbol{u}}\min_{\boldsymbol{x},\boldsymbol{y}} f(\boldsymbol{y})+g(\boldsymbol{x})+(A\boldsymbol{x}-\boldsymbol{y})^\top\boldsymbol{u}, \tag{7.65b}$$

其中交换 max 与 min 的最后一步，是由于 $f(\boldsymbol{y})$ 和 $g(\boldsymbol{x})$ 都是凸函数。把点积项拆开并分别收集 $\boldsymbol{x}$ 和 $\boldsymbol{y}$:

$$\max_{\boldsymbol{u}}\min_{\boldsymbol{x},\boldsymbol{y}} f(\boldsymbol{y})+g(\boldsymbol{x})+(A\boldsymbol{x}-\boldsymbol{y})^\top\boldsymbol{u} = \max_{\boldsymbol{u}}\Big[\min_{\boldsymbol{y}} -\boldsymbol{y}^\top\boldsymbol{u}+f(\boldsymbol{y})\Big]+\Big[\min_{\boldsymbol{x}}(A\boldsymbol{x})^\top\boldsymbol{u}+g(\boldsymbol{x})\Big] \tag{7.66a}$$

$$= \max_{\boldsymbol{u}}\Big[\min_{\boldsymbol{y}} -\boldsymbol{y}^\top\boldsymbol{u}+f(\boldsymbol{y})\Big]+\Big[\min_{\boldsymbol{x}}\boldsymbol{x}^\top A^\top\boldsymbol{u}+g(\boldsymbol{x})\Big] \tag{7.66b}$$

回忆凸共轭（定义 7.4）以及点积对称这一事实（对一般内积，$A^\top$ 应替换为伴随算子 A^*）:

伴随算子

$$\max_{\boldsymbol{u}}\Big[\min_{\boldsymbol{y}} -\boldsymbol{y}^\top\boldsymbol{u}+f(\boldsymbol{y})\Big]+\Big[\min_{\boldsymbol{x}}\boldsymbol{x}^\top A^\top\boldsymbol{u}+g(\boldsymbol{x})\Big] = \max_{\boldsymbol{u}} -f^*(\boldsymbol{u})-g^*(-A^\top\boldsymbol{u}). \tag{7.67a}$$

因此我们证明了

$$\min_{\boldsymbol{x}} f(A\boldsymbol{x})+g(\boldsymbol{x}) = \max_{\boldsymbol{u}} -f^*(\boldsymbol{u})-g^*(-A^\top\boldsymbol{u}). \tag{7.68}$$

事实证明，勒让德–芬切尔共轭对于那些可表述为凸优化问题的机器学习问题非常有用。特别地，对独立作用于每个样本的凸损失函数，共轭损失是一种推导对偶问题的便捷方式。 原书 p.246

7.4　拓展阅读

连续优化是一个活跃的研究领域，我们并不试图全面介绍最新进展。

从梯度下降的视角看，它有两大弱点，每一个都有各自的文献。第一个挑战是：梯度下降是一阶算法，不使用关于曲面曲率的信息。当存在长山谷时，梯度垂直于我们感兴趣的方向。动量的思想可推广为一大类加速方法（Nesterov, 2018）。共轭梯度法通过考虑先前的方向，避免了梯度下降遇到的问题（Shewchuk, 1994）。牛顿法等二阶方法利用 Hessian 矩阵提供曲率信息。许多选择步长的方法以及动量之类的思想，都是通过考虑目标函数的曲率而提出的（Goh, 2017; Bottou et al., 2018）。L-BFGS 等拟牛顿法试图用计算量更小的方法来近似 Hessian（Nocedal and Wright, 2006）。近来人们对用其他度量来计算下降方向产生了兴趣，从而产生了镜像下降（mirror descent）（Beck and Teboulle, 2003）和自然梯度（natural gradient）（Toussaint, 2012）等方法。

第二个挑战是处理不可微函数。当函数上有尖点（kink）时，梯度方法没有良好定义。在这些情形下，可以使用次梯度方法（subgradient methods）（Shor, 1985）。关于优化不可微函数的更多信息与算法，我们推荐 Bertsekas (1999) 的书。关于数值求解连续优化问题（包括约束优化问题的算法），已有大量文献。要了解这些文献，较好的入门是 Luenberger (1969) 和 Bonnans et al. (2006) 的书。关于连续优化的最新综述见 Bubeck (2015)。

Hugo Gonçalves 的博客也是一个更容易入门勒让德–芬切尔变换的好资源:`https://tinyurl.com/ydaal7hj`。

博客资源

现代机器学习应用往往意味着数据规模使批量梯度下降无法使用，因此随机梯度下降是当前大规模机器学习方法的主力。相关最新综述见 Hazan (2015) 和 Bottou et al. (2018)。

关于对偶与凸优化，Boyd and Vandenberghe (2004) 的书附有在线讲义和幻灯片。更偏数学的处理见 Bertsekas (2009), 该领域一位重要研究者的近著是 Nesterov (2018)。凸优化以凸分析为基础, 对凸函数更基础结果感兴趣的读者可参阅 Rockafellar (1970)、Hiriart-Urruty and Lemaréchal (2001) 和 Borwein and Lewis (2006)。勒让德–芬切尔变换也在上述凸分析著作中有所讨论，但更适合初学者的介绍见 Zia et al. (2009)。勒让德–芬切尔变换在凸优化算法分析中的作用，综述于 Polyak (2016)。

原书 p.247

习题

习题 7.1

考虑单变量函数

$$f(x) = x^3 + 6x^2 - 3x - 5.$$

求它的驻点，并指出它们是极大、极小还是鞍点。

习题 7.2

考虑随机梯度下降的更新方程（式 (7.15)）。写出当小批量规模为 1 时的更新式。

习题 7.3

判断下列命题是否为真：

(a) 任意两个凸集的交是凸的。

(b) 任意两个凸集的并是凸的。

(c) 一个凸集 A 与另一个凸集 B 的差集是凸的。

习题 7.4

判断下列命题是否为真：

(a) 任意两个凸函数之和是凸的。

(b) 任意两个凸函数之差是凸的。

(c) 任意两个凸函数之积是凸的。

(d) 任意两个凸函数的最大值函数是凸的。

习题 7.5

把下列优化问题写成矩阵记号下的标准线性规划：

$$\max_{\boldsymbol{x}\in\mathbb{R}^2,\ \xi\in\mathbb{R}} \boldsymbol{p}^\top \boldsymbol{x} + \xi$$

约束为 $\xi \geqslant 0$、$x_0 \leqslant 0$、$x_1 \leqslant 3$。

习题 7.6

考虑图 7.9 所示的线性规划，

$$\min_{\boldsymbol{x}\in\mathbb{R}^2} -\begin{bmatrix}5\\3\end{bmatrix}^\top \begin{bmatrix}x_1\\x_2\end{bmatrix}$$

$$\text{subject to} \quad \begin{bmatrix} 2 & 2 \\ 2 & -4 \\ 2 & 1 \\ 0 & -1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \leqslant \begin{bmatrix} 33 \\ 8 \\ 5 \\ -1 \\ 8 \end{bmatrix}$$

用拉格朗日对偶推导对偶线性规划。

习题 7.7

考虑图 7.4 所示的二次规划，

$$\min_{\boldsymbol{x}\in\mathbb{R}^2} \frac{1}{2} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}^\top \begin{bmatrix} 2 & 1 \\ 1 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + \begin{bmatrix} 5 \\ 3 \end{bmatrix}^\top \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

原书 p.248

$$\text{subject to} \quad \begin{bmatrix} 1 & 0 \\ -1 & 0 \\ 0 & 1 \\ 0 & -1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \leqslant \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \end{bmatrix}$$

用拉格朗日对偶推导对偶二次规划。

习题 7.8

考虑如下凸优化问题

$$\min_{\boldsymbol{w}\in\mathbb{R}^D} \frac{1}{2}\boldsymbol{w}^\top\boldsymbol{w} \qquad \text{subject to} \quad \boldsymbol{w}^\top\boldsymbol{x} \geqslant 1.$$

通过引入拉格朗日乘子 λ，推导其拉格朗日对偶。

习题 7.9

考虑 $\boldsymbol{x} \in \mathbb{R}^D$ 的负熵

$$f(\boldsymbol{x}) = \sum_{d=1}^{D} x_d \log x_d.$$

假设使用标准点积，推导凸共轭函数 $f^*(s)$。

提示：对合适的函数求梯度并令梯度为零。

习题 7.10

考虑函数

$$f(x) = \frac{1}{2}\boldsymbol{x}^\top A\boldsymbol{x} + \boldsymbol{b}^\top\boldsymbol{x} + c,$$

其中 A 严格正定，即可逆。推导 $f(x)$ 的凸共轭。

提示：对合适的函数求梯度并令梯度为零。

习题 7.11

合页损失（hinge loss，支持向量机使用的损失）为

$$L(\alpha) = \max\{0,\, 1-\alpha\}.$$

如果我们想应用 L-BFGS 之类的梯度方法，而又不想诉诸次梯度方法，就需要把合页损失中的尖点平滑化。计算合页损失的凸共轭 $L^*(\beta)$，其中 β 是对偶变量。再加入一个 ℓ_2 近端项，计算所得函数的共轭

$$L^*(\beta) + \frac{\gamma}{2}\beta^2,$$

其中 γ 是给定的超参数。

第二部分

第二部分　机器学习核心问题

第 8 章　当模型遇见数据

原书 p.251

在本书第一部分中，我们介绍了构成许多机器学习方法基础的数学知识。我们希望读者能从第一部分学会数学语言的基本形式，然后用它来描述和讨论机器学习。本书第二部分介绍机器学习的四大支柱：

- 回归（第 9 章）
- 降维（第 10 章）
- 密度估计（第 11 章）
- 分类（第 12 章）

本部分的主要目的是说明：如何利用第一部分引入的数学概念来设计机器学习算法，从而解决四大支柱范围内的任务。我们并不打算介绍高等机器学习概念，而是提供一套实用方法，使读者能够应用从第一部分获得的知识；对于已经熟悉数学的读者，它也为更广阔的机器学习文献提供了入口。

8.1　数据、模型与学习

在此值得停下来思考一下：机器学习算法究竟是为解决什么问题而设计的。如第 1 章所述，机器学习系统有三大组成部分：数据、模型和学习。机器学习的核心问题是“我们所说的好模型是什么意思?”“模型（model）”一词有许多微妙之处，本章我们会多次回到它。如何客观地定义“好”也并非一目了然。机器学习的一条指导原则是：好模型应当在未见数据上表现良好。这要求我们定义一些性能度量，例如准确率或与真实值的距离，并找出在这些性能度量下做好的方法。本章介绍一些常用的、用于讨论机器学习模型的数学与统计语言的必要片段。通过这样做，我们简要勾勒出训练模型的最佳实践，使得所得预测器在我们尚未见过的数据上表现良好。

模型

如第 1 章所述，“机器学习算法”这一短语在两种意义上使用：训练与预测。本章将描述这些思想，以及在不同模型之间做选择的思想。我们将在 8.2 节介绍经验风险最小化框架，在 8.3 节介绍最大似然原理，在 8.4 节介绍概率模型的思想；在 8.5 节简要勾勒一种用于指定概率模型的图形语言，最后在 8.6 节讨论模型选择。本节余下部分展开讨论机器学习的三大组成部分：数据、模型与学习。

8.1.1　作为向量的数据

我们假设数据可以被计算机读取，并以数值格式充分地表示。数据被假定为表格形式（图 8.1）：表的每一行表示一个具体的实例或样本，每一列表示一个具体的特征。近年来，机器学习已被应用于许多并非显然以表格数值格式出现的数据，例如基因组序列、网页的文本与图像内容、社交网络图。我们不讨论识别好特征这一重要而富有挑战

数据规整

性的方面；其中许多方面依赖领域专业知识并需要精心的工程，近年来被归入数据科学（data science）的范畴（Stray, 2016; Adhikari and DeNero, 2018）。

原书 p.252

即使数据已是表格形式，要得到数值表示仍有许多选择。例如在表 8.1 中，性别列（一个类别变量）可以转换为数字 0 表示“男”、1 表示“女”；或者性别也可以分别用数字 $-1, +1$ 表示（如表 8.2 所示）。此外，构造表示时使用领域知识往往很重要，例如知道大学学位由学士到硕士再到博士递进，或者意识到所给邮编并非一串字符，而是实际编码了伦敦的一个区域。在表 8.2 中，我们把表 8.1 的数据转换为数值格式，每个邮编被表示为两个数：纬度和经度。即使是可以直接读入机器学习算法的数值数据，也应仔细考虑单位、缩放和约束。在没有额外信息时，应将数据集的所有列平移缩放，使其经验均值为 0、经验方差为 1。本书假设领域专家已经把数据恰当转换好，即每个输入 $\boldsymbol{x}_n$ 都是一个 D 维实向量，称为特征（feature）、属性（attribute）或协变量（covariate）。我们认为数据集具有表 8.2 所示的形式。注意在新的数值表示中我们丢掉了表 8.1 的“姓名”列。这样做有两个主要原因：(1) 我们不期望标识符（姓名）对机器学习任务有信息；(2) 我们可能希望对数据匿名化以保护员工隐私。

特征/ 协变量

在本书本部分，我们用 N 表示数据集中样本的数量，并用小写 $n = 1, \ldots, N$ 为样本编号。假设我们得到一组以向量数组表示的数值数据（表 8.2）。每一行是一个具体的个体 $\boldsymbol{x}_n$，在机器学习中常称为一个样本（example）或数据点（data point）。下标 n 表示这是数据集中 N 个样本中的第 n 个。每一列表示关于该样本的一个我们感兴趣的特征，特征编号为 $d = 1, \ldots, D$。回忆数据被表示为向量，意味着每个样本（每个数据点）都是一个 D 维向量。表格的取向源自数据库界，但对某些机器学习算法（例如第 10 章），把样本表示为列向量更为方便。

样本/ 数据点

考虑基于表 8.2 数据由年龄预测年薪的问题。这称为监督学习问题，其中每个样本 $\boldsymbol{x}_n$（年龄）都有一个与之关联的标签 y_n（薪水）。标签 y_n 还有其他名字，包括目标（target）、响应变量（response variable）和标注（annotation）。数据集写为一组样本–标签对 $\{(\boldsymbol{x}_1, y_1), \ldots, (\boldsymbol{x}_n, y_n), \ldots, (\boldsymbol{x}_N, y_N)\}$。样本表 $\{\boldsymbol{x}_1, \ldots, \boldsymbol{x}_N\}$ 常被拼接起来，记为 $X \in \mathbb{R}^{N \times D}$。图 8.1 示出由表 8.2 最右两列构成的数据集，其中 $x =$ 年龄，$y =$ 薪水。

标签

我们用第一部分引入的概念来形式化上一段那样的机器学习问题。把数据表示为向量 $\boldsymbol{x}_n$，使我们可以使用线性代数（第 2 章）的概念。在许多机器学习算法中，我们还需要能够比较两个向量。正如将在第 9 章和第 12 章看到的，计算两个样本之间的相似度或距离，使我们能够把“特征相似的样本应有相似标签”这一直觉形式化。两个向量的比较要求我们构造一种几何（第 3 章），并使我们能用第 7 章的技术优化所得的学习问题。

既然数据有了向量表示，我们就可以操纵数据以寻找可能更好的表示。我们将用两种方式讨论寻找好表示：寻找原始特征向量的低维逼近；以及使用原始特征向量的非线性高维组合。在第 10 章，我们将看到通过寻找主成分来为原始数据空间寻找低维逼近的例子。寻找主成分与第 4 章介绍的特征值和奇异值分解密切相关。对于高维表示，我们将看到一个显式特征映射 $\phi(\cdot)$，它使我们能用更高维的表示 $\phi(\boldsymbol{x}_n)$ 来表示输入 $\boldsymbol{x}_n$。高维表示的主要动机是：我们可以把新特征构造为原始特征的非线性组合，从而可能使学习问题更容易。我们将在 9.2 节讨论特征映射，并在 12.4 节说明该特征映射如何导出核（kernel）。近年来，深度学习方法（Goodfellow et al., 2016）在利用数据本身学习新的好特征方面展现出前景，并在计算机视觉、语音识别、自然语言处理等领域非常成功。本书本部分不讨论神经网络，但读者可参阅 5.6 节中关于反向传播（backpropagation）的数学描述，它是训练神经网络的关键概念。

特征映射

核

原书 p.254

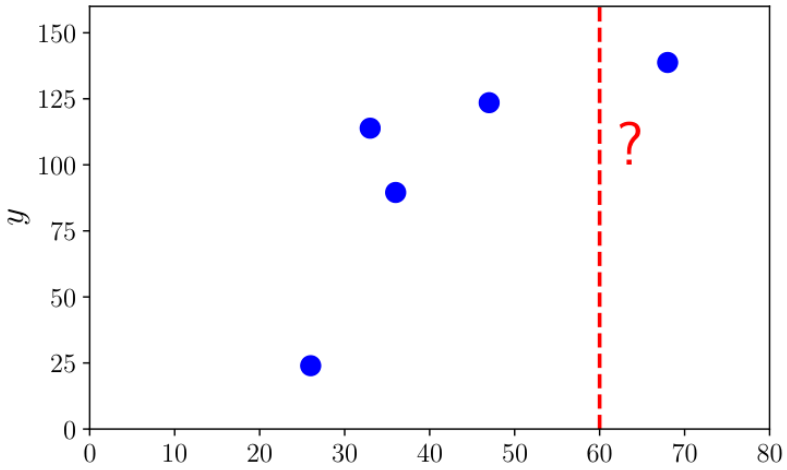


图 8.1: 线性回归的玩具数据。训练数据取自表 8.2 最右两列，以 $(\boldsymbol{x}_n, y_n)$ 对表示。我们关心一位六十岁者（$x = 60$）的薪水，用红色竖直虚线标出，它不属于训练数据。（对应原书 Figure 8.1。）

8.1.2　作为函数的模型

一旦数据有了合适的向量表示，我们就可以着手构造预测函数（称为预测器 predictor）。在第 1 章我们还没有精确描述模型的语言。借助第一部分的概念，现在可以引入“模型”的含义。本书提出两大主要途径：把预测器看作函数，以及把预测器看作概率模型。我们在此描述前者，下一小节描述后者。

预测器

预测器是一个函数：给定一个具体的输入样本（在我们这里是特征向量），它产生一个输出。暂且把输出看作一个数，即实值标量输出。可写为

$$f : \mathbb{R}^D \to \mathbb{R}, \tag{8.1}$$

其中输入向量 $\boldsymbol{x}$ 是 D 维的（有 D 个特征），作用于它的函数 f（写作 $f(\boldsymbol{x})$）返回一个实数。图 8.2 示出一个可用于计算输入 x 预测值的可能函数。

本书不考虑所有函数这一一般情形（那需要泛函分析），而是考虑线性函数这一特殊情形

$$f(\boldsymbol{x}) = \boldsymbol{\theta}^\top \boldsymbol{x} + \theta_0 \tag{8.2}$$

其中 $\boldsymbol{\theta}$ 与 θ_0 未知。这一限制意味着，仅用第 2 章和第 3 章的内容就足以精确陈述非概率（与下一小节描述的概率观点相对）机器学习观点下的预测器概念。线性函数在“可解决问题的广泛性”与“所需背景数学的量”之间取得了良好平衡。

原书 p.255

8.1.3　作为概率分布的模型

我们常把数据看作对某个真实底层效应的含噪观测，并希望通过应用机器学习从噪声中识别出信号。这要求我们有一种量化噪声效应的语言。我们还常希望预测器能表达某种不确定性，例如量化我们对某个具体测试数据点预测值的置信度。如第 6 章所见，概率论提供了一种量化不确定性的语言。图 8.3 以高斯分布示出该函数的预测不确定性。

我们可以不把预测器看作单个函数，而把预测器看作概率模型，即描述可能函数之分布的模型。本书把自己限制在具有有限维参数的分布这一特殊情形，从而无需随机过

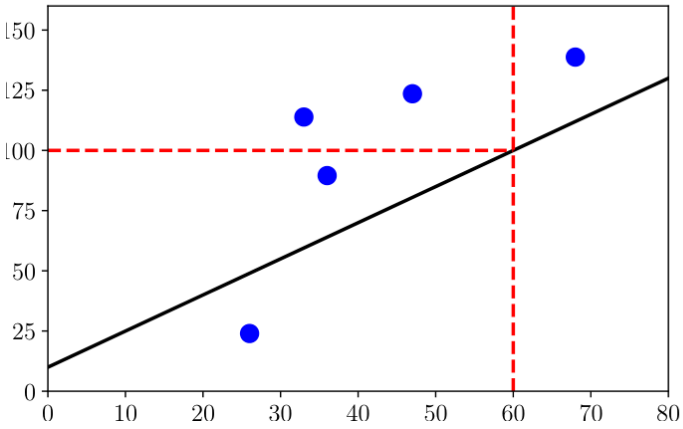


图 8.2: 示例函数（黑色实线对角线）及其在 $x = 60$ 处的预测，即 $f(60) = 100$。（对应原书 Figure 8.2。）

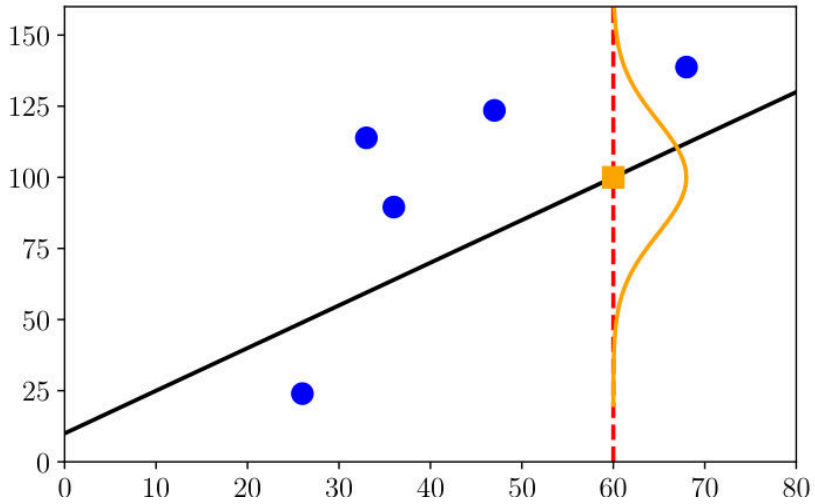


图 8.3: 示例函数（黑色实线对角线）及其在 $x = 60$ 处的预测不确定性（画为高斯分布）。（对应原书 Figure 8.3。）

程和随机测度即可描述概率模型。对这一特殊情形，我们可以把概率模型看作多元概率分布，这已经能容纳一类丰富的模型。

我们将在 8.4 节介绍如何使用概率（第 6 章）的概念来定义机器学习模型，并在 8.5 节介绍一种以紧凑方式描述概率模型的图形语言。

原书 p.256

8.1.4　学习即寻找参数

原书 p.257

学习的目标是找到一个模型及其相应参数，使所得预测器在未见数据上表现良好。讨论机器学习算法时，概念上有三个不同的算法阶段：

1. 预测或推断
2. 训练或参数估计
3. 超参数调节或模型选择

预测阶段是把训练好的预测器用于先前未见的测试数据。换言之，参数和模型选择已经固定，预测器被应用于表示新输入数据点的新向量。如第 1 章和上一小节所述，本书将考虑机器学习的两个学派，分别对应预测器是函数还是概率模型。当我们有一个概率模型（详见 8.4 节）时，预测阶段称为推断（inference）。

注。遗憾的是，不同算法阶段的命名并无统一约定。“推断”一词有时也被用来指概率模型的参数估计，较少时候也可能被用来指非概率模型的预测。◇

训练或参数估计阶段是我们根据训练数据调整预测模型的阶段。我们希望在给定训练数据下找到好的预测器，主要有两条策略：基于某种质量度量找到最佳预测器（有时称为寻找点估计），或者使用贝叶斯推断。寻找点估计可应用于两类预测器，但贝叶斯推断需要概率模型。

对非概率模型，我们遵循经验风险最小化（empirical risk minimization）原理，将在 8.2 节描述。经验风险最小化直接给出一个寻找好参数的优化问题。对于统计模型，使用最大似然（maximum likelihood）原理来寻找一组合适的参数（8.3 节）。我们还可以用概率模型对参数的不确定性建模，将在 8.4 节更详细地讨论。

经验风险最小化
最大似然

我们用数值方法寻找“拟合”数据的好参数，大多数训练方法可被看作爬山（hill-climbing）方法以寻找目标的最大值，例如似然的最大值。要应用爬山方法，我们使用第 5 章所述的梯度，并实现第 7 章的数值优化方法。优化的约定是最小化目标，因此机器学习目标中常有一个额外的负号。

原书 p.258

如第 1 章所述，我们关心基于数据学习一个模型，使其在未来数据上表现良好。模型仅仅拟合训练数据是不够的，预测器还需在未见数据上表现良好。我们用交叉验证（cross-validation，8.2.4 节）来模拟预测器在未来未见数据上的行为。正如本章将看到的要实现在未见数据上表现良好这一目标，我们需要在“在训练数据上拟合得好”与“对现象找到‘简单’解释”之间取得平衡。这一折中通过正则化（8.2.3 节）或加入先验（8.3.2 节）来实现。在哲学上，这既不被认为是归纳也不被认为是演绎，而被称为溯因（abduction）。根据《斯坦福哲学百科全书》，溯因就是最佳解释推理的过程（Douven, 2017）。

交叉验证

我们常常需要对预测器的结构做高层建模决策，例如使用多少分量、或考虑哪一类概率分布。分量数的选择就是一个超参数（hyperparameter）的例子，该选择会显著影响模型性能。在不同模型之间做选择的问题称为模型选择（model selection），将在 8.6 节描述。对非概率模型，模型选择常用嵌套交叉验证（nested cross-validation）完成，见 8.6.1 节。我们也用模型选择来选择模型的超参数。

超参数
模型选择
嵌套交叉验证

注。参数与超参数之间的区分有些任意，主要由“什么可以数值优化”与“什么需要使用搜索技术”之间的区分所驱动。另一种看待该区分的方式是：把参数看作概率模型的显式参数，把超参数（更高层的参数）看作控制这些显式参数之分布的参数。◇

在以下各节中，我们将考察机器学习的三种风味：经验风险最小化（8.2 节）、最大似然原理（8.3 节）和概率建模（8.4 节）。

8.2　经验风险最小化

原书 p.259

掌握了全部数学工具之后，我们现在可以引入“学习”的含义。机器学习的“学习”部分归结为基于训练数据估计参数。本节考虑预测器是函数的情形；概率模型的情形在 8.3 节考虑。我们描述经验风险最小化的思想，它最初因支持向量机（第 12 章）的提出而流行。但其一般原理广泛适用，使我们无需显式构造概率模型即可追问“什么是学习”。有四个主要的设计选择，将在以下各小节详细讨论：

- 8.2.1 我们允许预测器取什么样的函数集合?
- 8.2.2 我们如何度量预测器在训练数据上的好坏?
- 8.2.3 如何仅凭训练数据构造出在未见测试数据上表现良好的预测器?
- 8.2.4 在模型空间中搜索的流程是什么?

8.2.1　函数的假设类

假设给定 N 个样本 $\boldsymbol{x}_n \in \mathbb{R}^D$ 和相应的标量标签 $y_n \in \mathbb{R}$。我们考虑监督学习情形，得到对 $(\boldsymbol{x}_1, y_1), \ldots, (\boldsymbol{x}_N, y_N)$。给定这些数据，我们希望估计一个由 $\boldsymbol{\theta}$ 参数化的预测器 $f(\cdot, \boldsymbol{\theta}) : \mathbb{R}^D \to \mathbb{R}$。我们希望能找到一个好参数 $\boldsymbol{\theta}^*$，使我们很好地拟合数据，即

$$f(\boldsymbol{x}_n, \boldsymbol{\theta}^*) \approx y_n \quad \text{对所有} \quad n = 1, \ldots, N. \tag{8.3}$$

本节用记号 $\hat{y}_n = f(\boldsymbol{x}_n, \boldsymbol{\theta}^*)$ 表示预测器的输出。

注。为叙述方便，我们将用监督学习（有标签的情形）来描述经验风险最小化。这简化了假设类和损失函数的定义。在机器学习中选择一个参数化的函数类（例如仿射函数）也很常见。⋄

例 8.1. 我们引入普通最小二乘回归问题来说明经验风险最小化。回归的更完整论述见第 9 章。当标签 y_n 为实值时，预测器函数类的一个流行选择是仿射函数集合。在机器学习中仿射函数常被称为线性函数。我们把额外的单位特征 $x^{(0)} = 1$ 拼接到 $\boldsymbol{x}_n$ 上，得到更紧凑的仿射函数记号 $\boldsymbol{x}_n = [1, x_n^{(1)}, x_n^{(2)}, \ldots, x_n^{(D)}]^\top$。相应地参数向量为 $\boldsymbol{\theta} = [\theta_0, \theta_1, \theta_2, \ldots, \theta_D]^\top$，从而可把预测器写为线性函数

仿射函数

$$f(\boldsymbol{x}_n, \boldsymbol{\theta}) = \boldsymbol{\theta}^\top \boldsymbol{x}_n. \tag{8.4}$$

该线性预测器等价于仿射模型

$$f(\boldsymbol{x}_n, \boldsymbol{\theta}) = \theta_0 + \sum_{d=1}^{D} \theta_d x_n^{(d)}. \tag{8.5}$$

预测器以表示单个样本的特征向量 $\boldsymbol{x}_n$ 为输入，产生实值输出，即 $f : \mathbb{R}^{D+1} \to \mathbb{R}$。本章前面各图中的直线预测器，意味着我们已经假设了一个仿射函数。

原书 p.260

我们也可以不使用线性函数，而希望把非线性函数作为预测器。近年来神经网络的进展使我们能高效计算更复杂的非线性函数类。

给定函数类后，我们想搜索一个好的预测器。现在转入经验风险最小化的第二个要素：如何度量预测器拟合训练数据的好坏。

8.2.2　用于训练的损失函数

考虑某个样本的标签 y_n，以及我们基于 $\boldsymbol{x}_n$ 作出的相应预测 $\hat{y}_n$。要定义“拟合得好”是什么意思，需要指定一个损失函数（loss function）$\ell(y_n, \hat{y}_n)$，它以真实标签和预测为输入，产生一个非负数（称为损失），表示我们在这一次具体预测上犯了多大错误。我们寻找好参数向量 $\boldsymbol{\theta}^*$ 的目标是最小化 N 个训练样本上的平均损失。“误差（error）”一词常被用来指损失。

损失函数

机器学习中一个常见假设是样本集 $(\boldsymbol{x}_1, y_1), \ldots, (\boldsymbol{x}_N, y_N)$ 是独立同分布（independent and identically distributed, i.i.d.）的。“独立”一词（6.4.5 节）意味着两个数据点 $(\boldsymbol{x}_i, y_i)$ 与 $(\boldsymbol{x}_j, y_j)$ 在统计上互不依赖，即经验均值是总体均值的良好估计（6.4.1 节）。这意味

独立同分布

着我们可以使用训练数据上损失的经验均值。对给定的训练集 $\{(\boldsymbol{x}_1, y_1), \ldots, (\boldsymbol{x}_N, y_N)\}$，我们引入样本矩阵 $X := [\boldsymbol{x}_1, \ldots, \boldsymbol{x}_N]^\top \in \mathbb{R}^{N \times D}$ 和标签向量 $\boldsymbol{y} := [y_1, \ldots, y_N]^\top \in \mathbb{R}^N$ 使用这一矩阵记号，平均损失为

训练集

$$R_{\text{emp}}(f, X, \boldsymbol{y}) = \frac{1}{N} \sum_{n=1}^{N} \ell(y_n, \hat{y}_n), \tag{8.6}$$

其中 $\hat{y}_n = f(\boldsymbol{x}_n, \boldsymbol{\theta})$。式 (8.6) 称为经验风险（empirical risk），它依赖三个参数：预测器 f 以及数据 $X, \boldsymbol{y}$。这种一般性的学习策略称为经验风险最小化。

经验风险最小化

例 8.2 (最小二乘损失)**.** 继续最小二乘回归的例子，我们指定用平方损失 $\ell(y_n, \hat{y}_n) = (y_n - \hat{y}_n)^2$ 来度量训练中犯错的代价。我们希望最小化经验风险 (8.6)，即数据上损失的平均

原书 p.261

$$\min_{\boldsymbol{\theta} \in \mathbb{R}^D} \frac{1}{N} \sum_{n=1}^{N} (y_n - f(\boldsymbol{x}_n, \boldsymbol{\theta}))^2, \tag{8.7}$$

其中代入了预测器 $\hat{y}_n = f(\boldsymbol{x}_n, \boldsymbol{\theta})$。使用我们所选的线性预测器 $f(\boldsymbol{x}_n, \boldsymbol{\theta}) = \boldsymbol{\theta}^\top \boldsymbol{x}_n$，得到优化问题

$$\min_{\boldsymbol{\theta} \in \mathbb{R}^D} \frac{1}{N} \sum_{n=1}^{N} (y_n - \boldsymbol{\theta}^\top \boldsymbol{x}_n)^2. \tag{8.8}$$

该方程可等价地写成矩阵形式

$$\min_{\boldsymbol{\theta} \in \mathbb{R}^D} \frac{1}{N} \|\boldsymbol{y} - X\boldsymbol{\theta}\|^2. \tag{8.9}$$

这就是最小二乘问题（least-squares problem）。它有解析闭式解，即求解正规方程，我们将在 9.2 节讨论。

最小二乘问题

我们对一个只在训练数据上表现良好的预测器并不感兴趣；相反，我们寻求一个在未见测试数据上表现良好（风险低）的预测器。更形式化地，我们感兴趣的是找到一个预测器 f（参数固定）使期望风险（expected risk）最小：

期望风险

$$R_{\text{true}}(f) = \mathbb{E}_{x,y}\big[\ell(y, f(x))\big], \tag{8.10}$$

其中 y 是标签，$f(x)$ 是基于样本 x 的预测。记号 $R_{\text{true}}(f)$ 表示：如果我们能获得无穷多数据，这就是真实风险。期望是对所有可能的数据与标签的（无穷）集合取的。期望风险的另一个常用说法是“总体风险（population risk）”。由最小化期望风险的愿望引出两个实际问题，将在以下两小节处理：

- 我们应如何改变训练过程才能泛化得好?
- 如何从（有限）数据估计期望风险?

注。许多机器学习任务都附带一个性能度量，例如预测准确率或均方根误差。性能度量可以更复杂，可以是代价敏感的，并能刻画具体应用的细节。原则上，经验风险最小化的损失函数设计应与机器学习任务指定的性能度量直接对应。实践中，损失函数的设计与性能度量之间常常存在错配，这可能是由于实现容易或优化效率等问题。◇

8.2.3　用正则化缓解过拟合

原书 p.262

本节描述对经验风险最小化的一种补充，使其能泛化良好（近似最小化期望风险）。回忆训练机器学习预测器的目的是让我们在未见数据上表现良好，即预测器泛化良好。

我们通过留出整个数据集的一部分来模拟这种未见数据。这个留出集合称为测试集（test set）。即使仅仅知道预测器在测试集上的性能也会泄漏信息（Blum and Hardt, 2015）。给定预测器 f 足够丰富的函数类，我们原则上可以记住训练数据而得到零经验风险。虽然这在最小化训练数据上的损失（从而风险）方面很好，但我们不期望该预测器能很好地泛化到未见数据。实践中我们只有有限数据，因此把数据划分为训练集和测试集。训练集用于拟合模型，测试集（训练期间不被机器学习算法看到）用于评估泛化性能。重要的是，用户在观察测试集之后不应再回到新一轮训练。我们用下标 train 和 test 分别表示训练集和测试集。我们将在 8.2.4 节回到用有限数据集评估期望风险这一想法。

测试集

事实证明经验风险最小化会导致过拟合（overfitting），即预测器对训练数据拟合得过紧，不能很好地泛化到新数据（Mitchell, 1997）。这种“在训练集上平均损失很小、但在测试集上平均损失很大”的普遍现象，往往发生在数据少而假设类复杂的时候。对某个具体预测器 f（参数固定），当训练数据上的风险估计 $R_{\text{emp}}(f, X_{\text{train}}, \boldsymbol{y}_{\text{train}})$ 低估了期望风险 $R_{\text{true}}(f)$ 时，就出现过拟合。由于我们用测试集上的经验风险 $R_{\text{emp}}(f, X_{\text{test}}, \boldsymbol{y}_{\text{test}})$ 来估计期望风险 $R_{\text{true}}(f)$，若测试风险远大于训练风险，就表明过拟合。我们将在 8.3.3 节回到过拟合。

过拟合

因此，我们需要以某种方式偏向经验风险最小化的搜索，引入一个惩罚项，使优化器更难返回一个过于灵活的预测器。在机器学习中，这个惩罚项称为正则化（regularization）。正则化是在“精确求解经验风险最小化”与“解的大小或复杂度”之间折中。

正则化

例 8.3 (正则化最小二乘)**.** 正则化是一种抑制优化问题的复杂或极端解的方法。最简单的正则化策略是把前例中的最小二乘问题 原书 p.263

$$\min_{\boldsymbol{\theta}} \frac{1}{N}\|\boldsymbol{y} - X\boldsymbol{\theta}\|^2 \tag{8.11}$$

替换为“正则化”问题，加入一个只涉及 $\boldsymbol{\theta}$ 的惩罚项：

$$\min_{\boldsymbol{\theta}} \frac{1}{N}\|\boldsymbol{y} - X\boldsymbol{\theta}\|^2 + \lambda\|\boldsymbol{\theta}\|^2. \tag{8.12}$$

额外项 $\|\boldsymbol{\theta}\|^2$ 称为正则项（regularizer），参数 λ 是正则化参数（regularization parameter）正则化参数在“最小化训练集上的损失”与“参数 $\boldsymbol{\theta}$ 的大小”之间折中。当我们陷入过拟合时，参数值的大小往往会变得相当大（Bishop, 2006）。

正则项
正则化参数

正则项有时也称为惩罚项（penalty term），它把向量 $\boldsymbol{\theta}$ 偏向原点。正则化的思想在概率模型中也表现为参数的先验概率。回忆 6.6 节，要使后验分布与先验分布同形式，先验与似然需要共轭。我们将在 8.3.2 节回到这一思想。在第 12 章将看到，正则项的思想等价于大间隔（large margin）的思想。

惩罚项

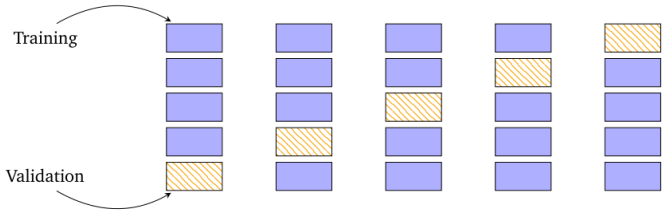
8.2.4　用交叉验证评估泛化性能

上一节提到我们通过把预测器应用于测试数据来估计泛化误差。该数据有时也称为验证集（validation set）。验证集是从可用训练数据中留出的一个子集。这种方法的一个实际问题是数据量有限，而理想上我们希望用尽可能多的数据训练模型。这就要求验证集 V 很小，从而对预测性能的估计噪声很大（方差高）。解决这些相互矛盾的目标（大训练集、大验证集）的一个办法是使用交叉验证（cross-validation）。K 折交叉验证有效地把数据分成 K 块，其中 $K-1$ 块构成训练集 R，最后一块作为验证集 V（类似于前面概述的想法）。交叉验证（理想地）迭代遍历把块分配给 R 和 V 的所有组合；见图 8.4。对验证集的 K 种选择都重复这一流程，并对 K 次运行的模型性能取平均。

验证集

交叉验证

我们把数据集划分为两个不相交的集合 $D = R \cup V$（$R \cap V = \emptyset$），其中 V 是验证集，在 R 上训练模型。训练后，在验证集 V 上评估预测器 f 的性能（例如计算训练好



alidation set $\mathcal{V}$ (e.g., by computing root mean square error (RMSE) of

图 8.4: K 折交叉验证。数据集被分成 $K = 5$ 块，其中 $K - 1$ 块作为训练集（蓝色），一块作为验证集（橙色阴影）。（对应原书 Figure 8.4。）

的模型在验证集上的均方根误差 RMSE）。更精确地，对每个划分 k，训练数据 $R^{(k)}$ 产生预测器 $f^{(k)}$，再把它应用于验证集 $V^{(k)}$ 以计算经验风险 $R(f^{(k)}, V^{(k)})$。我们遍历验证集与训练集的所有可能划分，计算预测器的平均泛化误差。交叉验证近似期望泛化误差

$$\mathbb{E}_V[R(f, V)] \approx \frac{1}{K}\sum_{k=1}^{K} R(f^{(k)}, V^{(k)}), \tag{8.13}$$

其中 $R(f^{(k)}, V^{(k)})$ 是预测器 $f^{(k)}$ 在验证集 $V^{(k)}$ 上的风险（例如 RMSE）。该近似有两个来源：第一，由于训练集有限，得到的不是最佳的 $f^{(k)}$；第二，由于验证集有限，对风险 $R(f^{(k)}, V^{(k)})$ 的估计不准确。K 折交叉验证的一个潜在缺点是训练模型 K 次的计算代价，当训练代价在计算上很昂贵时会很繁重。实践中，只看直接参数往往不够。例如我们需要探索多个复杂度参数（例如多个正则化参数），它们可能不是模型的直接参数。评估模型质量（依赖于这些超参数）可能导致训练运行次数关于模型参数个数指数增长。可以使用嵌套交叉验证（8.6.1 节）来搜索好的超参数。

不过，交叉验证是一个易并行（embarrassingly parallel）问题，即几乎不需要费力就能把问题拆成若干并行任务。给定足够的计算资源（例如云计算、服务器集群），交叉验证所需时间不比单次性能评估更长。

易并行

本节中我们看到经验风险最小化基于以下概念：函数的假设类、损失函数和正则化。在 8.3 节，我们将看到用概率分布取代损失函数和正则化思想的效果。

原书 p.264

8.2.5　拓展阅读

原书 p.265

由于经验风险最小化（Vapnik, 1998）最初的发展包裹在高度理论化的语言中，后来的许多发展都是理论性的。这一研究领域称为统计学习理论（statistical learning theory）。（Vapnik, 1999; Evgeniou et al., 2000; Hastie et al., 2001; von Luxburg and Schölkopf, 2011）一本在理论基础上发展高效学习算法的近期机器学习教材是 Shalev-Shwartz and Ben-David (2014)。

统计学习理论

正则化的概念根源于不适定逆问题的求解（Neumaier, 1998）。这里介绍的方法称为 Tikhonov 正则化（Tikhonov regularization），还有一个密切相关的受约束版本称为 Ivanov 正则化。Tikhonov 正则化与偏差–方差折中、特征选择有深刻联系（Bühlmann and Van De Geer, 2011）。交叉验证的替代方法是 bootstrap 和 jackknife（Efron and Tibshirani, 1993; Davidson and Hinkley, 1997; Hall, 1992）。

Tikhonov 正则化

把经验风险最小化（8.2 节）看作“无概率”是不正确的。底层有一个未知概率分布 $p(x, y)$ 支配着数据生成。然而，经验风险最小化的方法对该分布的选择是不可知的。这与显式要求知道 $p(x, y)$ 的标准统计方法形成对比。此外，由于该分布是样本 x 和标

签 y 的联合分布，标签可以是非确定性的。与标准统计不同，我们不需要为标签 y 指定噪声分布。

8.3　参数估计

在 8.2 节中，我们没有用概率分布显式地对问题建模。本节将看到如何用概率分布来建模因观测过程而产生的不确定性，以及我们对预测器参数的不确定性。在 8.3.1 节，我们引入似然（likelihood），它类似于经验风险最小化中损失函数（8.2.2 节）的概念。先验（prior）的概念（8.3.2 节）则类似于正则化（8.2.3 节）的概念。

8.3.1　最大似然估计

原书 p.266

最大似然估计（maximum likelihood estimation, MLE）背后的思想是：定义一个关于参数的函数，使我们能找到一个很好拟合数据的模型。估计问题聚焦于似然函数（likelihood），或更确切地说是它的负对数。对由随机变量 x 表示的数据、以及一族由 $\boldsymbol{\theta}$ 参数化的概率密度 $p(x \mid \boldsymbol{\theta})$，负对数似然（negative log-likelihood）为

最大似然估计
似然
负对数似然

$$L_x(\boldsymbol{\theta}) = -\log p(x \mid \boldsymbol{\theta}). \tag{8.14}$$

记号 $L_x(\boldsymbol{\theta})$ 强调参数 $\boldsymbol{\theta}$ 在变化而数据 x 固定。我们写负对数似然时常略去对 x 的引用，因为它实际上是 $\boldsymbol{\theta}$ 的函数；当表示数据中不确定性的随机变量从上下文清楚可知时，就写成 $L(\boldsymbol{\theta})$。

让我们解释：对固定的 $\boldsymbol{\theta}$，概率密度 $p(x \mid \boldsymbol{\theta})$ 在建模什么。它是一个在给定参数设置下对数据不确定性建模的分布。对给定数据集 x，似然使我们能表达对参数 $\boldsymbol{\theta}$ 不同设置的偏好，我们可以选择那个更“可能”生成该数据的设置。

从互补的观点看：如果我们把数据看作固定（因为已被观测到），而改变参数 $\boldsymbol{\theta}$，那么 $L(\boldsymbol{\theta})$ 告诉我们什么？它告诉我们：对观测 x 而言，$\boldsymbol{\theta}$ 的某个具体设置有多可能。基于这第二种观点，最大似然估计给出对该数据集而言最可能的参数 $\boldsymbol{\theta}$。

我们考虑监督学习情形，得到对 $(\boldsymbol{x}_1, y_1), \ldots, (\boldsymbol{x}_N, y_N)$，其中 $\boldsymbol{x}_n \in \mathbb{R}^D$，标签 $y_n \in \mathbb{R}$。我们希望构造一个以特征向量 $\boldsymbol{x}_n$ 为输入、产生预测 y_n（或接近它的东西）的预测器；即给定向量 $\boldsymbol{x}_n$，我们想要标签 y_n 的概率分布。换言之，对具体的参数设置 $\boldsymbol{\theta}$，我们指定给定样本时标签的条件概率分布。

例 8.4. 第一个常用例子是指定给定样本时标签的条件概率为高斯分布。换言之，我们假设能用零均值独立高斯噪声（见 6.5 节）解释观测不确定性，$\varepsilon_n \sim \mathcal{N}(0, \sigma^2)$。进一步假设使用线性模型 $\boldsymbol{x}_n^\top \boldsymbol{\theta}$ 做预测。这意味着我们为每个样本–标签对 $(\boldsymbol{x}_n, y_n)$ 指定一个高斯似然：

$$p(y_n \mid \boldsymbol{x}_n, \boldsymbol{\theta}) = \mathcal{N}\big(y_n \mid \boldsymbol{x}_n^\top \boldsymbol{\theta}, \sigma^2\big). \tag{8.15}$$

给定参数 $\boldsymbol{\theta}$ 下高斯似然的示意图见图 8.3。我们将在 9.2 节看到如何按高斯分布显式展开上式。

我们假设样本集 $(\boldsymbol{x}_1, y_1), \ldots, (\boldsymbol{x}_N, y_N)$ 是独立同分布（i.i.d.）的。“独立”（6.4.5 节）意味着涉及整个数据集（$Y = \{y_1, \ldots, y_N\}$，$X = \{\boldsymbol{x}_1, \ldots, \boldsymbol{x}_N\}$）的似然可分解为每个样本似然的乘积：

独立同分布

$$p(Y \mid X, \boldsymbol{\theta}) = \prod_{n=1}^{N} p(y_n \mid \boldsymbol{x}_n, \boldsymbol{\theta}), \tag{8.16}$$

其中 $p(y_n \mid \boldsymbol{x}_n, \boldsymbol{\theta})$ 是某个具体分布（在例 8.4 中是高斯）。“同分布”意味着乘积 (8.16) 中每一项都是同一分布，且共享相同参数。从优化角度看，计算可分解为简单函数之和的函数往往更容易。因此，在机器学习中我们常考虑负对数似然（回忆 $\log(ab) = \log a + \log b$）

$$L(\boldsymbol{\theta}) = -\log p(Y \mid X, \boldsymbol{\theta}) = -\sum_{n=1}^{N} \log p(y_n \mid \boldsymbol{x}_n, \boldsymbol{\theta}). \tag{8.17}$$

虽然很容易把 $\boldsymbol{\theta}$ 在条件竖线右侧这一事实解释为 $\boldsymbol{\theta}$ 被观测且固定，但这种解释是错误的。负对数似然 $L(\boldsymbol{\theta})$ 是 $\boldsymbol{\theta}$ 的函数。因此，要找到一个好地解释数据 $(\boldsymbol{x}_1, y_1), \ldots, (\boldsymbol{x}_N, y_N)$ 的参数向量 $\boldsymbol{\theta}$，就关于 $\boldsymbol{\theta}$ 最小化负对数似然 $L(\boldsymbol{\theta})$。

注。(8.17) 中的负号是历史遗留：由于我们要最大化似然，而数值优化文献倾向于研究函数的最小化。◇

例 8.5. 继续高斯似然 (8.15) 的例子，负对数似然可重写为

$$L(\boldsymbol{\theta}) = -\sum_{n=1}^{N} \log p(y_n \mid \boldsymbol{x}_n, \boldsymbol{\theta}) = -\sum_{n=1}^{N} \log \mathcal{N}\big(y_n \mid \boldsymbol{x}_n^\top \boldsymbol{\theta}, \sigma^2\big) \tag{8.18a}$$

$$= -\sum_{n=1}^{N} \log \left[\frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_n - \boldsymbol{x}_n^\top \boldsymbol{\theta})^2}{2\sigma^2} \right) \right] \tag{8.18b}$$

$$= -\sum_{n=1}^{N} \log \exp\left(-\frac{(y_n - \boldsymbol{x}_n^\top \boldsymbol{\theta})^2}{2\sigma^2} \right) - \sum_{n=1}^{N} \log \frac{1}{\sqrt{2\pi\sigma^2}} \tag{8.18c}$$

$$= \frac{1}{2\sigma^2} \sum_{n=1}^{N} (y_n - \boldsymbol{x}_n^\top \boldsymbol{\theta})^2 - \sum_{n=1}^{N} \log \frac{1}{\sqrt{2\pi\sigma^2}}. \tag{8.18d}$$

由于 σ 给定，(8.18d) 中第二项是常数，最小化 $L(\boldsymbol{\theta})$ 对应于求解第一项所表达的最小二乘问题（与 (8.8) 比较）。

事实证明，对高斯似然而言，最大似然估计所对应的优化问题有闭式解。更多细节将在第 9 章看到。图 8.5 示出一个回归数据集以及由最大似然参数诱导出的函数。最大似然估计可能遭受过拟合（8.3.3 节），类似于未正则化的经验风险最小化（8.2.3 节）。对于其他似然函数，即如果我们用非高斯分布建模噪声，最大似然估计可能没有解析闭式解。这时我们求助于第 7 章讨论的数值优化方法。

原书 p.268

8.3.2　最大后验估计

原书 p.269

如果我们对参数 $\boldsymbol{\theta}$ 的分布有先验知识，可以在似然上乘一个额外项。这个额外项是参数上的先验概率分布 $p(\boldsymbol{\theta})$。对给定先验，在观测到一些数据 x 之后，我们应如何更新 $\boldsymbol{\theta}$ 的分布？换言之，在观测数据 x 之后，我们应如何表达“对 $\boldsymbol{\theta}$ 有了更具体的知识”这一事实？如 6.3 节讨论的贝叶斯定理，给我们一个更新随机变量概率分布的有原则工具。它使我们能从一般的先验陈述（先验分布）$p(\boldsymbol{\theta})$ 和联系参数 $\boldsymbol{\theta}$ 与观测数据 x 的函数 $p(x \mid \boldsymbol{\theta})$（称为似然），计算出参数 $\boldsymbol{\theta}$ 上的后验分布（posterior）$p(\boldsymbol{\theta} \mid x)$：

$$p(\boldsymbol{\theta} \mid x) = \frac{p(x \mid \boldsymbol{\theta})\, p(\boldsymbol{\theta})}{p(x)}. \tag{8.19}$$

回忆我们感兴趣的是最大化后验的参数 $\boldsymbol{\theta}$。由于分布 $p(x)$ 不依赖 $\boldsymbol{\theta}$，优化时可忽略分母的值，得到

$$p(\boldsymbol{\theta} \mid x) \propto p(x \mid \boldsymbol{\theta})\, p(\boldsymbol{\theta}). \tag{8.20}$$

上面的正比关系隐藏了数据密度 $p(x)$，它可能难以估计。现在我们不是估计负对数似然的最小值，而是估计负对数后验的最小值，这称为最大后验估计（maximum a posteriori estimation, MAP）。加入零均值高斯先验的效果示意图见图 8.6。

最大后验估计

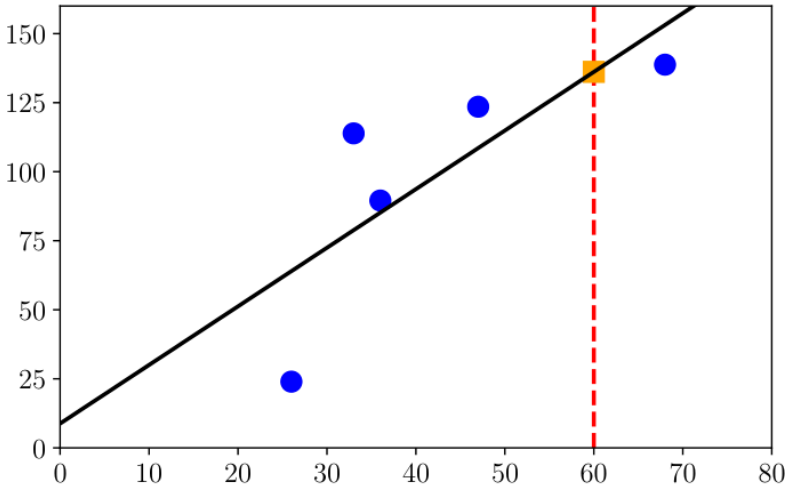


图 8.5: 对给定数据，参数的最大似然估计结果为黑色对角线。橙色方块示出在 $x = 60$ 处的最大似然预测值。（对应原书 Figure 8.5。）

例 8.6. 在上例高斯似然假设之外，我们进一步假设参数向量服从零均值多元高斯，即 $p(\boldsymbol{\theta}) = \mathcal{N}(\mathbf{0}, \Sigma)$，其中 Σ 是协方差矩阵（6.5 节）。注意高斯的共轭先验仍是高斯（6.6.1 节），因此我们期望后验分布也是高斯。最大后验估计的细节将在第 9 章看到。

包含“好参数位于何处”的先验知识这一思想在机器学习中很普遍。我们在 8.2.3 节看到的另一种观点是正则化思想，它引入一个额外项，把所得参数偏向接近原点。最大后验估计可被看作沟通非概率世界与概率世界的桥梁：它显式承认需要先验分布，但仍然只产生参数的点估计。

注。最大似然估计 $\boldsymbol{\theta}_{\text{ML}}$ 具有以下性质（Lehmann and Casella, 1998; Efron and Hastie, 2016）：

- 渐近一致性：在无穷多观测的极限下，MLE 收敛到真值，加上一个近似正态的随机误差。达到这些性质所需的样本量可能相当大。
- 误差的方差按 $1/N$ 衰减，其中 N 是数据点数。
- 尤其在“小”数据情形下，最大似然估计可能导致过拟合。

◇

最大似然估计（以及最大后验估计）原理用概率建模来对数据和模型参数中的不确定性进行推理。然而我们还没有把概率建模用到极致。本节中，所得训练过程仍然产生预测器的点估计，即训练返回一组代表最佳预测器的参数值。在 8.4 节，我们将采取参数值也应被当作随机变量这一观点，并且在做预测时不估计该分布的“最佳”值，而是使用完整的参数分布。

8.3.3　模型拟合

考虑这样的设定：给定一个数据集，我们想把一个参数化模型拟合到数据上。谈到“拟合”时，我们通常指优化/学习模型参数，使它们最小化某个损失函数，例如负对数似然。借助最大似然（8.3.1 节）和最大后验估计（8.3.2 节），我们已经讨论了两种常用的模型拟合算法。

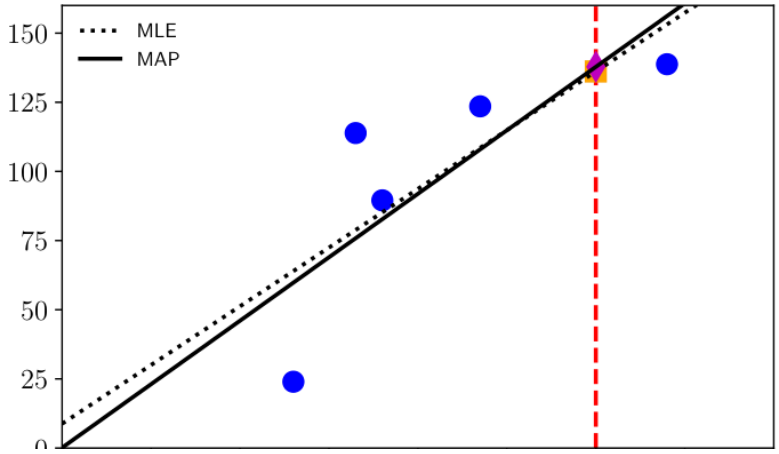


图 8.6: 在 $x = 60$ 处比较最大似然估计与 MAP 估计的预测。先验把斜率偏向更平缓、截距偏向更接近零。本例中，把截距拉向零的偏置实际上增大了斜率。（对应原书 Figure 8.6。）

模型的参数化定义了一个模型类 $\mathcal{M}_{\boldsymbol{\theta}}$，我们在其中操作。例如在线性回归设定中，我们可以把输入 x 与（无噪）观测 y 之间的关系定义为 $y = ax + b$，其中 $\boldsymbol{\theta} := \{a, b\}$ 是模型参数。此时模型参数 $\boldsymbol{\theta}$ 描述仿射函数族，即斜率为 a、相对 0 偏移 b 的直线。假设数据来自一个我们未知的模型 $\mathcal{M}^*$。对给定训练数据集，我们优化 $\boldsymbol{\theta}$ 使 $\mathcal{M}_{\boldsymbol{\theta}}$ 尽可能接近 $\mathcal{M}^*$，其中“接近”由我们优化的目标函数定义（例如训练数据上的平方损失）。图 8.7 示出这样一种设定：我们有一个小的模型类（以圆 $\mathcal{M}_{\boldsymbol{\theta}}$ 表示），而数据生成模型 $\mathcal{M}^*$ 位于所考虑模型集合之外。我们从 $\mathcal{M}_{\boldsymbol{\theta}_0}$ 开始参数搜索。优化之后，即得到最佳可能参数 $\boldsymbol{\theta}^*$ 时，我们区分三种情况：(i) 过拟合、(ii) 欠拟合、(iii) 拟合良好。下面给出这三个概念的高层直觉。

原书 p.271

过拟合

粗略地说，过拟合（overfitting）指参数化模型类过于丰富，以至于能建模由 $\mathcal{M}^*$ 生成的数据集，即 $\mathcal{M}_{\boldsymbol{\theta}}$ 可以建模复杂得多的数据集。例如，如果数据集由线性函数生成而我们把 $\mathcal{M}_{\boldsymbol{\theta}}$ 定义为七次多项式类，那么我们不仅能建模线性函数，还能建模二次、三次等多项式。过拟合的模型通常参数很多。我们常观察到：过于灵活的模型类 $\mathcal{M}_{\boldsymbol{\theta}}$ 用它全部的建模能力去降低训练误差。如果训练数据含噪，它就会在噪声本身中找到一些有用信号。当我们在远离训练数据的地方预测时，这会造成巨大问题。图 8.8(a) 给出回归情境下过拟合的例子，其中模型参数通过最大似然学习（见 8.3.1 节）。回归中的过拟合将在 9.2.2 节进一步讨论。实践中检测过拟合的一个办法是在交叉验证（8.2.4 节）中观察模型训练风险低但测试风险高。

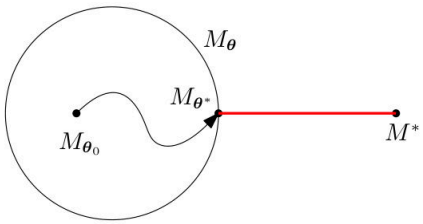
欠拟合

当我们遇到欠拟合（underfitting）时，遇到相反的问题：模型类 $\mathcal{M}_{\boldsymbol{\theta}}$ 不够丰富。例如，如果数据集由正弦函数生成，但 $\boldsymbol{\theta}$ 只参数化直线，那么最好的优化过程也不会让我们接近真实模型。不过我们仍然优化参数，找到建模该数据集的最佳直线。图 8.8(b) 示出一个因不够灵活而欠拟合的模型。欠拟合的模型通常参数很少。

原书 p.272

第三种情况是参数化模型类刚好合适。这时我们的模型拟合良好，即既不过拟合也不欠拟合。这意味着我们的模型类刚好足够丰富，能描述所给数据集。图 8.8(c) 示出一个很好拟合给定数据集的模型。理想情况下，这是我们希望使用的模型类，因为它具有良好的泛化性质。

实践中，我们常定义参数很多的非常丰富的模型类 $\mathcal{M}_{\boldsymbol{\theta}}$，例如深度神经网络。为缓



ıfinitely many observations, plus a random error that is a

图 8.7: 模型拟合。在参数化模型类 $\mathcal{M}_{\boldsymbol{\theta}}$ 中，我们优化模型参数 $\boldsymbol{\theta}$，使到真实（未知）模型 $\mathcal{M}^*$ 的距离最小。（对应原书 Figure 8.7。）

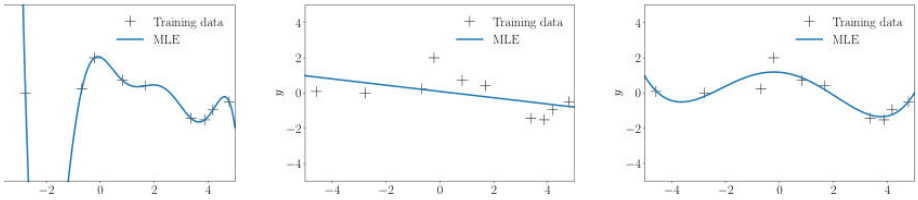


图 8.8: （用最大似然）把不同模型类拟合到一个回归数据集。(a) 过拟合；(b) 欠拟合；(c) 拟合良好。（对应原书 Figure 8.8。）

解过拟合问题，我们可以使用正则化（8.2.3 节）或先验（8.3.2 节）。如何选择模型类将在 8.6 节讨论。

8.3.4　拓展阅读

考虑概率模型时，最大似然估计原理推广了线性模型最小二乘回归的思想，第 9 章将详细讨论。当把预测器限制为线性形式、并在输出上施加额外非线性函数 ϕ 时，即

$$p(y_n \mid \boldsymbol{x}_n, \boldsymbol{\theta}) = \phi(\boldsymbol{\theta}^\top \boldsymbol{x}_n), \tag{8.21}$$

我们可以为其他预测任务考虑其他模型，例如二分类或计数数据建模（McCullagh and Nelder, 1989）。另一种观点是考虑来自指数族（6.6 节）的似然。这类模型在参数与数据之间有线性依赖、并可能有非线性变换 ϕ（称为链接函数 link function），称为广义线性模型（generalized linear model）。（Agresti, 2002, 第 4 章）。

链接函数
广义线性模型

最大似然估计历史悠久，最初由 Ronald Fisher 爵士在 20 世纪 30 年代提出。我们将在 8.4 节展开概率模型的思想。使用概率模型的研究者之间有一场争论：贝叶斯统计与频率派统计之争。如 6.1.1 节所述，它归结为概率的定义。回忆 6.1 节，我们可以把概率看作逻辑推理的推广（允许不确定性）（Cheeseman, 1985; Jaynes, 2003）。最大似然估计方法本质上是频率派的；对贝叶斯与频率派统计 balanced 的观点，感兴趣的读者可参阅 Efron and Hastie (2016)。

有些概率模型中最大似然估计可能无法进行。关于矩估计、M 估计、估计方程等方法，读者可参阅更高级的统计教材，例如 Casella and Berger (2002)。

8.4　概率建模与推断

在机器学习中，我们经常关注数据的解释与分析，例如预测未来事件和做决策。为使这一任务更可处理，我们常构建描述生成观测数据之生成过程（generative process）的

模型。例如，我们可以分两步描述抛硬币实验（“正面”或“反面”）的结果。第一步定义一个参数 μ，它描述“正面”的概率，作为伯努利分布（第 6 章）的参数；第二步，我们可以从伯努利分布 $p(x \mid \mu) = \text{Ber}(\mu)$ 中采样一个结果 $x \in \{\text{head}, \text{tail}\}$。参数 μ 产生一个具体数据集 X，并取决于所用的硬币。由于 μ 事先未知且永远无法直接观测，我们需要在给定抛硬币实验观测结果的情况下了解 μ 的机制。下面我们讨论如何用概率建模来做到这一点。

生成过程

8.4.1　概率模型

概率模型把实验中不确定的方面表示为概率分布。使用概率模型的好处是：它们提供了一套来自概率论（第 6 章）的统一而一致的工具，用于建模、推断、预测和模型选择。概率模型由所有随机变量的联合分布指定。

在概率建模中，观测变量 $\boldsymbol{x}$ 与隐参数 $\boldsymbol{\theta}$ 的联合分布 $p(\boldsymbol{x}, \boldsymbol{\theta})$ 处于核心地位：它封装了以下信息：

- 先验与似然（乘法法则，6.3 节）。
- 边际似然 $p(\boldsymbol{x})$，它在模型选择（8.6 节）中起重要作用，可由联合分布对参数积分（求和法则，6.3 节）得到。
- 后验，可由联合除以边际似然得到。

只有联合分布具有这一性质。因此，一个概率模型由其所有随机变量的联合分布指定。

8.4.2　贝叶斯推断

参数估计可被表述为一个优化问题。机器学习中的一个关键任务是：给定模型和数据，在观测变量 $\boldsymbol{x}$ 下揭示模型隐变量 $\boldsymbol{\theta}$ 的值。在 8.3.1 节，我们已经讨论了用最大似然或最大后验估计来估计模型参数 $\boldsymbol{\theta}$ 的两种方式。在这两种情况下，我们都得到 $\boldsymbol{\theta}$ 的单一最佳值，因此参数估计这一关键算法问题就是求解一个优化问题。一旦知道这些点估计 $\boldsymbol{\theta}^*$，我们就用它们做预测。更具体地，预测分布将是 $p(x \mid \boldsymbol{\theta}^*)$，其中在似然函数中使用 $\boldsymbol{\theta}^*$。

原书 p.274

如 6.3 节讨论的，仅仅关注后验分布的某个统计量（例如最大化后验的参数 $\boldsymbol{\theta}^*$）会丢失信息，这在使用预测 $p(x \mid \boldsymbol{\theta}^*)$ 做决策的系统中可能是关键的。这些决策系统的目标函数通常与似然、平方误差损失或误分类误差不同。因此，拥有完整的后验分布会非常有用，并带来更稳健的决策。贝叶斯推断（Bayesian inference）就是关于寻找这个后验分布。（Gelman et al., 2004）对数据集 X、参数先验 $p(\boldsymbol{\theta})$ 和似然函数，后验

贝叶斯推断

$$p(\boldsymbol{\theta} \mid X) = \frac{p(X \mid \boldsymbol{\theta})\, p(\boldsymbol{\theta})}{p(X)}, \qquad p(X) = \int p(X \mid \boldsymbol{\theta})\, p(\boldsymbol{\theta})\, \mathrm{d}\boldsymbol{\theta}, \tag{8.22}$$

由应用贝叶斯定理得到。其关键思想是利用贝叶斯定理反转参数 $\boldsymbol{\theta}$ 与数据 X 之间（由似然给出）的关系，以获得后验分布 $p(\boldsymbol{\theta} \mid X)$。贝叶斯推断反转参数与数据之间的关系。

在参数上有后验分布的含义是：它可以用来把不确定性从参数传播到数据。更具体地，参数上有分布 $p(\boldsymbol{\theta})$ 时，我们的预测为

$$p(x) = \int p(x \mid \boldsymbol{\theta})\, p(\boldsymbol{\theta})\, \mathrm{d}\boldsymbol{\theta} = \mathbb{E}_{\boldsymbol{\theta}}[p(x \mid \boldsymbol{\theta})], \tag{8.23}$$

它们不再依赖已被边际化/积出的模型参数 $\boldsymbol{\theta}$。式 (8.23) 表明，预测是对所有似是而非的参数值 $\boldsymbol{\theta}$ 的平均，其中似是而非性由参数分布 $p(\boldsymbol{\theta})$ 封装。

讨论了 8.3 节的参数估计和这里的贝叶斯推断之后，让我们比较这两种学习途径。通过最大似然或 MAP 估计的参数估计得到参数的一个一致点估计 $\boldsymbol{\theta}^*$，要解决的关键计算问题是优化。相反，贝叶斯推断得到一个（后验）分布，要解决的关键计算问题是积分。用点估计做预测很直接，而贝叶斯框架下的预测需要再解一个积分问题；见 (8.23)。然而，贝叶斯推断给我们一种有原则的方式来纳入先验知识、考虑侧边信息并纳入结构知识，这些在参数估计的语境中都不容易做到。此外，在数据高效学习的语境下，参数不确定性向预测的传播在风险评估和探索方面对决策系统很有价值（Deisenroth et al., 2015; Kamthe and Deisenroth, 2018）。

原书 p.275

虽然贝叶斯推断是一个在数学上有原则的学习参数和做预测的框架，但由于需要求解的积分问题（见 (8.22) 和 (8.23)），它带来一些实际挑战。更具体地，如果我们不在参数上选择共轭先验（6.6.1 节），(8.22) 和 (8.23) 中的积分就不是解析可处理的，我们无法以闭式计算后验、预测或边际似然。在这些情况下，我们求助于近似。这里可以使用随机近似，例如马尔可夫链蒙特卡洛（MCMC）（Gilks et al., 1996）；或确定性近似，例如拉普拉斯近似（Bishop, 2006; Barber, 2012; Murphy, 2012）、变分推断（Jordan et al., 1999; Blei et al., 2017）或期望传播（Minka, 2001a）。

尽管有这些挑战，贝叶斯推断已成功应用于各种问题，包括大规模主题建模（Hoffman et al., 2013）、点击率预测（Graepel et al., 2010）、控制系统中数据高效的强化学习（Deisenroth et al., 2015）、在线排序系统（Herbrich et al., 2007）和大规模推荐系统。还有一些通用工具，例如贝叶斯优化（Brochu et al., 2009; Snoek et al., 2012; Shahriari et al., 2016），它们是高效搜索模型或算法元参数的非常有用的成分。

注。在机器学习文献中，（随机）“变量”与“参数”之间的划分有些任意。参数被估计（例如通过最大似然），而变量通常被边际化掉。本书对这种划分不那么严格，因为原则上我们可以在任何参数上放置先验并把它积出，按上述划分这就把参数变成了随机变量。◇

8.4.3　隐变量模型

实践中，在模型中加入额外的隐变量 z（除模型参数 $\boldsymbol{\theta}$ 之外）有时很有用（Moustaki et al., 2015）。这些隐变量与模型参数 $\boldsymbol{\theta}$ 不同，因为它们不显式地参数化模型。隐变量可以描述数据生成过程，从而有助于模型的可解释性。它们还常简化模型结构，使我们能定义更简单、更丰富的模型结构。模型结构的简化往往伴随着模型参数数量的减少（Paquet, 2008; Murphy, 2012）。隐变量模型中的学习（至少通过最大似然）可以用期望最大化（EM）算法有原则地完成（Dempster et al., 1977; Bishop, 2006）。这类隐变量有用的例子包括：用于降维的主成分分析（第 10 章）、用于密度估计的高斯混合模型（第 11 章）、用于时间序列建模的隐马尔可夫模型（Maybeck, 1979）或动力系统（Ghahramani and Roweis, 1999; Ljung, 1999），以及元学习与任务泛化（Hausman et al., 2018; Säemundsson et al., 2018）。虽然引入这些隐变量可能使模型结构和生成过程更简单，但隐变量模型中的学习通常很难，我们将在第 11 章看到。

隐变量

原书 p.276

由于隐变量模型还允许我们定义由参数生成数据的过程，让我们看一下这个生成过程。记数据为 x、模型参数为 $\boldsymbol{\theta}$、隐变量为 z，我们得到条件分布

$$p(x \mid z, \boldsymbol{\theta}) \tag{8.24}$$

它允许我们为任意模型参数和隐变量生成数据。由于 z 是隐变量，我们在其上放置先验 $p(z)$。

与前面讨论的模型一样，带隐变量的模型可在 8.3 节和 8.4.2 节讨论的框架内用于参数学习和推断。为便于学习（例如通过最大似然估计或贝叶斯推断），我们遵循两步

流程。第一步，计算模型的似然 $p(x \mid \boldsymbol{\theta})$，它不依赖于隐变量。第二步，把该似然用于参数估计或贝叶斯推断，其中使用与 8.3 节和 8.4.2 节完全相同的表达式。

由于似然函数 $p(x \mid \boldsymbol{\theta})$ 是给定模型参数下数据的预测分布，我们需要把隐变量边际化掉，使得

$$p(x \mid \boldsymbol{\theta}) = \int p(x \mid z, \boldsymbol{\theta})\, p(z)\, \mathrm{d}z, \tag{8.25}$$

其中 $p(x \mid z, \boldsymbol{\theta})$ 由 (8.24) 给出，$p(z)$ 是隐变量上的先验。注意似然必须不依赖于隐变量 z，而只是数据 x 和模型参数 $\boldsymbol{\theta}$ 的函数。似然是数据和模型参数的函数，但独立于隐变量。

(8.25) 中的似然直接允许通过最大似然做参数估计。如 8.3.2 节讨论的，在模型参数 $\boldsymbol{\theta}$ 上再加一个先验，MAP 估计也很直接。此外，有了似然 (8.25)，隐变量模型中的贝叶斯推断（8.4.2 节）照常进行：我们在模型参数上放置先验 $p(\boldsymbol{\theta})$，用贝叶斯定理得到给定数据集 X 下模型参数上的后验分布

$$p(\boldsymbol{\theta} \mid X) = \frac{p(X \mid \boldsymbol{\theta})\, p(\boldsymbol{\theta})}{p(X)}. \tag{8.26}$$

(8.26) 中的后验可在贝叶斯推断框架内用于预测；见 (8.23)。

这个隐变量模型的一个挑战是：似然 $p(X \mid \boldsymbol{\theta})$ 需要按 (8.25) 对隐变量做边际化。除非我们为 $p(x \mid z, \boldsymbol{\theta})$ 选择共轭先验 $p(z)$，(8.25) 中的边际化就不是解析可处理的，我们需要求助于近似（Bishop, 2006; Paquet, 2008; Murphy, 2012; Moustaki et al., 2015）。

原书 p.277

与参数后验 (8.26) 类似，我们可以按

$$p(z \mid X) = \frac{p(X \mid z)\, p(z)}{p(X)}, \qquad p(X \mid z) = \int p(X \mid z, \boldsymbol{\theta})\, p(\boldsymbol{\theta})\, \mathrm{d}\boldsymbol{\theta}, \tag{8.27}$$

计算隐变量上的后验，其中 $p(z)$ 是隐变量上的先验，$p(X \mid z)$ 要求我们把模型参数 $\boldsymbol{\theta}$ 积出。

鉴于解析求解积分的困难，很清楚同时把隐变量和模型参数都边际化掉一般是不可能的（Bishop, 2006; Murphy, 2012）。一个更容易计算的量是隐变量上的后验分布，但以模型参数为条件，即

$$p(z \mid X, \boldsymbol{\theta}) = \frac{p(X \mid z, \boldsymbol{\theta})\, p(z)}{p(X \mid \boldsymbol{\theta})}, \tag{8.28}$$

其中 $p(z)$ 是隐变量上的先验，$p(X \mid z, \boldsymbol{\theta})$ 由 (8.24) 给出。

在第 10 章和第 11 章，我们分别推导 PCA 和高斯混合模型的似然函数。此外，我们为 PCA 和高斯混合模型都计算隐变量上的后验分布 (8.28)。

注。在后面几章中，我们可能不在隐变量 z 与不确定模型参数 $\boldsymbol{\theta}$ 之间作如此清晰的区分，而把模型参数也称为“隐”或“隐藏”的，因为它们未被观测。在使用隐变量 z 的第 10 章和第 11 章，我们会注意这一区别，因为那里有两种不同类型的隐藏变量：模型参数 $\boldsymbol{\theta}$ 和隐变量 z。$\diamond$

我们可以利用“概率模型的所有元素都是随机变量”这一事实，定义一种统一的语言来表示它们。在 8.5 节，我们将看到一种表示概率模型结构的简洁图形语言。我们将在后续章节使用这种图形语言来描述概率模型。

8.4.4　拓展阅读

原书 p.278

机器学习中的概率模型（Bishop, 2006; Barber, 2012; Murphy, 2012）为用户以有原则的方式捕捉关于数据和预测模型的不确定性提供了一条途径。Ghahramani (2015) 给出了机器学习中概率模型的简短综述。给定一个概率模型，我们可能很幸运地能解析地

计算感兴趣的参数。但一般而言解析解很罕见，于是使用采样（Gilks et al., 1996; Brooks et al., 2011）和变分推断（Jordan et al., 1999; Blei et al., 2017）等计算方法。Moustaki et al. (2015) 和 Paquet (2008) 很好地综述了隐变量模型中的贝叶斯推断。

近年来，人们提出了若干编程语言，旨在把软件中定义的变量当作对应概率分布的随机变量来处理。其目标是能够编写概率分布的复杂函数，而在底层由编译器自动处理贝叶斯推断的规则。这个快速变化的领域称为概率编程（probabilistic programming）。

概率编程

8.5　有向图模型

本节介绍一种用于指定概率模型的图形语言，称为有向图模型（directed graphical model）。它提供了一种紧凑而简洁的方式来指定概率模型，并使读者能直观地解析随机变量之间的依赖。图模型直观地刻画了所有随机变量上的联合分布如何能分解为仅依赖这些变量子集的因子之乘积。在 8.4 节，我们把概率模型的联合分布识别为关键量，因为它包含了先验、似然和后验的信息。然而联合分布本身可能相当复杂，且它没有告诉我们关于概率模型结构性质的任何信息。例如联合分布 $p(a, b, c)$ 没有告诉我们任何独立性关系。这正是图模型发挥作用之处。本节依赖 6.4.5 节所述的独立性和条件独立性概念。有向图模型也称为贝叶斯网络（Bayesian networks）。

有向图模型

在图模型中，节点是随机变量。在图 8.9(a) 中，节点表示随机变量 a, b, c。边表示变量之间的概率关系，例如条件概率。

图模型

注。并非每个分布都能在某种图模型选择中表示出来。对此的讨论见 Bishop (2006)。
◇

概率图模型有一些方便的性质：

- 它们是可视化概率模型结构的简单方式。
- 它们可用于设计或启发新型统计模型。
- 仅观察图就能让我们洞察性质，例如条件独立性。
- 统计模型中推断和学习的复杂计算可用图上的操作来表达。

8.5.1　图语义

有向图模型/贝叶斯网络是一种表示概率模型中条件依赖的方法。它们提供了条件概率的可视化描述，从而为描述复杂相互依赖提供了一种简单语言。这种模块化描述还带来计算上的简化。两个节点（随机变量）之间的有向链接（箭头）表示条件概率。例如，图 8.9(a) 中 a 与 b 之间的箭头给出给定 a 时 b 的条件概率 $p(b \mid a)$。在额外假设下，箭头可用来表示因果关系（Pearl, 2009）。

贝叶斯网络

如果我们知道联合分布的某种分解，就可以从联合分布导出有向图模型。

例 8.7. 考虑三个随机变量 a, b, c 的联合分布

$$p(a, b, c) = p(c \mid a, b)\, p(b \mid a)\, p(a) \tag{8.29}$$

(8.29) 中联合分布的分解告诉我们关于随机变量之间关系的一些信息：

- c 直接依赖于 a 和 b。
- b 直接依赖于 a。
- a 既不依赖于 b 也不依赖于 c。

对 (8.29) 中的分解，我们得到图 8.9(a) 的有向图模型。

一般地，我们可以从一个分解的联合分布构造相应的有向图模型：

1. 为所有随机变量创建一个节点。
2. 对每个条件分布，从该分布所条件于的变量对应的节点向图中加一条有向链接（箭头）。

图的布局取决于联合分布分解方式的选择。

原书 p.280

我们讨论了如何从已知的联合分布分解得到相应的有向图模型。现在做完全相反的事：描述如何从给定图模型提取一组随机变量的联合分布。

例 8.8. 观察图 8.9(b) 中的图模型，我们利用两条性质：

- 我们所求的联合分布 $p(x_1, \ldots, x_5)$ 是一组条件概率的乘积，图中每个节点一个条件。在本例中，我们需要五个条件。
- 每个条件只依赖于图中相应节点的父节点。例如 x_4 将以 x_2 为条件。

这两条性质给出联合分布的期望分解

$$p(x_1, x_2, x_3, x_4, x_5) = p(x_1)\, p(x_5)\, p(x_2 \mid x_5)\, p(x_3 \mid x_1, x_2)\, p(x_4 \mid x_2). \tag{8.30}$$

一般地，联合分布 $p(\boldsymbol{x}) = p(x_1, \ldots, x_K)$ 为

$$p(\boldsymbol{x}) = \prod_{k=1}^{K} p(x_k \mid \mathrm{Pa}_k), \tag{8.31}$$

其中 Pa_k 意为“x_k 的父节点”。x_k 的父节点是那些有箭头指向 x_k 的节点。

我们用抛硬币实验的具体例子结束本小节。考虑一个伯努利实验（例 6.8），其中该实验结果 x 为“正面”的概率为

$$p(x \mid \mu) = \mathrm{Ber}(\mu). \tag{8.32}$$

现在把这个实验重复 N 次，观测到结果 $x_1, \ldots, x_N$，从而得到联合分布

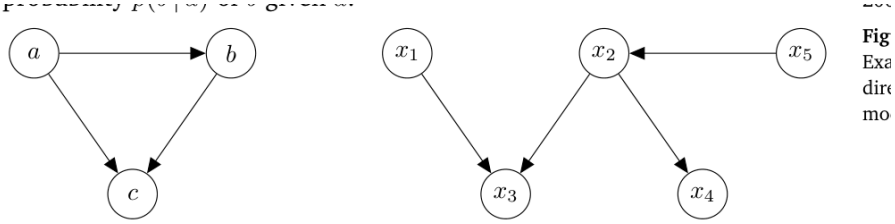
原书 p.281

$$p(x_1, \ldots, x_N \mid \mu) = \prod_{n=1}^{N} p(x_n \mid \mu). \tag{8.33}$$

右端是每个结果上伯努利分布的乘积，因为各次实验独立。回忆 6.4.5 节，统计独立意味着分布可分解。为这种情形写下图模型时，我们区分未观测/隐变量与观测变量。在图上，观测变量用阴影节点表示，于是得到图 8.10(a) 的图模型。我们看到单个参数 μ 对所有 x_n（$n = 1, \ldots, N$）都相同，因为结果 x_n 是同分布的。这种情形的一个更紧凑但等价的图模型见图 8.10(b)，其中我们使用了板记法（plate notation）。板（方框）把里面的一切（这里是观测 x_n）重复 N 次。因此两个图模型等价，但板记法更紧凑。图模型使我们能立即在 μ 上放置一个超先验（hyperprior）。超先验是第一层先验参数上的第二层先验分布。图 8.10(c) 在隐变量 μ 上放置一个 Beta(α, β) 先验。如果把 α 和 β 当作确定参数，即不是随机变量，我们就省略它们外面的圆圈。

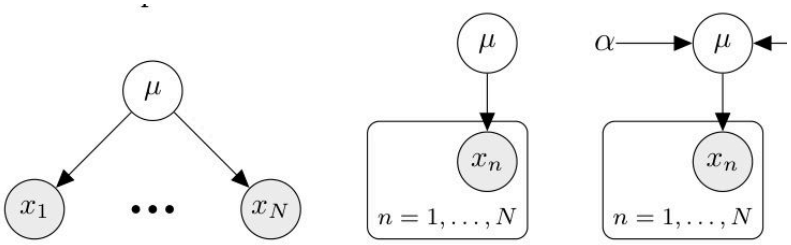
板

超先验



(a) Fully connected.　(b) Not fully connected.

图 8.9: 有向图模型示例。(a) 全连接；(b) 非全连接。（对应原书 Figure 8.9。）



(a) Version with x_n explicit.　(b) Version with plate notation.　(c) Hyperparamet and β on the latent

图 8.10: 重复伯努利实验的图模型。(a) 显式画出 x_n 的版本；(b) 用板记法的版本；(c) 在隐变量 μ 上的超参数 α 和 β。（对应原书 Figure 8.10。）

8.5.2　条件独立性与 d-分离

有向图模型使我们仅通过观察图就能发现联合分布的条件独立性（6.4.5 节）关系性质。一个称为 d-分离（d-separation）的概念是关键。考虑一个一般有向图，其中 A, B, C 是任意互不相交的节点集合（它们的并集可以小于图中全部节点集）。我们希望断定一个具体的条件独立性陈述“在给定 C 下 A 条件独立于 B”，记作 d-分离

$$A \perp\!\!\!\perp B \mid C, \tag{8.34}$$

是否由给定有向无环图蕴涵。为此，我们考虑从 A 中任一节点到 B 中任一节点的所有可能迹（忽略箭头方向的路径）。如果某条路径包含任一节点，使得以下两条之一成立，则称该路径被阻断：

- 路径上的箭头在该节点处头对尾或尾对尾相接，且该节点在集合 C 中；
- 箭头在该节点处头对头相接，且该节点及其所有后代都不在集合 C 中。

如果所有路径都被阻断，则称 A 被 C d-分离于 B，图中所有变量上的联合分布将满足 $A \perp\!\!\!\perp B \mid C$。

例 8.9 (条件独立性)**.** 考虑图 8.11 中的图模型。目视检查给出

$$b \perp\!\!\!\perp d \mid a, c \tag{8.35}$$

$$a \perp\!\!\!\perp c \mid b \tag{8.36}$$

$$b \not\perp\!\!\!\perp d \mid c \tag{8.37}$$

$$a \not\perp\!\!\!\perp c \mid b, e. \tag{8.38}$$

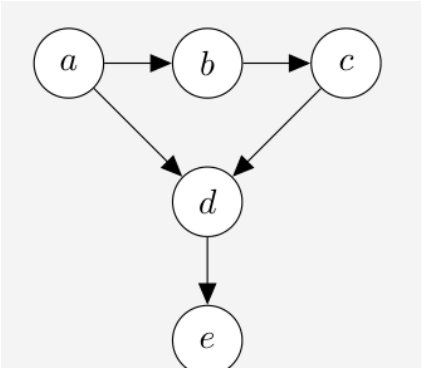


图 8.11: d-分离示例。（对应原书 Figure 8.11。）

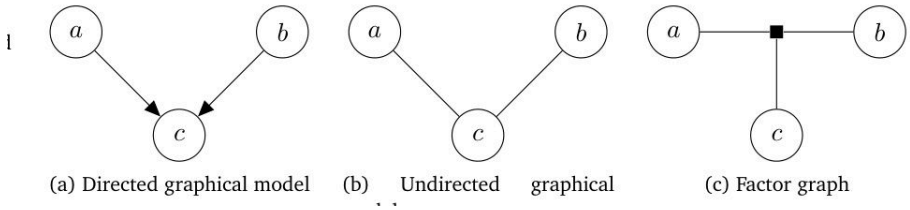


图 8.12: 三类图模型：(a) 有向图模型（贝叶斯网络）；(b) 无向图模型（马尔可夫随机场）；(c) 因子图。（对应原书 Figure 8.12。）

有向图模型允许对概率模型作紧凑表示，我们将在第 9、10、11 章看到有向图模型的例子。该表示连同条件独立性的概念，使我们能把相应概率模型分解为更容易优化的表达式。

概率模型的图形表示使我们能直观看到我们所做的设计选择对模型结构的影响。我们常常需要对模型结构做高层假设。这些建模假设（超参数）影响预测性能，但不能用目前所见的方法直接选择。我们将在 8.6 节讨论选择结构的不同方法。

原书 p.282

8.5.3　拓展阅读

原书 p.283

概率图模型的介绍见 Bishop (2006, 第 8 章)；不同应用及相应算法含义的广泛描述见 Koller and Friedman (2009) 的书。概率图模型主要有三类：

- 有向图模型（贝叶斯网络）；见图 8.12(a)
- 无向图模型（马尔可夫随机场）；见图 8.12(b)
- 因子图；见图 8.12(c)

贝叶斯网络

马尔可夫随机场

因子图

图模型允许基于图的推断与学习算法，例如通过局部消息传递。应用范围从在线游戏中的排序（Herbrich et al., 2007）和计算机视觉（如图像分割、语义标注、图像去噪、图像复原（Kittler and Föglein, 1984; Sucar and Gillies, 1994; Shotton et al., 2006; Szeliski et al., 2008)），到编码理论（McEliece et al., 1998）、求解线性方程组（Shental et al., 2008），以及信号处理中的迭代贝叶斯状态估计（Bickson et al., 2007; Deisenroth and Mohamed, 2012）。

本书不讨论在实际应用中特别重要的一个主题，即结构化预测（structured prediction）（Bakir et al., 2007; Nowozin et al., 2014），它使机器学习模型能处理结构化的预测，例如序列、树和图。神经网络模型的流行使更灵活的概率模型得以使用，从而产生了结

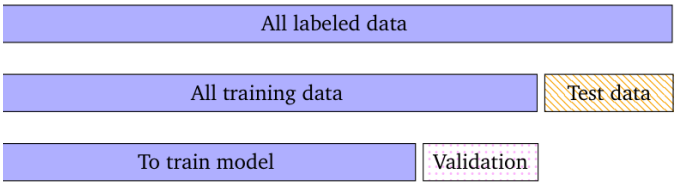


图 8.13: 嵌套交叉验证。我们做两层 K 折交叉验证。（对应原书 Figure 8.13。）

构化模型的许多有用应用（Goodfellow et al., 2016, 第 16 章）。近年来，由于图模型在因果推断中的应用，人们对图模型重新产生兴趣（Pearl, 2009; Imbens and Rubin, 2015; Peters et al., 2017; Rosenbaum, 2017）。

8.6　模型选择

在机器学习中，我们常常需要做对模型性能有关键影响的高层建模决策。我们所做的选择（例如似然的函数形式）影响模型中自由参数的数量和类型，从而影响模型的灵活性和表达能力。更复杂的模型更灵活，即它们可用来描述更多数据集。例如，一次多项式（直线 $y = a_0 + a_1 x$）只能描述输入 x 与观测 y 之间的线性关系。二次多项式还能描述输入与观测之间的二次关系。多项式 $y = a_0 + a_1 x + a_2 x^2$ 也可以通过令 $a_2 = 0$ 来描述线性函数，即它严格地比一次多项式更有表达力。

人们现在会认为，非常灵活的模型一般优于简单模型，因为它们更有表达力。一个普遍问题是：训练时我们只能用训练集来评估模型性能和学习参数。然而，我们真正关心的并不是训练集上的性能。在 8.3 节我们看到，最大似然估计会导致过拟合，尤其当训练数据集很小时。理想情况下，我们的模型（还）在测试集上（训练时不可得）也表现良好。因此，我们需要某种机制来评估模型如何泛化到未见测试数据。模型选择（model selection）处理的正是这个问题。

8.6.1　嵌套交叉验证

我们已经见过一种可用于模型选择的方法（8.2.4 节的交叉验证）。回忆交叉验证通过反复把数据集划分为训练集和验证集来提供泛化误差的估计。我们可以把这个思想再用一次，即对每次划分再做一轮交叉验证。这有时称为嵌套交叉验证（nested cross-validation）；见图 8.13。内层用于估计某个具体模型或超参数选择在内部验证集上的性能。外层用于估计由内层循环选出的最佳模型选择的泛化性能。我们可以在内层循环中测试不同的模型和超参数选择。为区分这两层，用于估计泛化性能的集合常称为测试集（test set），用于选择最佳模型的集合称为验证集（validation set）。内层循环通过用验证集上的经验误差逼近，来估计给定模型的泛化误差期望值 (8.39)，即

嵌套交叉验证

测试集

$$\mathbb{E}_V[R(V \mid M)] \approx \frac{1}{K} \sum_{k=1}^{K} R(V^{(k)} \mid M), \tag{8.39}$$

其中 $R(V \mid M)$ 是模型 M 在验证集 V 上的经验风险（例如均方根误差）。我们对所有模型重复这一流程，选择表现最好的模型。注意交叉验证不仅给出期望泛化误差，我们还能得到高阶统计量，例如标准误，它是均值估计不确定性的一个估计。标准误定义为 $\sigma/\sqrt{K}$，其中 K 是实验次数，σ 是每次实验风险的标准差。一旦选定模型，我们就可以在测试集上评估最终性能。

原书 p.284

8.6.2　贝叶斯模型选择

模型选择有许多方法，本节覆盖其中一些。一般而言，它们都试图在模型复杂度与数据拟合之间折中。我们假设简单模型比复杂模型更不易过拟合，因此模型选择的目标是找到能相当好地解释数据的最简单模型。这一概念也称为奥卡姆剃刀（Occam's razor）。

奥卡姆剃刀

注。如果我们把模型选择看作假设检验问题，我们就是在寻找与数据一致的最简单假设（Murphy, 2012）。◇

原书 p.285

人们可能考虑在模型上放置一个偏向简单模型的先验。然而这并不必要：一个“自动奥卡姆剃刀”在贝叶斯概率的应用中被定量地体现出来（Smith and Spiegelhalter, 1980; Jefferys and Berger, 1992; MacKay, 1992）。图 8.14 改编自 MacKay (2003)，它给出为什么复杂而非常有表达力的模型对建模给定数据集 D 而言反而可能是较不可能的选择这一直观解释。让我们把横轴想成所有可能数据集 D 的空间。如果我们关心给定数据 D 时模型 M_i 的后验概率 $p(M_i \mid D)$，可以使用贝叶斯定理。假设所有模型上有均匀先验 $p(M)$，贝叶斯定理按模型对已发生数据的预测程度来奖励模型。给定模型 M_i 对数据的这一预测 $p(D \mid M_i)$ 称为 M_i 的证据（evidence）。一个简单模型 M_1 只能预测少数数据集，由 $p(D \mid M_1)$ 表示；一个更强大的模型 M_2（例如比 M_1 有更多自由参数）能预测更多种类的数据集。然而这意味着 M_2 对区域 C 中数据集的预测不如 M_1 好。假设两个模型被赋予相等的先验概率。那么如果数据集落在区域 C，较弱的模型 M_1 就是更可能的模型。

证据

本章前面我们论证过，模型需要能解释数据，即应有办法从给定模型生成数据。此外，如果模型已从数据中恰当学习，那么我们期望生成的数据应与经验数据相似。为此，把模型选择表述为一个分层推断问题是有帮助的，它使我们能计算模型上的后验分布。

考虑有限个模型 $M = \{M_1, \dots, M_K\}$，其中每个模型 M_k 拥有参数 $\boldsymbol{\theta}_k$。在贝叶斯模型选择（Bayesian model selection）中，我们在模型集合上放置先验 $p(M)$。使我们能从该模型生成数据的相应生成过程（generative process）为

贝叶斯模型选择过程

$$M_k \sim p(M) \tag{8.40}$$

$$\boldsymbol{\theta}_k \sim p(\boldsymbol{\theta} \mid M_k) \tag{8.41}$$

$$D \sim p(D \mid \boldsymbol{\theta}_k) \tag{8.42}$$

如图 8.15 所示。给定训练集 D，我们应用贝叶斯定理，把模型上的后验分布计算为

$$p(M_k \mid D) \propto p(M_k)\, p(D \mid M_k). \tag{8.43}$$

注意这个后验不再依赖模型参数 $\boldsymbol{\theta}_k$，因为在贝叶斯设定下它们已被积出：

$$p(D \mid M_k) = \int p(D \mid \boldsymbol{\theta}_k)\, p(\boldsymbol{\theta}_k \mid M_k)\, \mathrm{d}\boldsymbol{\theta}_k, \tag{8.44}$$

其中 $p(\boldsymbol{\theta}_k \mid M_k)$ 是模型 M_k 的模型参数 $\boldsymbol{\theta}_k$ 的先验分布。(8.44) 项称为模型证据（model evidence）或边际似然（marginal likelihood）。从 (8.43) 的后验，我们确定 MAP 估计

模型证据/ 边际似然

$$M^* = \arg\max_{M_k} p(M_k \mid D). \tag{8.45}$$

在先验 $p(M_k) = \frac{1}{K}$（给每个模型相等的（先验）概率）下，确定模型上的 MAP 估计等价于挑选最大化模型证据 (8.44) 的模型。

注（似然与边际似然）。似然与边际似然（证据）之间有一些重要区别：似然容易过拟合，而边际似然通常不会，因为模型参数已被边际化掉（即我们不再需要拟合参数）。此外，边际似然自动体现模型复杂度与数据拟合之间的折中（奥卡姆剃刀）。◇

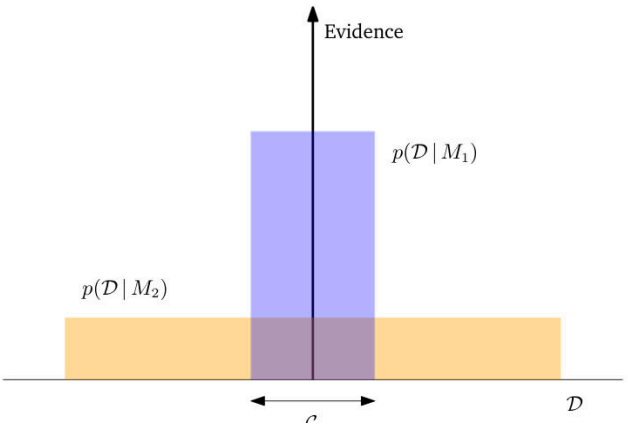
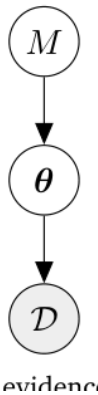


Figure Bayesia embodi razor. T horizon describe of all pc datasets evidenc axis) ev well a n predicts data. Si $p(\mathcal{D} \mid M$ integrat should model v

图 8.14: 贝叶斯推断体现奥卡姆剃刀。横轴描述所有可能数据集 D 的空间。证据（纵轴）评估模型对可得数据的预测好坏。由于 $p(D \mid M_i)$ 需积分为 1，我们应选择证据最大的模型。改编自 MacKay (2003)。（对应原书 Figure 8.14。）



model evidence

图 8.15: 贝叶斯模型选择中层级生成过程的示意。我们在模型集合上放置先验 $p(M)$。对每个模型，在相应模型参数上有分布 $p(\boldsymbol{\theta} \mid M)$，用于生成数据 D。（对应原书 Figure 8.15。）

8.6.3　用于模型比较的贝叶斯因子

考虑给定数据集 D 时比较两个概率模型 M_1, M_2 的问题。如果计算后验 $p(M_1 \mid D)$ 和 $p(M_2 \mid D)$，就可以计算后验之比　原书 p.287

$$\underbrace{\frac{p(M_1 \mid D)}{p(M_2 \mid D)}}_{\text{后验几率}} = \frac{\dfrac{p(D \mid M_1)\, p(M_1)}{p(D)}}{\dfrac{p(D \mid M_2)\, p(M_2)}{p(D)}} = \underbrace{\frac{p(M_1)}{p(M_2)}}_{\text{先验几率}} \underbrace{\frac{p(D \mid M_1)}{p(D \mid M_2)}}_{\text{贝叶斯因子}}. \tag{8.46}$$

后验之比也称为后验几率（posterior odds）。(8.46) 右端第一个分数是先验几率（prior odds），它度量我们的先验（初始）信念在多大程度上偏向 M_1 而非 M_2。边际似然之比（右端第二个分数）称为贝叶斯因子（Bayes factor），它度量数据 D 被 M_1 预测得比 M_2 好多少。

后验几率
先验几率
贝叶斯因子

注。Jeffreys–Lindley 悖论（Jeffreys-Lindley paradox）指出：“贝叶斯因子总是偏向更简单的模型，因为在带 diffuse 先验的复杂模型下数据的概率会非常小”（Murphy, 2012）。这里 diffuse 先验指不偏向特定模型的先验，即在该先验下许多模型先验上都似是而非。

Jeffreys-Lindley 悖论

◇

如果在模型上选均匀先验，(8.46) 中的先验几率项为 1，即后验几率就是边际似然之比（贝叶斯因子）

$$\frac{p(D \mid M_1)}{p(D \mid M_2)}. \tag{8.47}$$

如果贝叶斯因子大于 1，选模型 M_1，否则选模型 M_2。与频率派统计类似，在认为结果“显著”之前，对该比值大小有一些指南（Jeffreys, 1961）。

注（计算边际似然）。边际似然在模型选择中起重要作用：我们需要计算贝叶斯因子 (8.46) 和模型上的后验分布 (8.43)。遗憾的是，计算边际似然要求我们求解一个积分 (8.44)。该积分一般解析不可处理，我们不得不求助于近似技术，例如数值积分（Stoer and Burlirsch, 2002）、使用蒙特卡洛的随机近似（Murphy, 2012）或贝叶斯蒙特卡洛技术（O'Hagan, 1991; Rasmussen and Ghahramani, 2003）。

不过也有一些特殊情形我们能求解它。在 6.6.1 节我们讨论了共轭模型。如果选择共轭参数先验 $p(\boldsymbol{\theta})$，就能以闭式计算边际似然。在第 9 章，我们将在线性回归语境中正是这样做。◇

原书 p.288

本章我们简要介绍了机器学习的基本概念。在本书本部分余下篇幅中，我们将看到 8.2、8.3、8.4 节中三种不同风味的学习如何应用于机器学习的四大支柱（回归、降维、密度估计和分类）。

8.6.4　拓展阅读

我们在本节开头提到，存在影响模型性能的高层建模选择。例子包括：

- 回归设定中多项式的次数；
- 混合模型中的分量数；
- （深度）神经网络的网络结构；
- 支持向量机中核的类型；
- PCA 中隐空间的维数；
- 优化算法中的学习率（调度）。

在参数化模型中，参数数量常与模型类的复杂度相关。Rasmussen and Ghahramani (2001) 表明，自动奥卡姆剃刀不一定惩罚模型中参数的数量，但它在函数复杂度方面是活跃的。他们还表明，自动奥卡姆剃刀对带许多参数的贝叶斯非参数模型也成立，例如高斯过程。

如果我们聚焦于最大似然估计，存在一些抑制过拟合的模型选择启发式。它们称为信息准则（information criteria），我们选择值最大的模型。赤池信息准则（Akaike information criterion, AIC）（Akaike, 1974）

AIC

$$\log p(x \mid \boldsymbol{\theta}) - M \tag{8.48}$$

通过加一个惩罚项来校正最大似然估计的偏差，以补偿带大量参数的更复杂模型的过拟合。这里 M 是模型参数个数。AIC 估计给定模型所损失的相对信息。

贝叶斯信息准则（Bayesian information criterion, BIC）（Schwarz, 1978）

BIC

$$\log p(x) = \log \int p(x \mid \boldsymbol{\theta})\, p(\boldsymbol{\theta})\, \mathrm{d}\boldsymbol{\theta} \approx \log p(x \mid \boldsymbol{\theta}) - \frac{1}{2} M \log N \tag{8.49}$$

可用于指数族分布。这里 N 是数据点数，M 是参数个数。BIC 比 AIC 更严厉地惩罚模型复杂度。

第 9 章　线性回归

原书 p.289

在下文中，我们将应用第 2、5、6、7 章中的数学概念来求解线性回归（曲线拟合）问题。在回归中，我们的目标是找到一个函数 f，它把输入 $\boldsymbol{x} \in \mathbb{R}^D$ 映射到相应的函数值 $f(\boldsymbol{x}) \in \mathbb{R}$。我们假设给定一组训练输入 $\boldsymbol{x}_n$ 以及相应的含噪观测 $y_n = f(\boldsymbol{x}_n) + \epsilon$，其中 ϵ 是一个独立同分布随机变量，描述测量/观测噪声以及可能未被建模的过程（本章不再进一步讨论后者）。本章通篇假设零均值高斯噪声。我们的任务是找到一个函数，它不仅能对训练数据建模，还能很好地泛化到预测那些不属于训练数据的输入位置处的函数值（见第 8 章）。这样一个回归问题的示意见图 9.1。图 9.1(a) 给出了一个典型的回归设定：对于某些输入值 $\boldsymbol{x}_n$，我们观测到（含噪的）函数值 $y_n = f(\boldsymbol{x}_n) + \epsilon$。任务是推断出生成数据的函数 f，并使其在新输入位置处的函数值上泛化良好。一个可能的解见图 9.1(b)，其中我们还画出了以函数值 $f(\boldsymbol{x})$ 为中心的三个分布，用以表示数据中的噪声。

回归

原书 p.290

回归是机器学习中的一个基本问题，回归问题出现在多种多样的研究领域和应用中，包括时间序列分析（如系统辨识）、控制与机器人学（如强化学习、前向/逆向模型学习）、优化（如线性搜索、全局优化）以及深度学习应用（如计算机游戏、语音转文本、图像识别、自动视频标注）。回归也是分类算法中的一个关键成分。寻找回归函数需要解决一系列问题，包括：

- **模型（类型）的选择与回归函数的参数化**。给定一个数据集，哪些函数类（例如多项式）是对数据建模的良好候选？我们应选择怎样的特定参数化（例如多项式的次数）？模型选择（如 8.6 节所讨论）使我们能够比较各种模型，以找到能合理良好地解释训练数据的最简模型。
- **寻找好的参数**。选定回归函数的模型之后，我们如何找到好的模型参数？这里我们需要考察不同的损失/目标函数（它们决定了什么是” 好” 的拟合）以及允许我们最小化该损失的优化算法。
- **过拟合与模型选择**。当过回归函数” 过好” 地拟合了训练数据却不能泛化到未见测试数据时，就出现了过拟合问题。过拟合通常发生在底层模型（或其参数化）过于灵活和富有表达力时；见 8.6 节。我们将考察其底层原因，并在线性回归的语境下讨论缓解过拟合影响的方法。
- **损失函数与参数先验之间的关系**。损失函数（优化目标）往往由概率模型所启发和诱导。我们将考察损失函数与诱导这些损失的底层先验假设之间的联系。
- **不确定性建模**。在任何实际设定中，我们只能获得有限的（可能很多）（训练）数据来选择模型类及相应参数。鉴于这有限量的训练数据并不能覆盖所有可能情形，我们可能希望描述剩余的参数不确定性，以便在测试时获得对模型预测的置信度度量；训练集越小，不确定性建模就越重要。一致地对不确定性进行建模，可以为模型预测配备置信界。

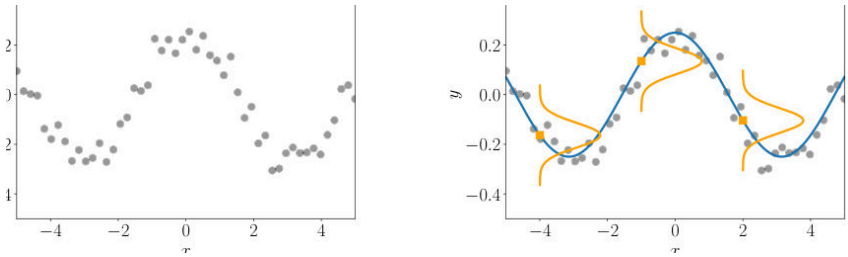


图 9.1: 回归问题示例。(a) 数据集；(b) 回归问题的一个可能解。左图：观测到的含噪函数值，我们希望从中推断出生成数据的底层函数；右图：可能生成该数据的函数（蓝色），并在相应输入处标示函数值的测量噪声（橙色分布）。（对应原书 Figure 9.1。）

在下文中，我们将使用第 3、5、6、7 章的数学工具来求解线性回归问题。我们将讨论最大似然和最大后验（MAP）估计以寻找最优模型参数。利用这些参数估计，我们将简要考察泛化误差和过拟合。在本章末尾，我们将讨论贝叶斯线性回归，它使我们能够在更高层次上对模型参数进行推理，从而消除最大似然和 MAP 估计中遇到的一些问题。

9.1　问题形式化

原书 p.291

由于存在观测噪声，我们将采用概率方法，并用似然函数显式地对噪声建模。更具体地，本章通篇考虑一个具有如下似然函数的回归问题

$$p(y \mid \boldsymbol{x}) = \mathcal{N}\left(y \,\middle|\, f(\boldsymbol{x}), \sigma^2\right). \tag{9.1}$$

这里，$\boldsymbol{x} \in \mathbb{R}^D$ 是输入，$y \in \mathbb{R}$ 是含噪的函数值（目标）。由 (9.1)，$\boldsymbol{x}$ 与 y 之间的函数关系为

$$y = f(\boldsymbol{x}) + \epsilon, \tag{9.2}$$

其中 $\epsilon \sim \mathcal{N}\left(0, \sigma^2\right)$ 是独立同分布（i.i.d.）的高斯测量噪声，均值为 0，方差为 σ^2。我们的目标是找到一个与生成数据的未知函数 f 接近（相似）且泛化良好的函数。

本章聚焦于参数模型，即我们选择一个参数化函数，并找到对数据建模"效果良好"的参数 $\boldsymbol{\theta}$。暂且假设噪声方差 σ^2 已知，专注于学习模型参数 $\boldsymbol{\theta}$。在线性回归中，我们考虑参数 $\boldsymbol{\theta}$ 在模型中线性出现这一特殊情形。线性回归的一个例子由下式给出

$$p(y \mid \boldsymbol{x}, \boldsymbol{\theta}) = \mathcal{N}\left(y \,\middle|\, \boldsymbol{x}^\top \boldsymbol{\theta}, \sigma^2\right) \tag{9.3}$$

$$\iff y = \boldsymbol{x}^\top \boldsymbol{\theta} + \epsilon, \qquad \epsilon \sim \mathcal{N}\left(0, \sigma^2\right), \tag{9.4}$$

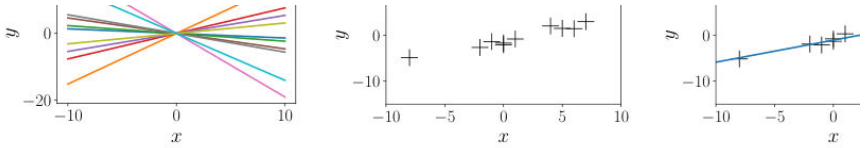
其中 $\boldsymbol{\theta} \in \mathbb{R}^D$ 是我们寻求的参数。由 (9.4) 描述的函数类是过原点的直线。在 (9.4) 中，我们选择了参数化 $f(\boldsymbol{x}) = \boldsymbol{x}^\top \boldsymbol{\theta}$。

狄拉克δ

似然

式 (9.3) 中的似然是在 $\boldsymbol{x}^\top \boldsymbol{\theta}$ 处取值的 y 的概率密度函数。注意，不确定性的唯一来源是观测噪声（因为在 (9.3) 中 $\boldsymbol{x}$ 和 $\boldsymbol{\theta}$ 被假定为已知）。若没有观测噪声，$\boldsymbol{x}$ 与 y 之间的关系将是确定性的，(9.3) 将是一个狄拉克 δ 函数。

例 9.1. 对于 $\boldsymbol{x}, \boldsymbol{\theta} \in \mathbb{R}$，式 (9.4) 中的线性回归模型描述直线（线性函数），参数 $\boldsymbol{\theta}$ 是直线的斜率。图 9.2(a) 示出了不同 $\boldsymbol{\theta}$ 值对应的一些示例函数。



(a) Example functions (straight lines) that can be described using the linear model in (9.4)

(b) Training set.

(c) Maximum likelihood estimate.

图 9.2: 线性回归示例。(a) 属于此类的示例函数（直线），可由式 (9.4) 中的线性模型描述；(b) 训练集；(c) 最大似然估计。（对应原书 Figure 9.2。）

deterministic/
known values are
without circles.

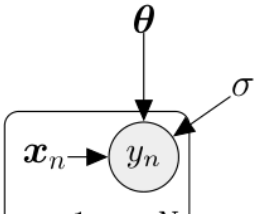


图 9.3: 线性回归的概率图模型。观测随机变量以阴影表示，确定性/已知值不带圆圈。（对应原书 Figure 9.3。）

式 (9.3)–(9.4) 中的线性回归模型不仅关于参数线性,而且关于输入 $\boldsymbol{x}$ 也线性。图 9.2(a) 示出了这类函数的例子。我们稍后将看到，对于非线性变换 ϕ，$y = \phi^\top(\boldsymbol{x})\boldsymbol{\theta}$ 也是一个线性回归模型，因为” 线性回归” 指的是” 关于参数线性” 的模型，即通过输入特征的线性组合来描述函数的模型。这里，” 特征” 是输入 $\boldsymbol{x}$ 的一种表示 $\phi(\boldsymbol{x})$。

关于参数线性

在下文中，我们将更详细地讨论如何寻找好的参数 $\boldsymbol{\theta}$，以及如何评估一组参数是否” 效果良好”。暂且假设噪声方差 σ^2 已知。

9.2　参数估计

考虑线性回归设定 (9.4),并假设我们给定一个训练集 $\mathcal{D} := \{(\boldsymbol{x}_1, y_1), \ldots, (\boldsymbol{x}_N, y_N)\}$，它由 N 个输入 $\boldsymbol{x}_n \in \mathbb{R}^D$ 和相应的观测/目标 $y_n \in \mathbb{R}$ 组成，$n = 1, \ldots, N$。相应的图模型见图 9.3。注意 y_i 和 y_j 在给定各自输入 $\boldsymbol{x}_i, \boldsymbol{x}_j$ 时条件独立，因此似然可分解为

训练集

$$p(\mathcal{Y} \mid \mathcal{X}, \boldsymbol{\theta}) = p(y_1, \ldots, y_N \mid \boldsymbol{x}_1, \ldots, \boldsymbol{x}_N, \boldsymbol{\theta}) \tag{9.5a}$$

$$= \prod_{n=1}^{N} p(y_n \mid \boldsymbol{x}_n, \boldsymbol{\theta}) = \prod_{n=1}^{N} \mathcal{N}\left(y_n \mid \boldsymbol{x}_n^\top \boldsymbol{\theta}, \sigma^2\right), \tag{9.5b}$$

其中我们定义 $\mathcal{X} := \{\boldsymbol{x}_1, \ldots, \boldsymbol{x}_N\}$ 和 $\mathcal{Y} := \{y_1, \ldots, y_N\}$ 分别为训练输入集和相应目标集。由于噪声分布，似然及因子 $p(y_n \mid \boldsymbol{x}_n, \boldsymbol{\theta})$ 都是高斯的；见 (9.3)。

在下文中，我们将讨论如何为线性回归模型 (9.4) 寻找最优参数 $\boldsymbol{\theta}^* \in \mathbb{R}^D$。一旦找到参数 $\boldsymbol{\theta}^*$，我们就可以在 (9.4) 中使用该参数估计来预测函数值，即在任意测试输入 $\boldsymbol{x}^*$ 处，相应目标 y^* 的分布为

$$p(y^* \mid \boldsymbol{x}^*, \boldsymbol{\theta}^*) = \mathcal{N}\left(y^* \mid \boldsymbol{x}_*^\top \boldsymbol{\theta}^*, \sigma^2\right). \tag{9.6}$$

在下文中，我们将通过最大化似然来考察参数估计，这一主题我们已在 8.3 节中有所讨论。

9.2.1　最大似然估计

原书 p.293

最大似然估计

寻找所需参数 $\boldsymbol{\theta}_{\mathrm{ML}}$ 的一种广泛使用的方法是最大似然估计，即找到使似然 (9.5b) 最大化的参数 $\boldsymbol{\theta}_{\mathrm{ML}}$。直观地，最大化似然意味着最大化给定模型参数下训练数据的预测分布。我们得到最大似然参数为

$$\boldsymbol{\theta}_{\mathrm{ML}} \in \arg\max_{\boldsymbol{\theta}} p(\mathcal{Y} \mid \mathcal{X}, \boldsymbol{\theta}). \tag{9.7}$$

注。似然 $p(y \mid \boldsymbol{x}, \boldsymbol{\theta})$ 并不是关于 $\boldsymbol{\theta}$ 的概率分布：它只是参数 $\boldsymbol{\theta}$ 的一个函数，但并不积分到 1（即它未归一化），甚至可能关于 $\boldsymbol{\theta}$ 不可积。然而，(9.7) 中的似然关于 y 是一个归一化的概率分布。$\diamond$

为找到使似然最大的所需参数 $\boldsymbol{\theta}_{\mathrm{ML}}$，我们通常执行梯度上升（或对负似然做梯度下降）。然而，在我们这里考虑的线性回归情形中，存在闭式解，这使得迭代梯度下降不再必要。实践中，我们并不直接最大化似然，而是对似然函数施加对数变换，并最小化负对数似然。

对数变换

注（对数变换）。由于似然 (9.5b) 是 N 个高斯分布的乘积，对数变换很有用，因为 (a) 它不会遭遇数值下溢，(b) 求导法则将变得更简单。更具体地，当我们相乘 N 个概率时（N 是数据点个数），数值下溢将成为问题，因为我们无法表示非常小的数，例如 10^{-256}。此外，对数变换将乘积变为对数概率之和，使得相应的梯度是各梯度之和，而不是反复应用乘积法则 (5.46) 来计算 N 项乘积的梯度。$\diamond$

为找到线性回归问题的最优参数 $\boldsymbol{\theta}_{\mathrm{ML}}$，我们最小化负对数似然

$$-\log p(\mathcal{Y} \mid \mathcal{X}, \boldsymbol{\theta}) = -\log \prod_{n=1}^{N} p(y_n \mid \boldsymbol{x}_n, \boldsymbol{\theta}) = -\sum_{n=1}^{N} \log p(y_n \mid \boldsymbol{x}_n, \boldsymbol{\theta}), \tag{9.8}$$

其中我们利用了：由于训练集上的独立性假设，似然 (9.5b) 按数据点个数分解。

在线性回归模型 (9.4) 中，似然是高斯的（由于高斯加性噪声项），因此我们得到

$$\log p(y_n \mid \boldsymbol{x}_n, \boldsymbol{\theta}) = -\frac{1}{2\sigma^2}(y_n - \boldsymbol{x}_n^\top \boldsymbol{\theta})^2 + \text{const}, \tag{9.9}$$

其中常数包含所有与 $\boldsymbol{\theta}$ 无关的项。将 (9.9) 代入负对数似然 (9.8)，我们得到（忽略常数项）

原书 p.294

$$L(\boldsymbol{\theta}) := \frac{1}{2\sigma^2}\sum_{n=1}^{N}(y_n - \boldsymbol{x}_n^\top \boldsymbol{\theta})^2 \tag{9.10a}$$

$$= \frac{1}{2\sigma^2}(\boldsymbol{y} - X\boldsymbol{\theta})^\top(\boldsymbol{y} - X\boldsymbol{\theta}) = \frac{1}{2\sigma^2}\|\boldsymbol{y} - X\boldsymbol{\theta}\|^2, \tag{9.10b}$$

其中我们定义设计矩阵 $X := [\boldsymbol{x}_1, \ldots, \boldsymbol{x}_N]^\top \in \mathbb{R}^{N \times D}$ 为训练输入的集合，并定义 $\boldsymbol{y} := [y_1, \ldots, y_N]^\top \in \mathbb{R}^N$ 为收集所有训练目标的向量。注意设计矩阵 X 中的第 n 行对应于训练输入 $\boldsymbol{x}_n$。在 (9.10b) 中，我们利用了如下事实：观测 y_n 与相应模型预测 $\boldsymbol{x}_n^\top \boldsymbol{\theta}$ 之间的平方误差之和等于 $\boldsymbol{y}$ 与 $X\boldsymbol{\theta}$ 之间的平方距离。

设计矩阵

平方误差

由 (9.10b)，我们现在得到了需要优化的负对数似然函数的具体形式。我们立即看到 (9.10b) 关于 $\boldsymbol{\theta}$ 是二次的。这意味着我们可以找到最小化负对数似然 L 的唯一全局解 $\boldsymbol{\theta}_{\mathrm{ML}}$。我们可以通过计算 L 的梯度、令其为 0 并解出 $\boldsymbol{\theta}$ 来找到全局最优。

利用第 5 章的结果，我们计算 L 关于参数的梯度为

$$\frac{\mathrm{d}L}{\mathrm{d}\boldsymbol{\theta}} = \frac{\mathrm{d}}{\mathrm{d}\boldsymbol{\theta}}\left(\frac{1}{2\sigma^2}(\boldsymbol{y}-X\boldsymbol{\theta})^\top(\boldsymbol{y}-X\boldsymbol{\theta})\right) \tag{9.11a}$$

$$= \frac{1}{2\sigma^2}\frac{\mathrm{d}}{\mathrm{d}\boldsymbol{\theta}}\left(\boldsymbol{y}^\top\boldsymbol{y} - 2\boldsymbol{y}^\top X\boldsymbol{\theta} + \boldsymbol{\theta}^\top X^\top X\boldsymbol{\theta}\right) \tag{9.11b}$$

$$= \frac{1}{\sigma^2}\left(-\boldsymbol{y}^\top X + \boldsymbol{\theta}^\top X^\top X\right) \in \mathbb{R}^{1\times D}. \tag{9.11c}$$

最大似然估计量 $\boldsymbol{\theta}_{\mathrm{ML}}$ 求解 $\frac{\mathrm{d}L}{\mathrm{d}\boldsymbol{\theta}} = \mathbf{0}^\top$（必要最优性条件），我们得到

$$\frac{\mathrm{d}L}{\mathrm{d}\boldsymbol{\theta}} = \mathbf{0}^\top \text{ 由}(9.11c) \iff \boldsymbol{\theta}_{\mathrm{ML}}^\top X^\top X = \boldsymbol{y}^\top X \tag{9.12a}$$

$$\iff \boldsymbol{\theta}_{\mathrm{ML}}^\top = \boldsymbol{y}^\top X(X^\top X)^{-1} \tag{9.12b}$$

$$\iff \boldsymbol{\theta}_{\mathrm{ML}} = (X^\top X)^{-1}X^\top\boldsymbol{y}. \tag{9.12c}$$

我们之所以可以在第一个方程右乘 $(X^\top X)^{-1}$，是因为当 $\mathrm{rk}(X) = D$ 时 $X^\top X$ 是正定的，其中 $\mathrm{rk}(X)$ 表示 X 的秩。

注。令梯度为 $\mathbf{0}^\top$ 是必要且充分条件,且我们得到全局最小值,因为 Hessian $\nabla^2_{\boldsymbol{\theta}}L(\boldsymbol{\theta}) = X^\top X \in \mathbb{R}^{D\times D}$ 是正定的。$\diamond$

注。(9.12c) 中的最大似然解要求我们求解一个形如 $A\boldsymbol{\theta} = \boldsymbol{b}$ 的线性方程组，其中 $A = (X^\top X)$，$\boldsymbol{b} = X^\top\boldsymbol{y}$。$\diamond$

原书 p.295

例 9.2 (拟合直线)**.** 让我们查看图 9.2, 我们希望用最大似然估计拟合一条直线 $f(x) = \theta x$（其中 θ 是未知斜率）到一个数据集上。此模型类（直线）中的函数示例见图 9.2(a)。对于图 9.2(b) 所示的数据集, 我们使用 (9.12c) 找到斜率参数 θ 的最大似然估计, 得到图 9.2(c) 中的最大似然线性函数。

带特征的最大似然估计

原书 p.296

到目前为止，我们考虑了 (9.4) 中描述的线性回归设定，它允许我们用最大似然估计把直线拟合到数据上。然而，当拟合更有趣的数据时，直线的表达力不够强。幸运的是，线性回归为我们提供了一种在线性回归框架内拟合非线性函数的方法：由于" 线性回归" 仅指" 关于参数线性"，我们可以对输入 $\boldsymbol{x}$ 执行任意非线性变换 $\phi(\boldsymbol{x})$，然后对该变换的各分量进行线性组合。相应的线性回归模型为

$$p(y \mid \boldsymbol{x}, \boldsymbol{\theta}) = \mathcal{N}\left(y \,\middle|\, \phi^\top(\boldsymbol{x})\boldsymbol{\theta},\, \sigma^2\right) \iff y = \phi^\top(\boldsymbol{x})\boldsymbol{\theta} + \epsilon = \sum_{k=0}^{K-1}\theta_k\phi_k(\boldsymbol{x}) + \epsilon, \tag{9.13}$$

其中 $\phi : \mathbb{R}^D \to \mathbb{R}^K$ 是输入 $\boldsymbol{x}$ 的一个（非线性）变换，$\phi_k : \mathbb{R}^D \to \mathbb{R}$ 是特征向量 ϕ 的第 k 个分量。注意模型参数 $\boldsymbol{\theta}$ 仍然只线性出现。

特征向量

例 9.3 (多项式回归)**.** 我们关心一个回归问题 $y = \phi^\top(x)\boldsymbol{\theta} + \epsilon$，其中 $x \in \mathbb{R}$，$\boldsymbol{\theta} \in \mathbb{R}^K$。在此语境中常用的一个变换为

$$\phi(x) = \begin{bmatrix}\phi_0(x)\\ \phi_1(x)\\ \vdots\\ \phi_{K-1}(x)\end{bmatrix} = \begin{bmatrix}1\\ x\\ x^2\\ x^3\\ \vdots\\ x^{K-1}\end{bmatrix} \in \mathbb{R}^K. \tag{9.14}$$

这意味着我们将原始一维输入空间" 提升" 为一个 K 维特征空间，该空间由所有单项式 x^k（$k=0,\dots,K-1$）组成。有了这些特征，我们就可以在线性回归框架内对次数 $\leqslant K-1$ 的多项式建模：一个次数为 $K-1$ 的多项式为

$$f(x)=\sum_{k=0}^{K-1}\theta_k x^k=\phi^\top(x)\boldsymbol{\theta}, \tag{9.15}$$

其中 ϕ 由 (9.14) 定义，$\boldsymbol{\theta}=[\theta_0,\dots,\theta_{K-1}]^\top\in\mathbb{R}^K$ 包含（线性）参数 θ_k。

现在让我们考察线性回归模型 (9.13) 中参数 $\boldsymbol{\theta}$ 的最大似然估计。我们考虑训练输入 $\boldsymbol{x}_n\in\mathbb{R}^D$ 和目标 $y_n\in\mathbb{R}$，$n=1,\dots,N$，并将特征矩阵（设计矩阵）定义为

$$\Phi:=\begin{bmatrix}\phi^\top(\boldsymbol{x}_1)\\ \vdots\\ \phi^\top(\boldsymbol{x}_N)\end{bmatrix}=\begin{bmatrix}\phi_0(\boldsymbol{x}_1) & \cdots & \phi_{K-1}(\boldsymbol{x}_1)\\ \phi_0(\boldsymbol{x}_2) & \cdots & \phi_{K-1}(\boldsymbol{x}_2)\\ \vdots & & \vdots\\ \phi_0(\boldsymbol{x}_N) & \cdots & \phi_{K-1}(\boldsymbol{x}_N)\end{bmatrix}\in\mathbb{R}^{N\times K}, \tag{9.16}$$

其中 $\Phi_{ij}=\phi_j(\boldsymbol{x}_i)$，$\phi_j:\mathbb{R}^D\to\mathbb{R}$。

特征矩阵

例 9.4 (二阶多项式的特征矩阵)**.** 对于二阶多项式和 N 个训练点 $\boldsymbol{x}_n\in\mathbb{R}$，$n=1,\dots,N$，特征矩阵为

$$\Phi=\begin{bmatrix}1 & x_1 & x_1^2\\ 1 & x_2 & x_2^2\\ \vdots & \vdots & \vdots\\ 1 & x_N & x_N^2\end{bmatrix}. \tag{9.17}$$

利用 (9.16) 中定义的特征矩阵 Φ，线性回归模型 (9.13) 的负对数似然可写为

$$-\log p(\mathcal{Y}\mid\mathcal{X},\boldsymbol{\theta})=\frac{1}{2\sigma^2}(\boldsymbol{y}-\Phi\boldsymbol{\theta})^\top(\boldsymbol{y}-\Phi\boldsymbol{\theta})+\text{const.} \tag{9.18}$$

将 (9.18) 与" 无特征" 模型的负对数似然 (9.10b) 比较，我们立即看到只需将 X 替换为 Φ。由于 X 和 Φ 都与我们希望优化的参数 $\boldsymbol{\theta}$ 无关，我们立即得到 (9.13) 中定义的带非线性特征的线性回归问题的最大似然估计

$$\boldsymbol{\theta}_{\text{ML}}=(\Phi^\top\Phi)^{-1}\Phi^\top\boldsymbol{y}. \tag{9.19}$$

原书 p.297

注。当我们不使用特征时，我们要求 $X^\top X$ 可逆，这在 $\text{rk}(X)=D$ 时成立，即 X 的列线性无关。因此在 (9.19) 中，我们要求 $\Phi^\top\Phi\in\mathbb{R}^{K\times K}$ 可逆。当且仅当 $\text{rk}(\Phi)=K$ 时此条件成立。$\diamond$

例 9.5 (最大似然多项式拟合)**.** 考虑图 9.4(a) 中的数据集。该数据集由 $N=10$ 对 $(\boldsymbol{x}_n,y_n)$ 组成，其中 $x_n\sim\mathcal{U}[-5,5]$，$y_n=-\sin(x_n/5)+\cos(x_n)+\epsilon$，$\epsilon\sim\mathcal{N}\big(0,\,0.2^2\big)$。

我们用最大似然估计拟合一个四次多项式，即参数 $\boldsymbol{\theta}_{\text{ML}}$ 由 (9.19) 给出。最大似然估计在任意测试位置 $\boldsymbol{x}^*$ 处产生函数值 $\phi^\top(\boldsymbol{x}^*)\boldsymbol{\theta}_{\text{ML}}$。结果见图 9.4(b)。

估计噪声方差

到目前为止，我们假设噪声方差 σ^2 已知。然而，我们也可以使用最大似然估计原理来获得噪声方差的最大似然估计量 σ^2_{ML}。为此，我们遵循标准流程：写出对数似然，

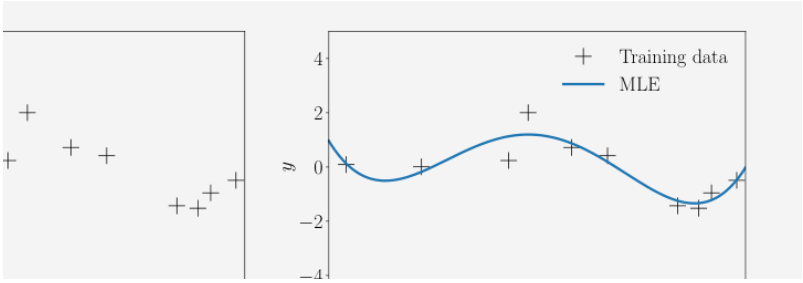


图 9.4: 多项式回归。(a) 由 (x_n, y_n) 对组成的数据集，$n = 1, \ldots, 10$；(b) 由最大似然估计确定的四次多项式。（对应原书 Figure 9.4。）

计算其关于 $\sigma^2 > 0$ 的导数，令其为 0 并求解。对数似然为

$$\log p(\mathcal{Y} \mid \mathcal{X}, \boldsymbol{\theta}, \sigma^2) = \sum_{n=1}^{N} \log \mathcal{N}\left(y_n \mid \phi^\top(\boldsymbol{x}_n)\boldsymbol{\theta}, \sigma^2\right) \tag{9.20a}$$

$$= \sum_{n=1}^{N} \left(-\frac{1}{2}\log(2\pi) - \frac{1}{2}\log\sigma^2 - \frac{1}{2\sigma^2}(y_n - \phi^\top(\boldsymbol{x}_n)\boldsymbol{\theta})^2\right) \tag{9.20b}$$

$$= -\frac{N}{2}\log\sigma^2 - \frac{1}{2\sigma^2}\underbrace{\sum_{n=1}^{N}(y_n - \phi^\top(\boldsymbol{x}_n)\boldsymbol{\theta})^2}_{=:s} + \text{const.} \tag{9.20c}$$

对数似然关于 σ^2 的偏导数为　原书 p.298

$$\frac{\partial \log p(\mathcal{Y} \mid \mathcal{X}, \boldsymbol{\theta}, \sigma^2)}{\partial \sigma^2} = -\frac{N}{2\sigma^2} + \frac{1}{2\sigma^4}s = 0 \tag{9.21a}$$

$$\iff \frac{N}{2\sigma^2} = \frac{s}{2\sigma^4}, \tag{9.21b}$$

由此我们确定

$$\sigma^2_{\text{ML}} = \frac{s}{N} = \frac{1}{N}\sum_{n=1}^{N}(y_n - \phi^\top(\boldsymbol{x}_n)\boldsymbol{\theta})^2. \tag{9.22}$$

因此，噪声方差的最大似然估计是无噪函数值 $\phi^\top(\boldsymbol{x}_n)\boldsymbol{\theta}$ 与在输入位置 $\boldsymbol{x}_n$ 处相应的含噪观测 y_n 之间平方距离的经验均值。

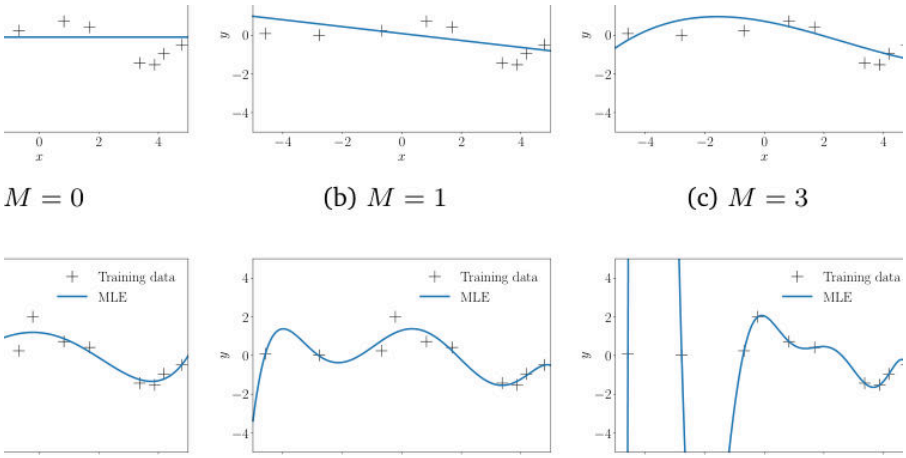
9.2.2　线性回归中的过拟合

我们刚刚讨论了如何使用最大似然估计将线性模型（例如多项式）拟合到数据上。我们可以通过计算所产生的误差/损失来评估模型的质量。一种方法是计算负对数似然 (9.10b)，我们最小化它来确定最大似然估计量。或者，鉴于噪声参数 σ^2 不是自由模型参数，我们可以忽略 $1/\sigma^2$ 的缩放，从而得到一个平方误差损失函数 $\|\boldsymbol{y} - \Phi\boldsymbol{\theta}\|^2$。我们经常不使用这种平方损失，而使用均方根误差（RMSE）

$$\text{RMSE}\sqrt{\frac{1}{N}\|\boldsymbol{y} - \Phi\boldsymbol{\theta}\|^2} = \sqrt{\frac{1}{N}\sum_{n=1}^{N}(y_n - \phi^\top(\boldsymbol{x}_n)\boldsymbol{\theta})^2}, \tag{9.23}$$

它 (a) 允许我们比较不同大小数据集的误差，(b) 与观测函数值 y_n 具有相同的尺度和相同的单位。例如，如果我们拟合一个将邮编（x 以纬度、经度给出）映射到房价（y 值以欧元计）的模型，那么 RMSE 也以欧元度量，而平方误差以欧元 ^{2} 给出。如果我们选择保留原始负对数似然 (9.10b) 中的因子 σ^2，那么我们最终得到一个无量纲目标，即在前面的例子中，我们的目标将不再以欧元或欧元 ^{2} 为单位。

均方根误差



$M = 0$　(b) $M = 1$　(c) $M = 3$

图 9.5: 不同多项式次数 M 的最大似然拟合。(a) $M = 0$；(b) $M = 1$；(c) $M = 3$；(d) $M = 4$；(e) $M = 6$；(f) $M = 9$。（对应原书 Figure 9.5。）

对于模型选择（见 8.6 节），我们可以使用 RMSE（或负对数似然）来确定多项式的最佳次数，方法是找到使目标最小化的多项式次数 M。鉴于多项式次数是自然数，我们可以执行暴力搜索并枚举所有（合理的）M 值。对于大小为 N 的训练集，测试 $0 \leqslant M \leqslant N-1$ 就足够了。对于 $M < N$，最大似然估计量是唯一的。对于 $M \geqslant N$，我们有比数据点更多的参数，并且需要求解一个欠定的线性方程组（(9.19) 中的 $\Phi^\top\Phi$ 也将不再可逆），从而存在无限多个可能的最大似然估计量。

原书 p.299

图 9.5 示出了对图 9.4(a) 中 $N = 10$ 个观测的数据集由最大似然确定的若干多项式拟合。我们注意到，低次多项式（例如常数 ($M = 0$) 或线性 ($M = 1$)）对数据拟合得很差，因此是对真实底层函数的拙劣表示。对于次数 $M = 3, \ldots, 6$，拟合看起来合理且平滑地插值了数据。当我们转向更高次多项式时，我们注意到它们对数据拟合得越来越好。在 $M = N - 1 = 9$ 的极端情形下，函数将经过每一个数据点。然而，这些高次多项式剧烈振荡，是对生成数据的底层函数的拙劣表示，从而我们遭受过拟合。

过拟合

记住，目标是通过对新的（未见）数据做出准确预测来实现良好的泛化。我们通过考虑一个单独的测试集来获得泛化性能对多项式次数 M 之依赖关系的一些定量洞察，该测试集包含 200 个数据点，使用与生成训练集完全相同的过程生成。作为测试输入，我们在区间 $[-5, 5]$ 中选择 200 个点的线性网格。对于 M 的每一种选择，我们对训练数据和测试数据都计算 RMSE (9.23)。

现在查看测试误差，它是相应多项式泛化性质的定性度量，我们注意到测试误差最初下降；见图 9.6（橙色）。对于四次多项式，测试误差相对较低，并且直到五次都保持相对恒定。然而，从六次开始，测试误差显著增加，高阶多项式的泛化性质非常差。在这个特定例子中，这一点从图 9.5 中的相应最大似然拟合中也很明显。注意，当多项式次数增加时，训练误差（图 9.6 中的蓝色训练曲线）从不增加。在我们的例子中，最佳泛化（测试误差最小的点）由四次多项式获得。

训练误差
测试误差

9.2.3　最大后验估计

我们刚刚看到最大似然估计容易过拟合。我们经常观察到，如果我们陷入过拟合，参数值的幅值会变得相对较大（Bishop, 2006）。

为了缓解巨大参数值的影响，我们可以在参数上放置一个先验分布 $p(\boldsymbol{\theta})$。先验分布显式地编码了（在看到任何数据之前）什么样的参数值是合理的。例如，单个参数 θ

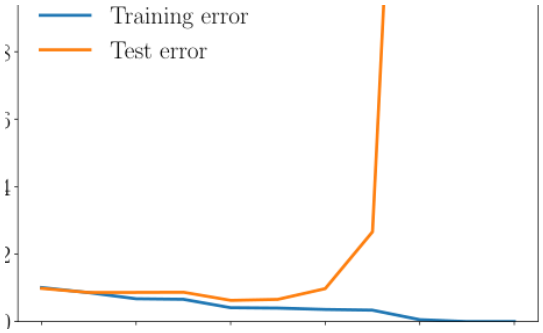


图 9.6: 训练误差与测试误差。（对应原书 Figure 9.6。）

上的高斯先验 $p(\theta) = \mathcal{N}(0, 1)$ 编码了参数值预期落在区间 $[-2, 2]$ 内（均值周围两个标准差）。一旦数据集 $\mathcal{X}, \mathcal{Y}$ 可用，我们不是最大化似然，而是寻求使后验分布 $p(\boldsymbol{\theta} \mid \mathcal{X}, \mathcal{Y})$ 最大化的参数。这个过程称为最大后验（MAP）估计。

最大后验

给定训练数据 $\mathcal{X}, \mathcal{Y}$，参数 $\boldsymbol{\theta}$ 上的后验通过应用贝叶斯定理（6.3 节）得到

$$p(\boldsymbol{\theta} \mid \mathcal{X}, \mathcal{Y}) = \frac{p(\mathcal{Y} \mid \mathcal{X}, \boldsymbol{\theta}) p(\boldsymbol{\theta})}{p(\mathcal{Y} \mid \mathcal{X})}. \tag{9.24}$$

由于后验显式地依赖于参数先验 $p(\boldsymbol{\theta})$，先验将影响我们作为后验最大化者找到的参数向量。我们将在下面更明确地看到这一点。使后验 (9.24) 最大化的参数向量 $\boldsymbol{\theta}_{\text{MAP}}$ 就是 MAP 估计。

为找到 MAP 估计，我们遵循与最大似然估计风格相似的步骤。我们从对数变换开始，计算对数后验为

$$\log p(\boldsymbol{\theta} \mid \mathcal{X}, \mathcal{Y}) = \log p(\mathcal{Y} \mid \mathcal{X}, \boldsymbol{\theta}) + \log p(\boldsymbol{\theta}) + \text{const}, \tag{9.25}$$

其中常数包含与 $\boldsymbol{\theta}$ 无关的项。我们看到 (9.25) 中的对数后验是对数似然 $p(\mathcal{Y} \mid \mathcal{X}, \boldsymbol{\theta})$ 与对数先验 $\log p(\boldsymbol{\theta})$ 之和，因此 MAP 估计将是先验（我们在观测数据之前对合理参数值的建议）与依赖数据的似然之间的一个" 折中"。

原书 p.301

为找到 MAP 估计 $\boldsymbol{\theta}_{\text{MAP}}$，我们关于 $\boldsymbol{\theta}$ 最小化负对数后验分布，即求解

$$\boldsymbol{\theta}_{\text{MAP}} \in \arg\min_{\boldsymbol{\theta}} \{-\log p(\mathcal{Y} \mid \mathcal{X}, \boldsymbol{\theta}) - \log p(\boldsymbol{\theta})\}. \tag{9.26}$$

负对数后验关于 $\boldsymbol{\theta}$ 的梯度为

$$-\frac{\mathrm{d} \log p(\boldsymbol{\theta} \mid \mathcal{X}, \mathcal{Y})}{\mathrm{d}\boldsymbol{\theta}} = -\frac{\mathrm{d} \log p(\mathcal{Y} \mid \mathcal{X}, \boldsymbol{\theta})}{\mathrm{d}\boldsymbol{\theta}} - \frac{\mathrm{d} \log p(\boldsymbol{\theta})}{\mathrm{d}\boldsymbol{\theta}}, \tag{9.27}$$

其中我们将右侧第一项识别为 (9.11c) 中负对数似然的梯度。

对参数 $\boldsymbol{\theta}$ 施加（共轭）高斯先验 $p(\boldsymbol{\theta}) = \mathcal{N}\left(\mathbf{0}, b^2 I\right)$，对于线性回归设定 (9.13)，我们得到负对数后验

$$-\log p(\boldsymbol{\theta} \mid \mathcal{X}, \mathcal{Y}) = \frac{1}{2\sigma^2}(\boldsymbol{y} - \Phi\boldsymbol{\theta})^\top (\boldsymbol{y} - \Phi\boldsymbol{\theta}) + \frac{1}{2b^2}\boldsymbol{\theta}^\top \boldsymbol{\theta} + \text{const}. \tag{9.28}$$

这里，第一项对应于来自对数似然的贡献，第二项来自对数先验。对数后验关于参数 $\boldsymbol{\theta}$ 的梯度为

$$-\frac{\mathrm{d} \log p(\boldsymbol{\theta} \mid \mathcal{X}, \mathcal{Y})}{\mathrm{d}\boldsymbol{\theta}} = \frac{1}{\sigma^2}\left(\boldsymbol{\theta}^\top \Phi^\top \Phi - \boldsymbol{y}^\top \Phi\right) + \frac{1}{b^2}\boldsymbol{\theta}^\top. \tag{9.29}$$

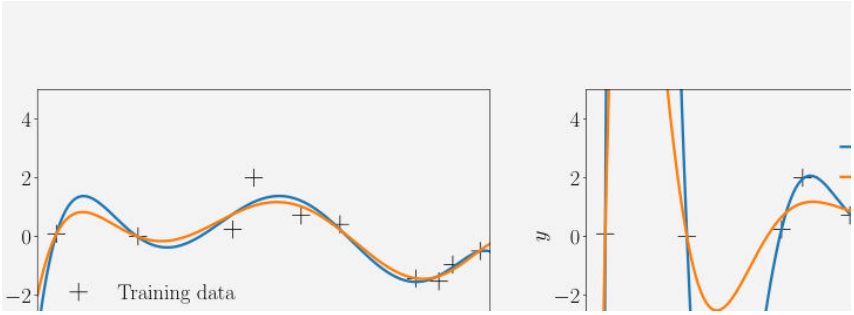


图 9.7: 多项式回归：最大似然估计与 MAP 估计。(a) 六次多项式；(b) 八次多项式。（对应原书 Figure 9.7。）

我们通过令此梯度为 $\mathbf{0}^\top$ 并求解 $\boldsymbol{\theta}_{\text{MAP}}$ 来找到 MAP 估计。我们得到

$$\frac{1}{\sigma^2}\left(\boldsymbol{\theta}^\top\Phi^\top\Phi - \boldsymbol{y}^\top\Phi\right) + \frac{1}{b^2}\boldsymbol{\theta}^\top = \mathbf{0}^\top \tag{9.30a}$$

$$\iff \boldsymbol{\theta}^\top\left(\frac{1}{\sigma^2}\Phi^\top\Phi + \frac{1}{b^2}I\right) - \frac{1}{\sigma^2}\boldsymbol{y}^\top\Phi = \mathbf{0}^\top \tag{9.30b}$$

$$\iff \boldsymbol{\theta}^\top\left(\Phi^\top\Phi + \frac{\sigma^2}{b^2}I\right) = \boldsymbol{y}^\top\Phi \tag{9.30c}$$

$$\iff \boldsymbol{\theta}^\top = \boldsymbol{y}^\top\Phi\left(\Phi^\top\Phi + \frac{\sigma^2}{b^2}I\right)^{-1}, \tag{9.30d}$$

因此 MAP 估计为（将最后一个等式两边转置）

$$\boldsymbol{\theta}_{\text{MAP}} = \left(\Phi^\top\Phi + \frac{\sigma^2}{b^2}I\right)^{-1}\Phi^\top\boldsymbol{y}. \tag{9.31}$$

将 (9.31) 中的 MAP 估计与 (9.19) 中的最大似然估计比较，我们看到两个解之间的唯一区别是逆矩阵中额外的项 $\frac{\sigma^2}{b^2}I$。该项确保 $\Phi^\top\Phi + \frac{\sigma^2}{b^2}I$ 是对称且严格正定的（即其逆存在，且 MAP 估计是线性方程组的唯一解）。此外，它反映了正则化项的影响。 原书 p.302

例 9.6 (多项式回归的 MAP 估计)**.** 在 9.2.1 节的多项式回归例子中，我们在参数 $\boldsymbol{\theta}$ 上放置高斯先验 $p(\boldsymbol{\theta}) = \mathcal{N}(\mathbf{0}, I)$，并根据 (9.31) 确定 MAP 估计。在图 9.7 中，我们同时示出了六次多项式（左）和八次多项式（右）的最大似然估计和 MAP 估计。先验（正则化项）对低次多项式不起显著作用，但对高次多项式使函数保持相对平滑。尽管 MAP 估计可以推移过拟合的边界，但它并不是该问题的通用解，因此我们需要一种更有原则的方法来处理过拟合。

9.2.4　MAP 估计作为正则化

我们也可以不在参数 $\boldsymbol{\theta}$ 上放置先验分布，而是通过正则化惩罚参数的幅值来缓解过拟合的影响。在正则化最小二乘中，我们考虑损失函数

$$\|\boldsymbol{y} - \Phi\boldsymbol{\theta}\|^2 + \lambda\|\boldsymbol{\theta}\|_2^2, \tag{9.32}$$

我们关于 $\boldsymbol{\theta}$ 最小化它（见 8.2.3 节）。这里，第一项是数据拟合项（也称为失配项），它正比于负对数似然；见 (9.10b)。第二项称为正则项，正则化参数 $\lambda \geqslant 0$ 控制正则化的"严格程度"。 正则化 数据拟合项

注。我们可以在 (9.32) 中选择任意 p-范数 $\|\cdot\|_p$ 代替欧几里得范数 $\|\cdot\|_2$。实践中，较小的 p 值导致更稀疏的解。这里，"稀疏"意味着许多参数值 $\theta_d = 0$，这对于变量选择也 原书 p.303

很有用。对于 $p=1$，该正则项称为 LASSO（最小绝对收缩与选择算子），由 Tibshirani (1996) 提出。$\diamond$

(9.32) 中的正则项 $\lambda\|\boldsymbol{\theta}\|_2^2$ 可被解释为负对数高斯先验，我们在 MAP 估计中使用它；见 (9.26)。更具体地，对于高斯先验 $p(\boldsymbol{\theta})=\mathcal{N}\left(\mathbf{0},\, b^2 I\right)$，我们得到负对数高斯先验

$$-\log p(\boldsymbol{\theta})=\frac{1}{2b^2}\|\boldsymbol{\theta}\|_2^2+\text{const}, \tag{9.33}$$

因此当 $\lambda=\frac{1}{2b^2}$ 时，正则化项与负对数高斯先验完全相同。

鉴于 (9.32) 中的正则化最小二乘损失函数由与负对数似然加上负对数先验密切相关的各项组成，当我们最小化此损失时，得到一个与 (9.31) 中 MAP 估计非常相似的解，这并不奇怪。更具体地，最小化正则化最小二乘损失函数得到

$$\boldsymbol{\theta}_{\text{RLS}}=(\Phi^\top\Phi+\lambda I)^{-1}\Phi^\top\boldsymbol{y}, \tag{9.34}$$

当 $\lambda=\frac{\sigma^2}{b^2}$ 时，它与 (9.31) 中的 MAP 估计完全相同，其中 σ^2 是噪声方差，b^2 是各向同性高斯先验 $p(\boldsymbol{\theta})=\mathcal{N}\left(\mathbf{0},\, b^2 I\right)$ 的方差。

到目前为止，我们已经涵盖了使用最大似然和 MAP 估计进行参数估计，其中我们找到了优化目标函数（似然或后验）的点估计 $\boldsymbol{\theta}^*$。我们看到最大似然和 MAP 估计都可能导致过拟合。在下一节中，我们将讨论贝叶斯线性回归，其中我们使用贝叶斯推断（8.4 节）来找到未知参数上的后验分布，随后用它来做预测。更具体地，对于预测，我们将对所有合理的参数集取平均，而不是聚焦于点估计。

9.3　贝叶斯线性回归

先前，我们考察了线性回归模型，其中我们估计了模型参数 $\boldsymbol{\theta}$，例如通过最大似然或 MAP 估计。我们发现 MLE 可能导致严重的过拟合，尤其是在小数据情形下。MAP 通过在参数上放置一个充当正则项角色的先验来解决这个问题。

贝叶斯线性回归

贝叶斯线性回归将参数先验的思想推进一步，甚至不尝试计算参数的点估计，而是在做预测时将参数上的完整后验分布纳入考虑。这意味着我们不拟合任何参数，而是对所有合理的参数设定（根据后验）计算一个均值。

9.3.1　模型

原书 p.304

在贝叶斯线性回归中，我们考虑模型

$$\begin{aligned}\text{先验}\quad & p(\boldsymbol{\theta})=\mathcal{N}(\boldsymbol{\theta}\,|\,\boldsymbol{m}_0,\, S_0)\,,\\ \text{似然}\quad & p(y\,|\,\boldsymbol{x},\boldsymbol{\theta})=\mathcal{N}\left(y\,\middle|\,\phi^\top(\boldsymbol{x})\boldsymbol{\theta},\,\sigma^2\right),\end{aligned} \tag{9.35}$$

其中我们现在显式地在 $\boldsymbol{\theta}$ 上放置高斯先验 $p(\boldsymbol{\theta})=\mathcal{N}(\boldsymbol{m}_0,S_0)$，这将参数向量变成了一个随机变量。这使我们能够写出相应的图模型，见图 9.8，其中我们将 $\boldsymbol{\theta}$ 上高斯先验的参数显式画出。完整的概率模型，即观测和未观测随机变量 y 和 $\boldsymbol{\theta}$ 的联合分布，为

$$p(y,\boldsymbol{\theta}\,|\,\boldsymbol{x})=p(y\,|\,\boldsymbol{x},\boldsymbol{\theta})p(\boldsymbol{\theta}). \tag{9.36}$$

9.3.2　先验预测

实践中，我们通常不太关心参数值 $\boldsymbol{\theta}$ 本身。相反，我们的焦点通常在于用这些参数值做出的预测。在贝叶斯设定中，我们取参数分布，并在做预测时对所有合理的参数设

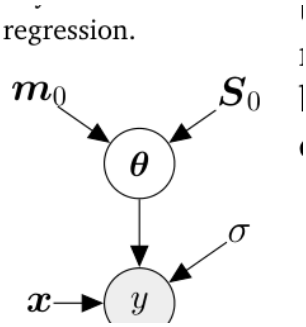


图 9.8: 贝叶斯线性回归的图模型。（对应原书 Figure 9.8。）

定取平均。更具体地，为在输入 $\boldsymbol{x}^*$ 处做预测，我们将 $\boldsymbol{\theta}$ 积出，得到

$$p(y^* \mid \boldsymbol{x}^*) = \int p(y^* \mid \boldsymbol{x}^*, \boldsymbol{\theta}) p(\boldsymbol{\theta}) \, \mathrm{d}\theta = \mathbb{E}_{\boldsymbol{\theta}}[p(y^* \mid \boldsymbol{x}^*, \boldsymbol{\theta})], \tag{9.37}$$

我们可以将其解释为：根据先验分布 $p(\boldsymbol{\theta})$，对所有合理参数 $\boldsymbol{\theta}$，$y^* \mid \boldsymbol{x}^*, \boldsymbol{\theta}$ 的平均预测。注意，仅使用先验分布的预测只要求我们指定输入 $\boldsymbol{x}^*$，而不需要训练数据。

在我们的模型 (9.35) 中，我们在 $\boldsymbol{\theta}$ 上选择了共轭（高斯）先验，因此预测分布也是高斯的（并且可以闭式计算）：对于先验分布 $p(\boldsymbol{\theta}) = \mathcal{N}(\boldsymbol{m}_0, S_0)$，我们得到预测分布为

$$p(y^* \mid \boldsymbol{x}^*) = \mathcal{N}\big(y^* \,\big|\, \phi^\top(\boldsymbol{x}^*)\boldsymbol{m}_0,\ \phi^\top(\boldsymbol{x}^*) S_0 \phi(\boldsymbol{x}^*) + \sigma^2\big)\,, \tag{9.38}$$

其中我们利用了：(i) 由于共轭性（见 6.6 节）和高斯的边缘化性质（见 6.5 节），预测是高斯的；(ii) 高斯噪声独立，因此

$$\mathbb{V}[y^*] = \mathbb{V}_{\boldsymbol{\theta}}[\phi^\top(\boldsymbol{x}^*)\boldsymbol{\theta}] + \mathbb{V}_\epsilon[\epsilon]; \tag{9.39}$$

(iii) y^* 是 $\boldsymbol{\theta}$ 的线性变换，因此我们可以分别使用 (6.50) 和 (6.51) 解析地应用计算预测均值和协方差的规则。在 (9.38) 中，预测方差中的项 $\phi^\top(\boldsymbol{x}^*) S_0 \phi(\boldsymbol{x}^*)$ 显式地考虑了与参数 $\boldsymbol{\theta}$ 相关的不确定性，而 σ^2 是由测量噪声引起的不确定性贡献。

原书 p.305

如果我们感兴趣的是预测无噪函数值 $f(\boldsymbol{x}^*) = \phi^\top(\boldsymbol{x}^*)\boldsymbol{\theta}$，而不是含噪目标 y^*，我们得到

$$p(f(\boldsymbol{x}^*)) = \mathcal{N}\big(f(\boldsymbol{x}^*) \,\big|\, \phi^\top(\boldsymbol{x}^*)\boldsymbol{m}_0,\ \phi^\top(\boldsymbol{x}^*) S_0 \phi(\boldsymbol{x}^*)\big)\,, \tag{9.40}$$

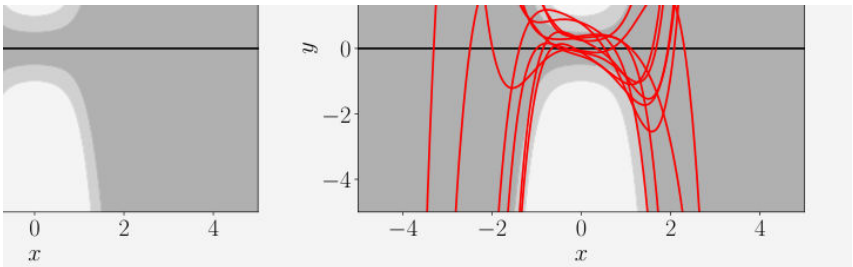
它与 (9.38) 的区别仅在于预测方差中省略了噪声方差 σ^2。

注（函数上的分布）。由于我们可以用一组样本 $\boldsymbol{\theta}_i$ 表示分布 $p(\boldsymbol{\theta})$，且每个样本 $\boldsymbol{\theta}_i$ 产生一个函数 $f_i(\cdot) = \boldsymbol{\theta}_i^\top \phi(\cdot)$，由此可知参数分布 $p(\boldsymbol{\theta})$ 诱导了函数上的一个分布 $p(f(\cdot))$。这里我们使用记号 $(\cdot)$ 来显式表示函数关系。$\diamond$

例 9.7 (函数上的先验)**.** 让我们考虑一个五次多项式的贝叶斯线性回归问题。我们选择参数先验 $p(\boldsymbol{\theta}) = \mathcal{N}\big(\mathbf{0}, \frac{1}{4} I\big)$。图 9.9 可视化了由此参数先验诱导的函数上的先验分布（阴影区域：深灰：67% 置信界；浅灰：95% 置信界），包括来自该先验的一些函数样本。

一个函数样本通过首先采样参数向量 $\boldsymbol{\theta}_i \sim p(\boldsymbol{\theta})$，然后计算 $f_i(\cdot) = \boldsymbol{\theta}_i^\top \phi(\cdot)$ 获得。我们使用 200 个输入位置 $x^* \in [-5, 5]$，对其应用特征函数 $\phi(\cdot)$。图 9.9 中的不确定性（由阴影区域表示）完全来自参数不确定性，因为我们考虑的是无噪预测分布 (9.40)。

到目前为止，我们考察了使用参数先验 $p(\boldsymbol{\theta})$ 计算预测。然而，当我们有了参数后验（给定一些训练数据 $\mathcal{X}, \mathcal{Y}$）时，预测和推断的相同原理仍然成立，如 (9.37) 所示——我们只需将先验 $p(\boldsymbol{\theta})$ 替换为后验 $p(\boldsymbol{\theta} \mid \mathcal{X}, \mathcal{Y})$。在下文中，我们将详细推导后验分布，然后用它来做预测。



ion over functions.　(b) Samples from the prior distribution over

图 9.9: 函数上的先验。(a) 由均值函数（黑线）和边缘不确定性（阴影）表示的函数上的分布，分别表示 67% 和 95% 置信界；(b) 函数上先验的样本，它们由参数先验的样本诱导。（对应原书 Figure 9.9。）

9.3.3　后验分布

原书 p.306

给定训练输入集 $\boldsymbol{x}_n \in \mathbb{R}^D$ 和相应观测 $y_n \in \mathbb{R}$，$n = 1, \ldots, N$，我们使用贝叶斯定理计算参数上的后验为

$$p(\boldsymbol{\theta} \mid \mathcal{X}, \mathcal{Y}) = \frac{p(\mathcal{Y} \mid \mathcal{X}, \boldsymbol{\theta}) p(\boldsymbol{\theta})}{p(\mathcal{Y} \mid \mathcal{X})}, \tag{9.41}$$

其中 $\mathcal{X}$ 是训练输入集，$\mathcal{Y}$ 是相应训练目标的集合。此外，$p(\mathcal{Y} \mid \mathcal{X}, \boldsymbol{\theta})$ 是似然，$p(\boldsymbol{\theta})$ 是参数先验，

$$p(\mathcal{Y} \mid \mathcal{X}) = \int p(\mathcal{Y} \mid \mathcal{X}, \boldsymbol{\theta}) p(\boldsymbol{\theta}) \, \mathrm{d}\boldsymbol{\theta} = \mathbb{E}_{\boldsymbol{\theta}}[p(\mathcal{Y} \mid \mathcal{X}, \boldsymbol{\theta})] \tag{9.42}$$

是边际似然/证据，它与参数 $\boldsymbol{\theta}$ 无关，并确保后验是归一化的，即它积分到 1。我们可以将边际似然看作对所有可能参数设定（关于先验分布 $p(\boldsymbol{\theta})$）平均后的似然。

边际似然
证据

定理 9.1 (参数后验)**.** 在我们的模型 *(9.35)* 中，参数后验 *(9.41)* 可以闭式计算为

$$p(\boldsymbol{\theta} \mid \mathcal{X}, \mathcal{Y}) = \mathcal{N}(\boldsymbol{\theta} \mid \boldsymbol{m}_N, S_N), \tag{9.43a}$$

$$S_N = \left(S_0^{-1} + \sigma^{-2} \Phi^\top \Phi\right)^{-1}, \tag{9.43b}$$

$$\boldsymbol{m}_N = S_N \left(S_0^{-1} \boldsymbol{m}_0 + \sigma^{-2} \Phi^\top \boldsymbol{y}\right), \tag{9.43c}$$

其中下标 N 表示训练集的大小。

证明。贝叶斯定理告诉我们，后验 $p(\boldsymbol{\theta} \mid \mathcal{X}, \mathcal{Y})$ 正比于似然 $p(\mathcal{Y} \mid \mathcal{X}, \boldsymbol{\theta})$ 与先验 $p(\boldsymbol{\theta})$ 的乘积：

$$\text{后验} \quad p(\boldsymbol{\theta} \mid \mathcal{X}, \mathcal{Y}) = \frac{p(\mathcal{Y} \mid \mathcal{X}, \boldsymbol{\theta}) p(\boldsymbol{\theta})}{p(\mathcal{Y} \mid \mathcal{X})} \tag{9.44a}$$

$$\text{似然} \quad p(\mathcal{Y} \mid \mathcal{X}, \boldsymbol{\theta}) = \mathcal{N}\left(\boldsymbol{y} \,\middle|\, \Phi\boldsymbol{\theta}, \sigma^2 I\right) \tag{9.44b}$$

$$\text{先验} \quad p(\boldsymbol{\theta}) = \mathcal{N}(\boldsymbol{\theta} \mid \boldsymbol{m}_0, S_0). \tag{9.44c}$$

我们不考察先验与似然的乘积，而是可以将问题变换到对数空间，并通过配方法求解后验的均值和协方差。对数先验与对数似然之和为

$$\log \mathcal{N}\left(\boldsymbol{y} \,\middle|\, \Phi\boldsymbol{\theta}, \sigma^2 I\right) + \log \mathcal{N}(\boldsymbol{\theta} \mid \boldsymbol{m}_0, S_0) \tag{9.45a}$$

$$= -\frac{1}{2}\left[\sigma^{-2}(\boldsymbol{y} - \Phi\boldsymbol{\theta})^\top (\boldsymbol{y} - \Phi\boldsymbol{\theta}) + (\boldsymbol{\theta} - \boldsymbol{m}_0)^\top S_0^{-1} (\boldsymbol{\theta} - \boldsymbol{m}_0)\right] + \text{const}, \tag{9.45b}$$

其中常数包含与 $\boldsymbol{\theta}$ 无关的项。我们在下文中忽略常数。现在我们展开 (9.45b)，得到

原书 p.307

$$-\frac{1}{2}\Big[\sigma^{-2}\boldsymbol{y}^\top\boldsymbol{y}-2\sigma^{-2}\boldsymbol{y}^\top\Phi\boldsymbol{\theta}+\boldsymbol{\theta}^\top\sigma^{-2}\Phi^\top\Phi\boldsymbol{\theta}+\boldsymbol{\theta}^\top S_0^{-1}\boldsymbol{\theta} \tag{9.46a}$$

$$-2\boldsymbol{m}_0^\top S_0^{-1}\boldsymbol{\theta}+\boldsymbol{m}_0^\top S_0^{-1}\boldsymbol{m}_0\Big]$$

$$=-\frac{1}{2}\left[\boldsymbol{\theta}^\top\left(\sigma^{-2}\Phi^\top\Phi+S_0^{-1}\right)\boldsymbol{\theta}-2\left(\sigma^{-2}\Phi^\top\boldsymbol{y}+S_0^{-1}\boldsymbol{m}_0\right)^\top\boldsymbol{\theta}\right]+\text{const}, \tag{9.46b}$$

其中常数包含 (9.46a) 中与 $\boldsymbol{\theta}$ 无关的黑色项。橙色项是关于 $\boldsymbol{\theta}$ 线性的项，蓝色项是关于 $\boldsymbol{\theta}$ 二次的项。考察 (9.46b)，我们发现该方程关于 $\boldsymbol{\theta}$ 是二次的。未归一化的对数后验分布是一个（负）二次型这一事实意味着后验是高斯的，即

$$p(\boldsymbol{\theta}\mid\mathcal{X},\mathcal{Y})=\exp(\log p(\boldsymbol{\theta}\mid\mathcal{X},\mathcal{Y}))\propto\exp\big(\log p(\mathcal{Y}\mid\mathcal{X},\boldsymbol{\theta})+\log p(\boldsymbol{\theta})\big) \tag{9.47a}$$

$$\propto\exp\left(-\frac{1}{2}\left[\boldsymbol{\theta}^\top\left(\sigma^{-2}\Phi^\top\Phi+S_0^{-1}\right)\boldsymbol{\theta}-2\left(\sigma^{-2}\Phi^\top\boldsymbol{y}+S_0^{-1}\boldsymbol{m}_0\right)^\top\boldsymbol{\theta}\right]\right), \tag{9.47b}$$

其中最后一个表达式中使用了 (9.46b)。

剩余的任务是将这个（未归一化的）高斯变换为正比于 $\mathcal{N}(\boldsymbol{\theta}\mid\boldsymbol{m}_N,S_N)$ 的形式，即我们需要识别均值 $\boldsymbol{m}_N$ 和协方差矩阵 S_N。为此，我们使用配方法的概念。所需的对数后验为

配方法

$$\log\mathcal{N}(\boldsymbol{\theta}\,|\,\boldsymbol{m}_N,\,S_N)=-\frac{1}{2}(\boldsymbol{\theta}-\boldsymbol{m}_N)^\top S_N^{-1}(\boldsymbol{\theta}-\boldsymbol{m}_N)+\text{const} \tag{9.48a}$$

$$=-\frac{1}{2}\left[\boldsymbol{\theta}^\top S_N^{-1}\boldsymbol{\theta}-2\boldsymbol{m}_N^\top S_N^{-1}\boldsymbol{\theta}+\boldsymbol{m}_N^\top S_N^{-1}\boldsymbol{m}_N\right]. \tag{9.48b}$$

这里，我们将二次型 $(\boldsymbol{\theta}-\boldsymbol{m}_N)^\top S_N^{-1}(\boldsymbol{\theta}-\boldsymbol{m}_N)$ 分解为一个仅关于 $\boldsymbol{\theta}$ 二次的项（蓝色）、一个关于 $\boldsymbol{\theta}$ 线性的项（橙色）和一个常数项（黑色）。这使我们现在能够通过匹配 (9.46b) 和 (9.48b) 中的彩色表达式来找到 S_N 和 $\boldsymbol{m}_N$，得到

$$S_N^{-1}=\Phi^\top\sigma^{-2}I\Phi+S_0^{-1} \tag{9.49a}$$

$$\iff S_N=\left(\sigma^{-2}\Phi^\top\Phi+S_0^{-1}\right)^{-1} \tag{9.49b}$$

和

$$\boldsymbol{m}_N^\top S_N^{-1}=\left(\sigma^{-2}\Phi^\top\boldsymbol{y}+S_0^{-1}\boldsymbol{m}_0\right)^\top \tag{9.50a}$$

$$\iff\boldsymbol{m}_N=S_N\left(\sigma^{-2}\Phi^\top\boldsymbol{y}+S_0^{-1}\boldsymbol{m}_0\right). \tag{9.50b}$$

◇

原书 p.308

注（配方法的一般方法）。如果我们给定一个方程

$$\boldsymbol{x}^\top A\boldsymbol{x}-2\boldsymbol{a}^\top\boldsymbol{x}+\text{const}_1, \tag{9.51}$$

其中 A 对称正定，我们希望将其变换为形式

$$(\boldsymbol{x}-\boldsymbol{\mu})^\top\Sigma(\boldsymbol{x}-\boldsymbol{\mu})+\text{const}_2, \tag{9.52}$$

我们可以通过令

$$\Sigma:=A, \tag{9.53}$$

$$\boldsymbol{\mu}:=\Sigma^{-1}\boldsymbol{a} \tag{9.54}$$

来做到这一点，且 $\text{const}_2=\text{const}_1-\boldsymbol{\mu}^\top\Sigma\boldsymbol{\mu}$。◇

我们可以看到 (9.47b) 指数内的各项属于 (9.51) 的形式，其中

$$A:=\sigma^{-2}\Phi^\top\Phi+S_0^{-1}, \tag{9.55}$$

$$\boldsymbol{a}:=\sigma^{-2}\Phi^\top\boldsymbol{y}+S_0^{-1}\boldsymbol{m}_0. \tag{9.56}$$

由于 $A,\boldsymbol{a}$ 在像 (9.46a) 这样的方程中可能难以识别，将这些方程变换为 (9.51) 的形式通常很有帮助，它将二次项、线性项和常数解耦，从而简化了寻找所需解的过程。

9.3.4　后验预测

在 (9.37) 中，我们使用参数先验 $p(\boldsymbol{\theta})$ 计算了测试输入 $\boldsymbol{x}^*$ 处 y^* 的预测分布。原则上，使用参数后验 $p(\boldsymbol{\theta} \mid \mathcal{X}, \mathcal{Y})$ 进行预测并没有根本不同，因为在我们的共轭模型中，先验和后验都是高斯的（参数不同）。因此，通过遵循与 9.3.2 节相同的推理，我们得到（后验）预测分布

$$p(y^* \mid \mathcal{X}, \mathcal{Y}, \boldsymbol{x}^*) = \int p(y^* \mid \boldsymbol{x}^*, \boldsymbol{\theta}) p(\boldsymbol{\theta} \mid \mathcal{X}, \mathcal{Y}) \, \mathrm{d}\boldsymbol{\theta} \tag{9.57a}$$

$$= \int \mathcal{N}\left(y^* \,\middle|\, \phi^\top(\boldsymbol{x}^*)\boldsymbol{\theta}, \, \sigma^2\right) \mathcal{N}(\boldsymbol{\theta} \,|\, \boldsymbol{m}_N, \, S_N) \, \mathrm{d}\boldsymbol{\theta} \tag{9.57b}$$

$$= \mathcal{N}\left(y^* \,\middle|\, \phi^\top(\boldsymbol{x}^*)\boldsymbol{m}_N, \, \phi^\top(\boldsymbol{x}^*) S_N \phi(\boldsymbol{x}^*) + \sigma^2\right). \tag{9.57c}$$

项 $\phi^\top(\boldsymbol{x}^*) S_N \phi(\boldsymbol{x}^*)$ 反映了与参数 $\boldsymbol{\theta}$ 相关的后验不确定性。注意 S_N 通过 Φ 依赖于训练输入；见 (9.43b)。预测均值 $\phi^\top(\boldsymbol{x}^*)\boldsymbol{m}_N$ 与使用 MAP 估计 $\boldsymbol{\theta}_{\text{MAP}}$ 做出的预测一致。

原书 p.309

注（边际似然与后验预测分布）。通过替换 (9.57a) 中的积分，预测分布可以等价地写为期望 $\mathbb{E}_{\boldsymbol{\theta}|\mathcal{X},\mathcal{Y}}[p(y^* \mid \boldsymbol{x}^*, \boldsymbol{\theta})]$，其中期望是关于参数后验 $p(\boldsymbol{\theta} \mid \mathcal{X}, \mathcal{Y})$ 取的。以这种方式写出后验预测分布，凸显了它与边际似然 (9.42) 的密切相似性。边际似然与后验预测分布之间的关键区别是：(i) 边际似然可以被看作是预测训练目标 $\boldsymbol{y}$ 而不是测试目标 y^*；(ii) 边际似然关于参数先验取平均，而不是关于参数后验。$\diamond$

注（无噪函数值的均值和方差）。在许多情况下，我们对（含噪）观测 y^* 的预测分布 $p(y^* \mid \mathcal{X}, \mathcal{Y}, \boldsymbol{x}^*)$ 不感兴趣。相反，我们希望获得（无噪）函数值 $f(\boldsymbol{x}^*) = \phi^\top(\boldsymbol{x}^*)\boldsymbol{\theta}$ 的分布。我们通过利用均值和方差的性质确定相应的矩，得到

$$\mathbb{E}[f(\boldsymbol{x}^*) \mid \mathcal{X}, \mathcal{Y}] = \mathbb{E}_{\boldsymbol{\theta}}[\phi^\top(\boldsymbol{x}^*)\boldsymbol{\theta} \mid \mathcal{X}, \mathcal{Y}] = \phi^\top(\boldsymbol{x}^*)\mathbb{E}_{\boldsymbol{\theta}}[\boldsymbol{\theta} \mid \mathcal{X}, \mathcal{Y}] = \phi^\top(\boldsymbol{x}^*)\boldsymbol{m}_N = \boldsymbol{m}_N^\top \phi(\boldsymbol{x}^*), \tag{9.58}$$

$$\mathbb{V}_{\boldsymbol{\theta}}[f(\boldsymbol{x}^*) \mid \mathcal{X}, \mathcal{Y}] = \mathbb{V}_{\boldsymbol{\theta}}[\phi^\top(\boldsymbol{x}^*)\boldsymbol{\theta} \mid \mathcal{X}, \mathcal{Y}] = \phi^\top(\boldsymbol{x}^*)\mathbb{V}_{\boldsymbol{\theta}}[\boldsymbol{\theta} \mid \mathcal{X}, \mathcal{Y}]\phi(\boldsymbol{x}^*) = \phi^\top(\boldsymbol{x}^*) S_N \phi(\boldsymbol{x}^*). \tag{9.59}$$

我们看到，预测均值与含噪观测的预测均值相同，因为噪声均值为 0，而预测方差仅相差 σ^2，即测量噪声的方差：当我们预测含噪函数值时，我们需要将 σ^2 作为不确定性的一个来源包含进来，但对于无噪预测不需要此项。这里，剩余的不确定性仅来自参数后验。$\diamond$

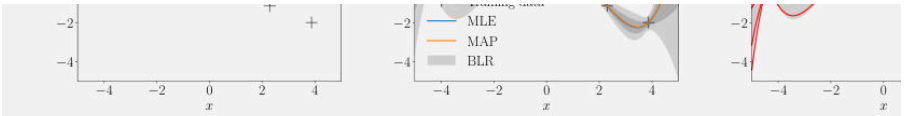
注（函数上的分布）。我们将参数 $\boldsymbol{\theta}$ 积出这一事实诱导了函数上的一个分布：如果我们从参数后验采样 $\boldsymbol{\theta}_i \sim p(\boldsymbol{\theta} \mid \mathcal{X}, \mathcal{Y})$，我们得到一个单一的函数实现 $\boldsymbol{\theta}_i^\top \phi(\cdot)$。这个函数上分布的均值函数，即所有期望函数值 $\mathbb{E}_{\boldsymbol{\theta}}[f(\cdot) \mid \boldsymbol{\theta}, \mathcal{X}, \mathcal{Y}]$ 的集合，是 $\boldsymbol{m}_N^\top \phi(\cdot)$。（边缘）方差，即函数 $f(\cdot)$ 的方差，由 $\phi^\top(\cdot) S_N \phi(\cdot)$ 给出。$\diamond$

例 9.8 (函数上的后验)**.** 让我们回到五次多项式的贝叶斯线性回归问题。我们选择参数先验 $p(\boldsymbol{\theta}) = \mathcal{N}\left(\mathbf{0}, \, \frac{1}{4} I\right)$。图 9.10 示出了我们通过贝叶斯线性回归获得的函数上的后验。训练数据集显示在面板 (a) 中；面板 (b) 示出了函数上的后验分布，包括我们通过最大似然和 MAP 估计获得的函数。我们使用 MAP 估计获得的函数也对应于贝叶斯线性回归设定中的后验均值函数。面板 (c) 示出了该函数上后验下函数的一些合理实现（样本）。

原书 p.310

图 9.11 示出了由参数后验诱导的一些函数上的后验分布。对于不同的多项式次数 M，左面板示出了最大似然函数 $\boldsymbol{\theta}_{\text{ML}}^\top \phi(\cdot)$、MAP 函数 $\boldsymbol{\theta}_{\text{MAP}}^\top \phi(\cdot)$（与后验均值函数相同），以及由贝叶斯线性回归获得的 67% 和 95% 预测置信界，由阴影区域表示。

右面板示出了函数上后验的样本：这里，我们从参数后验采样参数 $\boldsymbol{\theta}_i$，并计算函数 $\phi^\top(\boldsymbol{x}^*)\boldsymbol{\theta}_i$，它是函数上后验分布下的一个单一函数实现。对于低次多项式，参数后验不允许参数变化太多：采样的函数几乎相同。当我们通过添加更多参数使模型更灵活



(a) Training data.

(b) Posterior over functions represented by the marginal uncertainties (shaded) showing the 67% and 95% predictive confidence bounds, the maximum

(c) Samples from t over functions, wh duced by the samp parameter posterio

图 9.10: 贝叶斯线性回归与函数上的后验。(a) 训练数据；(b) 由边缘不确定性（阴影）表示的函数上的后验分布，显示 67% 和 95% 预测置信界，以及最大似然估计（MLE）和 MAP 估计（MAP），后者与后验均值函数相同；(c) 函数上后验的样本，它们由参数后验的样本诱导。（对应原书 Figure 9.10。）

时（即得到更高次多项式），这些参数不受后验充分约束，采样的函数可以容易地在视觉上区分开。我们在相应的左面板中也看到不确定性如何增加，尤其是在边界处。

尽管对于七次多项式，MAP 估计给出了合理的拟合，但贝叶斯线性回归模型额外告诉我们，后验不确定性巨大。当我们在决策系统中使用这些预测时，这个信息可能至关重要，因为错误的决策可能产生重大后果（例如在强化学习或机器人学中）。

原书 p.311

9.3.5　计算边际似然

原书 p.312

在 8.6.2 节中，我们强调了边际似然对贝叶斯模型选择的重要性。在下文中，我们计算在参数上具有共轭高斯先验的贝叶斯线性回归的边际似然，即正是我们本章一直在讨论的设定。

简要回顾，我们考虑如下生成过程：

$$\boldsymbol{\theta} \sim \mathcal{N}(\boldsymbol{m}_0, S_0) \tag{9.60a}$$

$$y_n \mid \boldsymbol{x}_n, \boldsymbol{\theta} \sim \mathcal{N}\left(\boldsymbol{x}_n^\top \boldsymbol{\theta}, \sigma^2\right), \tag{9.60b}$$

$n = 1, \ldots, N$。边际似然由下式给出

$$p(\mathcal{Y} \mid \mathcal{X}) = \int p(\mathcal{Y} \mid \mathcal{X}, \boldsymbol{\theta}) p(\boldsymbol{\theta}) \, \mathrm{d}\boldsymbol{\theta} \tag{9.61a}$$

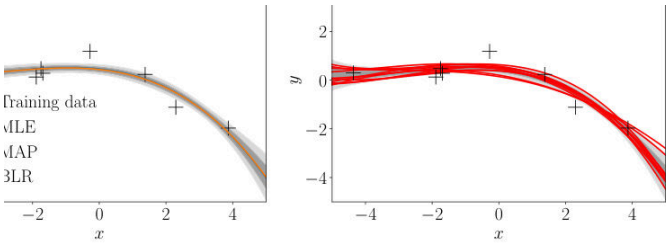
$$= \int \mathcal{N}\left(\boldsymbol{y} \,|\, X\boldsymbol{\theta}, \sigma^2 I\right) \mathcal{N}(\boldsymbol{\theta} \,|\, \boldsymbol{m}_0, S_0) \, \mathrm{d}\boldsymbol{\theta}, \tag{9.61b}$$

其中我们将模型参数 $\boldsymbol{\theta}$ 积出。我们分两步计算边际似然：首先，我们证明边际似然是高斯的（作为 $\boldsymbol{y}$ 的分布）；其次，我们计算该高斯的均值和协方差。

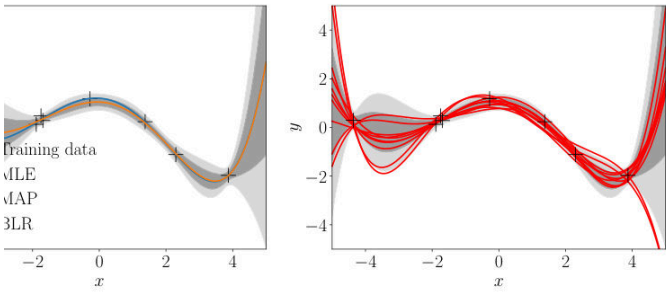
1. **边际似然是高斯的：**由 6.5.2 节，我们知道 (i) 两个高斯随机变量的乘积是一个（未归一化的）高斯分布；(ii) 高斯随机变量的线性变换服从高斯分布。在 (9.61b) 中，我们需要一个线性变换将 $\mathcal{N}(\boldsymbol{y} \mid X\boldsymbol{\theta}, \sigma^2 I)$ 变换为 $\mathcal{N}(\boldsymbol{\theta} \mid \boldsymbol{\mu}, \Sigma)$ 的形式（对某个 $\boldsymbol{\mu}, \Sigma$）。一旦完成，积分就可以闭式求解。结果是两个高斯乘积的归一化常数。归一化常数本身具有高斯形状；见 (6.76)。

2. **均值和协方差。**我们利用随机变量仿射变换的均值和协方差的标准结果，计算边际似然的均值和协方差矩阵；见 6.4.4 节。边际似然的均值计算为

$$\mathbb{E}[\mathcal{Y} \mid \mathcal{X}] = \mathbb{E}_{\boldsymbol{\theta}, \epsilon}[X\boldsymbol{\theta} + \epsilon] = X \, \mathbb{E}_{\boldsymbol{\theta}}[\boldsymbol{\theta}] = X\boldsymbol{m}_0. \tag{9.62}$$



istribution for polynomials of degree $M = 3$ (left) and samples from the pos-
:tions (right).



listribution for polynomials of degree $M = 5$ (left) and samples from the
functions (right).

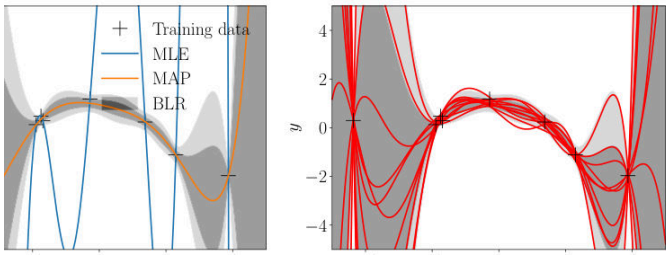


图 9.11: 贝叶斯线性回归。左面板：阴影区域表示 67%（深灰）和 95%（浅灰）预测置信界。贝叶斯线性回归模型的均值与 MAP 估计一致。预测不确定性是噪声项和后验参数不确定性之和，后者依赖于测试输入的位置。右面板：从后验分布采样的函数。(a) $M = 3$；(b) $M = 5$；(c) $M = 7$。（对应原书 Figure 9.11。）

注意 $\epsilon \sim \mathcal{N}(0, \sigma^2 I)$ 是一个 i.i.d. 随机变量向量。协方差矩阵为

$$\begin{aligned} \mathrm{Cov}[\mathcal{Y} \mid \mathcal{X}] &= \mathrm{Cov}_{\boldsymbol{\theta},\epsilon}[X\boldsymbol{\theta} + \epsilon] = \mathrm{Cov}_{\boldsymbol{\theta}}[X\boldsymbol{\theta}] + \sigma^2 I & \text{(9.63a)} \\ &= X\ \mathrm{Cov}_{\boldsymbol{\theta}}[\boldsymbol{\theta}] X^\top + \sigma^2 I = X S_0 X^\top + \sigma^2 I. & \text{(9.63b)} \end{aligned}$$

因此，边际似然为

$$\begin{aligned} p(\mathcal{Y} \mid \mathcal{X}) &= (2\pi)^{-N/2} \det(X S_0 X^\top + \sigma^2 I)^{-1/2} & \text{(9.64a)} \\ &\quad \cdot \exp\left(-\frac{1}{2} (\boldsymbol{y} - X\boldsymbol{m}_0)^\top (X S_0 X^\top + \sigma^2 I)^{-1} (\boldsymbol{y} - X\boldsymbol{m}_0) \right) \\ &= \mathcal{N}\left(\boldsymbol{y} \,\middle|\, X\boldsymbol{m}_0,\ X S_0 X^\top + \sigma^2 I \right). & \text{(9.64b)} \end{aligned}$$

鉴于与后验预测分布的密切联系（见本节前面关于边际似然与后验预测分布的注），边际似然的函数形式不应太令人惊讶。

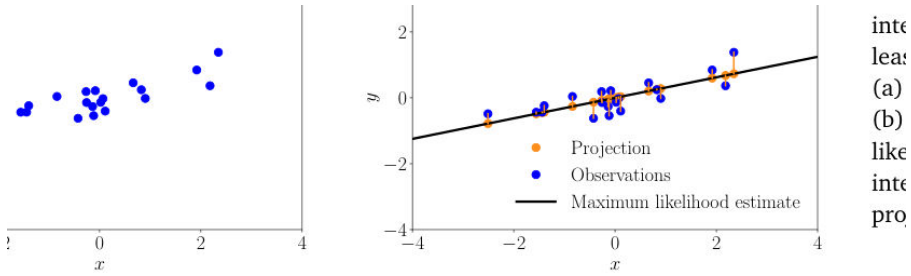


图 9.12: 最小二乘的几何解释。(a) 回归数据集，由输入位置 x_n 处函数值 $f(x_n)$ 的含噪观测 y_n（蓝点）组成；(b) 橙点是含噪观测（蓝点）到直线 $\theta_{\mathrm{ML}}x$ 上的投影。线性回归问题的最大似然解找到了一个子空间（直线），使观测的整体投影误差（橙线）最小化。（对应原书 Figure 9.12。）

9.4　最大似然作为正交投影

在推导出最大似然和 MAP 估计的大量代数运算之后，我们现在提供最大似然估计的几何解释。让我们考虑一个简单的线性回归设定

$$y = x\theta + \epsilon, \qquad \epsilon \sim \mathcal{N}\left(0, \sigma^2\right), \tag{9.65}$$

其中我们考虑过原点的线性函数 $f : \mathbb{R} \to \mathbb{R}$（为清晰起见，这里省略特征）。参数 θ 决定直线的斜率。图 9.12(a) 示出了一个一维数据集。

原书 p.313

给定训练集 $\{(x_1, y_1), \ldots, (x_N, y_N)\}$，我们回顾 9.2.1 节的结果，得到斜率参数的最大似然估计量为

$$\theta_{\mathrm{ML}} = (X^\top X)^{-1} X^\top \boldsymbol{y} = \frac{X^\top \boldsymbol{y}}{X^\top X} \in \mathbb{R}, \tag{9.66}$$

其中 $X = [x_1, \ldots, x_N]^\top \in \mathbb{R}^N$，$\boldsymbol{y} = [y_1, \ldots, y_N]^\top \in \mathbb{R}^N$。

这意味着对于训练输入 X，我们得到训练目标的最优（最大似然）重构为

$$X\theta_{\mathrm{ML}} = X\frac{X^\top \boldsymbol{y}}{X^\top X} = \frac{XX^\top}{X^\top X}\boldsymbol{y}, \tag{9.67}$$

即我们得到 $\boldsymbol{y}$ 与 $X\boldsymbol{\theta}$ 之间最小最小二乘误差的逼近。

原书 p.314

由于我们在寻找 $y = X\theta$ 的解，我们可以将线性回归看作求解线性方程组的问题。因此，我们可以联系到第 2 章和第 3 章中讨论的线性代数和解析几何的概念。特别地，仔细考察 (9.67)，我们看到在 (9.65) 的例子中，最大似然估计量 θ_{ML} 实际上是将 $\boldsymbol{y}$ 正交投影到由 X 张成的一维子空间上。回顾 3.8 节关于正交投影的结果，我们将 $\frac{XX^\top}{X^\top X}$ 识别为投影矩阵，将 θ_{ML} 识别为投影到 X 所张成的 $\mathbb{R}^N$ 一维子空间上的坐标，将 $X\theta_{\mathrm{ML}}$ 识别为 $\boldsymbol{y}$ 到该子空间的正交投影。

正交投影

因此，最大似然解通过在 X 所张成的子空间中找到与相应观测 $\boldsymbol{y}$" 最接近" 的向量，也提供了几何上最优的解，其中" 最接近" 意味着函数值 y_n 到 $x_n\theta$ 的（平方）距离最小。这是通过正交投影实现的。图 9.12(b) 示出了含噪观测到使原始数据集与其投影之间平方距离最小的子空间上的投影（注意 x 坐标是固定的），它对应于最大似然解。

在一般的线性回归情形中，

$$y = \phi^\top(\boldsymbol{x})\boldsymbol{\theta} + \epsilon, \qquad \epsilon \sim \mathcal{N}\left(0, \sigma^2\right), \tag{9.68}$$

具有向量值特征 $\phi(\boldsymbol{x}) \in \mathbb{R}^K$，我们同样可以将最大似然结果

$$\boldsymbol{y} \approx \Phi\boldsymbol{\theta}_{\mathrm{ML}}, \tag{9.69}$$

$$\boldsymbol{\theta}_{\mathrm{ML}} = (\Phi^\top \Phi)^{-1} \Phi^\top \boldsymbol{y} \tag{9.70}$$

解释为投影到 $\mathbb{R}^N$ 的一个 K 维子空间上，该子空间由特征矩阵 Φ 的列张成；见 3.8.2 节。

如果我们用来构造特征矩阵 Φ 的特征函数 ϕ_k 是标准正交的（见 3.7 节），我们得到一个特殊情形，其中 Φ 的列构成一个标准正交基（见 3.5 节），使得 $\Phi^\top \Phi = I$。这将导致投影

$$\Phi(\Phi^\top \Phi)^{-1} \Phi^\top \boldsymbol{y} = \Phi \Phi^\top \boldsymbol{y} = \left(\sum_{k=1}^{K} \phi_k \phi_k^\top \right) \boldsymbol{y}, \tag{9.71}$$

因此最大似然投影简单地就是 $\boldsymbol{y}$ 到各个基向量 ϕ_k（即 Φ 的列）上的投影之和。此外，由于基的正交性，不同特征之间的耦合消失了。信号处理中许多流行的基函数，例如小波和傅里叶基，都是正交基函数。

原书 p.315

当基不是正交的时，可以使用 Gram-Schmidt 过程将一组线性无关的基函数转换为正交基；见 3.8.3 节和 (Strang, 2003)。

9.5　进一步阅读

在本章中，我们讨论了针对高斯似然和模型参数上共轭高斯先验的线性回归。这允许了闭式贝叶斯推断。然而，在某些应用中，我们可能希望选择不同的似然函数。例如，在二分类设定中，我们只观测到两种可能的（类别）结果之一，此时高斯似然是不合适的。相反，我们可以选择伯努利似然，它将返回预测标签为 1（或 0）的概率。关于分类问题的深入介绍，我们推荐 Barber (2012)、Bishop (2006) 和 Murphy (2012) 的著作。非高斯似然重要的另一个例子是计数数据。计数是非负整数，在这种情况下，二项或泊松似然比高斯似然是更好的选择。

分类

所有这些例子都属于广义线性模型的范畴，它是线性回归的一个灵活推广，允许响应变量具有高斯分布以外的误差分布。GLM 通过让线性模型经由一个平滑且可逆的函数 $\sigma(\cdot)$（可以是非线性的）与观测值相关来推广线性回归，使得 $y = \sigma(f(\boldsymbol{x}))$，其中 $f(\boldsymbol{x}) = \boldsymbol{\theta}^\top \phi(\boldsymbol{x})$ 是 (9.13) 中的线性回归模型。因此我们可以将广义线性模型看作函数复合 $y = \sigma \circ f$，其中 f 是线性回归模型，σ 是激活函数。注意，尽管我们在谈论" 广义线性模型"，输出 y 不再关于参数 $\boldsymbol{\theta}$ 线性。在逻辑回归中，我们选择逻辑 S 形函数 $\sigma(f) = \frac{1}{1+\exp(-f)} \in [0, 1]$，它可以被解释为伯努利随机变量 $y \in \{0, 1\}$ 观测到 $y = 1$ 的概率。函数 $\sigma(\cdot)$ 称为传递函数或激活函数，其逆称为典范链接函数。从这个角度也很清楚，广义线性模型是（深度）前馈神经网络的构建块：如果我们考虑广义线性模型 $y = \sigma(A\boldsymbol{x} + \boldsymbol{b})$，其中 A 是权重矩阵，$\boldsymbol{b}$ 是偏置向量，我们将此广义线性模型识别为具有激活函数 $\sigma(\cdot)$ 的单层神经网络。我们现在可以通过下式递归地复合这些函数

广义线性模型

逻辑回归

激活函数

$$\boldsymbol{x}_{k+1} = f_k(\boldsymbol{x}_k), \qquad f_k(\boldsymbol{x}_k) = \sigma_k(A_k \boldsymbol{x}_k + \boldsymbol{b}_k), \tag{9.72}$$

$k = 0, \ldots, K-1$，其中 $\boldsymbol{x}_0$ 是输入特征，$\boldsymbol{x}_K = \boldsymbol{y}$ 是观测输出，使得 $f_{K-1} \circ \cdots \circ f_0$ 是一个 K 层深度神经网络。因此，这个深度神经网络的构建块就是 (9.72) 中定义的广义线性模型。神经网络（Bishop, 1995; Goodfellow et al., 2016）比线性回归模型具有显著更强的表达力和灵活性。然而，最大似然参数估计是一个非凸优化问题，在完全贝叶斯设定中对参数的边缘化在解析上是不可处理的。

原书 p.316

我们简要提到了参数上的分布诱导回归函数上的分布这一事实。高斯过程（Rasmussen and Williams, 2006）是一类回归模型，其中函数上分布的概念处于核心地位。高斯过程不在参数上放置分布，而是直接在函数空间上放置分布，而无需经由参数的" 绕

高斯过程

行”。为此，高斯过程利用核技巧（Schölkopf and Smola, 2002），它允许我们仅通过查看相应的输入 $\boldsymbol{x}_i, \boldsymbol{x}_j$ 来计算两个函数值 $f(\boldsymbol{x}_i), f(\boldsymbol{x}_j)$ 之间的内积。高斯过程与贝叶斯线性回归和支持向量回归都密切相关，但也可以被解释为具有单层隐藏层且隐藏单元数趋于无穷的贝叶斯神经网络（Neal, 1996; Williams, 1997）。关于高斯过程的优秀介绍可参见 MacKay (1998) 和 Rasmussen and Williams (2006)。

核技巧

我们在本章讨论中聚焦于高斯参数先验，因为它们允许线性回归模型中的闭式推断。然而，即使在具有高斯似然的回归设定中，我们也可以选择非高斯先验。考虑这样一个设定：输入为 $\boldsymbol{x} \in \mathbb{R}^D$，我们的训练集很小，大小为 $N \ll D$。这意味着回归问题是欠定的。在这种情况下，我们可以选择一个强制稀疏性的参数先验，即一个试图将尽可能多的参数设为 0 的先验（变量选择）。这个先验提供了比高斯先验更强的正则项，这通常导致预测精度和模型可解释性的提高。拉普拉斯先验是经常用于此目的的一个例子。在参数上施加拉普拉斯先验的线性回归模型等价于带 L1 正则化的线性回归（LASSO）（Tibshirani, 1996）。拉普拉斯分布在零处尖锐达峰（其一阶导数不连续），且其概率质量比高斯分布更集中在零附近，这鼓励参数为 0。因此，非零参数与回归问题相关，这就是为什么我们也称之为” 变量选择”。

变量选择

LASSO

第 10 章　降维：主成分分析

原书 p.317

直接处理高维数据（例如图像）会带来一些困难：难以分析、难以解释、几乎无法可视化，而且（从实用角度看）数据向量的存储代价高昂。（一张 640×480 像素的彩色图像就是一个百万维空间中的数据点，其中每个像素对应三个维度，分别对应红、绿蓝三个颜色通道。）然而，高维数据往往具有我们可以利用的性质。例如，高维数据常常是过完备的，即许多维度是冗余的，可以由其他维度的组合来解释。此外，高维数据中的各个维度往往彼此相关，因此数据具有某种内在的更低维结构。降维（dimensionality reduction）正是利用这种结构与相关性，使我们能够用更紧凑的数据表示来工作，并且理想情况下不损失信息。我们可以把降维看作一种压缩技术，类似于 jpeg 或 mp3——它们分别是图像与音乐的压缩算法。

图像即高维数据点

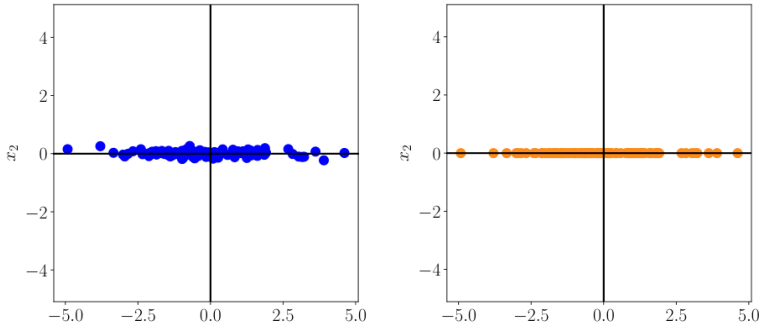


图 10.1: 降维示意。(a) 原始数据集沿 x_2 方向几乎没有变化；(b) (a) 中的数据几乎可以无损地只用 x_1 坐标来表示。

本章我们讨论主成分分析（principal component analysis, PCA），一种用于线性降维的算法。PCA 由 Pearson (1901) 与 Hotelling (1933) 提出，至今已有 100 多年历史，仍是最常用的数据压缩与数据可视化技术之一。它还可用于识别高维数据中的简单模式、潜在因子与结构。在信号处理领域，PCA 也称为 Karhunen–Loève 变换（Karhunen–Loève transform）。本章我们从第一性原理出发推导 PCA，用到基与基变换（第 2.6.1、2.7.2 节）投影（第 3.8 节）、特征值（第 4.2 节）、高斯分布（第 6.5 节）以及带约束优化（第 7.2 节）等知识。

主成分分析

K-L 变换

降维通常利用高维数据（例如图像）的一个性质：它们常常落在某个低维子空间上。图 10.1 给出了二维情形下的示意。虽然图 10.1(a) 中的数据并非严格落在一条直线上，但它们在 x_2 方向上变化很小，因此我们几乎可以无损地把它们视为在一条直线上；见图 10.1(b)。要描述图 10.1(b) 中的数据，只需要 x_1 坐标，数据位于 $\mathbb{R}^2$ 的一个一维子空间中。

10.1　问题设定

在 PCA 中，我们关心的是为数据点 x_n 寻找投影 $\tilde{x}_n$，使其尽可能与原始数据点相似，但具有显著更低的内在维数。图 10.1 给出了直观示意。

更具体地，我们考虑一个均值为 0 的 i.i.d. 数据集 $\mathcal{X} = \{x_1, \dots, x_N\}$，$x_n \in \mathbb{R}^D$，它具有数据协方差矩阵（(6.42)）

数据协方差矩阵

$$S = \frac{1}{N}\sum_{n=1}^{N} x_n x_n^\top . \tag{10.1}$$

进一步假设存在 x_n 的一个低维压缩表示（编码）

编码

$$z_n = B^\top x_n \in \mathbb{R}^M \tag{10.2}$$

其中我们定义投影矩阵

$$B := [b_1, \dots, b_M] \in \mathbb{R}^{D\times M} . \tag{10.3}$$

我们假设 B 的各列标准正交（定义 3.7），即当且仅当 $i \neq j$ 时 $b_i^\top b_j = 0$，且 $b_i^\top b_i = 1$。我们寻找一个 M 维子空间 $U \subseteq \mathbb{R}^D$，$\dim(U) = M < D$，把数据投影到其上。记投影后的数据为 $\tilde{x}_n \in U$，它们（关于 U 的基向量 $b_1, \dots, b_M$）的坐标为 z_n。我们的目标是找到投影 $\tilde{x}_n \in \mathbb{R}^D$（等价地找到编码 z_n 与基向量 $b_1, \dots, b_M$），使它们尽可能接近原始数据 x_n，并最小化压缩带来的损失。

例 10.1 (坐标表示/编码)**.** 考虑 $\mathbb{R}^2$ 的标准基 $e_1 = [1, 0]^\top$、$e_2 = [0, 1]^\top$。由第 2 章可知，$x \in \mathbb{R}^2$ 可表示为这些基向量的线性组合，例如

$$\begin{bmatrix} 5 \\ 3 \end{bmatrix} = 5e_1 + 3e_2 . \tag{10.4}$$

然而，当我们考虑形如

$$\tilde{x} = \begin{bmatrix} 0 \\ z \end{bmatrix} \in \mathbb{R}^2, \qquad z \in \mathbb{R} \tag{10.5}$$

的向量时，它们总能写成 $0e_1 + ze_2$。要表示这些向量，只需记住/存储 $\tilde{x}$ 关于 e_2 向量的坐标/编码 z。

更确切地说，这些 $\tilde{x}$ 向量的集合（连同标准的向量加法与数乘）构成一个向量子空间 U（见第 2.4 节），$\dim(U) = 1$，因为 $U = \text{span}[e_2]$。

原书 p.319

在第 10.2 节中，我们将寻找能保留尽可能多信息、最小化压缩损失的低维表示。第 10.3 节给出 PCA 的另一种推导，即最小化原始数据 x_n 与其投影 $\tilde{x}_n$ 之间的平方重构误差 $\|x_n - \tilde{x}_n\|^2$。

图 10.2 说明了 PCA 中考虑的设定：z 表示压缩数据 $\tilde{x}$ 的低维表示，扮演瓶颈的角色，控制 x 与 $\tilde{x}$ 之间能流动多少信息。在 PCA 中，我们考虑原始数据 x 与其低维编码 z 之间的线性关系：对某个合适的矩阵 B，有 $z = B^\top x$ 与 $\tilde{x} = Bz$。基于把 PCA 看作数据压缩技术的动机，我们可以把图 10.2 中的箭头解释为一对操作：编码器与解码器。由 B 表示的线性映射可看作解码器，它把低维编码 $z \in \mathbb{R}^M$ 映射回原始数据空间 $\mathbb{R}^D$；类似地，$B^\top$ 可看作编码器，它把原始数据 x 编码为低维（压缩）编码 z。

编码器/ 解码器

贯穿本章，我们将使用 MNIST 手写数字数据集作为贯穿例子（running example）它包含 60,000 个手写数字 0 到 9 的样本。每个数字是一张 28×28 的灰度图像，即包含 784 个像素，因此我们可以把该数据集中的每一张图像解释为一个向量 $x \in \mathbb{R}^{784}$。这些数字的示例如图 10.3 所示。

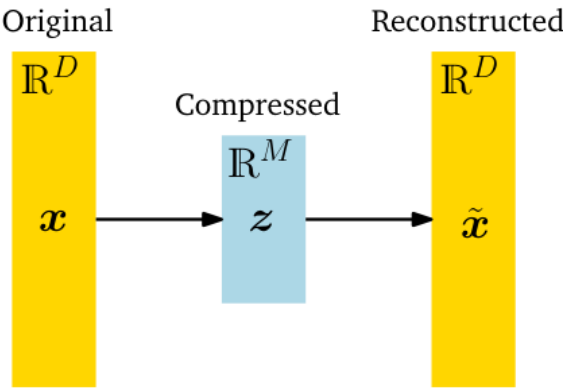


图 10.2: PCA 的图示。在 PCA 中，我们寻找原始数据 x 的压缩版本 z；压缩后的数据可重构为 $\tilde{x}$，它仍处于原始数据空间中，但具有比 x 更低维的内在表示。



图 10.3: MNIST 数据集中手写数字的示例。

10.2　最大方差视角

图 10.1 给出了一个二维数据集如何用单个坐标表示的例子。在图 10.1(b) 中，我们选择忽略数据的 x_2 坐标，因为它没有带来太多信息，从而压缩后的数据仍与图 10.1(a) 中的原始数据相似。我们本可以选择忽略 x_1 坐标，但那样压缩后的数据就会与原始数据大相径庭，数据中的大量信息也将丢失。

如果我们把数据中的信息含量解释为数据集“填满空间”的程度，那么就可以通过考察数据的散布来描述数据所含信息。由第 6.4.1 节可知，方差是数据散布的一个指标；于是我们可以把 PCA 推导为这样一种降维算法：它最大化数据低维表示中的方差，以保留尽可能多的信息。图 10.4 对此作了示意。

原书 p.321

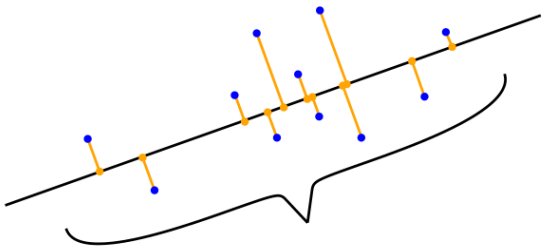


图 10.4: PCA 寻找一个低维子空间（直线），使得数据（蓝色）投影到该子空间（橙色）上方差（数据散布）保持尽可能大。

考虑第 10.1 节讨论的设定，我们的目标是找到一个矩阵 B（见 (10.3)），使得把数据投影到 B 的各列 $b_1, \ldots, b_M$ 张成的子空间上进行压缩时，能保留尽可能多的信息。数据压缩后保留最多信息，等价于在低维编码中捕获最大的方差量（Hotelling, 1933）。

注 (中心化数据). 对于 (10.1) 中的数据协方差矩阵，我们假设数据已中心化。这一假设不失一般性：设 μ 为数据均值。利用第 6.4.4 节讨论过的方差性质，有

$$\mathbb{V}_z[z] = \mathbb{V}_x[B^\top(x-\mu)] = \mathbb{V}_x[B^\top x - B^\top \mu] = \mathbb{V}_x[B^\top x]\,, \tag{10.6}$$

即低维编码的方差不依赖于数据均值。因此，在本节余下部分我们不妨假设数据均值为 0。在此假设下，低维编码的均值也为 0，因为 $\mathbb{E}_z[z] = \mathbb{E}_x[B^\top x] = B^\top \mathbb{E}_x[x] = 0$。

10.2.1　方差最大的方向

我们用一种序贯方法来最大化低维编码的方差。首先寻找单个向量 $b_1 \in \mathbb{R}^D$，使其最大化投影数据的方差，即我们旨在最大化 $z \in \mathbb{R}^M$ 的第一个坐标 z_1 的方差：

b1 为首个基向量

$$V_1 := \mathbb{V}[z_1] = \frac{1}{N}\sum_{n=1}^{N} z_{1n}^2 \tag{10.7}$$

最大。这里我们利用了数据的 i.i.d. 假设，并定义 z_{1n} 为 $x_n \in \mathbb{R}^D$ 的低维表示 $z_n \in \mathbb{R}^M$ 的第一个坐标。注意 z_n 的第一个分量由下式给出：

$$z_{1n} = b_1^\top x_n\,, \tag{10.8}$$

即它是 x_n 在 b_1 张成的一维子空间上正交投影的坐标（第 3.8 节）。把 (10.8) 代入 (10.7)，得到

$$V_1 = \frac{1}{N}\sum_{n=1}^{N}(b_1^\top x_n)^2 = \frac{1}{N}\sum_{n=1}^{N} b_1^\top x_n x_n^\top b_1 \tag{10.9a}$$

$$= b_1^\top\Big(\frac{1}{N}\sum_{n=1}^{N} x_n x_n^\top\Big)b_1 = b_1^\top S b_1\,, \tag{10.9b}$$

其中 S 是 (10.1) 定义的数据协方差矩阵。在 (10.9a) 中，我们用到了两个向量的点积关于其自变量对称这一事实，即 $b_1^\top x_n = x_n^\top b_1$。

原书 p.322

注意到任意增大向量 b_1 的模都会增大 V_1：长度加倍的向量 b_1 可能使 V_1 变为原来的四倍。因此，我们把所有解限制为 $\|b_1\|^2 = 1$，即 $\|b_1\| = 1$，从而得到一个带约束优化问题，在此问题中我们寻找数据变化最大的方向。把解空间限制为单位向量后，指向最大方差方向的向量 b_1 可由如下带约束优化问题求得：

‖b1‖= 1

$$\max_{b_1}\; b_1^\top S b_1 \qquad \text{subject to } \|b_1\|^2 = 1\,. \tag{10.10}$$

按照第 7.2 节，我们得到拉格朗日函数

$$\mathcal{L}(b_1, \lambda_1) = b_1^\top S b_1 + \lambda_1(1 - b_1^\top b_1) \tag{10.11}$$

来求解这个带约束优化问题。$\mathcal{L}$ 关于 b_1 和 λ_1 的偏导数分别为

$$\frac{\partial \mathcal{L}}{\partial b_1} = 2b_1^\top S - 2\lambda_1 b_1^\top\,, \qquad \frac{\partial \mathcal{L}}{\partial \lambda_1} = 1 - b_1^\top b_1\,, \tag{10.12}$$

令这些偏导数为 0，得到关系

$$S b_1 = \lambda_1 b_1\,, \tag{10.13}$$

$$b_1^\top b_1 = 1\,. \tag{10.14}$$

把它与特征分解的定义（第 4.4 节）相比较可知，b_1 是数据协方差矩阵 S 的一个特征向量，而拉格朗日乘子 λ_1 扮演相应特征值的角色。这一特征向量性质 (10.13) 使我们可把方差目标 (10.10) 改写为

$$V_1 = b_1^\top S b_1 = \lambda_1 b_1^\top b_1 = \lambda_1 \,, \tag{10.15}$$

即数据投影到一维子空间上的方差，等于张成该子空间的基向量 b_1 所对应的特征值。因此，为了最大化低维编码的方差，我们选择与数据协方差矩阵最大特征值相关联的基向量。该特征向量称为**第一主成分**（first principal component）。通过把坐标 z_{1n} 映射回数据空间，我们可以确定主成分 b_1 在原始数据空间中的作用/贡献，由此得到原始数据空间中的投影数据点

主成分

$$\tilde{x}_n = b_1 z_{1n} = b_1 b_1^\top x_n \in \mathbb{R}^D \,. \tag{10.16}$$

注. 虽然 $\tilde{x}_n$ 是一个 D 维向量，但相对于基向量 $b_1 \in \mathbb{R}^D$，它只需单个坐标 z_{1n} 即可表示。

10.2.2 方差最大的 M 维子空间

原书 p.323

假设我们已经求得前 $m-1$ 个主成分，即 S 的与最大的 $m-1$ 个特征值相关联的 $m-1$ 个特征向量。由于 S 对称，谱定理（定理 4.15）告诉我们：可以用这些特征向量构造 $\mathbb{R}^D$ 的一个 $(m-1)$ 维子空间的标准正交特征基。一般地，第 m 个主成分可通过从数据中扣除前 $m-1$ 个主成分 $b_1, \dots, b_{m-1}$ 的作用来求得，从而寻找能压缩剩余信息的主成分。于是我们得到新的数据矩阵

$$\hat{X} := X - \sum_{i=1}^{m-1} b_i b_i^\top X = X - B_{m-1} X \,, \tag{10.17}$$

其中 $X = [x_1, \dots, x_N] \in \mathbb{R}^{D \times N}$ 以数据点为列向量，$B_{m-1} := \sum_{i=1}^{m-1} b_i b_i^\top$ 是一个投影矩阵，把数据投影到 $b_1, \dots, b_{m-1}$ 张成的子空间上。

原书 p.324

注 (记号). 贯穿本章，我们不遵循把数据 $x_1, \dots, x_N$ 作为数据矩阵行的惯例，而是把它们定义为 X 的列。这意味着我们的数据矩阵 X 是 $D \times N$ 矩阵，而非通常的 $N \times D$ 矩阵。这样选择的原因是：代数运算可以平滑地进行，无需转置矩阵，也无需把向量重新定义为左乘矩阵的行向量。

为寻找第 m 个主成分，我们在约束 $\|b_m\|^2 = 1$ 下最大化方差

$$V_m = \mathbb{V}[z_m] = \frac{1}{N} \sum_{n=1}^{N} z_{mn}^2 = \frac{1}{N} \sum_{n=1}^{N} (b_m^\top \hat{x}_n)^2 = b_m^\top \hat{S} b_m \,, \tag{10.18}$$

其中我们沿用了 (10.9b) 的步骤，并把 $\hat{S}$ 定义为变换后数据集 $\hat{X} := \{\hat{x}_1, \dots, \hat{x}_N\}$ 的数据协方差矩阵。与先前单独考察第一主成分时一样，我们求解一个带约束优化问题，并发现最优解 b_m 是 $\hat{S}$ 的与 $\hat{S}$ 最大特征值相关联的特征向量。

事实上，b_m 也是 S 的特征向量。更一般地，S 与 $\hat{S}$ 的特征向量集合完全相同。由于 S 与 $\hat{S}$ 都对称，由谱定理 4.15 可知二者都存在一组标准正交特征基（ONB），即 S 与 $\hat{S}$ 都有 D 个互不相同的特征向量。下面我们证明 S 的每个特征向量也是 $\hat{S}$ 的特征向量。假设我们已经求得 $\hat{S}$ 的特征向量 $b_1, \dots, b_{m-1}$。考虑 S 的一个特征向量 b_i，即 $S b_i = \lambda_i b_i$。一般地，

$$\hat{S} b_i = \frac{1}{N} \hat{X} \hat{X}^\top b_i = \frac{1}{N} (X - B_{m-1} X)(X - B_{m-1} X)^\top b_i \tag{10.19a}$$

$$= (S - S B_{m-1} - B_{m-1} S + B_{m-1} S B_{m-1}) b_i \,. \tag{10.19b}$$

我们区分两种情形。若 $i \geqslant m$，即 b_i 不在前 $m-1$ 个主成分之中，则 b_i 与前 $m-1$ 个主成分正交，$B_{m-1}b_i = 0$。若 $i < m$，即 b_i 属于前 $m-1$ 个主成分，则 b_i 是 B_{m-1} 所投影到的主子空间的一个基向量。由于 $b_1, \ldots, b_{m-1}$ 是该主子空间的一组 ONB，故有 $B_{m-1}b_i = b_i$。两种情形可汇总为：

$$B_{m-1}b_i = b_i \quad 若 i < m, \qquad B_{m-1}b_i = 0 \quad 若 i \geqslant m\,. \tag{10.20}$$

在 $i \geqslant m$ 的情形下，把 (10.20) 代入 (10.19b)，得 $\hat{S}b_i = (S - B_{m-1}S)b_i = Sb_i = \lambda_i b_i$，即 b_i 也是 $\hat{S}$ 的特征向量，特征值为 λ_i。特别地，

$$\hat{S}b_m = Sb_m = \lambda_m b_m\,. \tag{10.21}$$

式 (10.21) 表明，b_m 不仅是 S 的特征向量，也是 $\hat{S}$ 的特征向量。具体地，λ_m 是 $\hat{S}$ 的最大特征值，同时是 S 的第 m 大特征值，二者都以 b_m 为对应的特征向量。

在 $i < m$ 的情形下，把 (10.20) 代入 (10.19b)，得

$$\hat{S}b_i = (S - SB_{m-1} - B_{m-1}S + B_{m-1}SB_{m-1})b_i = 0 = 0b_i\,. \tag{10.22}$$

这意味着 $b_1, \ldots, b_{m-1}$ 也是 $\hat{S}$ 的特征向量，但它们对应的特征值为 0，因此 $b_1, \ldots, b_{m-1}$ 张成 $\hat{S}$ 的零空间。

总之，S 的每个特征向量也是 $\hat{S}$ 的特征向量；但若 S 的特征向量属于那个 $(m-1)$ 维主子空间，则它在 $\hat{S}$ 中对应的特征值为 0。

由关系 (10.21) 与 $b_m^\top b_m = 1$，数据投影到第 m 个主成分上的方差为

$$V_m = b_m^\top S b_m \overset{(10.21)}{=} \lambda_m b_m^\top b_m = \lambda_m\,. \tag{10.23}$$

这意味着：当数据投影到一个 M 维子空间上时，其方差等于数据协方差矩阵相应特征向量所关联的特征值之和。

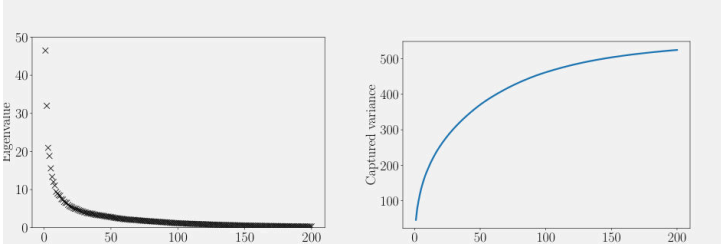


图 10.5: MNIST 数字“8”训练数据的性质。(a) 按降序排列的特征值；(b) 由与最大特征值关联的各主成分所捕获的方差。

例 10.2 (MNIST 数字“8”的特征值)**.** 取 MNIST 训练数据中所有的数字“8”，计算数据协方差矩阵的特征值。图 10.5(a) 给出了数据协方差矩阵最大的 200 个特征值。我们看到，其中只有少数几个的值与 0 有显著差异。因此，当把数据投影到相应特征向量张成的子空间上时，大部分方差仅由少数几个主成分捕获，如图 10.5(b) 所示。

总之，为在 $\mathbb{R}^D$ 中找到一个保留尽可能多信息的 M 维子空间，PCA 告诉我们：把 (10.3) 中矩阵 B 的各列取为数据协方差矩阵 S 的与 M 个最大特征值相关联的 M 个特征向量。PCA 用前 M 个主成分所能捕获的最大方差量为

$$V_M = \sum_{m=1}^{M} \lambda_m\,, \tag{10.24}$$

其中 λ_m 是数据协方差矩阵 S 的 M 个最大特征值。相应地，通过 PCA 进行数据压缩所损失的方差为

$$J_M := \sum_{j=M+1}^{D} \lambda_j = V_D - V_M \,. \tag{10.25}$$

与其使用这些绝对量，我们可以定义相对捕获方差为 V_M/V_D，压缩的相对损失方差为 $1 - V_M/V_D$。

10.3　投影视角

原书 p.325

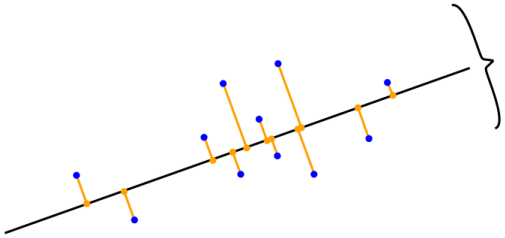


图 10.6: 投影方法示意：寻找一个子空间（直线），使投影后（橙色）与原始（蓝色）数据之间差向量的长度最小。

下面我们把 PCA 推导为一种直接最小化平均重构误差的算法。这一视角使我们可以把 PCA 解释为实现了一个最优线性自编码器。我们将大量用到第 2、3 章的知识。

上一节中，我们通过最大化投影空间中的方差来推导 PCA，以保留尽可能多的信息。接下来我们考察原始数据 x_n 与其重构 $\tilde{x}_n$ 之间的差向量，并最小化这一距离，使 x_n 与 $\tilde{x}_n$ 尽可能接近。图 10.6 说明了这一设定。

10.3.1　设定与目标

设 $B = (b_1, \ldots, b_D)$ 是 $\mathbb{R}^D$ 的一组（有序）标准正交基（ONB），即当且仅当 $i = j$ 时 $b_i^\top b_j = 1$，否则为 0。

由第 2.5 节可知，对于 $\mathbb{R}^D$ 的一组基 $(b_1, \ldots, b_D)$，任意 $x \in \mathbb{R}^D$ 都可写成基向量的线性组合，即

$$x = \sum_{d=1}^{D} \zeta_d b_d = \sum_{m=1}^{M} \zeta_m b_m + \sum_{j=M+1}^{D} \zeta_j b_j \tag{10.26}$$

其中 $\zeta_d \in \mathbb{R}$ 为适当的坐标。

原书 p.326

我们希望找到向量 $\tilde{x} \in \mathbb{R}^D$，它位于更低维的子空间 $U \subseteq \mathbb{R}^D$ 中，$\dim(U) = M$，使得

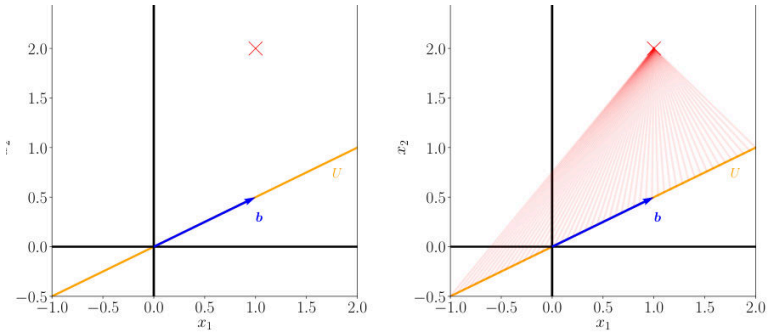
$$\tilde{x} = \sum_{m=1}^{M} z_m b_m \in U \subseteq \mathbb{R}^D \tag{10.27}$$

尽可能接近 x。注意此处我们必须假设：$\tilde{x}$ 的坐标 z_m 与 x 的坐标 ζ_m 并不相同。

下面我们正是利用这种 $\tilde{x}$ 的表示来寻找最优坐标 z 与基向量 $b_1, \ldots, b_M$，使 $\tilde{x}$ 尽可能接近原始数据点 x，即我们旨在最小化（欧氏）距离 $\|x - \tilde{x}\|$。图 10.7 说明了这一设定。

原书 p.327

不失一般性，我们假设数据集 $\mathcal{X} = \{x_1, \ldots, x_N\}$，$x_n \in \mathbb{R}^D$，已中心化于 0，即 $\mathbb{E}[\mathcal{X}] = 0$。若不做零均值假设，我们会得到完全相同的解，但记号会繁琐得多。



(a) Setting.　(b) Differences $\boldsymbol{x} - \tilde{\boldsymbol{x}}_i$ for 50 different $\tilde{\boldsymbol{x}}_i$ are shown by the red lines.

图 10.7: 简化的投影设定。(a) 一个向量 $x \in \mathbb{R}^2$（红叉）应被投影到由 b 张成的一维子空间 $U \subseteq \mathbb{R}^2$ 上；(b) 给出 x 与若干候选 $\tilde{x}$ 之间的差向量。

我们希望找到 $\mathcal{X}$ 到 $\mathbb{R}^D$ 的一个低维子空间 U（$\dim(U) = M$，基向量标准正交为 $b_1, \ldots, b_M$）的最佳线性投影。我们称这个子空间 U 为主子空间（principal subspace）。数据点的投影记为

主子空间

$$\tilde{x}_n := \sum_{m=1}^{M} z_{m_n} b_m = B z_n \in \mathbb{R}^D \,, \tag{10.28}$$

其中 $z_n := [z_{1n}, \ldots, z_{Mn}]^\top \in \mathbb{R}^M$ 是 $\tilde{x}_n$ 关于基 $(b_1, \ldots, b_M)$ 的坐标向量。更具体地，我们希望 $\tilde{x}_n$ 尽可能接近 x_n。

下面使用的相似性度量是 x 与 $\tilde{x}$ 之间的平方距离（欧氏范数）$\|x - \tilde{x}\|^2$。因此我们把目标定义为最小化平均平方欧氏距离（重构误差，reconstruction error）（Pearson, 1901）：

重构误差

$$J_M := \frac{1}{N} \sum_{n=1}^{N} \|x_n - \tilde{x}_n\|^2 \,, \tag{10.29}$$

这里我们显式指出投影所到子空间的维数为 M。为找到这个最优线性投影，我们需要找到主子空间的标准正交基，以及投影关于该基的坐标 $z_n \in \mathbb{R}^M$。

为找到坐标 z_n 与主子空间的 ONB,我们采用两步法:首先,对给定的 ONB $(b_1, \ldots, b_M)$ 优化坐标 z_n；其次，寻找最优的 ONB。

10.3.2　寻找最优坐标

先来寻找投影 $\tilde{x}_n$（$n = 1, \ldots, N$）的最优坐标 $z_{1n}, \ldots, z_{Mn}$。考虑图 10.7(b)，其中主子空间由单个向量 b 张成。从几何上说，寻找最优坐标 z，对应于在关于 b 的表示中找到使 $\tilde{x} - x$ 距离最小的那个线性投影 $\tilde{x}$。由图 10.7(b) 显然可见，这将是正交投影；下面我们将严格证明这一点。

设 $U \subseteq \mathbb{R}^D$ 有一组 ONB $(b_1, \ldots, b_M)$。为找到关于该基的最优坐标 z_m，我们需要偏导数

$$\frac{\partial J_M}{\partial z_{in}} = \frac{\partial J_M}{\partial \tilde{x}_n} \frac{\partial \tilde{x}_n}{\partial z_{in}} \,, \tag{10.30a}$$

$$\frac{\partial J_M}{\partial \tilde{x}_n} = -\frac{2}{N} (x_n - \tilde{x}_n)^\top \in \mathbb{R}^{1 \times D} \,, \tag{10.30b}$$

$$\frac{\partial \tilde{x}_n}{\partial z_{in}} \overset{(10.28)}{=} \frac{\partial}{\partial z_{in}} \Big(\sum_{m=1}^{M} z_{mn} b_m \Big) = b_i \tag{10.30c}$$

对 $i=1,\dots,M$ 成立，于是得到

$$\frac{\partial J_M}{\partial z_{in}} \overset{\substack{(10.30b)\\(10.30c)}}{=} -\frac{2}{N}(x_n-\tilde{x}_n)^\top b_i \overset{(10.28)}{=} -\frac{2}{N}\Big(x_n-\sum_{m=1}^{M} z_{mn}b_m\Big)^\top b_i \tag{10.31a}$$

$$\overset{\text{ONB}}{=} -\frac{2}{N}(x_n^\top b_i - z_{in}b_i^\top b_i) = -\frac{2}{N}(x_n^\top b_i - z_{in})\,, \tag{10.31b}$$

因为 $b_i^\top b_i=1$。令此偏导数为 0，立即得到最优坐标

原书 p.328

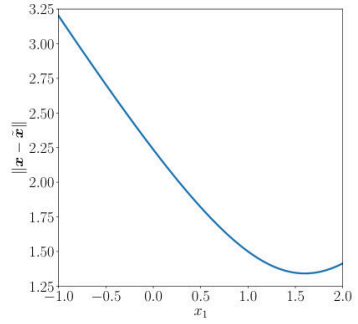
$$z_{in}=x_n^\top b_i = b_i^\top x_n \tag{10.32}$$

对 $i=1,\dots,M$、$n=1,\dots,N$ 成立。这意味着投影 $\tilde{x}_n$ 的最优坐标 z_{in}，就是原始数据点 x_n 在由 b_i 张成的一维子空间上正交投影（见第 3.8 节）的坐标。由此可得：

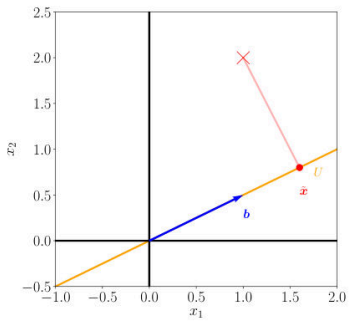
- x_n 的最优线性投影 $\tilde{x}_n$ 是一个正交投影。
- $\tilde{x}_n$ 关于基 $(b_1,\dots,b_M)$ 的坐标，就是 x_n 在主子空间上正交投影的坐标。
- 在目标 (10.29) 下，正交投影是最佳线性映射。

原书 p.329

式 (10.26) 中 x 的坐标 ζ_m 与式 (10.27) 中 $\tilde{x}$ 的坐标 z_m 对 $m=1,\dots,M$ 必须相同，因为 $U^\perp=\text{span}[b_{M+1},\dots,b_D]$ 是 $U=\text{span}[b_1,\dots,b_M]$ 的正交补（见第 3.6 节）。



(a) Distances $\|\boldsymbol{x}-\tilde{\boldsymbol{x}}\|$ for some $\tilde{\boldsymbol{x}}=z_1\boldsymbol{b}\in U=\text{span}[\boldsymbol{b}]$; see panel (b) for the setting.



(b) The vector $\tilde{\boldsymbol{x}}$ that minimizes the distance in panel (a) is its orthogonal projection onto U. The coordinate of the projection $\tilde{\boldsymbol{x}}$ with respect to the basis vector $\boldsymbol{b}$ that spans U

图 10.8: 向量 $x\in\mathbb{R}^2$ 到一维子空间的最优投影（续图 10.7）。(a) 某些 $\tilde{x}\in U$ 对应的距离 $\|x-\tilde{x}\|$；(b) 正交投影与最优坐标。

注 (标准正交基下的正交投影). 简要回顾第 3.8 节的正交投影。若 $(b_1,\dots,b_D)$ 是 $\mathbb{R}^D$ 的一组标准正交基，则

$$\tilde{x}=b_j(b_j^\top b_j)^{-1}b_j^\top x = b_j b_j^\top x\in\mathbb{R}^D \tag{10.33}$$

是 x 在第 j 个基向量张成的子空间上的正交投影，而 $z_j=b_j^\top x$ 是该投影关于张成该子空间的基向量 b_j 的坐标，因为 $z_j b_j=\tilde{x}$。图 10.8(b) 说明了这一设定。

更一般地，若我们想投影到 $\mathbb{R}^D$ 的一个 M 维子空间上，则 x 在该 M 维子空间（标准正交基为 $b_1,\dots,b_M$）上的正交投影为

$$\tilde{x}=B\underbrace{(B^\top B)}_{=I}{}^{-1}B^\top x = BB^\top x\,, \tag{10.34}$$

其中我们定义 $B:=[b_1,\dots,b_M]\in\mathbb{R}^{D\times M}$。该投影关于有序基 $(b_1,\dots,b_M)$ 的坐标为 $z:=B^\top x$，如第 3.8 节所述。

我们可以把坐标看作投影向量在由 $(b_1,\dots,b_M)$ 定义的新坐标系中的表示。注意虽然 $\tilde{x}\in\mathbb{R}^D$,我们只需 M 个坐标 $z_1,\dots,z_M$ 即可表示这个向量;关于基向量 $(b_{M+1},\dots,b_D)$ 的其余 $D-M$ 个坐标始终为 0。

至此，我们已经证明：对给定的 ONB，可通过在主子空间上作正交投影来找到 $\tilde{x}$ 的最优坐标。下面我们来确定最佳基是什么。

10.3.3　寻找主子空间的基

为确定主子空间的基向量 $b_1, \ldots, b_M$，我们用迄今所得结果重写损失函数 (10.29)，这将使寻找基向量更容易。利用先前的结果，有

$$\tilde{x}_n = \sum_{m=1}^{M} z_{mn} b_m \overset{(10.32)}{=} \sum_{m=1}^{M} (x_n^\top b_m) b_m \,. \tag{10.35}$$

再利用点积的对称性，得

$$\tilde{x}_n = \Big(\sum_{m=1}^{M} b_m b_m^\top\Big) x_n \,. \tag{10.36}$$

原书 p.330

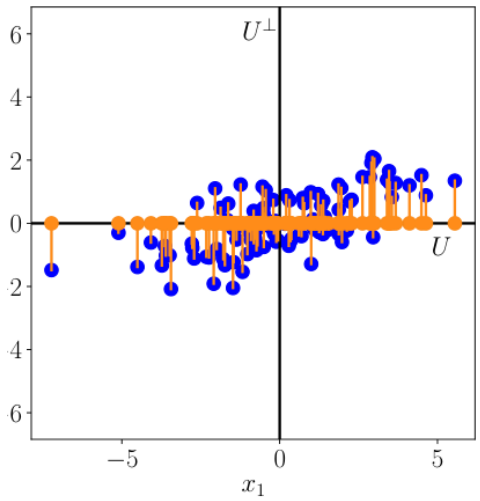


图 10.9: 正交投影与位移向量。把数据点 x_n（蓝色）投影到子空间 U_1 上，得到 $\tilde{x}_n$（橙色）。位移向量 $\tilde{x}_n - x_n$ 完全位于 U_1 的正交补 U_2 中。

由于原始数据点 x_n 一般可写成所有基向量的线性组合，故有

$$x_n = \sum_{d=1}^{D} z_{dn} b_d \overset{(10.32)}{=} \sum_{d=1}^{D} (x_n^\top b_d) b_d = \Big(\sum_{d=1}^{D} b_d b_d^\top\Big) x_n \tag{10.37a}$$

$$= \Big(\sum_{m=1}^{M} b_m b_m^\top\Big) x_n + \Big(\sum_{j=M+1}^{D} b_j b_j^\top\Big) x_n \,, \tag{10.37b}$$

这里我们把含 D 项的求和拆成对 M 项与对 $D-M$ 项的两个求和。由此可得位移向量 $x_n - \tilde{x}_n$（即原始数据点与其投影之间的差向量）为

$$x_n - \tilde{x}_n = \Big(\sum_{j=M+1}^{D} b_j b_j^\top\Big) x_n \tag{10.38a}$$

$$= \sum_{j=M+1}^{D} (x_n^\top b_j) b_j \,. \tag{10.38b}$$

这意味着该差向量恰好是数据点在主子空间的正交补上的投影：我们把 (10.38a) 中的矩阵 $\sum_{j=M+1}^{D} b_j b_j^\top$ 识别为执行该投影的投影矩阵。因此，位移向量 $x_n - \tilde{x}_n$ 位于与主子空间正交的子空间中，如图 10.9 所示。

注 (低秩近似). 在 (10.38a) 中我们看到，把 x 投影到 $\tilde{x}$ 的投影矩阵为

$$\sum_{m=1}^{M} b_m b_m^\top = BB^\top \,. \tag{10.39}$$

由其构造（秩一矩阵 $b_m b_m^\top$ 之和）可知 $BB^\top$ 对称且秩为 M。因此，平均平方重构误差也可写为

原书 p.331

$$\frac{1}{N}\sum_{n=1}^{N}\|x_n - \tilde{x}_n\|^2 = \frac{1}{N}\sum_{n=1}^{N}\|x_n - BB^\top x_n\|^2 \tag{10.40a}$$

$$= \frac{1}{N}\sum_{n=1}^{N}\|(I - BB^\top)x_n\|^2 \,. \tag{10.40b}$$

寻找使原始数据 x_n 与其投影 $\tilde{x}_n$ 之差最小的标准正交基向量 $b_1, \ldots, b_M$，等价于寻找单位矩阵 I 的最佳秩-M 近似 $BB^\top$（见第 4.6 节）。

最佳秩- M 近似

现在我们已具备重写损失函数 (10.29) 的全部工具：

$$J_M = \frac{1}{N}\sum_{n=1}^{N}\|x_n - \tilde{x}_n\|^2 \overset{(10.38b)}{=} \frac{1}{N}\sum_{n=1}^{N}\Big\|\sum_{j=M+1}^{D}(b_j^\top x_n)b_j\Big\|^2 \,. \tag{10.41}$$

现在我们显式计算平方范数，并利用 b_j 构成 ONB 这一事实，得到

$$J_M = \frac{1}{N}\sum_{n=1}^{N}\sum_{j=M+1}^{D}(b_j^\top x_n)^2 = \frac{1}{N}\sum_{n=1}^{N}\sum_{j=M+1}^{D} b_j^\top x_n b_j^\top x_n \tag{10.42a}$$

$$= \frac{1}{N}\sum_{n=1}^{N}\sum_{j=M+1}^{D} b_j^\top x_n x_n^\top b_j \,, \tag{10.42b}$$

其中最后一步利用点积的对称性写出 $b_j^\top x_n = x_n^\top b_j$。交换求和顺序，得

$$J_M = \sum_{j=M+1}^{D} b_j^\top \Big(\frac{1}{N}\sum_{n=1}^{N} x_n x_n^\top\Big)\underbrace{}_{=:S} b_j = \sum_{j=M+1}^{D} b_j^\top S b_j \tag{10.43a}$$

$$= \sum_{j=M+1}^{D}\operatorname{tr}(b_j^\top S b_j) = \sum_{j=M+1}^{D}\operatorname{tr}(S b_j b_j^\top) = \operatorname{tr}\Big(\underbrace{\Big(\sum_{j=M+1}^{D} b_j b_j^\top\Big)}_{\text{投影矩阵}} S\Big) \,, \tag{10.43b}$$

其中我们利用了迹算子 $\operatorname{tr}(\cdot)$（见 (4.18)）线性且在其自变量循环置换下不变的性质。由于我们假设数据集已中心化，即 $\mathbb{E}[\mathcal{X}] = 0$，故把 S 识别为数据协方差矩阵。由于 (10.43b) 中的投影矩阵由秩一矩阵 $b_j b_j^\top$ 求和构造，它本身的秩为 $D - M$。

原书 p.332

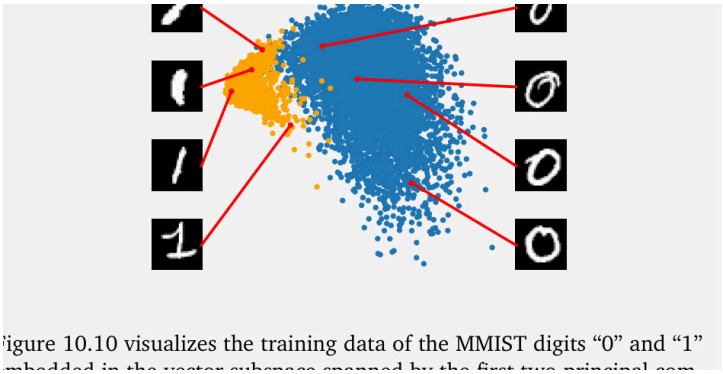
式 (10.43a) 表明：我们可以把平均平方重构误差等价地表述为数据协方差矩阵在主子空间正交补上的投影。因此，最小化平均平方重构误差，等价于最小化数据投影到我们所忽略的子空间（即主子空间的正交补）上的方差。等价地，我们最大化在主子空间中保留下来的投影的方差，这把投影损失与第 10.2 节讨论的 PCA 最大方差表述直接联系起来。但这同时也意味着：我们将得到与最大方差视角下相同的解。因此我们略去与第 10.2 节完全相同的推导，转而从投影视角总结先前的结果。

数据投影到 M 维主子空间上时的平均平方重构误差为

$$J_M = \sum_{j=M+1}^{D} \lambda_j \,, \tag{10.44}$$

其中 λ_j 是数据协方差矩阵的特征值。因此，为最小化 (10.44)，我们需要选取最小的 $D-M$ 个特征值，这进而意味着它们对应的特征向量构成主子空间正交补的基。于是这表明：主子空间的基由与数据协方差矩阵最大的 M 个特征值相关联的特征向量 $b_1, \ldots, b_M$ 构成。

原书 p.333



igure 10.10 visualizes the training data of the MMIST digits “0” and “1”

图 10.10: 用 PCA 把 MNIST 数字“0”（蓝色）与“1”（橙色）嵌入二维主子空间。图中以红色高亮标出数字“0”与“1”在主子空间中的四个嵌入点及其对应的原始数字。

例 10.3 (MNIST 数字嵌入)**.** 图 10.10 可视化了 MNIST 数字“0”与“1”的训练数据在由前两个主成分张成的向量子空间中的嵌入。我们观察到“0”（蓝点）与“1”（橙点）之间相对清晰的分离，也看到每一类内部的变化。数字“0”与“1”在主子空间中的四个嵌入点以红色高亮，并标出了相应的原始数字。该图揭示：“0”集合内部的变化显著大于“1”集合内部的变化。

10.4　特征向量计算与低秩近似

在前面几节中，我们把主子空间的基取为与数据协方差矩阵最大特征值相关联的特征向量：

$$S = \frac{1}{N}\sum_{n=1}^{N} x_n x_n^\top = \frac{1}{N} X X^\top \,, \tag{10.45}$$

$$X = [x_1, \ldots, x_N] \in \mathbb{R}^{D \times N} \,. \tag{10.46}$$

注意 X 是一个 $D \times N$ 矩阵，即它是“通常”数据矩阵的转置（Bishop, 2006; Murphy, 2012）。为求得 S 的特征值（及相应特征向量），我们可走两条路：

- 做特征分解（见第 4.2 节），直接计算 S 的特征值与特征向量。
- 使用奇异值分解（见第 4.5 节）。由于 S 对称且可分解为 $XX^\top$（忽略因子 $1/N$），S 的特征值就是 X 的奇异值的平方。

更具体地，X 的 SVD 为

$$\underbrace{X}_{D\times N} = \underbrace{U}_{D\times D}\,\underbrace{\Sigma}_{D\times N}\,\underbrace{V^\top}_{N\times N} \,, \tag{10.47}$$

其中 $U \in \mathbb{R}^{D\times D}$ 与 $V^\top \in \mathbb{R}^{N\times N}$ 是正交矩阵，$\Sigma \in \mathbb{R}^{D\times N}$ 是一个仅在对角线上有非零元（奇异值 $\sigma_{ii} \geqslant 0$）的矩阵。由此可得

$$S = \frac{1}{N}XX^\top = \frac{1}{N}U\Sigma\underbrace{V^\top V}_{=I_N}\Sigma^\top U^\top = \frac{1}{N}U\Sigma\Sigma^\top U^\top . \tag{10.48}$$

由第 4.5 节的结果，U 的各列是 $XX^\top$（因而也是 S）的特征向量。此外，S 的特征值 λ_d 与 X 的奇异值关系为

U 的列为S的特征向量

$$\lambda_d = \frac{\sigma_d^2}{N} . \tag{10.49}$$

S 的特征值与 X 的奇异值之间的这一关系，在最大方差视角（第 10.2 节）与奇异值分解之间建立了联系。

10.4.1　基于低秩矩阵近似的 PCA

原书 p.334

为最大化投影数据的方差（或最小化平均平方重构误差），PCA 选取 (10.48) 中 U 的各列作为与数据协方差矩阵 S 最大的 M 个特征值相关联的特征向量，于是我们把 U 识别为 (10.3) 中的投影矩阵 B，它把原始数据投影到一个 M 维的低维子空间上。Eckart–Young 定理（第 4.6 节定理 4.25）提供了估计低维表示的直接途径。考虑 X 的最佳秩-M 近似

Eckart–Young 定理

$$\tilde{X}_M := \operatorname*{argmin}_{\mathrm{rk}(A)\leqslant M} \|X - A\|_2 \in \mathbb{R}^{D\times N} , \tag{10.50}$$

其中 $\|\cdot\|_2$ 是 (4.93) 定义的谱范数。Eckart–Young 定理指出，$\tilde{X}_M$ 可通过把 SVD 在最大的 M 个奇异值处截断得到。换言之，我们得到

$$\tilde{X}_M = \underbrace{U_M}_{D\times M}\underbrace{\Sigma_M}_{M\times M}\underbrace{V_M^\top}_{M\times N} \in \mathbb{R}^{D\times N} \tag{10.51}$$

其中正交矩阵 $U_M := [u_1, \ldots, u_M] \in \mathbb{R}^{D\times M}$、$V_M := [v_1, \ldots, v_M] \in \mathbb{R}^{N\times M}$，对角矩阵 $\Sigma_M \in \mathbb{R}^{M\times M}$ 的对角元为 X 的 M 个最大奇异值。

10.4.2　实践要点

在其他一些需要矩阵分解的基本机器学习方法中，求特征值与特征向量也很重要。理论上，如第 4.2 节所讨论，我们可以把特征值作为特征多项式的根来求解。然而，对于大于 4×4 的矩阵这是不可行的，因为我们需要求一个五次或更高次多项式的根。而 Abel–Ruffini 定理（Ruffini, 1799; Abel, 1826）指出，对于五次及以上的多项式，该问题不存在代数解。因此在实践中，我们用迭代方法求解特征值或奇异值，这些方法在所有现代线性代数软件包中都有实现。

Abel–Ruffini 定理

原书 p.335

在许多应用中（例如本章介绍的 PCA），我们只需要少数几个特征向量。计算完整分解、再把前几个之外的所有特征向量丢弃，是很浪费的。事实上，如果我们只关心前几个（具有最大特征值的）特征向量，那么直接优化这些特征向量的迭代过程，在计算上比完整特征分解（或 SVD）更高效。在只需要第一个特征向量的极端情形，一种称为幂迭代（power iteration）的简单方法非常高效。幂迭代选取一个不在 S 的零空间中的随机向量 x_0，并遵循如下迭代：

幂迭代

$$x_{k+1} = \frac{Sx_k}{\|Sx_k\|}, \qquad k = 0, 1, \ldots . \tag{10.52}$$

这意味着每一步都用 S 乘以向量 x_k，再归一化，即始终有 $\|x_k\| = 1$。这个向量序列收敛到与 S 最大特征值相关联的特征向量。原始的 Google PageRank 算法（Page et al., 1999）就使用这样一种算法，基于网页超链接对网页进行排序。

10.5　高维情形下的 PCA

要做 PCA，我们需要计算数据协方差矩阵。在 D 维中，数据协方差矩阵是一个 $D \times D$ 矩阵。计算该矩阵的特征值与特征向量在计算上代价高昂，因为它随 D 呈三次方增长。因此，如前所述的 PCA 在极高维下将不可行。例如，若 x_n 是含 10,000 个像素的图像（例如 100×100 像素图像），我们就需要对一个 $10,000 \times 10,000$ 的协方差矩阵做特征分解。下面针对数据点数目远小于维数（即 $N \ll D$）的情形，给出这个问题的一个解法。

设我们有一个中心化数据集 $x_1, \dots, x_N$，$x_n \in \mathbb{R}^D$。则数据协方差矩阵为

$$S = \frac{1}{N} X X^\top \in \mathbb{R}^{D \times D} , \tag{10.53}$$

其中 $X = [x_1, \dots, x_N]$ 是一个 $D \times N$ 矩阵，其各列为数据点。

现在假设 $N \ll D$，即数据点数小于数据维数。若没有重复数据点，则协方差矩阵 S 的秩为 N，因此它有 $D - N + 1$ 个特征值为 0。直观地说，这意味着存在一些冗余。下面我们将利用这一点，把 $D \times D$ 的协方差矩阵转化为一个 $N \times N$、其特征值全为正的协方差矩阵。

在 PCA 中，我们最终得到特征向量方程

$$S b_m = \lambda_m b_m, \qquad m = 1, \dots, M , \tag{10.54}$$

其中 b_m 是主子空间的一个基向量。我们把该方程稍作改写：用 (10.53) 中定义的 S，有

$$S b_m = \frac{1}{N} X X^\top b_m = \lambda_m b_m . \tag{10.55}$$

现在从左边左乘 $X^\top \in \mathbb{R}^{N \times D}$，得

$$\underbrace{\frac{1}{N} X^\top X}_{N \times N} \underbrace{X^\top b_m}_{=: c_m} = \lambda_m X^\top b_m \quad \Longleftrightarrow \quad \frac{1}{N} X^\top X c_m = \lambda_m c_m , \tag{10.56}$$

于是我们得到一个新的特征向量/特征值方程：λ_m 仍为特征值，这印证了第 4.5.3 节的结果，即 $XX^\top$ 的非零特征值等于 $X^\top X$ 的非零特征值。我们得到矩阵 $\frac{1}{N} X^\top X \in \mathbb{R}^{N \times N}$ 与 λ_m 关联的特征向量 $c_m := X^\top b_m$。假设没有重复数据点，该矩阵秩为 N 且可逆。这也意味着 $\frac{1}{N} X^\top X$ 与数据协方差矩阵 S 具有相同的（非零）特征值。但现在它是一个 $N \times N$ 矩阵，因此我们可以比原先的 $D \times D$ 数据协方差矩阵高效得多地计算其特征值与特征向量。

原书 p.336

现在我们已经有了 $\frac{1}{N} X^\top X$ 的特征向量，接下来要恢复 PCA 仍需要的原始特征向量。当前我们知道 $\frac{1}{N} X^\top X$ 的特征向量。若用 X 左乘我们的特征值/特征向量方程，得

$$\underbrace{\frac{1}{N} X X^\top}_{S} X c_m = \lambda_m X c_m \tag{10.57}$$

我们再次得到数据协方差矩阵。这同时也意味着：我们把 Xc_m 恢复为 S 的一个特征向量。

注. 若我们想应用第 10.6 节讨论的 PCA 算法，则需要把 S 的特征向量 Xc_m 归一化，使其范数为 1。

10.6　实践中 PCA 的关键步骤

下面我们用一个贯穿例子来走完 PCA 的各个步骤，如图 10.11 所示。给定一个二维数据集（图 10.11(a)），我们想用 PCA 把它投影到一维子空间上。

1. **均值减法**。首先通过计算数据集均值 μ 并从每个数据点中减去它来中心化数据。这保证数据集均值为 0（图 10.11(b)）。均值减法并非严格必要，但能降低数值问题的风险。

2. **标准化**。对每一维 $d = 1, \ldots, D$，把数据点除以该维的标准差 σ_d。现在数据已无量纲，且沿每个轴的方差为 1，如图 10.11(c) 中两个箭头所示。这一步完成了数据的标准化（standardization）。 标准化

3. **协方差矩阵的特征分解**。计算数据协方差矩阵及其特征值与相应特征向量。由于协方差矩阵对称，谱定理（定理 4.15）告诉我们可以找到一组标准正交特征基。在图 10.11(d) 中，特征向量按相应特征值的大小缩放。较长的向量张成主子空间，记为 U。数据协方差矩阵由椭圆表示。

4. **投影**。我们可以把任意数据点 $x_* \in \mathbb{R}^D$ 投影到主子空间上：为正确地做到这一点，我们需要分别用训练数据在第 d 维上的均值 μ_d 与标准差 σ_d 对 x_* 做标准化，即

$$x_*^{(d)} \leftarrow \frac{x_*^{(d)} - \mu_d}{\sigma_d}, \qquad d = 1, \ldots, D\,, \tag{10.58}$$

   其中 $x_*^{(d)}$ 是 x_* 的第 d 个分量。我们得到投影

$$\tilde{x}_* = BB^\top x_* \tag{10.59}$$

   其关于主子空间基的坐标为

$$z_* = B^\top x_*\,. \tag{10.60}$$

   这里 B 是以数据协方差矩阵最大特征值所对应特征向量为列构成的矩阵。PCA 返回的是坐标 (10.60)，而不是投影 x_*。

对数据集标准化之后，(10.59) 只给出标准化数据集语境下的投影。为在原始数据空间（即标准化之前）得到投影，我们需要撤销标准化 (10.58)，先乘以标准差再加上均值，从而得到 原书 p.337 原书 p.338

$$\tilde{x}_*^{(d)} \leftarrow \tilde{x}_*^{(d)}\sigma_d + \mu_d, \qquad d = 1, \ldots, D\,. \tag{10.61}$$

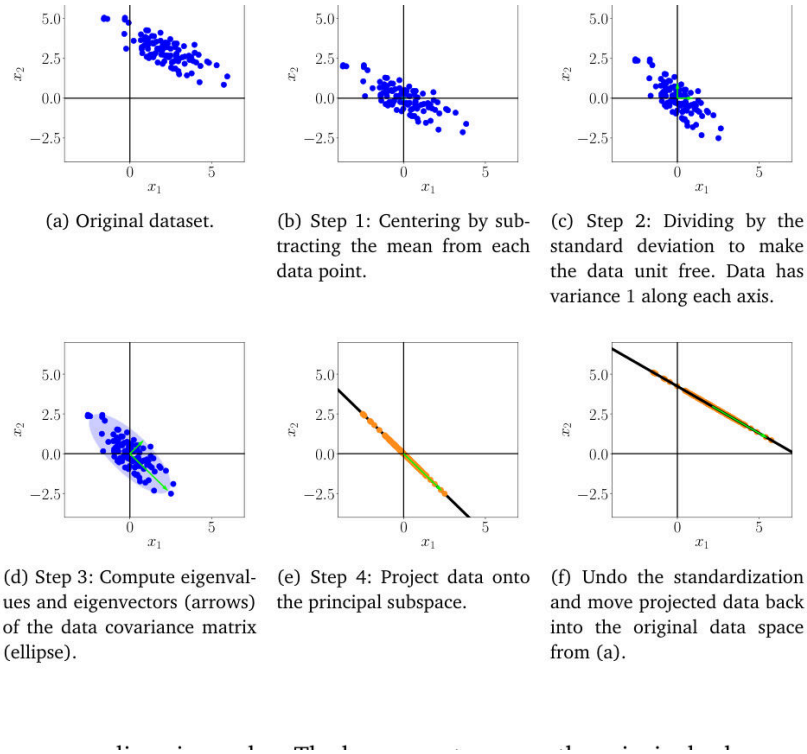
图 10.11(f) 说明了原始数据空间中的投影。

例 10.4 (MNIST 数字：重构)**.** 下面我们把 PCA 应用于 MNIST 手写数字数据集，它包含 60,000 个手写数字 0 到 9 的样本。每个数字是一张 28×28 的图像，即含 784 个像素，因此我们可以把该数据集中的每一张图像解释为一个向量 $x \in \mathbb{R}^{784}$。这些数字的示例如图 10.3 所示。

出于示意目的，我们把 PCA 应用于 MNIST 数字的一个子集，并聚焦于数字“8”。我们使用了 5,389 张数字“8”的训练图像，并按本章所述确定了主子空间。然后用学到的投影矩阵重构一组测试图像，如图 10.12 所示。图 10.12 第一行给出测试集中的四个原始数字；随后各行分别给出当主子空间维数为 1、10、100、500 时对同一批数字的重构。我们看到，即使只用一维主子空间，也能对原始数字得到还算像样的重构，但它模糊而泛化。随着主成分（PC）个数增加，重构变得更清晰，更多细节被保留。用 500 个主成分时，我们实际上得到近乎完美的重构。若选用 784 个主成分，我们将毫无压缩损失地恢复出精确的数字。 原书 p.339

图 10.13 给出了平均平方重构误差

$$\frac{1}{N}\sum_{n=1}^{N}\|x_n - \tilde{x}_n\|^2 = \sum_{i=M+1}^{D}\lambda_i \tag{10.62}$$



(a) Original dataset.

(b) Step 1: Centering by subtracting the mean from each data point.

(c) Step 2: Dividing by the standard deviation to make the data unit free. Data has variance 1 along each axis.

(d) Step 3: Compute eigenvalues and eigenvectors (arrows) of the data covariance matrix (ellipse).

(e) Step 4: Project data onto the principal subspace.

(f) Undo the standardization and move projected data back into the original data space from (a).

图 10.11: PCA 的步骤。(a) 原始数据集；(b) 中心化；(c) 除以标准差；(d) 特征分解；(e) 投影；(f) 映射回原始数据空间。

随主成分个数 M 的变化。我们可以看到，主成分的重要性迅速下降，增加更多 PC 只能带来边际收益。这与图 10.5 的观察完全一致：在那里我们发现投影数据的大部分方差仅由少数几个主成分捕获。用大约 550 个 PC，我们就能基本上完全重构包含数字“8”的训练数据（边界附近某些像素在整个数据集中无变化，因为它们始终为黑色）。

10.7　隐变量视角

原书 p.340

在前面几节中，我们没有使用任何概率模型的概念，而是用最大方差视角与投影视角推导了 PCA。一方面，这种做法之所以吸引人，是因为它使我们可以绕开概率论带来的一切数学困难；但另一方面，概率模型会给我们带来更大的灵活性与有用的洞见。更具体地说，概率模型将：

- 自带似然函数，使我们能够显式处理含噪声的观测（这是我们先前甚至未曾讨论过的）；
- 使我们能够通过边缘似然做贝叶斯模型比较，如第 8.6 节所述；
- 把 PCA 视为一个生成模型，使我们能够模拟新数据；
- 使我们能够直接建立与相关算法的联系；
- 通过应用贝叶斯定理，处理随机缺失的数据维度；
- 让我们能够衡量一个新数据点的新颖程度；
- 给我们一条有原则的途径来扩展模型，例如扩展为 PCA 模型的混合；

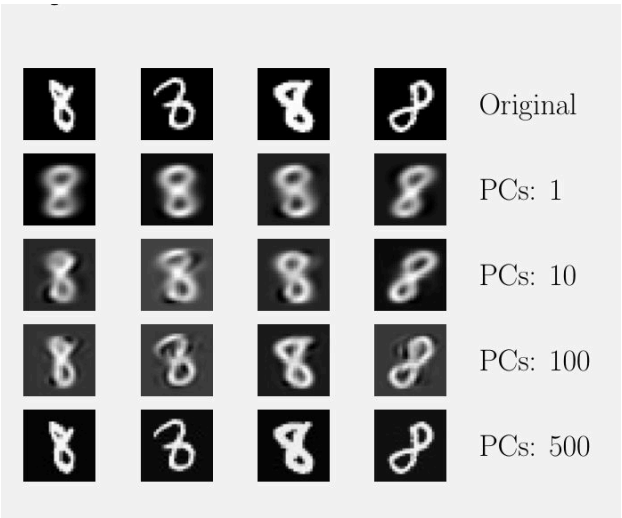


图 10.12: 增加主成分个数对重构的影响。

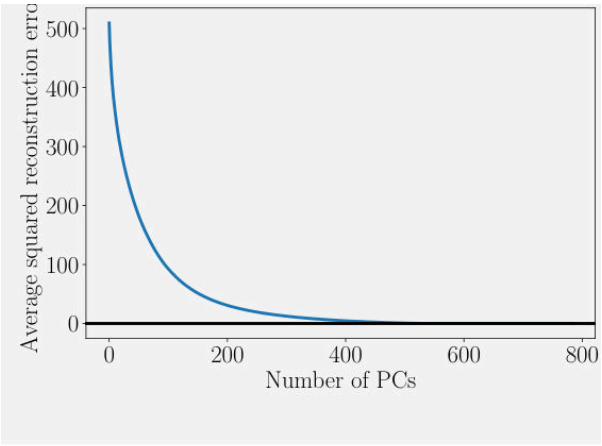


图 10.13: 平均平方重构误差随主成分个数的变化。平均平方重构误差等于主子空间正交补中各特征值之和。

- 把我们在前面几节推导的 PCA 作为一个特例包含在内；
- 通过对模型参数边缘化，允许完全的贝叶斯处理。

通过引入一个连续值隐变量 $z \in \mathbb{R}^M$，可以把 PCA 表述为一个概率隐变量模型。Tipping and Bishop (1999) 提出了这个隐变量模型，称为概率 PCA（probabilistic PCA, PPCA）。PPCA 解决了上述大部分问题，而我们通过最大化投影空间方差或最小化重构误差所得到的 PCA 解，是无噪声情形下最大似然估计的一个特例。

概率PCA

10.7.1　生成过程与概率模型

在 PPCA 中，我们显式写出线性降维的概率模型。为此，我们假设一个连续隐变量 $z \in \mathbb{R}^M$，其先验为标准正态 $p(z) = \mathcal{N}(z \mid 0, I)$，并假设隐变量与观测数据 x 之间存在线性关系：

$$x = Bz + \mu + \epsilon \in \mathbb{R}^D \,, \tag{10.63}$$

其中 $\epsilon \sim \mathcal{N}(\epsilon \mid 0, \sigma^2 I)$ 是高斯观测噪声，$B \in \mathbb{R}^{D\times M}$ 与 $\mu \in \mathbb{R}^D$ 描述从隐变量到观测变量的线性/仿射映射。因此，PPCA 通过下式联系隐变量与观测变量：

$$p(x \mid z, B, \mu, \sigma^2) = \mathcal{N}(x \mid Bz + \mu, \sigma^2 I) \,. \tag{10.64}$$

总体上，PPCA 诱导出如下生成过程：

$$z_n \sim \mathcal{N}(z_n \mid 0, I) \tag{10.65}$$

$$x_n \mid z_n \sim \mathcal{N}(x_n \mid Bz_n + \mu, \sigma^2 I) \,. \tag{10.66}$$

要生成一个在给定模型参数下具有代表性的数据点，我们遵循祖先采样（ancestral sampling）格式：首先从 $p(z)$ 中采样一个隐变量 z_n；然后在 (10.64) 中用 z_n，以采样到的 z_n 为条件采样一个数据点，即 $x_n \sim p(x \mid z_n, B, \mu, \sigma^2)$。

祖先采样

这个生成过程使我们能够写出概率模型（即所有随机变量的联合分布；见第 8.4 节）：

$$p(x, z \mid B, \mu, \sigma^2) = p(x \mid z, B, \mu, \sigma^2) p(z) \,, \tag{10.67}$$

利用第 8.5 节的结果，这立即给出图 10.14 所示的图模型。

原书 p.341

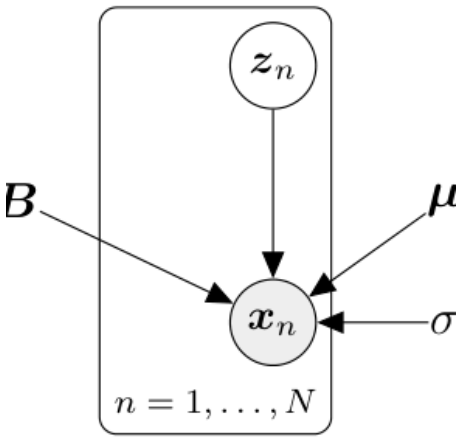


图 10.14: 概率 PCA 的图模型。观测 x_n 显式依赖于相应的隐变量 $z_n \sim \mathcal{N}(0, I)$。模型参数 B、μ 与似然参数 σ 在整个数据集上共享。

注. 注意连接隐变量 z 与观测数据 x 的箭头方向：箭头从 z 指向 x，这意味着 PPCA 模型假设高维观测 x 有一个低维的潜在原因 z。而最终我们显然关心的是在给定某些观测的情况下，反推 z 的信息。为此，我们将应用贝叶斯推断，隐式地“反转”箭头，从观测走向隐变量。

例 10.5 (用隐变量生成新数据)**.** 图 10.15 给出了用 PCA、在二维主子空间下求得的 MNIST 数字“8”的隐坐标（蓝点）。我们可以在这个隐空间中查询任意向量 z_*，并生成一张类似于数字“8”的图像 $\tilde{x}_* = Bz_*$。图中展示了八张这样生成的图像及其在隐空间中的对应表示。根据我们在隐空间中查询位置的不同，生成的图像看起来各不相同（形状、旋转、大小等）。若在远离训练数据的地方查询，我们会看到越来越多的伪影，例如左上角与右上角的数字。注意这些生成图像的内在维数仅为 2。

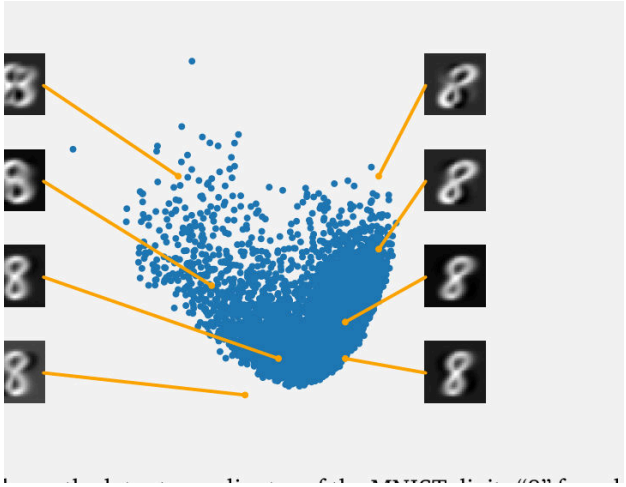


图 10.15: 生成新的 MNIST 数字。隐变量 z 可用于生成新数据 $\tilde{x} = Bz$。我们越靠近训练数据，生成的数据越真实。

10.7.2　似然与联合分布

原书 p.342

利用第 6 章的结果，我们通过把隐变量 z 积出（见第 8.4.3 节）来得到这个概率模型的似然：

$$p(x \mid B, \mu, \sigma^2) = \int p(x \mid z, B, \mu, \sigma^2) p(z) \, \mathrm{d}z \tag{10.68a}$$

$$= \int \mathcal{N}(x \mid Bz + \mu, \sigma^2 I) \, \mathcal{N}(z \mid 0, I) \, \mathrm{d}z \, . \tag{10.68b}$$

由第 6.5 节可知，该积分的解是一个高斯分布，其均值为

$$\mathbb{E}_x[x] = \mathbb{E}_z[Bz + \mu] + \mathbb{E}_\epsilon[\epsilon] = \mu \tag{10.69}$$

协方差矩阵为

$$\mathbb{V}[x] = \mathbb{V}_z[Bz + \mu] + \mathbb{V}_\epsilon[\epsilon] = \mathbb{V}_z[Bz] + \sigma^2 I \tag{10.70a}$$

$$= B\mathbb{V}_z[z]B^\top + \sigma^2 I = BB^\top + \sigma^2 I \, . \tag{10.70b}$$

式 (10.68b) 中的似然可用于模型参数的最大似然或 MAP 估计。

注. 我们不能用 (10.64) 中的条件分布做最大似然估计，因为它仍依赖于隐变量。我们做最大似然（或 MAP）估计所需的似然函数，应当只是数据 x 与模型参数的函数，而不得依赖隐变量。

由第 6.5 节可知，高斯随机变量 z 及其线性/仿射变换 $x = Bz$ 是联合高斯分布的。我们已经知道边缘分布 $p(z) = \mathcal{N}(z \mid 0, I)$ 与 $p(x) = \mathcal{N}(x \mid \mu, BB^\top + \sigma^2 I)$。缺失的互协方差为

$$\mathrm{Cov}[x, z] = \mathrm{Cov}_z[Bz + \mu] = B \, \mathrm{Cov}_z[z, z] = B \, . \tag{10.71}$$

因此，PPCA 的概率模型（即隐随机变量与观测随机变量的联合分布）显式地由下式给出：

$$p(x, z \mid B, \mu, \sigma^2) = \mathcal{N}\left(\begin{bmatrix} x \\ z \end{bmatrix} \middle| \begin{bmatrix} \mu \\ 0 \end{bmatrix}, \begin{bmatrix} BB^\top + \sigma^2 I & B \\ B^\top & I \end{bmatrix} \right) , \tag{10.72}$$

其均值向量长度为 $D + M$，协方差矩阵大小为 $(D + M) \times (D + M)$。

10.7.3　后验分布

原书 p.343

式 (10.72) 中的联合高斯分布 $p(x, z \mid B, \mu, \sigma^2)$，使我们可以直接应用第 6.5.1 节的高斯条件法则，确定后验分布 $p(z \mid x)$。给定观测 x，隐变量的后验分布为

$$p(z \mid x) = \mathcal{N}(z \mid m, C)\,, \tag{10.73}$$

$$m = B^\top (BB^\top + \sigma^2 I)^{-1}(x - \mu)\,, \tag{10.74}$$

$$C = I - B^\top (BB^\top + \sigma^2 I)^{-1} B\,. \tag{10.75}$$

注意后验协方差并不依赖于观测数据 x。对于数据空间中的新观测 x_*，我们用 (10.73) 确定相应隐变量 z_* 的后验分布。协方差矩阵 C 使我们能够评估该嵌入的置信度。一个行列式（度量体积）很小的协方差矩阵 C 告诉我们：隐嵌入 z_* 相当确定。若得到的后验分布 $p(z_* \mid x_*)$ 方差很大，我们可能面对一个离群点。然而，我们可以探索这个后验分布，以理解在该后验下还有哪些数据点 x 是合理的。为此，我们利用 PPCA 背后的生成过程：通过生成在该后验下合理的新数据，来探索隐变量上的后验分布：

1. 从隐变量上的后验分布 (10.73) 中采样一个隐变量 $z_* \sim p(z \mid x_*)$。
2. 从 (10.64) 中采样一个重构向量 $\tilde{x}_* \sim p(x \mid z_*, B, \mu, \sigma^2)$。

若我们把这个过程重复许多次，就可以探索隐变量 z_* 上的后验分布 (10.73) 及其对观测数据的影响。这个采样过程实际上是在假设在该后验下合理的数据。

10.8　拓展阅读

我们从两个视角推导了 PCA：(a) 最大化投影空间中的方差；(b) 最小化平均重构误差。然而，PCA 还可以从其他视角解释。回顾我们所做的工作：取高维数据 $x \in \mathbb{R}^D$，用矩阵 $B^\top$ 找到一个低维表示 $z \in \mathbb{R}^M$。B 的各列是数据协方差矩阵 S 与最大特征值相关联的特征向量。一旦有了低维表示 z，我们就可以（在原始数据空间中）得到它的一个高维版本 $x \approx \tilde{x} = Bz = BB^\top x \in \mathbb{R}^D$，其中 $BB^\top$ 是一个投影矩阵。

原书 p.344

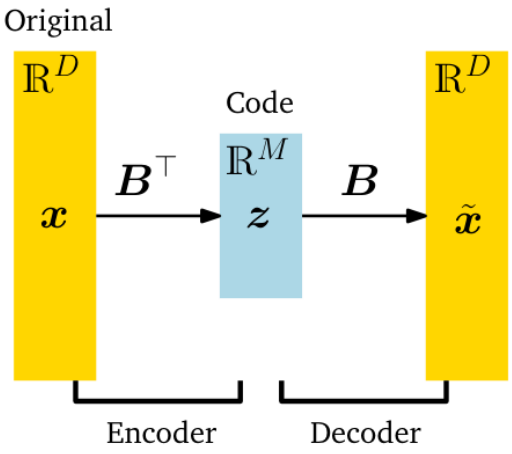


图 10.16: PCA 可看作一个线性自编码器。它把高维数据 x 编码为低维表示（编码）$z \in \mathbb{R}^M$，再用解码器解码 z。解码向量 $\tilde{x}$ 是原始数据 x 在 M 维主子空间上的正交投影。

我们还可以把 PCA 看作一个线性自编码器（auto-encoder），如图 10.16 所示。自编码器把数据 $x_n \in \mathbb{R}^D$ 编码为编码 $z_n \in \mathbb{R}^M$，再把它解码为与 x_n 相似的 $\tilde{x}_n$。从数据到编码的映射称为编码器（encoder），从编码回到原始数据空间的映射称为解码器（decoder）。若我们考虑线性映射，其中编码由 $z_n = B^\top x_n \in \mathbb{R}^M$ 给出，且我们关心最小化数据 x_n 与其重构 $\tilde{x}_n = Bz_n$（$n = 1, \ldots, N$）之间的平均平方误差，则得到

自编码器

$$\frac{1}{N}\sum_{n=1}^{N}\|x_n - \tilde{x}_n\|^2 = \frac{1}{N}\sum_{n=1}^{N}\|x_n - BB^\top x_n\|^2 \,. \tag{10.76}$$

这意味着我们最终得到与第 10.3 节所讨论的 (10.29) 相同的目标函数，因此当我们最小化平方自编码损失时，就得到 PCA 解。若把 PCA 的线性映射替换为非线性映射，就得到非线性自编码器。一个突出的例子是深度自编码器，其中线性函数被深度神经网络取代。在此语境下，编码器也称为识别网络（recognition network）或推断网络（inference network），而解码器也称为生成器（generator）。

识别网络　生成器网络

PCA 的另一种解释与信息论有关。我们可以把编码看作原始数据点的一个更小或压缩后的版本。当我们用编码重构原始数据时，得到的并不是精确的数据点，而是它的一个略微失真或含噪的版本。这意味着我们的压缩是“有损的”。直观上，我们希望最大化原始数据与低维编码之间的相关性。更形式化地，这与互信息有关。于是，通过最大化互信息（信息论中的一个核心概念），我们将得到与第 10.3 节所讨论的相同 PCA 解（MacKay, 2003）。

在关于 PPCA 的讨论中，我们假设模型参数（即 B、μ 与似然参数 σ^2）是已知的。Tipping and Bishop (1999) 描述了如何在 PPCA 设定下推导这些参数的最大似然估计（注意本章使用了不同的记号）。把 D 维数据投影到 M 维子空间时，最大似然参数为

原书 p.345

$$\mu_{\mathrm{ML}} = \frac{1}{N}\sum_{n=1}^{N} x_n \,, \tag{10.77}$$

$$B_{\mathrm{ML}} = T(\Lambda - \sigma^2 I)^{\frac{1}{2}} R \,, \tag{10.78}$$

$$\sigma^2_{\mathrm{ML}} = \frac{1}{D-M}\sum_{j=M+1}^{D} \lambda_j \,, \tag{10.79}$$

其中 $T \in \mathbb{R}^{D\times M}$ 包含数据协方差矩阵的 M 个特征向量，$\Lambda = \mathrm{diag}(\lambda_1, \ldots, \lambda_M) \in \mathbb{R}^{M\times M}$ 是一个对角矩阵，其对角元为与主成分轴关联的特征值，$R \in \mathbb{R}^{M\times M}$ 是任意正交矩阵。最大似然解 B_{ML} 在相差任意正交变换的意义下唯一：例如，我们可以用任意旋转矩阵 R 右乘 B_{ML}，因此 (10.78) 本质上是一个奇异值分解（见第 4.5 节）。证明梗概见 Tipping and Bishop (1999)。

式 (10.77) 中 μ 的最大似然估计是数据的样本均值。式 (10.79) 中观测噪声方差 σ^2 的最大似然估计，是主子空间正交补中的平均方差，即前 M 个主成分无法捕获的剩余平均方差被当作观测噪声。

在 $\sigma \to 0$ 的无噪声极限下，PPCA 与 PCA 给出相同的解：由于数据协方差矩阵 S 对称，它可以对角化（见第 4.4 节），即存在由 S 的特征向量构成的矩阵 T，使得

$$S = T\Lambda T^{-1} \,. \tag{10.80}$$

在 PPCA 模型中，数据协方差矩阵就是高斯似然 $p(x \mid B, \mu, \sigma^2)$ 的协方差矩阵，即 $BB^\top + \sigma^2 I$，见 (10.70b)。当 $\sigma \to 0$ 时，我们得到 $BB^\top$，因此该数据协方差必须等于 PCA 的数据协方差（及其 (10.80) 的分解），于是

$$\mathrm{Cov}[\mathcal{X}] = T\Lambda T^{-1} = BB^\top \quad \Longleftrightarrow \quad B = T\Lambda^{\frac{1}{2}} R \,, \tag{10.81}$$

即在 $\sigma = 0$ 时我们得到 (10.78) 中的最大似然估计。由 (10.78) 与 (10.80) 可以清楚看出，(P)PCA 对数据协方差矩阵做了一个分解。

在数据顺序到达的流式设定中，建议使用迭代的期望最大化（EM）算法做最大似然估计（Roweis, 1998）。

为确定隐变量的维数（即编码长度，也就是我们投影数据所到低维子空间的维数），Gavish and Donoho (2014) 给出启发式建议：若能估计数据的噪声方差 σ^2，则应丢弃所有小于 $4\sigma\sqrt{D}/\sqrt{3}$ 的奇异值。或者，我们可以使用（嵌套）交叉验证（第 8.6.1 节）或贝叶斯模型选择准则（第 8.6.2 节讨论）来确定数据内在维数的良好估计（Minka, 2001b）。

原书 p.346

与第 9 章关于线性回归的讨论类似，我们可以对模型参数施加一个先验分布并将其积出。这样做，(a) 避免了参数的点估计及点估计带来的种种问题（见第 8.6 节），(b) 允许自动选择隐空间恰当的维数 M。在这种由 Bishop (1999) 提出的贝叶斯 PCA（Bayesian PCA）中，对模型参数施加先验 $p(\mu, B, \sigma^2)$。生成过程使我们可以把模型参数积出，而不是以它们为条件，从而解决过拟合问题。由于这种积分在解析上不可行，Bishop (1999) 建议使用近似推断方法，例如 MCMC 或变分推断。这些近似推断技术的更多细节参见 Gilks et al. (1996) 与 Blei et al. (2017)。

贝叶斯PCA

在 PPCA 中，我们考虑线性模型 $p(x_n \mid z_n) = \mathcal{N}(x_n \mid Bz_n + \mu, \sigma^2 I)$，先验 $p(z_n) = \mathcal{N}(0, I)$，其中所有观测维度受相同大小噪声的影响。若允许每个观测维度 d 有不同的方差 σ_d^2，我们就得到因子分析（factor analysis, FA）（Spearman, 1904; Bartholomew et al., 2011）。这意味着 FA 比 PPCA 给似然带来更大的灵活性，但仍要求数据由模型参数 B μ 解释。然而，FA 不再有解析的最大似然解，因此我们需要使用迭代格式（例如期望最大化算法）来估计模型参数。在 PPCA 中所有驻点都是全局最优，而对 FA 这不再成立。与 PPCA 相比，FA 在缩放数据时不变，但在旋转数据时会返回不同的解。

因子分析

原书 p.347

另一个与 PCA 密切相关的算法是独立成分分析（independent component analysis, ICA）（Hyvarinen et al., 2001）。仍从隐变量视角 $p(x_n \mid z_n) = \mathcal{N}(x_n \mid Bz_n + \mu, \sigma^2 I)$ 出发我们现在把 z_n 的先验改为非高斯分布。ICA 可用于盲源分离（blind-source separation）想象你在一个繁忙的火车站，许多人在交谈。你的耳朵扮演麦克风的角色，它们线性地混合了车站中不同的语音信号。盲源分离的目标是识别出混合信号的各个组成部分。

独立成分分析

盲源分离

如前所述，在 PPCA 最大似然估计的语境中，原始 PCA 解对任意旋转都不变。因此，PCA 可以识别信号所在的最佳低维子空间，但不能识别信号本身（Murphy, 2012）。ICA 通过修改潜在源上的先验分布 $p(z)$ 来解决这一问题，要求 $p(z)$ 为非高斯先验。ICA 的更多细节参见 Hyvarinen et al. (2001) 与 Murphy (2012)。

PCA、因子分析与 ICA 是用线性模型做降维的三个例子。Cunningham and Ghahramani (2015) 给出了更广泛的线性降维综述。

我们这里讨论的 (P)PCA 模型还允许若干重要推广。在第 10.5 节中，我们说明了当输入维数 D 显著大于数据点数 N 时如何做 PCA。通过利用“PCA 可由计算（许多）内积来完成”这一洞见，可以把这一想法推到极致：考虑无穷维特征。核技巧（kernel trick）是核 PCA（kernel PCA）的基础，它使我们能够隐式地计算无穷维特征之间的内积（Schölkopf et al., 1998; Schölkopf and Smola, 2002）。

核PCA

还有一些由 PCA 导出的非线性降维技术（Burges (2010) 给出了很好的综述）。我们在本节先前讨论的 PCA 自编码器视角，可用于把 PCA 表述为深度自编码器的一个特例。在深度自编码器中，编码器与解码器都由多层前馈神经网络表示，而它们本身就是非线性映射。若把这些神经网络中的激活函数设为恒等函数，模型就等价于 PCA。另一种非线性降维方法是由 Lawrence (2005) 提出的高斯过程隐变量模型（Gaussian process latent-variable model, GP-LVM）。GP-LVM 从我们用来推导 PPCA 的隐变量视角出发，用高斯过程（GP）替换隐变量 z 与观测 x 之间的线性关系。GP-LVM 不像 PPCA 那样估

深度自编码器

GP-LVM

计映射的参数，而是把模型参数边缘化，并对隐变量 z 做点估计。与贝叶斯 PCA 类似，由 Titsias and Lawrence (2010) 提出的贝叶斯 GP-LVM 在隐变量 z 上维持一个分布，并用近似推断把它们也积出。

贝叶斯

GP-LVM

第 11 章　密度估计：高斯混合模型

原书 p.348

在前面几章中，我们已经讨论了机器学习中的两个基本问题：回归（第 9 章）与降维（第 10 章）。本章我们来考察机器学习的第三根支柱：密度估计。在这一过程中，我们将引入若干重要概念，例如期望最大化（expectation maximization, EM）算法，以及用混合模型做密度估计的隐变量视角。

密度估计

EM 算法

当我们把机器学习应用于数据时，常常希望以某种方式把数据表示出来。一种直截了当的做法是：把数据点本身当作数据的表示；图 11.1 给出了一个例子。然而，如果数据集非常庞大，或者我们感兴趣的是刻画数据的某些特征，这种做法可能并无裨益。在密度估计中，我们用来自某个参数族的密度（例如高斯分布或 Beta 分布）来紧凑地表示数据。举例来说，我们可能希望求出某个数据集的均值与方差，以便用一个高斯分布紧凑地表示该数据。均值与方差可以借助第 8.3 节讨论过的工具求得：最大似然估计或最大后验估计。随后，我们可以用这个高斯分布的均值与方差来表示数据背后的分布——也就是说，如果我们从该分布中抽样，就认为数据集是这一分布的一个典型实现。

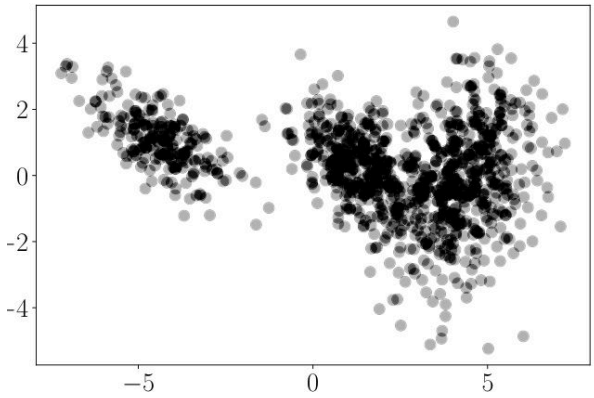


图 11.1: 无法用一个高斯分布有意义地表示的二维数据集。

实践中，高斯（以及我们迄今遇到的所有其他分布）的建模能力是有限的。例如，用一个高斯去逼近生成图 11.1 中数据的真实密度，效果会很差。下面我们来考察一族表达能力更强、可用于密度估计的分布：混合模型。

混合模型

混合模型可以通过 K 个简单（基）分布的凸组合来描述一个分布 $p(x)$：

$$p(x) = \sum_{k=1}^{K} \pi_k p_k(x) \tag{11.1}$$

$$0 \leqslant \pi_k \leqslant 1, \qquad \sum_{k=1}^{K} \pi_k = 1, \tag{11.2}$$

其中各分量 p_k 是某一基本分布族中的成员，例如高斯分布、伯努利分布或 Gamma 分布；而 π_k 称为混合权重（mixture weight）。混合模型比相应的基分布表达能力更强，因

混合权重

为它们允许多峰的数据表示，即可以描述含有多个“簇”的数据集，例如图 11.1 中的例子。

我们将聚焦于高斯混合模型（Gaussian mixture model, GMM），其中的基本分布都是高斯分布。对给定数据集，我们的目标是最大化模型参数的似然，以此来训练 GMM 为此，我们会用到第 5 章、第 6 章以及第 7.2 节的结果。然而，与我们先前讨论过的其他应用（线性回归或 PCA）不同，我们将得不到最大似然的解析解；相反，我们会得到一组相互耦合的联立方程，只能迭代地求解它们。

高斯混合模型

11.1　高斯混合模型

原书 p.350

高斯混合模型是这样一种密度模型：我们把有限个 K 个高斯分布 $\mathcal{N}\big(x \mid \mu_k, \Sigma_k\big)$ 组合起来，使得

$$p(x \mid \theta) = \sum_{k=1}^{K} \pi_k \mathcal{N}\big(x \mid \mu_k, \Sigma_k\big) \tag{11.3}$$

$$0 \leqslant \pi_k \leqslant 1, \qquad \sum_{k=1}^{K} \pi_k = 1, \tag{11.4}$$

其中我们把 $\theta := \{\mu_k, \Sigma_k, \pi_k : k = 1, \ldots, K\}$ 定义为模型全部参数的集合。这种高斯分布的凸组合，相比单个高斯分布（在 (11.3) 中取 $K = 1$ 即退化为单个高斯），在建模复杂密度时要灵活得多。图 11.2 给出了一个示意，图中画出了各加权分量以及混合密度本身，后者由下式给出：

$$p(x \mid \theta) = 0.5\mathcal{N}\big(x \mid -2, \tfrac{1}{2}\big) + 0.2\mathcal{N}(x \mid 1, 2) + 0.3\mathcal{N}(x \mid 4, 1). \tag{11.5}$$

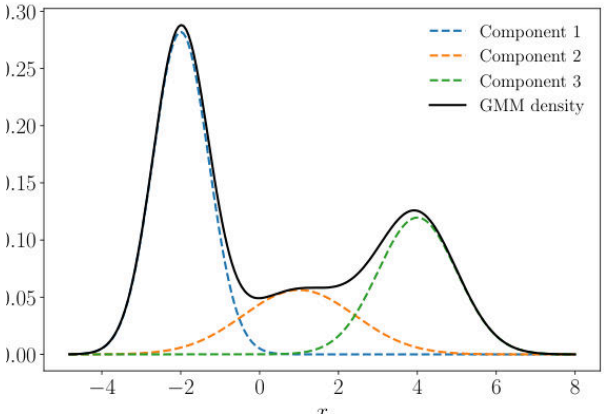


图 11.2: 高斯混合模型。高斯混合分布（黑色实线）由若干高斯分布的凸组合构成，比任意单个分量都更具表达能力。虚线表示各加权后的高斯分量。

11.2　通过最大似然学习参数

原书 p.351

假设给定一个数据集 $\mathcal{X} = \{x_1, \ldots, x_N\}$，其中 x_n（$n = 1, \ldots, N$）独立同地从某个未知分布 $p(x)$ 中抽取。我们的目标是：用一个具有 K 个混合分量的 GMM，为这个未知分布 $p(x)$ 找到一个良好的逼近/表示。GMM 的参数是 K 个均值 μ_k、协方差 Σ_k 以及混合权重 π_k。我们把所有这些自由参数汇总为 $\theta := \{\pi_k, \mu_k, \Sigma_k : k = 1, \ldots, K\}$。

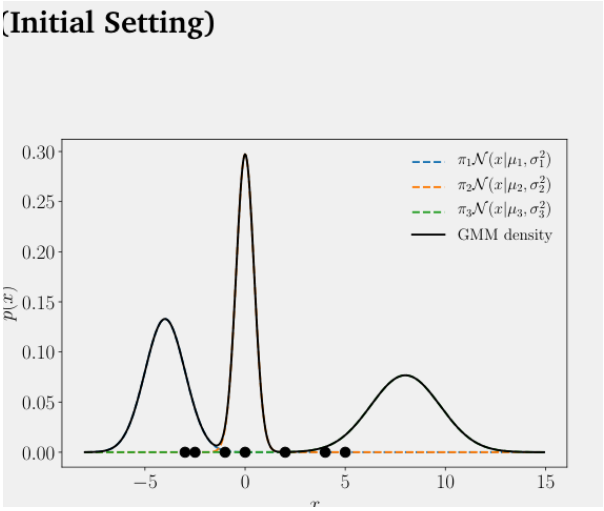


图 11.3: 初始设置：GMM（黑色实线）含三个混合分量（虚线）和七个数据点（圆点）。

例 11.1 (初始设置)**.** 贯穿本章，我们会使用一个简单的贯穿例子（running example），帮助我们说明并可视化重要概念。我们考虑一个一维数据集 $\mathcal{X} = \{-3, -2.5, -1, 0, 2, 4, 5\}$，它由七个数据点组成，我们希望找到一个具有 $K = 3$ 个分量的 GMM 来对数据密度建模。我们把各混合分量初始化为

$$p_1(x) = \mathcal{N}(x \mid -4, 1) \tag{11.6}$$

$$p_2(x) = \mathcal{N}(x \mid 0, 0.2) \tag{11.7}$$

$$p_3(x) = \mathcal{N}(x \mid 8, 3) \tag{11.8}$$

并赋予它们相等的权重 $\pi_1 = \pi_2 = \pi_3 = \frac{1}{3}$。相应的模型（以及数据点）如图 11.3 所示。

下面我们详细说明如何求得模型参数 θ 的最大似然估计 θ_{ML}。我们先写出似然，即在给定参数条件下训练数据的预测分布。利用独立同分布（i.i.d.）假设，似然可以分解为

$$p(\mathcal{X} \mid \theta) = \prod_{n=1}^{N} p(x_n \mid \theta), \qquad p(x_n \mid \theta) = \sum_{k=1}^{K} \pi_k \mathcal{N}\big(x_n \mid \mu_k, \Sigma_k\big), \tag{11.9}$$

其中每一个单项似然 $p(x_n \mid \theta)$ 都是一个高斯混合密度。于是我们得到对数似然：

$$\log p(\mathcal{X} \mid \theta) = \sum_{n=1}^{N} \log p(x_n \mid \theta) = \underbrace{\sum_{n=1}^{N} \log \sum_{k=1}^{K} \pi_k \mathcal{N}\big(x_n \mid \mu_k, \Sigma_k\big)}_{=:\mathcal{L}}. \tag{11.10}$$

我们的目标是找到使 (11.10) 中定义的对数似然 $\mathcal{L}$ 最大的参数 θ^*_{ML}。按“常规”做法，我们会计算对数似然关于模型参数 θ 的梯度 $\mathrm{d}\mathcal{L}/\mathrm{d}\theta$，令其为零，再解出 θ。然而，与我们先前做过的最大似然例子不同（例如第 9.2 节讨论线性回归时），这里得不到解析解。不过，我们可以借助一个迭代格式来求得良好的模型参数 θ_{ML}；它正是 GMM 的 EM 算法。其核心思想是：每次只更新一个模型参数，而把其余参数固定。

原书 p.352

注. 若我们把单个高斯分布作为目标密度，则 (11.10) 中对 k 的求和消失，log 可以直接作用到高斯分量上，于是得到

$$\log \mathcal{N}(x \mid \mu, \Sigma) = -\frac{D}{2}\log(2\pi) - \frac{1}{2}\log\det(\Sigma) - \frac{1}{2}(x-\mu)^\top \Sigma^{-1}(x-\mu). \tag{11.11}$$

这种简单形式使我们能够求得 μ 与 Σ 的解析最大似然估计，如第 8 章所述。而在 (11.10) 中，我们无法把 log 拿到对 k 的求和内部，因此得不到简单的解析最大似然解。

任一函数的局部最优值都满足：它关于参数的梯度必须为零（必要条件）；见第 7 章。在我们的问题中，当我们针对 GMM 参数 μ_k, Σ_k, π_k 优化 (11.10) 的对数似然时，得到如下必要条件：

$$\frac{\partial \mathcal{L}}{\partial \mu_k} = \mathbf{0}^\top \iff \sum_{n=1}^{N} \frac{\partial \log p(x_n \mid \theta)}{\partial \mu_k} = \mathbf{0}^\top, \tag{11.12}$$

$$\frac{\partial \mathcal{L}}{\partial \Sigma_k} = 0 \iff \sum_{n=1}^{N} \frac{\partial \log p(x_n \mid \theta)}{\partial \Sigma_k} = 0, \tag{11.13}$$

$$\frac{\partial \mathcal{L}}{\partial \pi_k} = 0 \iff \sum_{n=1}^{N} \frac{\partial \log p(x_n \mid \theta)}{\partial \pi_k} = 0. \tag{11.14}$$

对这三个必要条件，应用链式法则（见第 5.2.2 节）后，我们都需要如下形式的偏导数： 原书 p.353

$$\frac{\partial \log p(x_n \mid \theta)}{\partial \theta} = \frac{1}{p(x_n \mid \theta)} \frac{\partial p(x_n \mid \theta)}{\partial \theta}, \tag{11.15}$$

其中 $\theta = \{\mu_k, \Sigma_k, \pi_k, k = 1, \ldots, K\}$ 是模型参数，并且

$$\frac{1}{p(x_n \mid \theta)} = \frac{1}{\sum_{j=1}^{K} \pi_j \mathcal{N}\big(x_n \mid \mu_j, \Sigma_j\big)}. \tag{11.16}$$

下面我们来计算 (11.12)–(11.14) 的偏导数。但在此之前，先引入一个在本章余下部分扮演核心角色的量：职责（responsibilities）。 职责

11.2.1　职责

原书 p.354

我们定义量

$$r_{nk} := \frac{\pi_k \mathcal{N}\big(x_n \mid \mu_k, \Sigma_k\big)}{\sum_{j=1}^{K} \pi_j \mathcal{N}\big(x_n \mid \mu_j, \Sigma_j\big)} \tag{11.17}$$

为第 k 个混合分量对第 n 个数据点的**职责**（responsibility）。第 k 个混合分量对数据点 x_n 的职责 r_{nk}，正比于在给定该数据点时该混合分量的似然

$$p(x_n \mid \pi_k, \mu_k, \Sigma_k) = \pi_k \mathcal{N}\big(x_n \mid \mu_k, \Sigma_k\big). \tag{11.18}$$

因此，当某个数据点像是从某混合分量中合理抽样得到时，该混合分量对这个数据点就负有较高职责。注意 $r_n := [r_{n1}, \ldots, r_{nK}]^\top \in \mathbb{R}^K$ 是一个（归一化的）概率向量，即 $\sum_k r_{nk} = 1$ 且 $r_{nk} \geqslant 0$。这个概率向量把概率质量分配到 K 个混合分量上，我们可以把 r_n 看作把 x_n“软分配”到 K 个混合分量上的结果。因此，(11.17) 中的职责 r_{nk} 表示的是：x_n 由第 k 个混合分量生成的概率。 Boltzmann/Gibbs 职责 = 生成概率

例 11.2 (职责)**.** 对于图 11.3 中的例子，我们计算职责 r_{nk}（矩阵形式）：

$$\begin{bmatrix} 1.0 & 0.0 & 0.0 \\ 1.0 & 0.0 & 0.0 \\ 0.057 & 0.943 & 0.0 \\ 0.001 & 0.999 & 0.0 \\ 0.0 & 0.066 & 0.934 \\ 0.0 & 0.0 & 1.0 \\ 0.0 & 0.0 & 1.0 \end{bmatrix} \in \mathbb{R}^{N \times K}. \tag{11.19}$$

这里第 n 行告诉我们所有混合分量对 x_n 的职责。一个数据点所对应的 K 个职责之和（即每一行之和）为 1。第 k 列则概览了第 k 个混合分量的职责情况。我们可以看到，第三个混合分量（第三列）对前四个数据点几乎不负责任，但对其余数据点承担了很大职责。一列所有元素之和给出 N_k，即第 k 个混合分量的总职责。在我们的例子中，得到 $N_1 = 2.058$，$N_2 = 2.008$，$N_3 = 2.934$。

原书 p.355

下面我们在给定职责的条件下，确定模型参数 μ_k, Σ_k, π_k 的更新方式。我们会看到，各更新方程都依赖于职责，这使得最大似然估计问题不存在解析解。不过，在职责给定时，我们每次只更新一个模型参数、而固定其余参数；此后再重新计算职责。反复迭代这两步，最终会收敛到某个局部最优解，这正是 EM 算法的一个具体实例。我们将在第 11.3 节更详细地讨论它。

11.2.2　更新均值

定理 11.1 (GMM 均值的更新)**.** *GMM* 均值参数 μ_k（$k = 1, \dots, K$）的更新由下式给出：

$$\mu_k^{\text{new}} = \frac{\sum_{n=1}^{N} r_{nk} x_n}{\sum_{n=1}^{N} r_{nk}}, \tag{11.20}$$

其中职责 r_{nk} 定义于 (11.17)。

注. (11.20) 中各混合分量均值 μ_k 的更新，通过 (11.17) 给出的 r_{nk}，依赖于所有均值、协方差矩阵 Σ_k 和混合权重 π_k。因此，我们无法一次性求得所有 μ_k 的解析解。

证明. 由 (11.15) 可知，对数似然关于均值参数 μ_k（$k = 1, \dots, K$）的梯度，要求我们计算偏导数

$$\frac{\partial p(x_n \mid \theta)}{\partial \mu_k} = \sum_{j=1}^{K} \pi_j \frac{\partial \mathcal{N}\big(x_n \mid \mu_j, \Sigma_j\big)}{\partial \mu_k} = \pi_k \frac{\partial \mathcal{N}\big(x_n \mid \mu_k, \Sigma_k\big)}{\partial \mu_k} \tag{11.21a}$$

$$= \pi_k \left(x_n - \mu_k\right)^\top \Sigma_k^{-1} \mathcal{N}\big(x_n \mid \mu_k, \Sigma_k\big), \tag{11.21b}$$

这里我们利用了“只有第 k 个混合分量依赖于 μ_k”这一事实。

把 (11.21b) 的结果代入 (11.15)，并把各项合到一起，便得到 $\mathcal{L}$ 关于 μ_k 所要求的偏导数：

$$\frac{\partial \mathcal{L}}{\partial \mu_k} = \sum_{n=1}^{N} \frac{\partial \log p(x_n \mid \theta)}{\partial \mu_k} = \sum_{n=1}^{N} \frac{1}{p(x_n \mid \theta)} \frac{\partial p(x_n \mid \theta)}{\partial \mu_k} \tag{11.22a}$$

$$= \sum_{n=1}^{N} (x_n - \mu_k)^\top \Sigma_k^{-1} \underbrace{\frac{\pi_k \mathcal{N}\big(x_n \mid \mu_k, \Sigma_k\big)}{\sum_{j=1}^{K} \pi_j \mathcal{N}\big(x_n \mid \mu_j, \Sigma_j\big)}}_{= r_{nk}} \tag{11.22b}$$

$$= \sum_{n=1}^{N} r_{nk} (x_n - \mu_k)^\top \Sigma_k^{-1}. \tag{11.22c}$$

这里我们使用了 (11.16) 的恒等式以及 (11.21b) 的偏导结果，从而得到 (11.22b)；其中 r_{nk} 即我们在 (11.17) 中定义的职责。

现在我们求解 (11.22c)，令 $\partial \mathcal{L}(\mu_k^{\text{new}}) / \partial \mu_k = \mathbf{0}^\top$，得到

$$\sum_{n=1}^{N} r_{nk} x_n = \sum_{n=1}^{N} r_{nk} \mu_k^{\text{new}} \quad \Longleftrightarrow \quad \mu_k^{\text{new}} = \frac{\sum_{n=1}^{N} r_{nk} x_n}{\sum_{n=1}^{N} r_{nk}} = \frac{1}{N_k} \sum_{n=1}^{N} r_{nk} x_n, \tag{11.23}$$

其中我们定义

$$N_k := \sum_{n=1}^{N} r_{nk} \tag{11.24}$$

为第 k 个混合分量对整个数据集的总职责。定理 11.1 得证。 □

原书 p.356

直观上，(11.20) 可解释为均值的一个重要性加权蒙特卡洛估计，其中数据点 x_n 的重要性权重就是第 k 个簇对 x_n 的职责 r_{nk}（$k = 1, \ldots, K$）。因此，均值 μ_k 会被以强度 r_{nk} 拉向数据点 x_n；对于相应混合分量负有高职责（即高似然）的数据点，均值会被更强地拉过去。图 11.4 说明了这一点。我们也可以把 (11.20) 中的均值更新解释为：在由下式给出的分布下所有数据点的期望

均值被拉向数据

$$r_k := [r_{1k}, \ldots, r_{Nk}]^\top / N_k, \tag{11.25}$$

它是一个归一化的概率向量，即

$$\mu_k \leftarrow \mathbb{E}_{r_k}[X]. \tag{11.26}$$

原书 p.357

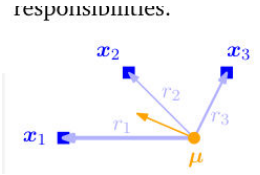


图 11.4: GMM 中混合分量均值参数的更新。均值 μ 被以相应职责为权重拉向各个数据点。

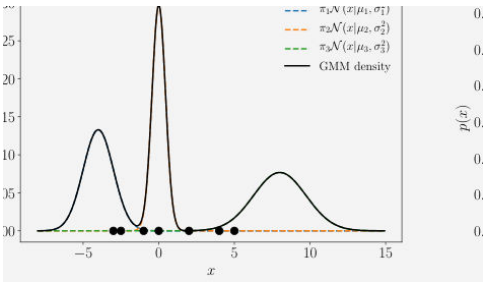
例 11.3 (均值更新)**.** 在图 11.3 的例子中，均值按如下方式更新：

$$\mu_1 : -4 \to -2.7 \tag{11.27}$$

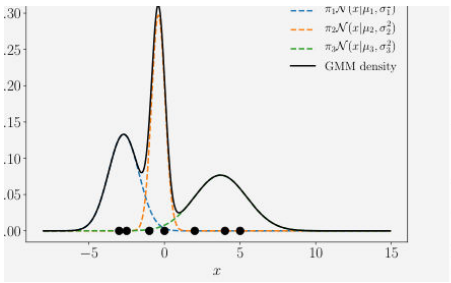
$$\mu_2 : 0 \to -0.4 \tag{11.28}$$

$$\mu_3 : 8 \to 3.7 \tag{11.29}$$

这里我们看到，第一和第三个混合分量的均值朝数据所在区域移动，而第二个分量的均值变化不大。图 11.5 说明了这一变化：图 11.5(a) 给出更新均值之前的 GMM 密度，图 11.5(b) 给出更新均值 μ_k 之后的 GMM 密度。



(a) 更新均值之前的 GMM 密度与各分量。



(b) 更新均值 μ_k（保持方差与混合权重不变）之后的 GMM 密度与各分量。

图 11.5: GMM 中更新均值的效果。

(11.20) 中均值参数的更新看起来相当直接。但请注意，职责 r_{nk} 是所有 $j = 1, \ldots, K$ 的 π_j, μ_j, Σ_j 的函数，因此 (11.20) 的更新依赖于 GMM 的所有参数；而我们在第 9.2 节线性回归或第 10 章 PCA 中得到的那种解析解，在这里是得不到的。 原书 p.358

11.2.3　更新协方差

定理 11.2 (GMM 协方差的更新)**.** *GMM* 协方差参数 Σ_k（$k = 1, \ldots, K$）的更新由下式给出：

$$\Sigma_k^{\text{new}} = \frac{1}{N_k} \sum_{n=1}^{N} r_{nk}(x_n - \mu_k)(x_n - \mu_k)^\top, \tag{11.30}$$

其中 r_{nk} 与 N_k 分别定义于 (11.17) 与 (11.24)。

证明. 为证明定理 11.2，我们的做法是：计算对数似然 $\mathcal{L}$ 关于协方差 Σ_k 的偏导数，令其为零，再解出 Σ_k。我们从一般形式出发： 原书 p.359

$$\frac{\partial \mathcal{L}}{\partial \Sigma_k} = \sum_{n=1}^{N} \frac{\partial \log p(x_n \mid \theta)}{\partial \Sigma_k} = \sum_{n=1}^{N} \frac{1}{p(x_n \mid \theta)} \frac{\partial p(x_n \mid \theta)}{\partial \Sigma_k}. \tag{11.31}$$

我们已经从 (11.16) 知道了 $1/p(x_n \mid \theta)$。为得到剩下的偏导数 $\partial p(x_n \mid \theta)/\partial \Sigma_k$，我们写出高斯分布 $p(x_n \mid \theta)$ 的定义（见 (11.9)），并略去除第 k 项外的所有项，于是得到

$$\frac{\partial p(x_n \mid \theta)}{\partial \Sigma_k} = \frac{\partial}{\partial \Sigma_k} \left(\pi_k (2\pi)^{-D/2} \det(\Sigma_k)^{-1/2} \exp\left[-\tfrac{1}{2}(x_n - \mu_k)^\top \Sigma_k^{-1}(x_n - \mu_k) \right] \right) \tag{11.32a}$$

$$= \pi_k (2\pi)^{-D/2} \left[\frac{\partial}{\partial \Sigma_k} \det(\Sigma_k)^{-1/2} \exp(\cdots) + \det(\Sigma_k)^{-1/2} \frac{\partial}{\partial \Sigma_k} \exp(\cdots) \right], \tag{11.32b}$$

其中指数内省略的是 $-\frac{1}{2}(x_n - \mu_k)^\top \Sigma_k^{-1}(x_n - \mu_k)$。

现在我们使用恒等式

$$\frac{\partial}{\partial \Sigma_k} \det(\Sigma_k)^{-1/2} \overset{(5.101)}{=} -\frac{1}{2} \det(\Sigma_k)^{-1/2} \Sigma_k^{-1}, \tag{11.33}$$

$$\frac{\partial}{\partial \Sigma_k} (x_n - \mu_k)^\top \Sigma_k^{-1}(x_n - \mu_k) \overset{(5.103)}{=} -\Sigma_k^{-1}(x_n - \mu_k)(x_n - \mu_k)^\top \Sigma_k^{-1} \tag{11.34}$$

（式中 (5.101)、(5.103) 为原书第 5 章的相应公式编号），整理后得到 (11.31) 所需的偏导数：

$$\frac{\partial p(x_n \mid \theta)}{\partial \Sigma_k} = \pi_k \mathcal{N}\big(x_n \mid \mu_k, \Sigma_k\big) \cdot \Big[-\tfrac{1}{2}\big(\Sigma_k^{-1} - \Sigma_k^{-1}(x_n - \mu_k)(x_n - \mu_k)^\top \Sigma_k^{-1}\big) \Big]. \tag{11.35}$$

把各项合到一起，对数似然关于 Σ_k 的偏导数为

$$\frac{\partial \mathcal{L}}{\partial \Sigma_k} = \sum_{n=1}^{N} \frac{\partial \log p(x_n \mid \theta)}{\partial \Sigma_k} = \sum_{n=1}^{N} \frac{1}{p(x_n \mid \theta)} \frac{\partial p(x_n \mid \theta)}{\partial \Sigma_k} \tag{11.36a}$$

$$= \sum_{n=1}^{N} \underbrace{\frac{\pi_k \mathcal{N}\big(x_n \mid \mu_k, \Sigma_k\big)}{\sum_{j=1}^{K} \pi_j \mathcal{N}\big(x_n \mid \mu_j, \Sigma_j\big)}}_{=r_{nk}} \cdot \Big[-\tfrac{1}{2}\big(\Sigma_k^{-1} - \Sigma_k^{-1}(x_n - \mu_k)(x_n - \mu_k)^\top \Sigma_k^{-1}\big)\Big] \tag{11.36b}$$

$$= -\frac{1}{2} \sum_{n=1}^{N} r_{nk}\big(\Sigma_k^{-1} - \Sigma_k^{-1}(x_n - \mu_k)(x_n - \mu_k)^\top \Sigma_k^{-1}\big) \tag{11.36c}$$

$$= -\frac{1}{2}\Sigma_k^{-1} \underbrace{\sum_{n=1}^{N} r_{nk}}_{=N_k} + \frac{1}{2}\Sigma_k^{-1}\Big(\sum_{n=1}^{N} r_{nk}(x_n - \mu_k)(x_n - \mu_k)^\top\Big)\Sigma_k^{-1}. \tag{11.36d}$$

我们看到，职责 r_{nk} 同样出现在这个偏导数中。令该偏导数为零，得到最优性的必要条件：

$$N_k \Sigma_k^{-1} = \Sigma_k^{-1}\Big(\sum_{n=1}^{N} r_{nk}(x_n - \mu_k)(x_n - \mu_k)^\top\Big)\Sigma_k^{-1} \tag{11.37a}$$

$$\iff \quad N_k I = \Big(\sum_{n=1}^{N} r_{nk}(x_n - \mu_k)(x_n - \mu_k)^\top\Big)\Sigma_k^{-1}. \tag{11.37b}$$

解出 Σ_k，得到

$$\Sigma_k^{\text{new}} = \frac{1}{N_k} \sum_{n=1}^{N} r_{nk}(x_n - \mu_k)(x_n - \mu_k)^\top, \tag{11.38}$$

其中 r_k 是 (11.25) 定义的概率向量。这就给出了 $k = 1, \ldots, K$ 时 Σ_k 的一个简单更新规则，定理 11.2 得证。 □

原书 p.360

与 (11.20) 中 μ_k 的更新类似，我们可以把 (11.30) 中协方差的更新，解释为中心化数据 $\widetilde{X}_k := \{x_1 - \mu_k, \ldots, x_N - \mu_k\}$ 平方的重要性加权期望。

例 11.4 (方差更新)**.** 在图 11.3 的例子中，方差按如下方式更新：

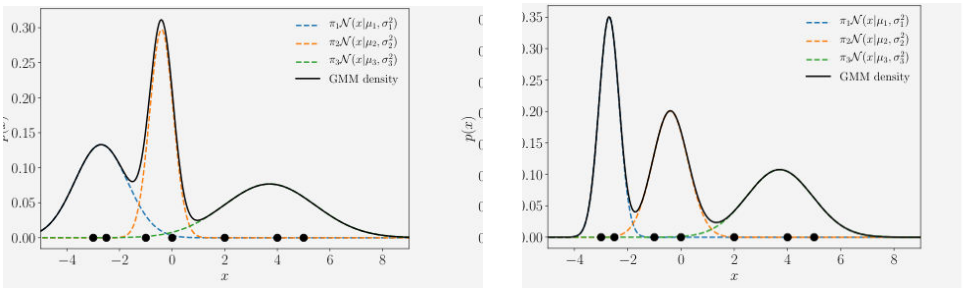
$$\sigma_1^2 : 1 \to 0.14 \tag{11.39}$$

$$\sigma_2^2 : 0.2 \to 0.44 \tag{11.40}$$

$$\sigma_3^2 : 3 \to 1.53 \tag{11.41}$$

这里我们看到，第一和第三个分量的方差显著收缩，而第二个分量的方差略有增大。图 11.6 说明了这一设置。图 11.6(a) 与图 11.5(b) 相同（但做了放大），给出更新方差之前的 GMM 密度及其各分量；图 11.6(b) 给出更新方差之后的 GMM 密度。

与均值参数的更新类似，我们可以把 (11.30) 解释为：与第 k 个混合分量相关联的数据点 x_n 的加权协方差的蒙特卡洛估计，其中权重就是职责 r_{nk}。与均值更新一样，由于职责 r_{nk} 的存在，该更新依赖于所有 $j = 1, \ldots, K$ 的 π_j, μ_j, Σ_j，因而无法求得解析解。



(a) 更新方差之前的 GMM 密度与各分量。

(b) 更新方差（保持均值与混合权重不变）之后的 GMM 密度与各分量。

图 11.6: GMM 中更新方差的效果。

11.2.4　更新混合权重

定理 11.3 (GMM 混合权重的更新)**.** *GMM* 的混合权重按如下方式更新：

$$\pi_k^{\text{new}} = \frac{N_k}{N}, \qquad k = 1, \ldots, K, \tag{11.42}$$

其中 N 是数据点个数，N_k 定义于 (11.24)。

证明. 为求得对数似然关于权重参数 π_k（$k = 1, \ldots, K$）的偏导数，我们用拉格朗日乘子（见第 7.2 节）来处理约束 $\sum_k \pi_k = 1$。拉格朗日函数为 原书 p.361

$$\mathcal{L}_{\text{ag}} = \mathcal{L} + \lambda\Big(\sum_{k=1}^{K} \pi_k - 1\Big) \tag{11.43a}$$

$$= \sum_{n=1}^{N} \log \sum_{k=1}^{K} \pi_k \mathcal{N}\big(x_n \mid \mu_k, \Sigma_k\big) + \lambda\Big(\sum_{k=1}^{K} \pi_k - 1\Big), \tag{11.43b}$$

其中 $\mathcal{L}$ 是 (11.10) 中的对数似然，第二项则编码了“所有混合权重之和必须为 1”这一等式约束。我们求得关于 π_k 的偏导数：

$$\frac{\partial \mathcal{L}_{\text{ag}}}{\partial \pi_k} = \sum_{n=1}^{N} \frac{\mathcal{N}\big(x_n \mid \mu_k, \Sigma_k\big)}{\sum_{j=1}^{K} \pi_j \mathcal{N}\big(x_n \mid \mu_j, \Sigma_j\big)} + \lambda \tag{11.44a}$$

$$= \frac{1}{\pi_k} \underbrace{\sum_{n=1}^{N} \frac{\pi_k \mathcal{N}\big(x_n \mid \mu_k, \Sigma_k\big)}{\sum_{j=1}^{K} \pi_j \mathcal{N}\big(x_n \mid \mu_j, \Sigma_j\big)}}_{=N_k} + \lambda = \frac{N_k}{\pi_k} + \lambda, \tag{11.44b}$$

以及关于拉格朗日乘子 λ 的偏导数：

$$\frac{\partial \mathcal{L}_{\text{ag}}}{\partial \lambda} = \sum_{k=1}^{K} \pi_k - 1. \tag{11.45}$$

令这两个偏导数都为零（最优的必要条件），得到方程组

$$\pi_k = -\frac{N_k}{\lambda}, \tag{11.46}$$

$$1 = \sum_{k=1}^{K} \pi_k. \tag{11.47}$$

把 (11.46) 代入 (11.47) 并解出 π_k：

$$\sum_{k=1}^{K} \pi_k = 1 \quad \Longleftrightarrow \quad -\frac{1}{\lambda} \sum_{k=1}^{K} N_k = 1 \quad \Longleftrightarrow \quad -\frac{N}{\lambda} = 1 \quad \Longleftrightarrow \quad \lambda = -N. \tag{11.48}$$

于是可以在 (11.46) 中用 $-N$ 代替 λ，得到

$$\pi_k^{\text{new}} = \frac{N_k}{N}, \tag{11.49}$$

这就给出了权重参数 π_k 的更新，定理 11.3 得证。 □

我们可以把 (11.42) 中的混合权重理解为：第 k 个簇的总职责与数据点总数之比。由于 $N = \sum_k N_k$，数据点总数也可以解释为所有混合分量合在一起的总职责，因此 π_k 就是第 k 个混合分量对数据集而言的相对重要性。

注. 由于 $N_k = \sum_{i=1}^{N} r_{ik}$，混合权重 π_k 的更新式 (11.42) 同样通过职责 r_{nk} 依赖于所有 $j = 1, \ldots, K$ 的 π_j, μ_j, Σ_j。

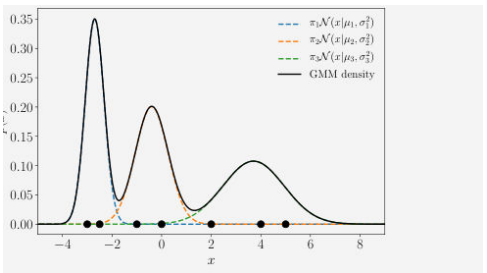
例 11.5 (权重参数更新)**.** 在图 11.3 的贯穿例子中，混合权重按如下方式更新：

$$\pi_1 : \tfrac{1}{3} \to 0.29 \tag{11.50}$$

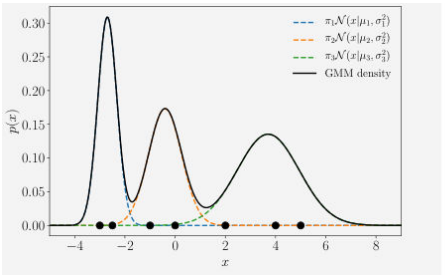
$$\pi_2 : \tfrac{1}{3} \to 0.29 \tag{11.51}$$

$$\pi_3 : \tfrac{1}{3} \to 0.42 \tag{11.52}$$

这里我们看到，第三个分量获得了更大的权重/重要性，而其他分量的重要性略有下降。图 11.7 说明了更新混合权重的效果。图 11.7(a) 与图 11.6(b) 相同，给出更新混合权重之前的 GMM 密度及其各分量；图 11.7(b) 给出更新混合权重之后的 GMM 密度。



(a) 更新混合权重之前的 GMM 密度与各分量。



(b) 更新混合权重（保持均值与方差不变）之后的 GMM 密度与各分量。注意两图纵轴刻度不同。

图 11.7: GMM 中更新混合权重的效果。

原书 p.362

总体而言，在把均值、方差和权重各更新一次之后，我们得到图 11.7(b) 所示的 GMM。与图 11.3 的初始化相比可以看到，参数更新使 GMM 密度把一部分质量移向了数据点。

在把均值、方差和权重各更新一次之后，图 11.7(b) 中的 GMM 拟合已经比图 11.3 的初始化明显更好。对数似然的值也印证了这一点：它从初始化时的 -28.3，经过一个完整更新周期后上升到 -14.4。

11.3　EM 算法

原书 p.363

遗憾的是，(11.20)、(11.30) 和 (11.42) 中的更新并不构成混合模型参数 μ_k, Σ_k, π_k 的解析解，因为职责 r_{nk} 以复杂方式依赖于这些参数。不过，这些结果提示了一个简单的迭代格式，可用于通过最大似然求解参数估计问题。期望最大化算法（EM 算法）由

Dempster et al. (1977) 提出，是一种通用的迭代格式，用于在混合模型（更一般地说，在隐变量模型）中学习参数（最大似然或 MAP）。

在高斯混合模型的例子中，我们为 μ_k, Σ_k, π_k 选择初值，并在下面两步之间交替迭代直到收敛：

- **E 步（E-step）**：计算职责 r_{nk}（即数据点 n 属于混合分量 k 的后验概率）。
- **M 步（M-step）**：用更新后的职责重新估计参数 μ_k, Σ_k, π_k。

EM 算法中的每一步都会使对数似然函数增大（Neal and Hinton, 1999）。为判断收敛，我们可以直接检查对数似然或参数。针对估计 GMM 参数，EM 算法的一个具体实例如下：

1. 初始化 μ_k, Σ_k, π_k。
2. **E 步**：用当前参数 π_k, μ_k, Σ_k 为每个数据点 x_n 计算职责 r_{nk}：

$$r_{nk} = \frac{\pi_k \mathcal{N}(x_n \mid \mu_k, \Sigma_k)}{\sum_j \pi_j \mathcal{N}(x_n \mid \mu_j, \Sigma_j)}. \tag{11.53}$$

3. **M 步**：用当前职责 r_{nk}（来自 E 步）重新估计参数 π_k, μ_k, Σ_k：

$$\mu_k = \frac{1}{N_k} \sum_{n=1}^{N} r_{nk} x_n, \tag{11.54}$$

$$\Sigma_k = \frac{1}{N_k} \sum_{n=1}^{N} r_{nk} (x_n - \mu_k)(x_n - \mu_k)^\top, \tag{11.55}$$

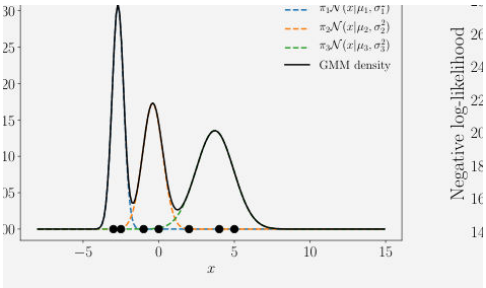
$$\pi_k = \frac{N_k}{N}. \tag{11.56}$$

E 步后用新均值更新协方差

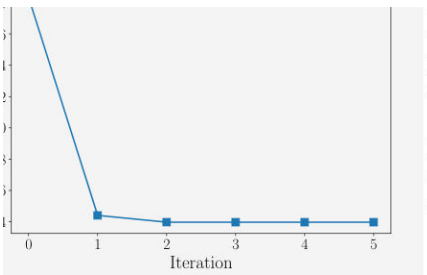
例 11.6 (GMM 拟合)**.** 当我们对图 11.3 的例子运行 EM 时，经过五次迭代得到图 11.8(a) 所示的最终结果；图 11.8(b) 则给出负对数似然随 EM 迭代如何演化。最终的 GMM 为

$$p(x) = 0.29\,\mathcal{N}(x \mid -2.75, 0.06) + 0.28\,\mathcal{N}(x \mid -0.50, 0.25) + 0.43\,\mathcal{N}(x \mid 3.64, 1.63). \tag{11.57}$$

原书 p.364



(a) 最终 GMM 拟合。五次迭代后 EM 算法收敛，返回该 GMM。



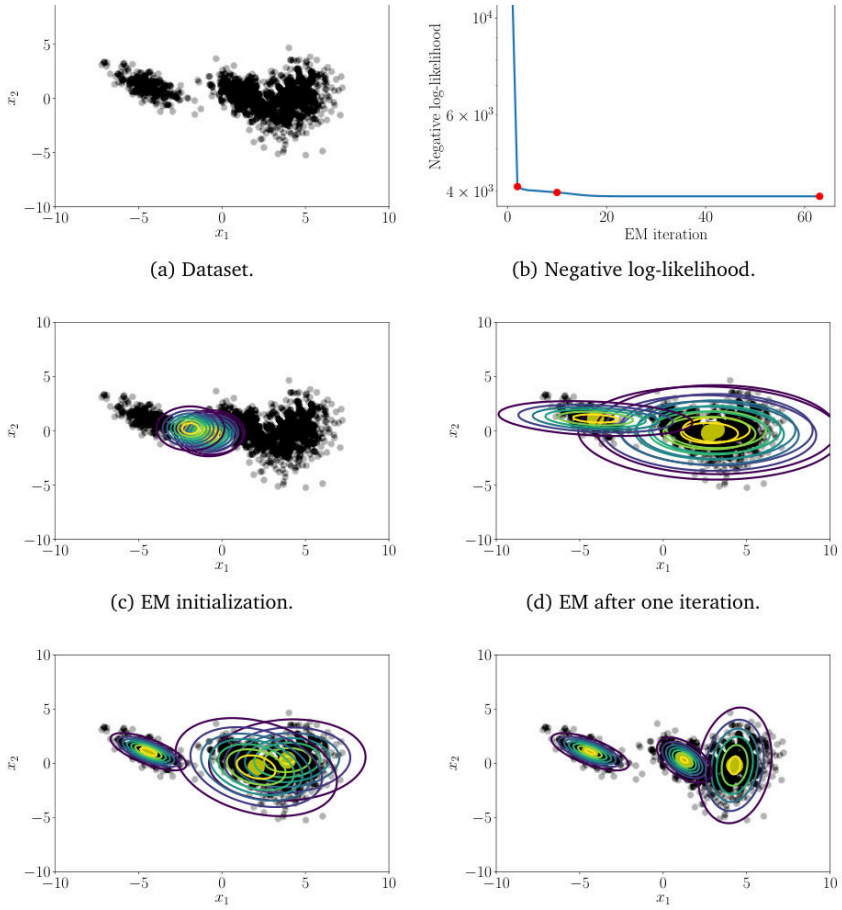
(b) 负对数似然随 EM 迭代次数的变化。

图 11.8: 把 EM 算法应用于图 11.2 中的 GMM。

原书 p.365

我们把 EM 算法应用于图 11.1 所示的二维数据集，取 $K = 3$ 个混合分量。图 11.9 展示了 EM 算法的若干步骤，并给出负对数似然随 EM 迭代的变化（图 11.9(b)）。图 11.10(a) 给出相应的最终 GMM 拟合；图 11.10(b) 则可视化收敛时各混合分量对数据点的最终职

责。数据集按 EM 收敛时各混合分量的职责着色。虽然左侧数据显然由单个混合分量负责，但右侧两个数据簇的重叠部分则可能由两个混合分量共同生成。可以清楚看到，存在一些数据点无法被唯一地指派给某一个分量（蓝色或黄色），因此这两个簇对这些点的职责都在 0.5 附近。



(a) Dataset.　(b) Negative log-likelihood.

(c) EM initialization.　(d) EM after one iteration.

(e) EM after 10 iterations.　(f) EM after 62 iterations.

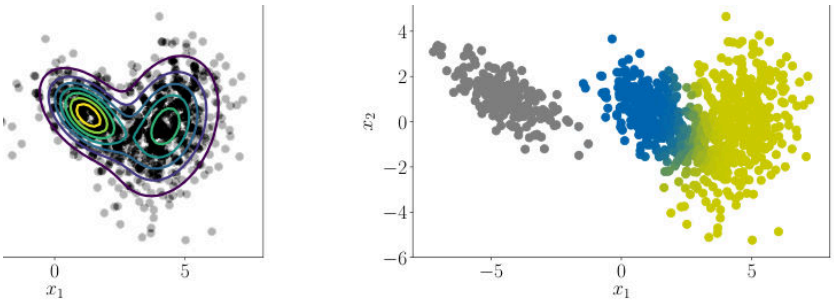
图 11.9: 用 EM 算法把一个含三个分量的高斯混合模型拟合到二维数据集的示意。(a) 数据集；(b) 负对数似然（越小越好）随 EM 迭代的变化。红点标出了对应迭代，其相应 GMM 拟合的混合分量在 (c)–(f) 中给出。黄色圆盘表示各高斯混合分量的均值。图 11.10(a) 给出最终 GMM 拟合。

11.4　隐变量视角

原书 p.366

我们可以从离散隐变量模型的视角来看待 GMM，即隐变量 z 只能取有限个值。这与 PCA 形成对比：在 PCA 中，隐变量是 $\mathbb{R}^M$ 中取值连续的数。

概率视角的优点在于：(i) 它能为我们前几节中所做的某些临时决定提供依据；(ii) 它让我们可以把职责具体解释为后验概率；(iii) 更新模型参数的迭代算法，可以有原则地推导为隐变量模型中做最大似然参数估计时的 EM 算法。



after 62 iterations.

(b) Dataset colored according to the responsibilities of the mixture components.

图 11.10: EM 收敛时的 GMM 拟合与职责。(a) EM 收敛时的 GMM 拟合；(b) 每个数据点按各混合分量的职责着色。

11.4.1　生成过程与概率模型

要推导出 GMM 的概率模型，最好先思考其**生成过程**（generative process），即借助一个概率模型来生成数据的过程。

我们假设一个含 K 个分量的混合模型，并假设一个数据点 x 恰好由某一个混合分量生成。我们引入一个两状态的二元指示变量 $z_k \in \{0, 1\}$（见第 6.2 节），它指示第 k 个混合分量是否生成了该数据点，于是

$$p(x \mid z_k = 1) = \mathcal{N}\big(x \mid \mu_k, \Sigma_k\big). \tag{11.58}$$

我们定义 $z := [z_1, \ldots, z_K]^\top \in \mathbb{R}^K$ 为一个概率向量，它含有 $K-1$ 个 0 和恰好一个 1。例如，当 $K = 3$ 时，一个合法的 z 可以是 $z = [z_1, z_2, z_3]^\top = [0, 1, 0]^\top$，它选中第二个混合分量，因为 $z_2 = 1$。 原书 p.367

注. 有时这种概率分布被称为“多项分布”（multinoulli），它是伯努利分布向多于两个取值的推广（Murphy, 2012）。

z 的性质意味着 $\sum_{k=1}^{K} z_k = 1$。因此 z 是一种独热编码（one-hot encoding，亦称 1-of-K 表示）。 独热编码

到此为止，我们都假设指示变量 z_k 是已知的。但在实际中并非如此，我们在隐变量 z 上放置一个先验分布

$$p(z) = \pi = [\pi_1, \ldots, \pi_K]^\top, \qquad \sum_{k=1}^{K} \pi_k = 1, \tag{11.59}$$

于是这个概率向量的第 k 个分量

$$\pi_k = p(z_k = 1) \tag{11.60}$$

描述了第 k 个混合分量生成数据点 x 的概率。

注 (从 GMM 中抽样). 这个隐变量模型的构造（相应图模型见图 11.11）天然给出一个非常简单的抽样过程（生成过程）来生成数据：

1. 抽样 $z^{(i)} \sim p(z)$。
2. 抽样 $x^{(i)} \sim p(x \mid z^{(i)} = 1)$。

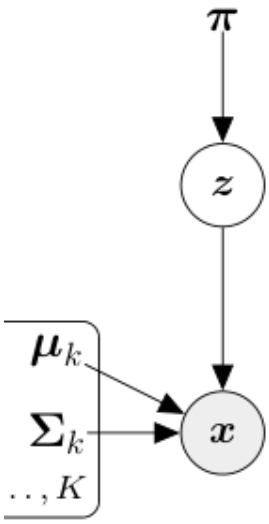


图 11.11: 含单个数据点的 GMM 的图模型。

第一步中，我们按照 $p(z) = \pi$ 随机选中一个混合分量 i（通过独热编码 z）；第二步中，我们从相应的混合分量中抽取一个样本。当我们把隐变量的样本丢弃、只留下 $x^{(i)}$ 时，就得到了来自 GMM 的合法样本。这种抽样方式——即随机变量的样本依赖于其在图模型中父节点的样本——称为**祖先采样**（ancestral sampling）。

祖先采样

一般而言，一个概率模型由数据与隐变量的联合分布定义（见第 8.4 节）。利用 (11.59) 和 (11.60) 定义的先验 $p(z)$，以及 (11.58) 的条件分布 $p(x \mid z)$，我们通过下式得到该联合分布的全部 K 个分量：

$$p(x, z_k = 1) = p(x \mid z_k = 1)p(z_k = 1) = \pi_k \mathcal{N}\big(x \mid \mu_k, \Sigma_k\big) \tag{11.61}$$

对 $k = 1, \ldots, K$ 成立，于是

$$p(x, z) = \begin{bmatrix} p(x, z_1 = 1) \\ \vdots \\ p(x, z_K = 1) \end{bmatrix} = \begin{bmatrix} \pi_1 \mathcal{N}\big(x \mid \mu_1, \Sigma_1\big) \\ \vdots \\ \pi_K \mathcal{N}\big(x \mid \mu_K, \Sigma_K\big) \end{bmatrix}, \tag{11.62}$$

这就完整地确定了概率模型。

11.4.2　似然

要在隐变量模型中得到似然 $p(x \mid \theta)$，我们需要把隐变量边缘化积出（见第 8.4.3 节）。在我们的问题中，这可以通过对 (11.62) 的联合分布 $p(x, z)$ 中所有隐变量求和来完成：

$$p(x \mid \theta) = \sum_z p(x \mid \theta, z)\, p(z \mid \theta), \qquad \theta := \{\mu_k, \Sigma_k, \pi_k : k = 1, \ldots, K\}. \tag{11.63}$$

现在我们显式地以概率模型参数 θ 为条件（此前我们省略了它）。在 (11.63) 中，我们对 z 的所有 K 种可能的独热编码求和，记为 $\sum_z$。由于每个 z 中只有一个非零分量，z 只有 K 种可能的配置/取值。例如，当 $K = 3$ 时，z 可以取

$$\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \quad \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \quad \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}. \tag{11.64}$$

在 (11.63) 中对 z 的所有可能配置求和，等价于考察 z 向量中的那个非零项并写成

$$p(x \mid \theta) = \sum_{z} p(x \mid \theta, z)\, p(z \mid \theta) \tag{11.65a}$$

$$= \sum_{k=1}^{K} p(x \mid \theta, z_k = 1)\, p(z_k = 1 \mid \theta) \tag{11.65b}$$

于是所求的边缘分布为

$$p(x \mid \theta) \overset{(11.65b)}{=} \sum_{k=1}^{K} p(x \mid \theta, z_k = 1)\, p(z_k = 1 \mid \theta) \tag{11.66a}$$

$$= \sum_{k=1}^{K} \pi_k \mathcal{N}\big(x \mid \mu_k, \Sigma_k\big), \tag{11.66b}$$

我们认出这正是 (11.3) 中的 GMM 模型。给定数据集 $\mathcal{X}$，我们立即得到似然

$$p(\mathcal{X} \mid \theta) = \prod_{n=1}^{N} p(x_n \mid \theta) \overset{(11.66b)}{=} \prod_{n=1}^{N} \sum_{k=1}^{K} \pi_k \mathcal{N}\big(x_n \mid \mu_k, \Sigma_k\big), \tag{11.67}$$

它正是 (11.9) 中的 GMM 似然。因此，带隐指示变量 z_k 的隐变量模型，是看待高斯混合模型的一种等价方式。

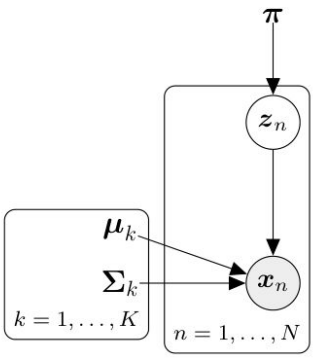


图 11.12: 含 N 个数据点的 GMM 的图模型（采用盘记法 plate notation）。

11.4.3　后验分布

原书 p.368

我们简要考察一下隐变量 z 上的后验分布。根据贝叶斯定理，“第 k 个分量生成了数据点 x”这一事件的后验为

$$p(z_k = 1 \mid x) = \frac{p(z_k = 1)\, p(x \mid z_k = 1)}{p(x)}, \tag{11.68}$$

其中边缘分布 $p(x)$ 由 (11.66b) 给出。由此得到第 k 个指示变量 z_k 的后验分布

$$p(z_k = 1 \mid x) = \frac{p(z_k = 1)\, p(x \mid z_k = 1)}{\sum_{j=1}^{K} p(z_j = 1)\, p(x \mid z_j = 1)} = \frac{\pi_k \mathcal{N}\big(x \mid \mu_k, \Sigma_k\big)}{\sum_{j=1}^{K} \pi_j \mathcal{N}\big(x \mid \mu_j, \Sigma_j\big)}, \tag{11.69}$$

我们认出它就是第 k 个混合分量对数据点 x 的职责。注意我们省略了对 GMM 参数 π_k, μ_k, Σ_k（$k = 1, \ldots, K$）的显式条件。

11.4.4　推广到完整数据集

到此为止，我们只讨论了数据集仅含单个数据点 x 的情形。但先验与后验的概念可以直接推广到含 N 个数据点 $\mathcal{X} := \{x_1, \ldots, x_N\}$ 的情形。在 GMM 的概率解释中，每个数据点 x_n 都有自己的隐变量

$$z_n = [z_{n1}, \ldots, z_{nK}]^\top \in \mathbb{R}^K. \tag{11.70}$$

先前（只考虑单个数据点 x 时）我们省略了下标 n，但现在它变得重要起来。我们在所有隐变量 z_n 之间共享同一个先验分布 π。相应的图模型见图 11.12，其中使用了盘记法（plate notation）。

条件分布 $p(x_1, \ldots, x_N \mid z_1, \ldots, z_N)$ 在数据点之间可分解，为

$$p(x_1, \ldots, x_N \mid z_1, \ldots, z_N) = \prod_{n=1}^{N} p(x_n \mid z_n). \tag{11.71}$$

为得到后验分布 $p(z_{nk} = 1 \mid x_n)$，我们沿用第 11.4.3 节中的推理，并应用贝叶斯定理：

$$p(z_{nk} = 1 \mid x_n) = \frac{p(x_n \mid z_{nk} = 1)\, p(z_{nk} = 1)}{\sum_{j=1}^{K} p(x_n \mid z_{nj} = 1)\, p(z_{nj} = 1)} \tag{11.72a}$$

$$= \frac{\pi_k \mathcal{N}\big(x_n \mid \mu_k, \Sigma_k\big)}{\sum_{j=1}^{K} \pi_j \mathcal{N}\big(x_n \mid \mu_j, \Sigma_j\big)} = r_{nk}. \tag{11.72b}$$

这意味着 $p(z_k = 1 \mid x_n)$ 是“第 k 个混合分量生成数据点 x_n”的（后验）概率，它对应于我们在 (11.17) 中引入的职责 r_{nk}。现在，职责不仅有了直观解释，也有了作为后验概率的严格数学解释。

11.4.5　再谈 EM 算法

我们先前作为最大似然估计的迭代格式引入的 EM 算法，可以从隐变量视角有原则地推导出来。给定模型参数的当前取值 $\theta^{(t)}$，E 步计算期望对数似然

$$Q(\theta \mid \theta^{(t)}) = \mathbb{E}_{z \mid x, \theta^{(t)}}\big[\log p(x, z \mid \theta)\big] \tag{11.73a}$$

$$= \int \log p(x, z \mid \theta)\, p(z \mid x, \theta^{(t)})\, \mathrm{d}z, \tag{11.73b}$$

其中 $\log p(x, z \mid \theta)$ 的期望是关于隐变量后验 $p(z \mid x, \theta^{(t)})$ 取的。M 步则通过最大化 (11.73b) 来选出一组更新后的模型参数 $\theta^{(t+1)}$。

虽然一次 EM 迭代确实会增大对数似然，但并不能保证 EM 收敛到最大似然解。EM 算法有可能收敛到对数似然的某个局部极大值。我们可以在多次 EM 运行中使用不同的参数初始化 θ，以降低陷入糟糕局部最优的风险。这里不再深入讨论，推荐读者参阅 Rogers and Girolami (2016) 与 Bishop (2006) 的优秀论述。

11.5　延伸阅读

GMM 可以被视为一个生成模型，因为用祖先采样可以很直接地生成新数据（Bishop, 2006）。对给定的 GMM 参数 π_k, μ_k, Σ_k $(k = 1, \ldots, K)$，我们先从概率向量 $[\pi_1, \ldots, \pi_K]^\top$ 中抽样出一个下标 k，再抽样一个数据点 $x \sim \mathcal{N}(\mu_k, \Sigma_k)$。把这个过程重复 N 次，就得到一个由 GMM 生成的数据集。图 11.1 就是用这种过程生成的。

贯穿本章，我们都假设分量数 K 是已知的。但在实际中往往并非如此。不过，我们可以使用第 8.6.1 节讨论的嵌套交叉验证（nested cross-validation）来找到好的模型。

高斯混合模型与 K 均值（K-means）聚类算法密切相关。K 均值同样使用 EM 算法把数据点指派到各个簇。如果我们把 GMM 中的均值看作簇中心，并忽略协方差（或把它们设为 I），就得到了 K 均值。正如 MacKay (2003) 所很好地描述的那样：K 均值把数据点“硬”指派到簇中心 μ_k，而 GMM 则通过职责做“软”指派。

硬指派与软指派

我们只是触及了 GMM 的隐变量视角与 EM 算法。注意，EM 可用于一般隐变量模型中的参数学习，例如非线性状态空间模型（Ghahramani and Roweis, 1999; Roweis and Ghahramani, 1999），以及 Barber (2012) 讨论的强化学习。因此，GMM 的隐变量视角有助于我们有原则地推导出相应的 EM 算法（Bishop, 2006; Barber, 2012; Murphy, 2012）。

我们只讨论了用最大似然估计（通过 EM 算法）来求 GMM 参数。最大似然估计受到的标准批评在这里同样适用：

- 与线性回归中一样，最大似然可能出现严重过拟合。在 GMM 情形下，当某个混合分量的均值恰好等于一个数据点、而其协方差趋于 0 时，就会发生这种情况；此时似然趋于无穷大。Bishop (2006) 和 Barber (2012) 详细讨论了这一问题。
- 我们只得到参数 π_k, μ_k, Σ_k（$k = 1, \ldots, K$）的点估计，它完全没有给出参数取值的不确定性信息。贝叶斯方法会在参数上放置一个先验，从而得到参数上的后验分布。这个后验使我们可以计算模型证据（边缘似然），用于模型比较；这就为确定混合分量个数提供了一条有原则的途径。遗憾的是，在这一设定下无法做解析推断，因为该模型没有共轭先验。不过，可以使用诸如变分推断（variational inference）之类的近似方法来得到近似后验（Bishop, 2006）。

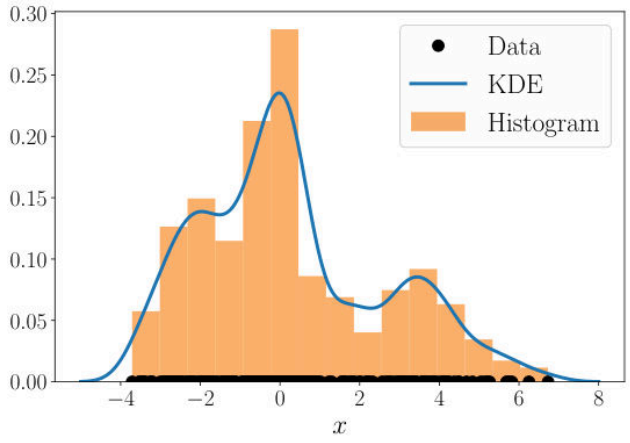


图 11.13: 直方图（橙色柱）与核密度估计（蓝色曲线）。核密度估计给出底层密度的光滑估计；而直方图则是对落入单个区间（bin）的数据点（黑色）个数做的一种不光滑计数。

本章讨论了用于密度估计的混合模型。可用的密度估计技术还有很多。在实践中，我们常使用直方图和核密度估计。

直方图

直方图提供了一种表示连续密度的非参数方法，由 Pearson (1895) 提出。构造直方图时，先把数据空间“分箱”（binning），统计落入每个箱中的数据点个数；然后在每个箱的中心画一根柱，柱高正比于该箱内的数据点数。箱宽（bin size）是一个关键的超参数，选择不当会导致过拟合或欠拟合。可以用第 8.2.4 节讨论的交叉验证来确定一个合适的箱宽。

核密度估计（kernel density estimation, KDE）由 Rosenblatt (1956) 和 Parzen (1962) 各自独立提出，是一种非参数的密度估计方法。给定 N 个独立同分布样本，核密度估

计子把底层分布表示为

$$p(x) = \frac{1}{Nh} \sum_{n=1}^{N} k\Big(\frac{x - x_n}{h}\Big), \tag{11.74}$$

其中 k 是核函数，即一个非负、且积分为 1 的函数；$h > 0$ 是光滑/带宽参数，其作用与直方图中的箱宽类似。注意我们在数据集中的每一个数据点 x_n 上都放置一个核。常用的核函数有均匀分布和高斯分布。核密度估计与直方图密切相关，但通过选择合适的核，我们可以保证密度估计的光滑性。图 11.13 以一个含 250 个数据点的数据集为例，说明了直方图与核密度估计子（采用高斯形状的核）之间的差异。

核密度估计

第 12 章　分类：支持向量机

原书 p.370

在许多情形中，我们希望机器学习算法预测若干（离散）结果中的某一个。例如，邮件客户端把邮件分为个人邮件与垃圾邮件两类；另一个例子是望远镜判断夜空中的某个天体是星系、恒星还是行星。通常结果数目很少，更重要的是，这些结果之间往往没有额外的结构。本章我们考虑输出二值的预测器，即只有两种可能的结果。这种机器学习任务称为二**分分类**（binary classification）。这与第 9 章形成对比，那里我们考虑的是输出连续值的预测问题。

二分分类

原书 p.371

对二分分类而言，标签/输出所能取的值的集合是二元的；本章我们把它们记为 $\{+1, -1\}$。换言之，我们考虑形如

$$f : \mathbb{R}^D \longrightarrow \{+1, -1\}. \tag{12.1}$$

回顾第 8 章，我们把每个样本（数据点）x_n 表示为一个由 D 个实数构成的特征向量。标签常分别称为正类与负类。读者不应把 $+1$ 这一类直觉地赋予“正向”之类的属性例如在癌症检测任务中，患癌病人常被标记为 $+1$。原则上可以使用任意两个不同的值，例如 $\{\text{True}, \text{False}\}$、$\{0, 1\}$ 或 $\{\text{red}, \text{blue}\}$。二分分类问题已被充分研究，我们把对其他方法的综述推迟到第 12.6 节。

类

我们介绍一种称为**支持向量机**（support vector machine, SVM）的方法，用于求解二分分类任务。与回归中一样，这是一个监督学习任务：我们有一组样本 $x_n \in \mathbb{R}^D$ 以及相应的（二元）标签 $y_n \in \{+1, -1\}$。给定由样本–标签对 $\{(x_1, y_1), \ldots, (x_N, y_N)\}$ 构成的训练集，我们希望估计模型的参数，使分类误差最小。与第 9 章类似，我们考虑线性模型，并把非线性掩藏在对样本的变换 ϕ 之中（式 (9.13)）。我们将在第 12.4 节重新回到 ϕ。

支持向量机

原书 p.372

SVM 在许多应用中给出了最优水准的结果，并具有可靠的理论保证（Steinwart and Christmann, 2008）。我们之所以选择用 SVM 来讲解二分分类，主要有两个原因。第一，SVM 提供了一种以几何方式思考监督学习的途径。在第 9 章中，我们用概率模型来表述机器学习问题，并用最大似然估计与贝叶斯推断来求解；而在这里，我们将考虑一种替代途径，即对机器学习任务做几何推理。它大量依赖于第 3 章讨论过的内积与投影等概念。第二个原因在于，与第 9 章不同，SVM 的优化问题没有解析解，因此我们需要借助第 7 章介绍的多种优化工具。

SVM 所体现的机器学习视角，与第 9 章的最大似然视角有微妙的差别。最大似然视角先基于数据分布的概率观点提出一个模型，再由此导出优化问题。相反，SVM 视角则是从几何直觉出发，先设计一个在训练中待优化的特定函数。我们在第 10 章已经见过类似的思路：那里我们从几何原理出发导出 PCA。在 SVM 情形中，我们遵循经验风险最小化（第 8.2 节）的原则，先设计一个要在训练数据上最小化的损失函数。

下面我们来推导在样本–标签对上训练 SVM 所对应的优化问题。直觉上，我们设想二分分类数据可以被一个超平面分隔，如图 12.1 所示。这里每个样本 x_n（一个二维向量）是一个二维位置 $(x_n^{(1)}, x_n^{(2)})$，相应的二元标签 y_n 是两种不同符号之一（橙色叉

号或蓝色圆点)。“超平面”是机器学习中常用的词，我们在第 2.8 节已经遇到过超平面。超平面是维数为 $D-1$ 的仿射子空间（若相应向量空间维数为 D)。这些样本由两类构成（有两种可能的标签)，其特征（表示样本的向量的各个分量）排列得使我们能够通过画一条直线来分隔/分类它们。

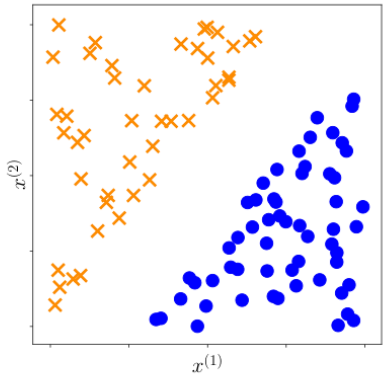


图 12.1: 二维数据示例，直观展示了存在一个线性分类器可将橙色叉号与蓝色圆点分开的情形。

下面我们把“找到两类之间的线性分隔子”这一想法形式化。我们先引入间隔（margin）的概念，再把线性分隔子推广到允许样本落在“错误”一侧、从而产生分类误差的情形。我们给出 SVM 的两种等价形式化途径：几何视角（第 12.2.4 节）与损失函数视角（第 12.2.5 节)。我们用拉格朗日乘子（第 7.2 节）推导 SVM 的对偶形式。对偶 SVM 使我们得以看到 SVM 的第三种形式化途径：用每一类样本的凸包来表述（第 12.3.2 节)。最后我们简要介绍核函数，以及如何数值地求解非线性核 SVM 优化问题。

12.1　可分超平面

原书 p.373

给定两个表示为向量 x_i、x_j 的样本，计算它们相似度的一种方式是使用内积 $\langle x_i, x_j\rangle$。回顾第 3.2 节，内积与两个向量之间的夹角密切相关。两个向量内积的取值取决于各自的长度（范数)。此外，内积使我们能够严格地定义正交、投影等几何概念。

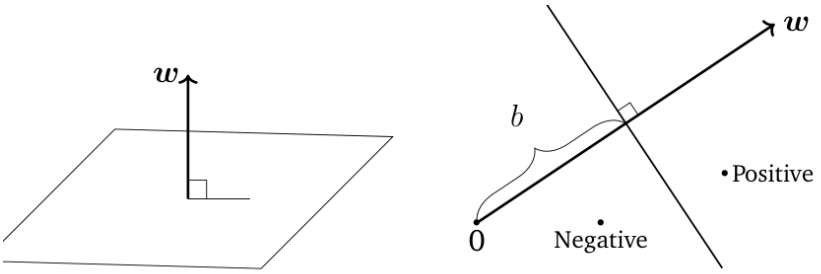
许多分类算法的主要思想是：把数据表示在 $\mathbb{R}^D$ 中，然后划分这个空间——理想情况下，使具有相同标签的样本（且不含其他样本）处于同一分区。在二分分类情形中，空间被分为两部分，分别对应正类与负类。我们考虑一种特别方便的划分方式：用一个超平面把空间（线性地）切成两半。设样本 $x \in \mathbb{R}^D$ 是数据空间中的一个元素。考虑函数

$$f : \mathbb{R}^D \longrightarrow \mathbb{R} \tag{12.2a}$$

$$x \longmapsto f(x) := \langle w, x\rangle + b, \tag{12.2b}$$

它由 $w \in \mathbb{R}^D$ 与 $b \in \mathbb{R}$ 参数化。回顾第 2.8 节，超平面是仿射子空间。因此，我们把二分分类问题中分隔两类的超平面定义为

$$\big\{x \in \mathbb{R}^D : f(x) = 0\big\}. \tag{12.3}$$



(a) Separating hyperplane in 3D

(b) Projection of the setting in (a) onto a plane

图 12.2: 可分超平面的方程 (12.3)。(a) 在三维中表示该方程的标准方式；(b) 为便于绘图，我们从侧面看超平面。

超平面的示意图见图 12.2，其中向量 w 是超平面的法向量，b 是截距。我们可以通过在超平面上任取两个样本 x_a、x_b，证明它们之间的向量与 w 正交，从而推出 w 是 (12.3) 中超平面的法向量。写成方程形式：

$$f(x_a) - f(x_b) = \langle w, x_a \rangle + b - \big(\langle w, x_b \rangle + b\big) \tag{12.4a}$$

$$= \langle w, x_a - x_b \rangle, \tag{12.4b}$$

其中第二行由内积的线性（第 3.2 节）得到。由于我们选取 x_a、x_b 在超平面上，这意味着 $f(x_a) = 0$、$f(x_b) = 0$，因而 $\langle w, x_a - x_b \rangle = 0$。回顾：当两个向量的内积为零时，它们正交。于是我们得到：w 与超平面上的任意向量正交。

注. 回顾第 2 章，我们可以用不同方式看待向量。在本章中，我们把参数向量 w 看作指示方向的箭头，即把 w 当作几何向量；相反，我们把样本向量 x 看作一个数据点（由其坐标指明），即把 x 看作向量在标准基下的坐标。

当面对一个测试样本时，我们根据它落在超平面的哪一侧，把它判为正类或负类。注意 (12.3) 不仅定义了一个超平面；它还额外定义了一个方向。换言之，它定义了超平面的正侧与负侧。因此，要对测试样本 x_{test} 分类，我们计算函数值 $f(x_{\text{test}})$：若 $f(x_{\text{test}}) \geqslant 0$ 则判为 $+1$，否则判为 -1。从几何上看，正样本位于超平面“上方”，负样本位于超平面“下方”。

训练分类器时，我们希望确保正标签样本位于超平面的正侧，即

$$\langle w, x_n \rangle + b \geqslant 0 \qquad \text{当} y_n = +1, \tag{12.5}$$

而负标签样本位于负侧，即

$$\langle w, x_n \rangle + b < 0 \qquad \text{当} y_n = -1. \tag{12.6}$$

正、负样本的几何直观见图 12.2。这两个条件常被合并写成一个方程：

$$y_n\big(\langle w, x_n \rangle + b\big) \geqslant 0. \tag{12.7}$$

当我们分别用 $y_n = 1$ 和 $y_n = -1$ 去乘 (12.5) 与 (12.6) 两边时，(12.7) 与 (12.5)、(12.6) 等价。

12.2　原始支持向量机

基于点到超平面的距离这一概念，我们现在可以讨论支持向量机了。对一个线性可

分的数据集 $\{(x_1, y_1), \ldots, (x_N, y_N)\}$，存在无穷多个候选超平面（见图 12.3），因而也存在无穷多个分类器，能在没有任何（训练）误差的情况下求解我们的分类问题。为了得到唯一解，一个思路是选择使正、负样本之间间隔最大的那个可分超平面。换言之，我们希望正、负样本被一个大间隔分开（第 12.2.1 节）。下面我们计算样本到超平面的距离，以导出间隔。回顾：给定一点（样本 x_n），超平面上离它最近的点由正交投影得到（第 3.8 节）。

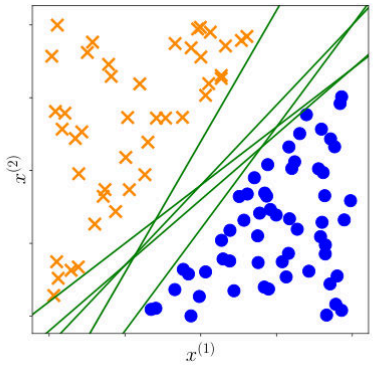


图 12.3: 可能的可分超平面。存在许多线性分类器（绿色直线）可将橙色叉号与蓝色圆点分开。

12.2.1　间隔的概念

间隔（margin）的概念直观看很简单：在数据集线性可分的前提下，它是可分超平面到数据集中最近样本的距离。然而，当我们试图把这个距离形式化时，存在一个可能令人困惑的技术细节：我们需要定义一个测量距离的尺度。一种潜在的尺度是考虑数据的尺度，即 x_n 的原始取值。这样做有问题，因为我们可以改变 x_n 的测量单位，从而改变 x_n 中的取值，进而改变到超平面的距离。正如我们很快会看到的，我们基于超平面方程 (12.3) 本身来定义尺度。

间隔 .375

考虑一个超平面 $\langle w, x\rangle + b$，以及一个样本 x_a，如图 12.4 所示。不失一般性，我们可以认为样本 x_a 位于超平面的正侧，即 $\langle w, x_a\rangle + b > 0$。我们希望计算 x_a 到超平面的距离 $r > 0$。做法是考虑 x_a 在超平面上的正交投影（第 3.8 节），记为 x'_a。由于 w 与超平面正交，我们知道距离 r 只是向量 w 的一个缩放。若 w 的长度已知，我们就能用这个缩放因子 r 算出 x_a 与 x'_a 之间的绝对距离。为方便起见，我们选择使用一个单位长度的向量（其范数为 1），即把 w 除以其范数得到 $w/\|w\|$。利用向量加法（第 2.4 节），我们得到

$$x_a = x'_a + r\frac{w}{\|w\|}. \tag{12.8}$$

思考 r 的另一种方式是：它是 x_a 在由 $w/\|w\|$ 张成的子空间中的坐标。我们已经把 x_a 到超平面的距离表示为 r；若选取 x_a 为离超平面最近的点，则这个距离 r 就是间隔。

原书 p.376

回顾：我们希望正样本离超平面远于 r，负样本离超平面远于距离 r（在负方向上）。类比于把 (12.5) 与 (12.6) 合并为 (12.7)，我们把这一目标表述为

$$y_n\big(\langle w, x_n\rangle + b\big) \geqslant r. \tag{12.9}$$

换言之，我们把“样本离超平面至少为 r（在正、负两个方向上）”的要求合并为一个不等式。

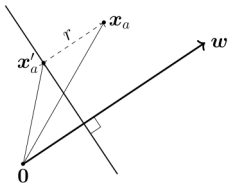


Figure
additior
distanc
hyperpl
$x_a = x$

图 12.4: 用向量加法表示到超平面的距离：$x_a = x'_a + r\,\dfrac{w}{\|w\|}$。

由于我们只关心方向，我们对模型附加一个假设：参数向量 w 为单位长度，即 $\|w\| = 1$，其中使用欧几里得范数 $\|w\| = \sqrt{w^\top w}$（第 3.1 节）。这个假设还使距离 r（式 (12.8)）有更直观的解释，因为它就是一个长度为 1 的向量的缩放因子。

注. 熟悉其他间隔讲法的读者会注意到，我们定义 $\|w\| = 1$ 的方式，与例如 Schölkopf and Smola (2002) 给出的 SVM 标准讲法不同。在第 12.2.3 节，我们将证明两种途径等价。

把三个要求汇集到一个带约束的优化问题中，我们得到目标

$$\max_{w,b,r} \underbrace{r}_{\text{间隔}} \quad \text{subject to} \quad \underbrace{y_n\big(\langle w, x_n\rangle + b\big) \geqslant r}_{\text{数据拟合}},\ \underbrace{\|w\| = 1}_{\text{归一化}},\ r > 0, \tag{12.10}$$

它表示：我们要最大化间隔 r，同时确保数据位于超平面正确的一侧。

注. 间隔的概念在机器学习中极为普遍。Vladimir Vapnik 与 Alexey Chervonenkis 曾用它证明：当间隔较大时，函数类的“复杂度”较低，因而学习成为可能（Vapnik, 2000）。事实证明，这一概念对从理论上分析泛化误差的多种不同方法都有用（Steinwart and Christmann, 2008; Shalev-Shwartz and Ben-David, 2014）。

12.2.2　间隔的传统推导

原书 p.377

上一节中，我们通过观察“我们只关心 w 的方向而不关心其长度”，导出了 (12.10)，并由此假设 $\|w\| = 1$。本节我们用另一个假设来推导间隔最大化问题。我们不选择把参数向量归一化，而是为数据选择一个尺度。我们这样选取尺度：使预测子 $\langle w, x\rangle + b$ 在最近样本处的值为 1。我们还把数据集中离超平面最近的样本记为 x_a。

图 12.5 与图 12.4 相同，只是现在我们重缩放了坐标轴，使样本 x_a 恰好落在间隔上，即 $\langle w, x_a\rangle + b = 1$。由于 x'_a 是 x_a 在超平面上的正交投影，按定义它必须落在超平面上，即

$$\langle w, x'_a\rangle + b = 0. \tag{12.11}$$

把 (12.8) 代入 (12.11)，我们得到

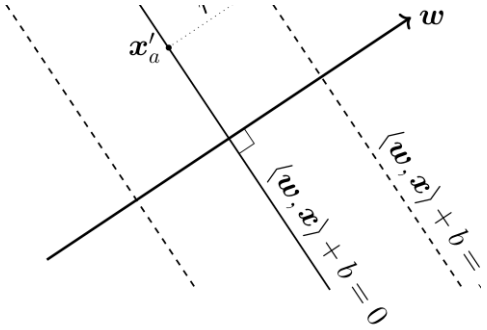
$$\left\langle w,\ x_a - r\,\frac{w}{\|w\|}\right\rangle + b = 0. \tag{12.12}$$

利用内积的双线性（见第 3.2 节），我们得到

$$\langle w, x_a\rangle + b - \frac{r\langle w, w\rangle}{\|w\|} = 0. \tag{12.13}$$

注意，由我们的尺度假设，第一项为 1，即 $\langle w, x_a\rangle + b = 1$。由第 3.1 节的 (3.16) 知 $\langle w, w\rangle = \|w\|^2$。因此第二项化简为 $r\|w\|$。利用这些化简，我们得到

$$r = \frac{1}{\|w\|}. \tag{12.14}$$



e obtain the objective

图 12.5: 间隔的推导：$r = \dfrac{1}{\|w\|}$。

这意味着我们用超平面的法向量 w 表示出了距离 r。乍一看，这个方程有些反直觉：我们似乎用向量 w 的长度表示了到超平面的距离，但我们尚不知道这个向量。一种理解方式是：把距离 r 看作一个仅用于本次推导的临时变量。因此，本节余下部分我们把到超平面的距离记为 $\dfrac{1}{\|w\|}$。在第 12.2.3 节我们将看到，“间隔等于 1”这一选择等价于第 12.2.1 节中 $\|w\| = 1$ 的先前假设。

与得到 (12.9) 的论证类似，我们希望正、负样本离超平面至少为 1，这给出条件

$$y_n\big(\langle w, x_n\rangle + b\big) \geqslant 1. \tag{12.15}$$

把间隔最大化与“样本须按其标签落在超平面正确一侧”这一事实结合起来，我们得到

$$\max_{w,b} \ \frac{1}{\|w\|} \tag{12.16}$$

$$\text{subject to} \quad y_n\big(\langle w, x_n\rangle + b\big) \geqslant 1 \qquad \text{对所有} n = 1, \ldots, N. \tag{12.17}$$

我们不直接如 (12.16) 那样最大化范数的倒数，而常改为最小化范数的平方。我们还常乘上一个常数 $\frac{1}{2}$，它不影响最优的 w, b，但在计算梯度时给出更整洁的形式。于是目标变为

$$\min_{w,b} \ \frac{1}{2}\|w\|^2 \tag{12.18}$$

$$\text{subject to} \quad y_n\big(\langle w, x_n\rangle + b\big) \geqslant 1 \qquad \text{对所有} n = 1, \ldots, N. \tag{12.19}$$

方程 (12.18) 称为**硬间隔 SVM**（hard margin SVM）。“硬”这一说法的由来是：该表述不允许任何违反间隔条件的情形。我们将在第 12.2.4 节看到，当数据线性不可分时，这个“硬”条件可以放松，以容纳违反。

硬间隔 SVM

12.2.3　为什么可以把间隔设为 1

第 12.2.1 节中，我们论证了希望最大化某个值 r，它表示最近样本到超平面的距离。第 12.2.2 节中，我们缩放数据，使最近样本到超平面的距离为 1。本节我们把两种推导联系起来，并证明它们等价。

原书 p.378

定理 12.1. 在 *(12.10)* 的归一化权重下最大化间隔 r，

$$\max_{w,b,r} \underbrace{r}_{\text{间隔}} \quad \textit{subject to} \quad \underbrace{y_n\big(\langle w, x_n\rangle + b\big) \geqslant r}_{\text{数据拟合}}, \ \underbrace{\|w\| = 1}_{\text{归一化}}, \ r > 0, \tag{12.20}$$

等价于把数据缩放至间隔为单位长度：

$$\min_{w,b} \underbrace{\frac{1}{2}\|w\|^2}_{\text{间隔}} \quad \textit{subject to} \quad \underbrace{y_n\big(\langle w, x_n\rangle + b\big) \geqslant 1}_{\text{数据拟合}}. \tag{12.21}$$

证明. 考虑 (12.20)。由于平方对非负自变量是严格单调变换，若我们在目标中考虑 r^2，最大值保持不变。由于 $\|w\| = 1$，我们可以用一个新的、未归一化的权重向量 w' 来重新参数化方程，显式地使用 $\dfrac{w'}{\|w'\|}$。我们得到

$$\max_{w',b,r} r^2 \quad \text{subject to} \quad y_n\left(\left\langle \frac{w'}{\|w'\|}, x_n \right\rangle + b\right) \geqslant r, \quad r > 0. \tag{12.22}$$

方程 (12.22) 显式声明距离 r 为正。因此我们可以把第一个约束除以 r，得到

$$\max_{w',b,r} r^2 \quad \text{subject to} \quad y_n\left(\left\langle \underbrace{\frac{w'}{\|w'\|r}}_{:=w''}, x_n \right\rangle + \underbrace{\frac{b}{r}}_{:=b''}\right) \geqslant 1, \quad r > 0, \tag{12.23}$$

这里把参数重命名为 w'' 与 b''。由于 $w'' = \dfrac{w'}{\|w'\|r}$，对 r 整理得

$$\|w''\| = \left\|\frac{w'}{\|w'\|r}\right\| = \frac{1}{r}\cdot\left\|\frac{w'}{\|w'\|}\right\| = \frac{1}{r}. \tag{12.24}$$

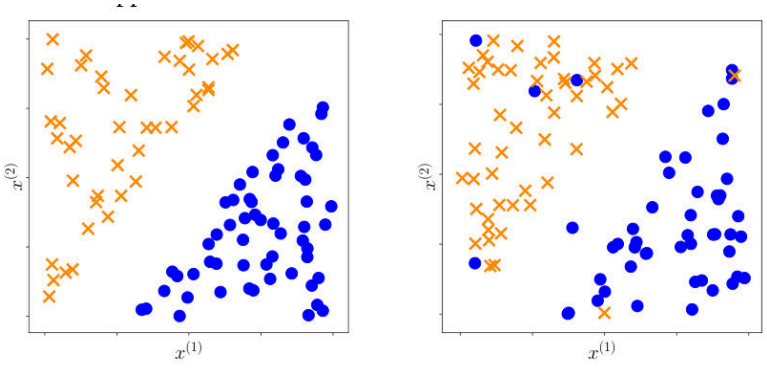
把此结果代入 (12.23)，我们得到

$$\max_{w'',b''} \frac{1}{\|w''\|^2} \quad \text{subject to} \quad y_n\big(\langle w'', x_n\rangle + b''\big) \geqslant 1. \tag{12.25}$$

最后一步是观察到：最大化 $\dfrac{1}{\|w''\|^2}$ 与最小化 $\dfrac{1}{2}\|w''\|^2$ 得到相同的解，这就完成了定理 12.1 的证明。 □

12.2.4　软间隔 SVM：几何视角

在数据线性不可分的情形中，我们可能希望允许某些样本落进间隔区域，甚至落在超平面的错误一侧，如图 12.6 所示。 原书 p.379



a) Linearly separable data, with a large nargin　(b) Non-linearly separable data

图 12.6: (a) 线性可分数据，具有较大间隔；(b) 线性不可分数据。

允许出现某些分类误差的模型称为**软间隔 SVM**（soft margin SVM）。本节我们用几何论证推导所得的优化问题。在第 12.2.5 节，我们将用损失函数的思想推导一个等价的优化问题。利用拉格朗日乘子（第 7.2 节），我们将在第 12.3 节推导 SVM 的对偶优化问题。这个对偶优化问题使我们得以看到 SVM 的第三种解释：作为一个平分正、负数据样本对应凸包之间连线的超平面（第 12.3.2 节）。

软间隔 SVM

关键的几何思想是：为每个样本–标签对 (x_n, y_n) 引入一个松弛变量（slack variable）ξ_n，使某个特定样本可以落在间隔之内，甚至落在超平面的错误一侧（见图 12.7）。我们从间隔中减去 ξ_n 的值，并约束 ξ_n 非负。为鼓励样本被正确分类，我们把 ξ_n 加入目标：

松弛变量

$$\min_{w,b,\xi} \ \frac{1}{2}\|w\|^2 + C\sum_{n=1}^{N}\xi_n \tag{12.26a}$$

$$\text{subject to} \quad y_n\big(\langle w, x_n\rangle + b\big) \geqslant 1 - \xi_n \tag{12.26b}$$

$$\xi_n \geqslant 0 \tag{12.26c}$$

对 $n = 1, \ldots, N$。与硬间隔 SVM 的优化问题 (12.18) 相比，这个问题称为软间隔 SVM。参数 $C > 0$ 在间隔大小与我们拥有的松弛总量之间做权衡。这个参数称为**正则化参数**（regularization parameter），因为如下一节将看到的，目标函数 (12.26a) 中的间隔项就是一个正则项。间隔项 $\|w\|^2$ 称为**正则项**（regularizer）；在许多数值优化教材中，正则化参数是乘在这个项上的（第 8.2.3 节）。这与我们本节的表述相反：这里较大的 C 值意味着较弱的正则化，因为我们给松弛变量更大的权重，从而更优先对待那些不落在间隔正确一侧的样本。

正则化参数

正则项

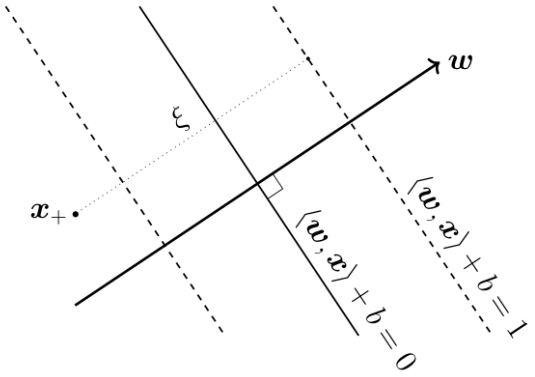


图 12.7: 软间隔 SVM 允许样本落在间隔之内或超平面的错误一侧。当正样本 x_+ 落在错误一侧时，松弛变量 ξ 度量 x_+ 到正间隔超平面 $\langle w, x\rangle + b = 1$ 的距离。

注. 在软间隔 SVM (12.26a) 的表述中，w 被正则化，但 b 没有被正则化。我们可以从“正则项不包含 b”看出这一点。未被正则化的项 b 会使理论分析变得复杂（Steinwart and Christmann, 2008, 第 1 章），并降低计算效率（Fan et al., 2008）。

12.2.5　软间隔 SVM：损失函数视角

让我们遵循经验风险最小化（第 8.2 节）的原则，考虑推导 SVM 的另一种途径。对 SVM 而言，我们选择超平面作为假设类，即

$$f(x) = \langle w, x\rangle + b. \tag{12.27}$$

本节我们将看到，间隔对应于正则项。剩下的问题是：损失函数是什么？与第 9 章不同（那里我们考虑回归问题，预测子的输出是实数），本章我们考虑二分分类问题（预测子的输出是两个标签 $\{+1, -1\}$ 之一）。因此，每个样本–标签对的误差/损失函数需要适合二分分类。例如，回归所用的平方损失 (9.10b) 就不适合二分分类。

注. 二值标签之间的理想损失函数，是数出预测与标签之间不匹配的个数。这意味着：对一个应用于样本 x_n 的预测子 f，我们比较输出 $f(x_n)$ 与标签 y_n。我们定义：若二者匹配则损失为零，不匹配则为一。这记作 $\mathbb{1}(f(x_n) \neq y_n)$，称为 **0-1 损失**（zero-one loss）。遗憾的是，0-1 损失会导致一个组合优化问题，以寻找最优参数 w, b。组合优化问题（与第 7 章讨论的连续优化问题不同）一般更难求解。

0-1 损失

原书 p.380

对应于 SVM 的损失函数是什么？考虑预测子输出 $f(x_n)$ 与标签 y_n 之间的误差。损失描述了在训练数据上犯的错误。推导 (12.26a) 的一种等价方式是使用**合页损失**（hinge loss）：

合页损失

$$\ell(t) = \max\{0, 1 - t\} \qquad \text{其中} \qquad t = yf(x) = y\big(\langle w, x\rangle + b\big). \tag{12.28}$$

若 $f(x)$ 位于超平面的正确一侧（按相应标签 y），且距离大于 1，这意味着 $t \geqslant 1$，合页损失返回零值。若 $f(x)$ 位于正确一侧但离超平面太近（$0 < t < 1$），样本 x 落在间隔之内，合页损失返回正值。当样本落在超平面错误一侧时（$t < 0$），合页损失返回更大的值，且线性增长。换言之：一旦我们离超平面比间隔更近，即使预测正确，我们也要付出惩罚，且惩罚线性增长。合页损失的另一种表述是把它看作两段线性：

$$\ell(t) = \begin{cases} 0 & \text{若} t \geqslant 1, \\ 1 - t & \text{若} t < 1, \end{cases} \tag{12.29}$$

如图 12.8 所示。对应于硬间隔 SVM (12.18) 的损失定义为

$$\ell(t) = \begin{cases} 0 & \text{若} t \geqslant 1, \\ \infty & \text{若} t < 1. \end{cases} \tag{12.30}$$

这个损失可以解释为：绝不允许任何样本落在间隔之内。

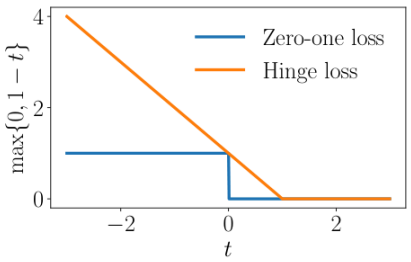


图 12.8: 合页损失是 0-1 损失的一个凸上界。

原书 p.381

对给定的训练集 $\{(x_1, y_1), \ldots, (x_N, y_N)\}$，我们寻求最小化总损失，同时用 ℓ_2 正则化对目标做正则化（见第 8.2.3 节）。使用合页损失 (12.28) 给出无约束优化问题

$$\min_{w,b} \underbrace{\frac{1}{2}\|w\|^2}_{\text{正则项}} + C \sum_{n=1}^{N} \underbrace{\max\{0, 1 - y_n(\langle w, x_n\rangle + b)\}}_{\text{误差项}}. \tag{12.31}$$

(12.31) 中的第一项称为正则项或正则化项（见第 8.2.3 节），第二项称为**损失项**（loss term）或**误差项**（error term）。回顾第 12.2.4 节，项 $\frac{1}{2}\|w\|^2$ 直接来自间隔。换言之，间隔最大化可以解释为正则化。

正则项
误差项
正则化

原则上，(12.31) 中的无约束优化问题可以用第 7.1 节所述的（次）梯度下降方法直接求解。为看出 (12.31) 与 (12.26a) 等价，注意合页损失 (12.28) 本质上由两段线性部分构成，如 (12.29) 所表达。考虑单个样本–标签对的合页损失 (12.28)。我们可以等价地把“对 t 最小化合页损失”替换为“对松弛变量 ξ 带两个约束的最小化”。写成方程：

$$\min_{t} \ \max\{0,\, 1-t\} \tag{12.32}$$

等价于

$$\min_{\xi,t} \ \xi \quad \text{subject to} \quad \xi \geqslant 0, \quad \xi \geqslant 1-t. \tag{12.33}$$

把此表达式代入 (12.31) 并整理其中一个约束，我们恰好得到软间隔 SVM (12.26a)。

注. 让我们把本节对损失函数的选择与第 9 章线性回归的损失函数做对比。回顾第 9.2.1 节，为求最大似然估计，我们通常最小化负对数似然。此外，由于带高斯噪声的线性回归其似然项是高斯的，每个样本的负对数似然是一个平方误差函数。平方误差函数就是在寻找最大似然解时被最小化的损失函数。

12.3　对偶支持向量机

原书 p.382

前几节中，以变量 w、b 表述的 SVM 称为**原始 SVM**（primal SVM）。回顾：我们考虑输入 $x \in \mathbb{R}^D$，具有 D 个特征。由于 w 与 x 同维，这意味着优化问题的参数个数（即 w 的维数）随特征数线性增长。

下面我们考虑一个等价的优化问题（所谓对偶视角），它与特征数无关。相反，参数个数随训练集中样本数增长。我们在第 10 章见过类似的思想：那里我们以一种不随特征数增长的方式表述学习问题。这对“特征数多于训练样本数”的问题很有用。对偶 SVM 还有一个额外优点：它能方便地引入核函数，正如我们将在本章末尾看到的。“对偶”一词在数学文献中经常出现，在这个特定情形中它指凸对偶。下面各小节本质上是第 7.2 节所讨论凸对偶的应用。

12.3.1　通过拉格朗日乘子实现凸对偶

原书 p.383

回顾原始软间隔 SVM (12.26a)。我们把对应于原始 SVM 的变量 w, b, ξ 称为原始变量。我们用 $\alpha_n \geqslant 0$ 作为对应于约束 (12.26b)（样本被正确分类）的拉格朗日乘子，用 $\gamma_n \geqslant 0$ 作为对应于松弛变量非负约束的拉格朗日乘子；见 (12.26c)。于是拉格朗日函数为

$$\begin{aligned}\mathcal{L}(w, b, \xi, \alpha, \gamma) = \frac{1}{2}\|w\|^2 + C\sum_{n=1}^{N}\xi_n \\ - \sum_{n=1}^{N}\underbrace{\alpha_n\big(y_n(\langle w, x_n\rangle + b) - 1 + \xi_n\big)}_{\text{约束 (12.26b)}} \\ - \sum_{n=1}^{N}\underbrace{\gamma_n\xi_n}_{\text{约束 (12.26c)}} \ .\end{aligned} \tag{12.34}$$

把拉格朗日函数 (12.34) 分别对三个原始变量 w, b, ξ 求导，我们得到

$$\frac{\partial \mathcal{L}}{\partial w} = w^\top - \sum_{n=1}^{N}\alpha_n y_n x_n^\top, \tag{12.35}$$

$$\frac{\partial \mathcal{L}}{\partial b} = -\sum_{n=1}^{N} \alpha_n y_n, \tag{12.36}$$

$$\frac{\partial \mathcal{L}}{\partial \xi_n} = C - \alpha_n - \gamma_n. \tag{12.37}$$

现在我们把这些偏导数分别置零，求拉格朗日函数的极大。把 (12.35) 置零，我们得到

$$w = \sum_{n=1}^{N} \alpha_n y_n x_n, \tag{12.38}$$

这是**表示定理**（representer theorem）的一个特例（Kimeldorf and Wahba, 1970）。方程 (12.38) 表明：原始问题中的最优权重向量是样本 x_n 的线性组合。回顾第 2.6.1 节，这意味着优化问题的解位于训练数据的张成空间中。此外，把 (12.36) 置零所得的约束意味着最优权重向量是样本的一个仿射组合。事实证明，表示定理在正则化经验风险最小化的很一般的设定下都成立（Hofmann et al., 2008; Argyriou and Dinuzzo, 2014）。该定理有更一般的版本（Schölkopf et al., 2001），其存在的充要条件可在 Yu et al. (2013) 中找到。

表示定理

注. 表示定理 (12.38) 还解释了“支持向量机”这一名称。对那些相应参数 $\alpha_n = 0$ 的样本 x_n，它们对解 w 毫无贡献。另一些 $\alpha_n > 0$ 的样本称为**支持向量**（support vector），因为它们“支撑”了超平面。

支持向量

把 w 的表达式代入拉格朗日函数 (12.34)，我们得到对偶

$$\begin{aligned} D(\xi, \alpha, \gamma) = &\frac{1}{2}\sum_{i=1}^{N}\sum_{j=1}^{N} y_i y_j \alpha_i \alpha_j \langle x_i, x_j \rangle - \sum_{i=1}^{N} y_i \alpha_i \left\langle \sum_{j=1}^{N} y_j \alpha_j x_j,\ x_i \right\rangle \\ &+ C\sum_{i=1}^{N} \xi_i - b\sum_{i=1}^{N} y_i \alpha_i + \sum_{i=1}^{N} \alpha_i - \sum_{i=1}^{N} \alpha_i \xi_i - \sum_{i=1}^{N} \gamma_i \xi_i. \end{aligned} \tag{12.39}$$

注意, 其中不再含有任何涉及原始变量 w 的项。把 (12.36) 置零, 我们得到 $\sum_{n=1}^{N} y_n \alpha_n = 0$。因此涉及 b 的项也消失了。回顾内积是对称且双线性的（见第 3.2 节）。因此 (12.39) 中的前两项作用在相同对象上。这些项可以化简，我们得到拉格朗日函数

$$D(\xi, \alpha, \gamma) = -\frac{1}{2}\sum_{i=1}^{N}\sum_{j=1}^{N} y_i y_j \alpha_i \alpha_j \langle x_i, x_j \rangle + \sum_{i=1}^{N} \alpha_i + \sum_{i=1}^{N} (C - \alpha_i - \gamma_i)\xi_i. \tag{12.40}$$

这个方程中的最后一项是所有含松弛变量 ξ_i 的项的集合。把 (12.37) 置零，我们看到 (12.40) 中的最后一项也为零。此外，利用同一方程并回顾拉格朗日乘子 γ_i 非负，我们得出 $\alpha_i \leqslant C$。

我们现在得到 SVM 的对偶优化问题，它完全用拉格朗日乘子 α_i 表述。回顾拉格朗日对偶（定义 7.1）：我们最大化对偶问题。这等价于最小化负的对偶问题，于是得到**对偶 SVM**：

对偶SVM

$$\min_{\alpha} \frac{1}{2}\sum_{i=1}^{N}\sum_{j=1}^{N} y_i y_j \alpha_i \alpha_j \langle x_i, x_j \rangle - \sum_{i=1}^{N} \alpha_i \quad \text{subject to} \quad \sum_{i=1}^{N} y_i \alpha_i = 0, \qquad 0 \leqslant \alpha_i \leqslant C \quad \text{对所有} i = 1, \ldots, N. \tag{12.41}$$

(12.41) 中的等式约束来自把 (12.36) 置零。不等式约束 $\alpha_i \geqslant 0$ 是施加于不等式约束的拉格朗日乘子上的条件（第 7.2 节）。不等式约束 $\alpha_i \leqslant C$ 在上一段已讨论过。

SVM 中这组不等式约束称为“**箱式约束**”（box constraints），因为它们把拉格朗日乘子向量 $\alpha = [\alpha_1, \ldots, \alpha_N]^\top \in \mathbb{R}^N$ 限制在由每个轴上的 0 与 C 所定义的箱子内部。这些轴对齐的箱子在数值求解器中实现得特别高效（Dostál, 2009, 第 5 章）。

箱式约束

一旦得到对偶参数 α，我们就可以用表示定理 (12.38) 恢复原始参数 w。设最优原始参数为 w^*。然而，仍有一个问题：如何得到参数 b^*。考虑一个恰好位于间隔边界上的样本 x_n，即 $\langle w^*, x_n\rangle + b = y_n$。回顾 y_n 要么是 $+1$ 要么是 -1。因此唯一的未知量是 b，它可由下式计算：

$$b^* = y_n - \langle w^*, x_n\rangle. \tag{12.42}$$

注. 原则上, 可能没有样本恰好落在间隔上。在这种情况下, 我们应当对所有支持向量计算 $|y_n - \langle w^*, x_n\rangle|$,并取这个绝对差值的中位数作为 b^* 的值。其推导可见 http://fouryears.eu/2012/06/07/the-svm-bias

12.3.2　对偶 SVM：凸包视角

原书 p.384

得到对偶 SVM 的另一种途径是考虑另一种几何论证。考虑具有相同标签的样本 x_n 的集合。我们希望构造一个包含所有样本的凸集，且它是最小的可能集合。这称为**凸包**（convex hull），如图 12.9 所示。

凸包

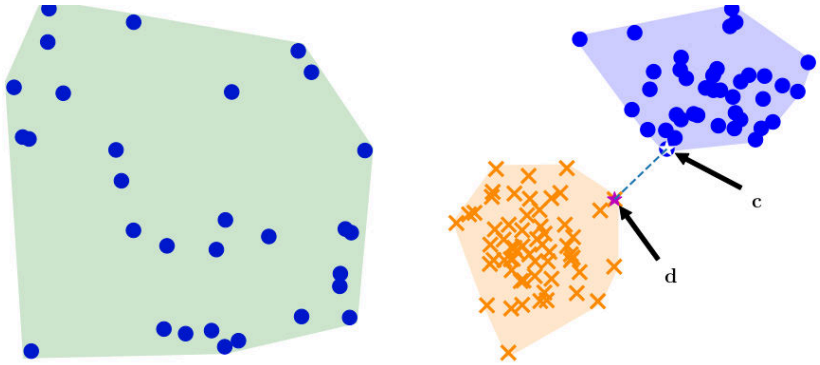


图 12.9: 凸包。(a) 点集的凸包，其中一些点位于边界之内；(b) 围绕正样本（蓝色）与负样本（橙色）的凸包。两个凸集之间的距离就是差向量 $c - d$ 的长度。

我们先对点的凸组合建立一些直觉。考虑两个点 x_1、x_2 以及相应的非负权重 $\alpha_1, \alpha_2 \geqslant 0$，满足 $\alpha_1 + \alpha_2 = 1$。方程 $\alpha_1 x_1 + \alpha_2 x_2$ 描述了 x_1 与 x_2 连线上的每个点。考虑当我们加入第三个点 x_3 以及权重 $\alpha_3 \geqslant 0$、满足 $\sum_{n=1}^{3} \alpha_n = 1$ 时会发生什么。这三个点 x_1, x_2, x_3 的凸组合张成一个二维区域。该区域的凸包就是由每对点之间相应边所形成的三角形。当我们加入更多点，且点数超过维数时，一些点将位于凸包内部，如图 12.9(a) 所示。

一般地，构造凸包可以通过为每个样本 x_n 引入非负权重 $\alpha_n \geqslant 0$ 来完成。于是凸包可描述为集合

$$\operatorname{conv}(X) = \left\{ \sum_{n=1}^{N} \alpha_n x_n \right\} \qquad \text{其中} \qquad \sum_{n=1}^{N} \alpha_n = 1, \quad \alpha_n \geqslant 0, \tag{12.43}$$

对所有 $n = 1, \ldots, N$。若对应于正类与负类的两团点是分离的，则两个凸包不重叠。给定训练数据 $(x_1, y_1), \ldots, (x_N, y_N)$，我们构造两个凸包，分别对应正类与负类。我们在正样本集合的凸包中选取一个点 c，它离负类分布最近。类似地，我们在负样本集合的凸包中选取一个点 d，它离正类分布最近；见图 12.9(b)。我们把 d 与 c 之间的差向量定义为

$$w := c - d. \tag{12.44}$$

如前所述那样选取点 c、d，并要求它们彼此最近，等价于最小化 w 的长度/范数，于是我们得到相应的优化问题

$$\arg\min_w \|w\| = \arg\min_w \frac{1}{2}\|w\|^2. \tag{12.45}$$

由于 c 必须在正类凸包中，它可表示为正样本的凸组合，即对非负系数 α_n^+，

$$c = \sum_{n:y_n=+1} \alpha_n^+ x_n. \tag{12.46}$$

在 (12.46) 中，我们用记号 $n : y_n = +1$ 表示使 $y_n = +1$ 的指标 n 的集合。类似地，对负标签样本，我们得到

$$d = \sum_{n:y_n=-1} \alpha_n^- x_n. \tag{12.47}$$

把 (12.44)、(12.46)、(12.47) 代入 (12.45)，我们得到目标

$$\min_{\alpha} \frac{1}{2} \left\| \sum_{n:y_n=+1} \alpha_n^+ x_n - \sum_{n:y_n=-1} \alpha_n^- x_n \right\|^2. \tag{12.48}$$

设 α 为所有系数的集合，即 α^+ 与 α^- 的拼接。回顾：我们要求每个凸包的系数之和为一，

$$\sum_{n:y_n=+1} \alpha_n^+ = 1 \qquad \text{且} \qquad \sum_{n:y_n=-1} \alpha_n^- = 1. \tag{12.49}$$

这蕴含约束

$$\sum_{n=1}^{N} y_n \alpha_n = 0. \tag{12.50}$$

把各类分别乘开即可看出这一结果：

$$\sum_{n=1}^{N} y_n \alpha_n = \sum_{n:y_n=+1} (+1)\alpha_n^+ + \sum_{n:y_n=-1} (-1)\alpha_n^- \tag{12.51a}$$

$$= \sum_{n:y_n=+1} \alpha_n^+ - \sum_{n:y_n=-1} \alpha_n^- = 1 - 1 = 0. \tag{12.51b}$$

目标函数 (12.48) 与约束 (12.50)，连同 $\alpha \geqslant 0$ 的假设，给出一个带约束的（凸）优化问题。可以证明，这个优化问题与对偶硬间隔 SVM 的优化问题相同（Bennett and Bredensteiner, 2000a）。

约化凸包

注. 为得到软间隔对偶，我们考虑**约化凸包**（reduced hull）。约化凸包类似于凸包，但对系数 α 的大小有一个上界。α 中元素的最大可能值限制了凸包所能取的大小。换言之，对 α 的界把凸包缩小到更小的体积（Bennett and Bredensteiner, 2000b）。

12.4　核函数

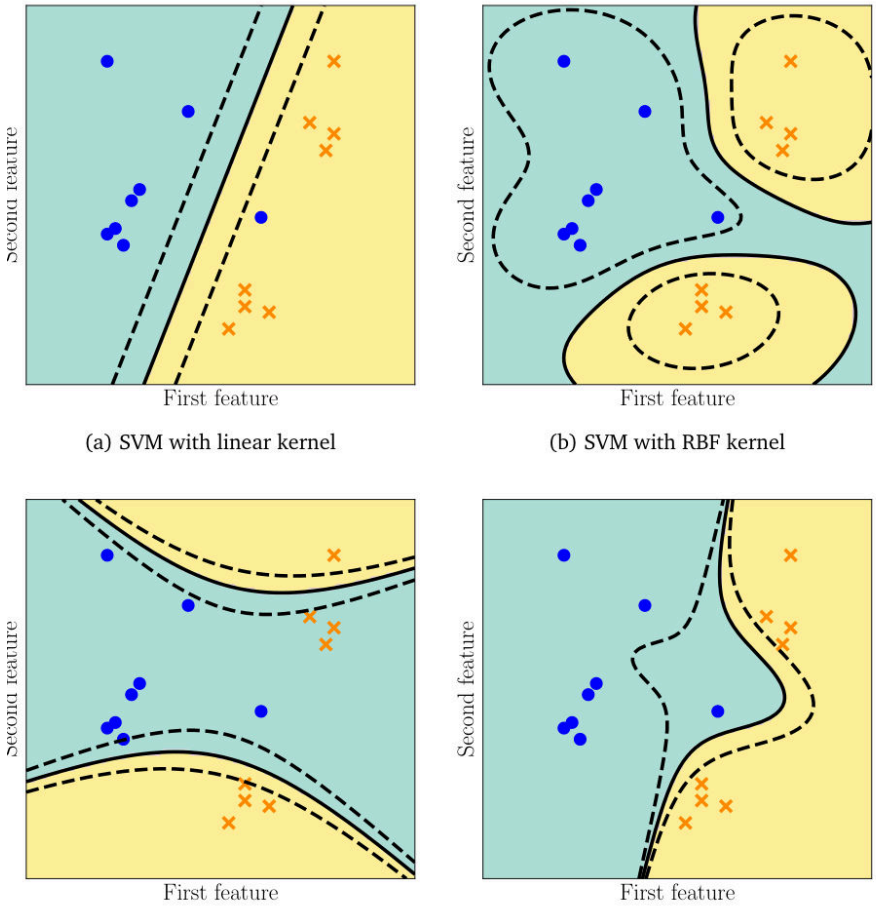
原书 p.385

考虑对偶 SVM (12.41) 的表述。注意目标中的内积只出现在样本 x_i 与 x_j 之间。样本与参数之间没有内积。因此，若我们考虑一组特征 $\phi(x_i)$ 来表示 x_i，对偶 SVM 中唯一的改变就是替换内积。这种模块化——分类方法（SVM）的选择与特征表示 $\phi(x)$ 的选择可以分开考虑——为我们独立地探索这两个问题提供了灵活性。本节我们讨论表示 $\phi(x)$，并简要介绍核函数的思想，但不深入技术细节。

由于 $\phi(x)$ 可以是非线性函数，我们可以用 SVM（它假设线性分类器）来构造在样本 x_n 上非线性的分类器。除软间隔之外，这为用户处理线性不可分数据集提供了第二条途径。事实证明，有许多算法与统计方法都具有我们在对偶 SVM 中观察到的这种性质：唯一的内积是出现在样本之间的那些内积。我们不显式地定义非线性特征映射 $\phi(\cdot)$、再计算样本 x_i 与 x_j 之间所得的内积，而是定义一个 x_i 与 x_j 之间的相似度函数 $k(x_i, x_j)$。对某一类称为**核**（kernel）的相似度函数，该相似度函数隐式地定义了一个　核

非线性特征映射 $\phi(\cdot)$。核按定义是函数 $k : \mathcal{X} \times \mathcal{X} \to \mathbb{R}$，对其存在一个希尔伯特空间 $\mathcal{H}$ 以及一个特征映射 $\phi : \mathcal{X} \to \mathcal{H}$，使得

$$k(x_i, x_j) = \langle \phi(x_i), \phi(x_j) \rangle_{\mathcal{H}}. \tag{12.52}$$



(a) SVM with linear kernel　(b) SVM with RBF kernel

图 12.10: 使用不同核的 SVM。注意：虽然决策边界是非线性的，但所求解的底层问题仍是一个线性可分超平面（只不过使用了非线性核）。

原书 p.386

每个核 k 都对应唯一的再生核希尔伯特空间（Aronszajn, 1950; Berlinet and Thomas-Agnan, 2004）。在这一唯一对应中，$\phi(x) = k(\cdot, x)$ 称为**典范特征映射**（canonical feature map）。从内积到核函数 (12.52) 的推广称为**核技巧**（kernel trick），因为它把显式的非线性特征映射掩藏起来（Schölkopf and Smola, 2002; Shawe-Taylor and Cristianini, 2004）。

典范特征映射

由内积、或由把 $k(\cdot, \cdot)$ 应用于一个数据集所得的矩阵 $K \in \mathbb{R}^{N \times N}$ 称为**格拉姆矩阵**（Gram matrix），常直接称为**核矩阵**（kernel matrix）。核必须是对称且半正定的函数，以使每个核矩阵 K 都是对称且半正定的（第 3.2.3 节）：

核矩阵

$$\forall z \in \mathbb{R}^N : \; z^\top K z \geqslant 0. \tag{12.53}$$

对多元实值数据 $x_i \in \mathbb{R}^D$，一些流行的核例子有多项式核、高斯径向基函数核和有理二次核（Schölkopf and Smola, 2002; Rasmussen and Williams, 2006）。图 12.10 展示了不同核对一个示例数据集上可分超平面的影响。注意我们仍在求解超平面，即函数的假设类仍是线性的。非线性曲面来自核函数。

注. 对刚入门的机器学习学习者来说，遗憾的是“核”一词有多重含义。在本章中，“核”一词来自再生核希尔伯特空间（RKHS）的思想（Aronszajn, 1950; Saitoh, 1988）。我们在第 2.7.3 节讨论过线性代数中核的思想，那里核是空空间（null space）的同义词。机器学习中“核”的第三种常见用法是核密度估计中的平滑核（第 11.5 节）。

由于显式表示 $\phi(x)$ 与核表示 $k(x_i, x_j)$ 在数学上等价，实践者常把核函数设计得比显式特征映射之间的内积计算起来更高效。例如考虑多项式核（Schölkopf and Smola, 2002）：当输入维数较大时，即使是低次多项式，其显式展开中的项数也增长得非常快。而核函数对每个输入维度只需一次乘法，这可以带来显著的计算节省。另一个例子是高斯径向基函数核（Schölkopf and Smola, 2002; Rasmussen and Williams, 2006），其相应特征空间是无穷维的。在这种情况下，我们无法显式表示特征空间，但仍可以用核来计算一对样本之间的相似度。

核技巧的另一个有用方面是：原始数据不必已经表示为多元实值数据。注意，内积定义在函数 $\phi(\cdot)$ 的输出上，但不把输入限制为实数。因此函数 $\phi(\cdot)$ 与核函数 $k(\cdot, \cdot)$ 可以定义在任意对象上，例如集合、序列、字符串、图和分布（Ben-Hur et al., 2008; Gärtner, 2008; Shi et al., 2009; Sriperumbudur et al., 2010; Vishwanathan et al., 2010）。

12.5　数值解

原书 p.387

我们通过了解如何用第 7 章介绍的概念来表述本章所推导的问题，以此结束对 SVM 的讨论。我们考虑两种求 SVM 最优解的途径。首先我们考虑 SVM 的损失视角（第 8.2.2 节），并把它表述为一个无约束优化问题。然后我们把原始与对偶 SVM 的带约束版本表述为标准形式的二次规划（第 7.3.2 节）。

考虑 SVM 的损失函数视角 (12.31)。这是一个凸无约束优化问题，但合页损失 (12.28) 不可微。因此我们应用次梯度方法来求解它。然而，合页损失除了铰链点 $t = 1$ 这一个点之外，几乎处处可微。在这一点，梯度是一组介于 0 与 -1 之间的可能值。因此合页损失的次梯度 g 为

$$g(t) = \begin{cases} -1 & t < 1, \\ [-1, 0] & t = 1, \\ 0 & t > 1. \end{cases} \tag{12.54}$$

使用这个次梯度，我们可以应用第 7.1 节介绍的优化方法。

原书 p.388

原始 SVM 与对偶 SVM 都导出一个凸二次规划问题（带约束优化）。注意，(12.26a) 中的原始 SVM 其优化变量的规模是输入样本的维数 D。(12.41) 中的对偶 SVM 其优化变量的规模是样本数 N。

为把原始 SVM 表述为二次规划的标准形式 (7.45)，我们假设使用点积 (3.5) 作为内积。我们重新整理原始 SVM (12.26a) 的方程，使优化变量都在右侧，且约束的不等式与标准形式一致。这给出优化问题

$$\min_{w,b,\xi} \frac{1}{2}\|w\|^2 + C\sum_{n=1}^{N} \xi_n \quad \text{subject to} \quad -y_n x_n^\top w - y_n b - \xi_n \leqslant -1, \qquad -\xi_n \leqslant 0, \tag{12.55}$$

对 $n = 1, \ldots, N$。通过把变量 w, b, ξ_n 拼接成单个向量，并仔细收集各项，我们得到软

间隔 SVM 的如下矩阵形式：

$$\begin{aligned}&\min_{w,b,\xi} \frac{1}{2}\begin{bmatrix} w \\ b \\ \xi \end{bmatrix}^\top \begin{bmatrix} I_D & 0_{D,N+1} \\ 0_{N+1,D} & 0_{N+1,N+1} \end{bmatrix} \begin{bmatrix} w \\ b \\ \xi \end{bmatrix} + \begin{bmatrix} 0_{D+1,1} \\ C1_{N,1} \end{bmatrix}^\top \begin{bmatrix} w \\ b \\ \xi \end{bmatrix} \\ &\text{subject to} \quad \begin{bmatrix} -YX & -y & -I_N \\ 0_{N,D+1} & -I_N & \end{bmatrix} \begin{bmatrix} w \\ b \\ \xi \end{bmatrix} \leqslant \begin{bmatrix} -1_{N,1} \\ 0_{N,1} \end{bmatrix}.\end{aligned} \tag{12.56}$$

在上述优化问题中，最小化是对参数 $[w^\top, b, \xi^\top]^\top \in \mathbb{R}^{D+1+N}$ 进行的，我们使用如下记号：I_m 表示 $m \times m$ 的单位矩阵，$0_{m,n}$ 表示 $m \times n$ ，$1_{m,n}$ 表示 $m \times n$ 的全一矩阵。此外，y 是标签向量 $[y_1, \ldots, y_N]^\top$，$Y = \text{diag}(y)$ 是一个 $N \times N$ 矩阵，其对角元素来自 y，$X \in \mathbb{R}^{N \times D}$ 是把所有样本拼接所得的矩阵。

我们可以类似地对 SVM 的对偶版本 (12.41) 做各项收集。为把对偶 SVM 表述为标准形式，我们首先需要把核矩阵 K 表述为每个元素 $K_{ij} = k(x_i, x_j)$。若我们有显式特征表示 x_i，则定义 $K_{ij} = \langle x_i, x_j \rangle$。为记号方便，我们引入一个除对角线上存储标签外处处为零的矩阵，即 $Y = \text{diag}(y)$。对偶 SVM 可写为

$$\min_\alpha \frac{1}{2}\alpha^\top YKY\alpha - 1_{N,1}^\top \alpha \quad \text{subject to} \quad \begin{bmatrix} y^\top \\ -y^\top \\ -I_N \\ I_N \end{bmatrix} \alpha \leqslant \begin{bmatrix} 0_{N+2,1} \\ C1_{N,1} \end{bmatrix}. \tag{12.57}$$

注. 在第 7.3.1 节与第 7.3.2 节中，我们介绍的约束标准形式是不等式约束。我们将把对偶 SVM 的等式约束表示为两个不等式约束，即

$$Ax = b \qquad \text{被替换为} \qquad Ax \leqslant b \quad \text{以及} \quad Ax \geqslant b. \tag{12.58}$$

凸优化方法的特定软件实现可能提供表达等式约束的能力。

原书 p.389

由于 SVM 有许多不同的可能视角，求解所得优化问题也有许多途径。这里给出的“把 SVM 问题表述为标准凸优化形式”的途径，在实践中并不常用。SVM 求解器的两个主要实现是 Chang and Lin (2011)（开源）与 Joachims (1999)。由于 SVM 有一个清晰且定义良好的优化问题，许多基于数值优化技术的途径都可应用（Nocedal and Wright, 2006; Shawe-Taylor and Sun, 2011）。

12.6　延伸阅读

原书 p.390

SVM 是研究二分分类的众多途径之一。其他途径包括感知机、逻辑回归、Fisher 判别、最近邻、朴素贝叶斯和随机森林（Bishop, 2006; Murphy, 2012）。关于离散序列上 SVM 与核的简短教程可在 Ben-Hur et al. (2008) 中找到。SVM 的发展与经验风险最小化密切相关（第 8.2 节）。因此，SVM 具有很强的理论性质（Vapnik, 2000; Steinwart and Christmann, 2008）。关于核方法的书（Schölkopf and Smola, 2002）包含了支持向量机及其优化方法的许多细节。另一本更全面的核方法著作（Shawe-Taylor and Cristianini, 2004）也包含了用于不同机器学习问题的许多线性代数方法。

原书 p.391

对偶 SVM 的另一种推导可以利用 Legendre–Fenchel 变换（第 7.3.3 节）得到。该推导分别考虑 SVM 无约束表述 (12.31) 的每一项，并计算它们的凸共轭（Rifkin and Lippert, 2007）。对 SVM 的泛函分析视角（也是正则化方法视角）感兴趣的读者，可参考 Wahba

(1990) 的工作。核的理论阐述（Aronszajn, 1950; Schwartz, 1964; Saitoh, 1988; Manton and Amblard, 2015）需要线性算子的基础（Akhiezer and Glazman, 1993）。核的思想已被推广到巴拿赫空间（Zhang et al., 2009）与 Kreĭn 空间（Ong et al., 2004; Loosli et al., 2016）。 原书 p.392

注意，合页损失有三种等价表示，如 (12.28)、(12.29) 以及 (12.33) 中的带约束优化问题所示。表述 (12.28) 常用于把 SVM 损失函数与其他损失函数比较（Steinwart, 2007）。两段式表述 (12.29) 便于计算次梯度，因为每一段都是线性的。第三种表述 (12.33) 如第 12.5 节所见，使凸二次规划（第 7.3.2 节）工具得以使用。 原书 p.393

由于二分分类是机器学习中被充分研究的任务，有时也使用其他词语，例如判别（discrimination）、分离（separation）和决策（decision）。此外，二分分类器的输出可以有三种量。第一种是线性函数本身的输出（常称为分数 score），它可取任意实数值。这个输出可用于对样本排序，而二分分类可看作在排序后的样本上选取一个阈值（Shawe-Taylor and Cristianini, 2004）。第二种常被视为二分分类器输出的量，是在经过一个非线性函数把值约束到有界区间（例如 $[0, 1]$）之后确定的输出。一个常见的非线性函数是 sigmoid 函数（Bishop, 2006）。当该非线性性产生良好校准的概率时（Gneiting and Raftery, 2007; Reid and Williamson, 2011），这称为类概率估计。二分分类器的第三种输出是最终的二值决策 $\{+1, -1\}$，这是最常被假定为分类器输出的那一个。

SVM 是一种自然不便于做概率解释的二分分类器。把线性函数的原始输出（分数）转换为校准良好的类概率估计 $P(Y = 1 \mid X = x)$，有若干途径，它们都涉及一个额外的校准步骤（Platt, 2000; Zadrozny and Elkan, 2001; Lin et al., 2007）。 原书 p.394

从训练角度看，有许多相关的概率途径。我们在第 12.2.5 节末尾提到过，损失函数与似然之间存在关系（另比较第 8.2 节与第 8.3 节）。对应于训练期间良好校准变换的最大似然途径称为逻辑回归，它来自一类称为广义线性模型的方法。从这一角度看逻辑回归的细节可在 Agresti (2002, 第 5 章) 与 McCullagh and Nelder (1989, 第 4 章) 中找到。自然地，人们也可以通过用贝叶斯逻辑回归估计后验分布，来对分类器输出采取更贝叶斯的视角。贝叶斯视角还包括先验的指定，其中包含与似然的共轭性（第 6.6.1 节）等设计选择。此外，人们可以把潜函数作为先验，这就导出了高斯过程分类（Rasmussen and Williams, 2006, 第 3 章）。

References

Abel, Niels H. 1826. *Démonstration de l'Impossibilité de la Résolution Algébrique des Équations Générales qui Passent le Quatrième Degré*. Grøndahl and Søn.

Adhikari, Ani, and DeNero, John. 2018. *Computational and Inferential Thinking: The Foundations of Data Science*. Gitbooks.

Agarwal, Arvind, and Daumé III, Hal. 2010. A Geometric View of Conjugate Priors. *Machine Learning*, **81**(1), 99–113.

Agresti, A. 2002. *Categorical Data Analysis*. Wiley.

Akaike, Hirotugu. 1974. A New Look at the Statistical Model Identification. *IEEE Transactions on Automatic Control*, **19**(6), 716–723.

Akhiezer, Naum I., and Glazman, Izrail M. 1993. *Theory of Linear Operators in Hilbert Space*. Dover Publications.

Alpaydin, Ethem. 2010. *Introduction to Machine Learning*. MIT Press.

Amari, Shun-ichi. 2016. *Information Geometry and Its Applications*. Springer.

Argyriou, Andreas, and Dinuzzo, Francesco. 2014. A Unifying View of Representer Theorems. In: *Proceedings of the International Conference on Machine Learning*.

Aronszajn, Nachman. 1950. Theory of Reproducing Kernels. *Transactions of the American Mathematical Society*, **68**, 337–404.

Axler, Sheldon. 2015. *Linear Algebra Done Right*. Springer.

Bakir, Gökhan, Hofmann, Thomas, Schölkopf, Bernhard, Smola, Alexander J., Taskar, Ben, and Vishwanathan, S. V. N. (eds). 2007. *Predicting Structured Data*. MIT Press.

Barber, David. 2012. *Bayesian Reasoning and Machine Learning*. Cambridge University Press.

Barndorff-Nielsen, Ole. 2014. *Information and Exponential Families: In Statistical Theory*. Wiley.

Bartholomew, David, Knott, Martin, and Moustaki, Irini. 2011. *Latent Variable Models and Factor Analysis: A Unified Approach*. Wiley.

Baydin, Atılım G., Pearlmutter, Barak A., Radul, Alexey A., and Siskind, Jeffrey M. 2018. Automatic Differentiation in Machine Learning: A Survey. *Journal of Machine Learning Research*, **18**, 1–43.

Beck, Amir, and Teboulle, Marc. 2003. Mirror Descent and Nonlinear Projected Subgradient Methods for Convex Optimization. *Operations Research Letters*, **31**(3), 167–175.

Belabbas, Mohamed-Ali, and Wolfe, Patrick J. 2009. Spectral Methods in Machine Learning and New Strategies for Very Large Datasets. *Proceedings of the National Academy of Sciences*, 0810600105.

Belkin, Mikhail, and Niyogi, Partha. 2003. Laplacian Eigenmaps for Dimensionality Reduction and Data Representation. *Neural Computation*, **15**(6), 1373–1396.

Ben-Hur, Asa, Ong, Cheng Soon, Sonnenburg, Sören, Schölkopf, Bernhard, and Rätsch, Gunnar. 2008. Support Vector Machines and Kernels for Computational Biology. *PLoS Computational Biology*, **4**(10), e1000173.

This material is published by Cambridge University Press as *Mathematics for Machine Learning* by Marc Peter Deisenroth, A. Aldo Faisal, and Cheng Soon Ong (2020). This version is free to view and download for personal use only. Not for re-distribution, re-sale, or use in derivative works. ©by M. P. Deisenroth, A. A. Faisal, and C. S. Ong, 2024. `https://mml-book.com`.

Bennett, Kristin P., and Bredensteiner, Erin J. 2000a. Duality and Geometry in SVM Classifiers. In: *Proceedings of the International Conference on Machine Learning*.

Bennett, Kristin P., and Bredensteiner, Erin J. 2000b. Geometry in Learning. Pages 132–145 of: *Geometry at Work*. Mathematical Association of America.

Berlinet, Alain, and Thomas-Agnan, Christine. 2004. *Reproducing Kernel Hilbert Spaces in Probability and Statistics*. Springer.

Bertsekas, Dimitri P. 1999. *Nonlinear Programming*. Athena Scientific.

Bertsekas, Dimitri P. 2009. *Convex Optimization Theory*. Athena Scientific.

Bickel, Peter J., and Doksum, Kjell. 2006. *Mathematical Statistics, Basic Ideas and Selected Topics*. Vol. 1. Prentice Hall.

Bickson, Danny, Dolev, Danny, Shental, Ori, Siegel, Paul H., and Wolf, Jack K. 2007. Linear Detection via Belief Propagation. In: *Proceedings of the Annual Allerton Conference on Communication, Control, and Computing*.

Billingsley, Patrick. 1995. *Probability and Measure*. Wiley.

Bishop, Christopher M. 1995. *Neural Networks for Pattern Recognition*. Clarendon Press.

Bishop, Christopher M. 1999. Bayesian PCA. In: *Advances in Neural Information Processing Systems*.

Bishop, Christopher M. 2006. *Pattern Recognition and Machine Learning*. Springer.

Blei, David M., Kucukelbir, Alp, and McAuliffe, Jon D. 2017. Variational Inference: A Review for Statisticians. *Journal of the American Statistical Association*, **112**(518), 859–877.

Blum, Arvim, and Hardt, Moritz. 2015. The Ladder: A Reliable Leaderboard for Machine Learning Competitions. In: *International Conference on Machine Learning*.

Bonnans, J. Frédéric, Gilbert, J. Charles, Lemaréchal, Claude, and Sagastizábal, Claudia A. 2006. *Numerical Optimization: Theoretical and Practical Aspects*. Springer.

Borwein, Jonathan M., and Lewis, Adrian S. 2006. *Convex Analysis and Nonlinear Optimization*. 2nd edn. Canadian Mathematical Society.

Bottou, Léon. 1998. Online Algorithms and Stochastic Approximations. Pages 9–42 of: *Online Learning and Neural Networks*. Cambridge University Press.

Bottou, Léon, Curtis, Frank E., and Nocedal, Jorge. 2018. Optimization Methods for Large-Scale Machine Learning. *SIAM Review*, **60**(2), 223–311.

Boucheron, Stephane, Lugosi, Gabor, and Massart, Pascal. 2013. *Concentration Inequalities: A Nonasymptotic Theory of Independence*. Oxford University Press.

Boyd, Stephen, and Vandenberghe, Lieven. 2004. *Convex Optimization*. Cambridge University Press.

Boyd, Stephen, and Vandenberghe, Lieven. 2018. *Introduction to Applied Linear Algebra*. Cambridge University Press.

Brochu, Eric, Cora, Vlad M., and de Freitas, Nando. 2009. *A Tutorial on Bayesian Optimization of Expensive Cost Functions, with Application to Active User Modeling and Hierarchical Reinforcement Learning*. Tech. rept. TR-2009-023. Department of Computer Science, University of British Columbia.

Brooks, Steve, Gelman, Andrew, Jones, Galin L., and Meng, Xiao-Li (eds). 2011. *Handbook of Markov Chain Monte Carlo*. Chapman and Hall/CRC.

Brown, Lawrence D. 1986. *Fundamentals of Statistical Exponential Families: With Applications in Statistical Decision Theory*. Institute of Mathematical Statistics.

Bryson, Arthur E. 1961. A Gradient Method for Optimizing Multi-Stage Allocation Processes. In: *Proceedings of the Harvard University Symposium on Digital Computers and Their Applications*.

Bubeck, Sébastien. 2015. Convex Optimization: Algorithms and Complexity. *Foundations and Trends in Machine Learning*, **8**(3-4), 231–357.

Bühlmann, Peter, and Van De Geer, Sara. 2011. *Statistics for High-Dimensional Data*. Springer.

Burges, Christopher. 2010. Dimension Reduction: A Guided Tour. *Foundations and Trends in Machine Learning*, **2**(4), 275–365.

Carroll, J Douglas, and Chang, Jih-Jie. 1970. Analysis of Individual Differences in Multidimensional Scaling via an N-Way Generalization of "Eckart-Young" Decomposition. *Psychometrika*, **35**(3), 283–319.

Casella, George, and Berger, Roger L. 2002. *Statistical Inference*. Duxbury.

Çinlar, Erhan. 2011. *Probability and Stochastics*. Springer.

Chang, Chih-Chung, and Lin, Chih-Jen. 2011. LIBSVM: A Library for Support Vector Machines. *ACM Transactions on Intelligent Systems and Technology*, **2**, 27:1–27:27.

Cheeseman, Peter. 1985. In Defense of Probability. In: *Proceedings of the International Joint Conference on Artificial Intelligence*.

Chollet, Francois, and Allaire, J. J. 2018. *Deep Learning with R*. Manning Publications.

Codd, Edgar F. 1990. *The Relational Model for Database Management*. Addison-Wesley Longman Publishing.

Cunningham, John P., and Ghahramani, Zoubin. 2015. Linear Dimensionality Reduction: Survey, Insights, and Generalizations. *Journal of Machine Learning Research*, **16**, 2859–2900.

Datta, Biswa N. 2010. *Numerical Linear Algebra and Applications*. SIAM.

Davidson, Anthony C., and Hinkley, David V. 1997. *Bootstrap Methods and Their Application*. Cambridge University Press.

Dean, Jeffrey, Corrado, Greg S., Monga, Rajat, and Chen, et al. 2012. Large Scale Distributed Deep Networks. In: *Advances in Neural Information Processing Systems*.

Deisenroth, Marc P., and Mohamed, Shakir. 2012. Expectation Propagation in Gaussian Process Dynamical Systems. Pages 2618–2626 of: *Advances in Neural Information Processing Systems*.

Deisenroth, Marc P., and Ohlsson, Henrik. 2011. A General Perspective on Gaussian Filtering and Smoothing: Explaining Current and Deriving New Algorithms. In: *Proceedings of the American Control Conference*.

Deisenroth, Marc P., Fox, Dieter, and Rasmussen, Carl E. 2015. Gaussian Processes for Data-Efficient Learning in Robotics and Control. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, **37**(2), 408–423.

Dempster, Arthur P., Laird, Nan M., and Rubin, Donald B. 1977. Maximum Likelihood from Incomplete Data via the EM Algorithm. *Journal of the Royal Statistical Society*, **39**(1), 1–38.

Deng, Li, Seltzer, Michael L., Yu, Dong, Acero, Alex, Mohamed, Abdel-rahman, and Hinton, Geoffrey E. 2010. Binary Coding of Speech Spectrograms Using a Deep Auto-Encoder. In: *Proceedings of Interspeech*.

Devroye, Luc. 1986. *Non-Uniform Random Variate Generation*. Springer.

Donoho, David L., and Grimes, Carrie. 2003. Hessian Eigenmaps: Locally Linear Embedding Techniques for High-Dimensional Data. *Proceedings of the National Academy of Sciences*, **100**(10), 5591–5596.

Dostál, Zdeněk. 2009. *Optimal Quadratic Programming Algorithms: With Applications to Variational Inequalities*. Springer.

Douven, Igor. 2017. Abduction. In: *The Stanford Encyclopedia of Philosophy*. Metaphysics Research Lab, Stanford University.

Downey, Allen B. 2014. *Think Stats: Exploratory Data Analysis*. 2nd edn. O'Reilly Media.

Dreyfus, Stuart. 1962. The Numerical Solution of Variational Problems. *Journal of Mathematical Analysis and Applications*, **5**(1), 30–45.

Drumm, Volker, and Weil, Wolfgang. 2001. *Lineare Algebra und Analytische Geometrie*. Lecture Notes, Universität Karlsruhe (TH).

Dudley, Richard M. 2002. *Real Analysis and Probability*. Cambridge University Press.

©2024 M. P. Deisenroth, A. A. Faisal, C. S. Ong. Published by Cambridge University Press (2020).

Eaton, Morris L. 2007. *Multivariate Statistics: A Vector Space Approach*. Institute of Mathematical Statistics Lecture Notes.

Eckart, Carl, and Young, Gale. 1936. The Approximation of One Matrix by Another of Lower Rank. *Psychometrika*, **1**(3), 211–218.

Efron, Bradley, and Hastie, Trevor. 2016. *Computer Age Statistical Inference: Algorithms, Evidence and Data Science*. Cambridge University Press.

Efron, Bradley, and Tibshirani, Robert J. 1993. *An Introduction to the Bootstrap*. Chapman and Hall/CRC.

Elliott, Conal. 2009. Beautiful Differentiation. In: *International Conference on Functional Programming*.

Evgeniou, Theodoros, Pontil, Massimiliano, and Poggio, Tomaso. 2000. Statistical Learning Theory: A Primer. *International Journal of Computer Vision*, **38**(1), 9–13.

Fan, Rong-En, Chang, Kai-Wei, Hsieh, Cho-Jui, Wang, Xiang-Rui, and Lin, Chih-Jen. 2008. LIBLINEAR: A Library for Large Linear Classification. *Journal of Machine Learning Research*, **9**, 1871–1874.

Gal, Yarin, van der Wilk, Mark, and Rasmussen, Carl E. 2014. Distributed Variational Inference in Sparse Gaussian Process Regression and Latent Variable Models. In: *Advances in Neural Information Processing Systems*.

Gärtner, Thomas. 2008. *Kernels for Structured Data*. World Scientific.

Gavish, Matan, and Donoho, David L. 2014. The Optimal Hard Threshold for Singular Values is $4\sqrt{3}$. *IEEE Transactions on Information Theory*, **60**(8), 5040–5053.

Gelman, Andrew, Carlin, John B., Stern, Hal S., and Rubin, Donald B. 2004. *Bayesian Data Analysis*. Chapman and Hall/CRC.

Gentle, James E. 2004. *Random Number Generation and Monte Carlo Methods*. Springer.

Ghahramani, Zoubin. 2015. Probabilistic Machine Learning and Artificial Intelligence. *Nature*, **521**, 452–459.

Ghahramani, Zoubin, and Roweis, Sam T. 1999. Learning Nonlinear Dynamical Systems Using an EM Algorithm. In: *Advances in Neural Information Processing Systems*. MIT Press.

Gilks, Walter R., Richardson, Sylvia, and Spiegelhalter, David J. 1996. *Markov Chain Monte Carlo in Practice*. Chapman and Hall/CRC.

Gneiting, Tilmann, and Raftery, Adrian E. 2007. Strictly Proper Scoring Rules, Prediction, and Estimation. *Journal of the American Statistical Association*, **102**(477), 359–378.

Goh, Gabriel. 2017. Why Momentum Really Works. *Distill*.

Gohberg, Israel, Goldberg, Seymour, and Krupnik, Nahum. 2012. *Traces and Determinants of Linear Operators*. Birkhäuser.

Golan, Jonathan S. 2007. *The Linear Algebra a Beginning Graduate Student Ought to Know*. Springer.

Golub, Gene H., and Van Loan, Charles F. 2012. *Matrix Computations*. JHU Press.

Goodfellow, Ian, Bengio, Yoshua, and Courville, Aaron. 2016. *Deep Learning*. MIT Press.

Graepel, Thore, Candela, Joaquin Quiñonero-Candela, Borchert, Thomas, and Herbrich, Ralf. 2010. Web-Scale Bayesian Click-through Rate Prediction for Sponsored Search Advertising in Microsoft's Bing Search Engine. In: *Proceedings of the International Conference on Machine Learning*.

Griewank, Andreas, and Walther, Andrea. 2003. Introduction to Automatic Differentiation. In: *Proceedings in Applied Mathematics and Mechanics*.

Griewank, Andreas, and Walther, Andrea. 2008. *Evaluating Derivatives, Principles and Techniques of Algorithmic Differentiation*. SIAM.

Grimmett, Geoffrey R., and Welsh, Dominic. 2014. *Probability: An Introduction*. Oxford University Press.

Grinstead, Charles M., and Snell, J. Laurie. 1997. *Introduction to Probability*. American Mathematical Society.
Hacking, Ian. 2001. *Probability and Inductive Logic*. Cambridge University Press.
Hall, Peter. 1992. *The Bootstrap and Edgeworth Expansion*. Springer.
Hallin, Marc, Paindaveine, Davy, and Šiman, Miroslav. 2010. Multivariate Quantiles and Multiple-Output Regression Quantiles: From ℓ_1 Optimization to Halfspace Depth. *Annals of Statistics*, **38**, 635–669.
Hasselblatt, Boris, and Katok, Anatole. 2003. *A First Course in Dynamics with a Panorama of Recent Developments*. Cambridge University Press.
Hastie, Trevor, Tibshirani, Robert, and Friedman, Jerome. 2001. *The Elements of Statistical Learning – Data Mining, Inference, and Prediction*. Springer.
Hausman, Karol, Springenberg, Jost T., Wang, Ziyu, Heess, Nicolas, and Riedmiller, Martin. 2018. Learning an Embedding Space for Transferable Robot Skills. In: *Proceedings of the International Conference on Learning Representations*.
Hazan, Elad. 2015. Introduction to Online Convex Optimization. *Foundations and Trends in Optimization*, **2**(3–4), 157–325.
Hensman, James, Fusi, Nicolò, and Lawrence, Neil D. 2013. Gaussian Processes for Big Data. In: *Proceedings of the Conference on Uncertainty in Artificial Intelligence*.
Herbrich, Ralf, Minka, Tom, and Graepel, Thore. 2007. TrueSkill(TM): A Bayesian Skill Rating System. In: *Advances in Neural Information Processing Systems*.
Hiriart-Urruty, Jean-Baptiste, and Lemaréchal, Claude. 2001. *Fundamentals of Convex Analysis*. Springer.
Hoffman, Matthew D., Blei, David M., and Bach, Francis. 2010. Online Learning for Latent Dirichlet Allocation. *Advances in Neural Information Processing Systems*.
Hoffman, Matthew D., Blei, David M., Wang, Chong, and Paisley, John. 2013. Stochastic Variational Inference. *Journal of Machine Learning Research*, **14**(1), 1303–1347.
Hofmann, Thomas, Schölkopf, Bernhard, and Smola, Alexander J. 2008. Kernel Methods in Machine Learning. *Annals of Statistics*, **36**(3), 1171–1220.
Hogben, Leslie. 2013. *Handbook of Linear Algebra*. Chapman and Hall/CRC.
Horn, Roger A., and Johnson, Charles R. 2013. *Matrix Analysis*. Cambridge University Press.
Hotelling, Harold. 1933. Analysis of a Complex of Statistical Variables into Principal Components. *Journal of Educational Psychology*, **24**, 417–441.
Hyvarinen, Aapo, Oja, Erkki, and Karhunen, Juha. 2001. *Independent Component Analysis*. Wiley.
Imbens, Guido W., and Rubin, Donald B. 2015. *Causal Inference for Statistics, Social and Biomedical Sciences*. Cambridge University Press.
Jacod, Jean, and Protter, Philip. 2004. *Probability Essentials*. Springer.
Jaynes, Edwin T. 2003. *Probability Theory: The Logic of Science*. Cambridge University Press.
Jefferys, William H., and Berger, James O. 1992. Ockham's Razor and Bayesian Analysis. *American Scientist*, **80**, 64–72.
Jeffreys, Harold. 1961. *Theory of Probability*. Oxford University Press.
Jimenez Rezende, Danilo, and Mohamed, Shakir. 2015. Variational Inference with Normalizing Flows. In: *Proceedings of the International Conference on Machine Learning*.
Jimenez Rezende, Danilo, Mohamed, Shakir, and Wierstra, Daan. 2014. Stochastic Backpropagation and Approximate Inference in Deep Generative Models. In: *Proceedings of the International Conference on Machine Learning*.
Joachims, Thorsten. 1999. *Advances in Kernel Methods – Support Vector Learning*. MIT Press. Chap. Making Large-Scale SVM Learning Practical, pages 169–184.
Jordan, Michael I., Ghahramani, Zoubin, Jaakkola, Tommi S., and Saul, Lawrence K. 1999. An Introduction to Variational Methods for Graphical Models. *Machine Learning*, **37**, 183–233.

©2024 M. P. Deisenroth, A. A. Faisal, C. S. Ong. Published by Cambridge University Press (2020).

Julier, Simon J., and Uhlmann, Jeffrey K. 1997. A New Extension of the Kalman Filter to Nonlinear Systems. In: *Proceedings of AeroSense Symposium on Aerospace/Defense Sensing, Simulation and Controls*.

Kaiser, Marcus, and Hilgetag, Claus C. 2006. Nonoptimal Component Placement, but Short Processing Paths, Due to Long-Distance Projections in Neural Systems. PLoS *Computational Biology*, **2**(7), e95.

Kalman, Dan. 1996. A Singularly Valuable Decomposition: The SVD of a Matrix. College *Mathematics Journal*, **27**(1), 2–23.

Kalman, Rudolf E. 1960. A New Approach to Linear Filtering and Prediction Problems. *Transactions of the ASME – Journal of Basic Engineering*, **82**(Series D), 35–45.

Kamthe, Sanket, and Deisenroth, Marc P. 2018. Data-Efficient Reinforcement Learning with Probabilistic Model Predictive Control. In: *Proceedings of the International Conference on Artificial Intelligence and Statistics*.

Katz, Victor J. 2004. *A History of Mathematics*. Pearson/Addison-Wesley.

Kelley, Henry J. 1960. Gradient Theory of Optimal Flight Paths. *Ars Journal*, **30**(10), 947–954.

Kimeldorf, George S., and Wahba, Grace. 1970. A Correspondence between Bayesian Estimation on Stochastic Processes and Smoothing by Splines. *Annals of Mathematical Statistics*, **41**(2), 495–502.

Kingma, Diederik P., and Welling, Max. 2014. Auto-Encoding Variational Bayes. In: *Proceedings of the International Conference on Learning Representations*.

Kittler, Josef, and Föglein, Janos. 1984. Contextual Classification of Multispectral Pixel Data. *Image and Vision Computing*, **2**(1), 13–29.

Kolda, Tamara G., and Bader, Brett W. 2009. Tensor Decompositions and Applications. *SIAM Review*, **51**(3), 455–500.

Koller, Daphne, and Friedman, Nir. 2009. *Probabilistic Graphical Models*. MIT Press.

Kong, Linglong, and Mizera, Ivan. 2012. Quantile Tomography: Using Quantiles with Multivariate Data. *Statistica Sinica*, **22**, 1598–1610.

Lang, Serge. 1987. *Linear Algebra*. Springer.

Lawrence, Neil D. 2005. Probabilistic Non-Linear Principal Component Analysis with Gaussian Process Latent Variable Models. *Journal of Machine Learning Research*, **6**(Nov.), 1783–1816.

Leemis, Lawrence M., and McQueston, Jacquelyn T. 2008. Univariate Distribution Relationships. *American Statistician*, **62**(1), 45–53.

Lehmann, Erich L., and Romano, Joseph P. 2005. *Testing Statistical Hypotheses*. Springer.

Lehmann, Erich Leo, and Casella, George. 1998. *Theory of Point Estimation*. Springer.

Liesen, Jörg, and Mehrmann, Volker. 2015. *Linear Algebra*. Springer.

Lin, Hsuan-Tien, Lin, Chih-Jen, and Weng, Ruby C. 2007. A Note on Platt's Probabilistic Outputs for Support Vector Machines. *Machine Learning*, **68**, 267–276.

Ljung, Lennart. 1999. *System Identification: Theory for the User*. Prentice Hall.

Loosli, Gaëlle, Canu, Stéphane, and Ong, Cheng Soon. 2016. Learning SVM in Kreĭn Spaces. *IEEE Transactions of Pattern Analysis and Machine Intelligence*, **38**(6), 1204–1216.

Luenberger, David G. 1969. *Optimization by Vector Space Methods*. Wiley.

MacKay, David J. C. 1992. Bayesian Interpolation. *Neural Computation*, **4**, 415–447.

MacKay, David J. C. 1998. Introduction to Gaussian Processes. Pages 133–165 of: Bishop, C. M. (ed), *Neural Networks and Machine Learning*. Springer.

MacKay, David J. C. 2003. *Information Theory, Inference, and Learning Algorithms*. Cambridge University Press.

Magnus, Jan R., and Neudecker, Heinz. 2007. *Matrix Differential Calculus with Applications in Statistics and Econometrics*. Wiley.

Manton, Jonathan H., and Amblard, Pierre-Olivier. 2015. A Primer on Reproducing Kernel Hilbert Spaces. *Foundations and Trends in Signal Processing*, **8**(1–2), 1–126.
Markovsky, Ivan. 2011. *Low Rank Approximation: Algorithms, Implementation, Applications*. Springer.
Maybeck, Peter S. 1979. *Stochastic Models, Estimation, and Control*. Academic Press.
McCullagh, Peter, and Nelder, John A. 1989. *Generalized Linear Models*. CRC Press.
McEliece, Robert J., MacKay, David J. C., and Cheng, Jung-Fu. 1998. Turbo Decoding as an Instance of Pearl's "Belief Propagation" Algorithm. *IEEE Journal on Selected Areas in Communications*, **16**(2), 140–152.
Mika, Sebastian, Rätsch, Gunnar, Weston, Jason, Schölkopf, Bernhard, and Müller, Klaus-Robert. 1999. Fisher Discriminant Analysis with Kernels. Pages 41–48 of: *Proceedings of the Workshop on Neural Networks for Signal Processing*.
Minka, Thomas P. 2001a. *A Family of Algorithms for Approximate Bayesian Inference*. Ph.D. thesis, Massachusetts Institute of Technology.
Minka, Tom. 2001b. Automatic Choice of Dimensionality of PCA. In: *Advances in Neural Information Processing Systems*.
Mitchell, Tom. 1997. *Machine Learning*. McGraw-Hill.
Mnih, Volodymyr, Kavukcuoglu, Koray, and Silver, David, et al. 2015. Human-Level Control through Deep Reinforcement Learning. *Nature*, **518**, 529–533.
Moonen, Marc, and De Moor, Bart. 1995. *SVD and Signal Processing, III: Algorithms, Architectures and Applications*. Elsevier.
Moustaki, Irini, Knott, Martin, and Bartholomew, David J. 2015. *Latent-Variable Modeling*. American Cancer Society. Pages 1–10.
Müller, Andreas C., and Guido, Sarah. 2016. *Introduction to Machine Learning with Python: A Guide for Data Scientists*. O'Reilly Publishing.
Murphy, Kevin P. 2012. *Machine Learning: A Probabilistic Perspective*. MIT Press.
Neal, Radford M. 1996. *Bayesian Learning for Neural Networks*. Ph.D. thesis, Department of Computer Science, University of Toronto.
Neal, Radford M., and Hinton, Geoffrey E. 1999. A View of the EM Algorithm that Justifies Incremental, Sparse, and Other Variants. Pages 355–368 of: *Learning in Graphical Models*. MIT Press.
Nelsen, Roger. 2006. *An Introduction to Copulas*. Springer.
Nesterov, Yuri. 2018. *Lectures on Convex Optimization*. Springer.
Neumaier, Arnold. 1998. Solving Ill-Conditioned and Singular Linear Systems: A Tutorial on Regularization. *SIAM Review*, **40**, 636–666.
Nocedal, Jorge, and Wright, Stephen J. 2006. *Numerical Optimization*. Springer.
Nowozin, Sebastian, Gehler, Peter V., Jancsary, Jeremy, and Lampert, Christoph H. (eds). 2014. *Advanced Structured Prediction*. MIT Press.
O'Hagan, Anthony. 1991. Bayes-Hermite Quadrature. *Journal of Statistical Planning and Inference*, **29**, 245–260.
Ong, Cheng Soon, Mary, Xavier, Canu, Stéphane, and Smola, Alexander J. 2004. Learning with Non-Positive Kernels. In: *Proceedings of the International Conference on Machine Learning*.
Ormoneit, Dirk, Sidenbladh, Hedvig, Black, Michael J., and Hastie, Trevor. 2001. Learning and Tracking Cyclic Human Motion. In: *Advances in Neural Information Processing Systems*.
Page, Lawrence, Brin, Sergey, Motwani, Rajeev, and Winograd, Terry. 1999. *The PageRank Citation Ranking: Bringing Order to the Web*. Tech. rept. Stanford InfoLab.
Paquet, Ulrich. 2008. *Bayesian Inference for Latent Variable Models*. Ph.D. thesis, University of Cambridge.
Parzen, Emanuel. 1962. On Estimation of a Probability Density Function and Mode. *Annals of Mathematical Statistics*, **33**(3), 1065–1076.

©2024 M. P. Deisenroth, A. A. Faisal, C. S. Ong. Published by Cambridge University Press (2020).

Pearl, Judea. 1988. *Probabilistic Reasoning in Intelligent Systems: Networks of Plausible Inference*. Morgan Kaufmann.

Pearl, Judea. 2009. *Causality: Models, Reasoning and Inference*. 2nd edn. Cambridge University Press.

Pearson, Karl. 1895. Contributions to the Mathematical Theory of Evolution. II. Skew Variation in Homogeneous Material. *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences*, **186**, 343–414.

Pearson, Karl. 1901. On Lines and Planes of Closest Fit to Systems of Points in Space. *Philosophical Magazine*, **2**(11), 559–572.

Peters, Jonas, Janzing, Dominik, and Schölkopf, Bernhard. 2017. *Elements of* Causal *Inference: Foundations and Learning Algorithms*. MIT Press.

Petersen, Kaare B., and Pedersen, Michael S. 2012. *The Matrix Cookbook*. Tech. rept. Technical University of Denmark.

Platt, John C. 2000. Probabilistic Outputs for Support Vector Machines and Comparisons to Regularized Likelihood Methods. In: *Advances in Large Margin Classifiers*.

Pollard, David. 2002. *A User's Guide to Measure Theoretic Probability*. Cambridge University Press.

Polyak, Roman A. 2016. The Legendre Transformation in Modern Optimization. Pages 437–507 of: Goldengorin, B. (ed), *Optimization and Its Applications in Control* and *Data Sciences*. Springer.

Press, William H., Teukolsky, Saul A., Vetterling, William T., and Flannery, Brian P. 2007. *Numerical Recipes: The Art of Scientific Computing*. Cambridge University Press.

Proschan, Michael A., and Presnell, Brett. 1998. Expect the Unexpected from Conditional Expectation. *American Statistician*, **52**(3), 248–252.

Raschka, Sebastian, and Mirjalili, Vahid. 2017. *Python Machine Learning: Machine Learning and Deep Learning with Python, scikit-learn, and TensorFlow*. Packt Publishing.

Rasmussen, Carl E., and Ghahramani, Zoubin. 2001. Occam's Razor. In: *Advances* in *Neural Information Processing Systems*.

Rasmussen, Carl E., and Ghahramani, Zoubin. 2003. Bayesian Monte Carlo. In: *Advances in Neural Information Processing Systems*.

Rasmussen, Carl E., and Williams, Christopher K. I. 2006. *Gaussian Processes* for *Machine Learning*. MIT Press.

Reid, Mark, and Williamson, Robert C. 2011. Information, Divergence and Risk for Binary Experiments. *Journal of Machine Learning Research*, **12**, 731–817.

Rifkin, Ryan M., and Lippert, Ross A. 2007. Value Regularization and Fenchel Duality. *Journal of Machine Learning Research*, **8**, 441–479.

Rockafellar, Ralph T. 1970. *Convex Analysis*. Princeton University Press.

Rogers, Simon, and Girolami, Mark. 2016. *A First Course in Machine Learning*. Chapman and Hall/CRC.

Rosenbaum, Paul R. 2017. *Observation and Experiment: An Introduction to* Causal *Inference*. Harvard University Press.

Rosenblatt, Murray. 1956. Remarks on Some Nonparametric Estimates of a Density Function. *Annals of Mathematical Statistics*, **27**(3), 832–837.

Roweis, Sam T. 1998. EM Algorithms for PCA and SPCA. Pages 626–632 of: *Advances in Neural Information Processing Systems*.

Roweis, Sam T., and Ghahramani, Zoubin. 1999. A Unifying Review of Linear Gaussian Models. *Neural Computation*, **11**(2), 305–345.

Roy, Anindya, and Banerjee, Sudipto. 2014. *Linear Algebra and Matrix Analysis* for *Statistics*. Chapman and Hall/CRC.

Rubinstein, Reuven Y., and Kroese, Dirk P. 2016. *Simulation and the Monte* Carlo *Method*. Wiley.

Ruffini, Paolo. 1799. *Teoria Generale delle Equazioni, in cui si Dimostra Impossibile la Soluzione Algebraica delle Equazioni Generali di Grado Superiore al Quarto*. Stamperia di S. Tommaso d'Aquino.

Rumelhart, David E., Hinton, Geoffrey E., and Williams, Ronald J. 1986. Learning Representations by Back-Propagating Errors. *Nature*, **323**(6088), 533–536.

Sæmundsson, Steindór, Hofmann, Katja, and Deisenroth, Marc P. 2018. Meta Reinforcement Learning with Latent Variable Gaussian Processes. In: *Proceedings of the Conference on Uncertainty in Artificial Intelligence*.

Saitoh, Saburou. 1988. *Theory of Reproducing Kernels and its Applications*. Longman Scientific and Technical.

Särkkä, Simo. 2013. *Bayesian Filtering and Smoothing*. Cambridge University Press.

Schölkopf, Bernhard, and Smola, Alexander J. 2002. *Learning with Kernels – Support Vector Machines, Regularization, Optimization, and Beyond*. MIT Press.

Schölkopf, Bernhard, Smola, Alexander J., and Müller, Klaus-Robert. 1997. Kernel Principal Component Analysis. In: *Proceedings of the International Conference on Artificial Neural Networks*.

Schölkopf, Bernhard, Smola, Alexander J., and Müller, Klaus-Robert. 1998. Nonlinear Component Analysis as a Kernel Eigenvalue Problem. *Neural Computation*, **10**(5), 1299–1319.

Schölkopf, Bernhard, Herbrich, Ralf, and Smola, Alexander J. 2001. A Generalized Representer Theorem. In: *Proceedings of the International Conference on Computational Learning Theory*.

Schwartz, Laurent. 1964. Sous Espaces Hilbertiens d'Espaces Vectoriels Topologiques et Noyaux Associés. *Journal d'Analyse Mathématique*, **13**, 115–256.

Schwarz, Gideon E. 1978. Estimating the Dimension of a Model. *Annals of Statistics*, **6**(2), 461–464.

Shahriari, Bobak, Swersky, Kevin, Wang, Ziyu, Adams, Ryan P., and De Freitas, Nando. 2016. Taking the Human out of the Loop: A Review of Bayesian Optimization. *Proceedings of the IEEE*, **104**(1), 148–175.

Shalev-Shwartz, Shai, and Ben-David, Shai. 2014. *Understanding Machine Learning: From Theory to Algorithms*. Cambridge University Press.

Shawe-Taylor, John, and Cristianini, Nello. 2004. *Kernel Methods for Pattern Analysis*. Cambridge University Press.

Shawe-Taylor, John, and Sun, Shiliang. 2011. A Review of Optimization Methodologies in Support Vector Machines. *Neurocomputing*, **74**(17), 3609–3618.

Shental, Ori, Siegel, Paul H., Wolf, Jack K., Bickson, Danny, and Dolev, Danny. 2008. Gaussian Belief Propagation Solver for Systems of Linear Equations. Pages 1863–1867 of: *Proceedings of the International Symposium on Information Theory*.

Shewchuk, Jonathan R. 1994. *An Introduction to the Conjugate Gradient Method without the Agonizing Pain*.

Shi, Jianbo, and Malik, Jitendra. 2000. Normalized Cuts and Image Segmentation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, **22**(8), 888–905.

Shi, Qinfeng, Petterson, James, Dror, Gideon, Langford, John, Smola, Alexander J., and Vishwanathan, S. V. N. 2009. Hash Kernels for Structured Data. *Journal of Machine Learning Research*, 2615–2637.

Shiryayev, Albert N. 1984. *Probability*. Springer.

Shor, Naum Z. 1985. *Minimization Methods for Non-Differentiable Functions*. Springer.

Shotton, Jamie, Winn, John, Rother, Carsten, and Criminisi, Antonio. 2006. TextonBoost: Joint Appearance, Shape and Context Modeling for Multi-Class Object Recognition and Segmentation. In: *Proceedings of the European Conference on Computer Vision*.

Smith, Adrian F. M., and Spiegelhalter, David. 1980. Bayes Factors and Choice Criteria for Linear Models. *Journal of the Royal Statistical Society B*, **42**(2), 213–220.

©2024 M. P. Deisenroth, A. A. Faisal, C. S. Ong. Published by Cambridge University Press (2020).

Snoek, Jasper, Larochelle, Hugo, and Adams, Ryan P. 2012. Practical Bayesian Optimization of Machine Learning Algorithms. In: *Advances in Neural Information Processing Systems*.

Spearman, Charles. 1904. "General Intelligence," Objectively Determined and Measured. *American Journal of Psychology*, **15**(2), 201–292.

Sriperumbudur, Bharath K., Gretton, Arthur, Fukumizu, Kenji, Schölkopf, Bernhard, and Lanckriet, Gert R. G. 2010. Hilbert Space Embeddings and Metrics on Probability Measures. *Journal of Machine Learning Research*, **11**, 1517–1561.

Steinwart, Ingo. 2007. How to Compare Different Loss Functions and Their Risks. *Constructive Approximation*, **26**, 225–287.

Steinwart, Ingo, and Christmann, Andreas. 2008. *Support Vector Machines*. Springer.

Stoer, Josef, and Burlirsch, Roland. 2002. *Introduction to Numerical Analysis*. Springer.

Strang, Gilbert. 1993. The Fundamental Theorem of Linear Algebra. *The American Mathematical Monthly*, **100**(9), 848–855.

Strang, Gilbert. 2003. *Introduction to Linear Algebra*. Wellesley-Cambridge Press.

Stray, Jonathan. 2016. *The Curious Journalist's Guide to Data*. Tow Center for Digital Journalism at Columbia's Graduate School of Journalism.

Strogatz, Steven. 2014. Writing about Math for the Perplexed and the Traumatized. *Notices of the American Mathematical Society*, **61**(3), 286–291.

Sucar, Luis E., and Gillies, Duncan F. 1994. Probabilistic Reasoning in High-Level Vision. *Image and Vision Computing*, **12**(1), 42–60.

Szeliski, Richard, Zabih, Ramin, and Scharstein, Daniel, et al. 2008. A Comparative Study of Energy Minimization Methods for Markov Random Fields with Smoothness-Based Priors. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, **30**(6), 1068–1080.

Tandra, Haryono. 2014. The Relationship between the Change of Variable Theorem and the Fundamental Theorem of Calculus for the Lebesgue Integral. *Teaching of Mathematics*, **17**(2), 76–83.

Tenenbaum, Joshua B., De Silva, Vin, and Langford, John C. 2000. A Global Geometric Framework for Nonlinear Dimensionality Reduction. *Science*, **290**(5500), 2319–2323.

Tibshirani, Robert. 1996. Regression Selection and Shrinkage via the Lasso. *Journal of the Royal Statistical Society B*, **58**(1), 267–288.

Tipping, Michael E., and Bishop, Christopher M. 1999. Probabilistic Principal Component Analysis. *Journal of the Royal Statistical Society: Series B*, **61**(3), 611–622.

Titsias, Michalis K., and Lawrence, Neil D. 2010. Bayesian Gaussian Process Latent Variable Model. In: *Proceedings of the International Conference on Artificial Intelligence and Statistics*.

Toussaint, Marc. 2012. *Some Notes on Gradient Descent*. https://ipvs.informatik.uni-stuttgart.de/mlr/marc/notes/gradientDescent.pdf.

Trefethen, Lloyd N., and Bau III, David. 1997. *Numerical Linear Algebra*. SIAM.

Tucker, Ledyard R. 1966. Some Mathematical Notes on Three-Mode Factor Analysis. *Psychometrika*, **31**(3), 279–311.

Vapnik, Vladimir N. 1998. *Statistical Learning Theory*. Wiley.

Vapnik, Vladimir N. 1999. An Overview of Statistical Learning Theory. *IEEE Transactions on Neural Networks*, **10**(5), 988–999.

Vapnik, Vladimir N. 2000. *The Nature of Statistical Learning Theory*. Springer.

Vishwanathan, S. V. N., Schraudolph, Nicol N., Kondor, Risi, and Borgwardt, Karsten M. 2010. Graph Kernels. *Journal of Machine Learning Research*, **11**, 1201–1242.

von Luxburg, Ulrike, and Schölkopf, Bernhard. 2011. Statistical Learning Theory: Models, Concepts, and Results. Pages 651–706 of: D. M. Gabbay, S. Hartmann, J. Woods (ed), *Handbook of the History of Logic*, vol. 10. Elsevier.

Wahba, Grace. 1990. *Spline Models for Observational Data*. Society for Industrial and Applied Mathematics.

Walpole, Ronald E., Myers, Raymond H., Myers, Sharon L., and Ye, Keying. 2011. *Probability and Statistics for Engineers and Scientists*. Prentice Hall.

Wasserman, Larry. 2004. *All of Statistics*. Springer.

Wasserman, Larry. 2007. *All of Nonparametric Statistics*. Springer.

Whittle, Peter. 2000. *Probability via Expectation*. Springer.

Wickham, Hadley. 2014. Tidy Data. *Journal of Statistical Software*, **59**, 1–23.

Williams, Christopher K. I. 1997. Computing with Infinite Networks. In: *Advances in Neural Information Processing Systems*.

Yu, Yaoliang, Cheng, Hao, Schuurmans, Dale, and Szepesvári, Csaba. 2013. Characterizing the Representer Theorem. In: *Proceedings of the International Conference on Machine Learning*.

Zadrozny, Bianca, and Elkan, Charles. 2001. Obtaining Calibrated Probability Estimates from Decision Trees and Naive Bayesian Classifiers. In: *Proceedings of the International Conference on Machine Learning*.

Zhang, Haizhang, Xu, Yuesheng, and Zhang, Jun. 2009. Reproducing Kernel Banach Spaces for Machine Learning. *Journal of Machine Learning Research*, **10**, 2741–2775.

Zia, Royce K. P., Redish, Edward F., and McKay, Susan R. 2009. Making Sense of the Legendre Transform. *American Journal of Physics*, **77**(614), 614–622.

©2024 M. P. Deisenroth, A. A. Faisal, C. S. Ong. Published by Cambridge University Press (2020).